

UNIVERZA V LJUBLJANI
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO

Tomi Božak

**Grafovske nevronske mreže za
klasifikacijo čustvenih oznak iz podatkov
sledilnika pogleda**

DIPLOMSKO DELO

UNIVERZITETNI ŠTUDIJSKI PROGRAM
PRVE STOPNJE
RAČUNALNIŠTVO IN INFORMATIKA

MENTOR: izr. prof. dr. Lovro Šubelj
SOMENTOR: doc. dr. Gašper Slapničar

Ljubljana, 2026

To delo je ponujeno pod licenco *Creative Commons Priznanje avtorstva-Deljenje pod enakimi pogoji 2.5 Slovenija* (ali novejšo različico). To pomeni, da se tako besedilo, slike, grafi in druge sestavine dela kot tudi rezultati diplomskega dela lahko prosto distribuirajo, reproducirajo, uporabljajo, priobčujejo javnosti in predelujejo, pod pogojem, da se jasno in vidno navede avtorja in naslov tega dela in da se v primeru spremembe, preoblikovanja ali uporabe tega dela v svojem delu, lahko distribuira predelava le pod licenco, ki je enaka tej. Podrobnosti licence so dostopne na spletni strani creativecommons.si ali na Inštitutu za intelektualno lastnino, Streliška 1, 1000 Ljubljana.



Izvorna koda diplomskega dela, njeni rezultati in v ta namen razvita programska oprema je ponujena pod licenco GNU General Public License, različica 3 (ali novejša). To pomeni, da se lahko prosto distribuira in/ali predeluje pod njenimi pogoji. Podrobnosti licence so dostopne na spletni strani <http://www.gnu.org/licenses/>.

Besedilo je oblikovano z urejevalnikom besedil $\text{\LaTeX}$.

Kandidat: Tomi Božak

Naslov: Grafovske nevronske mreže za klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda

Vrsta naloge: Diplomaska naloga na univerzitetnem programu prve stopnje

Mentor: izr. prof. dr. Lovro Šubelj

Somentor: doc. dr. Gašper Slapničar

Opis:

TODO: Besedilo teme diplomskega dela prepisi iz študijskega informacijskega sistema.

Title: Graph Neural Networks for Classification of Emotional Labels from Eye-Tracking Data

Description:

TODO: Prevedi uradni opis teme diplomskega dela iz STUDIS-a.

TODO: Zahvaliti se IJS, da so omogočili uporabo njihove infrastrukture. Zahvaliti se mentorju Lovru za nasvete pri razvoju GNN in somentorju za nasvete pri raziskovalnem delu. Zahvaliti se tudi Mitji Luštreku za nasvete pri raziskovalnem delu. (tudi FRIju in družini al je too much?)

TODO: Posvetilo lahko odstraniš, če ga ne
želiš.

Kazalo

Povzetek

Abstract

1	Uvod	1
1.1	Raziskovalni problem	1
1.1.1	Raziskovalna vprašanja	2
1.2	Doprinosi naloge	2
1.3	Struktura naloge	3
2	Teoretično ozadje	5
2.1	Grafi	5
2.1.1	Osnovna definicija grafa	5
2.1.2	Usmerjeni, uteženi in heterogeni grafi	5
2.2	Grafske nevronske mreže	6
2.2.1	Posredovanje sporočil	6
2.2.2	Klasifikacija na ravni grafa	7
2.2.3	Prekomerno glajenje in kolaps predstavitev	8
2.3	Podatki sledilnika pogleda	8
2.4	Čustvena stanja: valenca in vzburjenost	8
2.4.1	Dimenzijski opis čustev	8
2.4.2	Binarna klasifikacija	9

3	Sorodna dela	11
3.1	Podatki sledilnika pogleda pri klasifikaciji čustvenih oznak . . .	11
3.2	Podatkovna zbirka MAHNOB-HCI	12
3.3	Grafovske nevronske mreže za časovno-prostorske podatke . .	12
3.4	Učenje predstavitev iz signalov	13
3.5	Položaj te naloge glede na sorodna dela	14
4	Podatki in predobdelava	15
4.1	Podatkovna zbirka MAHNOB-HCI	15
4.2	Predhodni poskus z zbirko eSEEd_v2	16
4.3	Ciljne oznake	16
4.4	Priprava vhodnih signalov	17
4.4.1	Skupine signalov	17
4.4.2	Čiščenje podatkov	18
4.5	Normalizacija	20
4.6	Segmentacija v časovna okna	20
4.7	Povzetek predobdelave	21
5	Grafovska predstavitev podatkov sledilnika pogleda	23
5.1	Vozlišča	23
5.1.1	Definicija	23
5.1.2	Vektor značilk vozlišča	24
5.2	Relacije	24
5.2.1	Zakaj ločimo relacije	24
5.2.2	Časovne povezave	25
5.2.3	Prostorske povezave	25
5.2.4	Fiksacijske povezave	26
5.2.5	Značilke povezav	28
5.3	Grafovska konstrukcija po množicah signalov	29
5.4	Statistika konstruiranih grafov	31

6	Primerjani modeli	33
6.1	Pregled primerjanih pristopov	33
6.2	Negrafovski osnovni modeli	34
6.2.1	Izhodiščna klasifikatorja	34
6.2.2	Klasični modeli strojnega učenja	34
6.3	Zamrznjeni prednaučeni predstavitveni modeli	35
6.3.1	GazeMAE	36
6.3.2	MOMENT	36
6.3.3	Združene predstavitve GazeMAE in MOMENT	36
6.4	Grafovski modeli	37
6.4.1	Skupni cevovod grafovskih modelov	37
6.4.2	GCN	38
6.4.3	HeteroGCN-mean	38
6.4.4	HeteroGCN-MLP	39
6.4.5	HeteroGCN-MLP-w	39
6.4.6	Izbira grafovske konvolucije	39
6.5	Povzetek poglavja	40
7	Eksperimentalni protokol	43
7.1	Zasnova glavne primerjave	43
7.2	Validacijski protokol	44
7.2.1	7-kratno prečno preverjanje po subjektih	44
7.2.2	Predhodna preverjanja z LOO po subjektih	44
7.3	Nastavitve učenja in hiperparametri	45
7.4	Metrike vrednotenja	45
7.5	Spremljanje učenja	46
8	Rezultati	47
8.1	Glavni rezultati klasifikacije	47
8.2	Velikost in računska zahtevnost modelov	49
9	Diskusija	51

10 Zaključek	53
A Dodatni rezultati	55
A.1 Preslikava čustvenih oznak v valenco	57
A.2 Razširjeni rezultati binarne klasifikacije valence	58
A.3 Ujemanje izpeljanih oznak s samoocenami	60
A.4 Izbira tipa grafovske konvolucije	60
B Hiperparametri	63
B.1 Hiperparametri modelov	64
B.2 Strojna in programska oprema	64
B.3 Naučene uteži povezav	64
C Dodatne vizualizacije grafov	67
D Diagnostika predstavitev modela	71
D.1 Diagnostika prekomernega glajenja	72
E Zgodovinski poskusi na eSEEd_v2	73
Literatura	75

Seznam uporabljenih kratic

kratica	angleško	slovensko
AUC	area under the curve	ploščina pod krivuljo
F1	F1 score	mera F1
GAT	graph attention network	grafovska pozornostna mreža
GCN	graph convolutional network	grafovska konvolucijska mreža
GFM	graph foundation model	grafovski temeljni model
GNN	graph neural network	grafovska nevronska mreža
LOO	leave-one-out	izpusti enega
LORO	leave-one-recording-out	izpusti en posnetek
LOSO	leave-one-subject-out	izpusti en subjekt
MLP	multilayer perceptron	večslojni perceptron
SVM	support vector machine	metoda podpornih vektorjev

Povzetek

Naslov: Grafovske nevronske mreže za klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda

Avtor: Tomi Božak

V diplomski nalogi raziskujemo uporabo grafovskih nevronske mreže za prepoznavo afektivnih stanj iz podatkov sledilnika pogleda.

TODO: Povzetek prepisati po končnih rezultatih: glavna naloga naj bo binarna klasifikacija, glavna primerjava pa modeli pri množicah *samo pogled*, *pogled in zenici* in *vsii signali*; **GazeMAE** omeni kot referenco za množico *samo pogled*, **MOMENT**/*samo zenici* samo, če bo dejansko izveden.

TODO:

- Povzetek sme povzeti grafovsko predstavitev v enem stavku, ne sme pa ponavljati definicij grafa, heterogenosti ali uteži povezav.
- Uporabi enako terminologijo kot v glavnem besedilu: *časovno-prostorski graf* in *časovno-prostorska grafovska predstavitev*, ne mešaj s *prostorsko-časovni graf*.

Osrednji metodološki problem je predstavitev časovnega okna meritev pogleda kot prostorsko-časovnega grafa, v katerem vozlišča predstavljajo posamezne meritve, povezave pa opisujejo časovno bližino, prostorsko bližino in pripadnost isti fiksaciji. Na takšni predstavitvi razvijemo in ovrednotimo grafovski model za večrazredno klasifikacijo valence in vzburjenosti (ang. arousal).

Eksperimentalno evalvacijo izvedemo na podatkovni zbirki MAHNOB-HCI z dvema validacijskima protokoloma: delitvijo po subjektih in delitvijo po posnetkih. Grafovske modele primerjamo z negrafovskimi osnovnimi modeli ter s predstavitvijo **GazeMAE** kot predstavnikom sodobnih metod učenja predstavitev iz podatkov pogleda. Poleg končnih klasifikacijskih rezultatov analiziramo tudi vpliv posameznih komponent grafovske konstrukcije, vključno s časovnimi povezavami, prostorskimi povezavami, fiksacijskimi povezavami, značilkami zenice in utežmi povezav.

Glavno raziskovalno vprašanje naloge je, ali lahko prostorsko-časovna grafovska predstavitev oken meritev sledilnika pogleda izboljša klasifikacijo afektivnih stanj v primerjavi z negrafovskimi osnovnimi modeli na enakih vhodnih oknih.

Ključne besede: grafovske nevronske mreže, prostorsko-časovni grafi, sledilnik pogleda, prepoznavna čustev, afektivno računalništvo, strojno učenje.

Abstract

Title: Graph Neural Networks for Classification of Emotional Labels from Eye-Tracking Data

Author: Tomi Božak

This thesis investigates the use of graph neural networks for affective state recognition from eye-tracking data.

TODO: Rewrite the abstract after the final experiments: the main task should be binary classification, and the main comparison should cover models under the *gaze*, *gaze+pupil*, and *all* input sets; describe **GazeMAE** as a *gaze-only* reference and mention **MOMENT**/*pupil-only* only if the experiment is actually completed.

The central methodological problem is the representation of a temporal window of gaze measurements as a spatio-temporal graph, where nodes correspond to individual samples and edges encode temporal proximity, spatial proximity, and shared fixation membership. Based on this representation, we develop and evaluate a graph-based model for three-class classification of valence and arousal.

The experimental evaluation is performed on the MAHNOB-HCI dataset using two validation protocols: leave-one-subject-out and leave-one-recording-out evaluation. Graph-based models are compared against non-graph machine learning baselines and against **GazeMAE** as a representative of modern gaze representation learning methods. In addition to final classification performance, we analyze the contribution of individual components of the graph

construction, including temporal edges, spatial edges, fixation edges, pupil features, and edge weights.

The main research question of the thesis is whether a spatio-temporal graph representation of eye-tracking windows can improve affective state classification compared to non-graph models trained on the same input windows.

Keywords: graph neural networks, spatio-temporal graphs, eye tracking, emotion recognition, affective computing, machine learning.

Poglavje 1

Uvod

Za učenje iz podatkov, kjer niso pomembne zgolj lastnosti posameznih elementov, ampak tudi odnosi med njimi, lahko uporabimo grafske nevronske mreže (GNN) [4, 9]. Primer takšnih podatkov so podatki sledilnika pogleda. Meritvam sledilnika pogleda lahko smiselno določimo časovne in prostorske odnose in jim s tem priredimo časovno-prostorski graf. Na tem grafu se z grafsko nevronske mreže učimo predstavitev vozlišč in grafov, ki jih uporabimo za klasifikacijo grafa. Podatki, uporabljeni v tej nalogi, imajo ciljne oznake valence, izpeljane iz samoocen udeležencev, zato GNN učimo binarno klasifikacijo valence, rezultate pa primerjamo z rezultati uveljavljenih negrafskih pristopov. Eksperimentalno primerjavo izvedemo na štirih množicah signalov: samo koordinatah pogleda (*samo pogled*), samo velikostih zenic (*samo zenici*), združenih koordinatah pogleda in velikostih zenic (*pogled in zenici*) ter vseh razpoložljivih signalih (*vsi signali*).

1.1 Raziskovalni problem

Raziskovalni problem naloge je zasnova, implementacija in ovrednotenje grafske predstavitve podatkov sledilnika pogleda za klasifikacijo valence.

1.1.1 Raziskovalna vprašanja

Glavno raziskovalno vprašanje je:

RV1: Kakšna je klasifikacijska uspešnost grafovske nevronske mreže za binarno klasifikacijo valence iz podatkov sledilnika pogleda v primerjavi s klasifikacijsko uspešnostjo uveljavljenih negrafovskih pristopov?

Dodatna podvprašanja so:

PV1: Kako podatke sledilnika pogleda smiselno predstaviti kot časovno-prostorski graf?

PV2: Kako se klasifikacijska uspešnost modelov razlikuje med posameznimi množicami signalov sledilnika pogleda?

PV3: Kako se klasifikacijska uspešnost grafovskih modelov spreminja z večjo arhitekturno kompleksnostjo?

PV4: Kakšno je razmerje med klasifikacijsko uspešnostjo ter velikostjo in računsko zahtevnostjo primerjanih modelov?

1.2 Doprinosi naloge

Glavni doprinosi diplomske naloge so:

1. zasnova časovno-prostorske grafovske predstavitve časovnih oken podatkov sledilnika pogleda;
2. ovrednotenje arhitekturne lestvice grafovskih modelov za klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda;
3. primerjava klasifikacijske uspešnosti pri različnih množicah signalov;
4. primerjava grafovskih modelov z negrafovskimi osnovnimi modeli in zamrznjenimi prednaučenimi predstavitvenimi modeli.

[Ali rabimo te doprinose ali raje odstranimo, glede na to da se samo ponovijo raziskovalna vprašanja?]

1.3 Struktura naloge

V poglavju 2 predstavimo teoretično ozadje grafov, grafovskih nevronske mreže, podatkov sledilnika pogleda in afektivnega računalništva. V poglavju 3 predstavimo sorodna dela, vključno z uporabljenimi podatkovno zbirko MAHNOB-HCI in metodami učenja predstavitev iz podatkov pogleda. Poglavje 4 opisuje uporabljene podatke, ciljne oznake in predobdelavo. V poglavju 5 opišemo konstrukcijo časovno-prostorskega grafa. Poglavje 6 predstavi uporabljene modele. V poglavju 7 opišemo eksperimentalni protokol, v poglavju 8 pa rezultate glavne primerjave modelov na različnih množicah signalov. Poglavje 9 vsebuje interpretacijo rezultatov, omejitve in možnosti nadaljnjega dela. Nalogo sklenemo v poglavju 10.

Poglavje 2

Teoretično ozadje

V tem poglavju predstavimo metodološke pojme, ki so potrebni za razumevanje grafov, grafovskih nevronske mreže, podatkov sledilnika pogleda ter valence.

2.1 Grafi

2.1.1 Osnovna definicija grafa

Graf definiramo kot

$$G = (V, E), \quad (2.1)$$

kjer je V množica vozlišč, $E \subseteq V \times V$ pa množica povezav med vozlišči. Vozlišča praviloma vsebujejo značilke $\mathbf{x}_v$, ki jih zapišemo v matriko

$$X \in \mathbb{R}^{|V| \times d}, \quad (2.2)$$

kjer je d število značilk posameznega vozlišča. Povezavo med vozliščema i in j označimo z $e_{ij} \in E$.

2.1.2 Usmerjeni, uteženi in heterogeni grafi

V usmerjenih grafih ima povezava določeno izvorno in ponorno vozlišče, zato velja $e_{ij} \neq e_{ji}$. V neusmerjenih grafih povezave nimajo smeri, zato velja

$$e_{ij} = e_{ji}.$$

Povezave lahko vsebujejo tudi uteži. Utež povezave med vozliščema i in j označimo z w_{ij} . Za neutežene povezave si lahko predstavljamo, da imajo utež $w_{ij} = 1$. Če imajo povezave več uteži, jih zapišemo kot vektor $\mathbf{e}_{ij}$ [4].

Homogeni in heterogeni grafi

Homogeni graf je graf, ki ne loči različnih vrst vozlišč in povezav. Heterogeni graf vsebuje vsaj dve različni vrsti vozlišč ali povezav. V tej nalogi uporabljamo heterogeno grafovsko predstavitev, saj ločimo več tipov povezav.

2.2 Grafovske nevronske mreže

Grafovske nevronske mreže so razred nevronske mreže, namenjen učenju nad podatki, ki jih naravno predstavimo z grafom [4, 9, 13]. Cilj GNN je naučiti se predstavitev vozlišč, povezav ali celotnega grafa tako, da model pri izračunu predstavitve posameznega vozlišča upošteva tudi njegovo lokalno okolico.

2.2.1 Posredovanje sporočil

Osnovna ideja GNN je *posredovanje sporočil* [4]. Vsako vozlišče v posamezni plasti prejme informacije od svojih sosedov, jih agregira in na podlagi zbranih informacij posodobi svojo predstavitev.

Splošna oblika plasti

Splošno plast posredovanja sporočil lahko zapišemo kot

$$\mathbf{h}_v^{(k)} = \phi^{(k)} \left(\mathbf{h}_v^{(k-1)}, \bigoplus_{u \in \mathcal{N}(v)} \psi^{(k)}(\mathbf{h}_v^{(k-1)}, \mathbf{h}_u^{(k-1)}, \mathbf{e}_{uv}) \right), \quad (2.3)$$

kjer je $\mathcal{N}(v)$ množica sosedov vozlišča v , $\psi^{(k)}$ funkcija sporočila, $\oplus$ agregacijska funkcija, $\phi^{(k)}$ funkcija posodobitve, $\mathbf{h}_v^{(k)}$ pa predstavitev vozlišča v v plasti k .

Posredovanje sporočil v heterogenih grafih

Pri heterogenem grafu, kjer povezave razdelimo po tipih oziroma relacijah $r \in \mathcal{R}$, namesto ene same množice sosedov obravnavamo množice $\mathcal{N}_r(v)$, ki vsebujejo sosede vozlišča v po relaciji r . Sporočila se najprej agregirajo ločeno znotraj posamezne relacije:

$$\mathbf{m}_{v,r}^{(k)} = \bigoplus_{u \in \mathcal{N}_r(v)} \psi_r^{(k)}(\mathbf{h}_u^{(k-1)}, \mathbf{e}_{uv}). \quad (2.4)$$

Pri tem je $\psi_r^{(k)}$ funkcija sporočila za relacijo r , $\mathbf{m}_{v,r}^{(k)}$ pa agregirano sporočilo, ki ga vozlišče v prejme po tej relaciji v plasti k . Relacijska sporočila $\mathbf{m}_{v,r}^{(k)}$ se nato združijo v skupno sporočilo za vozlišče. Združevanje relacij je lahko preprosta vsota ali povprečje, lahko pa vključuje konkatencijo oziroma naučeno fuzijo relacijskih predstavitev.

Agregacijska funkcija

Agregacijska funkcija mora biti praviloma invariantna na vrstni red sosedov, saj graf v splošnem nima naravne ureditve vozlišč. Zato se pogosto uporabljajo operacije, kot so vsota, povprečje ali maksimum. Ta lastnost omogoča, da ista GNN plast deluje na grafih različnih velikosti.

2.2.2 Klasifikacija na ravni grafa

Če želimo napovedati oznako celotnega časovnega okna, lahko nalogo obravnavamo kot klasifikacijo grafa. Po več plasteh grafovske nevronske mreže dobimo končne predstavitve vozlišč $\mathbf{h}_v^{(K)}$, ki jih združimo v predstavitev celotnega grafa:

$$\mathbf{h}_G = \text{READOUT}(\{\mathbf{h}_v^{(K)} : v \in V\}). \quad (2.5)$$

Funkcija READOUT je agregacijska funkcija na ravni grafa. Pogoste izbire so povprečje, vsota, maksimum ali združevanje s pozornostjo. Predstavitev grafa $\mathbf{h}_G$ nato uporabimo v klasifikacijski glavi, ki napove razred celotnega grafa.

2.2.3 Prekomerno glajenje in kolaps predstavitev

Pri grafovskih nevronske mrežah lahko več zaporednih agregacij povzroči, da si predstavitve vozlišč postanejo preveč podobne. Ta pojav imenujemo prekomerno glajenje. V praksi se lahko pokaže kot zmanjšanje variance predstavitev, visoka medsebojna podobnost vozliščnih vektorjev in skoraj konstantni izhodi klasifikacijske glave.

Zato med treniranjem in evalvacijo modelov spremljamo statistike predstavitev na različnih delih modela. Varianca predstavitev kaže, ali model še ohranja razlike med vozlišči in grafi. Kosinusna podobnost pokaže, ali predstavitve postajajo usmerjene v podobno smer. Razpon logitov pa pokaže, ali klasifikacijska glava proizvaja dovolj raznolike napovedi ali se približuje skoraj konstantnemu izhodu.

2.3 Podatki sledilnika pogleda

Sledilnik pogleda je naprava, ki meri, kam v prostoru ali na zaslonu oseba usmerja pogled. Poleg lokacije pogleda lahko meri tudi velikost zenic, ki jo običajno opišemo s premerom zenice. Signal pogleda navadno opišemo s koordinatama x in y na zaslonu. Iz dinamike teh dveh signalov nekateri sledilniki zaznavajo in poročajo tudi informacije o fiksacijah, sakadah in mežikih, ki nas v tej domeni pogosto zanimajo. Meritve se izvajajo zaporedno z določeno vzorčno frekvenco, ki je odvisna od zmogljivosti naprave in namena uporabe. Pogoste vzorčne frekvence raziskovalnih sledilnikov pogleda so 60 Hz, 100 Hz, 500 Hz in 1000 Hz [10, 12].

2.4 Čustvena stanja: valenca in vzburjenost

2.4.1 Dimenzijski opis čustev

Čustvena stanja pogosto opisujemo z dimenzijama valence in vzburjenosti. Valenca opisuje prijetnost oziroma neprijetnost čustvenega odziva, vzburjenost

pa stopnjo aktivacije odziva [11].

2.4.2 Binarna klasifikacija

V uporabljeni podatkovni zbirki MAHNOB-HCI so po ogledu posnetkov na voljo številске samoocene valence in vzburjenosti ter udeleženceve samoocene diskretnega čustvenega razreda, kot so žalost, jeza, strah in druge [11]. V tej nalogi se omejimo na binarno klasifikacijo valence, pri čemer razrede določimo po vzoru izvirnega članka podatkovne zbirke MAHNOB-HCI; natančen postopek priprave ciljnih oznak opišemo v poglavju 4. Vzburjenosti v glavni nalogi ne obravnavamo, ker se izpeljani razredi v uporabljenem podnaboru slabše ujemajo s samoocenami kot pri valenci. Podrobnejša razlaga tega neskladja je podana v dodatku A.3.

Poglavje 3

Sorodna dela

To poglavje umešča nalogo med obstoječe pristope za delo s podatki sledilnika pogleda. Sorodna dela v tem poglavju obravnavamo z vidika vprašanja, kako podatke sledilnika pogleda predstaviti za klasifikacijo čustvenih oznak. Najprej povzamemo uporabo podatkov sledilnika pogleda pri klasifikaciji čustvenih oznak in vlogo podatkovne zbirke MAHNOB-HCI. Nato predstavimo grafovske nevronske mreže za časovne vrste in časovno-prostorske podatke, saj je osrednji del naloge pretvorba časovnega okna meritev v graf. Na koncu povzamemo še učenje predstavitev iz zaporedij meritev pogleda ter položaj te naloge glede na sorodna dela.

3.1 Podatki sledilnika pogleda pri klasifikaciji čustvenih oznak

Podatki sledilnika pogleda se med drugim uporabljajo kot vedenjski in psihofiziološki signal pri nalogah prepoznavе čustvenih stanj. V literaturi se pojavljajo različne ciljne naloge: klasifikacija diskretnih čustvenih stanj, regresija valence in vzburjenosti, binarna klasifikacija valence in vzburjenosti ter druge [10, 12].

Med pogosto uporabljenimi signali so velikost zenic, dinamika pogleda, fiksacije, sakade, mežiki in oddaljenost oči od sledilnika pogleda. Vhod v

klasične napovedne modele za čustvena stanja so pogosto ročno oblikovane statistične značilke, kot so povprečja, variance in ekstremi časovnih oken meritev velikosti zenic, signalov pogleda, fiksacij, sakad in mežikov [2, 10, 12]. Novejši modeli, na primer samokodirniki, pa kot vhod vzamejo tudi časovna okna manj agregiranih signalov pogleda, na primer zaporedja koordinat pogleda, iz katerih lahko izpeljejo tudi dinamiko gibanja pogleda [1].

3.2 Podatkovna zbirka MAHNOB-HCI

Podatkovna zbirka MAHNOB-HCI je večmodalna zbirka za prepoznavanje čustev in implicitno označevanje multimedijskih vsebin [11]. Vsebuje odzive udeležencev na čustvene video posnetke ter sinhrono zajete signale, med katerimi so video obraza, zvok, fiziološki signali, elektroencefalogram (EEG) in signali sledilnika pogleda. V tej nalogi uporabljamo samo signale sledilnika pogleda, ker je osrednji cilj raziskati grafovsko predstavitev tega tipa časovnega signala.

Pregledali in preizkusili smo več podatkovnih zbirk (na primer eSEEd_v2). MAHNOB-HCI se je za našo nalogo izkazal kot najprimernejši predvsem zaradi kakovosti in količine podatkov ter dobre dokumentacije.

Za to nalogo je pomemben predvsem del zbirke z odzivi na čustvene video posnetke, kjer so poleg signalov sledilnika pogleda na voljo tudi samoocene udeležencev. Te oznake uporabimo kot ciljno nalogo za evalvacijo predstavitev podatkov sledilnika pogleda; podrobno pripravo ciljnih oznak opišemo v poglavju 4.

3.3 Grafovske nevronske mreže za časovno-prostorske podatke

Grafovske nevronske mreže je smiselno uporabiti, kadar želimo poleg lastnosti elementov modelirati tudi odnose med njimi. Pri časovnih vrstah so takšni odnosi vsaj časovni – neka meritev je časovno pred drugo meritvijo ali za njo.

Pregled GNN za časovne vrste [7] to področje obravnava skozi naloge napovedovanja, klasifikacije, imputacije in zaznavanja anomalij ter posebej poudari modeliranje časovnih odvisnosti ter odvisnosti med različnimi spremenljivkami. Za to nalogo je pomembna predvsem formulacija, pri kateri posamezno časovno okno pretvorimo v grafovsko predstavitev in oznako napovemo na ravni celotnega grafa.

Pri podatkih sledilnika pogleda imajo meritve poleg časovnega vrstnega reda tudi prostorsko komponento, saj je vsaka veljavna meritev vezana na položaj pogleda na zaslonu. Podobno ločevanje časovnih in prostorskih odvisnosti uporabljajo časovno-prostorske grafovske mreže, na primer ST-GCN pri napovedovanju prometa, kjer grafovska konvolucija modelira prostorske povezave med senzorji, časovna konvolucija pa dinamiko signala skozi čas [16]. V tej nalogi je ta pristop uporaben kot metodološka analogija, saj ne napovedujemo prihodnjih meritev, temveč klasificiramo oznako časovnega okna meritev.

3.4 Učenje predstavitev iz signalov

Poleg ročno oblikovanih značilk obstajajo pristopi, ki se predstavitev naučijo neposredno iz zaporedij meritev. S tem zmanjšajo odvisnost od ročne izbire značilk, hkrati pa so njihove predstavitve vezane na podatke in naloge, uporabljene pri predtreniranju. V nalogi takšni modeli služijo kot most med klasičnimi modeli na ročno agregiranih značilkah in grafovskimi modeli, ki se predstavitev učijo na eksplicitno strukturiranih časovnih oknih.

GazeMAE je primer modela, zasnovanega posebej za očesne gibe – kot vhod uporablja zaporedje koordinat pogleda, iz katerega z avtokodirniško arhitekturo uči mikro- in makro-predstavitve [1]. **MOMENT** je splošnejši prednaučen temeljni model za časovne vrste, zato je uporaben kot primerjava pri signalih, ki niso omejeni na koordinate pogleda [6].

3.5 Položaj te naloge glede na sorodna dela

Ta naloga ne obravnava psihološkega modeliranja čustev. Čustvene oznake uporablja zgolj kot evalvacijsko nalogo za primerjavo predstavitev podatkov sledilnika pogleda. Glavna primerjava je med različnimi predstavitvami istega časovnega okna: agregiranimi značilkami za klasične modele, naučenimi predstavitvami iz prednaučenih kodirnikov in časovno-prostorsko grafovsko predstavitevijo za GNN.

Grafovski del naloge preverja, ali eksplicitne časovne, prostorske in fiksacijske relacije med meritvami pogleda prispevajo k uporabnejši predstavitvi okna. Naloga zato povezuje (1) klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda, (2) GNN za časovno-prostorske podatke ter (3) primerjavo ročno oblikovanih, naučenih in grafovskih predstavitev časovnih oken.

Poglavje 4

Podatki in predobdelava

4.1 Podatkovna zbirka MAHNOB-HCI

V delu uporabljamo podatke iz podatkovne zbirke MAHNOB-HCI [11]. Gre za večmodalno zbirko, namenjeno raziskavam prepoznavanja čustev in implicitnega označevanja multimedijskih vsebin. Zbirka vsebuje dva glavna eksperimentalna sklopa: prepoznavanje čustvenih stanj iz odzivov na čustvene videoposnetke in implicitno označevanje na podlagi odzivov na pravilne oziroma napačne oznake pod sliko ali posnetkom. V tej nalogi uporabljamo samo prvi sklop, to je eksperiment vzbujanja čustev z videoposnetki.

Izvirni članek poroča o 30 rekrutiranih udeležencih, od katerih je bilo v analizi uporabljenih 27. Udeleženci P9, P12 in P15 so bili izključeni zaradi tehničnih težav oziroma nepopolnega zajema podatkov. V tej nalogi po vzoru izvirnega članka izključimo iste tri udeležence. V eksperimentu vzbujanja čustev so udeleženci gledali 20 čustveno vzbujaajočih videoposnetkov. Pred vsakim čustvenim posnetkom je bil prikazan še kratek nevtralni posnetek, odziv nanj pa je bil shranjen ločeno. Po ogledu posameznega posnetka so udeleženci podali samoocene čustvene oznake, vznburjenosti, valence, dominantnosti in predvidljivosti.

Čeprav je MAHNOB-HCI večmodalna zbirka, v tej nalogi uporabljamo izključno signale sledilnika pogleda. Uporabljeni signali so podrobneje opisani

v razdelku 4.4. Meritve so bile zajete s sledilnikom Tobii X120 pri frekvenci 60 Hz.

4.2 Predhodni poskus z zbirko eSEEd_v2

Pred prehodom na MAHNOB-HCI je bil del razvoja izveden na podatkovni zbirki eSEEd_v2. Ta del ni osrednji eksperimentalni prispevek naloge, temveč služi kot zgodovinska motivacija za spremembo podatkovne zbirke. Začetni poskusi so pokazali težave z zanesljivostjo oznak, kakovostjo signalov in stabilnostjo učenja. Zato smo glavno eksperimentalno evalvacijo izvedli na podatkovni zbirki MAHNOB-HCI, ki ima za naš primer uporabnejšo množico signalov sledilnika pogleda.


4.3 Ciljne oznake

Oznake v tej nalogi izhajajo iz udeležencevih samoocen čustvenega razreda po ogledu videoposnetka. Diskretne čustvene razrede preslikamo v razrede valence po preslikavi iz izvirnega članka [11], ki je prikazana v dodatku A.1. S tem najprej dobimo tri razrede: neprijetno, nevtrarno in prijetno valenco. Nevtralni razred odstranimo, da ciljna naloga vsebuje izrazitejši kontrast med razredoma in s tem modelom omogočimo boljše pogoje za učenje vzorcev v podatkih.

Oznaka valence je določena na ravni kombinacije udeleženca in videoposnetka. Vsa časovna okna in s tem vsi grafi istega ogleda videoposnetka zato prejmejo isto oznako. Porazdelitev oken po odstranitvi nevtralnega razreda je prikazana na sliki 4.1; razreda sta pri vseh množicah signalov skoraj uravnotežena.

[Slika je delovna verzija iz runa RETAIN_2026-06-12_16-29-08. Pred oddajo preveri, ali je generirana iz končnega protokola, in jo po potrebi regeneriraj v paleti B.]

Vzburljenosti v tej nalogi ne klasificiramo. Razlog je predvsem večja šumnost oznak v uporabljeni podatkovni zbirki. Kot kaže matrika zmede v



Slika 4.1: Porazdelitev 10-sekundnih oken po razredih binarne valence.

dodatku A.3, se samoocene stopnje vzbujenosti slabše ujemajo z definiranimi razredi kot samoocene valence.

4.4 Priprava vhodnih signalov

4.4.1 Skupine signalov


Tukaj navedemo konkretne skupine signalov, ki jih uporabimo v eksperimentih. V uporabljeni podatkovni zbirki imamo na voljo pet osnovnih vrst signalov. To so:

- časovni žig meritve t_i ,
- koordinati pogleda na zaslonu (x_i, y_i) – povprečje med meritvama levega in desnega očesa,
- velikost leve in desne zenice $(p_i^{(l)}, p_i^{(r)})$,
- oddaljenost oči od sledilnika pogleda d_i ter
- informacija o fiksacijah, tj. pripadnost fiksaciji ter trajanje fiksacije.


Večina podatkovnih zbirk s podatki sledilnika pogleda vsebuje bodisi le koordinate pogleda bodisi le velikosti zenic bodisi oboje. Nekatere zbirke pa ponujajo tudi dodatne signale, kot sta v našem primeru oddaljenost od sledilnika ter informacije o fiksacijah. Da bi s primerjalno študijo pokrili čim širši razpon različnih tipov zbirk, MAHNOB-HCI podatke razdelimo v štiri delno prekrivajoče se eksperimentalne množice signalov. V vseh štirih množicah uporabimo tudi informacijo o času. Množica *samo pogled* poleg časa vsebuje koordinati pogleda, množica *samo zenici* vsebuje velikosti leve in desne zenice, množica *pogled in zenici* združi koordinati pogleda in velikosti zenic, množica *vsi signali* pa doda še oddaljenost od sledilnika pogleda in informacijo o fiksacijah. Podrobna povezava med temi množicami, značilkami vozlišč in razpoložljivimi tipi povezav je podana pri opisu grafovske konstrukcije v razdelku 5.3. *[Z zunanjo pomočjo mentorja ali slovenista najdi/potrdi izraze in jih potem uporablaj konsistentno v diplomi. Posebej preveri, ali naj bodo končna imena množic samo pogled, samo zenici, pogled in zenici in vsi signali, ter nato ta imena uporabi enako v besedilu, tabelah in slikah.]*

4.4.2 Čiščenje podatkov

Podatke pred uporabo očistimo. Najprej iz lokalne kopije zbirke MAHNOB-HCI odstranimo podatke, ki jih v tej nalogi ne uporabljamo, in ohranimo le podatke eksperimenta vzbujanja čustev. Nato odstranimo vrstice brez signalov pogleda ali velikosti zenic. Na voljo imamo tudi signale veljavnosti, na podlagi katerih odstranimo meritve, za katere je sledilnik poročal, da je meritev za vsaj eno oko neveljavna. Dodatno uporabimo filter osamelcev q01-q99, s katerim odstranimo izrazite ekstreme, ki izkrivljajo porazdelitve signalov. Na koncu kratke vrzeli v numeričnih signalih interpoliramo, signala velikosti leve in desne zenice pa dodatno zgladimo s kratkim drsečim povprečjem. Porazdelitvi položajev pogleda in velikosti zenic po čiščenju sta za množico signalov *pogled in zenici* prikazani na slikah 4.2 in 4.3.



Slika 4.2: Toplotni prikaz položajev pogleda v očiščenih podatkih za množico signalov pogled in zenici.



Slika 4.3: Porazdelitev velikosti leve in desne zenice v očiščenih podatkih za množico signalov pogled in zenici.

4.5 Normalizacija

Posamezne skupine signalov so izražene v različnih velikostnih redih. Modeli strojnega učenja, kot so SVM, MLP ter GNN, so občutljivi na merilo značilk. Zato signale standardiziramo. Povprečje in standardni odklon izračunamo na učni podmnožici, nato pa na validacijski in testni podmnožici standardizacijo uporabimo z istimi parametri kot na učni. Pri grafovskih modelih na enak način standardiziramo tudi značilke povezav, kadar jih uporabljena množica signalov vsebuje.

4.6 Segmentacija v časovna okna

Časovno vrsto razdelimo na neprekrivajoča se časovna okna dolžine $T = 10$ s. Vsako uporabno časovno okno predstavlja en učni primer. Za 10 s smo se odločili na podlagi sorodnega dela na podatkih sledilnika pogleda, kjer so se daljša okna med dolžinami 1, 3, 5 in 10 s praviloma izkazala za bolj informativna [2]. Daljših oken ne uporabimo, ker bi težje predpostavili, da celotno okno opisuje enoten čustveni odziv, saj se lahko ta med ogledom posnetka že opazno spremeni [17]. Tudi sorodna dela na prepoznavanju čustev iz očesnih signalov pogosto uporabljajo krajša okna, na primer 1-2 s [14, 15].

Oznaka okna je določena s parom udeleženec-posnetek, zato so vsa okna istega ogleda videoposnetka označena z isto čustveno oznako. Uporabnost okna določimo glede na kakovost podatkov v oknu.

Pri vzorčni frekvenci 60 Hz bi 10-sekundno okno brez manjkajočih vrednosti vsebovalo 600 vzorcev. Zaradi čiščenja, odstranjevanja neveljavnih vzorcev in filtriranja je dejansko število vzorcev v oknih manjše. Povprečno število meritev v oknu po čiščenju znaša

TODO: vstavi število

Po tvorbi časovnih oken se cevovod razdeli glede na uporabljeno predstavitev. Negrafovski osnovni modeli iz okna dobijo agregirane tabelarične

značilke, zamrznjeni prednaučeni predstavitveni modeli neposredno prejmejo časovne vrste izbranih signalov sledilnika pogleda, grafovski modeli pa grafovsko predstavitev okna. Podrobnosti teh predstavitev so opisane v poglavjih 5 in 6. V tem poglavju opišemo le skupne korake priprave podatkov.

4.7 Povzetek predobdelave

Tabela 4.1 povzema, kako se skozi opisane korake predobdelave zmanjša količina podatkov, uporabljena v končni eksperimentalni primerjavi.

Tabela 4.1: Zmanjševanje količine podatkov od izvirne zbirke MAHNOB-HCI do končnih časovnih oken, uporabljenih v eksperimentalnem cevovodu.

Korak	Vrstice	Udeleženci	Opis
Izbira izvirne zbirke MAHNOB-HCI	–	30	Večmodalna zbirka; izvirni članek v analizi uporabi 27 udeležencev.
Izbira podmnožice s čustvenimi oznakami	3 797 165	24	Ohranimo le posnetke iz eksperimenta vzbujanja čustev, ki imajo podatke sledilnika pogleda in čustvene oznake.
Izključitev šlabih udeležencev	3 535 842	22	Izključeni P9, P12 in P15.
Izbira veljavno označenih vrstic	2 995 632	22	Ohranjeni so samo označeni podatki, uporabljeni za učenje modelov čustvenih stanj.
Priprava podatkov za učenje	2 814 005	22	Odstranjene so vrstice brez signalov pogleda ali zenic.
Filter osamelcev q01-q99	2 639 048	22	Robustno filtriranje štirih osnovnih signalov pogleda in zenic.
Tvorba uporabnih 10-sekundnih časovnih oken	5 158	22	Vsako okno postane en učni primer oziroma graf.

Poglavje 5

Grafovska predstavitev podatkov sledilnika pogleda

V prejšnjem poglavju smo meritve sledilnika pogleda razdelili na 10-sekundna časovna okna. V tem poglavju opišemo, kako posamezno okno pretvorimo v graf, ki ga uporabimo kot vhod za grafovske modele. Vozlišča predstavljajo veljavne meritve znotraj okna, povezave pa izbrane odnose med meritvami.

Najprej podamo najbogatejšo grafovsko predstavitev učnega vzorca, ki uporablja vse razpoložljive signale. Nato pokažemo, kako se ista osnovna konstrukcija prilagodi štirim množicam signalov iz poglavja 4.4. Kadar določena množica signalov ne vsebuje informacije, potrebne za posamezno značilko ali relacijo, ta del predstavitve izpustimo. Graf zato v vseh primerih predstavlja isto vrsto učnega vzorca, razlikuje pa se po količini vhodne informacije in po razpoložljivih relacijah med meritvami.

5.1 Vozlišča

5.1.1 Definicija

Vsako vozlišče predstavlja eno meritev sledilnika pogleda znotraj časovnega okna:

$$v_i \leftrightarrow \mathbf{x}_i. \quad (5.1)$$

Če okno vsebuje n veljavnih meritev, potem graf vsebuje n vozlišč. Vrednost n se lahko med okni razlikuje, saj po čiščenju in filtriranju niso vsa okna popolna. Grafovska predstavitev naravno podpira spremenljivo število vozlišč.

5.1.2 Vektor značilk vozlišča

Vektor značilk vozlišča za končni graf za množico *vsi signali* je

$$\mathbf{x}_i = \left[t_i, x_i, y_i, p_i^{(l)}, p_i^{(r)}, d_i, f_{dur,i} \right], \quad (5.2)$$

kjer je t_i normaliziran časovni žig za vozlišče i , x_i in y_i sta koordinati pogleda, $p_i^{(l)}$ in $p_i^{(r)}$ velikosti leve in desne zenice, d_i je razdalja med sledilnikom in udeležencevimi očmi, $f_{dur,i}$ pa trajanje fiksacije.

Za ostale podgrafe se vektor značilk ustrezno filtrira. V vseh primerih ohranimo časovno značilko t_i , ostale podatke pa ohranimo glede na obravnavano množico signalov.

5.2 Relacije

Definiramo tri relacije med meritvami: časovno, prostorsko in fiksacijsko. Posledično v grafu oblikujemo štiri tipe povezav. Pri tem sta časovna tipa povezav usmerjena – časovne povezave naprej in nazaj. Prostorske in fiksacijske povezave pa obravnavamo kot neusmerjene.

5.2.1 Zakaj ločimo relacije

Vsaka povezava ima določen tip relacije, saj časovna povezava, prostorska povezava in fiksacijska povezava opisujejo različne odnose med meritvami. Ta zapis omogoča, da kasnejše stopnje arhitekturne lestvice relacije obravnavajo ločeno. Osnovni GCN uporabi isti nabor povezav, vendar relacij modelno ne loči; v tem primeru dobimo enostaven homogen graf. Podrobnosti o uporabi relacij v posameznih modelih so opisane v poglavju 6.

5.2.2 Časovne povezave

Časovne povezave povezujejo meritve zaporedne v času. Naj bodo vozlišča v posameznem oknu urejena po času, tako da je v_i i -ta meritev v časovnem zaporedju.

Ločimo usmerjene časovne povezave naprej in nazaj:

$$E_t^+ = \{(v_i, v_j) : 1 \leq j - i \leq k_t\}, \quad (5.3)$$

$$E_t^- = \{(v_i, v_j) : 1 \leq i - j \leq k_t\}. \quad (5.4)$$

Parameter $k_t \in \mathbb{N}$ določa število časovnih sosedov na vsako stran. Trenutna konfiguracija uporablja $k_t = 1$, zato je vozlišče v_i povezano samo z neposredno predhodno in neposredno naslednjo meritvijo, kadar ti vozlišči obstajata.

Povezave v E_t^+ potekajo od prejšnjih proti kasnejšim meritvam, povezave v E_t^- pa od kasnejših proti prejšnjim meritvam. Pri grafu z n vozlišči to pri $k_t = 1$ pomeni $n - 1$ časovnih povezav naprej in $n - 1$ časovnih povezav nazaj. Za polno 10-sekundno okno s pričakovanimi 600 meritvami je to 599 povezav v vsako smer.

5.2.3 Prostorske povezave

Prostorske povezave so neusmerjene povezave, ki povezujejo meritve s podobnim položajem pogleda znotraj istega časovnega okna. Te povezave lahko definiramo samo za grafe, ki imajo prostorsko informacijo, torej signala (x, y) . Za vsako vozlišče poiščemo k_s najbližjih sosedov v prostoru koordinat pogleda (x, y) .

Prostorsko razdaljo med meritvama i in j definiramo evklidsko:

$$d_{ij}^{(s)} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}. \quad (5.5)$$

Za vsako vozlišče v_i poiščemo k_s najbližjih sosedov v prostoru koordinat pogleda (x, y) z uporabo k-d drevesa. Če je v_j med temi sosedmi, dodamo povezavo med vozliščema v_i in v_j . Ker prostorske povezave obravnavamo kot neusmerjene, povezavo predstavimo z dvema usmerjenima povezavama (v_i, v_j) in (v_j, v_i) . Na koncu odstranimo podvojene povezave znotraj relacije E_s .

Število prostorskih povezav zato ni določeno samo z n in k_s , ampak tudi z geometrijo položajev pogleda. Pred simetrizacijo vsako vozlišče prispeva k_s sosedskih izbir, po simetrizaciji in odstranitvi podvojenih parov pa za usmerjeni zapis neusmerjene relacije velja

$$nk_s \leq |E_s| \leq 2nk_s. \quad (5.6)$$

Dejansko gostoto prostorskih povezav zato poročamo z opazovanimi statistikami grafov.

5.2.4 Fiksacijske povezave

Fiksacijske povezave povezujejo meritve, ki pripadajo isti zaznani fiksaciji. Pripadnost fiksaciji določimo z identifikatorjem fiksacije, podanim v MAHNOB-HCI podatkih. Ta podatek imamo zgolj v množici *usi signal*i, zato so te povezave vključene le v končni graf.

Redčenje povezav znotraj fiksacije

[Razmisli, ali to podsekcijo o redčenju skrajšati ali jo v celoti prestaviti v dodatek in tukaj samo omeniti redčenje v 1-2 povedih.]

Znotraj posamezne fiksacije ne povežemo vseh vozlišč med seboj, saj bi to povzročilo preveliko število fiksacijskih povezav. Namesto tega uporabimo redkejšo konstrukcijo, ki ohrani informacijo o pripadnosti isti fiksaciji, hkrati pa zmanjša prostorsko in časovno zahtevnost konstrukcije grafa ter učenja na grafu. To konstrukcijo sami imenujemo *razširjene povezave znotraj fiksacije* (angl. *dilated intra-fixation edges*). Fiksacijo obravnavamo kot neprekinjeno zaporedje vozlišč z istim veljavnim identifikatorjem *fixation-index*. Če ima taka fiksacija F vozlišč, jim znotraj fiksacije priredimo lokalne indekse $0, \dots, F - 1$.

Gostoto povezav uravnava parameter k_f , ki določa število fiksacijskih povezav, ki jih generira vsako vozlišče. V trenutni konfiguraciji uporabljamo $k_f = 3$. Za posamezno fiksacijo najprej izračunamo korak razširitve

$$s = \max(1, \lfloor F/k_f + 0,5 \rfloor). \quad (5.7)$$

Množico kandidatnih odmikov nato definiramo kot

$$D = \{(1 + qs) \bmod F \mid q = 0, \dots, k_f - 1\}. \quad (5.8)$$

Morebitni odmik 0 in podvojene odmiške odstranimo. Za vsak odmik $d \in D$ dodamo neusmerjene povezave

$$\{v_i, v_{(i+d) \bmod F}\}, \quad i = 0, \dots, F - 1. \quad (5.9)$$

Pri zapisu grafa za posredovanje sporočil vsako neusmerjeno povezavo predstavimo z dvema usmerjenima povezavama. Podvojene povezave znotraj relacije E_f odstranimo.

Na primer, pri fiksaciji dolžine $F = 30$ in parametru $k_f = 3$ dobimo $s = 10$. Vozlišče z lokalnim indeksom 0 torej povežemo z vozlišči 1, 11 in 21. Odmik 1 ohrani časovno lokalno komunikacijo znotraj fiksacije, večji odmiški pa omogočijo širjenje informacij tudi med časovno bolj oddaljenimi meritvami iste fiksacije.

Razširjene povezave imajo večji doseg kot zgolj zaporedne fiksacijske povezave, hkrati pa se izognejo kombinatorični eksploziji, ki bi nastala pri polnem kliku. Pri polnem kliku bi namreč število povezav naraščalo kvadratno z dolžino fiksacije. Pri analiziranih 10-sekundnih oknih dobimo približno 1.956 fiksacijskih povezav na graf pri $k_f = 2$, 2.908 pri $k_f = 3$, 4.163 pri $k_f = 5$ in 7.273 pri $k_f = 10$. Pri privzeti izbiri $k_f = 3$ so fiksacijske povezave predstavljale približno 45,7 % vseh povezav v grafu (relacije `temporal`, `spatial` in `fixation`).

Izbira $k_f = 3$ je zato kompromis med dosegom in gostoto grafa. Ker vsaka plast GNN omogoča izmenjavo informacij med neposredno povezanimi vozlišči, se doseg znotraj fiksacije povečuje tudi z večanjem števila plasti. Pri $k_f = 3$ vozlišče že v eni plasti prejme informacije iz več delov iste fiksacije, večplastni model pa lahko te informacije dodatno propagira po fiksacijski relaciji. Večje vrednosti k_f povečajo gostoto grafa, računsko zahtevnost in možnosti za prekomerno glajenje, manjše vrednosti pa graf dodatno razredčijo.

5.2.5 Značilke povezav

Povezavam poleg tipa relacije priredimo tudi značilke povezav, ki opisujejo odnos med izvirno meritvijo v_i in ciljno meritvijo v_j . Osnovne časovne značilke so normalizirani čas izvirne in ciljne meritve, t_i in t_j , ter časovna razlika $\Delta t = t_j - t_i$. Pri časovnih povezavah dodamo še smer ρ_{ij} , kjer ima povezava naprej vrednost $\rho_{ij} = 1$, povezava nazaj pa $\rho_{ij} = -1$. Značilke povezav so del grafovske predstavitve, uporabi jih končna utežena stopnja arhitekturne lestvice, opisana v poglavju 6.

Pri grafih, ki vsebujejo koordinate pogleda, povezavam dodamo tudi prostorske značilke. To sta razliki v koordinatah pogleda, $\Delta x = x_j - x_i$ in $\Delta y = y_j - y_i$, ter evklidska razdalja med položajema pogleda na zaslonu d_{ij}^{zaslon} . Te značilke so zato na voljo pri vseh množicah signalov, razen pri množici *samo zenici*.

Pri grafih, ki vsebujejo velikosti zenic, povezavam dodamo spremembi velikosti leve in desne zenice. Značilki $\Delta p_{ij}^{(l)} = p_j^{(l)} - p_i^{(l)}$ in $\Delta p_{ij}^{(r)} = p_j^{(r)} - p_i^{(r)}$ sta na voljo pri množicah *samo zenici*, *pogled in zenici* ter *vsii signali*.

Pri množici *vsii signali* povezavam dodamo še značilko, povezano z oddaljenostjo od sledilnika pogleda. Značilka $\Delta d_{ij} = d_j - d_i$ opisuje razliko v oddaljenosti od sledilnika pogleda med ciljno in izvirno meritvijo.

Pregled vseh značilk povezav in njihove uporabe je podan v tabeli 5.1.

Tabela 5.1: Značilke povezav v grafovski predstavitvi.

Značilka	Opis	Uporaba
t_i	Normaliziran čas izvirne meritve znotraj časovnega okna.	Vse povezave.
t_j	Normaliziran čas ciljne meritve znotraj časovnega okna.	Vse povezave.
Δt	Časovna razlika med ciljno in izvirno meritvijo, $\Delta t = t_j - t_i$.	Vse povezave.
ρ_{ij}	Smer časovne povezave; pri povezavi naprej je $\rho_{ij} = 1$, pri povezavi nazaj pa $\rho_{ij} = -1$.	Samo časovne povezave.
Δx	Razlika v vodoravni koordinati pogleda, $\Delta x = x_j - x_i$.	Grafi s koordinatami pogleda.
Δy	Razlika v navpični koordinati pogleda, $\Delta y = y_j - y_i$.	Grafi s koordinatami pogleda.
d_{ij}^{zaslon}	Evklidska razdalja med položajema pogleda na zaslonu.	Grafi s koordinatami pogleda.
$\Delta p_{ij}^{(l)}$	Razlika v velikosti leve zenice, $\Delta p_{ij}^{(l)} = p_j^{(l)} - p_i^{(l)}$.	Grafi z velikostmi zenic.
$\Delta p_{ij}^{(r)}$	Razlika v velikosti desne zenice, $\Delta p_{ij}^{(r)} = p_j^{(r)} - p_i^{(r)}$.	Grafi z velikostmi zenic.
Δd_{ij}	Razlika v oddaljenosti od sledilnika pogleda, $\Delta d_{ij} = d_j - d_i$.	Samo <i>vsilni signali</i> .

5.3 Grafovska konstrukcija po množicah signalov


Za vsako množico signalov iz razdelka 4.4 zgradimo graf po isti osnovni konstrukciji. Razlika med grafi je v značilkah vozlišč in relacijah, ki jih izbrana

množica signalov omogoča. Množica *vsí signali* je najbogatejša predstavitev. Ostale množice uporabijo ustrezne podmnožice značilk in povezav.

Tabela 5.2: Množice signalov in pripadajoča grafovska konstrukcija.

Množica signalov	Značilke vozlišč	Tipi povezav
<i>samo pogled</i>	čas in koordinati pogleda	časovne naprej, časovne nazaj, prostorske
<i>samo zenici</i>	čas in velikosti obeh zenic	časovne naprej, časovne nazaj
<i>pogled in zenici</i>	čas, koordinati pogleda in velikosti obeh zenic	časovne naprej, časovne nazaj, prostorske
<i>vsí signali</i>	čas, koordinati pogleda, velikosti obeh zenic, oddaljenost od sledilnika pogleda in fiksacijska informacija	časovne naprej, časovne nazaj, prostorske, fiksacijske

Slika 5.1 prikazuje primer najbogatejše konstrukcije na majhnem izseku časovnega okna za množico *vsí signali*. Prikaz združi vozlišča, časovne, prostorske in fiksacijske povezave v isti graf.



Slika 5.1: Primer grafovske konstrukcije za množico *vsi signali*. Vozlišča predstavljajo meritve v izseku časovnega okna, povezave pa prikazujejo časovne, prostorske in fiksacijske relacije. Ločeni prikazi posameznih relacij so zbrani v dodatku C.

5.4 Statistika konstruiranih grafov

Tabela 5.3 prikazuje osnovne statistike grafov, ki nastanejo pri končni konfiguraciji konstrukcije. Vrednosti so izračunane za osrednjo eksperimentalno nalogo, tj. binarno klasifikacijo nizke in visoke valence. Ker se posamezne množice signalov filtrirajo glede na razpoložljivost uporabljenih signalov, število konstruiranih grafov med stolpci ni povsem enako.

Tabela 5.3: Osnovne statistike konstruiranih grafov pri $k_t = 1$, $k_s = 1$ in $k_f = 3$.

Statistika	<i>samo pogled</i>	<i>samo zenici</i>	<i>pogled in zenici</i>	<i>vsi signali</i>
Število grafov	5.097	5.065	5.055	5.034
Mediana števila vozlišč	591	601	585	561
Mediana časovnih povezav naprej	590	600	584	560
Mediana časovnih povezav nazaj	590	600	584	560
Mediana prostorskih povezav	860	0	855	825
Mediana fiksacijskih povezav	0	0	0	3.210
Mediana skupnega števila povezav	2.047	1.200	2.029	5.153

Ničelne vrednosti pri prostorskih in fiksacijskih povezavah pomenijo, da ta relacija pri posamezni množici signalov ni del konstrukcije. Največjo razliko v gostoti grafa povzroči fiksacijska relacija pri množici *vsi signali*, kjer fiksacijske povezave doprinesejo 62,4 % vseh povezav.

Poglavje 6

Primerjani modeli

V nalogi se osredotočamo na primerjavo štirih družin modelov strojnega učenja za klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda. V tem poglavju razložimo, katere so te družine in na kratko opišemo vsak uporabljen model znotraj družine. Grafovske modele opišemo podrobneje, saj predstavljajo metodološko jedro naloge, poleg tega pa so za podatke sledilnika pogleda manj standardiziran pristop kot uveljavljeni klasični modeli.

Vsi modeli uporabljajo iste izvirne podatke, ista 10-sekundna okna in iste delitve na učne, validacijske in testne množice. Razlika je v predstavitvi vhodnih podatkov. Negrafovski osnovni modeli prejmejo agregirano tabelarno predstavitev istega okna, zamrznjeni prednaučeni predstavitveni modeli dobijo časovne vrste izbranih signalov, grafovski modeli pa delujejo na grafu, ki predstavlja časovno okno meritev.

6.1 Pregled primerjanih pristopov

V tabeli 6.1 je prikazano, katere modele uporabljamo, kateri družini vsak model pripada, kakšne podatke sprejme na vhod in kakšno vlogo ima v naši primerjalni študiji.

6.2 Negrafovski osnovni modeli

6.2.1 Izhodiščna klasifikatorja

Večinski in naključni klasifikator predstavljata spodnjo primerjalno mejo. Večinski klasifikator vedno napove večinski razred učne množice, naključni klasifikator pa razrede napoveduje z enako verjetnostjo ne glede na distribucijo podatkov. Pri binarni klasifikaciji to pomeni verjetnost 50 % za vsak razred. Če model ne preseže rezultatov teh dveh klasifikatorjev, težko trdimo, da se iz vhodnih podatkov nauči uporabnih vzorcev.

6.2.2 Klasični modeli strojnega učenja

Za pravično primerjavo negrafovskim osnovnim modelom podamo agregirane značilke istih signalov, kot jih prejme GNN. V primeru množice *vsí signali* so to koordinati pogleda (x , y), velikosti leve in desne zenice, oddaljenost od sledilnika pogleda ter informacija o fiksacijah. Dodamo tudi normaliziran čas meritve znotraj okna. Za vsako vhodno značilko izračunamo opisne statistike na ravni okna: povprečje, standardni odklon, minimum, maksimum, razpon, mediano, prvi kvartil, tretji kvartil in medkvartilni razmik. Pri fiksacijah dodamo še število fiksacij, delež meritev v oknu, ki pripadajo fiksacijam, vsoto trajanj, povprečno trajanje in največje trajanje fiksacije. V primeru množice *vsí signali* je eno okno v tabelarični predstavitvi opisano z 68 agregiranimi značilkami. Takšna pretvorba časovnega signala v opisne statistike na ravni okna oziroma odziva je običajen pristop pri klasičnih modelih strojnega učenja za podatke pogleda [2, 10, 12].

SVM

SVM uporabimo kot klasični model z RBF jedrom nad agregiranimi značilkami okna [3]. RBF jedro modelu omogoča nelinearno ločevanje razredov, zato je SVM uporaben kot močan negrafovski osnovni model. Ker je SVM občutljiv na velikostni red vhodnih značilk, agregirane značilke pred učenjem

standardiziramo.

LightGBM

LightGBM uporabimo kot predstavnika gradientno spodbujenih odločitvenih dreves [8]. Model je primeren za tabelarične podatke, zato je naravna primerjava za agregirane značilke časovnih oken. Za razliko od SVM in MLP standardizacije vhodnih značilk ne potrebuje, saj odločitvena drevesa delujejo na pragovih posameznih značilk.

MLP

Osnovni MLP uporabimo kot primer osnovnega nevronskega modela [5]. Vhod modela je vektor agregiranih značilk enega 10-sekundnega okna, izhod pa logiti za razrede ciljne naloge. Arhitektura je namerno preprosta: dve skriti polno povezani plasti z aktivacijo ReLU in izpuščanjem, za njima pa izhodna linearna plast. Model učimo z navzkrižno entropijo.

6.3 Zamrznjeni prednaučeni predstavitveni modeli

Poleg modelov nad ročno agregiranimi značilkami uporabimo tudi dva prednaučena kodirnika signalov: **GazeMAE** za podatke pogleda in **MOMENT** za ostale časovne vrste [1, 6]. Takšni modeli vhodnega okna ne pretvorijo v vnaprej določene statistike, temveč iz neposrednega signala izračunajo vektorsko predstavitev. V tej nalogi ju uporabimo kot zamrznjena kodirnika, zato njunih parametrov med učenjem ne spreminjamo. Na izračunanih predstavitvah nato učimo ločeno klasifikacijsko glavo MLP. Ta MLP je arhitekturno drugačen, vendar ločen in nepovezan s samostojnim klasifikatorjem MLP iz družine klasičnih modelov strojnega učenja.

6.3.1 GazeMAE

Za podatke pogleda uporabimo odprtokodni prednaučeni kodirnik **GazeMAE** [1]. Model prejme samo koordinati pogleda (x, y) , zato ga samostojno uporabimo le za množico *samo pogled*. Ker je bil **GazeMAE** učen na 2 s oknih, vzorčenih s frekvenco 500 Hz, uporabljena 10 s okna najprej pretvorimo v obliko, ki jo model pričakuje. Koordinati pogleda razdelimo na pet neprekrivajočih se 2 s kosov in ju prevzorčimo na ciljno frekvenco 500 Hz. Kodirnik temelji na časovno-konvolucijskih mrežah, ki ločeno kodirajo položaj in hitrost pogleda. Iz predstavitev posameznih kosov nato z združevanjem pridobimo predstavitev celotnega okna s 512 razsežnostmi.

6.3.2 MOMENT

MOMENT uporabimo kot splošni prednaučeni model za časovne vrste [6]. V nasprotju z **GazeMAE** ni vezan samo na koordinate pogleda, zato ga uporabimo za večkanalne časovne vrste signalov, ki pripadajo izbrani množici signalov v posameznem eksperimentu. To so lahko velikosti zenic, oddaljenost od sledilnika pogleda in trajanje fiksacije. Samostojno ga uporabimo le za množico *samo zenici*. Vhodno okno pred uporabo prevzorčimo na 512 časovnih korakov. **MOMENT** temelji na arhitekturi transformerjev za časovne vrste in v uporabljeni nastavitvi izračuna predstavitev okna s 768 razsežnostmi.

6.3.3 Združene predstavitve GazeMAE in MOMENT

Pri množicah *pogled in zenici* ter *vsii signali* uporabimo združeno predstavitev obeh kodirnikov. Predstavitev **GazeMAE** in predstavitev **MOMENT** konkatimiramo v en skupni vektor, ki je nato vhod v klasifikacijsko glavo MLP.

V rezultatih zamrznjene prednaučene predstavitvene modele obravnavamo kot eno družino modelov **GazeMAE/MOMENT**. Pri množici *samo pogled* ta vrstica pomeni uporabo **GazeMAE**, pri množici *samo zenici* uporabo **MOMENT**, pri množicah *pogled in zenici* ter *vsii signali* pa združeno predstavitev obeh kodirnikov. Za to smo se odločili zato, da ohranimo tabelo rezultatov pregledno.

6.4 Grafovski modeli

Grafovski modeli uporabljajo grafovsko predstavitev okna iz poglavja 5. Pri isti množici signalov vse stopnje uporabljajo iste vozliščne značilke, iste relacije in ista časovna okna. Razlikujejo se po tem, kako obravnavajo tipe povezav, kako združujejo relacijske predstavitve in ali uporabljajo značilke povezav za izračun naučenih uteži povezav. Najprej definiramo osnovno GNN, nato pa s tremi nadgradnjami postopno gradimo končni model. V tabeli 6.2 so na kratko predstavljene razlike med vsemi štirimi stopnjami grafovskih modelov.

6.4.1 Skupni cevovod grafovskih modelov

Grafovski modeli na vhod prejmejo graf glede na izbrano množico signalov, kot definirano v 5. Razsežnost vhodnih preslikav prilagodimo izbrani množici signalov – ločeno za značilke vozlišč, pri modelu **HeteroGCN-MLP-w** pa tudi za značilke povezav.

Vhodne vektorje najprej preslikamo v skupni latentni prostor z dvoslojnim MLP. Tako dobimo začetno predstavitev vsakega vozlišča, ki jo nato posodablja grafovske plasti. Te plasti posredujejo sporočila po povezavah grafa in pri vsakem vozlišču združijo informacije iz njegove okolice. V grafovskih blokih uporabimo aktivacijo GELU, rezidualne povezave, normalizacijo plasti in izpuščanje. Ti gradniki niso predmet primerjave med grafovskimi modeli. Primerjava se osredotoča na obravnavo relacij, fuzijo relacijskih predstavitev in uporabo značilk povezav. Iz končnih predstavitev vozlišč nato s pozornostnim združevanjem¹ izračunamo predstavitev celotnega grafa, to pa pošljemo skozi klasifikacijsko glavo MLP. Glava izračuna dva logita, enega za nizko in enega za visoko valenco. Napoved je razred z večjim logitom. Pri poročanju verjetnosti logite normaliziramo s softmaxom. Podrobnosti o številu plasti,

¹Ker napovedujemo oznako celotnega okna, predstavitev vozlišč združimo v predstavitev grafa. Uporabimo $\mathbf{h}_G = \sum_{v \in V} \alpha_v \mathbf{h}_v$, kjer je $\mathbf{h}_G$ predstavitev grafa, α_v utež pozornosti za vozlišče v , $\mathbf{h}_v$ pa predstavitev vozlišča v . Uteži pozornosti izračunamo s softmax normalizacijo: $\alpha_v = \exp(g(\mathbf{h}_v)) / \sum_{u \in V} \exp(g(\mathbf{h}_u))$, kjer je g naučena funkcija, ki predstavitvi vozlišča priredi skalarno oceno pomembnosti.

velikosti skritih predstavitev, verjetnosti izpuščanja in ostalih hiperparametrim so opisane v dodatku B.

Vse GNN treniramo od začetka do konca (ang. *end-to-end*), kar pomeni, da se vsi učljivi deli modela optimizirajo hkrati glede na klasifikacijsko izgubo. To vključuje začetno preslikavo značilk vozlišč, grafovske plasti, morebitno fuzijo relacij, pozornostno združevanje in klasifikacijsko glavo. V nadaljevanju opišemo specifične vsake arhitekture v štiri-stopenjski arhitekturni lestvici, začenši z najenostavnejšim – s homogenim GCN.

6.4.2 GCN

GCN je v osnovi homogeni grafovski model. Uporablja isto grafovsko predstavitev okna, kot je bila opisana v poglavju 5, vendar ne ločuje časovnih, prostorskih in fiksacijskih relacij. Vse povezave združi v en homogen graf, posredovanje sporočil pa izvede z običajnimi plastmi **GCNConv**. Model ne uporablja značilk povezav in posledično naučenih uteži povezav.

Tehnično lahko model zapišemo kot:

$$X \rightarrow MLP_{preprocess} \rightarrow f_{GCN} \rightarrow \text{READOUT} \rightarrow f_{\text{head}}, \quad (6.1)$$

kjer je X matrika značilk vozlišč, $MLP_{preprocess}$ predprocesirni dvoslojni perceptron, f_{GCN} zaporedje grafovskih konvolucijskih plasti, korak **READOUT** združi predstavitev vozlišč v predstavitev celotnega grafa, f_{head} pa iz te predstavitve izračuna napoved razreda. *[Zamenjaj to enačbo z diagramom, ko ga imaš. Z diagramom lažje prikažeš že samo razliko med tem in naslednjim modelom in imaš potem majhen diagram v vsaki subsekciji in obkrožiš razlike pri vsaki nadgradnji]*

6.4.3 HeteroGCN-mean

HeteroGCN-mean dobimo tako, da **GCN** nadgradimo s heterogeno grafovsko predstavitvijo. Kot opisano v 5 tukaj ločimo različne tipe relacij. Relacijske predstavitve vozlišč združimo v skupno predstavitev vozlišča s preprostim povprečenjem. Namen te stopnje je izolirati vpliv ločevanja relacij. Diagram ?? prikazuje, kje se zgodi sprememba.

TODO: ko bom naredil diagram, ga dodam tu

6.4.4 HeteroGCN-MLP

HeteroGCN-MLP dobimo tako, da HeteroGCN-mean nadgradimo z naučeno fuzijo relacijskih predstavitev. Različne predstavitve vozlišč – tiste, ki so v danem modelu na voljo izmed časovne naprej, časovne nazaj, prostorske ter fiksacijske – najprej konkateneramo, nato pa jih z dvoslojnim perceptronom združimo v skupno predstavitev vozlišča. S tem dopuščamo, da model sam določi, kateri deli katere relacije so pomembnejši za končno predstavitev. Diagram ?? prikazuje, kje se zgodi sprememba.

TODO: ko bom naredil diagram, ga dodam tu

6.4.5 HeteroGCN-MLP-w

HeteroGCN-MLP-w dobimo tako, da HeteroGCN-MLP nadgradimo z naučenimi utežmi povezav. Za izračun uteži povezav ima model tri večslojne perceptrone: f_w^{as} , f_w^{prostor} in $f_w^{\text{fiksacija}}$. Ti na podlagi vektorja značilk posamezne povezave, katerega komponente so povzete v tabeli 5.1, izračunajo skalarno predznačeno utež, ki določa, kako močno posamezna povezava vpliva na posredovanje sporočil. Pri posamezni množici signalov se uporabijo le funkcije za relacije, ki so v grafu prisotne. Časovne povezave naprej in nazaj si delijo isto funkcijo f_w^{as} , smer povezave pa je podana kot dodatna značilka povezave ρ_{ij} . Formule za izračun in normalizacijo uteži so podane v dodatku B.3. Namen te *končne* stopnje je preveriti, ali modelu koristi razlikovati moč in predznak prispevka posameznih povezav znotraj relacije.

6.4.6 Izbira grafske konvolucije

V vseh grafovskih modelih uporabimo plast GCNConv [9]. GCNConv je enostaven in uveljavljen operator posredovanja sporočil, ki ga lahko ohranimo nespremenjenega skozi celotno arhitekturno lestvico. Alternativni operatorji,

kot sta GraphSAGE ali GIN, bi v našem primeru odprli dodatne arhitekturne odločitve in s tem otežili neposredno primerjavo stopenj.

Izbirali smo preverili tudi z manjšim dodatnim poskusom na množici signalov *pogled in zenici*. Razlike med preizkušenimi operatorji so bile razmeroma majhne, GCNConv pa je dosegel primerljive in konsistentne rezultate tako pri osnovnem homogenem modelu kot tudi uteženi heterogeni arhitekturi. Podrobnosti primerjave so podane v dodatku A.4.

6.5 Povzetek poglavja

V delu primerjamo štiri družine modelov različnih kompleksnosti in različnih arhitektur: izhodiščna klasifikatorja, klasične modele strojnega učenja, zamrznjena prednaučena kodirnika in grafovske modele. Vhodne predstavitve za te modele posledično razdelimo na tri vrste: agregirane tabelarične značilke, neagregirane časovne vrste signalov in grafovske predstavitve podatkov sledilnika pogleda. Grafovska lestvica štirih GNN preverja, kaj prispevajo sama grafovska struktura, ločena obravnava relacij, naučena fuzija relacijskih predstavitev in uteženost povezav. V naslednjem poglavju opišemo evalvacijski protokol za primerjavo opisanih modelov na štirih množicah signalov.

Tabela 6.1: Pregled primerjanih modelov in njihovih vhodnih predstavitev.

Model	Družina modelov	Vhod v model	Vloga v primerjavi
Naključni	izhodiščna	brez učenja iz	spodnja meja
	klasifikatorja	značilke	naključnega ugibanja
Večinski			spodnja meja
			napovedovanja
			najpogostejšega
			razreda
SVM	klasični modeli	agregirane	klasični model
LightGBM	strojnega učenja	značilke okna	strojnega učenja
MLP			
GazeMAE	zamrznjeni	koordinati	prednaučena
	prednaučeni	pogleda (x, y)	predstavitev za
	predstavitveni		množico <i>samo pogled</i>
MOMENT	modeli	časovne vrste	prednaučena
		izbranih	predstavitev za
		signalov	množice s signali
			zenic oziroma več
			signali
GCN		homogeni graf	osnovni grafovski
		okna	model
HeteroGCN-mean	grafovski modeli	heterogeni graf	ločena obravnava
		okna	relacij s preprosto
			fuzijo
HeteroGCN-MLP			ločena obravnava
			relacij z naučeno
			fuzijo
HeteroGCN-MLP-w		heterogeni graf	najkompleksnejša
		okna in značilke	stopnja arhitekturne
		povezav	lestvice

Tabela 6.2: Arhitekturna lestvica grafovskih modelov.

Model	Ločene relacije	Fuzija relacij	Uteži povezav	Namen stopnje
GCN	ne	–	ne	preveri osnovno grafovsko predstavitev v homogenem grafu
HeteroGCN-mean	da	povprečje	ne	preveri vpliv ločene obravnave relacij
HeteroGCN-MLP	da	MLP	ne	preveri vpliv naučene fuzije relacijskih predstavitev
HeteroGCN-MLP-w	da	MLP	da	preveri vpliv naučenih predznačenih uteži povezav

Poglavje 7

Eksperimentalni protokol

V prejšnjih poglavjih smo definirali podatke, ciljne oznake, časovna okna, grafovsko predstavitev in primerjane modele. V tem poglavju določimo, kako te komponente ovrednotimo v skupni eksperimentalni primerjavi. Glavna evalvacijska naloga je binarna klasifikacija nizke proti visoki valenci. Primerjava je zasnovana kot kombinacija modelov iz poglavja 6 in množic signalov iz razdelka 4.4. Vsi modeli uporabljajo iste 10-sekundne učne vzorce in iste delitve na učno, validacijsko in testno množico.

7.1 Zasnova glavne primerjave

Cilj glavne primerjave je odgovoriti na raziskovalno vprašanje RV1: Kakšna je klasifikacijska uspešnost grafovske nevronske mreže za binarno klasifikacijo valence iz podatkov sledilnika pogleda v primerjavi s klasifikacijsko uspešnostjo uveljavljenih negrafovskih pristopov? Zato v primerjavi spreminjamo le način predstavitve okna in model, ki to predstavitev uporabi.

Ciljna oznaka je binarni razred valence, pri kateri model ločuje med nizko in visoko valenco. Vse štiri množice iz tabele 5.2 obravnavamo kot enakovreden del primerjave, saj nas zanima tudi, kako se klasifikacijska uspešnost spreminja z razpoložljivostjo različnih signalov sledilnika pogleda.

V primerjavi nastopajo vsi modeli iz tabele 6.1: izhodiščna klasifikatorja,

klasični modeli nad agregiranimi značilkami, zamrznjeni prednaučeni predstavitveni modeli in grafovski modeli. S tem primerjamo tri različne načine opisa istega časovnega okna: tabelarični povzetek signalov, vektorsko predstavitev časovne vrste in grafovsko predstavitev meritev.

7.2 Validacijski protokol

7.2.1 7-kratno prečno preverjanje po subjektih

Glavno primerjavo izvedemo s 7-kratnim prečnim preverjanjem po subjektih. Pri vsaki ponovitvi so testni subjekti popolnoma ločeni od subjektov, ki so uporabljeni za učenje in validacijo. Iz učnega dela izberemo eno skupino subjektov za validacijsko množico, preostali subjekti pa sestavljajo učno množico. Delitve so pri vseh modelih in vseh množicah signalov enake, določene s fiksnim naključnim semenom.

Takšna delitev ocenjuje posploševanje na nove udeležence. To je za uporabljeno nalogo pomembno, saj so signali sledilnika pogleda močno odvisni od specifik posameznika. Ker 22 subjektov ni deljivo s sedem, imajo posamezne testne razdelitve različno velikost – nekatere vsebujejo tri, druge pa štiri testne subjekte.

Validacijska množica se uporablja med učenjem, testna množica pa samo za končno oceno v posamezni ponovitvi. Pri nevronskih modelih zato najboljšo različico modela izberemo glede na validacijsko izgubo, nato pa njeno delovanje izmerimo na pripadajoči testni množici.

7.2.2 Predhodna preverjanja z LOO po subjektih

V zgodnejših fazah smo za množico *vsi signali* izvedli tudi LOO po subjektih. Ker končna primerjava vključuje več modelov in štiri množice signalov, bi polni LOO protokol bistveno povečal število potrebnih eksperimentov. Zato ga uporabimo kot podporno preverjanje, glavno primerjavo pa izvedemo s 7-kratnim protokolom. Primerjava obeh validacijskih protokolov za valenco

in množico *vsí signali* je podana v dodatku A.2, kjer vidimo, da je 7-kratno prečno preverjanje primerljivo z metodo LOO.

7.3 Nastavitve učenja in hiperparametri

V tem razdelku navedemo nastavitve učenja, ki vplivajo na izvedbo eksperimentov. Nevronske modele učimo z zgodnjim ustavljanjem na validacijski izgubi. Grafovski modeli uporabljajo operator `GCNConv`, dve grafovski plasti, skrite predstavitve velikosti 64 ter povezave s parametri $k_t = 1$, $k_s = 1$ in $k_f = 3$, kot so definirani v poglavju 5. Podrobni hiperparametri vseh modelov so podani v dodatku B.

Nastavitve grafovskih modelov izberemo na podlagi predhodnega kompaktne mrežnega iskanja. To iskanje je bilo izvedeno na 3-razredni valenci in ga v B poročamo samo kot pomožni poskus za izbiro stabilnih nastavitvev.

7.4 Metrike vrednotenja

Glavni metrike vrednotenja sta točnost in makro F1. Za vsak model in vsako množico signalov poročamo povprečje po sedmih testnih razdelitvah. Točnost uporabimo kot osnovno metriko, ker ima glavna naloga dva enakovredna in globalno skoraj uravnotežena razreda, kot kaže slika 4.1.

Makro F1 uporabimo kot dopolnilno glavno metriko. Čeprav sta razreda globalno skoraj uravnotežena, so lahko posamezne testne razdelitve precej neuravnotežene (tudi do razmerja 1 : 2). Makro F1 izračuna F1 ločeno za vsak razred in nato razreda povpreči z enako utežjo. S tem dopolni točnost predvsem pri modelih, ki lahko dosežejo sprejemljivo točnost, vendar večino primerov napovedujejo v en sam razred.

Poleg glavnih metrik spremljamo tudi uravnoteženo točnost, preciznost, priklic oziroma občutljivost, uteženi F1, AUC, izgubo in matrike zmede. Te metrike uporabimo predvsem za preverjanje stabilnosti in za podrobnejšo analizo napak. V glavnem besedilu se osredotočimo na točnost in makro F1,

razširjene metrike pa poročamo v dodatku A.2.

7.5 Spremljanje učenja

Poleg končnih metrik shranjujemo tudi podatke o poteku učenja. Pri nevronske modelih spremljamo učno in validacijsko izgubo, najboljšo epoho, informacijo o zgodnjem ustavljanju, čas epohe in norme gradientov. Krivulje izgub služijo predvsem preverjanju stabilnosti optimizacije in zaznavanju potencialnega prekomernega prileganja.

Pri grafovskih modelih spremljamo še nekaj diagnostičnih meritev naučenih predstavitev in napovedi. Med njimi so varianca predstavitev grafa, povprečna kosinusna podobnost predstavitev, razpon logitov in entropija napovednih verjetnosti. Te meritve uporabimo za preverjanje, ali se med učenjem pojavijo skoraj konstantne napovedi, zaznavanje kolapsa predstavitev ali znakov prekomernega glajenja. Te diagnostike ne poročamo med rezultati v poglavju 8, temveč le v dodatku D.1.

Poglavje 8

Rezultati

V tem poglavju predstavimo rezultate, ki odgovarjajo na raziskovalna vprašanja te naloge. To so rezultati primerjave različnih modelov za binarno klasifikacijo valence pri 7-kratnem prečnem preverjanju po subjektih. Dodatne rezultate in razširjene metrike poročamo v dodatku A.

8.1 Glavni rezultati klasifikacije

Tabela 8.1 prikazuje povprečno točnost in makro F1 pri 7-kratnem prečnem preverjanju po subjektih. Vse vrednosti so zapisane v odstotkih, štiri signalne množice pa so obravnavane kot enakovredne različice iste klasifikacijske naloge. Večinski klasifikator doseže točnost okoli 52 %, kar ustreza porazdelitvi razredov na sliki 4.1, vendar ima zaradi napovedovanja samo enega razreda makro F1 okoli 34 %.

Najvišjo točnost (70,5 %) in makro F1 (69,7 %) doseže SVM pri signalni množici *pogled in zenici*. **LightGBM** doseže najboljši rezultat pri množicah *samo pogled*, *samo zenici* in *vsi signali*. Med posameznimi signalnimi množicami je *samo zenici* najšibkejša, vendar vsi naučeni modeli tudi pri tej množici presežejo naključni in večinski klasifikator. Dodajanje zeničnih signalov k pogledu prinese najvišji posamični rezultat, medtem ko množica *vsi signali* v tej primerjavi ne preseže množice *pogled in zenici*.

Grafovski modeli so pri vseh signalnih množicah zanesljivo nad obema izhodiščnima klasifikatorjema, vendar ostanejo pod najboljšima modeloma SVM in LightGBM. Najboljši grafovski rezultat je odvisen od signalne množice – pri *samo pogled* je najuspešnejši HeteroGCN-MLP, pri *samo zenici* osnovni GCN, pri *pogled in zenici* in *vsi signali* pa HeteroGCN-MLP-w. Rezultati torej ne kažejo monotonega izboljševanja z večanjem arhitekturne kompleksnosti grafovskih modelov. V nadaljevanju podrobnejše rezultate matrike zmede ter računsko zahtevnost modelov prikažemo na primeru, kjer modeli dosegajo najboljše rezultate, to je na množici *pogled in zenici*.


Tabela 8.1: Glavna primerjava modelov pri binarni klasifikaciji valence. Celice vsebujejo točnost/makro F1 v odstotkih. Odebeljena pisava označuje najboljši rezultat za vsak stolpec, odebeljena poševna pisava pa najboljši rezultat med grafovskimi modeli.

Model	samo pogled	samo zenici	pogled in zenici	vsi signali
Naključni	50,2/50,1	50,7/50,6	50,8/50,6	50,9/50,7
Večinski	52,5/34,4	52,2/34,2	52,1/34,2	52,2/34,2
SVM	67,5/67,2	62,1/60,7	70,5/69,7	68,6/67,6
LightGBM	69,7/69,4	63,1/61,9	69,6/68,8	69,0/68,3
MLP	67,0/66,7	62,0/60,3	68,7/67,6	67,2/66,2
GazeMAE/MOMENT*	65,7/65,2	60,5/60,1	65,6/65,2	66,1/65,6
GCN	64,4/64,1	61,0/58,4	65,4/63,9	59,6/57,6
HeteroGCN-mean	61,7/59,2	58,6/55,7	63,8/61,1	61,8/59,7
HeteroGCN-MLP	65,9/65,8	59,1/56,0	64,2/62,8	60,5/56,6
HeteroGCN-MLP-w	64,3/64,0	58,4/54,5	65,5/64,4	62,7/60,8

Opomba: *GazeMAE/MOMENT označuje enoten prikaz zamrznjenih predstavitvenih modelov: GazeMAE pri pogledu, MOMENT pri zenicah in fuzijo obeh pri kombiniranih signalih, kot je pojasnjeno v poglavju 6.3.

Slika 8.1 prikazuje napake za signalno množico *pogled in zenici*, pri kateri je

dosežen najboljši skupni rezultat. Najuspešnejši model SVM pravilno razvrsti 73,0 % vzorcev nizke valence in 67,7 % vzorcev visoke valence, najuspešnejši grafovski model, HeteroGCN-MLP-w, pa 64,8 % oziroma 65,8 %.



Slika 8.1: Vrstično normalizirani matriki zmede za najboljši model SVM in najboljši grafovski model HeteroGCN-MLP-w pri množici signalov pogled in zenici.

8.2 Velikost in računska zahtevnost modelov

Za odgovor na podvprašanje PV4 smo poleg klasifikacijske uspešnosti primerjali tudi velikost modelov ter izmerjeni čas učenja in sklepanja. Tabela 8.2 prikazuje te vrednosti za množico signalov *pogled in zenici*, kjer je bil dosežen najboljši skupni rezultat. Stolpec *Vhod* loči modele, ki uporabljajo agregirane značilke okna, zamrznjene predstavitve prednaučenih kodirnikov oziroma grafovsko predstavitev okna.

Izhodiščna klasifikatorja ter modela SVM in LightGBM nimajo števila nevronskega parametrov, zato je pri njih ta vrednost označena z -. Pri GazeMAE/MOMENT stolpec učljivih parametrov zajema samo klasifikacijsko glavo, stolpec vseh parametrov pa tudi zamrznjena kodirnika. Grafovski modeli imajo bistveno manj parametrov kot zamrznjena prednaučena kodirnika, vendar je njihov izmerjeni čas učenja na okno za približno dva velikostna razreda večji kot pri negrafovskih modelih. Glede na razmerje med točnostjo

in izmerjenim časom sta v tej primerjavi najugodnejša klasična modela SVM in LightGBM.

Tabela 8.2: Velikost in računska zahtevnost modelov pri množici signalov pogled in zenici.

Model	Vhod	Učljivi [k]	Vsi [k]	Učenje [ms/ok.]	Inferenca [ms/ok.]	Točnost/ makro F1
Naključni	brez značilk	–	–	0,00	0,00	50,8/50,6
Večinski	brez značilk	–	–	0,00	0,00	52,1/34,2
SVM	agreg. znač.	–	–	0,39	0,08	70,5/69,7
LightGBM	agreg. znač.	–	–	0,04	0,00	69,6/68,8
MLP	agreg. znač.	7	7	0,39	0,00	68,7/67,6
GazeMAE/MOMENT	signal	181	127.217	0,26	0,00	65,6/65,2
GCN	grafi	26	26	20,73	0,19	65,4/63,9
HeteroGCN-mean	grafi	43	43	26,64	0,20	63,8/61,1
HeteroGCN-MLP	grafi	76	76	22,27	0,20	64,2/62,8
HeteroGCN-MLP-w	grafi	76	76	21,74	0,19	65,5/64,4

Poglavje 9

Diskusija

Kot kažejo slike 4.1, 4.2 in 4.3, ima glavna naloga skoraj uravnotežene razrede, očiščene meritve pa pričakovane porazdelitve. To poveča možnost, da se modeli naučijo uporabnih signalov namesto šuma. Matrike zmede pokažejo, da modeli niso izrazito pristranski do enega razreda. Posledično imata točnost in makro F1 v rezultatih podobne vrednosti.

Grafovski modeli se dokazano naučijo uporabnih informacij, saj dosegajo približno deset odstotnih točk višjo točnost od izhodiščnih klasifikatorjev. Podoben sklep velja za prednaučena kodirnika, ki dosegata zelo podobne rezultate kot GNN. Uporabljene grafovske predstavitve in predstavitve prednaučenih kodirnikov so torej informativne, niso pa za naš problem boljše od uveljavljenih pristopov s klasičnimi modeli strojnega učenja in ekspertno oblikovanimi značilkami. To je metodološko pomembna in zanimiva ugotovitev. Kljub večji izrazni moči globokih in grafovskih parametričnih modelov jih lahko enostavnejši modeli konsistentno prekašajo, poleg tega pa so slednji hitrejši in zasedejo manj pomnilnika.

Izkaže se, da je najinformativnejši signal v tej podatkovni množici signal pogleda, torej koordinati (x, y) v množici *samo pogled*. Velikosti zenic v množici *pogled in zenici* dodajo nekaj koristne informacije, ostali signali iz množice *usi signali* pa ne pokažejo izrazite dodane vrednosti. Čeprav slednja vsebuje več informacij, so rezultati večinoma slabši, kar kaže, da dodatni

signali v našem primeru modelom prej dodajo šum kot koristno strukturo. Rezultati torej kažejo, da je uporabljena grafovska predstavitev smiselna in informativna, vendar v tej raziskavi najmočnejši ostajajo klasični modeli z ročno oblikovanimi značilkami iz signalov koordinat pogleda in velikosti zenice.

Poglavje 10

Zaključek

Podatki sledilnika pogleda vsebujejo časovne, prostorske in fiksacijske odnose med meritvami, ki jih klasična tabelarična struktura podatkov ne modelira neposredno. Grafovske nevronske mreže omogočajo eksplicitno modeliranje relacij med meritvami, zato so naraven kandidat za obravnavo takšnih podatkov. V nalogi smo preverili uporabnost grafovske predstavitve podatkov sledilnika pogleda pri klasifikaciji valence kot čustvene oznake. Časovna okna meritev smo predstavili kot časovno-prostorske grafe in jih ovrednotili s štirimi grafovskimi modeli, ki se postopno nadgrajujejo od preproste proti kompleksnejšim različicam. Grafovske modele smo primerjali še s tremi družinami modelov: izhodiščnima modeloma (naključni in večinski klasifikator), klasičnimi modeli strojnega učenja (SVM, LightGBM, MLP) ter prednaučenima kodirnikoma signalov (GazeMAE, MOMENT). Izvedli smo primerjalno evalvacijo vseh modelov na štirih delno prekrivajočih se množicah signalov: *samo pogled*, *samo zenici*, *pogled in zenici* ter *usi signali*. Osrednja ugotovitev naloge je, da so grafovski modeli primerni za kodiranje signalov sledilnika pogleda, vendar v uporabljeni eksperimentalni zasnovi ne presežejo uspešnosti klasičnih modelov strojnega učenja.

Na podlagi izvedenih eksperimentov se je za najprimernejšo družino modelov za naš problem izkazala družina klasičnih modelov strojnega učenja z ročno oblikovanimi značilkami. Ta sklep je omejen na eno uporabljeno podatkovno

zbirko, izbrane signalne množice, binarno klasifikacijo ene čustvene dimenzije (valence) in protokol evalvacije, ki ne preverja generalizacije po posnetkih ali različnih podatkovnih zbirkah. Čustvene oznake so poleg tega izpeljane iz eksperimentalnih oznak oziroma samoocen, zato vsebujejo subjektivnost in šum. Omejitev je tudi sama grafovski predstavitev, saj je uporabljena konstrukcija samo ena izmed možnih predstavitev odnosov med meritvami.

Menimo, da je grafovsko modeliranje podatkov sledilnika pogleda še v veliki meri neraziskana, a smiselna nadaljnja raziskovalna smer. V nadaljnjem delu bomo preverili drugačna pravila povezovanja in še več grafovskih arhitektur, predvsem grafovske transformerje. Posebej zanimiva smer je tudi samonadzorovano predtreniranje na signalih sledilnika pogleda, saj bi s tem lahko zmanjšali odvisnost od majhnih in tudi neoznačenih podatkovnih zbirk. Grafovski predstavitev bi bilo mogoče razširiti še z mežiki, sakadami in fiksacijskimi meta-vozlišči, rezultate pa bi bilo potrebno preveriti na več podatkovnih zbirkah, pri prenosu med nalogami in v pogojih uporabe v realnem času.

Dodatek A

Dodatni rezultati

TODO:

- Sem dodaj dodatne tabele po foldih, rezultate manj pomembnih modelov in rezultate, ki niso šli v glavno besedilo.
- Dodaj rezultate za *LOO po subjektih* in *LOO po posnetkih* pri vseh signalnih naborih: pogled, zenici, pogled+zenici in vsi signali.
- Dodaj vse izračunane metrike rezultatov, ne samo *accuracy* in makro-F1, ki ostaneta v glavnem besedilu.
- Razširjene metrike: balanced accuracy, weighted-F1, AUC, po potrebi precision/recall po razredih in rezultati po posameznih gubah.
- Dodatne matrike zmede: LOO po posnetkih, binarne naloge, najboljši negrafovski osnovni model in primerjave, ki niso nujne za glavno zgodbo.
- Dodaj rezultate primerjave različnih tipov grafovskih konvolucij oziroma GNN slojev, če ostanejo zunaj glavnega besedila.
- Dodaj rezultate 3-razredne klasifikacije in kratek komentar primerjave z izvirnim člankom podatkovne zbirke MAHNOB-HCI oziroma HCI-tagging.
- Dodatne porazdelitve podatkov: porazdelitev razredov po subjektih, po posnetkih, po izvorni čustveni oznaki in za binarni low/high nalogi.
- Dodatne slike ujemanja oznak: podrobnejše heatmape Table 6 razredov proti samoocenam in povzetki label-noise analize, če v glavnem besedilu ostane samo ena skupna slika

A.1 Preslikava čustvenih oznak v valenco

Preslikava čustvenih oznak v razrede valence sledi tabeli 6 izvirnega članka podatkovne zbirke MAHNOB-HCI [11]. Razredi niso tvorjeni z neposrednim rezanjem številskih samoocen valence, temveč iz poročane čustvene oznake posnetka. Pri binarni nalogi uporabimo samo skrajna razreda valence, nevtralni razred pa izločimo.

Tabela A.1: Preslikava čustvenih oznak v razrede valence po izvirnem članku podatkovne zbirke MAHNOB-HCI. Pri binarni nalogi uporabimo samo neprijetno in prijetno valenco.

Razred valence	Uporaba v binarni nalogi	Izvirne čustvene oznake
Neprijetna valenca	da	<i>fear, anger, disgust, sadness, anxiety</i>
Nevtralna valenca	ne	<i>surprise, neutral</i>
Prijetna valenca	da	<i>joy, happiness, amusement</i>

A.2 Razširjeni rezultati binarne klasifikacije valence

TODO:

- Tabele v tem razdelku so razširjena različica glavne primerjave iz poglavja 8.
- V besedilu dodatka po potrebi pojasni, da so preciznost, priklic in AUC makro povprečja; Micro-F1 je pri enooznačni klasifikaciji enak točnosti.
- Vrednosti so podane kot povprečje $\pm$ standardni odklon čez sedem gub prečnega preverjanja po subjektih.
- Vir podatkov za vse štiri tabele je `metric_summary_with_std.csv` iz reteniranega teka `RETAIN_2026-06-12_16-29-08`.

Tabela A.2: Razširjeni rezultati za množico signalov samo pogled. Vrednosti so povprečje $\pm$ standardni odklon čez sedem gub, v odstotkih.

Model	Točnost	Preciznost	Priklic	Makro F1	Micro-F1	AUC
Naključni	50,2 $\pm$ 1,8	50,2 $\pm$ 1,7	50,2 $\pm$ 1,7	50,1 $\pm$ 1,6	50,2 $\pm$ 1,8	50,2 $\pm$ 1,7
Večinski	52,5 $\pm$ 4,7	26,2 $\pm$ 2,4	50,0 $\pm$ 0,0	34,4 $\pm$ 1,9	52,5 $\pm$ 4,7	50,0 $\pm$ 0,0
SVM	67,5 $\pm$ 1,8	67,5 $\pm$ 1,7	67,4 $\pm$ 1,7	67,2 $\pm$ 1,7	67,5 $\pm$ 1,8	72,6 $\pm$ 2,5
LightGBM	69,7 $\pm$ 2,2	69,6 $\pm$ 2,5	69,6 $\pm$ 2,1	69,4 $\pm$ 2,3	69,7 $\pm$ 2,2	76,6 $\pm$ 2,0
MLP	67,0 $\pm$ 2,1	67,0 $\pm$ 2,0	66,9 $\pm$ 2,1	66,7 $\pm$ 2,3	67,0 $\pm$ 2,1	72,6 $\pm$ 2,7
GazeMAE/MOMENT	65,7 $\pm$ 3,2	66,5 $\pm$ 3,0	65,8 $\pm$ 2,8	65,2 $\pm$ 3,5	65,7 $\pm$ 3,2	71,9 $\pm$ 4,9
GCN	64,4 $\pm$ 4,8	64,6 $\pm$ 4,5	64,6 $\pm$ 4,7	64,1 $\pm$ 5,2	64,4 $\pm$ 4,8	70,7 $\pm$ 6,3
HeteroGCN-mean	61,7 $\pm$ 6,3	60,1 $\pm$ 9,9	61,3 $\pm$ 6,9	59,2 $\pm$ 11,2	61,7 $\pm$ 6,3	64,7 $\pm$ 11,2
HeteroGCN-MLP	65,9 $\pm$ 3,9	66,1 $\pm$ 3,8	66,2 $\pm$ 3,6	65,8 $\pm$ 4,0	65,9 $\pm$ 3,9	72,2 $\pm$ 4,7
HeteroGCN-MLP-w	64,3 $\pm$ 5,0	64,8 $\pm$ 4,8	64,6 $\pm$ 4,8	64,0 $\pm$ 5,2	64,3 $\pm$ 5,0	70,3 $\pm$ 5,8

Tabela A.3: Razširjeni rezultati za množico signalov samo zenici. Vrednosti so povprečje $\pm$ standardni odklon čez sedem gub, v odstotkih.

Model	Točnost	Preciznost	Priklic	Makro F1	Micro-F1	AUC
Naključni	50,7 $\pm$ 2,0	50,7 $\pm$ 2,0	50,7 $\pm$ 2,0	50,6 $\pm$ 1,9	50,7 $\pm$ 2,0	50,7 $\pm$ 2,0
Večinski	52,2 $\pm$ 4,9	26,1 $\pm$ 2,4	50,0 $\pm$ 0,0	34,2 $\pm$ 2,0	52,2 $\pm$ 4,9	50,0 $\pm$ 0,0
SVM	62,1 $\pm$ 3,3	62,9 $\pm$ 3,0	61,7 $\pm$ 2,8	60,7 $\pm$ 3,6	62,1 $\pm$ 3,3	66,5 $\pm$ 3,4
LightGBM	63,1 $\pm$ 3,9	63,7 $\pm$ 2,7	62,7 $\pm$ 3,2	61,9 $\pm$ 4,3	63,1 $\pm$ 3,9	68,7 $\pm$ 3,4
MLP	62,0 $\pm$ 4,0	63,6 $\pm$ 3,9	61,5 $\pm$ 2,8	60,3 $\pm$ 4,6	62,0 $\pm$ 4,0	67,6 $\pm$ 3,6
GazeMAE/MOMENT	60,5 $\pm$ 2,5	60,8 $\pm$ 2,7	60,6 $\pm$ 2,7	60,1 $\pm$ 2,4	60,5 $\pm$ 2,5	64,9 $\pm$ 3,0
GCN	61,0 $\pm$ 3,4	65,1 $\pm$ 7,0	60,7 $\pm$ 3,0	58,4 $\pm$ 4,4	61,0 $\pm$ 3,4	67,5 $\pm$ 5,0
HeteroGCN-mean	58,6 $\pm$ 4,2	61,5 $\pm$ 6,8	58,3 $\pm$ 3,9	55,7 $\pm$ 6,1	58,6 $\pm$ 4,2	64,5 $\pm$ 3,6
HeteroGCN-MLP	59,1 $\pm$ 4,1	62,7 $\pm$ 6,7	58,8 $\pm$ 3,6	56,0 $\pm$ 6,1	59,1 $\pm$ 4,1	64,9 $\pm$ 5,0
HeteroGCN-MLP-w	58,4 $\pm$ 4,1	62,4 $\pm$ 6,3	58,1 $\pm$ 3,5	54,5 $\pm$ 7,5	58,4 $\pm$ 4,1	66,4 $\pm$ 4,9

Tabela A.4: Razširjeni rezultati za množico signalov pogled in zenici. Vrednosti so povprečje $\pm$ standardni odklon čez sedem gub, v odstotkih.

Model	Točnost	Preciznost	Priklic	Makro F1	Micro-F1	AUC
Naključni	50,8 $\pm$ 2,2	50,7 $\pm$ 2,1	50,7 $\pm$ 2,1	50,6 $\pm$ 2,0	50,8 $\pm$ 2,2	50,7 $\pm$ 2,1
Večinski	52,1 $\pm$ 4,9	26,0 $\pm$ 2,4	50,0 $\pm$ 0,0	34,2 $\pm$ 2,0	52,1 $\pm$ 4,9	50,0 $\pm$ 0,0
SVM	70,5 $\pm$ 2,9	71,9 $\pm$ 2,1	70,3 $\pm$ 2,6	69,7 $\pm$ 3,4	70,5 $\pm$ 2,9	78,1 $\pm$ 1,9
LightGBM	69,6 $\pm$ 2,7	71,0 $\pm$ 2,0	69,5 $\pm$ 2,3	68,8 $\pm$ 3,1	69,6 $\pm$ 2,7	78,2 $\pm$ 2,2
MLP	68,7 $\pm$ 1,9	70,6 $\pm$ 1,8	68,5 $\pm$ 1,6	67,6 $\pm$ 2,5	68,7 $\pm$ 1,9	77,8 $\pm$ 2,4
GazeMAE/MOMENT	65,6 $\pm$ 4,7	66,5 $\pm$ 4,3	65,9 $\pm$ 4,0	65,2 $\pm$ 4,7	65,6 $\pm$ 4,7	73,0 $\pm$ 6,9
GCN	65,4 $\pm$ 2,8	67,2 $\pm$ 1,4	65,1 $\pm$ 1,8	63,9 $\pm$ 3,2	65,4 $\pm$ 2,8	73,1 $\pm$ 2,2
HeteroGCN-mean	63,8 $\pm$ 4,0	66,6 $\pm$ 2,0	63,3 $\pm$ 4,0	61,1 $\pm$ 6,9	63,8 $\pm$ 4,0	72,8 $\pm$ 2,7
HeteroGCN-MLP	64,2 $\pm$ 3,7	65,5 $\pm$ 3,1	63,8 $\pm$ 2,8	62,8 $\pm$ 3,6	64,2 $\pm$ 3,7	72,3 $\pm$ 3,7
HeteroGCN-MLP-w	65,5 $\pm$ 2,3	66,6 $\pm$ 1,3	65,2 $\pm$ 1,5	64,4 $\pm$ 2,6	65,5 $\pm$ 2,3	73,2 $\pm$ 1,6

Tabela A.5: Razširjeni rezultati za množico signalov vsi signali. Vrednosti so povprečje $\pm$ standardni odklon čez sedem gub, v odstotkih.

Model	Točnost	Preciznost	Priklic	Makro F1	Micro-F1	AUC
Naključni	50,9 $\pm$ 2,0	50,8 $\pm$ 1,9	50,9 $\pm$ 1,9	50,7 $\pm$ 1,8	50,9 $\pm$ 2,0	50,9 $\pm$ 1,9
Večinski	52,2 $\pm$ 4,8	26,1 $\pm$ 2,4	50,0 $\pm$ 0,0	34,2 $\pm$ 2,0	52,2 $\pm$ 4,8	50,0 $\pm$ 0,0
SVM	68,6 $\pm$ 3,3	69,9 $\pm$ 2,1	68,3 $\pm$ 2,3	67,6 $\pm$ 3,3	68,6 $\pm$ 3,3	76,2 $\pm$ 2,6
LightGBM	69,0 $\pm$ 3,0	70,4 $\pm$ 2,2	69,0 $\pm$ 2,5	68,3 $\pm$ 3,2	69,0 $\pm$ 3,0	77,6 $\pm$ 2,7
MLP	67,2 $\pm$ 3,0	68,9 $\pm$ 2,6	67,1 $\pm$ 2,2	66,2 $\pm$ 2,7	67,2 $\pm$ 3,0	75,4 $\pm$ 3,6
GazeMAE/MOMENT	66,1 $\pm$ 3,1	66,8 $\pm$ 2,6	66,3 $\pm$ 3,0	65,6 $\pm$ 3,4	66,1 $\pm$ 3,1	72,2 $\pm$ 4,2
GCN	59,6 $\pm$ 8,4	61,5 $\pm$ 8,9	59,3 $\pm$ 8,0	57,6 $\pm$ 8,5	59,6 $\pm$ 8,4	65,7 $\pm$ 12,3
HeteroGCN-mean	61,8 $\pm$ 3,9	63,8 $\pm$ 3,7	61,3 $\pm$ 2,5	59,7 $\pm$ 4,0	61,8 $\pm$ 3,9	69,6 $\pm$ 3,1
HeteroGCN-MLP	60,5 $\pm$ 6,7	61,3 $\pm$ 9,3	59,9 $\pm$ 6,3	56,6 $\pm$ 10,7	60,5 $\pm$ 6,7	69,0 $\pm$ 6,2
HeteroGCN-MLP-w	62,7 $\pm$ 4,5	64,6 $\pm$ 3,0	62,3 $\pm$ 3,1	60,8 $\pm$ 5,1	62,7 $\pm$ 4,5	70,2 $\pm$ 3,4

A.3 Ujemanje izpeljanih oznak s samoocenami

TODO: Dodaj podrobnejše heatmape oziroma povzetke analize ujemanja razredov iz tabele 6 s številskimi samoocenami. Ta dodatek naj utemelji, zakaj je vznurjenost v uporabljenem podnaboru šumnejša ciljna oznaka kot valenca.

A.4 Izbira tipa grafovske konvolucije

Za preverjanje izbire grafovskega operatorja smo izvedli dodatni poskus na binarni nalogi valence z naborom signalov pogled+zenici. Primerjali smo osnovni homogeni grafovski model in uteženo heterogeno arhitekturo z različnimi tipi grafovskih konvolucij. Pri osnovnem modelu so bile povezave neutružene, pri uteženi heterogeni arhitekturi pa so različice **GCNConv**, **GraphConv** in **GINEConv** uporabile naučene skalarne uteži povezav. Različica **GATConv** teh skalarne uteži ni uporabila, saj pomembnost povezav modelira z notranjim mehanizmom pozornosti.

Če bi izbirali izključno najboljši operator za ta dodatni poskus, bi pri neutruženem osnovnem modelu izbrali **GINConv**, pri uteženi heterogeni arhitekturi pa **GraphConv**. V glavnih poskusih tega nismo storili, ker bi s tem hkrati

spremenili več delov arhitekture in otežili primerjavo med osnovnim GCN in uteženo heterogeno različico. GCNConv se je v obeh skupinah uvrstil približno v sredino: ni bil najboljši operator, hkrati pa tudi ni izrazito odstopal navzdol. Zato smo ga obravnavali kot dober kompromis med enostavnostjo, konsistentnostjo eksperimentalne zasnove in rezultati. Glavni namen naloge ni bil poiskati absolutno najboljši grafovski operator, temveč primerjati grafovsko predstavitev in arhitekturne stopnje pri enakem, razmeroma standardnem operatorju posredovanja sporočil.

Tabela A.6: Primerjava tipov grafovskih konvolucij pri naboru signalov pogled+zenici.

Arhitektura	Operator	Accuracy	Makro-F1	Opomba
Osnovni GCN	GCNConv	0,6474	0,6337	neuteženi homogeni graf
Osnovni GCN	GATConv	0,6484	0,6336	neutežena pozor- nost
Osnovni GCN	GraphConv	0,6367	0,6192	neuteženi homogeni graf
Osnovni GCN	GINConv	0,6613	0,6501	najboljši neuteženi rezultat
HeteroGCN-MLP-w	GCNConv	0,6391	0,6103	naučene uteži povezav
HeteroGCN-MLP-w	GATConv	0,6370	0,6116	pozornost brez skalarnih uteži
HeteroGCN-MLP-w	GraphConv	0,6606	0,6503	najboljši uteženi rezultat
HeteroGCN-MLP-w	GINEConv	0,6325	0,6028	značilke in uteži povezav

Dodatek B

Hiperparametri

TODO:

- preveri in po potrebi dopolni enotno tabelo hiperparametrov;
- dodaj rezultate mrežnega iskanja velikostnih hiperparametrov GNN: k_t , k_s , k_f , število slojev in dimenzija skritih predstavitev;
- dodaj kratek opis uporabljene strojne in programske opreme za poganjanje poskusov: CPU, GPU, RAM, operacijski sistem, različica Pythona, ključne knjižnice in različice paketov;
- dodaj kratko poročilo o času učenja oziroma trajanju poskusov, po potrebi ločeno za glavne modele, protokole delitev in mrežna iskanja;
- finalni config path;
- search space, če bo uporabljen;
- opomba, če kaj ni bilo sistematično tunano.

B.1 Hiperparametri modelov

Tabela B.1 povzema glavne hiperparametre modelov v končnih eksperimentih. Klasični primerjalni modeli uporabljajo agregirane tabelarične značilke, nevronske primerjalne glave uporabljajo bodisi agregirane značilke bodisi zamrznjene predstavitve, grafovski modeli pa uporabljajo grafovsko predstavitev časovnih oken.

B.2 Strojna in programska oprema

Glavni eksperimenti so bili izvedeni na računalniku z operacijskim sistemom Linux Ubuntu, grafično kartico NVIDIA GeForce RTX 4070 z 12 GB grafičnega pomnilnika, procesorjem AMD Ryzen 7 5700X, 32 GB sistemskega pomnilnika in pogonom Samsung SSD 990 PRO NVMe. Poskusi so bili poganjani v okolju Conda gfm.

TODO: Pred oddajo dopolni natančno različico Pythona, CUDA in ključnih knjižnic (PyTorch, PyTorch Geometric, scikit-learn, LightGBM, NumPy, pandas).

B.3 Naučene uteži povezav

V modelu HeteroGCN-MLP-w značilke povezave uporabimo za izračun skalarne uteži povezave. Naj bo $\mathbf{e}_{ij}^{(r)}$ vektor značilk povezave (v_i, v_j) v relaciji r . Najprej izračunamo surovo oceno:

$$s_{ij}^{(r)} = f_w^{(r)} \left(\mathbf{e}_{ij}^{(r)} \right), \quad (\text{B.1})$$

kjer je $f_w^{(r)}$ večslojni perceptron za ustrezno družino relacij. Za časovne povezave naprej in nazaj uporabimo isti perceptron f_w^{as} , za prostorske povezave f_w^{prostor} , za fiksacijske povezave pa $f_w^{\text{fiksacija}}$. Vsak od teh perceptronov ima obliko

$$d_e \rightarrow 6 \rightarrow 4 \rightarrow 2 \rightarrow 1, \quad (\text{B.2})$$

Tabela B.1: Glavni hiperparametri modelov v končnih eksperimentih.

Model oziroma družina	Podatkovna predstavitev	Glavni hiperparametri
Naključni model	agregirane tabelarične značilke	enakomerna naključna napoved razreda; seme 42
Večinski model	agregirane tabelarične značilke	napoved večinskega razreda na učni množici
SVM	agregirane tabelarične značilke	jedro RBF; $C = 1,0$; <code>probability=true</code> ; <code>decision_function_shape=ovr</code> ; standardizacija značilk na učni množici
LightGBM	agregirane tabelarične značilke	<code>n_estimators=100</code> ; <code>learning_rate=0.05</code> ; <code>max_depth=5</code> ; <code>random_state=42</code>
MLP	agregirane tabelarične značilke	klasifikacijska glava MLP s skrito velikostjo 64; največ 200 epoh; učna stopnja 10^{-3} ; <code>weight_decay=0.0001</code> ; <code>dropout=0.1</code> ; mini-serija 128; zgodnje ustavljanje s potrpežljivostjo 15 epoh
GazeMAE in MOMENT glave	zamrznjene predstavitve časovnih oken	klasifikacijska glava MLP s skrito velikostjo 128; največ 100 epoh; učna stopnja 10^{-3} ; <code>weight_decay=0.0001</code> ; <code>dropout=0.2</code> ; mini-serija 128; zgodnje ustavljanje s potrpežljivostjo 15 epoh
Grafovski modeli	grafovska predstavitev časovnih oken	GCNConv; dve grafovski plasti; <code>hidden_channels=64</code> ; pozornostno združevanje grafa; predobdelavni MLP; <code>dropout=0.1</code> ; učna stopnja $5 \cdot 10^{-5}$; mini-serija 256; največ 350 epoh; zgodnje ustavljanje s potrpežljivostjo 20 epoh
GCN	grafovska predstavitev časovnih oken	homogen graf; relacije niso modelno ločene; brez značilk povezav
HeteroGCN-mean	grafovska predstavitev časovnih oken	heterogeni graf; ločene časovne, prostorske in fiksacijske relacije; združevanje relacij s povprečenjem
HeteroGCN-MLP	grafovska predstavitev časovnih oken	heterogeni graf; ločene časovne, prostorske in fiksacijske relacije; združevanje relacij z MLP
HeteroGCN-MLP-w	grafovska predstavitev časovnih oken	kot HeteroGCN-MLP, dodatno naučene predznačene uteži povezav iz značilk povezav
Grafovska konstrukcija	grafovska predstavitev časovnih oken	$k_t = 1$; $k_s = 1$; $k_f = 3$ (<code>fixation_dilation_k</code>); standardizacija značilk povezav; značilke povezav odvisne od uporabljene množice signalov

kjer je d_e razsežnost vektorja značilk povezave za izbrano relacijo in množico signalov.

Surovo oceno nato omejimo s funkcijo $\tanh$:

$$\tilde{w}_{ij}^{(r)} = \tanh \left(s_{ij}^{(r)} \right). \quad (\text{B.3})$$

Končno utež normaliziramo po vhodnih povezavah ciljne meritve v_j znotraj iste relacije:


$$w_{ij}^{(r)} = \frac{\tilde{w}_{ij}^{(r)}}{\sum_{k:(v_k, v_j) \in E_r} \left| \tilde{w}_{kj}^{(r)} \right| + \epsilon}, \quad (\text{B.4})$$

kjer je $\epsilon = 10^{-8}$ majhna konstanta za numerično stabilnost. Ker normalizacija ohrani predznak uteži, lahko povezava prispevek sosednjega vozlišča tudi zmanjša, ne le poveča.


Dodatek C

Dodatne vizualizacije grafov


Ta dodatek dopolnjuje osrednji primer grafovske konstrukcije iz poglavja 5. Slike prikazujejo isti izsek časovnega okna, vendar ločeno za posamezne tipe povezav.



Slika C.1: Primer časovnih povezav v izseku grafa. Povezave sledijo časovni urejenosti meritev in ločijo smer naprej ter nazaj.



Slika C.2: Primer prostorskih povezav v izseku grafa. Povezave nastanejo med meritvami s podobnim položajem pogleda, zato niso nujno omejene na časovno zaporedne meritve.



Slika C.3: Primer fiksacijskih povezav v izseku grafa. Povezave združujejo meritve, ki pripadajo isti zaznani fiksaciji, pri čemer razširjena konstrukcija ohrani redkejšo povezovalno strukturo.

TODO:

- Po potrebi dodaj primer celotnega 10-sekundnega grafa.
- Po potrebi dodaj ločen prikaz razširjenih fiksacijskih povezav znotraj ene fiksacije za razlago parametra k_f .
- Po potrebi dodaj prikaz prekrivanja relacij med istimi pari vozlišč s krivljenimi povezavami.

Dodatek D

Diagnostika predstavitev modela

TODO:

- Dodaj variance po plasteh, kosinusne podobnosti, porazdelitve logitov in dodatne slike kolapsa predstavitev.
- Dodaj per-fold krivulje učne in validacijske izgube, če so v glavnem besedilu prikazane samo agregirane ali reprezentativne krivulje.
- Dodaj porazdelitve entropije napovednih verjetnosti in razpona logitov za osnovni GCN ter predlagani GNN.
- Dodaj porazdelitve naučenih uteži povezav po relacijah `temporal_forward`, `temporal_backward`, `spatial` in `fixation`, če so artefakti na voljo.
- UMAP naučenih predstavitev grafa dodaj sem, če je slika uporabna kot diagnostika, vendar ni dovolj močna za glavno besedilo. Pri vsakem UMAP prikazu zapiši, ali je barvan po razredu, subjektu ali posnetku.
- Če UMAP kaže predvsem subjektne ali stimulusne gručice, ga interpretiraj kot omejitev oziroma opozorilo, ne kot dokaz razredne ločljivosti.

D.1 Diagnostika prekomernega glajenja

TODO: V tem razdelku poročaj diagnostiko iz GFM-for-eyetracker/results/quick_v1_v2_comparison/RETAIN_2026-06-12_16-29-08. Interpretacija naj bo informativna: rezultati ne kažejo jasnega kolapsa predstavitev oziroma prekomernega glajenja pri glavnih grafovskih modelih. Posebej omeni, da je signalni nabor `pupil_only` šibkejši in ima bolj neodločne napovedi, vendar tega ne predstavimo kot dokaz sistemskega kolapsa GNN.

Tabela D.1: TODO: Diagnostika naučenih predstavitev in izhodov najboljšega grafovskega modela za posamezen signalni nabor pri binarni klasifikaciji valence. Vrednosti so agregirane po testnih gubah.

Signalni nabor	Najboljši GNN	Makro-F1	Urav. točnost	Razpon logitov	Entropija	Varianca predstavitev	Kos. podobnost
<code>all_signals</code>	HeteroGCN-MLP-w	0,608	0,623	3,31	0,545	0,352	0,409
<code>gaze_only</code>	HeteroGCN-MLP	0,658	0,662	3,93	0,583	0,291	0,307
<code>gaze_pupil</code>	HeteroGCN-MLP-w	0,644	0,652	3,38	0,582	0,336	0,360
<code>pupil_only</code>	GCN	0,584	0,607	1,40	0,653	0,258	0,569

Dodatek E

Zgodovinski poskusi na eSEEd_v2

TODO: Če želiš ohraniti eSEEd_v2 rezultate, jih daj sem: kratka motivacija, glavne težave, zakaj ni glavni dataset, brez pretiranega širjenja glavne zgodbe.

Literatura

- [1] Louise Gillian C. Bautista in Prospero C. Naval. „GazeMAE: General Representations of Eye Movements Using a Micro-Macro Autoencoder“. V: *2020 25th International Conference on Pattern Recognition (ICPR)*. IEEE, 2021, str. 7004–7011. DOI: 10.1109/ICPR48806.2021.9412761.
- [2] Tomi Božak, Mitja Luštrek in Gašper Slapničar. „Feature-Based Emotion Classification Using Eye-Tracking Data“. V: *Information Society 2024*. Ljubljana, Slovenia, 2024. DOI: 10.70314/is.2024.scai.9988.
- [3] Corinna Cortes in Vladimir Vapnik. „Support-Vector Networks“. V: *Machine Learning* 20.3 (1995), str. 273–297. DOI: 10.1007/BF00994018.
- [4] Justin Gilmer in sod. „Neural Message Passing for Quantum Chemistry“. V: *Proceedings of the 34th International Conference on Machine Learning*. Zv. 70. Proceedings of Machine Learning Research. PMLR, 2017, str. 1263–1272.
- [5] Ian Goodfellow, Yoshua Bengio in Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [6] Mononito Goswami in sod. „MOMENT: A Family of Open Time-Series Foundation Models“. V: *Proceedings of the 41st International Conference on Machine Learning*. Zv. 235. Proceedings of Machine Learning Research. PMLR, 2024, str. 16115–16152. URL: <https://proceedings.mlr.press/v235/goswami24a.html>.

- [7] Ming Jin in sod. „A Survey on Graph Neural Networks for Time Series: Forecasting, Classification, Imputation, and Anomaly Detection“. V: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 46.12 (2024), str. 10466–10485. DOI: 10.1109/TPAMI.2024.3443141.
- [8] Guolin Ke in sod. „LightGBM: A Highly Efficient Gradient Boosting Decision Tree“. V: *Advances in Neural Information Processing Systems*. Zv. 30. Curran Associates, Inc., 2017, str. 3149–3157. URL: <https://papers.nips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree>.
- [9] Thomas N. Kipf in Max Welling. „Semi-Supervised Classification with Graph Convolutional Networks“. V: *International Conference on Learning Representations*. 2017. URL: <https://openreview.net/forum?id=SJU4ayYgl>.
- [10] Jia Zheng Lim, James Mountstephens in Jason Teo. „Emotion Recognition Using Eye-Tracking: Taxonomy, Review and Current Challenges“. V: *Sensors* 20.8 (2020), str. 2384. DOI: 10.3390/s20082384.
- [11] Mohammad Soleymani in sod. „A Multimodal Database for Affect Recognition and Implicit Tagging“. V: *IEEE Transactions on Affective Computing* 3.1 (2012), str. 42–55. DOI: 10.1109/T-AFFC.2011.25.
- [12] Paweł Tarnowski in sod. „Eye-Tracking Analysis for Emotion Recognition“. V: *Computational Intelligence and Neuroscience 2020* (2020), str. 2909267. DOI: 10.1155/2020/2909267.
- [13] Petar Veličković in sod. „Graph Attention Networks“. V: *International Conference on Learning Representations*. 2018. URL: <https://openreview.net/forum?id=rJXMpikCZ>.
- [14] Yang Wang, Zhao Lv in Yongjun Zheng. „Automatic Emotion Perception Using Eye Movement Information for E-Healthcare Systems“. V: *Sensors* 18.9 (2018), str. 2826. DOI: 10.3390/s18092826.

-
- [15] Qun Wu in sod. „Emotion Classification on Eye-Tracking and Electroencephalograph Fused Signals Employing Deep Gradient Neural Networks“. V: *Applied Soft Computing* 110 (2021), str. 107752. DOI: 10.1016/j.asoc.2021.107752.
- [16] Bing Yu, Haoteng Yin in Zhanxing Zhu. „Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting“. V: *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence*. International Joint Conferences on Artificial Intelligence Organization, 2018, str. 3634–3640. DOI: 10.24963/ijcai.2018/505.
- [17] Tianyi Zhang in sod. „RCEA: Real-Time, Continuous Emotion Annotation for Collecting Precise Mobile Video Ground Truth Labels“. V: *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, 2020, str. 1–15. DOI: 10.1145/3313831.3376808.