

UNIVERZA V LJUBLJANI
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO
FAKULTETA ZA MATEMATIKO IN FIZIKO

Tomi Božak

**Grafovske nevronske mreže za
klasifikacijo valence iz podatkov
sledilnika pogleda**

DIPLOMSKO DELO

INTERDISCIPLINARNI UNIVERZITETNI
ŠTUDIJSKI PROGRAM PRVE STOPNJE
RAČUNALNIŠTVO IN MATEMATIKA

MENTOR: izr. prof. dr. Lovro Šubelj
SOMENTOR: doc. dr. Gašper Slapničar

Ljubljana, 2026

To delo je ponujeno pod licenco *Creative Commons Priznanje avtorstva-Deljenje pod enakimi pogoji 2.5 Slovenija* (ali novejšo različico). To pomeni, da se tako besedilo, slike, grafi in druge sestavine dela kot tudi rezultati diplomskega dela lahko prosto distribuirajo, reproducirajo, uporabljajo, priobčujejo javnosti in predelujejo, pod pogojem, da se jasno in vidno navede avtorja in naslov tega dela in da se v primeru spremembe, preoblikovanja ali uporabe tega dela v svojem delu, lahko distribuira predelava le pod licenco, ki je enaka tej. Podrobnosti licence so dostopne na spletni strani creativecommons.si ali na Inštitutu za intelektualno lastnino, Streliška 1, 1000 Ljubljana.



Izvorna koda diplomskega dela, njeni rezultati in v ta namen razvita programska oprema so ponujeni pod licenco GNU General Public License, različica 3 (ali novejša). To pomeni, da se lahko prosto distribuira in/ali predeluje pod njenimi pogoji. Podrobnosti licence so dostopne na spletni strani <http://www.gnu.org/licenses/>.

Besedilo je oblikovano z urejevalnikom besedil L^AT_EX.

Kandidat: Tomi Božak

Naslov: Grafovske nevronske mreže za klasifikacijo valence iz podatkov sledilnika pogleda

Vrsta naloge: Diplomaska naloga na univerzitetnem programu prve stopnje

Mentor: izr. prof. dr. Lovro Šubelj

Somentor: doc. dr. Gašper Slapničar

Opis:

Podatki, pridobljeni s sledilniki pogleda, se pogosto uporabljajo za klasifikacijo čustvenih stanj posameznikov med izvajanjem različnih nalog. V diplomskem delu se osredotočite na problem napovedovanja pozitivne oziroma negativne valence. V ta namen predlagajte ustrezno arhitekturo grafovskih nevronskih mrež ter uspešnost naučenega modela primerjajte z drugimi pristopi, kot so klasični modeli strojnega učenja za tabelarične podatke ter prednaučeni kodirniki signalov. Na koncu kritično ovrednotite uspešnost pristopa, ki temelji na grafovskem modeliranju, in predlagajte smernice za prihodnje delo.

Title: Graph Neural Networks for Valence Classification from Eye-Tracking Data

Iskreno se želim zahvaliti obema mentorjema, izr. prof. dr. Lovru Šublju za usmerjanje na področju grafovskih nevronskih mrež in doc. dr. Gašperju Slapničarju za nesebično svetovanje – nemalokrat tudi izven delovnega časa –, dvoletno mentoriranje na raziskovalnem področju in usmerjanje tako pri večjih kot tudi manjših odločitvah. Odseku E9 na IJS se zahvaljujem za neprecenljive izkušnje na področju raziskovanja in podatkovne znanosti, za prostor, računske vire in možnost, da sem diplomsko delo opravljal v sklopu raziskovalnega dela. Hvala sodelavcem skupine AMI za strokovne razprave ter koristne nasvete in ideje ob raziskovalnih izzivih. Hvala FRI in FMF za kakovostne temelje na področju računalništva in matematike. Nenazadnje pa gre zahvala od srca tudi družini in partnerki Lari za večno podporo v vseh okoliščinah. Brez vaše pomoči bi bil vsak korak te poti težji.

Kazalo

Povzetek

Abstract

1	Uvod	1
2	Teoretično ozadje in sorodna dela	5
2.1	Osnove grafovskih nevronske mreže	5
2.2	GNN za časovno-prostorske podatke	8
2.3	Učenje predstavitev iz signalov	8
2.4	Položaj naloge glede na sorodna dela	9
3	Podatki in predobdelava	11
3.1	Podatkovne zbirke sledilnika pogleda	11
3.2	Samooocene čustvenega stanja in ciljni razredi	13
3.3	Priprava podatkov za učenje	14
3.3.1	Množice signalov in čiščenje podatkov	14
3.3.2	Standardizacija in tvorba časovnih oken	15
4	Grafovska predstavitev podatkov sledilnika pogleda	19
4.1	Graf in vozlišča	19
4.2	Relacije in značilke povezav	20
4.2.1	Časovne povezave	21
4.2.2	Prostorske povezave	21
4.2.3	Fiksacijske povezave	22

4.2.4	Značilke povezav	22
4.3	Grafovska predstavitev po množicah signalov	24
5	Primerjani modeli	27
5.1	Pregled primerjanih pristopov	27
5.2	Negrafovski osnovni modeli	29
5.3	Zamrznjeni prednaučeni predstavitveni modeli	30
5.4	Grafovski modeli	32
5.4.1	Skupni arhitekturni cevovod	32
6	Eksperimentalni protokol in rezultati	41
6.1	Zasnova in prečno preverjanje	41
6.2	Nastavitve in vrednotenje	42
6.3	Rezultati	45
7	Diskusija in zaključek	51
7.1	Interpretacija rezultatov	51
7.2	Omejitve in doprinosi	52
7.3	Nadaljnje delo in zaključek	53
A	Dodatni rezultati	55
A.1	Oznake in dodatne metrike	55
A.2	Razširjeni rezultati	57
A.3	Dodatne analize	65
B	Dodatne metodološke podrobnosti	69
B.1	Hiperparametri in izbira nastavitvev	69
B.2	Izvedbene podrobnosti	71
B.3	Konstrukcija in značilke povezav	72
B.4	Ločeni prikazi tipov povezav	73
	Literatura	79

Seznam uporabljenih kratic

kratica	angleško	slovensko
AUC	area under the curve	ploščina pod krivuljo
CUDA	compute unified device architecture	arhitektura CUDA za računanje na grafičnih procesorjih
EEG	electroencephalography	elektroencefalografija
F1	F1 score	mera F1
GAT	graph attention network	grafovska pozornostna mreža
GCN	graph convolutional network	grafovska konvolucijska mreža
GELU	Gaussian error linear unit	aktivacijska funkcija GELU
GIN	graph isomorphism network	grafovska izomorfna mreža
GNN	graph neural network	grafovska nevronska mreža
LightGBM	light gradient boosting machine	metoda LightGBM z gradientno spodbujenimi odločitvenimi drevesi
LOSO	leave-one-subject-out cross validation	prečno preverjanje z izločitvijo enega udeleženca
MAHNOB-HCI	MAHNOB-HCI database	podatkovna zbirka MAHNOB-HCI
MLP	multilayer perceptron	večslojni perceptron
PyG	PyTorch Geometric	knjižnica PyTorch Geometric
RBF	radial basis function	radialna bazna funkcija
ST-GCN	spatio-temporal graph convolutional network	časovno-prostorska grafovska konvolucijska mreža
SVM	support vector machine	metoda podpornih vektorjev

Povzetek

Naslov: Grafovske nevronske mreže za klasifikacijo valence iz podatkov sledilnika pogleda

Avtor: Tomi Božak

V diplomski nalogi smo zasnovali in ovrednotili časovno-prostorsko grafovsko predstavitev podatkov sledilnika pogleda za binarno klasifikacijo valence. Meritve iz zbirke MAHNOB-HCI smo razdelili na desetsekundna okna in jih predstavili kot vozlišča s časovnimi, prostorskimi in fiksacijskimi povezavami. Primerjali smo homogeni GCN in tri heterogene različice z ločenim obravnavanjem relacij, učljivo fuzijo in utežmi povezav. S sedemkratnim prečnim preverjanjem po 22 udeležencih smo jih primerjali z modeli SVM, LightGBM, MLP, GazeMAE in MOMENT. Najboljši rezultat je dosegel SVM na koordinatah pogleda in velikostih zenic (točnost = 70,5 %, makro F1 = 69,7 %), najboljši grafovski model HeteroGCN-MLP pa samo na koordinatah pogleda (65,9 %, 65,8 %). Vsi grafovski modeli so presegli naključni in večinski klasifikator, vendar večja kompleksnost modela ne kaže doslednih izboljšav. V nalogi smo ugotovili, da grafovska predstavitev podatkov sledilnika pogleda vsebuje uporaben signal, vendar agregirane značilke ostajajo uspešnejše in računsko učinkovitejše za binarno klasifikacijo valence.

Ključne besede: grafovske nevronske mreže, časovno-prostorski grafi, podatki sledilnika pogleda, klasifikacija valence.

Abstract

Title: Graph Neural Networks for Valence Classification from Eye-Tracking Data

Author: Tomi Božak

In this thesis, we designed and evaluated a spatio-temporal graph representation of eye-tracking data for binary valence classification. Measurements from the MAHNOB-HCI dataset were divided into ten-second windows and represented as nodes connected by temporal, spatial, and fixation edges. We compared a homogeneous GCN with three heterogeneous variants incorporating relation-specific processing, learned relation fusion, and edge weights. Using seven-fold subject-wise cross-validation across 22 participants, we compared them with SVM, LightGBM, MLP, GazeMAE, and MOMENT. The best result was achieved by SVM using gaze coordinates and pupil sizes (accuracy = 70.5 %, macro F1 = 69.7 %), whereas the best graph model, HeteroGCN-MLP, used gaze coordinates alone (65.9 %, 65.8 %). All graph models outperformed the random and majority classifiers, but increasing model complexity did not yield consistent improvements. We conclude that the graph representation of eye-tracking data contains useful information, although aggregated features remain more accurate and computationally efficient for binary valence classification.


Keywords: graph neural networks, spatio-temporal graphs, eye-tracking data, valence classification.

Poglavje 1

Uvod

Za učenje iz podatkov, kjer niso pomembne zgolj lastnosti posameznih elementov, ampak tudi odnosi med njimi, lahko med drugim uporabimo grafovske nevronske mreže (GNN) [8, 17]. Primer takšnih podatkov so podatki sledilnika pogleda. Meritvam sledilnika pogleda lahko smiselno določimo časovne in prostorske odnose in jim s tem priredimo časovno-prostorski graf. Na tem grafu se z grafovsko nevronske mreže učimo predstavitev vozlišč in grafov, ki jih uporabimo za klasifikacijo grafa. Podatki, uporabljeni v tej nalogi, vsebujejo samoocene čustvenega stanja udeležencev, iz katerih smo izpeljali razrede valence. Valenca pri tem opisuje razpon čustvenega odziva od negativnega do pozitivnega. GNN smo učili binarno klasificirati valenco, rezultate pa smo primerjali z rezultati uveljavljenih negrafovskih pristopov.

Z izrazom *množica signalov* v tej nalogi označujemo podmnožico podatkov sledilnika pogleda, ki jo uporabimo v dotičnem poskusu. Eksperimentalno primerjavo smo izvedli na štirih množicah signalov: samo koordinatah pogleda (*samo pogled*), samo velikostih zenic (*samo zenici*), združenih koordinatah pogleda in velikostih zenic (*pogled in zenici*) ter vseh razpoložljivih signalih (*vsi signali*). Pregled celotnega eksperimentalnega toka je prikazan na sliki 1.1 – iz podatkovne zbirke smo izpeljali več vhodnih predstavitev, jih ovrednotili z različnimi družinami modelov in rezultate primerjali na problemu binarne klasifikacije valence.



Slika 1.1: Pregled naloge: priprava podatkov MAHNOB-HCI, tri glavne poti modeliranja, štiri množice signalov in povzetek eksperimentalne primerjave binarne klasifikacije valence iz podatkov sledilnika pogleda.

Raziskovalni problem naloge je zasnova, implementacija in ovrednotenje grafovske predstavitve podatkov sledilnika pogleda za binarno klasifikacijo valence.

Glavno raziskovalno vprašanje je: Kakšna je klasifikacijska uspešnost grafovske nevronske mreže za binarno klasifikacijo valence iz podatkov sledilnika pogleda v primerjavi s klasifikacijsko uspešnostjo uveljavljenih negrafovskih pristopov?

Dodatna podvprašanja so:

1. Kako podatke sledilnika pogleda smiselno predstaviti kot časovno-prostorski graf?
2. Kako se klasifikacijska uspešnost modelov razlikuje med posameznimi

množicami signalov sledilnika pogleda?

3. Kako se klasifikacijska uspešnost grafovskih modelov spreminja z večanjem arhitekturne kompleksnosti?
4. Kakšno je razmerje med klasifikacijsko uspešnostjo ter velikostjo in računsko zahtevnostjo primerjanih modelov?

V nadaljevanju v poglavju 2 najprej predstavimo teoretične osnove grafovskih nevronskih mrež, sorodna dela in metode učenja predstavitev iz podatkov pogleda. Poglavje 3 opisuje uporabljene podatke, samoocene čustvenega stanja, ciljne razrede in predobdelavo, v poglavju 4 pa opišemo konstrukcijo časovno-prostorskega grafa. V poglavju 5 predstavimo primerjane modele. Poglavje 6 združuje eksperimentalni protokol in rezultate glavne primerjave modelov na različnih množicah signalov. Nalogo sklenemo z interpretacijo rezultatov, omejitvami, doprinosi in možnostmi nadaljnjega dela v poglavju 7.

Pri pripravi diplomskega dela je bil kot podporno orodje uporabljen ChatGPT (GPT-5.5 Thinking) [24]. Uporabljen je bil za pisanje programske kode, pomoč pri strukturiranju poglavij, jezikovno in slogovno izboljševanje besedila, preverjanje razumljivosti razlage, iskanje terminoloških možnosti in prevodov, pripravo slik in tabel ter oblikovanje zapisov v okolju L^AT_EX. Orodje ni bilo uporabljeno kot samostojen vir znanstvenih trditev. Vse vsebinske trditve, uporabljeni viri, eksperimentalni rezultati, programska koda in končne odločitve so bili preverjeni, dopolnjeni, popravljeni in potrjeni s strani avtorja. V orodje niso bili vneseni osebni podatki udeležencev ali drugi zaupni podatki. Avtor prevzema polno odgovornost za vsebino diplomskega dela.

Poglavje 2

Teoretično ozadje in sorodna dela

To poglavje predstavi teoretične osnove grafovskih nevronske mreže in umesti obravnavano raziskavo med obstoječe pristope za delo s podatki sledilnika pogleda. Sorodna dela v tem poglavju obravnavamo z vidika vprašanja, kako podatke sledilnika pogleda predstaviti za klasifikacijo čustvenih oznak. Čustvena stanja se pogosto opisujejo z dimenzijama valence in vzburjenosti, pri čemer valenca opisuje razpon čustvenega odziva od negativnega do pozitivnega [19].

Najprej predstavimo osnove grafovskih nevronske mreže ter njihovo uporabo pri časovnih vrstah in časovno-prostorskih podatkih, saj je osrednji del raziskave pretvorba časovnega okna meritev sledilnika pogleda v graf. Nato povzamemo učenje predstavitev iz signalov in položaj predlaganega pristopa glede na sorodna dela.

2.1 Osnove grafovskih nevronske mreže

Graf definiramo kot

$$G = (V, E), \tag{2.1}$$

kjer je V množica vozlišč, $E \subseteq V \times V$ pa množica povezav med vozlišči. Vozlišča praviloma vsebujejo značilke $\mathbf{x}_i$, ki jih zapišemo v matriko

$$X \in \mathbb{R}^{|V| \times d}, \tag{2.2}$$

kjer je d število značilk posameznega vozlišča, operator $|\cdot|$ pa moč množice oziroma število njenih elementov. Povezavo med vozliščema i in j označimo z $e_{ij} \in E$. V usmerjenih grafih ima povezava določeno izvirno in ponorno vozlišče, zato v splošnem velja $e_{ij} \neq e_{ji}$. V neusmerjenih grafih pa povezave nimajo smeri, zato velja $e_{ij} = e_{ji}$. Strukturo grafa zapišemo z matriko sosednosti $\mathbf{A}$, za katero velja

$$A_{ij} = \begin{cases} 1, & e_{ij} \in E, \\ 0, & e_{ij} \notin E. \end{cases} \quad (2.3)$$

Pripadajoča diagonalna matrika stopenj $\mathbf{D}$ ima diagonalne elemente $D_{ii} = \sum_j A_{ij}$.

Povezave lahko vsebujejo tudi uteži. Utež povezave med vozliščema i in j označimo z w_{ij} . Za neutružene povezave si lahko predstavljamo, da imajo utež $w_{ij} = 1$. Če imajo povezave več uteži, jih zapišemo kot vektor $\mathbf{e}_{ij}$ [8].

Homogeni graf je graf, ki ne loči različnih vrst vozlišč in povezav. Heterogeni graf pa vsebuje vsaj dve različni vrsti vozlišč ali povezav.

Grafske nevronske mreže (GNN) so razred nevronske mreže, namenjen učenju nad podatki, ki jih lahko predstavimo z grafom [8, 17]. Cilj GNN je naučiti se predstavitev vozlišč, povezav ali celotnega grafa tako, da model pri izračunu predstavitve posameznega vozlišča upošteva tudi njegovo lokalno okolico.

Osnovna ideja GNN je *posredovanje sporočil* [8]. Vsako vozlišče v posamezni plasti prejme informacije od svojih sosedov, jih agregira in na podlagi zbranih informacij posodobi svojo predstavitev.

Splošno plast posredovanja sporočil lahko zapišemo kot

$$\mathbf{h}_j^{(k)} = \phi^{(k)} \left(\mathbf{h}_j^{(k-1)}, \bigoplus_{i \in \mathcal{N}(j)} \psi^{(k)} \left(\mathbf{h}_j^{(k-1)}, \mathbf{h}_i^{(k-1)}, \mathbf{e}_{ij} \right) \right), \quad (2.4)$$

kjer je $\mathcal{N}(j)$ množica sosedov vozlišča j , $\psi^{(k)}$ funkcija sporočila, $\oplus$ agregacijska funkcija, $\phi^{(k)}$ funkcija posodobitve, $\mathbf{h}_j^{(k)}$ pa predstavitev vozlišča j v plasti k . Funkcija $\psi^{(k)}$ je lahko na primer linearna preslikava ali večslojni

perceptron nad predstavitvama vozlišč in značilkami povezave, $\phi^{(k)}$ pa preprosta vsota prejšnje predstavitve vozlišča in agregiranega sporočila, večslojni perceptron ali rekurentna enota. Isti funkciji $\psi^{(k)}$ in $\phi^{(k)}$ uporabimo pri vseh vozliščih, zato je plast ob invariantni agregaciji ekvivariantna na permutacijo vozlišč, kar pomeni, da preureditev vozlišč le enako preuredi njihove izhodne predstavitve. Agregacijska funkcija $\oplus$ mora biti invariantna na vrstni red sosedov. To lastnost imajo na primer vsota, povprečje in maksimum, zato lahko ista GNN plast deluje na grafih različnih velikosti. Pri časovnih vrstah je ureditev meritev sicer naravno določena s časom, vendar jo mora model zajeti eksplicitno, na primer s časovnimi povezavami ali časovnimi značilkami, saj se z grafovsko predstavitvijo sicer izgubi.

Pri heterogenem grafu, kjer povezave razdelimo po tipih oziroma relacijah $r \in \mathcal{R}$, namesto ene same množice sosedov obravnavamo množice $\mathcal{N}_r(j)$, ki vsebujejo sosedje vozlišča j po relaciji r . Sporočila se najprej agregirajo ločeno znotraj posamezne relacije:

$$\mathbf{m}_{j,r}^{(k)} = \bigoplus_{i \in \mathcal{N}_r(j)} \psi_r^{(k)} \left(\mathbf{h}_i^{(k-1)}, \mathbf{e}_{ij} \right). \quad (2.5)$$

Pri tem je $\psi_r^{(k)}$ funkcija sporočila za relacijo r , $\mathbf{m}_{j,r}^{(k)}$ pa agregirano sporočilo, ki ga vozlišče j prejme po tej relaciji v plasti k . Za vsako relacijo lahko uporabimo ločeno linearno preslikavo ali večslojni perceptron $\psi_r^{(k)}$, agregacija znotraj posamezne relacije pa mora biti, tako kot prej, invariantna na vrstni red sosedov. Relacijska sporočila $\mathbf{m}_{j,r}^{(k)}$ se nato združijo v skupno sporočilo za vozlišče. Združevanje relacij je lahko vsota ali povprečje, lahko pa vključuje konkatencijo oziroma učljivo fuzijo relacijskih predstavitev, pri čemer mora biti vrstni red relacij vnaprej določen.

Če želimo napovedati razred celotnega grafa, lahko nalogo obravnavamo kot klasifikacijo na ravni grafa. Naj bo L število plasti grafovske nevronske mreže. Na zadnji, L -ti plasti dobimo končne predstavitve vozlišč $\mathbf{h}_i^{(L)}$, ki jih združimo v predstavitev celotnega grafa:

$$\mathbf{h}_G = \text{READOUT} \left(\{ \mathbf{h}_i^{(L)} : i \in V \} \right). \quad (2.6)$$

Funkcija READOUT je agregacijska funkcija na ravni grafa. Pogoste izbire so povprečje, vsota, maksimum ali združevanje s pozornostjo. Predstavitev grafa $\mathbf{h}_G$ nato uporabimo v klasifikacijski glavi, ki napove razred celotnega grafa.

2.2 GNN za časovno-prostorske podatke

Za modeliranje časovnih vrst se pogosto uporabljajo rekurentne nevronske mreže z dolgim kratkoročnim spominom (LSTM, angl. *long short-term memory*) in transformerji, ki modelirajo časovne odvisnosti med meritvami [15]. Grafovski predstavitev je smiselna, kadar želimo poleg časovne urejenosti eksplicitno modelirati tudi odnose med več časovnimi vrstami ali prostorske odnose med meritvami [15]. Pregled GNN za časovne vrste to področje obravnava skozi naloge napovedovanja, klasifikacije, imputacije in zaznavanja anomalij. Za obravnavani problem je pomembna predvsem formulacija, pri kateri posamezno časovno okno pretvorimo v grafovsko predstavitev in razred napovemo na ravni celotnega grafa.

Pri podatkih sledilnika pogleda imajo meritve poleg časovnega vrstnega reda tudi prostorsko komponento, saj je vsaka veljavna meritev vezana na položaj pogleda na zaslonu. Podobno ločevanje časovnih in prostorskih odvisnosti uporablja na primer časovno-prostorska grafovski konvolucijska mreža ST-GCN (angl. *spatio-temporal graph convolutional network*) pri napovedovanju prometa, kjer grafovski konvolucija modelira prostorske povezave med senzorji, časovna konvolucija pa dinamiko signala skozi čas [35]. Pri predlaganem pristopu je to uporabna metodološka analogija, saj ne napovedujemo prihodnjih meritev, temveč klasificiramo razred časovnega okna meritev.

2.3 Učenje predstavitev iz signalov

Poleg ročno oblikovanih značilk obstajajo pristopi, ki se predstavitev naučijo neposredno iz zaporedij meritev. S tem zmanjšajo odvisnost od ročne

izbire značilke, hkrati pa so njihove predstavitve vezane na podatke in naloge, uporabljene pri predtreniranju. Takšni modeli služijo kot most med klasičnimi modeli na ročno agregiranih značilkah in grafovskimi modeli, ki se predstavitev učijo na sami strukturi podatkov.

GazeMAE je primer odprtokodnega modela, zasnovanega posebej za očesne gibe, ki z dvema časovno-konvolucijskima avtokodirnikoma ločeno kodira zaporedji koordinat pogleda in iz njih izračunanih hitrosti. Pri samonadzorovanem učenju avtokodirnika rekonstruirata delno izpuščene vrednosti signalov [2]. **MOMENT** je splošnejši prednaučen temeljni model za časovne vrste, ki signal razdeli na dele fiksne dolžine in jih kodira z arhitekturo transformerjev. Pri predtreniranju naključno zakrije nekatere dele signala in se uči njihove rekonstrukcije iz preostalega konteksta. Ker njegov vhod ni omejen na koordinate zaslona, je uporaben kot primerjava pri ostalih signalih [10].

2.4 Položaj naloge glede na sorodna dela

Pregled sorodnih del kaže, da se podatki sledilnika pogleda pri prepoznavanju čustvenih stanj najpogosteje uporabljajo v obliki ročno oblikovanih značilk ali zaporedij meritev [19, 30, 21]. Tudi izvirni članek podatkovne zbirke MAHNOB-HCI uporablja ročno oblikovane značilke pogleda: pri trirazredni klasifikaciji valence po protokolu LOSO (angl. *leave-one-subject-out*) – pri katerem je vsak udeleženec enkrat uporabljen kot testna množica – so avtorji dosegli točnost 68,8 % in povprečno mero F1 68 % [27]. Ti rezultati niso neposredno primerljivi z rezultati tega dela, saj smo uporabili binarno klasifikacijo, drugačna časovna okna in drug eksperimentalni protokol.

Grafovski modeli so pogosteje uporabljeni pri drugih vrstah časovno-prostorskih podatkov oziroma pri fizioloških signalih, predvsem pri elektroencefalografskih signalih (EEG), kjer vozlišča običajno predstavljajo elektrode ali možganska področja [28, 37, 20]. Obstajajo tudi večmodalni pristopi za prepoznavo čustev iz EEG in podatkov očesnih gibov [33, 21]. Ker v pregledu sorodnih del nismo našli pristopa, ki bi podatke sledilnika pogleda samostojno

obravnaval kot časovno-prostorski graf posameznih meritev, preverjamo uporabnost takšne predstavitve pri klasifikaciji čustvenih oznak. Diplomsko delo torej povezuje (1) binarno klasifikacijo valence iz podatkov sledilnika pogleda, (2) GNN za časovno-prostorske podatke ter (3) primerjavo ročno oblikovanih, samonaučenih in grafovskih predstavitev časovnih oken.

Poglavje 3

Podatki in predobdelava

V tem poglavju opišemo podatke sledilnika pogleda, katero podatkovno zbirko smo izbrali in zakaj ter kako smo podatke predprocesirali.

3.1 Podatkovne zbirke sledilnika pogleda

Sledilnik pogleda je naprava, ki meri, kam v prostoru ali na zaslonu oseba usmerja pogled. Poleg lokacije pogleda lahko meri tudi velikost zenic, ki jo običajno opišemo s premerom zenice. Signal pogleda navadno opišemo s koordinatama x in y na zaslonu. Iz dinamike teh dveh signalov nekateri sledilniki zaznavajo in poročajo tudi informacije o fiksacijah, sakadah in mežikih, ki nas v tej domeni pogosto zanimajo. Fiksacija je obdobje razmeroma stabilnega pogleda na omejenem območju, sakada hiter premik pogleda med fiksacijama, mežik pa kratkotrajno zaprtje oči [19]. Meritve se izvajajo zaporedno z določeno frekvenco vzorčenja (pogosto med 60 Hz in 1000 Hz), ki je odvisna od zmogljivosti naprave in namena uporabe.


Na voljo je več prosto dostopnih podatkovnih zbirk sledilnika pogleda, ki se razlikujejo po vrsti zajetih signalov. Tukaj naštejemo le nekatere. Najpogostejše vsebujejo koordinate pogleda in velikosti zenic, vendar so nekateri podatki omejeni zgolj na velikosti zenic [25] ali koordinate pogleda [3]. Zbirki COLET in GazeBase vsebujejo podatke o pogledu in velikosti zenic [18, 11],

zbirki MAHNOB-HCI in eSEEd_v2 pa poleg njih vključujeta še dodatne informacije [27, 26].

Podatkovna zbirka MAHNOB-HCI

Podatkovna zbirka MAHNOB-HCI je večmodalna zbirka za prepoznavanje čustev in implicitno označevanje multimedijskih vsebin [27]. Zbirka vsebuje dva glavna eksperimentalna sklopa: (1) prepoznavanje čustvenih stanj iz odzivov na videoposnetke in (2) implicitno označevanje na podlagi odzivov na pravilne oziroma napačne oznake pod sliko ali posnetkom. Odzive sinhrono zajame z videoposnetkom obraza, zvokom, elektroencefalogramom (EEG), fiziološkimi signali – elektrokardiogramom (EKG), galvanskim odzivom kože (GSR), amplitudo dihanja in temperaturo kože – ter signali sledilnika pogleda. Meritve sledilnika pogleda so bile zajete s sledilnikom Tobii X120 pri frekvenci 60 *Hz*. V tej nalogi smo uporabili samo prvi sklop, to je eksperiment vzbujanja čustev z videoposnetki, in izključno signale sledilnika pogleda.

Izvirni članek poroča o 30 rekrutiranih udeležencih. Udeležence P9, P12 in P15 so avtorji izključili zaradi tehničnih težav oziroma nepopolnega zajema podatkov. Po vzoru izvirnega članka smo izključili iste tri udeležence, poleg tega pa tudi udeležence, za katere ni bilo na voljo podatkov iz eksperimentov vzbujanja čustev. V eksperimentu vzbujanja čustev so udeleženci gledali 20 videoposnetkov. Pred vsakim posnetkom, ki naj bi vzbujal določeno čustvo, je bil prikazan še kratek nevtralni posnetek, odziv nanj pa je bil shranjen ločeno. Po ogledu posameznega posnetka so udeleženci podali samoocene čustvenega stanja – številski oceni valence in vznburjenosti, diskretno samooceno čustvenega stanja ter nekaj dodatnih ocen, ki jih nismo uporabili.



Slika 3.1: Porazdelitev 10-sekundnih oken po razredih binarne valence.

3.2 Samoocene čustvenega stanja in ciljni razredi

Ciljni razredi v tej nalogi izhajajo iz diskretnih samoocen čustvenega stanja, ki so jih udeleženci podali po ogledu videoposnetka. Diskretne samoocene čustvenega stanja smo preslikali v razrede valence skladno s preslikavo iz izvirnega članka [27], ki je prikazana v dodatku A.1. S tem smo najprej dobili tri razrede: negativno, nevtralno in pozitivno valenco. Nevtralni razred smo odstranili, da ciljna naloga vsebuje izrazitejši kontrast med razredoma in da imajo modeli boljše pogoje za učenje vzorcev v podatkih.

Razred valence je določen na ravni kombinacije udeleženca in videoposnetka. Vsa časovna okna in s tem vsi grafi istega ogleda videoposnetka posledično pripadajo istemu razredu. Porazdelitev oken po odstranitvi nevtralnega razreda prikazana na sliki 3.1 kaže, da sta končna razreda pri vseh množicah signalov skoraj uravnotežena.

Vzbujenosti v tej nalogi nismo klasificirali. Razlog je predvsem večja šumnost razredov v uporabljeni podatkovni zbirki. Kot kaže prikaz ujemanja izpeljanih razredov s samoocenami v dodatku A.3, se samoocene stopnje

vzbujenosti slabše ujemajo z definiranimi razredi kot samoocene valence.

3.3 Priprava podatkov za učenje

V tem razdelku opišemo skupne korake priprave podatkov: izbiro in čiščenje signalov, standardizacijo ter tvorbo časovnih oken. Predobdelava pri tem označuje celoten postopek priprave podatkov pred učenjem modelov, čiščenje pa njegov ožji del, ki vključuje izbor uporabnih zapisov ter obravnavo neveljavnih, manjkajočih in osamelih meritev.

3.3.1 Množice signalov in čiščenje podatkov

Tukaj navedemo konkretne skupine signalov, ki smo jih uporabili v eksperimentih. Indeks i označuje posamezno meritev sledilnika pogleda. V uporabljeni podatkovni zbirki imamo na voljo pet osnovnih vrst signalov. To so:

- časovni žig meritve t_i ,
- koordinati pogleda na zaslonu (x_i, y_i) – povprečje med meritvama levega in desnega očesa,
- velikost leve in desne zenice $(p_i^{(l)}, p_i^{(r)})$,
- oddaljenost od sledilnika pogleda d_i^{sled} ter
- **informacija o fiksacijah**, tj. pripadnost fiksaciji ter trajanje fiksacije.

Za boljšo preglednost v besedilu in slikah uporabljamo enako barvno označevanje signalov tudi v nadaljevanju.

Da bi preverili robustnost modelov glede na razpoložljivost vhodnih signalov ter primerjali njihovo klasifikacijsko uspešnost za posamezne tipe vhodnih signalov, smo podatke MAHNOB-HCI razdelili v štiri delno prekrivajoče se eksperimentalne množice signalov. V vseh štirih množicah smo uporabili informacijo o času. Množica *samo pogled* poleg časa vsebuje koordinati pogleda, množica *samo zenici* vsebuje velikosti leve in desne zenice, množica


pogled in zenici združi koordinati pogleda in velikosti zenic, množica *usi signali* pa doda še oddaljenost od sledilnika pogleda in informacijo o fiksacijah. Podrobna povezava med temi množicami, značilkami vozlišč in razpoložljivimi tipi povezav je podana pri opisu grafovske konstrukcije v razdelku 4.3.

Izbrane podatke smo pred uporabo očistili. Najprej smo iz lokalne kopije zbirke MAHNOB-HCI odstranili podatke, ki jih v tej nalogi nismo uporabili, in ohranili le podatke eksperimenta vzbujanja čustev. Nato smo odstranili vrstice brez signalov pogleda ali velikosti zenic. Na voljo smo imeli tudi signale veljavnosti, na podlagi katerih smo odstranili meritve, za katere je sledilnik poročal, da je meritev za vsaj eno oko neveljavna. Dodatno smo uporabili filter osamelcev q01–q99, ki je odstranil meritve, pri katerih je bil vsaj eden od štirih osnovnih signalov pod prvim ali nad devetindevetdesetim percentilom, saj te vrednosti močno izkrivljajo porazdelitve signalov. Na koncu smo kratke vrzeli v numeričnih signalih linearno interpolirali, signala velikosti leve in desne zenice pa dodatno zgladili s kratkim centriranim drsečim povprečjem treh meritev. Okno smo uporabili, če je po čiščenju in filtriranju vsebovalo vsaj 60 veljavnih meritev.


Porazdelitvi položajev pogleda in velikosti zenic po čiščenju sta za množico signalov *pogled in zenici* prikazani na slikah 3.2 in 3.3. Na sliki 3.3 je opazen tudi rahel sistematični zamik med porazdelitvama velikosti leve in desne zenice, ki ga izvirni članek o zbirki MAHNOB-HCI ne obravnava [27]. Ker zamik ni vezan na posameznega udeleženca, je naša hipoteza, da to ni fiziološka asimetrija, temveč merilni artefakt sledilnika pogleda.

3.3.2 Standardizacija in tvorba časovnih oken

Posamezne skupine signalov so izražene v različnih velikostnih redih. Modeli strojnega učenja, kot so metoda podpornih vektorjev (SVM), večslojni perceptron (MLP) in GNN, so občutljivi na velikostni red vhodnih značilk oziroma signalov. Zato smo vsako meritev x za vsak signal standardizirali po formuli $\frac{x-\mu}{\sigma}$. Povprečje μ in standardni odklon σ smo izračunali na učni podmnožici, nato pa na validacijski in testni podmnožici standardizacijo



Slika 3.2: Toplotni prikaz položajev pogleda v očiščenih podatkih za množico signalov *pogled in zenici*.



Slika 3.3: Porazdelitev velikosti leve in desne zenice v očiščenih podatkih za množico signalov *pogled in zenici*.

uporabili z istimi parametri kot na učni. Pri grafovskih modelih smo na enak način standardizirali tudi značilke povezav, kadar jih je uporabljena množica signalov vsebovala.

Nato smo časovno vrsto razdelili na neprekrivajoča se časovna okna dolžine $T = 10$ s. Vsako uporabno časovno okno je predstavljalo en učni primer. Za 10 s smo se odločili na podlagi sorodnega dela na podatkih sledilnika pogleda, kjer so se daljša okna med dolžinami 1, 3, 5 in 10 s praviloma izkazala za bolj informativna [5]. Daljših oken nismo uporabili, ker bi težje predpostavili, da celotno okno opisuje enoten čustveni odziv, saj se lahko ta med ogledom posnetka že opazno spremeni [36]. Tudi sorodna dela, ki prepoznava čustva iz očesnih signalov, pogosto uporabljajo razmeroma kratka okna [32, 33].

Pri frekvenci vzorčenja 60 Hz bi 10-sekundno okno brez manjkajočih vrednosti vsebovalo 600 vzorcev. Zaradi čiščenja, odstranjevanja neveljavnih vzorcev in filtriranja je dejansko število vzorcev v oknih manjše. Po filtru osamelcev je ostalo 2.639.048 meritev in 5.158 uporabnih 10-sekundnih časovnih oken, kar pomeni povprečno približno 512 meritev na uporabno okno. Pri kasnejši gradnji grafov se število vozlišč nekoliko razlikuje med množicami signalov; te vrednosti povzemamo v tabeli 4.2.

Po tvorbi časovnih oken se cevovod razdeli glede na uporabljeno predstavitev. Negrafovski osnovni modeli iz okna dobijo agregirane tabelarične značilke, zamrznjeni prednaučeni predstavitveni modeli neposredno prejmejo časovne vrste izbranih signalov sledilnika pogleda, grafovski modeli pa grafovsko predstavitev okna. Podrobnosti teh predstavitev so opisane v poglavjih 4 in 5. Tabela 3.1 povzema, kako se skozi opisane korake predobdelave zmanjša količina podatkov.

Tabela 3.1: Zmanjševanje količine podatkov od izvirne zbirke MAHNOB-HCI do končnih časovnih oken. Stolpec Vrstice pri vseh korakih razen zadnjem predstavlja število meritev, pri zadnjem pa število časovnih oken, od katerih vsako vsebuje več meritev.

Korak	Vrstice	Udeleženci	Opis
Izbira izvirne zbirke MAHNOB-HCI	–	30	Večmodalna zbirka; izvirni članek v analizi uporabi 27 udeležencev.
Izbira podmnožice s samooocenami čustvenega stanja	3.797.165	24	Ohranimo le posnetke iz eksperimenta vzbujanja čustev, ki imajo podatke sledilnika pogleda in samoocene čustvenega stanja.
Izključitev manj kakovostnih udeležencev	3.535.842	22	Izključena P9 ter P12. P15 izključen že prej, ker nima samooznak čustev.
Izbira vrstic z veljavnimi samooocenami	2.995.632	22	Ohranimo le vrstice s podatki, uporabljenimi za učenje modelov samoocen čustvenega stanja.
Priprava podatkov za učenje	2.814.005	22	Odstranjene so vrstice brez signalov pogleda ali zenic.
Filter osamelcev q01–q99	2.639.048	22	Robustno filtriranje štirih osnovnih signalov pogleda in zenic.
Tvorba uporabnih* 10-sekundnih časovnih oken	5.158	22	Vsako okno postane en učni primer oziroma graf.

Opomba: * Za uporabno štejemo časovno okno, ki po čiščenju in filtriranju osamelcev vsebuje najmanj 60 veljavnih meritev sledilnika pogleda.

Poglavje 4

Grafovski predstavitev podatkov sledilnika pogleda

V prejšnjem poglavju smo podatke sledilnika pogleda pripravili za učenje modelov strojnega učenja. V tem poglavju opišemo, kako smo posamezno časovno okno meritev pretvorili v graf, ki smo ga uporabili kot vhod za grafovskie modele. Vozlišča predstavljajo veljavne meritve znotraj okna, povezave pa izbrane odnose med meritvami.

Najprej podamo najbogatejšo grafovsko predstavitev učnega vzorca, ki uporablja vse razpoložljive signale množice *vsi signali*. Nato pokažemo, kako se ista osnovna konstrukcija prilagodi ostalim trem množicam signalov iz poglavja 3.3. Kadar določena množica signalov ne vsebuje informacije, potrebne za posamezno značilko ali relacijo, ta del predstavitve izpustimo. Graf zato v štirih primerih predstavlja isti učni vzorec, razlikuje pa se po količini vhodne informacije in po razpoložljivih relacijah med meritvami.

4.1 Graf in vozlišča

Posamezno 10 s časovno okno predstavimo kot graf $G = (V, E)$, v katerem vozlišča predstavljajo veljavne meritve sledilnika pogleda, povezave pa časovne, prostorske in fiksacijske odnose med njimi. Osnovni pojmi in zapis grafov so

predstavljeni v razdelku 2.1. V tej nalogi smo uporabili heterogeno grafovsko predstavitev, saj smo ločili več tipov povezav. Vsako vozlišče v_i predstavlja eno meritev sledilnika pogleda x_i v trenutku i znotraj časovnega okna:

$$v_i \leftrightarrow \mathbf{x}_i. \quad (4.1)$$

Če okno vsebuje n veljavnih meritev, potem graf vsebuje n vozlišč. Število n se lahko med okni zaradi čiščenja in filtriranja razlikuje, kar GNN podpira, kot je pojasnjeno v razdelku 2.1.

Vektor značilk vozlišča za končni graf za množico *vsi signali* je

$$\mathbf{x}_i = \left[t_i, x_i, y_i, p_i^{(l)}, p_i^{(r)}, d_i^{\text{sled}}, f_{dur,i} \right], \quad (4.2)$$

Oznake signalov so uvedene v razdelku 3.3, dodatna značilka $f_{dur,i}$ pa pomeni trajanje fiksacije.

Naj bo $\tilde{t}_i$ izvirni relativni časovni žig meritve, $\tilde{t}_0$ časovni žig prve veljavne meritve v oknu, $T = 10$ s pa dolžina okna. Normaliziran časovni žig izračunamo s formulo

$$t_i = \frac{\tilde{t}_i - \tilde{t}_0}{T}. \quad (4.3)$$

Tako ima prva veljavna meritev v oknu časovno značilko $t_0 = 0$, preostale meritve pa so izražene relativno na dolžino okna.

4.2 Relacije in značilke povezav

Definiramo tri relacije med meritvami: časovno, prostorsko in fiksacijsko. Posledično v grafu oblikujemo štiri tipe povezav, saj je časovni tip povezave usmerjen – bodisi naprej bodisi nazaj. Prostorske in fiksacijske povezave obravnavamo kot neusmerjene.

Vsaka povezava ima določen tip relacije, saj časovna, prostorska in fiksacijska povezava opisujejo različne odnose med meritvami. Ta zapis heterogenim grafovskim modelom, opisanim v poglavju 5, omogoča ločeno obravnavo relacij.

4.2.1 Časovne povezave

Časovne povezave povezujejo meritve zaporedne v času. Naj bodo vozlišča v posameznem oknu urejena po času, tako da je v_i i -ta meritev v časovnem zaporedju. Ločimo usmerjene časovne povezave:

- naprej $E_t^+ = \{(v_i, v_j) : 1 \leq j - i \leq k_t\}$ in
- nazaj $E_t^- = \{(v_i, v_j) : 1 \leq i - j \leq k_t\}$.

Parameter $k_t \in \mathbb{N}$ določa število časovnih sosedov na vsako stran. Končna konfiguracija uporablja $k_t = 1$, zato je vozlišče v_i povezano samo z neposredno predhodno in neposredno naslednjo meritvijo, kadar ti vozlišči obstajata.

Povezave v E_t^+ potekajo od prejšnjih proti kasnejšim meritvam, povezave v E_t^- pa od kasnejših proti prejšnjim meritvam. Pri grafu z n vozlišči to pri $k_t = 1$ pomeni $n - 1$ časovnih povezav naprej in $n - 1$ časovnih povezav nazaj. Za polno 10-sekundno okno s pričakovanimi 600 meritvami je to 599 povezav v vsako smer.

4.2.2 Prostorske povezave

Prostorske povezave tvorijo množico E_s neusmerjenih povezav, ki povezujejo meritve s podobnim položajem pogleda znotraj istega časovnega okna. Zato so na voljo le pri množicah signalov *samo pogled*, *pogled in zenici* in *vsii signali*, ki vsebujejo koordinati pogleda (x, y) .

Prostorsko razdaljo med meritvama i in j definiramo evklidsko:

$$d_{ij}^{\text{zaslon}} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}. \quad (4.4)$$

Za vsako vozlišče v_i poiščemo k_s najbližjih sosedov v prostoru koordinat pogleda (x, y) z uporabo k-d drevesa, podatkovne strukture za učinkovito iskanje sosedov v večrazsežnem prostoru. Če je v_j med temi sosedi, dodamo povezavo med vozliščema v_i in v_j . Ker prostorske povezave obravnavamo kot neusmerjene, povezavo predstavimo z dvema usmerjenima povezavama (v_i, v_j) in (v_j, v_i) . Na koncu iz množice E_s odstranimo podvojene povezave.

Število prostorskih povezav torej ni določeno samo z n in k_s , ampak tudi z geometrijo položajev pogleda. Pred simetrizacijo vsako vozlišče prispeva k_s sosedskih izbir, po simetrizaciji in odstranitvi podvojenih parov pa za usmerjeni zapis neusmerjene relacije velja

$$nk_s \leq |E_s| \leq 2nk_s. \quad (4.5)$$

Dejansko gostoto prostorskih povezav poročamo z opazovanimi statistikami grafov v tabeli 4.2.

4.2.3 Fiksacijske povezave


Fiksacijske povezave tvorijo množico E_f in povezujejo meritve, ki pripadajo isti zaznani fiksaciji. Pripadnost fiksaciji določimo z identifikatorjem fiksacije, podanim v MAHNOB-HCI podatkih. Ta podatek imamo zgolj v množici *vsil signali*, zato so te povezave vključene le v končni graf.

Redčenje povezav znotraj fiksacije

Znotraj posamezne fiksacije ne povežemo vseh vozlišč med seboj, saj bi to povzročilo preveliko število fiksacijskih povezav. Za to nalogo smo zato definirali redkejšo konstrukcijo, ki jo imenujemo *razširjene povezave znotraj fiksacije* (angl. *dilated intra-fixation edges*). Ta ohrani pripadnost isti fiksaciji, ne da bi graf postal pregost. Parameter $k_f = 3$ iz vsakega vozlišča generira tri povezave – eno do neposrednega naslednika in dve do meritev na približno enakomerno razporejenih položajih znotraj iste fiksacije. Na ta način združimo lokalne in bolj oddaljene povezave znotraj fiksacije, hkrati pa se izognemo kvadratni rasti števila povezav pri polni kliku. Shematski prikaz je na sliki 4.1, formalna definicija konstrukcije pa v dodatku B.3.

4.2.4 Značilke povezav

Povezavam smo poleg tipa relacije priredili tudi značilke povezav, ki opisujejo odnos med izvirno meritvijo v_i in ciljno meritvijo v_j . Osnovne časovne



Slika 4.1: Shematski prikaz razširjenih povezav znotraj ene fiksacije za povprečno velikost fiksacije. Iz $F = 21$ in $k_f = 3$ izračunamo $s = 7$ in $D = \{1, 8, 15\}$. Število plasti GNN je $L = 2$, kar vpliva na doseg sporočila posameznega vozlišča in gostoto grafa. Vozlišča so prikazana v krogu z lokalnimi indeksi znotraj fiksacije. Odtenka modrih povezav ločita neposredne sosede izbranega vozlišča $v = 0$ in dodatna vozlišča, dosegljiva v drugem skoku po fiksacijski relaciji.

značilke so normalizirani čas izvirne in ciljne meritve, t_i in t_j , ter časovna razlika $\Delta t = t_j - t_i$. Čeprav bi model te časovne značilke načeloma lahko izpeljal iz značilk obeh vozlišč, smo jih vključili neposredno, da bi mu olajšali učenje časovnih odnosov med meritvama. Pri časovnih povezavah smo dodali še smer ρ_{ij} , kjer ima povezava naprej vrednost $\rho_{ij} = 1$, povezava nazaj pa $\rho_{ij} = -1$. Značilke povezav so del grafovske predstavitve, vendar jih uporabi le model **HeteroGCN-MLP-w**, opisan v poglavju 5.

Pri grafih, ki vsebujejo koordinate pogleda, smo povezavam dodali tudi prostorske značilke. To sta razliki v koordinatah pogleda, $\Delta x = x_j - x_i$ in $\Delta y = y_j - y_i$, ter evklidska razdalja med položajema pogleda na zaslonu d_{ij}^{zaslon} . Te značilke so zato na voljo pri vseh množicah signalov, razen pri množici *samo zenici*.

Pri grafih, ki vsebujejo velikosti zenic, smo povezavam dodali spremembi velikosti leve in desne zenice. Značilki $\Delta p_{ij}^{(l)} = p_j^{(l)} - p_i^{(l)}$ in $\Delta p_{ij}^{(r)} = p_j^{(r)} - p_i^{(r)}$ sta na voljo pri množicah *samo zenici*, *pogled in zenici* ter *vsi signali*.

Pri množici *vsi signali* smo povezavam dodali še značilko, povezano z oddaljenostjo od sledilnika pogleda. Značilka $\Delta d_{ij}^{\text{sled}} = d_j^{\text{sled}} - d_i^{\text{sled}}$ opisuje razliko v oddaljenosti od sledilnika pogleda med ciljno in izvirno meritvijo.

Podroben pregled značilk povezav je podan v tabeli B.3 v dodatku B.

4.3 Grafovska predstavitev po množicah signalov

Za vsako množico signalov, definirano v razdelku 3.3, smo graf zgradili po zgoraj opisani osnovni konstrukciji. Tabela 4.1 povzema razlike v uporabljenih značilkah vozlišč, relacijah in značilkah povezav. Na sliki 4.2 vidimo podgraf za množico *vsi signali* na majhnem izseku časovnega okna. Razvidni so vsi tipi povezav in za eno vozlišče primer vektorja značilk vozlišča.

Tabela 4.1: Množice signalov in pripadajoča grafovskaja konstrukcija. Značilke povezav uporabi le model HeteroGCN-MLP-w pri izračunu ucljivih predznačenih uteži povezav. Smer ρ_{ij} velja samo za časovne povezave.

Množica signalov	Značilke vozlišč	Relacije	Značilke povezav
<i>samo pogled</i>	t_i, x_i, y_i	E_t^+, E_t^-, E_s	$t_i, t_j, \Delta t, \rho_{ij}, \Delta x, \Delta y, d_{ij}^{\text{zaslon}}$
<i>samo zenici</i>	$t_i, p_i^{(l)}, p_i^{(r)}$	E_t^+, E_t^-	$t_i, t_j, \Delta t, \rho_{ij}, \Delta p_{ij}^{(l)}, \Delta p_{ij}^{(r)}$
<i>pogled in zenici</i>	$t_i, x_i, y_i, p_i^{(l)}, p_i^{(r)}$	E_t^+, E_t^-, E_s	$t_i, t_j, \Delta t, \rho_{ij}, \Delta x, \Delta y, d_{ij}^{\text{zaslon}}, \Delta p_{ij}^{(l)}, \Delta p_{ij}^{(r)}$
<i>usi signali</i>	$t_i, x_i, y_i, p_i^{(l)}, p_i^{(r)}, d_i^{\text{sled}}, f_{dur,i}$	E_t^+, E_t^-, E_s, E_f	$t_i, t_j, \Delta t, \rho_{ij}, \Delta x, \Delta y, d_{ij}^{\text{zaslon}}, \Delta p_{ij}^{(l)}, \Delta p_{ij}^{(r)}, \Delta d_{ij}^{\text{sled}}$

Opomba: Barve označujejo čas, pogled in prostorske značilke, zenici ter dodatne signale.


Statistika konstruiranih grafov

Tabela 4.2 prikazuje osnovne statistike grafov, ki nastanejo pri končni konfiguraciji konstrukcije. Vrednosti so izračunane za osrednjo eksperimentalno nalogo, tj. binarno klasifikacijo negativne in pozitivne valence. Ker se posamezne množice signalov filtrirajo glede na razpoložljivost uporabljenih signalov, število konstruiranih grafov med stolpci ni povsem enako.

Ničelne vrednosti pri prostorskih in fiksacijskih povezavah pomenijo, da ta relacija pri posamezni množici signalov ni del konstrukcije. Največjo razliko v gostoti grafa povzroči fiksacijska relacija pri množici *usi signali*, kjer fiksacijske povezave doprinesejo 62,4 % vseh povezav.

Tabela 4.2: Osnovne statistike konstruiranih grafov pri $k_t = 1$, $k_s = 1$ in $k_f = 3$.

Statistika	<i>samo pogled</i>	<i>samo zenici</i>	<i>pogled in zenici</i>	<i>vsí signali</i>
Število grafov	5.097	5.065	5.055	5.034
Mediana $ V $	591	601	585	561
Mediana $ E $	2.047	1.200	2.029	5.153
Mediana $ E_t^+ $	590	600	584	560
Mediana $ E_t^- $	590	600	584	560
Mediana $ E_s $	860	0	855	825
Mediana $ E_f $	0	0	0	3.210



Slika 4.2: Primer grafske konstrukcije za množico *vsí signali*. Vozlišča predstavljajo meritve v izseku časovnega okna, povezave pa prikazujejo časovne, prostorske in fiksacijske relacije. Ločeni prikazi posameznih relacij so zbrani v dodatku B.4.

Poglavje 5

Primerjani modeli

V nalogi se osredotočamo na primerjavo štirih družin modelov strojnega učenja za klasifikacijo valence iz podatkov sledilnika pogleda. V tem poglavju razložimo, katere so te družine, in na kratko opišemo vsak uporabljen model znotraj družine. Grafovske modele opišemo podrobneje, saj predstavljajo metodološko jedro naloge, poleg tega pa so za podatke sledilnika pogleda manj standardiziran pristop kot uveljavljeni klasični modeli.

Modeli se razlikujejo po predstavitvi vhodnih podatkov. Negrafovski osnovni modeli prejmejo agregirano tabelarično predstavitev posameznega časovnega okna (značilke), zamrznjeni prednaučeni predstavitveni modeli dobijo časovne vrste izbranih signalov, grafovski modeli pa delujejo na grafu, ki predstavlja časovno okno meritev.

5.1 Pregled primerjanih pristopov

V tabeli 5.1 je prikazano, katere modele smo uporabili, kateri družini vsak model pripada, kakšne podatke sprejme na vhod in kakšno vlogo ima v naši primerjalni študiji.

Tabela 5.1: Pregled primerjanih modelov in njihovih vhodnih predstavitev.

Družina modelov	Model	Vhod v model	Vloga v primerjavi
izhodiščna klasifikatorja	Naključni	brez učenja iz značilke	spodnja meja naključnega ugibanja
	Večinski		spodnja meja napovedovanja najpogostejšega razreda
klasični modeli strojnega učenja	SVM	agregirane značilke okna	klasični model strojnega učenja
	LightGBM		
	MLP		
zamrznjeni prednaučeni predstavitveni modeli	GazeMAE	koordinati pogleda (x, y)	prednaučena predstavitev za množico <i>samo pogled</i>
	MOMENT	časovne vrste izbranih signalov	prednaučena predstavitev za množice s signali zenic oziroma več signali
grafovski modeli	GCN	homogeni graf okna	osnovni grafovski model
	HeteroGCN-mean	heterogeni graf okna	ločena obravnava relacij s preprosto fuzijo
	HeteroGCN-MLP		ločena obravnava relacij z učljivo fuzijo
	HeteroGCN-MLP-w	heterogeni graf okna in značilke povezav	najkompleksnejša stopnja arhitekturne lestvice

5.2 Negrafovski osnovni modeli

Izhodiščna klasifikatorja

Večinski in naključni klasifikator sta enostavna klasifikatorja, ki predstavljata spodnjo primerjalno mejo oziroma izhodišče. Večinski klasifikator vedno napove večinski razred učne množice, naključni klasifikator pa razrede napoveduje z enako verjetnostjo ne glede na porazdelitev podatkov. Cilj je, da naučeni modeli presežejo rezultate izhodiščnih klasifikatorjev, saj s tem pokažemo uspešno prepoznavanje vzorcev.

Klasični modeli strojnega učenja

Za pravično primerjavo smo negrafovskim osnovnim modelom podali agregirane značilke istih signalov, kot so jih prejele GNN. V primeru množice *vsí signali* so to koordinati pogleda (x , y), velikosti leve in desne zenice, oddaljenost od sledilnika pogleda ter informacija o fiksacijah. Dodali smo tudi normaliziran čas meritve znotraj okna. Za vsak signal smo izračunali opisne statistike na ravni okna. To so povprečje, standardni odklon, minimum, maksimum, razpon, mediana, prvi kvartil, tretji kvartil in medkvartilni razmik. Pri fiksacijah smo dodali še število fiksacij, delež meritev v oknu, ki pripadajo fiksacijam, vsoto trajanj, povprečno trajanje in največje trajanje fiksacije. V primeru množice *vsí signali* je eno okno v tabelarični predstavitvi opisano z 68 agregiranimi značilkami. Takšna pretvorba časovnega signala v opisne statistike na ravni okna oziroma odziva je običajen pristop pri klasičnih modelih strojnega učenja za podatke pogleda [5, 19, 30].

SVM

SVM smo uporabili kot klasični model z nelinearnim jedrom radialne bazne funkcije (RBF) nad agregiranimi značilkami okna [6]. Ker je SVM občutljiv na velikostni red vhodnih značilk, smo agregirane značilke pred učenjem standardizirali, da značilke z večjimi števili vrednostmi niso nesorazmerno vplivale na odločanje modela.

MLP

Osnovni MLP smo uporabili kot primer osnovnega nevronskega modela [9]. Vhod modela je vektor agregiranih značilk enega časovnega okna, izhod pa logiti za razrede ciljne naloge. Tudi MLP je občutljiv na velikostni red značilk, zato smo tudi tukaj zanj značilke standardizirali. Ker cilj naloge ni ustvariti nov globok nevronske model, smo namenoma sestavili preprost perceptron z dvema skritima polno povezanimi plastema z aktivacijo ReLU (angl. *rectified linear unit*) in izpuščanjem, za njima pa izhodno linearno plastjo. MLP smo učili z izgubo križne entropije, tj. s povprečno negativno logaritemsko verjetnostjo pravilnega razreda, ki kaznuje majhno napovedano verjetnost pravilnega razreda.

LightGBM

LightGBM smo uporabili kot predstavnika gradientno spodbujenih odločitvenih dreves [16]. Model je primeren za tabelarične podatke, zato je naravna primerjava za agregirane značilke časovnih oken. Za razliko od SVM in MLP standardizacije vhodnih značilk ne potrebuje, saj odločitvena drevesa delujejo na pragovih posameznih značilk.

5.3 Zamrznjeni prednaučeni predstavitveni modeli

Poleg modelov nad ročno agregiranimi značilkami smo uporabili tudi dva prednaučena kodirnika signalov: **GazeMAE** za podatke pogleda in **MOMENT** za ostale časovne vrste. Takšni modeli vhodnega okna ne pretvorijo v vnaprej določene statistike, temveč neposredno iz signala izračunajo vektorsko predstavitev. V tej nalogi smo ju uporabili kot zamrznjena kodirnika, zato njunih parametrov med učenjem nismo spreminjali. Na izračunanih predstavitev smo nato učili ločeno klasifikacijsko glavo MLP. Ta MLP je arhitekturno drugačen, ločen in nepovezan s samostojnim klasifikatorjem MLP iz družine klasičnih modelov

strojnega učenja.

GazeMAE

Za podatke pogleda smo uporabili odprtokodni prednaučeni kodirnik **GazeMAE** [2]. Model prejme zgolj koordinati pogleda (x, y) , zato smo ga samostojno uporabili le za množico *samo pogled*. Ker je bil **GazeMAE** učen na dvosekundnih oknih, vzorčenih s frekvenco 500 Hz, smo uporabljena 10 s okna najprej pretvorili v obliko, ki jo model pričakuje. Koordinati pogleda smo razdelili na pet neprekrivajočih se dvosekundnih kosov in ju prevzorčili na ciljno frekvenco 500 Hz. Kodirnika znotraj modela temeljita na časovno-konvolucijskih mrežah ter ločeno kodirata položaj in hitrost pogleda. Za vsak kos vrneta po eno predstavitev s 128 dimenzijami, ki ju združimo v predstavitev s 256 dimenzijami [2]. V naši implementaciji smo nato po petih kosih izračunali povprečje in standardni odklon vsake dimenzije ter oba vektorja združili v predstavitev celotnega okna s 512 dimenzijami.

MOMENT

MOMENT smo uporabili kot splošni prednaučeni model za časovne vrste [10]. V nasprotju z **GazeMAE** ni vezan samo na koordinate pogleda, zato smo ga uporabili za večkanalne časovne vrste signalov, ki so pripadali izbrani množici signalov v posameznem eksperimentu. To so lahko velikosti zenic, oddaljenost od sledilnika pogleda in trajanje fiksacije. Samostojno smo ga uporabili le za množico *samo zenici*. Vhodno okno smo pred uporabo prevzorčili na 512 časovnih korakov. **MOMENT** temelji na arhitekturi transformerjev za časovne vrste in v uporabljeni nastavitvi izračuna predstavitev okna s 768 dimenzijami.

Združene predstavitve GazeMAE in MOMENT

Pri množicah *pogled in zenici* ter *vsí signali* smo uporabili združeno predstavitev obeh kodirnikov. Predstavitev **GazeMAE** in predstavitev **MOMENT** smo konkatenerali v en skupni vektor, ki je bil nato vhod v klasifikacijsko glavo MLP.

V rezultatih zamrznjene prednaučene predstavitvene modele obravnavamo kot eno družino modelov GazeMAE/MOMENT. Pri množici *samo pogled* ta vrstica pomeni uporabo GazeMAE, pri množici *samo zenici* uporabo MOMENT, pri množicah *pogled in zenici* ter *vsi signali* pa združeno predstavitev obeh kodirnikov. Za ta pristop smo se odločili zato, da ohranimo tabelo rezultatov pregledno.

5.4 Grafovski modeli

Štiri grafovske modele uredimo v arhitekturno lestvico, tj. zaporedje postopnih nadgradenj, v katerem vsaka naslednja stopnja doda eno obravnavano zmožnost modela. Pri isti množici signalov vse stopnje uporabljajo iste vozliščne značilke, iste relacije in ista časovna okna. Razlikujejo se po tem, kako obravnavajo tipe povezav, kako združujejo relacijske predstavitve in ali uporabljajo značilke povezav za izračun učljivih uteži povezav. Najprej definiramo osnovno GNN, nato pa s tremi nadgradnjami postopno gradimo *končni* model. V tabeli 5.2 so na kratko predstavljene razlike med vsemi štirimi stopnjami grafovskih modelov.

5.4.1 Skupni arhitekturni cevovod

Vsi obravnavani grafovski modeli sledijo splošnemu postopku posredovanja sporočil, predstavljenemu v razdelku 2.1, razlikujejo pa se po obravnavi relacij, njihovi fuziji in uporabi značilk povezav. Na vhod prejmejo graf glede na izbrano množico signalov, kot je definirano v poglavju 4. Dimenzijo vhodnih preslikav prilagodimo izbrani množici signalov – ločeno za značilke vozlišč, pri modelu HeteroGCN-MLP-w, ki ga bomo kmalu predstavili, pa tudi za značilke povezav.

Vhodne vektorje najprej preslikamo v skupni latentni prostor oziroma prostor skritih predstavitev z dvoslojnim MLP. Tako dobimo začetno predstavitev vsakega vozlišča, ki jo nato posodabljaajo grafovske plasti. Te plasti posredujejo sporočila po povezavah grafa in pri vsakem vozlišču združijo in-

Tabela 5.2: Arhitekturna lestvica grafovskih modelov.

Model	Ločene relacije	Fuzija relacij	Uteži povezav	Namen stopnje
GCN	ne	–	ne	preveri osnovno grafovsko predstavitev v homogenem grafu
HeteroGCN-mean	da	povprečje	ne	preveri vpliv ločene obravnave relacij
HeteroGCN-MLP	da	MLP	ne	preveri vpliv učljive fuzije relacijskih predstavitev
HeteroGCN-MLP-w	da	MLP	da	preveri vpliv učljivih predznačenih uteži povezav

formacije iz njegove okolice. V grafovskih blokih uporabimo aktivacijo GELU, rezidualne povezave, normalizacijo plasti in izpuščanje. Aktivacijska funkcija GELU je določena kot $\text{GELU}(x) = x\Phi(x)$, kjer $\Phi(x)$ označuje porazdelitveno funkcijo standardne normalne porazdelitve. Rezidualna povezava vhod bloka prišteje njegovi izhodni preslikavi, normalizacija plasti pa za vsako vozlišče normalizira komponente predstavitev z njihovim povprečjem in varianco. Izpuščanje med učenjem z določeno verjetnostjo nastavi posamezne aktivacije na nič, s čimer omejuje prekomerno prileganje. Ti gradniki niso predmet primerjave med grafovskimi modeli. Gre za uveljavljene gradnike nevronske mreže, ki podpirajo stabilnejše učenje in omejujejo prekomerno prileganje [13, 12, 1, 29]. Primerjava se osredotoča na obravnavo relacij, fuzijo relacijskih predstavitev in uporabo značilk povezav. Ker napovedujemo razred celotnega okna, iz končnih predstavitev vozlišč s pozornostnim združevanjem izračunamo predstavitev celotnega grafa. Uporabimo $\mathbf{h}_G = \sum_{i \in V} \alpha_i \mathbf{h}_i$, kjer je $\mathbf{h}_G$ predstavitev grafa, α_i utež pozornosti za vozlišče i , $\mathbf{h}_i$ pa predstavitev vozlišča

i. Uteži pozornosti normaliziramo s softmax normalizacijo:

$$\alpha_i = \frac{\exp(g(\mathbf{h}_i))}{\sum_{j \in V} \exp(g(\mathbf{h}_j))}. \quad (5.1)$$

Pri tem je g učljiva funkcija, ki predstavitev vozlišča priredi skalarno oceno pomembnosti. Predstavitev grafa nato pošljemo skozi klasifikacijsko glavo MLP. Glava izračuna dva logita, enega za negativno in enega za pozitivno valenco. Napoved je razred z večjim logitom. Pri poročanju verjetnosti logite normaliziramo s softmaxom. Podrobnosti o številu plasti, velikosti skritih predstavitev, verjetnosti izpuščanja in ostalih hiperparametrah so opisane v dodatku B.

Vse GNN smo učili od začetka do konca (angl. *end-to-end*), kar pomeni, da so se vsi učljivi deli modela optimizirali hkrati glede na klasifikacijsko izgubo. To vključuje začetno preslikavo značilk vozlišč, grafovskie plasti, morebitno fuzijo relacij, pozornostno združevanje in klasifikacijsko glavo. V nadaljevanju opišemo specifične vsake arhitekture v štiristopenjski arhitekturni lestvici, začenši z najenostavnejšim – s homogenim GCN. V enačbah posameznih modelov je $\mathbf{H}^{(k-1)}$ matrika vhodnih predstavitev vozlišč v k -ti grafovski plasti, $\mathbf{Z}^{(k)}$ pa njen izhod pred skupno rezidualno povezavo, normalizacijo plasti in izpuščanjem.


GCN

GCN je v osnovi homogeni grafovski model. Uporablja isto grafovsko predstavitev okna, kot je bila opisana v poglavju 4, vendar ne ločuje časovnih, prostorskih in fiksacijskih relacij. Vse povezave združi v en homogen graf, posredovanje sporočil pa izvede s plastmi GCNConv iz knjižnice PyTorch Geometric (PyG) [7]. Model ne uporablja značilk povezav in posledično učljivih uteži povezav. Glavni korak ene plasti modela zapišemo kot

$$\mathbf{Z}^{(k)} = \text{GELU}\left(\mathbf{D}^{-\frac{1}{2}}\mathbf{A}\mathbf{D}^{-\frac{1}{2}}\mathbf{H}^{(k-1)}\boldsymbol{\Theta}^{(k)} + \mathbf{b}^{(k)}\right), \quad (5.2)$$

kjer sta $\mathbf{A}$ in $\mathbf{D}$ matriki sosednosti in stopenj homogenega grafa, $\boldsymbol{\Theta}^{(k)}$ matrika učljivih parametrov in $\mathbf{b}^{(k)}$ pristranskost [17]. V grafovski konvoluciji ne

dodajamo zank iz vozlišča vase, saj se lastna predstavitev vozlišča ohranja prek rezidualne povezave. Slika 5.1 prikazuje osnovni cevovod tega modela.



Slika 5.1: Diagram arhitekture GCN. Model vse povezave obravnava kot en homogen graf, zato se sporočila posredujejo prek ene skupne grafovske konvolucije.


HeteroGCN-mean

S HeteroGCN-mean preidemo od homogenega modela k ločeni obravnavi različnih tipov relacij. Kot opisano v poglavju 4, tukaj ločimo različne tipe relacij. Relacijske predstavitve vozlišč združimo v skupno predstavitev vozlišča s preprostim povprečenjem. Ker časovne, prostorske in fiksacijske povezave opisujejo različne odnose med meritvami, pričakujemo, da bo njihova ločena obdelava ohranila informacije, ki se pri homogenem združevanju povezav lahko izgubijo. Za vsako relacijo $r \in \mathcal{R}$ uporabimo ločeno grafovsko konvolucijo,

nato pa njihove izhode povprečimo:

$$\begin{aligned} \mathbf{z}_r^{(k)} &= \text{GELU}\left(\mathbf{D}_r^{-\frac{1}{2}} \mathbf{A}_r \mathbf{D}_r^{-\frac{1}{2}} \mathbf{H}^{(k-1)} \boldsymbol{\Theta}_r^{(k)} + \mathbf{b}_r^{(k)}\right), \\ \mathbf{z}^{(k)} &= \frac{1}{|\mathcal{R}|} \sum_{r \in \mathcal{R}} \mathbf{z}_r^{(k)}, \end{aligned} \quad (5.3)$$

kjer $\mathbf{A}_r$ in $\mathbf{D}_r$ opisujeta povezave in stopnje vozlišč znotraj relacije r , vsaka relacija pa ima svoje parametre $\boldsymbol{\Theta}_r^{(k)}$ in $\mathbf{b}_r^{(k)}$. Kot prikazano na sliki 5.2, je sprememba glede na homogeni GCN samo v tem, da se sporočila najprej izračunajo ločeno po relacijah, nato pa združijo s povprečenjem.



Slika 5.2: Diagram arhitekture HeteroGCN-mean. Model ločeno izračuna sporočila po časovnih, prostorskih in fiksacijskih relacijah, relacijske predstavitve pa združi s povprečenjem.

HeteroGCN-MLP

Kot prikazuje slika 5.3, **HeteroGCN-MLP** ročno določeno fuzijo modela **HeteroGCN-mean** nadomesti z učljivo fuzijo relacijskih predstavitev. Različne predstavitve vozlišč – za vsako razpoložljivo relacijo eno – najprej konkatenujemo, nato pa jih z dvoslojnim perceptronom združimo v skupno predstavitev vozlišča. Preprosto povprečenje je v **HeteroGCN-mean** vsem relacijam pripisalo enako vlogo, v **HeteroGCN-MLP** pa učljiva fuzija omogoči, da model različne relacijske predstavitve uporabi različno. Relacijski izhodi $\mathbf{Z}_r^{(k)}$ se izračunajo kot v enačbi (5.3), njihovo učljivo fuzijo pa zapišemo kot


$$\mathbf{Z}^{(k)} = f_{\text{fuz}}^{(k)} \left(\parallel_{r \in \mathcal{R}} \mathbf{Z}_r^{(k)} \right), \quad (5.4)$$

kjer $\parallel$ označuje konkatencijo v vnaprej določenem vrstnem redu relacij, $f_{\text{fuz}}^{(k)}$ pa dvoslojni perceptron k -te grafske plasti.

HeteroGCN-MLP-w

Arhitekturno lestvico sklene **HeteroGCN-MLP-w**, ki učljivi fuziji doda še uteži povezav, izračunane iz njihovih značilnk. Za izračun uteži povezav ima model tri večslojne perceptrone: $f_w^{\text{čas}}$, f_w^{prostor} in $f_w^{\text{fiksacija}}$. Ti na podlagi vektorja značilnk posamezne povezave, katerega komponente so povzete v tabeli B.3, izračunajo skalarno predznačeno utež, ki določa, kako močno posamezna povezava vpliva na posredovanje sporočil. Pri posamezni množici signalov se uporabijo le funkcije za relacije, ki so v grafu prisotne. Časovne povezave naprej in nazaj si delijo isto funkcijo $f_w^{\text{čas}}$, smer povezave pa je podana kot dodatna značilka povezave ρ_{ij} . Formule za izračun uteži in njihova normalizacija po absolutni vsoti vhodnih uteži so podane v dodatku B.2, posebej v enačbi (B.4). Za vozlišče j in relacijo r je glavni korak uteženega posredovanja sporočil


$$\begin{aligned} \mathbf{z}_{j,r}^{(k)} &= \text{GELU} \left(\sum_{i \in \mathcal{N}_r(j)} w_{ij}^{(r)} \Theta_r^{(k)} \mathbf{h}_i^{(k-1)} + \mathbf{b}_r^{(k)} \right), \\ \mathbf{z}_j^{(k)} &= f_{\text{fuz}}^{(k)} \left(\parallel_{r \in \mathcal{R}} \mathbf{z}_{j,r}^{(k)} \right). \end{aligned} \quad (5.5)$$



Slika 5.3: Diagram arhitekture HeteroGCN-MLP. Model relacijske predstavitve najprej konkatencira, nato pa jih združi z učljivo fuzijo prek dvoslojnega perceptrona.

Uteži $w_{ij}^{(r)}$ so že normalizirane po vhodnih povezavah vozlišča j znotraj relacije.

Ker tudi povezave istega tipa niso nujno enako informativne, lahko model v tej končni stopnji z utežmi na podlagi njihovih značilk poudari koristnejše povezave, oslabi manj koristne ali obrne predznak njihovega prispevka. Slika 5.4 prikazuje dodano vejo za izračun učljivih uteži povezav.



Slika 5.4: Diagram arhitekture **HeteroGCN-MLP-w**. Model poleg učljive fuzije relacij uporablja še značilke povezav, iz katerih z relacijsko odvisnimi perceptroni izračuna učljive predznačene uteži povezav.

Izbira grafovske konvolucije

V glavnih poskusih smo v vseh grafovskih modelih uporabili plast **GCNConv** [17]. **GCNConv** je enostaven in uveljavljen operator posredovanja sporočil, ki smo ga lahko ohranili nespremenjenega skozi celotno arhitekturno lestvico. V dodatnem poskusu smo ga primerjali z drugimi operatorji, razlike med njimi pa so bile razmeroma majhne. Podrobnosti primerjave so podane v dodatku A.3.

Poglavje 6

Eksperimentalni protokol in rezultati

V prejšnjih poglavjih smo definirali podatke, ciljne razrede, časovna okna, grafovsko predstavitev in primerjane modele. V tem poglavju opišemo, kako smo te komponente ovrednotili v skupni eksperimentalni primerjavi, in predstavimo rezultate. Glavna evalvacijska naloga je binarna klasifikacija negativne proti pozitivni valenci. Vsi modeli uporabljajo iste učne vzorce in iste delitve na učno, validacijsko in testno množico. Koda za predobdelavo, konstrukcijo grafov, učenje modelov, evalvacijo in generiranje rezultatov je javno dostopna v repozitoriju projekta [4]. Podatkovna zbirka MAHNOB-HCI v repozitorij ni vključena. Pridobili smo jo preko uradnega spletnega mesta podatkovne zbirke [22].

6.1 Zasnova in prečno preverjanje

Zasnova glavne primerjave

Cilj glavne primerjave je odgovoriti na glavno raziskovalno vprašanje iz uvoda: Kakšna je klasifikacijska uspešnost grafovske nevronske mreže za binarno klasifikacijo valence iz podatkov sledilnika pogleda v primerjavi s klasifikacijsko uspešnostjo uveljavljenih negrafovskih pristopov? V primerjavi

smo uporabili vse modele iz tabele 5.1: izhodiščna klasifikatorja, klasični modeli nad agregiranimi značilkami, zamrznjeni prednaučeni predstavitveni modeli in grafovski modeli. S tem smo primerjali tri različne načine opisa istega časovnega okna: tabelarični povzetek signalov, vektorsko predstavitev časovne vrste in grafovsko predstavitev meritev.

Vse štiri množice iz tabele 4.1 smo obravnavali kot enakovreden del primerjave, saj nas je zanimalo tudi, kako se klasifikacijska uspešnost spreminja z razpoložljivostjo različnih signalov sledilnika pogleda.

7-kratno prečno preverjanje po udeležencih

Glavno primerjavo smo izvedli s 7-kratnim prečnim preverjanjem po udeležencih. Pri vsaki ponovitvi so bili testni udeleženci popolnoma ločeni od udeležencev, uporabljenih za učenje in validacijo. Iz učnega dela smo izbrali eno skupino udeležencev za validacijsko množico, preostali udeleženci pa so sestavljali učno množico. Delitve so bile pri vseh modelih in vseh množicah signalov enake ter določene s fiksnim naključnim semenom.

Takšna delitev ocenjuje posploševanje na nove udeležence. To je za našo nalogo pomembno, saj so signali sledilnika pogleda močno odvisni od specifik posameznika [19]. Ker 22 udeležencev ni deljivo s sedem, imajo posamezne testne razdelitve različno velikost – nekatere vsebujejo tri, druge pa štiri testne udeležence.

Pri nevronske modelih smo najboljšo različico modela izbrali glede na validacijsko izgubo, nato pa njeno delovanje izmerili na pripadajoči testni množici. V zgodnejših fazah smo izvedli tudi podporno preverjanje z LOSO, ki je skupaj s primerjavo obeh validacijskih protokolov podano v dodatku A.2.

6.2 Nastavitve in vrednotenje

Nastavitve učenja in hiperparametri

V tem razdelku navedemo nastavitve učenja, ki vplivajo na izvedbo eksperimentov. Nevronske modele smo učili z zgodnjim ustavljanjem na validacijski

izgubi. Grafovski modeli so uporabljali operator **GCNConv**, dve grafovski plasti, skrite predstavitve velikosti 64 ter povezave s parametri $k_t = 1$, $k_s = 1$ in $k_f = 3$, kot so definirani v poglavju 4. Podrobni hiperparametri modelov ter uporabljena strojna in programska oprema so podani v dodatku B.

Nastavitve grafovskih modelov smo izbrali na podlagi predhodnega kompaktne mrežnega iskanja. To iskanje smo izvedli v zgodnejši fazi raziskave, ko je klasifikacijska naloga bila še trirazredna in je poleg negativne in pozitivne vključevala tudi nevtralno valenco. V dodatku rezultate iskanja poročamo le kot podporni poskus pri izbiri stabilnih nastavitvev.

Metrike vrednotenja

Za vrednotenje smo uporabili več standardnih metrik, pri čemer sta bili glavni točnost in makro F1. Za vsak model in vsako množico signalov smo izračunali povprečje po sedmih testnih razdelitvah. Točnost smo uporabili kot osnovno metriko, ker ima glavna naloga dva enakovredna in globalno skoraj uravnotežena razreda, kot kaže slika 3.1. Za C razredov in N primerov, kjer je TP_c število pravilno razvrščenih primerov razreda c , jo izračunamo kot

$$\text{točnost} = \frac{1}{N} \sum_{c=1}^C TP_c, \quad (6.1)$$

Makro F1 smo uporabili kot dopolnilno glavno metriko. Čeprav sta razreda globalno skoraj uravnotežena, so lahko posamezne testne razdelitve precej neuravnotežene (tudi do razmerja 1 : 2). Makro F1 izračuna F1 ločeno za vsak razred in nato rezultate povpreči z enako utežjo:

$$\text{makro F1} = \frac{1}{C} \sum_{c=1}^C \frac{2TP_c}{2TP_c + FP_c + FN_c}, \quad (6.2)$$

kjer FP_c in FN_c označujeta število lažno pozitivnih oziroma lažno negativnih napovedi za razred c . S tem dopolni točnost predvsem pri modelih, ki lahko dosežejo sprejemljivo točnost, vendar večino primerov napovedujejo v en sam razred.

Poleg glavnih metrik smo spremljali tudi preciznost, priklic oziroma občutljivost, uteženi F1, ploščino pod krivuljo ROC (AUC, angl. *area under the receiver operating characteristic curve*) in matrike zamenjav. Te metrike smo uporabili predvsem za preverjanje stabilnosti in za podrobnejšo analizo napak. Njihove definicije so podane v dodatku A.1. V glavnem besedilu se osredotočimo na točnost in makro F1, v dodatku A.2 pa poročamo še preciznost, priklic, uteženi F1 in AUC.

Spremljanje učenja

Poleg končnih metrik smo shranjevali tudi podatke o poteku učenja. Pri nevronskih modelih smo kot funkcijo izgube uporabljali križno entropijo. Pri nevronskih modelih smo spremljali učno in validacijsko izgubo, najboljšo epoho, informacijo o zgodnjem ustavljanju, čas epohe in norme gradientov. Krivulje izgub služijo predvsem preverjanju stabilnosti optimizacije in zaznavanju potencialnega prekomernega prileganja.

Pri grafovskih nevronskih mrežah lahko več zaporednih agregacij povzroči, da si predstavitev vozlišč postanejo preveč podobne. Ta pojav imenujemo prekomerno glajenje. V praksi se lahko pokaže kot zmanjšanje variance predstavitev, visoka medsebojna podobnost vozliščnih vektorjev in skoraj konstantni izhodi klasifikacijske glave. Pri grafovskih modelih smo spremljali še nekaj diagnostičnih meritev naučenih predstavitev in napovedi. Med njimi so varianca predstavitev grafa, povprečna kosinusna podobnost predstavitev, razpon logitov in entropija napovednih verjetnosti. Te meritve smo uporabili za preverjanje, ali so se med učenjem pojavile skoraj konstantne napovedi, kolaps predstavitev ali znaki prekomernega glajenja. Definicije spremljanih učnih in diagnostičnih meritev so podane v dodatku A.1. Krivulje učne in validacijske izgube poročamo med rezultati v nadaljevanju, diagnostiko naučenih predstavitev in napovedi pa v dodatku A.3.

6.3 Rezultati

V nadaljevanju predstavimo rezultate primerjave različnih modelov za binarno klasifikacijo valence pri 7-kratnem prečnem preverjanju po udeležencih. Dodatne rezultate in razširjene metrike poročamo v dodatku A.

Tabela 6.1 prikazuje povprečno točnost in makro F1 pri 7-kratnem prečnem preverjanju po udeležencih. Vse vrednosti so zapisane v odstotkih, štiri signalne množice pa so obravnavane kot enakovredne različice iste klasifikacijske naloge. Večinski klasifikator doseže točnost približno 52 %, kar ustreza porazdelitvi razredov na sliki 3.1, vendar ima zaradi napovedovanja samo enega razreda makro F1 približno 34 %.

Najvišjo točnost (70,5 %) in makro F1 (69,7 %) doseže SVM pri signalni množici *pogled in zenici*. LightGBM doseže najboljši rezultat pri množicah *samo pogled*, *samo zenici* in *vsi signali*. Med posameznimi signalnimi množicami je *samo zenici* najšibkejša, vendar vsi naučeni modeli tudi pri tej množici presežejo naključni in večinski klasifikator. Dodajanje zeničnih signalov k pogledu prinese najvišji posamični rezultat, medtem ko množica *vsi signali* v tej primerjavi ne preseže množice *pogled in zenici*.

Grafovski modeli so pri vseh signalnih množicah zanesljivo nad obema izhodiščnima klasifikatorjema, vendar ostanejo pod najboljšima modeloma SVM in LightGBM. Najboljši grafovski rezultat je odvisen od signalne množice – pri *samo pogled* je najuspešnejši HeteroGCN-MLP, pri *samo zenici* osnovni GCN, pri *pogled in zenici* in *vsi signali* pa HeteroGCN-MLP-w. Rezultati torej ne kažejo monotonega izboljševanja z večanjem arhitekturne kompleksnosti grafovskih modelov. V nadaljevanju podrobnejše rezultate matrike zamenjav ter računsko zahtevnost modelov prikažemo na primeru, kjer modeli dosegajo najboljše rezultate, to je na množici *pogled in zenici*. Dodatne matrike zamenjav za vse modele in vse množice signalov so prikazane v dodatku A.2.

Tabela 6.1: Glavna primerjava modelov pri binarni klasifikaciji valence. Celice vsebujejo točnost/makro F1 v odstotkih. Odebeljena pisava označuje najboljši rezultat za vsak stolpec, odebeljena poševna pisava pa najboljši rezultat med grafovskimi modeli.

Model	samo pogled	samo zenici	pogled in zenici	vsi signali
Naključni	50,2/50,1	50,7/50,6	50,8/50,6	50,9/50,7
Večinski	52,5/34,4	52,2/34,2	52,1/34,2	52,2/34,2
SVM	67,5/67,2	62,1/60,7	70,5/69,7	68,6/67,6
LightGBM	69,7/69,4	63,1/61,9	69,6/68,8	69,0/68,3
MLP	67,0/66,7	62,0/60,3	68,7/67,6	67,2/66,2
GazeMAE/MOMENT*	65,7/65,2	60,5/60,1	65,6/65,2	66,1/65,6
GCN	64,4/64,1	61,0/58,4	65,4/63,9	59,6/57,6
HeteroGCN-mean	61,7/59,2	58,6/55,7	63,8/61,1	61,8/59,7
HeteroGCN-MLP	65,9/65,8	59,1/56,0	64,2/62,8	60,5/56,6
HeteroGCN-MLP-w	64,3/64,0	58,4/54,5	65,5/64,4	62,7/60,8


Opomba: * GazeMAE/MOMENT označuje enoten prikaz zamrznjenih predstavitvenih modelov: GazeMAE pri pogledu, MOMENT pri zenicah in fuzijo obeh pri kombiniranih signalih, kot je pojasnjeno v poglavju 5.3.

Potek učenja

Poleg končnih klasifikacijskih meritev smo preverili tudi potek učenja modelov. Slika 6.1 prikazuje učno in validacijsko izgubo vseh štirih grafovskih arhitektur pri množici signalov *pogled in zenici*. Za berljivost so prikazane povprečne vrednosti čez sedem delitev po udeležencih, zasenčeno območje pa predstavlja standardni odklon med delitvami. Ker se delitve zaradi zgodnjega ustavljanja končajo po različnem številu epoh, se dolžina krivulj med modeli razlikuje in se posledično zasenčeno območje pri večjem številu epoh skrči vse do 0, saj se je le pri eni delitvi model učil največ epoh. Od te točke dalje prikazana krivulja zato ne predstavlja več povprečja več delitev, temveč potek ene same

delitve, kar pojasni tudi njen stopničast potek.

Potek učne in validacijske izgube pri množici pogled in zenici




Slika 6.1: Povprečni potek učne in validacijske izgube grafovskih modelov pri množici signalov *pogled in zenici*. Zasenčena območja predstavljajo standardni odklon čez sedem delitev po udeležencih.

Pri vseh arhitekturah učna izguba na začetku hitro upade, nato pa se spremembe umirijo. Validacijska izguba se po začetnem izboljšanju večinoma stabilizira, pri čemer med delitvami ostaja opazna variabilnost. Validacijska izguba je pri večini modelov nižja od učne, kar je lahko posledica merjenja v različnih načinih delovanja modela. Modele smo učili z izpuščanjem, ki je povečalo šum in s tem učno izgubo, med validacijo pa izpuščanja ni bilo. Poleg tega je učna izguba povprečje med posodabljanjem uteži skozi epoho, validacijska izguba pa se izračuna po koncu epohe, ko so uteži že prilagojene.

Matriki zamenjav

Slika 6.2 prikazuje napake za signalno množico *pogled in zenici*, pri kateri je dosežen najboljši skupni rezultat. Najuspešnejši model SVM pravilno raz-

vrsti 73,0 % vzorcev negativne valence in 67,7 % vzorcev pozitivne valence, najuspešnejši grafovski model, HeteroGCN-MLP-w, pa 64,8 % oziroma 65,8 %.



Slika 6.2: Vrstično normalizirani matriki zamenjav za najboljši model SVM in najboljši grafovski model HeteroGCN-MLP-w pri množici signalov *pogled in zenici*.

Računska zahtevnost

Za odgovor na podvprašanje 4 smo poleg klasifikacijske uspešnosti primerjali tudi velikost modelov ter izmerjeni čas učenja in sklepanja. Tabela 6.2 prikazuje te vrednosti za množico signalov *pogled in zenici*, kjer je bil dosežen najboljši skupni rezultat.

Izhodiščna klasifikatorja ter modela SVM in LightGBM nimajo števila nevronskega parametrov, zato je pri njih ta vrednost označena z -. Pri GazeMAE, MOMENT in njuni združeni različici stolpec učljivih parametrov zajema samo klasifikacijsko glavo, stolpec vseh parametrov pa tudi uporabljena zamrznjena kodirnika. Grafovski modeli imajo bistveno manj parametrov kot zamrznjeni prednaučeni kodirniki, vendar je njihov izmerjeni čas učenja na okno za približno dva velikostna razreda večji kot pri negrafovskih modelih. Glede na razmerje med točnostjo in izmerjenim časom sta v tej primerjavi najugodnejša klasična modela SVM in LightGBM.

Tabela 6.2: Velikost in računska zahtevnost modelov pri množici signalov *pogled in zenici*. Števili parametrov sta podani v tisočih, časa učenja in sklepanja pa v milisekundah na okno.

Model	Vhod	Učljivi	Vsi	Učenje	Sklepanje	Točnost
Naključni	–	–	–	0,00	0,00	50,8
Večinski	–	–	–	0,00	0,00	52,1
SVM	agregirane značilke	–	–	0,39	0,08	70,5
LightGBM		–	–	0,04	0,00	69,6
MLP		7	7	0,39	0,00	68,7
GazeMAE*	s. pogleda	82	2.119	0,25	2,64	65,7
MOMENT*	s. zenic	115	125.115	0,24	1,69	60,5
GazeMAE+MOMENT	s. pogleda in zenic	181	127.217	0,26	6,12	65,6
GCN	grafi	26	26	20,73	0,19	65,4
HeteroGCN-mean		43	43	26,64	0,20	63,8
HeteroGCN-MLP		76	76	22,27	0,20	64,2
HeteroGCN-MLP-w		76	76	21,74	0,19	65,5

Opomba: * Vrstici za GazeMAE in MOMENT prikazujeta rezultate na množicah signalov *samo pogled* oziroma *samo zenici*. Čas sklepanja zajema celoten napovedni prehod od že pripravljenega vhoda modela (signalov) do razrednih verjetnosti – to vključuje kodiranje signala, združevanje predstavitev in klasifikacijsko glavo.

Poglavje 7

Diskusija in zaključek

7.1 Interpretacija rezultatov

Kot kažejo slike 3.1, 3.2 in 3.3, ima glavna naloga skoraj uravnotežene razrede, očiščene meritve pa pričakovane porazdelitve. To poveča možnost, da se modeli naučijo uporabnih signalov namesto šuma. Matrike zamenjav pokažejo, da modeli niso izrazito pristranski do enega razreda. Posledično imata točnost in makro F1 v rezultatih podobne vrednosti.

Grafovski modeli iz podatkov izluščijo uporaben signal, saj izhodiščne klasifikatorje presegajo za približno deset odstotnih točk točnosti. Njihova uspešnost je primerljiva z uspešnostjo zamrznjenih prednaučenih kodirnikov. Primerjava sicer ni povsem neposredna. GNN smo v vsaki delitvi učili izključno na učnem delu podatkovne zbirke MAHNOB-HCI, medtem ko sta bila GazeMAE in MOMENT prednaučena na drugih večjih podatkovnih zbirkah, na MAHNOB-HCI pa so bile naučene le njune klasifikacijske glave. Grafovske predstavitve in predstavitve prednaučenih kodirnikov so torej informativne, vendar pri obravnavanju problema ne presegajo uveljavljenih pristopov s klasičnimi modeli strojnega učenja in ekspertno oblikovanimi značilkami. Ta ugotovitev je metodološko pomembna, saj kaže, da večja izrazna moč grafovskih in drugih globokih modelov sama po sebi ne zagotavlja boljše klasifikacijske uspešnosti. Enostavnejši modeli jih konsistentno prekašajo,

hkrati pa so hitrejši in zasedejo manj pomnilnika.

Izkaže se, da je najinformativnejši signal v tej podatkovni množici signal pogleda, torej koordinati (x, y) v množici *samo pogled*. Velikosti zenic v množici *pogled in zenici* dodajo nekaj koristne informacije, ostali signali iz množice *vsii signali* pa ne pokažejo izrazite dodane vrednosti. Čeprav slednja vsebuje več informacij, so rezultati večinoma slabši, kar kaže, da dodatni signali v našem primeru modelom prej dodajo šum kot koristno strukturo. Rezultati torej kažejo, da je uporabljena grafovska predstavitev smiselna in informativna, vendar v tej raziskavi najmočnejši ostajajo klasični modeli z ročno oblikovanimi značilkami iz signalov koordinat pogleda in velikosti zenice.

7.2 Omejitve in doprinosi

Doprinosi

V nalogi smo preverili uporabnost grafovske predstavitve podatkov sledilnika pogleda pri binarni klasifikaciji valence. Časovna okna meritev smo predstavili kot časovno-prostorske grafe in jih ovrednotili s štirimi grafovskimi modeli, ki se postopno nadgrajujejo od preproste proti kompleksnejšim različicam. Grafovske modele smo primerjali z izhodiščnima modeloma, klasičnimi modeli strojnega učenja in prednaučenima kodirnikoma signalov na štirih delno prekrivajočih se množicah signalov.

Glavni doprinosi naloge izhajajo neposredno iz raziskovalnih vprašanj in so:

1. časovno-prostorska grafovska predstavitev časovnih oken podatkov sledilnika pogleda;
2. ovrednotenje arhitekturne lestvice grafovskih modelov za binarno klasifikacijo valence iz podatkov sledilnika pogleda;
3. primerjava klasifikacijske uspešnosti med štirimi množicami signalov sledilnika pogleda;

4. primerjava grafovskih modelov z negrafovskimi osnovnimi modeli in zamrznjenimi prednaučenimi predstavitvenimi modeli.

Omejitve

Ugotovitve so omejene na uporabljeno podatkovno zbirko, izbrane množice signalov, binarno klasifikacijo valence in protokol evalvacije, ki ne preverja generalizacije na druge posnetke ali podatkovne zbirke. Ciljni razredi so izpeljani iz samoocen čustvenega stanja, zato vsebujejo določeno mero subjektivnosti in šuma. Omejitev je tudi uporabljena grafovska konstrukcija, saj predstavlja le enega izmed možnih načinov modeliranja odnosov med meritvami sledilnika pogleda.

7.3 Nadaljnje delo in zaključek

Grafovsko modeliranje podatkov sledilnika pogleda je še v veliki meri neraziskano, vendar pomeni smiselno nadaljnjo raziskovalno smer. V nadaljnjem delu bomo preverili drugačna pravila povezovanja, na primer povezovanje vozlišč s podobno dinamiko pogleda ali povezovanje meritev iste fiksacije z metavozliščem, s čimer bi graf razširili v tretjo dimenzijo. Grafovsko predstavitev bi bilo mogoče dopolniti tudi z mežiki in sakadami ter preizkusiti dodatne grafovske arhitekture, predvsem grafovske transformerje. Posebej zanimivo je samonadzorovano predtreniranje na signalih sledilnika pogleda, ki bi lahko zmanjšalo odvisnost od majhnih označenih podatkovnih zbirk in omogočilo uporabo neoznačenih podatkov. Rezultate bi bilo treba preveriti še na več podatkovnih zbirkah, pri prenosu med nalogami in v pogojih uporabe v realnem času.

Grafovska predstavitev se je izkazala kot informativna, saj je najboljša GNN pri binarni klasifikaciji valence dosegla točnost 65,9 % in s tem presegla izhodiščna klasifikatorja. Ni pa premagala najboljšega negrafovskega modela SVM, ki je z ekspertno oblikovanimi značilkami dosegel točnost 70,5 %.

Dodatek A

Dodatni rezultati

A.1 Oznake in dodatne metrike

Preslikava diskretnih samoocen čustvenega stanja v valenco

Preslikava diskretnih samoocen čustvenega stanja v razrede valence sledi tabeli 6 izvirnega članka podatkovne zbirke MAHNOB-HCI [27]. Pri binarni nalogi smo uporabili samo skrajna razreda valence, nevtralni razred pa izločili. Tako model ločuje med negativno in pozitivno valenco, primeri z vmesnim oziroma nevtralnim razredom pa niso del glavne evalvacijske naloge.

Tabela A.1: Preslikava diskretnih samoocen čustvenega stanja v razrede valence po izvirnem članku podatkovne zbirke MAHNOB-HCI.

Razred valence	Uporaba v binarni nalogi	Izvorne diskretne samoocene čustvenega stanja
Negativna valenca	da	<i>fear, anger, disgust, sadness, anxiety</i>
Nevtralna valenca	ne	<i>surprise, neutral</i>
Pozitivna valenca	da	<i>joy, happiness, amusement</i>

Dodatne metrike in diagnostične meritve

V nadaljevanju so na kratko opredeljene mere, uporabljene poleg točnosti in makro F1, ki sta definirani v poglavju 6.2. Za razred c naj bodo TP_c , FP_c in FN_c števila pravih pozitivnih, lažno pozitivnih oziroma lažno negativnih napovedi.

Preciznost pove, kolikšen delež napovedi razreda c je pravilen, priklic oziroma občutljivost pa, kolikšen delež dejanskih primerov tega razreda model prepozna:

$$\text{preciznost}_c = \frac{TP_c}{TP_c + FP_c}, \quad \text{priklic}_c = \frac{TP_c}{TP_c + FN_c}.$$

V poročanih binarnih rezultatih sta preciznost in priklic makro povprečji po razredih. Uteženi F1 je povprečje F1 po razredih, pri katerem je prispevek posameznega razreda utežen z njegovim številom primerov:

$$\text{uteeni F1} = \sum_{c=1}^C \frac{n_c}{N} \frac{2TP_c}{2TP_c + FP_c + FN_c},$$

kjer je n_c število dejanskih primerov razreda c , N pa skupno število primerov.

AUC (angl. *area under the ROC curve*) je ploščina pod krivuljo ROC in meri, kako dobro napovedne verjetnosti razvrstijo pozitivne primere pred negativne neodvisno od izbranega klasifikacijskega praga. Matrika zamenjav vsebuje števila primerov za vse pare dejanskih vrstic in napovedanih stolpcev, diagonalne celice so pravilne napovedi, preostale pa napake.

Med učenjem smo shranjevali učno in validacijsko izgubo po epohah, najboljšo epoho z najmanjšo validacijsko izgubo, podatek o zgodnjem ustavljanju, čas epohe ter povprečno in največjo L_2 -normo gradientov parametrov. Pri grafovskih modelih smo dodatno spremljali povprečno varianco komponent predstavitev grafa, povprečno kosinusno podobnost vseh parov predstavitev, razpon logitov kot razliko med največjim in najmanjšim logitom ter povprečno entropijo napovednih verjetnosti. Nizka varianca oziroma majhen razpon logitov skupaj z visoko podobnostjo lahko kažeta na skoraj konstantne predstavitve ali napovedi; entropija pove njihovo povprečno gotovost.

A.2 Razširjeni rezultati

Tabele v tem razdelku razširjajo glavno primerjavo iz poglavja 6. Vrednosti so povprečje $\pm$ standardni odklon čez sedem testnih množic prečnega preverjanja po udeležencih. Mikro F1 je pri tej enooznačni klasifikaciji enak točnosti. Razširjene metrike dodatno potrjujejo sklep iz glavne primerjave, saj ostane podoben tudi pri drugih pogledih na napake modelov.

Tabela A.2: Razširjeni rezultati za množico signalov *samo pogled*. Vrednosti so povprečje $\pm$ standardni odklon čez sedem testnih množic (v odstotkih). Krepko je označen najboljši rezultat v posameznem stolpcu, krepko poševno pa najboljši rezultat med grafovskimi modeli.

Model	Točnost	Preciznost	Priklic	Makro F1	Uteženi F1	AUC
Naključni	50,2 $\pm$ 1,8	50,2 $\pm$ 1,7	50,2 $\pm$ 1,7	50,1 $\pm$ 1,6	50,3 $\pm$ 2,0	50,2 $\pm$ 1,7
Večinski	52,5 $\pm$ 4,7	26,2 $\pm$ 2,4	50,0 $\pm$ 0,0	34,4 $\pm$ 1,9	36,2 $\pm$ 5,6	50,0 $\pm$ 0,0
SVM	67,5 $\pm$ 1,8	67,5 $\pm$ 1,7	67,4 $\pm$ 1,7	67,2 $\pm$ 1,7	67,4 $\pm$ 1,8	72,6 $\pm$ 2,5
LightGBM	69,7 $\pm$ 2,2	69,6 $\pm$ 2,5	69,6 $\pm$ 2,1	69,4 $\pm$ 2,3	69,7 $\pm$ 2,0	76,6 $\pm$ 2,0
MLP	67,0 $\pm$ 2,1	67,0 $\pm$ 2,0	66,9 $\pm$ 2,1	66,7 $\pm$ 2,3	67,0 $\pm$ 2,2	72,6 $\pm$ 2,7
GazeMAE/MOMENT	65,7 $\pm$ 3,2	66,5 $\pm$ 3,0	65,8 $\pm$ 2,8	65,2 $\pm$ 3,5	65,4 $\pm$ 3,3	71,9 $\pm$ 4,9
GCN	64,4 $\pm$ 4,8	64,6 $\pm$ 4,5	64,6 $\pm$ 4,7	64,1 $\pm$ 5,2	64,2 $\pm$ 5,2	70,7 $\pm$ 6,3
HeteroGCN-mean	61,7 $\pm$ 6,3	60,1 $\pm$ 9,9	61,3 $\pm$ 6,9	59,2 $\pm$ 11,2	59,7 $\pm$ 10,8	64,7 $\pm$ 11,2
HeteroGCN-MLP	65,9 $\pm$ 3,9	66,1 $\pm$ 3,8	66,2 $\pm$ 3,6	65,8 $\pm$ 4,0	66,0 $\pm$ 3,8	72,2 $\pm$ 4,7
HeteroGCN-MLP-w	64,3 $\pm$ 5,0	64,8 $\pm$ 4,8	64,6 $\pm$ 4,8	64,0 $\pm$ 5,2	64,1 $\pm$ 5,1	70,3 $\pm$ 5,8

Tabela A.3: Razširjeni rezultati za množico signalov *samo zenici*. Vrednosti so povprečje $\pm$ standardni odklon čez sedem testnih množic (v odstotkih). Krepko je označen najboljši rezultat v posameznem stolpcu, krepko poševno pa najboljši rezultat med grafovskimi modeli.

Model	Točnost	Preciznost	Priklic	Makro F1	Uteženi F1	AUC
Naključni	50,7 $\pm$ 2,0	50,7 $\pm$ 2,0	50,7 $\pm$ 2,0	50,6 $\pm$ 1,9	50,8 $\pm$ 2,2	50,7 $\pm$ 2,0
Večinski	52,2 $\pm$ 4,9	26,1 $\pm$ 2,4	50,0 $\pm$ 0,0	34,2 $\pm$ 2,0	35,9 $\pm$ 5,8	50,0 $\pm$ 0,0
SVM	62,1 $\pm$ 3,3	62,9 $\pm$ 3,0	61,7 $\pm$ 2,8	60,7 $\pm$ 3,6	61,1 $\pm$ 4,0	66,5 $\pm$ 3,4
LightGBM	63,1 $\pm$ 3,9	63,7 $\pm$ 2,7	62,7 $\pm$ 3,2	61,9 $\pm$ 4,3	62,2 $\pm$ 4,7	68,7 $\pm$ 3,4
MLP	62,0 $\pm$ 4,0	63,6 $\pm$ 3,9	61,5 $\pm$ 2,8	60,3 $\pm$ 4,6	60,7 $\pm$ 5,4	67,6 $\pm$ 3,6
GazeMAE/MOMENT	60,5 $\pm$ 2,5	60,8 $\pm$ 2,7	60,6 $\pm$ 2,7	60,1 $\pm$ 2,4	60,3 $\pm$ 2,5	64,9 $\pm$ 3,0
GCN	61,0 $\pm$ 3,4	65,1 $\pm$ 7,0	60,7 $\pm$ 3,0	58,4 $\pm$ 4,4	58,7 $\pm$ 4,9	67,5 $\pm$ 5,0
HeteroGCN-mean	58,6 $\pm$ 4,2	61,5 $\pm$ 6,8	58,3 $\pm$ 3,9	55,7 $\pm$ 6,1	56,1 $\pm$ 6,5	64,5 $\pm$ 3,6
HeteroGCN-MLP	59,1 $\pm$ 4,1	62,7 $\pm$ 6,7	58,8 $\pm$ 3,6	56,0 $\pm$ 6,1	56,4 $\pm$ 6,6	64,9 $\pm$ 5,0
HeteroGCN-MLP-w	58,4 $\pm$ 4,1	62,4 $\pm$ 6,3	58,1 $\pm$ 3,5	54,5 $\pm$ 7,5	54,8 $\pm$ 7,9	66,4 $\pm$ 4,9

Tabela A.4: Razširjeni rezultati za množico signalov *pogled in zenici*. Vrednosti so povprečje $\pm$ standardni odklon čez sedem testnih množic (v odstotkih). Krepko je označen najboljši rezultat v posameznem stolpcu, krepko poševno pa najboljši rezultat med grafovskimi modeli.

Model	Točnost	Preciznost	Priklic	Makro F1	Uteženi F1	AUC
Naključni	50,8 $\pm$ 2,2	50,7 $\pm$ 2,1	50,7 $\pm$ 2,1	50,6 $\pm$ 2,0	50,9 $\pm$ 2,3	50,7 $\pm$ 2,1
Večinski	52,1 $\pm$ 4,9	26,0 $\pm$ 2,4	50,0 $\pm$ 0,0	34,2 $\pm$ 2,0	35,8 $\pm$ 5,8	50,0 $\pm$ 0,0
SVM	70,5 $\pm$ 2,9	71,9 $\pm$ 2,1	70,3 $\pm$ 2,6	69,7 $\pm$ 3,4	69,9 $\pm$ 3,5	78,1 $\pm$ 1,9
LightGBM	69,6 $\pm$ 2,7	71,0 $\pm$ 2,0	69,5 $\pm$ 2,3	68,8 $\pm$ 3,1	69,0 $\pm$ 3,3	78,2 $\pm$ 2,2
MLP	68,7 $\pm$ 1,9	70,6 $\pm$ 1,8	68,5 $\pm$ 1,6	67,6 $\pm$ 2,5	67,9 $\pm$ 2,8	77,8 $\pm$ 2,4
GazeMAE/MOMENT	65,6 $\pm$ 4,7	66,5 $\pm$ 4,3	65,9 $\pm$ 4,0	65,2 $\pm$ 4,7	65,4 $\pm$ 4,5	73,0 $\pm$ 6,9
GCN	65,4 $\pm$ 2,8	67,2 $\pm$ 1,4	65,1 $\pm$ 1,8	63,9 $\pm$ 3,2	64,3 $\pm$ 3,8	73,1 $\pm$ 2,2
HeteroGCN-mean	63,8 $\pm$ 4,0	66,6 $\pm$ 2,0	63,3 $\pm$ 4,0	61,1 $\pm$ 6,9	61,6 $\pm$ 7,0	72,8 $\pm$ 2,7
HeteroGCN-MLP	64,2 $\pm$ 3,7	65,5 $\pm$ 3,1	63,8 $\pm$ 2,8	62,8 $\pm$ 3,6	63,2 $\pm$ 4,2	72,3 $\pm$ 3,7
HeteroGCN-MLP-w	65,5 $\pm$ 2,3	66,6 $\pm$ 1,3	65,2 $\pm$ 1,5	64,4 $\pm$ 2,6	64,7 $\pm$ 3,1	73,2 $\pm$ 1,6

Tabela A.5: Razširjeni rezultati za množico signalov *vsí signali*. Vrednosti so povprečje $\pm$ standardni odklon čez sedem testnih množic (v odstotkih). Krepko je označen najboljši rezultat v posameznem stolpcu, krepko poševno pa najboljši rezultat med grafovskimi modeli.

Model	Točnost	Preciznost	Priklic	Makro F1	Uteženi F1	AUC
Naključni	50,9 $\pm$ 2,0	50,8 $\pm$ 1,9	50,9 $\pm$ 1,9	50,7 $\pm$ 1,8	51,0 $\pm$ 2,1	50,9 $\pm$ 1,9
Večinski	52,2 $\pm$ 4,8	26,1 $\pm$ 2,4	50,0 $\pm$ 0,0	34,2 $\pm$ 2,0	35,9 $\pm$ 5,7	50,0 $\pm$ 0,0
SVM	68,6 $\pm$ 3,3	69,9 $\pm$ 2,1	68,3 $\pm$ 2,3	67,6 $\pm$ 3,3	67,9 $\pm$ 3,8	76,2 $\pm$ 2,6
LightGBM	69,0 $\pm$ 3,0	70,4 $\pm$ 2,2	69,0 $\pm$ 2,5	68,3 $\pm$ 3,2	68,4 $\pm$ 3,7	77,6 $\pm$ 2,7
MLP	67,2 $\pm$ 3,0	68,9 $\pm$ 2,6	67,1 $\pm$ 2,2	66,2 $\pm$ 2,7	66,5 $\pm$ 3,4	75,4 $\pm$ 3,6
GazeMAE/MOMENT	66,1 $\pm$ 3,1	66,8 $\pm$ 2,6	66,3 $\pm$ 3,0	65,6 $\pm$ 3,4	65,8 $\pm$ 3,5	72,2 $\pm$ 4,2
GCN	59,6 $\pm$ 8,4	61,5 $\pm$ 8,9	59,3 $\pm$ 8,0	57,6 $\pm$ 8,5	57,9 $\pm$ 9,0	65,7 $\pm$ 12,3
HeteroGCN-mean	61,8 $\pm$ 3,9	63,8 $\pm$ 3,7	61,3 $\pm$ 2,5	59,7 $\pm$ 4,0	60,1 $\pm$ 4,9	69,6 $\pm$ 3,1
HeteroGCN-MLP	60,5 $\pm$ 6,7	61,3 $\pm$ 9,3	59,9 $\pm$ 6,3	56,6 $\pm$ 10,7	57,1 $\pm$ 10,8	69,0 $\pm$ 6,2
HeteroGCN-MLP-w	62,7 $\pm$ 4,5	64,6 $\pm$ 3,0	62,3 $\pm$ 3,1	60,8 $\pm$ 5,1	61,2 $\pm$ 5,9	70,2 $\pm$ 3,4

Primerjava z LOSO

LOSO v vsaki ponovitvi uporabi enega udeleženca kot testno množico, vse ostale udeležence pa za učenje oziroma validacijo. V primerjavi s 7-kratnim protokolom zato uporabi več ponovitev in manjšo testno množico v posamezni ponovitvi. LOSO smo uporabili kot podporno preverjanje, ne kot glavni evalvacijski protokol. Ker bi njegova izvedba za vse modele in štiri množice signalov bistveno povečala število potrebnih poskusov, smo ga izvedli le za izbrane modele pri množici *pogled in zenici*. Spodnja tabela A.6 primerja oba protokola.


Matrike zamenjav

V nadaljevanju so prikazane vrstično normalizirane matrike zamenjav za vse modele in vse množice signalov. Za vsako množico signalov je pripravljen en prikaz z desetimi matrikami zamenjav v vrstnem redu modelov iz glavne tabele rezultatov. Vrstice predstavljajo pravilni razred, stolpci pa napovedani


Tabela A.6: Primerjava 7-kratnega prečnega preverjanja po udeležencih in LOSO za množico signalov *pogled in zenici* za izbrane modele. Prikazani so samo modeli, za katere so na voljo rezultati LOSO. Vrednosti so povprečja v odstotkih. Krepko je označen najboljši rezultat v posameznem stolpcu, krepko poševno pa najboljši rezultat med grafovskimi modeli.

Model	Točnost		Makro F1	
	7-kratno	LOSO	7-kratno	LOSO
Naključni	50,8	48,7	50,6	48,2
Večinski	52,1	51,8	34,2	33,9
LightGBM	69,6	70,1	68,8	68,3
GazeMAE/MOMENT	65,6	68,6	65,2	67,8
GCN	65,4	64,0	63,9	61,0
HeteroGCN-MLP-w	65,5	63,2	64,4	60,1

razred. Vrednosti so deleži znotraj pravilnega razreda. Matrike dopolnjujejo agregirane metrike iz prejšnjih tabel, ker pokažejo, ali model napake dela približno simetrično ali pa sistematično preferira en razred. Večinski model pričakovano napoveduje samo najpogostejši razred, pri naučenih modelih pa je razlika med diagonalnima celicama manj izrazita. Pri množici *samo zenici* opazimo, da smo najbližje naključnemu ugibanju, kar podpira sklep, da same zenice v tej podatkovni zbirki nosijo šibkejši signal za binarno valenco.



Slika A.1: Matrike zamenjav za množico signalov *samo pogled*. Prikaz vključuje naključni in večinski model, klasične modele SVM, LightGBM in MLP, zamrznjene predstavitve GazeMAE/MOMENT ter štiri grafovske modele od osnovnega GCN do HeteroGCN-MLP-w.




Slika A.2: Matrike zamenjav za množico signalov *samo zenici*. Razporeditev modelov je enaka kot pri drugih množicah signalov: izhodiščna modela, trije klasični oziroma nevronske primerjalni modeli, zamrznjene predstavitve in štiri grafske arhitekture.

Matrike zamenjav za množico signalov pogled in zenici

		Naključni		Večinski	
dejanski razred	negativna	0,52	0,48	1,00	0,00
	pozitivna	0,50	0,50	1,00	0,00
		negativna	pozitivna	negativna	pozitivna
		SVM		LightGBM	
dejanski razred	negativna	0,73	0,27	0,71	0,29
	pozitivna	0,32	0,68	0,32	0,68
		negativna	pozitivna	negativna	pozitivna
		MLP		GazeMAE/MOMENT	
dejanski razred	negativna	0,71	0,29	0,67	0,33
	pozitivna	0,34	0,66	0,35	0,65
		negativna	pozitivna	negativna	pozitivna
		GCN		HeteroGCN-mean	
dejanski razred	negativna	0,69	0,31	0,69	0,31
	pozitivna	0,38	0,62	0,42	0,58
		negativna	pozitivna	negativna	pozitivna
		HeteroGCN-MLP		HeteroGCN-MLP-w	
dejanski razred	negativna	0,69	0,31	0,65	0,35
	pozitivna	0,41	0,59	0,34	0,66
		negativna	pozitivna	negativna	pozitivna
		napoved		napoved	

Slika A.3: Matrike zamenjav za množico signalov *pogled in zenici*. Ta množica doseže najboljši skupni rezultat v glavni primerjavi. Prikaz omogoča neposredno primerjavo napak med najuspešnejšim SVM in grafovskimi modeli.




Slika A.4: Matrike zamenjav za množico signalov *vs* signali. Prikaz povzema napake modelov pri najbogatejši vhodni predstavitvi, ki poleg pogleda in zenic vključuje še oddaljenost od sledilnika pogleda ter fiksacijske informacije.

A.3 Dodatne analize

Ujemanje izpeljanih razredov s samoocenami

Slika A.5 primerja razrede, izpeljane iz preslikave v tabeli A.1, z razredi, dobljenimi iz številskih samoocen. Primerjava je uporabna kot groba ocena skladnosti med diskretnimi in številskimi samoocenami čustvenega stanja, ki so bile zbrane v istem eksperimentu. Pri binarni valenci je ujemanje na uporabljenem podnaboru 96,7 %, pri binarni vzburjenosti pa 70,3 %. Zato vzburjenosti nismo uporabili kot glavno ciljno nalogo. Vidimo, da izpeljani razredi valence bolje sledijo samoocenam udeležencev kot izpeljani razredi vzburjenosti. To ne pomeni, da so razredi valence brez šuma, vendar je za glavno primerjavo modelov bolj smiselna in stabilna ciljna naloga.



Slika A.5: Ujemanje razredov valence in vzburjenosti, izpeljanih iz preslikave v tabeli A.1, z razredi iz številskih samoocen. Vrednosti so deleži znotraj izpeljanega razreda.

Izbira tipa grafovske konvolucije

Izbiro operatorja GCNConv smo preverili z dodatnim poskusom na binarni nalogi valence pri množici signalov *pogled in zenici*. GCNConv je najpreprostejša

izbira in ustreza osnovnemu posredovanju sporočil po normalizirani sosednosti. **GATConv** doda pozornost nad sosedi in je uporaben, kadar želimo, da model sam uteži prispevke sosednjih vozlišč [31]. **GraphConv** uporabi ločen prispevek lastnega vozlišča in sosedov, pri osnovnem modelu pa deluje brez uteži povezav [23]. **GINConv** agregirano predstavitev obdela z večslojnim perceptronom [34], **GINEConv** pa v agregacijo vključi tudi značilke povezav [14]. Pri modelu **HeteroGCN-MLP-w** plasti **GCNConv** in **GraphConv** uporabljata učljive skalarne uteži povezav. **GATConv** namesto njih značilke povezav vključi v izračun pozornosti, **GINEConv** pa je razširjen kot **WeightedGINEConv**, ki uporabi značilke povezav in učljive skalarne uteži. V naših poskusih so bile razlike majhne. Pri osnovnem GCN je najvišjo vrednost dosegel **GINConv**, pri **HeteroGCN-MLP-w** pa **GraphConv**, vendar razlika ni bila dovolj velika, da bi spreminjala glavno eksperimentalno zgodbo. Zato smo v glavnih poskusih ohranili enoten in enostaven operator **GCNConv**. Ta primerjava ni ločeno iskanje najboljše grafovске arhitekture, temveč preverjanje, da izbira osnovnega operatorja ne določa glavnega sklepa naloge.

Diagnostika predstavitev

Diagnostika ne kaže jasnega kolapsa predstavitev pri glavnih grafovskih modelih. Množica *samo zenici* ima bolj neodločne napovedi, vendar tega ne obravnavamo kot sistemski kolaps grafovskih modelov. Entropija in razpon logitov opisujeta gotovost napovedi, varianca predstavitev in kosinusna podobnost pa razpršenost naučenih predstavitev grafov. Pri množici *samo zenici* sta razpon logitov in varianca predstavitev manjša, entropija pa večja, kar je skladno z manj odločnimi napovedmi. Pri množicah s koordinatami pogleda so logiti izrazitejši in predstavitve bolj razpršene. Slabši rezultati grafovskih modelov v glavni primerjavi torej niso posledica očitnega kolapsa predstavitev v skoraj enake vektorje. Rezultati so predstavljeni v tabeli A.8.

Tabela A.7: Primerjava tipov grafovskih konvolucij pri množici signalov *pogled in zenici*. Stolpec arhitektura označuje grafovski model, v katerem je bil zamenjan operator posredovanja sporočil, stolpec operator pa uporabljeno grafovsko konvolucijo. Točnost in makro F1 sta povprečni vrednosti čez sedem testnih množic. Krepko je označen najboljši rezultat za posamezno metriko znotraj vsake arhitekturne skupine, krepko poševno pa drugi najboljši rezultat.

Arhitektura	Operator	Točnost	Makro F1
Osnovni GCN	GCNConv	0,6474	0,6337
Osnovni GCN	GATConv	0,6484	0,6336
Osnovni GCN	GraphConv	0,6367	0,6192
Osnovni GCN	GINConv	0,6613	0,6501
HeteroGCN-MLP-w	GCNConv	0,6391	0,6103
HeteroGCN-MLP-w	GATConv	0,6370	0,6116
HeteroGCN-MLP-w	GraphConv	0,6606	0,6503
HeteroGCN-MLP-w	GINEConv	0,6325	0,6028

Tabela A.8: Diagnostika naučenih predstavitev in izhodov najboljšega grafovskega modela po množicah signalov. Makro F1 opisuje uspešnost klasifikacije, razpon logitov in entropija gotovost napovedi, varianca predstavitev razpršenost naučenih vektorjev, kos. pod. pa povprečno kosinusno podobnost med predstavitvami. Krepko je označen najboljši makro F1.

Množica signalov	Najboljša GNN	Makro F1	Razpon logitov	Entropija	Varianca predst.	Kos. pod.
<i>vsii signali</i>	HeteroGCN-MLP-w	0,608	3,31	0,545	0,352	0,409
<i>samo pogled</i>	HeteroGCN-MLP	0,658	3,93	0,583	0,291	0,307
<i>pogled in zenici</i>	HeteroGCN-MLP-w	0,644	3,38	0,582	0,336	0,360
<i>samo zenici</i>	GCN	0,584	1,40	0,653	0,258	0,569

Dodatek B

Dodatne metodološke podrobnosti

V tem dodatku podamo podrobnejše nastavitve eksperimentov in modelov ter dopolnimo opis grafovske konstrukcije iz poglavja 4.

B.1 Hiperparametri in izbira nastavitev

Tabela B.1 povzema glavne hiperparametre modelov v končnih eksperimentih. Nastavitve grafovske konstrukcije smo izbrali po majhnem predhodnem mrežnem iskanju na trirazredni valenci, glede na izvirne razrede definirane v tabeli A.1. Iskanje je spreminjalo število grafovskih plasti, velikost skritih predstavitev ter parametre konstrukcije k_t , k_s in k_f . Primerjali smo več nastavitev števila plasti in skrite dimenzije, vendar med njimi ni bilo velikih razlik. Ker je bil najmanjši model med najboljšimi in najstabilnejšimi, hkrati pa je računsko najvarčnejši, smo za končne poskuse izbrali $L = 2$ (število skritih plasti GNN) in $d = 64$ (dimenzija skritih plasti). Pri tej arhitekturni nastavitvi smo v mrežnem iskanju spreminjali $k_t \in \{1, 2, 3\}$, $k_s \in \{1, 2, 3\}$ in $k_f \in \{1, 2, 3, 5\}$. Najvišji rezultat v tem pomožnem iskanju je dosegla nastavitve $k_t = 3$, $k_s = 1$ in $k_f = 5$, vendar so bile razlike majhne. V končnih poskusih smo uporabili redkejšo nastavitve $k_t = 1$, $k_s = 1$ in $k_f = 3$, ker zmanjša gostoto grafa in računsko zahtevnost ter ohrani stabilno delovanje.

Tabela B.1: Glavni hiperparametri modelov v končnih eksperimentih.

Model oziroma družina	Podatkovna predstavitev	Glavni hiperparametri
Naključni model	agregirane značilke	enakomerna naključna napoved; seme 42
Večinski model	agregirane značilke	napoved večinskega razreda na učni množici
SVM	agregirane značilke	RBF; $C = 1,0$; <code>probability=true</code> ; standardizacija značilk
LightGBM	agregirane značilke	<code>n_estimators=100</code> ; <code>learning_rate=0.05</code> ; <code>max_depth=5</code> ; seme 42
MLP	agregirane značilke	skrita velikost 64; največ 200 epoh; učna stopnja 10^{-3} ; <code>dropout=0.1</code> ; mini-serija 128; potrpežljivost 15
GazeMAE/MOMENT glave	zamrznjene predstavitve	skrita velikost 128; največ 100 epoh; učna stopnja 10^{-3} ; <code>dropout=0.2</code> ; mini-serija 128; potrpežljivost 15
Grafovski modeli	grafi časovnih oken	GCNConv; 2 plasti; <code>hidden_channels=64</code> ; pozornostno združevanje; <code>dropout=0.1</code> ; učna stopnja $5 \cdot 10^{-5}$; mini-serija 256; največ 350 epoh; potrpežljivost 20
GCN	grafi časovnih oken	homogen graf; brez ločenih relacij in značilk povezav
HeteroGCN-mean	grafi časovnih oken	ločene relacije; združevanje s povprečenjem
HeteroGCN-MLP	grafi časovnih oken	ločene relacije; združevanje z MLP
HeteroGCN-MLP-w	grafi časovnih oken	kot HeteroGCN-MLP, z učljivimi utežmi povezav
Grafovska konstrukcija	grafi časovnih oken	$k_t = 1$; $k_s = 1$; $k_f = 3$; standardizirane značilke povezav

Tabela B.2: Povzetek predhodnega mrežnega iskanja hiperparametrov grafovske konstrukcije. Stolpci k_t , k_s in k_f pomenijo velikost časovne, prostorske oziroma fiksacijske okolice pri konstrukciji grafa. Vrstica preiskani prostor podaja množice preizkušenih vrednosti, vrstica najvišji makro F1 najboljšo najdeno kombinacijo, vrstica končna nastavitve pa vrednosti, uporabljene v glavnih poskusih.

Nastavitev	k_t	k_s	k_f	Opomba
Preiskani prostor	$\{1, 2, 3\}$	$\{1, 2, 3\}$	$\{1, 2, 3, 5\}$	36 uspešno izvedenih kombinacij
Najvišji makro F1	3	1	5	makro F1 = 0,510, točnost = 0,522
Končna nastavitve	1	1	3	makro F1 = 0,507, točnost = 0,518

B.2 Izvedbene podrobnosti

Strojna in programska oprema

Glavni eksperimenti so bili izvedeni na računalniku z operacijskim sistemom Ubuntu, grafično kartico NVIDIA GeForce RTX 4070 z 12 GB grafičnega pomnilnika, procesorjem AMD Ryzen 7 5700X, 32 GB systemskega pomnilnika in pogonom Samsung SSD 990 PRO NVMe. Poskusi so bili izvedeni v virtualnem okolju Conda. Uporabljene so bile različice: Python 3.10.19, PyTorch 2.9.1+cu126, CUDA 12.6, PyG 2.7.0, scikit-learn 1.7.2, LightGBM 4.6.0, NumPy 1.25.2, pandas 2.3.3, Matplotlib 3.10.6 in seaborn 0.13.2.

Učljive uteži povezav

V modelu **HeteroGCN-MLP-w** značilke povezave uporabimo za izračun skalarne uteži povezave. Naj bo $\mathbf{e}_{ij}^{(r)}$ vektor značilk povezave (v_i, v_j) v relaciji r . Najprej izračunamo surovo oceno:

$$s_{ij}^{(r)} = f_w^{(r)} \left(\mathbf{e}_{ij}^{(r)} \right), \quad (\text{B.1})$$

kjer je $f_w^{(r)}$ večslojni perceptron za ustrezno družino relacij. Za časovne povezave naprej in nazaj uporabimo isti perceptron $f_w^{\text{čas}}$, za prostorske povezave f_w^{prostor} , za fiksacijske povezave pa $f_w^{\text{fiksacija}}$. Vsak od teh perceptronov ima obliko

$$d_e \rightarrow 6 \rightarrow 4 \rightarrow 2 \rightarrow 1, \quad (\text{B.2})$$

kjer je d_e dimenzija vektorja značilke povezave za izbrano relacijo in množico signalov.

Surovo oceno nato omejimo s funkcijo $\tanh$:

$$\tilde{w}_{ij}^{(r)} = \tanh \left(s_{ij}^{(r)} \right). \quad (\text{B.3})$$

Končno utež normaliziramo po vhodnih povezavah ciljne meritve v_j znotraj iste relacije:

$$w_{ij}^{(r)} = \frac{\tilde{w}_{ij}^{(r)}}{\sum_{k:(v_k, v_j) \in E_r} \left| \tilde{w}_{kj}^{(r)} \right| + \epsilon}, \quad (\text{B.4})$$

kjer je $\epsilon = 10^{-8}$ majhna konstanta za numerično stabilnost. Vsota absolutnih vrednosti uteži vseh vhodnih povezav vozlišča znotraj posamezne relacije je zato približno enaka 1. Odstopanje povzroči le člen ϵ . V uporabljeni izvedbi plast `GCNConv` pri modelu `HeteroGCN-MLP-w` teh uteži ne normalizira ponovno po stopnjah vozlišč in ne dodaja samozank, temveč jih neposredno uporabi kot koeficiente sporočil. Lastna predstavitev vozlišča se ohranja po ločeni rezidualni povezavi. Normalizacija v enačbi (B.4) ohrani predznak, zato negativna utež obrne predznak prispevka sosednjega vozlišča, njena absolutna vrednost pa določa njegovo jakost.

B.3 Konstrukcija in značilke povezav

Razširjene povezave znotraj fiksacije

Fiksacijo obravnavamo kot neprekinjeno zaporedje vozlišč z istim veljavnim identifikatorjem fiksacije. Če ima taka fiksacija F vozlišč, jim priredimo lokalne indekse $0, \dots, F-1$. Parameter k_f določa število fiksacijskih povezav,

ki jih generira vsako vozlišče. Za posamezno fiksacijo najprej izračunamo korak razširitve

$$s = \max(1, \lfloor F/k_f + 0,5 \rfloor). \quad (\text{B.5})$$

Množico kandidatnih odmikov določimo kot

$$D = \{(1 + qs) \bmod F \mid q = 0, \dots, k_f - 1\}. \quad (\text{B.6})$$

Morebitni odmik 0 in podvojene odmiške odstranimo. Za vsak odmik $d \in D$ dodamo neusmerjene povezave

$$\{v_i, v_{(i+d) \bmod F}\}, \quad i = 0, \dots, F - 1. \quad (\text{B.7})$$

Pri zapisu grafa za posredovanje sporočil vsako neusmerjeno povezavo predstavimo z dvema usmerjenima povezavama in odstranimo podvojene povezave znotraj relacije E_f .

Pri fiksaciji dolžine $F = 21$ in parametru $k_f = 3$ dobimo $s = 7$. Vozlišče z lokalnim indeksom 0 se zato poveže z vozlišči 1, 8 in 15. Odmik 1 ohrani časovno lokalno komunikacijo, večji odmiški pa omogočijo širjenje informacij tudi med časovno bolj oddaljenimi meritvami iste fiksacije. Ker vsaka plast GNN omogoča izmenjavo informacij med neposredno povezanimi vozlišči, se doseg znotraj fiksacije dodatno povečuje s številom plasti. Opisano lepo prikaže slika 4.1 v glavnem besedilu.

Značilke povezav

Tabela B.3 podrobno opisuje simbole značilk povezav, uporabljene v tabeli 4.1.


B.4 Ločeni prikazi tipov povezav

Slike B.1, B.2 in B.3 prikazujejo isti izsek časovnega okna, vendar ločeno za posamezne tipe povezav. Namenjene so predvsem lažjemu branju slike 4.2. Časovne povezave pokažejo lokalni red meritev, prostorske povezave sosednost položajev pogleda na zaslonu, fiksacijske povezave pa povezovanje meritev znotraj iste zaznane fiksacije.


Tabela B.3: Značilke povezav v grafovski predstavitvi. Izraz *vse relacije* pomeni vse relacije, ki so prisotne pri navedeni množici signalov.

Značilka	Opis	Relacije	Množice signalov
t_i	Normaliziran čas izvirne meritve znotraj časovnega okna.	Vse relacije.	Vse štiri množice.
t_j	Normaliziran čas ciljne meritve znotraj časovnega okna.	Vse relacije.	Vse štiri množice.
Δt	Časovna razlika med ciljno in izvirno meritvijo, $\Delta t = t_j - t_i$.	Vse relacije.	Vse štiri množice.
ρ_{ij}	Smer časovne povezave; pri povezavi naprej je $\rho_{ij} = 1$, pri povezavi nazaj pa $\rho_{ij} = -1$.	Samo časovne.	Vse štiri množice.
Δx	Razlika v vodoravni koordinati pogleda, $\Delta x = x_j - x_i$.	Vse relacije.	<i>samo pogled, pogled in zenici, vsi signali.</i>
Δy	Razlika v navpični koordinati pogleda, $\Delta y = y_j - y_i$.	Vse relacije.	<i>samo pogled, pogled in zenici, vsi signali.</i>
d_{ij}^{zaslon}	Evklidska razdalja med položajema pogleda na zaslonu. $d_{ij}^{\text{zaslon}} = \sqrt{\Delta x^2 + \Delta y^2}$	Vse relacije.	<i>samo pogled, pogled in zenici, vsi signali.</i>
$\Delta p_{ij}^{(l)}$	Razlika v velikosti leve zenice, $\Delta p_{ij}^{(l)} = p_j^{(l)} - p_i^{(l)}$.	Vse relacije.	<i>samo zenici, pogled in zenici, vsi signali.</i>
$\Delta p_{ij}^{(r)}$	Razlika v velikosti desne zenice, $\Delta p_{ij}^{(r)} = p_j^{(r)} - p_i^{(r)}$.	Vse relacije.	<i>samo zenici, pogled in zenici, vsi signali.</i>
$\Delta d_{ij}^{\text{sled}}$	Razlika v oddaljenosti od sledilnika pogleda, $\Delta d_{ij}^{\text{sled}} = d_j^{\text{sled}} - d_i^{\text{sled}}$.	Vse relacije.	<i>vsii signali.</i>


Opomba: Barve označujejo čas, pogled in prostorske značilke, zenici ter dodatne signale.



Slika B.1: Časovne povezave v izseku grafa. Oranžne povezave vodijo naprej po zaporedju meritev, rožnate pa nazaj. Slika prikazuje lokalno časovno okolico vsakega vozlišča.



Slika B.2: Prostorske povezave v izseku grafa. Povezujejo meritve s podobnim položajem pogleda na zaslonu, zato lahko povežejo tudi časovno bolj oddaljena vozlišča.



Slika B.3: Fiksacijske povezave v izseku grafa. Povezujejo meritve iz iste zaznane fiksacije, vendar z omejenim številom odmikov, da graf ne postane preveč gost.

Literatura

- [1] Jimmy Lei Ba, Jamie Ryan Kiros in Geoffrey E. Hinton. „Layer Normalization“. V: *arXiv preprint arXiv:1607.06450* (2016). URL: <https://arxiv.org/abs/1607.06450>.
- [2] Louise Gillian C. Bautista in Prospero C. Naval. „GazeMAE: General Representations of Eye Movements Using a Micro-Macro Autoencoder“. V: *2020 25th International Conference on Pattern Recognition (ICPR)*. IEEE, 2021, str. 7004–7011. DOI: 10.1109/ICPR48806.2021.9412761.
- [3] Marie E. Bellet in sod. „Human-Level Saccade Detection Performance Using Deep Neural Networks“. V: *Journal of Neurophysiology* 121.2 (2019), str. 646–661. DOI: 10.1152/jn.00601.2018.
- [4] Tomi Božak. *GFM-for-eyetracker: Graph Foundation Model Research Codebase for Eye-Tracking Signals*. GitHub repository, commit 2a5cacc. 2026. URL: <https://github.com/Space0code/GFM-for-eyetracker> (pridobljeno 8. 7. 2026).
- [5] Tomi Božak, Mitja Luštrek in Gašper Slapničar. „Feature-Based Emotion Classification Using Eye-Tracking Data“. V: *Information Society 2024*. Ljubljana, Slovenia, 2024. DOI: 10.70314/is.2024.scai.9988.
- [6] Corinna Cortes in Vladimir Vapnik. „Support-Vector Networks“. V: *Machine Learning* 20.3 (1995), str. 273–297. DOI: 10.1007/BF00994018.
- [7] Matthias Fey in Jan Eric Lenssen. „Fast Graph Representation Learning with PyTorch Geometric“. V: *ICLR Workshop on Representation*

- Learning on Graphs and Manifolds*. 2019. arXiv: 1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.
- [8] Justin Gilmer in sod. „Neural Message Passing for Quantum Chemistry“. V: *Proceedings of the 34th International Conference on Machine Learning*. Zv. 70. Proceedings of Machine Learning Research. PMLR, 2017, str. 1263–1272.
- [9] Ian Goodfellow, Yoshua Bengio in Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [10] Mononito Goswami in sod. „MOMENT: A Family of Open Time-Series Foundation Models“. V: *Proceedings of the 41st International Conference on Machine Learning*. Zv. 235. Proceedings of Machine Learning Research. PMLR, 2024, str. 16115–16152. URL: <https://proceedings.mlr.press/v235/goswami24a.html>.
- [11] Henry Griffith in sod. „GazeBase, a Large-Scale, Multi-Stimulus, Longitudinal Eye Movement Dataset“. V: *Scientific Data* 8.1 (2021), str. 184. DOI: 10.1038/s41597-021-00959-y.
- [12] Kaiming He in sod. „Deep Residual Learning for Image Recognition“. V: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016, str. 770–778. DOI: 10.1109/CVPR.2016.90.
- [13] Dan Hendrycks in Kevin Gimpel. „Gaussian Error Linear Units (GELUs)“. V: *arXiv preprint arXiv:1606.08415* (2016). URL: <https://arxiv.org/abs/1606.08415>.
- [14] Weihua Hu in sod. „Strategies for Pre-Training Graph Neural Networks“. V: *International Conference on Learning Representations*. 2020. URL: <https://openreview.net/forum?id=HJlWWJSFDH>.
- [15] Ming Jin in sod. „A Survey on Graph Neural Networks for Time Series: Forecasting, Classification, Imputation, and Anomaly Detection“. V: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 46.12 (2024), str. 10466–10485. DOI: 10.1109/TPAMI.2024.3443141.

- [16] Guolin Ke in sod. „LightGBM: A Highly Efficient Gradient Boosting Decision Tree“. V: *Advances in Neural Information Processing Systems*. Zv. 30. Curran Associates, Inc., 2017. URL: <https://papers.nips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree>.
- [17] Thomas N. Kipf in Max Welling. „Semi-Supervised Classification with Graph Convolutional Networks“. V: *International Conference on Learning Representations*. 2017. URL: <https://openreview.net/forum?id=SJU4ayYgl>.
- [18] Emmanouil Ktistakis in sod. „COLET: A Dataset for COgnitive workLoad Estimation Based on Eye-Tracking“. V: *Computer Methods and Programs in Biomedicine* 224 (2022), str. 106989. DOI: 10.1016/j.cmpb.2022.106989.
- [19] Jia Zheng Lim, James Mountstephens in Jason Teo. „Emotion Recognition Using Eye-Tracking: Taxonomy, Review and Current Challenges“. V: *Sensors* 20.8 (2020), str. 2384. DOI: 10.3390/s20082384.
- [20] Chenyu Liu in sod. „Graph Neural Networks in EEG-Based Emotion Recognition: A Survey“. V: *arXiv preprint arXiv:2402.01138* (2024). arXiv: 2402.01138 [cs.LG].
- [21] Yifei Lu in sod. „Combining Eye Movements and EEG to Enhance Emotion Recognition“. V: *Proceedings of the Twenty-Fourth International Joint Conference on Artificial Intelligence*. IJCAI. 2015, str. 1170–1176.
- [22] *MAHNOB Databases*. MAHNOB. URL: <https://mahnob-db.eu/> (pridobljeno 22. 8. 2024).
- [23] Christopher Morris in sod. „Weisfeiler and Leman Go Neural: Higher-Order Graph Neural Networks“. V: *Proceedings of the AAAI Conference on Artificial Intelligence*. Zv. 33. 1. 2019, str. 4602–4609. DOI: 10.1609/aaai.v33i01.33014602.
- [24] OpenAI. *ChatGPT*. Uporabljeno podporno orodje; model GPT-5.5 Thinking. 2026. URL: <https://chatgpt.com/> (pridobljeno 8. 7. 2026).

- [25] Marco Pedrotti in sod. „Automatic Stress Classification With Pupil Diameter Analysis“. V: *International Journal of Human-Computer Interaction* 30.3 (2014), str. 220–236. DOI: 10.1080/10447318.2013.848320.
- [26] Vasileios Skaramagkas in sod. „eSEE-d: Emotional State Estimation Based on Eye-Tracking Dataset“. V: *Brain Sciences* 13.4 (2023), str. 589. DOI: 10.3390/brainsci13040589.
- [27] Mohammad Soleymani in sod. „A Multimodal Database for Affect Recognition and Implicit Tagging“. V: *IEEE Transactions on Affective Computing* 3.1 (2012), str. 42–55. DOI: 10.1109/T-AFFC.2011.25.
- [28] Tengfei Song in sod. „EEG Emotion Recognition Using Dynamical Graph Convolutional Neural Networks“. V: *IEEE Transactions on Affective Computing* 11.3 (2020), str. 532–541. DOI: 10.1109/TAFFC.2018.2817622.
- [29] Nitish Srivastava in sod. „Dropout: A Simple Way to Prevent Neural Networks from Overfitting“. V: *Journal of Machine Learning Research* 15.56 (2014), str. 1929–1958. URL: <http://jmlr.org/papers/v15/srivastava14a.html>.
- [30] Paweł Tarnowski in sod. „Eye-Tracking Analysis for Emotion Recognition“. V: *Computational Intelligence and Neuroscience* 2020 (2020), str. 2909267. DOI: 10.1155/2020/2909267.
- [31] Petar Veličković in sod. „Graph Attention Networks“. V: *International Conference on Learning Representations*. 2018. URL: <https://openreview.net/forum?id=rJXMpikCZ>.
- [32] Yang Wang, Zhao Lv in Yongjun Zheng. „Automatic Emotion Perception Using Eye Movement Information for E-Healthcare Systems“. V: *Sensors* 18.9 (2018), str. 2826. DOI: 10.3390/s18092826.
- [33] Qun Wu in sod. „Emotion Classification on Eye-Tracking and Electroencephalograph Fused Signals Employing Deep Gradient Neural Networks“. V: *Applied Soft Computing* 110 (2021), str. 107752. DOI: 10.1016/j.asoc.2021.107752.

-
- [34] Keyulu Xu in sod. „How Powerful Are Graph Neural Networks?“ V: *International Conference on Learning Representations*. 2019. URL: <https://openreview.net/forum?id=ryGs6iA5Km>.
- [35] Bing Yu, Haoteng Yin in Zhanxing Zhu. „Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting“. V: *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence*. International Joint Conferences on Artificial Intelligence Organization, 2018, str. 3634–3640. DOI: 10.24963/ijcai.2018/505.
- [36] Tianyi Zhang in sod. „RCEA: Real-Time, Continuous Emotion Annotation for Collecting Precise Mobile Video Ground Truth Labels“. V: *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, 2020, str. 1–15. DOI: 10.1145/3313831.3376808.
- [37] Peixiang Zhong, Di Wang in Chunyan Miao. „EEG-Based Emotion Recognition Using Regularized Graph Neural Networks“. V: *IEEE Transactions on Affective Computing* 13.3 (2022), str. 1290–1301. DOI: 10.1109/TAFFC.2020.2994159.