

UNIVERZA V LJUBLJANI
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO

Tomi Božak

**Grafovske nevronske mreže za
klasifikacijo čustvenih oznak iz podatkov
sledilnika pogleda**

DIPLOMSKO DELO

UNIVERZITETNI ŠTUDIJSKI PROGRAM
PRVE STOPNJE
RAČUNALNIŠTVO IN INFORMATIKA

MENTOR: izr. prof. dr. Lovro Šubelj
SOMENTOR: doc. dr. Gašper Slapničar

Ljubljana, 2026

To delo je ponujeno pod licenco *Creative Commons Priznanje avtorstva-Deljenje pod enakimi pogoji 2.5 Slovenija* (ali novejšo različico). To pomeni, da se tako besedilo, slike, grafi in druge sestavine dela kot tudi rezultati diplomskega dela lahko prosto distribuirajo, reproducirajo, uporabljajo, priobčujejo javnosti in predelujejo, pod pogojem, da se jasno in vidno navede avtorja in naslov tega dela in da se v primeru spremembe, preoblikovanja ali uporabe tega dela v svojem delu, lahko distribuira predelava le pod licenco, ki je enaka tej. Podrobnosti licence so dostopne na spletni strani creativecommons.si ali na Inštitutu za intelektualno lastnino, Streliška 1, 1000 Ljubljana.



Izvorna koda diplomskega dela, njeni rezultati in v ta namen razvita programska oprema je ponujena pod licenco GNU General Public License, različica 3 (ali novejša). To pomeni, da se lahko prosto distribuira in/ali predeluje pod njenimi pogoji. Podrobnosti licence so dostopne na spletni strani <http://www.gnu.org/licenses/>.

Besedilo je oblikovano z urejevalnikom besedil L^AT_EX.

Kandidat: Tomi Božak

Naslov: Grafovske nevronske mreže za klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda

Vrsta naloge: Diplomaska naloga na univerzitetnem programu prve stopnje

Mentor: izr. prof. dr. Lovro Šubelj

Somentor: doc. dr. Gašper Slapničar

Opis:

TODO: Besedilo teme diplomskega dela prepisi iz študijskega informacijskega sistema.

Title: Graph Neural Networks for Classification of Emotional Labels from Eye-Tracking Data

Description:

TODO: Prevedi uradni opis teme diplomskega dela iz STUDIS-a.

TODO: Zahvaliti se IJS, da so omogočili uporabo njihove infrastrukture. Zahvaliti se mentorju Lovru za nasvete pri razvoju GNN in somentorju za nasvete pri raziskovalnem delu. Zahvaliti se tudi Mitji Luštreku za nasvete pri raziskovalnem delu. (tudi FRIju in družini al je too much?)

TODO: Posvetilo lahko odstraniš, če ga ne želiš.

Kazalo

Povzetek

Abstract

Razširjeni povzetek	1
1 Uvod	5
1.1 Raziskovalni problem	5
1.1.1 Raziskovalna vprašanja	6
1.2 Doprinosi naloge	6
1.3 Struktura naloge	7
2 Teoretično ozadje	9
2.1 Grafi	9
2.1.1 Osnovna definicija grafa	9
2.1.2 Usmerjeni, uteženi in heterogeni grafi	9
2.2 Grafske nevroonske mreže	10
2.2.1 Posredovanje sporočil	10
2.2.2 Klasifikacija na ravni grafa	11
2.2.3 Prekomerno glajenje in kolaps predstavitev	12
2.3 Podatki sledilnika pogleda	12
2.4 Čustvena stanja: valenca in vznemirjenost	12
2.4.1 Dimenzijski opis čustev	12
2.4.2 Binarna klasifikacija	13

3	Sorodna dela	15
3.1	Podatki sledilnika pogleda pri klasifikaciji čustvenih oznak . . .	15
3.2	Podatkovna zbirka MAHNOB-HCI	16
3.3	Grafovske nevronske mreže za časovno-prostorske podatke . . .	17
3.4	Učenje predstavitev iz signalov	17
3.5	Položaj te naloge glede na sorodna dela	18
4	Podatki in predobdelava	19
4.1	Podatkovna zbirka MAHNOB-HCI	19
4.1.1	Izvirna zbirka	19
4.2	Predhodni poskus z zbirko eSEEd_v2	20
4.3	Ciljne oznake	20
4.3.1	Izvor čustvenih oznak	20
4.4	Priprava vhodnih signalov	21
4.4.1	Skupine signalov	21
4.4.2	Čiščenje podatkov	22
4.5	Normalizacija	23
4.6	Segmentacija v časovna okna	23
4.7	Povzetek predobdelave	24
5	Grafovska predstavitev podatkov sledilnika pogleda	27
5.1	Vozlišča	27
5.1.1	Definicija	27
5.1.2	Vektor značilk vozlišča	28
5.2	Relacije	28
5.2.1	Zakaj ločimo relacije	28
5.2.2	Časovne povezave	29
5.2.3	Prostorske povezave	29
5.2.4	Fiksacijske povezave	30
5.2.5	Značilke povezav	32
5.3	Grafovska konstrukcija po množicah signalov	33
5.4	Statistika konstruiranih grafov	35

6	Primerjani modeli in predlagana arhitektura	37
6.1	Negrafovski osnovni modeli	39
6.1.1	MLP	40
6.2	Negrafovski predstavnik SOTA: GazeMAE + MLP	40
6.3	Osnovni GCN	41
6.3.1	Izbira grafovske konvolucije	42
6.4	Predlagani prostorsko-časovni heterogeni GNN	43
6.4.1	Pregled arhitekture	43
6.4.2	Relacijsko posredovanje sporočil in uteži povezav	44
6.4.3	Fuzija relacijskih predstavitev	45
6.4.4	Predstavitev grafa in napoved	46
6.4.5	Stabilizacija učenja	47
7	Eksperimentalni protokol	49
7.1	Eksperimentalne naloge	49
7.1.1	Valenca in vzburjenost	50
7.2	Validacijska protokola	51
7.2.1	Prečno preverjanje z izpuščanjem enega primerka	51
7.2.2	LOO po subjektih	53
7.2.3	LOO po posnetkih	53
7.3	Metrike	54
7.4	Spremljanje učenja in diagnostika	55
7.5	Glavna primerjava modelov	56
7.6	Ablacijska študija	59
8	Rezultati	63
8.1	Porazdelitev razredov in zanesljivost oznak	64
8.2	Glavna primerjava modelov	65
8.3	Vpliv množice signalov	68
8.4	Matrike zmede	68
8.5	Velikost in računska zahtevnost modelov	69
8.6	Dodatna preverjanja	70

8.7	Povzetek rezultatov	71
9	Diskusija	73
9.1	Ali grafovska predstavitev pomaga?	74
9.2	Vloga časovnih in prostorskih povezav	75
9.3	Primerjava z GazeMAE	76
9.4	Stabilnost učenja in notranje predstavitve	77
9.5	Primerjava z izvirnim MAHNOB-HCI pristopom	78
9.6	Omejitve	78
9.7	Možnosti nadaljnjega dela	79
10	Zaključek	81
A	Dodatni rezultati	85
A.1	Preslikava čustvenih oznak v valenco	87
A.2	Razširjeni rezultati binarne klasifikacije valence	88
A.3	Ujemanje izpeljanih oznak s samoocenami	90
A.4	Izbira tipa grafovske konvolucije	90
B	Hiperparametri	93
C	Dodatne vizualizacije grafov	95
D	Diagnostika predstavitev modela	99
D.1	Diagnostika prekomernega glajenja	100
E	Zgodovinski poskusi na eSEEd_v2	101
	Literatura	103

Seznam uporabljenih kratic

kratica	angleško	slovensko
AUC	area under the curve	ploščina pod krivuljo
F1	F1 score	mera F1
GAT	graph attention network	grafovska pozornostna mreža
GCN	graph convolutional network	grafovska konvolucijska mreža
GFM	graph foundation model	grafovski temeljni model
GNN	graph neural network	grafovska nevronska mreža
LOO	leave-one-out	izpusti enega
LORO	leave-one-recording-out	izpusti en posnetek
LOSO	leave-one-subject-out	izpusti en subjekt
MLP	multilayer perceptron	večslojni perceptron
SVM	support vector machine	metoda podpornih vektorjev

Povzetek

Naslov: Grafovske nevronske mreže za klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda

Avtor: Tomi Božak

V diplomski nalogi raziskujemo uporabo grafovskih nevronskih mrež za prepoznavo afektivnih stanj iz podatkov sledilnika pogleda.

TODO: Povzetek prepisati po končnih rezultatih: glavna naloga naj bo binarna klasifikacija, glavna primerjava pa modeli pri množicah *samo pogled*, *pogled in zenici* in *vsii signali*; GazeMAE omeni kot referenco za množico *samo pogled*, MOMENT/*samo zenici* samo, če bo dejansko izveden.

TODO:

- Povzetek sme povzeti grafovsko predstavitev v enem stavku, ne sme pa ponavljati definicij grafa, heterogenosti ali uteži povezav.
- Uporabi enako terminologijo kot v glavnem besedilu: *časovno-prostorski graf* in *časovno-prostorska grafovska predstavitev*, ne mešaj s *prostorsko-časovni graf*.

Osrednji metodološki problem je predstavitev časovnega okna meritev pogleda kot prostorsko-časovnega grafa, v katerem vozlišča predstavljajo posamezne meritve, povezave pa opisujejo časovno bližino, prostorsko bližino in pripadnost isti fiksaciji. Na takšni predstavitvi razvijemo in ovrednotimo grafovski model za večrazredno klasifikacijo valence in vznburjenosti (ang.

arousal).

Eksperimentalno evalvacijo izvedemo na podatkovni zbirki MAHNOB-HCI z dvema validacijskima protokoloma: delitvijo po subjektih in delitvijo po posnetkih. Grafovske modele primerjamo z ne-grafovskimi modeli strojnega učenja ter s predstavitvijo GazeMAE kot predstavnikom sodobnih metod učenja predstavitev iz podatkov pogleda. Poleg končnih klasifikacijskih rezultatov analiziramo tudi vpliv posameznih komponent grafovske konstrukcije, vključno s časovnimi povezavami, prostorskimi povezavami, fiksacijskimi povezavami, značilkami zenice in utežmi povezav.

Glavno raziskovalno vprašanje naloge je, ali lahko prostorsko-časovna grafovska predstavitve oken meritev sledilnika pogleda izboljša klasifikacijo afektivnih stanj v primerjavi z ne-grafovskimi modeli na enakih vhodnih oknih.

Ključne besede: grafovske nevronske mreže, prostorsko-časovni grafi, sledilnik pogleda, prepoznavanje čustev, afektivno računalništvo, strojno učenje.

Abstract

Title: Graph Neural Networks for Classification of Emotional Labels from Eye-Tracking Data

Author: Tomi Božak

This thesis investigates the use of graph neural networks for affective state recognition from eye-tracking data.

TODO: Rewrite the abstract after the final experiments: the main task should be binary classification, and the main comparison should cover models under the *gaze*, *gaze+pupil*, and *all* input sets; describe GazeMAE as a *gaze-only* reference and mention MOMENT/*pupil-only* only if the experiment is actually completed.

The central methodological problem is the representation of a temporal window of gaze measurements as a spatio-temporal graph, where nodes correspond to individual samples and edges encode temporal proximity, spatial proximity, and shared fixation membership. Based on this representation, we develop and evaluate a graph-based model for three-class classification of valence and arousal.

The experimental evaluation is performed on the MAHNOB-HCI dataset using two validation protocols: leave-one-subject-out and leave-one-recording-out evaluation. Graph-based models are compared against non-graph machine learning baselines and against GazeMAE as a representative of modern gaze representation learning methods. In addition to final classification performance, we analyze the contribution of individual components of the

graph construction, including temporal edges, spatial edges, fixation edges, pupil features, and edge weights.

The main research question of the thesis is whether a spatio-temporal graph representation of eye-tracking windows can improve affective state classification compared to non-graph models trained on the same input windows.

Keywords: graph neural networks, spatio-temporal graphs, eye tracking, emotion recognition, affective computing, machine learning.

Razširjeni povzetek

TODO: To poglavje napiši na koncu, ko bodo znani rezultati. Struktura naj bo podobna raziskovalnemu članku:

- novo izhodišče: glavna evalvacija naj bo binarna klasifikacija in primerjava modelov pri množicah *samo pogled*, *pogled in zenici* in *vsii signali*;
- GazeMAE opiši kot referenco za množico *samo pogled*; *samo zenici*/MOMENT omeni samo, če bo eksperiment dokončan;
- motivacija: zakaj grafovska predstavitev podatkov sledilnika pogleda;
- predlagana metoda: kako iz časovnih oken nastanejo grafi;
- eksperimentalni protokol: MAHNOB-HCI, 3-razredna valenca/vzbujenost, LOO po subjektih in LOO po posnetkih;
- rezultati: primerjava s primerjalnimi modeli, GazeMAE in GNN arhitekturami;
- sklep: kaj grafovska predstavitev prispeva in kje so omejitve.

I Grafovske nevronske mreže in motivacija

TODO: Kratko povzemi, kaj so grafovske nevronske mreže, zakaj so primerne za podatke z relacijsko, prostorsko ali časovno strukturo in zakaj je okno meritev sledilnika pogleda smiselno obravnavati kot prostorsko-časovni graf.

II Grafovska predstavitev podatkov sledilnika pogleda

TODO:

- Razširjeni povzetek naj grafovsko predstavitev samo povzame; natančne definicije ostanejo v poglavju 5.
- Ne ponavljaj formul za konstrukcijo povezav, značilk povezav ali normalizacijo uteži.
- Uteži povezav omeni samo kot arhitekturno komponento, definirano v poglavju 6; ne kot del osnovne definicije vhodnega grafa.
- vozlišče = ena meritev sledilnika pogleda;
- značilke vozlišča = koordinati pogleda (x , y), leva/desna zenica, `time-window-normalized`, `distance-avg`, `fixation-duration`;
- časovne povezave = bližina vzorcev v času, $k_t = 2$;
- prostorske povezave = bližina vzorcev v prostoru pogleda, $k_s = 2$;
- fiksacijske povezave = razširjene povezave znotraj fiksacije, $k_f = 3$;
- uteži povezav = naučene predznačene uteži iz značilk relacije;
- `fixation-index` = grupiranje, ne numerična značilka vozlišča.

III Modeliranje in eksperimentalna evalvacija

TODO: Kratko povzemi uporabljeno podatkovno zbirko MAHNOB-HCI, nalogi 3-razredne valence in 3-razredne vzburjenosti, validacijo LOO po subjektih in LOO po posnetkih ter primerjane modele: SVM, LightGBM, MLP, GazeMAE + MLP, osnovni GCN in predlagani GNN.

IV Rezultati in sklep

TODO: Dopolni po zaključku eksperimentov: kateri model je najboljši pri valenci, kateri pri vzburjenosti, ali GNN izboljša rezultate glede na ne-grafovske primerjalne modele, katere komponente grafa najbolj prispevajo k rezultatu ter glavne omejitve in prihodnje delo.

Poglavje 1

Uvod

Za učenje iz podatkov, kjer niso pomembne zgolj lastnosti posameznih elementov, ampak tudi odnosi med njimi, lahko uporabimo grafovske nevronske mreže (GNN) [5, 11]. Primer takšnih podatkov so podatki sledilnika pogleda. Meritvam sledilnika pogleda lahko smiselno določimo časovne in prostorske odnose in jim s tem priredimo časovno-prostorski graf. Na tem grafu se z grafovsko nevronske mreže učimo predstavitev vozlišč in grafov, ki jih uporabimo za klasifikacijo grafa. Podatki, uporabljeni v tej nalogi, so označeni s čustvenimi oznakami valence, zato GNN učimo binarno klasifikacijo valence, rezultate pa primerjamo z rezultati uveljavljenih negrafovskih pristopov. Eksperimentalno primerjavo izvedemo na štirih signalnih naborih: samo koordinatah pogleda (pogled), samo velikostih zenic (zenici), združenih koordinatah pogleda in velikostih zenic (pogled+zenici) ter celotnem naboru razpoložljivih signalov (vsi signali).

1.1 Raziskovalni problem

Raziskovalni problem naloge je zasnova, implementacija in ovrednotenje grafovskih predstavitev podatkov sledilnika pogleda za klasifikacijo valence.

1.1.1 Raziskovalna vprašanja

Glavno raziskovalno vprašanje je:

RV1: Kakšna je klasifikacijska uspešnost grafovske nevronske mreže za binarno klasifikacijo valence iz podatkov sledilnika pogleda v primerjavi s klasifikacijsko uspešnostjo uveljavljenih negrafovskih pristopov?

Dodatna podvprašanja so:

PV1: Kako podatke sledilnika pogleda smiselno predstaviti kot časovno-prostorski graf?

PV2: Kako se uspešnost klasifikatorjev razlikuje med posameznimi nabori signalov sledilnika pogleda?

PV3: Kako se klasifikacijska uspešnost spreminja z večjo kompleksnostjo grafovske nevronske mreže?

1.2 Doprinosi naloge

Glavni doprinosi diplomske naloge so:

1. zasnova časovno-prostorske grafovske predstavitve časovnih oken podatkov sledilnika pogleda;
2. ovrednotenje arhitekturne lestvice grafovskih modelov za klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda;
3. primerjava klasifikacijske uspešnosti pri različnih signalnih naborih;
4. primerjava grafovskih modelov z uveljavljenimi negrafovskimi modeli in zamrznjenimi prednaučenimi predstavitvenimi modeli.

[Ali rabimo te doprinose ali raje odstranimo, glede na to da se samo ponovijo raziskovalna vprašanja?]

1.3 Struktura naloge

V poglavju 2 predstavimo teoretično ozadje grafov, grafovskih nevronske mreže, podatkov sledilnika pogleda in afektivnega računalništva. V poglavju 3 predstavimo sorodna dela, vključno z uporabo podatkovne zbirke MAHNOB-HCI in metodami učenja predstavitev iz podatkov pogleda. Poglavje 4 opisuje uporabljene podatke, ciljne oznake in predobdelavo. V poglavju 5 opišemo konstrukcijo časovno-prostorskega grafa. Poglavje 6 predstavi uporabljene modele. V poglavju 7 opišemo eksperimentalni protokol, v poglavju 8 pa rezultate glavne primerjave modelov in signalnih naborov. Poglavje 9 vsebuje interpretacijo rezultatov, omejitve in možnosti nadaljnjega dela. Nalogo sklenemo v poglavju 10.

Poglavje 2

Teoretično ozadje

V tem poglavju predstavimo metodološke pojme, ki so potrebni za razumevanje grafov, grafovskih nevronske mreže, podatkov sledilnika pogleda ter valence.

2.1 Grafi

2.1.1 Osnovna definicija grafa

Graf definiramo kot

$$G = (V, E), \quad (2.1)$$

kjer je V množica vozlišč, $E \subseteq V \times V$ pa množica povezav med vozlišči. Vozlišča praviloma vsebujejo značilke $\mathbf{x}_v$, ki jih zapišemo v matriko

$$X \in \mathbb{R}^{|V| \times d}, \quad (2.2)$$

kjer je d število značilk posameznega vozlišča. Povezavo med vozliščema i in j označimo z $e_{ij} \in E$.

2.1.2 Usmerjeni, uteženi in heterogeni grafi

V usmerjenih grafih ima povezava določeno izvorno in ponorno vozlišče, zato velja $e_{ij} \neq e_{ji}$. V neusmerjenih grafih povezave nimajo smeri, zato velja

$$e_{ij} = e_{ji}.$$

Povezave lahko vsebujejo tudi uteži. Utež povezave med vozliščema i in j označimo z w_{ij} . Za neutežene povezave si lahko predstavljamo, da imajo utež $w_{ij} = 1$. Če imajo povezave več uteži, jih zapišemo kot vektor $\mathbf{e}_{ij}$ [5].

Homogeni in heterogeni grafi

Homogeni graf je graf, ki ne loči različnih vrst vozlišč in povezav. Heterogeni graf vsebuje vsaj dve različni vrsti vozlišč ali povezav. V tej nalogi uporabljamo heterogeno grafovsko predstavitev, saj ločimo več tipov povezav.

2.2 Grafovske nevronske mreže

Grafovske nevronske mreže so razred nevronskih mrež, namenjen učenju nad podatki, ki jih naravno predstavimo z grafom [5, 11, 17]. Cilj GNN je naučiti se predstavitev vozlišč, povezav ali celotnega grafa tako, da model pri izračunu predstavitve posameznega vozlišča upošteva tudi njegovo lokalno okolico.

2.2.1 Posredovanje sporočil

Osnovna ideja GNN je *posredovanje sporočil* [5]. Vsako vozlišče v posamezni plasti prejme informacije od svojih sosedov, jih agregira in na podlagi zbranih informacij posodobi svojo predstavitev.

Splošna oblika plasti

Splošno plast posredovanja sporočil lahko zapišemo kot

$$\mathbf{h}_v^{(k)} = \phi^{(k)} \left(\mathbf{h}_v^{(k-1)}, \bigoplus_{u \in \mathcal{N}(v)} \psi^{(k)}(\mathbf{h}_v^{(k-1)}, \mathbf{h}_u^{(k-1)}, \mathbf{e}_{uv}) \right), \quad (2.3)$$

kjer je $\mathcal{N}(v)$ množica sosedov vozlišča v , $\psi^{(k)}$ funkcija sporočila, $\oplus$ agregacijska funkcija, $\phi^{(k)}$ funkcija posodobitve, $\mathbf{h}_v^{(k)}$ pa predstavitev vozlišča v v plasti k .

Posredovanje sporočil v heterogenih grafih

Pri heterogenem grafu, kjer povezave razdelimo po tipih oziroma relacijah $r \in \mathcal{R}$, namesto ene same množice sosedov obravnavamo množice $\mathcal{N}_r(v)$, ki vsebujejo sosede vozlišča v po relaciji r . Sporočila se najprej agregirajo ločeno znotraj posamezne relacije:

$$\mathbf{m}_{v,r}^{(k)} = \bigoplus_{u \in \mathcal{N}_r(v)} \psi_r^{(k)}(\mathbf{h}_u^{(k-1)}, \mathbf{e}_{uv}). \quad (2.4)$$

Pri tem je $\psi_r^{(k)}$ funkcija sporočila za relacijo r , $\mathbf{m}_{v,r}^{(k)}$ pa agregirano sporočilo, ki ga vozlišče v prejme po tej relaciji v plasti k . Relacijska sporočila $\mathbf{m}_{v,r}^{(k)}$ se nato združijo v skupno sporočilo za vozlišče. Združevanje relacij je lahko preprosta vsota ali povprečje, lahko pa vključuje konkatencijo oziroma naučeno fuzijo relacijskih predstavitev.

Agregacijska funkcija

Agregacijska funkcija mora biti praviloma invariantna na vrstni red sosedov, saj graf v splošnem nima naravne ureditve vozlišč. Zato se pogosto uporabljajo operacije, kot so vsota, povprečje ali maksimum. Ta lastnost omogoča, da ista GNN plast deluje na grafih različnih velikosti.

2.2.2 Klasifikacija na ravni grafa

Če želimo napovedati oznako celotnega časovnega okna, lahko nalogo obravnavamo kot klasifikacijo grafa. Po več plasteh grafovske nevronske mreže dobimo končne predstavitve vozlišč $\mathbf{h}_v^{(K)}$, ki jih združimo v predstavitev celotnega grafa:

$$\mathbf{h}_G = \text{READOUT}(\{\mathbf{h}_v^{(K)} : v \in V\}). \quad (2.5)$$

Funkcija READOUT je agregacijska funkcija na ravni grafa. Pogoste izbire so povprečje, vsota, maksimum ali združevanje s pozornostjo. Predstavitev grafa $\mathbf{h}_G$ nato uporabimo v klasifikacijski glavi, ki napove razred celotnega grafa.

2.2.3 Prekomerno glajenje in kolaps predstavitev

Pri grafovskih nevronske mrežah lahko več zaporednih agregacij povzroči, da si predstavitve vozlišč postanejo preveč podobne. Ta pojav imenujemo prekomerno glajenje. V praksi se lahko pokaže kot zmanjšanje variance predstavitev, visoka medsebojna podobnost vozliščnih vektorjev in skoraj konstantni izhodi klasifikacijske glave.

Zato med treniranjem in evalvacijo modelov spremljamo statistike predstavitev na različnih delih modela. Varianca predstavitev kaže, ali model še ohranja razlike med vozlišči in grafi. Kosinusna podobnost pokaže, ali predstavitve postajajo usmerjene v podobno smer. Razpon logitov pa pokaže, ali klasifikacijska glava proizvaja dovolj raznolike napovedi ali se približuje skoraj konstantnemu izhodu.

2.3 Podatki sledilnika pogleda

Sledilnik pogleda je naprava, ki meri, kam v prostoru ali na zaslonu oseba usmerja pogled. Poleg lokacije pogleda lahko meri tudi velikost zenic, ki jo običajno opišemo s premerom zenice. Signal pogleda navadno opišemo s koordinatama x in y na zaslonu. Iz dinamike teh dveh signalov nekateri sledilniki zaznavajo in poročajo tudi informacije o fiksacijah, sakadah in mežikih, ki nas pogosto zanimajo v tej domeni. Meritve se izvajajo zaporedno z določeno vzorčno frekvenco, ki je odvisna od zmogljivosti naprave in namena uporabe. Pogoste vzorčne frekvence raziskovalnih sledilnikov pogleda so 60 Hz, 100 Hz, 500 Hz in 1000 Hz [13, 16].

2.4 Čustvena stanja: valenca in vzburjenost

2.4.1 Dimenzijski opis čustev

Čustvena stanja pogosto opisujemo z dimenzijama valence in vzburjenosti. Valenca opisuje prijetnost oziroma neprijetnost čustvenega odziva, vzburjenost

pa stopnjo aktivacije odziva [14].

2.4.2 Binarna klasifikacija

V uporabljeni podatkovni zbirki MAHNOB-HCI so poleg številskih samoocen valence in vzburjenosti na voljo tudi eksplicitne čustvene oznake posnetkov, kot so žalost, jeza, strah in druge [14]. V tej nalogi se omejimo na binarno klasifikacijo valence, pri čemer razrede določimo po vzoru izvirnega članka podatkovne zbirke MAHNOB-HCI. Podrobna preslikava čustvenih oznak v razrede valence je navedena v dodatku A.1. Vzburjenosti v glavni nalogi ne obravnavamo, ker se izpeljani razredi v uporabljenem podnaboru slabše ujemajo s samoocenami kot pri valenci. Podrobnejša razlaga tega neskladja je podana v dodatku A.3.

Poglavje 3

Sorodna dela

To poglavje umešča nalogo med obstoječe pristope za delo s podatki sledilnika pogleda. Sorodna dela v tem poglavju obravnavamo z vidika vprašanja, kako podatke sledilnika pogleda predstaviti za klasifikacijo čustvenih oznak. Najprej povzamemo uporabo podatkov sledilnika pogleda pri klasifikaciji čustvenih oznak in vlogo podatkovne zbirke MAHNOB-HCI. Nato predstavimo grafovske nevronske mreže za časovne vrste in časovno-prostorske podatke, saj je osrednji del naloge pretvorba časovnega okna meritev v graf. Na koncu povzamemo še učenje predstavitev iz zaporedij pogleda ter položaj te naloge glede na sorodna dela.

3.1 Podatki sledilnika pogleda pri klasifikaciji čustvenih oznak

Podatki sledilnika pogleda se med drugim uporabljajo kot vedenjski in psihofiziološki signal pri nalogah prepoznavе čustvenih stanj. V literaturi se pojavljajo različne ciljne naloge: klasifikacija diskretnih čustvenih stanj, regresija valence in vzburjenosti, binarna klasifikacija valence in vzburjenosti ter druge [13, 16].

Med pogosto uporabljenimi signali so velikost zenic, dinamika pogleda, fiksacije, sakade, mežiki in oddaljenost oči od sledilnika pogleda. Vhod v

klasične napovedne modele za čustvena stanja so pogosto ročno oblikovane statistične značilke, kot so povprečja, variance in ekstremi časovnih oken meritev velikosti zenic, signalov pogleda, fiksacij, sakad in mežikov [4, 13, 16]. Novejši modeli, na primer samokodirniki, pa kot vhod vzamejo tudi časovna okna manj agregiranih signalov pogleda, na primer zaporedja koordinat pogleda, iz katerih lahko izpeljejo tudi dinamiko gibanja pogleda [3].

3.2 Podatkovna zbirka MAHNOB-HCI

Podatkovna zbirka MAHNOB-HCI je večmodalna zbirka za prepoznavanje čustev in implicitno označevanje multimedijskih vsebin [14]. Vsebuje odzive udeležencev na čustvene video posnetke ter sinhrono zajete signale, med katerimi so video obraza, zvok, fiziološki signali, elektroencefalogram (EEG) in signali sledilnika pogleda. V tej nalogi uporabljamo samo signale sledilnika pogleda, ker je osrednji cilj raziskati grafovsko predstavitev tega tipa časovnega signala.

Pregledali in preizkusili smo več podatkovnih zbirk (na primer eSEEd_v2). MAHNOB-HCI se je za našo nalogo izkazal kot najprimernejši predvsem zaradi kakovosti in količine podatkov ter dobre dokumentacije.

Za to nalogo je pomemben predvsem del zbirke z odzivi na čustvene video posnetke, kjer so poleg signalov sledilnika pogleda na voljo tudi samoocene udeležencev in čustvene oznake posnetkov. V izvirnem članku so avtorji te oznake uporabili za definicijo razredov valence in vzburjenosti ter med drugim poročali rezultate 3-razredne klasifikacije. V tej nalogi isto preslikavo uporabimo kot izhodišče za definicijo razredov valence, glavno nalogo pa omejimo na binarno klasifikacijo skrajnih razredov. Podrobna preslikava čustvenih oznak v razrede valence je navedena v dodatku A.1.

3.3 Grafovske nevronske mreže za časovno-prostorske podatke

Grafovske nevronske mreže je smiselno uporabiti, kadar želimo poleg lastnosti elementov modelirati tudi odnose med njimi. Pri časovnih vrstah so takšni odnosi vsaj časovni – neka meritev je časovno pred drugo meritvijo ali za njo. Pregled GNN za časovne vrste [10] to področje obravnava skozi naloge napovedovanja, klasifikacije, imputacije in zaznavanja anomalij ter posebej poudari modeliranje časovnih odvisnosti ter odvisnosti med različnimi spremenljivkami. Za to nalogo je pomembna predvsem formulacija, pri kateri posamezno časovno okno pretvorimo v grafovsko predstavitev in oznako napovemo na ravni celotnega grafa.

Pri podatkih sledilnika pogleda imajo meritve poleg časovnega vrstnega reda tudi prostorsko komponento, saj je vsaka veljavna meritev vezana na položaj pogleda na zaslonu. Podobno ločevanje časovnih in prostorskih odvisnosti uporabljajo časovno-prostorske grafovske mreže, na primer ST-GCN pri napovedovanju prometa, kjer grafovska konvolucija modelira prostorske povezave med senzorji, časovna konvolucija pa dinamiko signala skozi čas [20]. V tej nalogi je ta pristop uporaben kot metodološka analogija: ne napovedujemo prihodnjih meritev, temveč klasificiramo oznako časovnega okna meritev.

3.4 Učenje predstavitev iz signalov

Poleg ročno oblikovanih značilk obstajajo pristopi, ki se predstavitev naučijo neposredno iz zaporedij meritev. S tem zmanjšajo odvisnost od ročne izbire značilk, hkrati pa so njihove predstavitve vezane na podatke in naloge, uporabljene pri predtreniranju. V nalogi takšni modeli služijo kot most med klasičnimi modeli na ročno agregiranih značilkah in grafovskimi modeli, ki se predstavitev učijo na eksplicitno strukturiranih časovnih oknih.

GazeMAE je primer modela, zasnovanega posebej za očesne gibe – kot vhod uporablja zaporedje koordinat pogleda, iz katerega z avtokodirniško

arhitekturo uči mikro- in makro-predstavitve [3]. MOMENT je splošnejši prednaučen temeljni model za časovne vrste, zato je uporaben kot primerjava pri signalih, ki niso omejeni na koordinate pogleda [7].

3.5 Položaj te naloge glede na sorodna dela

Ta naloga ne obravnava psihološkega modeliranja čustev. Čustvene oznake uporablja zgolj kot evalvacijsko nalogo za primerjavo predstavitev podatkov sledilnika pogleda. Glavna primerjava je med različnimi predstavitvami istega časovnega okna: agregiranimi značilkami za klasične modele, naučenimi predstavitvami iz prednaučenih kodirnikov in časovno-prostorsko grafovsko predstavitevijo za GNN.

Grafovski del naloge preverja, ali eksplicitne časovne, prostorske in fiksacijske relacije med meritvami pogleda prispevajo k uporabnejši predstavitvi okna. Naloga zato povezuje (1) klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda, (2) GNN za časovno-prostorske podatke ter (3) primerjavo ročno oblikovanih, naučenih in grafovskih predstavitev časovnih oken.

Poglavje 4

Podatki in predobdelava

4.1 Podatkovna zbirka MAHNOB-HCI

4.1.1 Izvirna zbirka

V delu uporabljamo podatke iz podatkovne zbirke MAHNOB-HCI [14]. Gre za večmodalno zbirko, namenjeno raziskavam prepoznavanja čustev in implicitnega označevanja multimedijskih vsebin. Zbirka vsebuje dva glavna eksperimentalna sklopa: prepoznavanje čustvenih stanj iz odzivov na čustvene videoposnetke in implicitno označevanje na podlagi odzivov na pravilne oziroma napačne oznake pod sliko ali posnetkom. V tej nalogi uporabljamo samo prvi sklop, to je eksperiment vzbujanja čustev z videoposnetki.

Izvirni članek poroča o 30 rekrutiranih udeležencih, od katerih je bilo v analizi uporabljenih 27. Udeleženci P9, P12 in P15 so bili izključeni zaradi tehničnih težav oziroma nepopolnega zajema podatkov. V tej nalogi po vzoru izvirnega članka izključimo iste tri udeležence. V eksperimentu vzbujanja čustev so udeleženci gledali 20 čustveno vzbujajočih videoposnetkov. Pred vsakim čustvenim posnetkom je bil prikazan še kratek nevtralni posnetek, odzivi nanj pa je bil shranjen ločeno. Po ogledu posameznega posnetka so udeleženci podali samoocene čustvene oznake, vzburjenosti, valence, dominantnosti in predvidljivosti.

Čeprav je MAHNOB-HCI večmodalna zbirka, v tej nalogi uporabljamo izključno signale sledilnika pogleda. Uporabljeni signali so podrobneje opisani v razdelku 4.4. Meritve so bile zajete s sledilnikom Tobii X120 pri frekvenci 60 Hz.

4.2 Predhodni poskus z zbirko eSEEd_v2

Pred prehodom na MAHNOB-HCI je bil del razvoja izveden na podatkovni zbirki eSEEd_v2. Ta del ni osrednji eksperimentalni prispevek naloge, temveč služi kot zgodovinska motivacija za spremembo podatkovne zbirke. Začetni poskusi so pokazali težave z zanesljivostjo oznak, kakovostjo signalov in stabilnostjo učenja. Zato smo glavno eksperimentalno evalvacijo izvedli na podatkovni zbirki MAHNOB-HCI, ki ima za naš primer uporabnejšo množico signalov sledilnika pogleda.


4.3 Ciljne oznake

4.3.1 Izvor čustvenih oznak

Oznake v tej nalogi izhajajo iz udeležencevih samoocen čustvenega razreda po ogledu videoposnetka. Diskretne čustvene razrede preslikamo v razrede valence po preslikavi iz izvirnega članka [14], ki je prikazana v dodatku A.1. S tem najprej dobimo tri razrede: neprijetno, nevtrarno in prijetno valenco. Nevtralni razred odstranimo, da ciljna naloga vsebuje izrazitejši kontrast med razredoma in s tem modelom omogočimo boljše pogoje za učenje vzorcev v podatkih.

Oznaka valence je določena na ravni kombinacije udeleženca in videoposnetka. Vsa časovna okna in s tem vsi grafi istega ogleda videoposnetka zato prejmejo isto oznako.

Vzburljenosti v tej nalogi ne klasificiramo. Razlog je predvsem večja šumnost oznak v uporabljeni podatkovni zbirki. Kot kaže matrika zmede v



Slika 4.1: Delovna porazdelitev končnih 10-sekundnih oken po razredih binarne valence.

datku A.3, se samoocene stopnje vzburjenosti slabše ujemajo z definiranimi razredi kot samoocene valence.

[Slika je delovna verzija iz runa RETAIN_2026-06-12_16-29-08. Pred oddajo preveri, ali je generirana iz končnega protokola, in jo po potrebi regeneriraj v paleti B.]

4.4 Priprava vhodnih signalov

4.4.1 Skupine signalov

Splošen opis meritev sledilnika pogleda je podan v razdelku 2.3; tukaj na-vedemo konkretne skupine signalov, ki jih uporabimo v eksperimentih. V uporabljeni podatkovni zbirki imamo na voljo pet osnovnih vrst signalov. To so:

- časovni žig meritve t_i ,
- koordinati pogleda na zaslonu (x_i, y_i) – povprečje med meritvama levega in desnega očesa,
- velikost leve in desne zenice $(p_i^{(l)}, p_i^{(r)})$,
- oddaljenost oči od sledilnika pogleda d_i ter
- informacija o fiksacijah, tj. pripadnost fiksaciji ter trajanje fiksacije.

Tabela 4.1: Množice signalov, uporabljene v eksperimentalni primerjavi.

Množica	Vključeni signali
<i>samo pogled</i>	koordinati pogleda (x_i, y_i)
<i>samo zenici</i>	velikosti leve in desne zenice $(p_i^{(l)}, p_i^{(r)})$
<i>pogled in zenici</i>	koordinati pogleda ter velikosti leve in desne zenice
<i>vsi signali</i>	koordinati pogleda, velikosti zenic, oddaljenost od sledilnika pogleda in informacija o fiksacijah

Večina podatkovnih zbirk s podatki sledilnika pogleda vsebuje bodisi le koordinate pogleda bodisi le velikost zenic bodisi oboje. Nekatere zbirke pa ponujajo tudi dodatne signale, kot sta v našem primeru oddaljenost ter informacije o fiksacijah. Da bi s primerjalno študijo pokrili čim širši razpon različnih tipov zbirk, MAHNOB-HCI podatke razdelimo v štiri delno prekrivajoče se eksperimentalne množice signalov, prikazane v tabeli 4.1. V vseh štirih množicah uporabimo tudi informacijo o času, zato v tabeli navedemo le preostale vključene signale.

[Z zunanjo pomočjo mentorja ali slovenista najdi/potrdi izraze in jih potem uporablja konsistentno v diplomu. Posebej preveri, ali naj bodo končna imena množic samo pogled, samo zenici, pogled in zenici in vsi signali, ter nato ta imena uporabi enako v besedilu, tabelah in slikah.]

4.4.2 Čiščenje podatkov

Podatke pred uporabo očistimo. Najprej iz lokalne kopije zbirke MAHNOB-HCI odstranimo podatke, ki jih v tej nalogi ne uporabljamo, in ohranimo le podatke eksperimenta vzbujaanja čustev. Nato odstranimo vrstice brez signalov pogleda ali velikosti zenic. Na voljo imamo tudi signale veljavnosti, na podlagi katerih odstranimo meritve, za katere je sledilnik poročal, da je meritev za vsaj eno oko neveljavna. Dodatno uporabimo filter osamelcev q01-q99, s katerim odstranimo izrazite ekstreme, ki izkrivljajo porazdelitve signalov. Na koncu kratke vrzeli v numeričnih signalih interpoliramo, signala velikosti leve

in desne zenice pa dodatno zgladimo s kratkim drsečim povprečjem.

4.5 Normalizacija

Posamezne skupine signalov so izražene v različnih velikostnih redih. Modeli strojnega učenja, kot so SVM, MLP ter GNN, so občutljivi na merilo značilk. Zato signale standardiziramo. Povprečje in standardni odklon izračunamo na učni podmnožici, nato pa na validacijski in testni podmnožici standardizacijo uporabimo z istimi parametri kot na učni.

4.6 Segmentacija v časovna okna

Časovno vrsto razdelimo na neprekrivajoča se časovna okna dolžine $T = 10$ s. Vsako uporabno časovno okno predstavlja en učni primer. Za 10 s smo se odločili na podlagi sorodnega dela na podatkih sledilnika pogleda, kjer so se daljša okna med dolžinami 1, 3, 5 in 10 s praviloma izkazala za bolj informativna [4]. Daljših oken ne uporabimo, ker bi težje predpostavili, da celotno okno opisuje enoten čustveni odziv, saj se lahko ta med ogledom posnetka že opazno spremeni [21]. Tudi sorodna dela na prepoznavanju čustev iz očesnih signalov pogosto uporabljajo krajša okna, na primer 1-2 s [18, 19].

Oznaka okna je določena s parom udeleženec-posnetek, zato so vsa okna istega ogleda videoposnetka označena z isto čustveno oznako. Uporabnost okna določimo glede na kakovost podatkov v oknu.

Pri vzorčni frekvenci 60 Hz bi 10-sekundno okno brez manjkajočih vrednosti vsebovalo 600 vzorcev. Zaradi čiščenja, odstranjevanja neveljavnih vzorcev in filtriranja je dejansko število vzorcev v oknih manjše. Povprečno število meritev v oknu po čiščenju znaša

TODO: vstavi številko

Po tvorbi časovnih oken se cevovod razdeli glede na uporabljeno predstavitev. Klasični negrafovski modeli iz okna dobijo agregirane tabelarične

značilke, prednaučeni kodirniki neposredno prejmejo časovne vrste izbranih signalov sledilnika pogleda, grafovski modeli pa grafovsko predstavitev okna. Podrobnosti teh predstavitev so opisane v poglavjih 5 in 6. V tem poglavju opišemo le skupne korake priprave podatkov.

4.7 Povzetek predobdelave

Tabela 4.2 povzema, kako se skozi opisane korake predobdelave zmanjša količina podatkov, uporabljena v končni eksperimentalni primerjavi.

Tabela 4.2: Zmanjševanje količine podatkov od izvirne zbirke MAHNOB-HCI do končnih časovnih oken, uporabljenih v eksperimentalnem cevovodu.

Korak	Vrstice	Udeleženci	Opis
Izvirna zbirka MAHNOB-HCI	–	30	Večmodalna zbirka; izvirni članek v analizi uporabi 27 udeležencev.
Lokalna podmnožica podatkov sledilnika pogleda	3 797 165	24	Lokalna kopija eksperimenta vzbujanja čustev s podatki sledilnika pogleda in oznakami.
Po izključitvi šlabih "udeležencev"	3 535 842	22	Izključeni P9, P12 in P15.
Veljavno označene vrstice	2 995 632	22	Ohranjeni so samo označeni podatki, uporabljeni za učenje modelov čustvenih stanj.
Pripravljeno za učenje	2 814 005	22	Odstranjene so vrstice brez ključnih signalov pogleda ali zenic.
Po filtru osamelcev q01-q99	2 639 048	22	Robustno filtriranje štirih osnovnih signalov pogleda in zenic.
Uporabna 10-sekundna časovna okna	5 158	22	Vsako okno postane en učni primer oziroma graf.

Poglavje 5

Grafovska predstavitev podatkov sledilnika pogleda

V prejšnjem poglavju smo meritve sledilnika pogleda razdelili na 10-sekundna časovna okna. V tem poglavju opišemo, kako posamezno okno pretvorimo v graf, ki ga uporabimo kot vhod za grafovske modele. Vozlišča predstavljajo veljavne meritve znotraj okna, povezave pa izbrane odnose med meritvami.

Najprej podamo najbogatejšo grafovsko predstavitev učnega vzorca, ki uporablja vse razpoložljive signale. Nato pokažemo, kako se ista osnovna konstrukcija prilagodi štirim množicam signalov iz poglavja 4.4. Kadar določena množica signalov ne vsebuje informacije, potrebne za posamezno značilko ali relacijo, ta del predstavitve izpustimo. Graf zato v vseh primerih predstavlja isto vrsto učnega vzorca, razlikuje pa se po količini vhodne informacije in po razpoložljivih relacijah med meritvami.

5.1 Vozlišča

5.1.1 Definicija

Vsako vozlišče predstavlja eno meritev sledilnika pogleda znotraj časovnega okna:

$$v_i \leftrightarrow \mathbf{x}_i. \quad (5.1)$$

Če okno vsebuje n veljavnih meritev, potem graf vsebuje n vozlišč. Vrednost n se lahko med okni razlikuje, saj po čiščenju in filtriranju niso vsa okna popolna. Grafovska predstavitev naravno podpira spremenljivo število vozlišč.

5.1.2 Vektor značilk vozlišča

Vektor značilk vozlišča za končni graf za množico *vsi signali* je

$$\mathbf{x}_i = \left[t_i, x_i, y_i, p_i^{(l)}, p_i^{(r)}, d_i, f_{dur,i} \right], \quad (5.2)$$

kjer je t_i normaliziran časovni žig za vozlišče i , x_i in y_i sta koordinati pogleda, $p_i^{(l)}$ in $p_i^{(r)}$ velikosti leve in desne zenice, d_i je razdalja med sledilnikom in udeležencevimi očmi, $f_{dur,i}$ pa trajanje fiksacije.

Za ostale podgrafe se vektor značilk ustrezno filtrira. V vseh primerih ohranimo časovno značilko t_i , ostale podatke pa ohranimo glede na obravnavano množico signalov.

5.2 Relacije

Definiramo tri relacije med meritvami: časovno, prostorsko in fiksacijsko. Posledično v grafu oblikujemo štiri tipe povezav. Pri tem sta časovna tipa povezav usmerjena – časovne povezave naprej in nazaj. Prostorske in fiksacijske povezave pa obravnavamo kot neusmerjene.

5.2.1 Zakaj ločimo relacije

Vsaka povezava ima določen tip relacije, saj časovna povezava, prostorska povezava in fiksacijska povezava opisujejo različne odnose med meritvami. Ta zapis omogoča, da kasnejše stopnje arhitekturne lestvice relacije obravnavajo ločeno. Osnovni GCN uporabi isti nabor povezav, vendar relacij modelno ne loči; v tem primeru dobimo enostaven homogen graf. Podrobnosti o uporabi relacij v posameznih modelih so opisane v poglavju 6.

5.2.2 Časovne povezave

Časovne povezave povezujejo meritve zaporedne v času. Naj bodo vozlišča v posameznem oknu urejena po času, tako da je v_i i -ta meritev v časovnem zaporedju.

Ločimo usmerjene časovne povezave naprej in nazaj:

$$E_t^+ = \{(v_i, v_j) : 1 \leq j - i \leq k_t\}, \quad (5.3)$$

$$E_t^- = \{(v_i, v_j) : 1 \leq i - j \leq k_t\}. \quad (5.4)$$

Parameter $k_t \in \mathbb{N}$ določa število časovnih sosedov na vsako stran. Trenutna konfiguracija uporablja $k_t = 1$, zato je vozlišče v_i povezano samo z neposredno predhodno in neposredno naslednjo meritvijo, kadar ti vozlišči obstajata.

Povezave v E_t^+ potekajo od prejšnjih proti kasnejšim meritvam, povezave v E_t^- pa od kasnejših proti prejšnjim meritvam. Pri grafu z n vozlišči to pri $k_t = 1$ pomeni $n - 1$ časovnih povezav naprej in $n - 1$ časovnih povezav nazaj. Za polno 10-sekundno okno s pričakovanimi 600 meritvami je to 599 povezav v vsako smer.

5.2.3 Prostorske povezave

Prostorske povezave so neusmerjene povezave, ki povezujejo meritve s podobnim položajem pogleda znotraj istega časovnega okna. Te povezave lahko definiramo samo za grafe, ki imajo prostorsko informacijo, torej signala (x, y) . Za vsako vozlišče poiščemo k_s najbližjih sosedov v prostoru koordinat pogleda (x, y) .

Prostorsko razdaljo med meritvama i in j definiramo evklidsko:

$$d_{ij}^{(s)} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}. \quad (5.5)$$

Za vsako vozlišče v_i poiščemo k_s najbližjih sosedov v prostoru koordinat pogleda (x, y) z uporabo k-d drevesa. Če je v_j med temi sosedmi, dodamo povezavo med vozliščema v_i in v_j . Ker prostorske povezave obravnavamo kot neusmerjene, povezavo predstavimo z dvema usmerjenima povezavama (v_i, v_j) in (v_j, v_i) . Na koncu odstranimo podvojene povezave znotraj relacije E_s .

Število prostorskih povezav zato ni določeno samo z n in k_s , ampak tudi z geometrijo položajev pogleda. Pred simetrizacijo vsako vozlišče prispeva k_s sosedskih izbir, po simetrizaciji in odstranitvi podvojenih parov pa za usmerjeni zapis neusmerjene relacije velja

$$nk_s \leq |E_s| \leq 2nk_s. \quad (5.6)$$

Dejansko gostoto prostorskih povezav zato poročamo z opazovanimi statistikami grafov.

5.2.4 Fiksacijske povezave

Fiksacijske povezave povezujejo meritve, ki pripadajo isti zaznani fiksaciji. Pripadnost fiksaciji določimo z identifikatorjem fiksacije, podanim v MAHNOB-HCI podatkih. Ta podatek imamo zgolj v množici *vsí signali*, zato so te povezave vključene le v končni graf.

Redčenje povezav znotraj fiksacije

Znotraj posamezne fiksacije ne povežemo vseh vozlišč med seboj, saj bi to povzročilo preveliko število fiksacijskih povezav. Namesto tega uporabimo redkejšo konstrukcijo, ki ohrani informacijo o pripadnosti isti fiksaciji, hkrati pa zmanjša prostorsko in časovno zahtevnost konstrukcije grafa ter učenja na grafu. To konstrukcijo sami imenujemo *razširjene povezave znotraj fiksacije* (angl. *dilated intra-fixation edges*). Fiksacijo obravnavamo kot neprekinjeno zaporedje vozlišč z istim veljavnim identifikatorjem **fixation-index**. Če ima taka fiksacija F vozlišč, jim znotraj fiksacije priredimo lokalne indekse $0, \dots, F - 1$.

Gostoto povezav uravnava parameter k_f , ki določa število fiksacijskih povezav, ki jih generira vsako vozlišče. V trenutni konfiguraciji uporabljamo $k_f = 3$. Za posamezno fiksacijo najprej izračunamo korak razširitve

$$s = \max(1, \lfloor F/k_f + 0,5 \rfloor). \quad (5.7)$$

Množico kandidatnih odmikov nato definiramo kot

$$D = \{(1 + qs) \bmod F \mid q = 0, \dots, k_f - 1\}. \quad (5.8)$$

Morebitni odmik 0 in podvojene odmiške odstranimo. Za vsak odmik $d \in D$ dodamo neusmerjene povezave

$$\{v_i, v_{(i+d) \bmod F}\}, \quad i = 0, \dots, F - 1. \quad (5.9)$$

Pri zapisu grafa za posredovanje sporočil vsako neusmerjeno povezavo predstavimo z dvema usmerjenima povezavama. Podvojene povezave znotraj relacije E_f odstranimo.

Na primer, pri fiksaciji dolžine $F = 30$ in parametru $k_f = 3$ dobimo $s = 10$. Vozlišče z lokalnim indeksom 0 torej povežemo z vozlišči 1, 11 in 21. Odmik 1 ohrani časovno lokalno komunikacijo znotraj fiksacije, večji odmiški pa omogočijo širjenje informacij tudi med časovno bolj oddaljenimi meritvami iste fiksacije.

Razširjene povezave imajo večji doseg kot zgolj zaporedne fiksacijske povezave, hkrati pa se izognejo kombinatorični eksploziji, ki bi nastala pri polnem kliku. Pri polnem kliku bi namreč število povezav naraščalo kvadratno z dolžino fiksacije. Pri analiziranih 10-sekundnih oknih dobimo približno 1.956 fiksacijskih povezav na graf pri $k_f = 2$, 2.908 pri $k_f = 3$, 4.163 pri $k_f = 5$ in 7.273 pri $k_f = 10$. Pri privzeti izbiri $k_f = 3$ so fiksacijske povezave predstavljale približno 45,7 % vseh povezav v grafu (relacije **temporal**, **spatial** in **fixation**).

Izbira $k_f = 3$ je zato kompromis med dosegom in gostoto grafa. Ker vsaka plast GNN omogoča izmenjavo informacij med neposredno povezanimi vozlišči, se doseg znotraj fiksacije povečuje tudi z večanjem števila plasti. Pri $k_f = 3$ vozlišče že v eni plasti prejme informacije iz več delov iste fiksacije, večplastni model pa lahko te informacije dodatno propagira po fiksacijski relaciji. Večje vrednosti k_f povečajo gostoto grafa, računsko zahtevnost in možnosti za prekomerno glajenje, manjše vrednosti pa graf dodatno razredčijo.

5.2.5 Značilke povezav

Povezavam poleg tipa relacije priredimo tudi značilke povezav, ki opisujejo odnos med izvirno meritvijo v_i in ciljno meritvijo v_j . Osnovne časovne značilke so normalizirani čas izvirne in ciljne meritve, t_i in t_j , ter časovna razlika $\Delta t = t_j - t_i$. Pri časovnih povezavah dodamo še smer ρ_{ij} , kjer ima povezava naprej vrednost $\rho_{ij} = 1$, povezava nazaj pa $\rho_{ij} = -1$. Značilke povezav so del najbogatejše grafovske predstavitve; eksplicitno jih uporabi utežena stopnja arhitekturne lestvice, opisana v poglavju 6.

Pri grafih, ki vsebujejo koordinate pogleda, povezavam dodamo tudi prostorske značilke. To sta razliki v koordinatah pogleda, $\Delta x = x_j - x_i$ in $\Delta y = y_j - y_i$, ter evklidska razdalja med položajema pogleda na zaslonu d_{ij}^{zaslon} . Te značilke so zato na voljo pri vseh množicah signalov, razen pri množici *samo zenici*.

Pri množici *vsi signali* povezavam dodamo še značilko, povezano z oddaljenostjo od sledilnika pogleda. Značilka $\Delta d_{ij}^{\text{oči}}$ opisuje razliko v oddaljenosti med ciljno in izvirno meritvijo.

Pregled vseh značilk povezav in njihove uporabe je podan v tabeli 5.1.

Tabela 5.1: Značilke povezav v grafovski predstavitvi.

Značilka	Opis	Uporaba
t_i	Normaliziran čas izvirne meritve znotraj časovnega okna.	Vse povezave.
t_j	Normaliziran čas ciljne meritve znotraj časovnega okna.	Vse povezave.
Δt	Časovna razlika med ciljno in izvirno meritvijo, $\Delta t = t_j - t_i$.	Vse povezave.
ρ_{ij}	Smer časovne povezave; pri povezavi naprej je $\rho_{ij} = 1$, pri povezavi nazaj pa $\rho_{ij} = -1$.	Samo časovne povezave.
Δx	Razlika v vodoravni koordinati pogleda, $\Delta x = x_j - x_i$.	Grafi s koordinatami pogleda.
Δy	Razlika v navpični koordinati pogleda, $\Delta y = y_j - y_i$.	Grafi s koordinatami pogleda.
d_{ij}^{zaslon}	Evklidska razdalja med položajema pogleda na zaslonu.	Grafi s koordinatami pogleda.
$\Delta d_{ij}^{\text{oči}}$	Razlika v oddaljenosti od sledilnika pogleda med ciljno in izvirno meritvijo.	Samo <i>vsí signali</i> .


5.3 Grafovska konstrukcija po množicah signalov

Za vsako množico signalov iz tabele 4.1 zgradimo graf po isti osnovni konstrukciji. Razlika med grafi je v značilkah vozlišč in relacijah, ki jih izbrana množica signalov omogoča. Množica *vsí signali* je najbogatejša predstavitev. Ostale množice uporabijo ustrezne podmnožice značilk in povezav.

Tabela 5.2: Grafovska konstrukcija po množicah signalov.

Množica signalov	Značilke vozlišč	Tipi povezav
<i>samo pogled</i>	čas in koordinati pogleda	časovne naprej, časovne nazaj, prostorske
<i>samo zenici</i>	čas in velikosti obeh zenic	časovne naprej, časovne nazaj
<i>pogled in zenici</i>	čas, koordinati pogleda in velikosti obeh zenic	časovne naprej, časovne nazaj, prostorske
<i>vsí signali</i>	čas, koordinati pogleda, velikosti obeh zenic, oddaljenost od sledilnika pogleda in fiksacijska informacija	časovne naprej, časovne nazaj, prostorske, fiksacijske

Slika 5.1 prikazuje primer najbogatejše konstrukcije na majhnem izseku časovnega okna za množico *vsí signali*. Prikaz združi vozlišča, časovne, prostorske in fiksacijske povezave v isti graf.



Slika 5.1: Primer grafovske konstrukcije za množico *vsi signali*. Vozlišča predstavljajo meritve v izseku časovnega okna, povezave pa prikazujejo časovne, prostorske in fiksacijske relacije.

Ločeni prikazi posameznih relacij so zbrani v dodatku C.

5.4 Statistika konstruiranih grafov

Tabela 5.3 prikazuje osnovne statistike grafov, ki nastanejo pri končni konfiguraciji konstrukcije. Vrednosti so izračunane za osrednjo eksperimentalno nalogo, tj. binarno klasifikacijo nizke in visoke valence. Ker se posamezne množice signalov filtrirajo glede na razpoložljivost uporabljenih signalov, število konstruiranih grafov med stolpci ni povsem enako.

Tabela 5.3: Osnovne statistike konstruiranih grafov pri $k_t = 1$, $k_s = 1$ in $k_f = 3$.

Statistika	<i>samo pogled</i>	<i>samo zenici</i>	<i>pogled in zenici</i>	<i>vsí signali</i>
Število grafov	5.097	5.065	5.055	5.034
Mediana števila vozlišč	591	601	585	561
Mediana časovnih povezav naprej	590	600	584	560
Mediana časovnih povezav nazaj	590	600	584	560
Mediana prostorskih povezav	860	0	855	825
Mediana fiksacijskih povezav	0	0	0	3.210
Mediana skupnega števila povezav	2.047	1.200	2.029	5.153

Ničelne vrednosti pri prostorskih in fiksacijskih povezavah pomenijo, da ta relacija pri posamezni množici signalov ni del konstrukcije. Največjo razliko v gostoti grafa povzroči fiksacijska relacija pri množici *vsí signali*, kjer fiksacijske povezave doprinesejo 62,4 % vseh povezav.

Poglavje 6

Primerjani modeli in predlagana arhitektura

V tem poglavju predstavimo klasifikacijske modele strojnega učenja, ki jih primerjamo v eksperimentalni evalvaciji. Modele razdelimo na negrafovske osnovne modele, model GazeMAE + MLP kot predstavnika SOTA ter grafovske modele. *[...grafovske modele - množina?]*

Vsi modeli uporabljajo iste izvirne podatke, ista 10-sekundna okna in iste delitve na učne, validacijske (v primerih nevronske mreže) in testne množice. Razlika je v predstavitvi vhodnih podatkov. Grafovski modeli prejmejo okno kot graf meritev, negrafovski osnovni modeli prejmejo agregirano tabelarično predstavitev istega okna, GazeMAE pa po svoji konstrukciji le koordinati pogleda (x , y) za celotno 10 s okno.

TODO:

- To poglavje naj bo edino mesto za opis arhitektur modelov.
- Ne ponavljaj splošnih definicij grafov in GNN iz poglavja 2.
- Ne ponavljaj pravil konstrukcije časovnih, prostorskih in fiksacijskih povezav iz poglavja 5; uporabi sklic na konkretno grafovsko predstavitev.
- Tu pa obdrži opis, kako posamezen model uporablja že definirano predstavitev: homogenizacija pri osnovnem GCN, relacijska obravnavna pri heterogenem GNN, naučene uteži povezav, fuzija relacij in konkretni READOUT.

TODO:

- Poglavje preurediti tako, da modeli niso opisani samo za en polni vhodni nabor, ampak za primerjavo po množicah *samo pogled*, *pogled in zenici* in *vsi signali*.
- Jasno zapisati, da GazeMAE učimo oziroma uporabimo samo na vходу *samo pogled*, ker uporablja koordinate pogleda; če dosega močne rezultate, ga lahko v rezultatih primerjamo kot referenco tudi proti modelom, ki uporabljajo bogatejše nabore signalov.
- Dodati opomnik za morebitni MOMENT + MLP nad zeničnim signalom ter za kombinacijo MOMENT in GazeMAE predstavitev v skupni MLP pri *pogled in zenici* oziroma *vsi signali*.
- Pri GNN zaenkrat ne dodajati različice *samo zenici*, dokler ni jasen smiseln grafovski protokol.

Za pravično primerjavo osnovnim modelom podamo agregirane značilke istih signalov kot jih prejme GNN. To so: koordinati pogleda (x , y), velikosti leve in desne zenice, oddaljenost od zaslona ter informacija o fiksacijah. Za vsak signal izračunamo opisne statistike na ravni okna: povprečje, standardni

odklon, minimum, maksimum, razpon, mediano, prvi kvartil, tretji kvartil in medkvartilni razmik. Pri fiksacijah dodamo še število fiksacij, delež meritev v oknu, ki pripadajo fiksacijam, vsoto trajanj, povprečno trajanje in največje trajanje fiksacije. Takšna pretvorba časovnega signala v opisne statistike na ravni okna oziroma odziva je običajen pristop pri klasičnih modelih strojnega učenja za podatke pogleda [4, 13, 16].

6.1 Negrafovski osnovni modeli

Prvo skupino primerjalnih modelov sestavljajo negrafovski osnovni modeli. Z izrazom osnovni model označujemo preprostejši primerjalni model, s katerim preverimo, ali zahtevnejša arhitektura prinaša dodatno korist. V to skupino vključimo večinski klasifikator, naključni klasifikator, klasifikator podpornih vektorjev (SVM), Light Gradient Boosting Machine (LightGBM) in večplastni perceptron (MLP).

Večinski in naključni klasifikator predstavljata spodnjo primerjalno mejo. Večinski klasifikator vedno napove večinski razred testne množice, naključni klasifikator pa vse razrede napove z enako verjetnostjo (33,3 % oz 50 %). Če model ne preseže rezultatov teh dveh klasifikatorjev, težko trdimo, da se iz vhodnih podatkov uči uporabne vzorce.

SVM vključimo kot predstavnika jedrnih metod oziroma metod podpornih vektorjev, LightGBM kot učinkovitega predstavnika ansambelskih drevesnih metod z gradientnim spodbujevanjem, MLP pa kot osnovni nevronske model brez grafovske strukture. Hiperparametrov osnovnih modelov nismo optimizirali.

Pri modelih SVM in MLP vhodne značilke standardiziramo s pretvorbo, naučeno samo na učni podmnožici. Ista pretvorba se nato uporabi na testni in, v primeru MLP, tudi validacijski množici. LightGBM standardizacije ne potrebuje, zato prejme neposredno tabelarično predstavitev okna.

6.1.1 MLP

Osnovni MLP uporabimo kot nevronske model nad agregirano tabelarično predstavitev okna. Vhod modela je vektor agregiranih značilke enega 10-sekundnega okna, izhod pa logiti za tri razrede valence oziroma vznemirjenosti. Arhitektura je namerno preprosta: dve skriti polno povezani plasti velikosti 64 z aktivacijo ReLU in izpuščanjem, za njima pa izhodna linearna plast. Model učimo z navzkrižno entropijo. Za optimizacijo uporabimo AdamW, validacijsko podmnožico pa uporabimo za zgodnje ustavljanje na podlagi validacijske izgube.

6.2 Negrafovski predstavnik SOTA: GazeMAE + MLP

Za primerjavo s sodobnim temeljnim modelom smo uporabili odprtokodni prednaučeni kodirnik GazeMAE [3]. Uporabili smo ga po principu zamrzne hrbtenice. To pomeni, da parametrov kodirnika med učenjem nismo spreminjali, ampak smo z njim iz podatkov pogleda izračunali vektorske predstavitve, na katerih smo nato učili MLP. V tem delu MLP zato ne nastopa kot samostojen klasifikator nad ročno agregiranimi značilkami, temveč kot klasifikacijska glava nad značilkami, ki jih izračuna GazeMAE. Ker je bil GazeMAE učen na 2 s oknih, vzorčenih s frekvenco 500 Hz, smo tudi uporabljena 10 s okna najprej pretvorili v obliko, ki jo model pričakuje. Signala koordinat pogleda (x, y) smo razdelili na pet neprekrivajočih se 2 s kosov in ju prevzorčili na ciljno frekvenco 500 Hz. Iz teh kosov smo s kodirnikom pridobili predstavitev celotnega okna s 512 razsežnostmi, ta predstavitev pa je bila vhod v klasifikacijsko glavo MLP. Procesna veriga torej izgleda sledeče:

koordinate $(x, y) \rightarrow$ predprocesiranje $\rightarrow$ *GazeMAE* $\rightarrow$ predstavitev $\rightarrow$ *MLP* $\rightarrow$ napoved.

(6.1)

TODO: naredi lep diagram/grafiko/nekaj boljšega kot je trenutni zapis procesne verige.

6.3 Osnovni GCN

TODO:

- Ta razdelek naj ne redefinira grafa; sklicuj se na poglavje 5.
- Natančno povej samo arhitekturno razliko: osnovni GCN združi vse relacije v homogen graf, ne uporablja značilke povezav in ne uporablja naučenih uteži povezav.
- READOUT opiši samo kot konkretno izbiro modela, ne kot ponovno splošno definicijo klasifikacije grafov; splošna definicija je v poglavju 2.2.2.

Grafovski modeli se od negrafovskih modelov razlikujejo že v predstavitvi podatkov, saj okno meritev obravnavajo kot graf in ne kot tabelarični vektor značilke. Predlagani model, predstavljen v naslednjem odseku, tej predstavitvi doda še ločeno obravnavo tipov povezav, fuzijo relacijskih predstavitev in naučene uteži povezav. Zato za primerjavo s predlaganim modelom poleg negrafovskih modelov uporabimo še osnovni GCN, s katerim ločimo vpliv same grafovske predstavitve od vpliva bolj dodelane heterogene grafovske arhitekture.

Osnovni GCN je homogeni GCN. Osnovni GCN uporablja isto grafovsko predstavitev okna, kot je bila opisana v poglavju 5: vozlišča vsebujejo iste značilke, uporabljeni so isti izvorni signali in ista časovna okna. Od predlaganega GNN, ki ga opišemo v naslednjem odseku, se razlikuje po tem, da ne ločuje časovnih, prostorskih in fiksacijskih relacij. Vse povezave združi v en homogen graf, posredovanje sporočil pa izvede z običajnimi plastmi `GCNConv`. Model prav tako ne uporablja uteži povezav.

Tehnično lahko osnovni GCN zapišemo kot:

$$X \rightarrow f_{GCN} \rightarrow \text{READOUT} \rightarrow f_{\text{head}}, \quad (6.2)$$

kjer je X matrika značilke vozlišč, f_{GCN} zaporedje grafovskih konvolucijskih plasti, korak READOUT združi predstavitev vozlišč v predstavitev celotnega grafa, f_{head} pa iz te predstavitve izračuna napoved razreda. Ta model zato

predstavlja vmesno primerjavo med učenjem nad agregiranimi tabelaričnimi značilkami in predlaganim heterogenim grafovskim modelom.

[Ko bo osnovni GCN dokončno definiran, koda napisana, rezultati pridobljeni, tehnično še bolj specifikiraj točno arhitekturo. Npr: uporabljen je bil identičen MLP head, ista READOUT funkcija, isti preprocessing $X \rightarrow fGCN$, itd.] [Zamenjaj vse te diagrame z lepo grafiko, ki nazorno pokaže cevovode/poteke.]

TODO:

- Pisanje: opis uskladiti s končno implementacijo: ista grafovska predstavitev, isti signali, ista okna, iste delitve in ista standardizacija kot pri predlaganem GNN.
- Pisanje: preveriti in zapisati, da uporablja `GCNConv`, isto napovedno glavo, iste YAML hiperparametre in ločen readout parameter, trenutno `attention`; možnost `mean` omeni samo, če bo dejansko preverjena.

6.3.1 Izbira grafovske konvolucije

TODO:

- Odloči, ali ta razdelek ostane v poglavju 6 ali gre v eksperimentalni protokol kot utemeljitev fiksiiranega operatorja.
- Če ostane tukaj, naj poglavje 7 ne ponavlja razlage primerjave `GCNConv`, `GATConv`, `GraphConv` in `GINConv`, ampak naj se sklicuje sem oziroma v dodatek.

V vseh grafovskih modelih uporabimo plast `GCNConv` [11]. Ta izbira ohrani konvolucijski operator fiksni, zato lahko primerjava med grafovskimi modeli bolj jasno pokaže vpliv tistih delov, ki so za nalogo pomembnejši: ločevanja časovnih, prostorskih in fiksacijskih relacij, združevanja relacijskih predstavitev ter naučenih uteži povezav. Poleg tega `GCNConv` neposredno podpira skalarne uteži povezav, ki jih predlagani model izračuna iz značilk povezav.


Drugih grafovskih plasti zato ne obravnavamo kot del glavnega eksperimentalnega protokola. GATConv [17] bi pomenil drugačen način določanja pomembnosti sosedov in v trenutni implementaciji ne uporablja istih skalar-
nih uteži povezav. GraphSAGE je zanimiv predvsem pri zelo velikih grafih in vzorčenju sosesk, kar pri grafih posameznih časovnih oken ni osrednja omejit-
tev. GIN je močan model za klasifikacijo grafov, vendar bi zahteval dodatno uglaševanje na razmeroma majhni in šumni podatkovni zbirki. Grafovski transformerji so smiselna smer nadaljnjega dela, vendar bi v to nalogo vnesli še ločeno vprašanje pozicijskih in strukturnih kodiranj.

6.4 Predlagani prostorsko-časovni heterogeni GNN

Končni model nadgradi osnovni GCN iz prejšnjega odseka in temelji na prostorsko-časovni heterogeni grafovski nevronske mreži. Model ločeno obrav-
nava časovne povezave naprej, časovne povezave nazaj, prostorske povezave in fiksacijske povezave. S tem lahko za različne tipe odnosov uporablja različne transformacije.

6.4.1 Pregled arhitekture

Osnovni potek modela je prikazan na sliki 6.1.



Slika 6.1: Delovna shema predlaganega GNN. Diagram prikazuje glavni tok podatkov od vhodnega okna do napovedi ter ločeno pot za izračun uteži povezav in pozornostnih uteži vozlišč.

TODO: Trenutni diagram je samo delovna predloga za pisanje. Pred oddajo je treba izdelati končne diagrame arhitekture in z njimi zamenjati to predlogo: pregledni diagram celotnega predlaganega GNN ter ločen diagram notranjosti heterogene GNN plasti. Besedilo pod diagrammom pa je treba prilagoditi poimenovanjem na diagramu. dodati je treba tudi računanje uteži na povezavah

Na diagramu je X vhodna matrika značilk vozlišč opisana v poglavju ??, f_{pre} je naučena preslikava X v skupni latentni prostor, $f_{\text{HeteroGNN}}$ so plasti predlagane heterogene grafovске nevronske mreže, f_{fuzija} označuje združevanje vseh štirih predstavitev vozlišča v eno skupno predstavitev, READOUT predstavlja združevanje predstavitev vozlišč v predstavitev celotnega grafa, ki se prenese kot vhod v napovedno klasifikacijsko glavo f_{head} .

Za primerjavo podajamo tudi potek osnovnega GCN:

$$X \rightarrow f_{\text{GCN}} \rightarrow \text{READOUT} \rightarrow f_{\text{head}}, \quad (6.3)$$

6.4.2 Relacijsko posredovanje sporočil in uteži povezav

TODO:

- Ta podrazdelek naj bo glavno mesto za arhitekturno razlago naučenih uteži povezav.
- Sem prestavi formuli za surovo oceno, preslikavo s tanh in normalizacijo uteži iz poglavja 5.2.5, če ostaneta del končnega modela.
- V poglavju 5 naj po predstavitvi ostane samo tabela značilk povezav in sklic, da jih končni model uporabi za izračun uteži.

Kot definirano v poglavju ??, $f_{\text{HeteroGNN}}$ ločeno obravnava različne relacije oziroma tipe povezav med vozlišči. Za primerjavo, osnovni GCN vse povezave obravnava kot enake, zato težje prilagodi posredovanje sporočil različnim odnosom med meritvami.

Posredovanje sporočil med vozlišči v heterogenem grafovskem modelu izvajamo ločeno po relacijah. Model se za vsako relacijo nauči svojo grafovsko

konvolucijo in tako ločeno izračuna predstavitev vozlišč na podlagi vseh štirih tipov povezav.

Za izračun uteži povezav se model uči treh večslojnih perceptronov f_w^{time} , f_w^{space} ter f_w^{fixation} . Te funkcije iz značilk povezave izračunajo skalarno predznačeno utež, ki določa, kako močno posamezna povezava vpliva na posredovanje sporočil. Ker so uteži predznačene, lahko povezava prispevek sosednjega vozlišča tudi zmanjša. Časovne povezave naprej in nazaj si delijo isto funkcijo f_w^{time} , smer povezave pa je podana kot dodatna značilka povezave ρ_{ij} . Značilke povezav, iz katerih model izračuna uteži, so opisane v poglavju 5.2.5.

[Ko bomo imeli sliko/diagram poteka (nekaj podobnega kot je GFM-for-eyetracker/docs/figures/gnn_pipeline bomo tukaj referencirali funkcijo/MLP, ki računa uteži. Trenutno za placeholder pustimo f_w^{rel}].

[Če normalizacijo uteži prestaviš iz poglavja 5 v 6.4, dodaj tukaj kratko formulo; sicer formule ne ponavljaj.]

6.4.3 Fuzija relacijskih predstavitev

Po posredovanju sporočil po različnih tipih povezav dobimo za vsako vozlišče eno predstavitev na relacijo. Te predstavitve združimo na ravni vozlišč s konkatencijo in MLP fuzijo v enotno predstavitev vozlišča:

$$\mathbf{h}_i = f_{\text{fuzija}} \left(\left[\mathbf{h}_i^{(t+)} \parallel \mathbf{h}_i^{(t-)} \parallel \mathbf{h}_i^{(s)} \parallel \mathbf{h}_i^{(f)} \right] \right), \quad (6.4)$$

kjer $\parallel$ označuje konkatencijo, $\mathbf{h}_i^{(t+)}$ časovno predstavitev naprej, $\mathbf{h}_i^{(t-)}$ časovno predstavitev nazaj, $\mathbf{h}_i^{(s)}$ prostorsko predstavitev in $\mathbf{h}_i^{(f)}$ fiksacijsko predstavitev.

6.4.4 Predstavitev grafa in napoved

TODO:

- Ne ponavljaj splošne razlage READOUT iz poglavja 2.2.2.
- Tukaj opiši samo konkretno izbiro arhitekture: združevanje s pozornostjo, izračun α_v , klasifikacijska glava in izguba za dejansko število razredov.
- Uskladi besedilo in izgubo z novo glavno nalogo: binarna klasifikacija valence, ne trirazredna valenca in vzburjenost, razen če bo ta del ostal kot sekundarni eksperiment.

Ker napovedujemo oznako celotnega okna, moramo predstavitev vozlišč združiti v predstavitev grafa. Uporabimo združevanje s pozornostjo:

$$\mathbf{h}_G = \sum_{v \in V} \alpha_v \mathbf{h}_v, \quad (6.5)$$

kjer je $\mathbf{h}_G$ predstavitev grafa, α_v utež pozornosti za vozlišče v , $\mathbf{h}_v$ pa predstavitev vozlišča v . S tem modelu omogočimo, da se dinamično opre na informativne dele časovnega okna, torej na informativna vozlišča. Uteži pozornosti izračunamo s softmax normalizacijo, kot je običajno pri mehki pozornosti in pozornostnem združevanju grafov [2, 12]:

$$\alpha_v = \frac{\exp(g(\mathbf{h}_v))}{\sum_{u \in V} \exp(g(\mathbf{h}_u))}, \quad (6.6)$$

kjer je g naučena funkcija, ki vozliščni predstavitvi priredi skalarno oceno pomembnosti.

Predstavitev grafa $\mathbf{h}_G$ posredujemo v napovedno glavo f_{head} , ki vrne logite za tri razrede. Pri vrednotenju logite s funkcijo softmax pretvorimo v napovedne verjetnosti, končno napoved pa določimo kot razred z največjo napovedno verjetnostjo. Valenco in vzburjenost obravnavamo kot ločeni klasifikacijski nalogi, zato za vsako nalogo učimo ločen model z enako arhitekturo. Model

učimo z znano navzkrižno entropijo za trirazredno klasifikacijo:

$$\mathcal{L} = - \sum_{c=1}^3 y_c \log \hat{y}_c, \quad (6.7)$$

kjer je $\mathcal{L}$ izguba, y_c prava oznaka razreda c , $\hat{y}_c$ pa napovedana verjetnost za razred c [6].

Podrobnosti optimizacije, kot so učna stopnja, velikost mini-serij in število epoh, podamo v eksperimentalnem protokolu.

6.4.5 Stabilizacija učenja

Pri učenju uporabimo več uveljavljenih mehanizmov, ki pomagajo pri stabilnosti optimizacije in zmanjševanju prekomernega prileganja. Rezidualne povezave olajšajo pretok informacij skozi več grafovskih plasti, normalizacija plasti stabilizira porazdelitve latentnih predstavitev, aktivacija GELU uvede gladko nelinearnost, izpuščanje pa deluje kot regularizacija [8, 1, 9, 15]. Te komponente ne spreminjajo grafovske predstavitve podatkov, temveč izboljšajo učni postopek predlagane arhitekture.

[Dodamo angleške izraze v oklepajih? Npr. izpuščanje (ang. dropout)]

Poglavje 7

Eksperimentalni protokol

7.1 Eksperimentalne naloge

TODO:

- Novo delovno izhodišče: glavna naloga naj bo binarna klasifikacija, ne več 3-razredna klasifikacija; obstoječi opis 3-razredne naloge kasneje predstaviti v dodatni ali primerjalni del, če jo bomo še poročali.
- Glavno primerjavo zastaviti kot model $\times$ množica signalov, z množicami *samo pogled*, *pogled in zenici* in *vsi signali*; *samo zenici* naj ostane opomnik za morebitni MOMENT eksperiment, ne obvezni del GNN primerjave.
- Za začetek uporabiti k-kratno prečno preverjanje po subjektih kot glavni protokol; k-kratno prečno preverjanje po posnetkih, LOO po subjektih in LOO po posnetkih označiti kot možne dodatne robustnostne preveritve, če bodo izvedene.
- GazeMAE trenirati oziroma uporabiti samo na množici *samo pogled*; v tabelah ga je dovoljeno primerjati tudi z drugimi nabori kot referenčni model, vendar ne kot model, treniran na teh signalih.

7.1.1 Valenca in vzburjenost

V nalogi obravnavamo dve glavni klasifikacijski nalogi: 3-razredno klasifikacijo valence ter 3-razredno klasifikacijo vzburjenosti. Obe nalogi definiramo po preslikavi iz tabele 6 izvirnega članka podatkovne zbirke MAHNOB-HCI [14]. Razredi niso dobljeni z neposredno diskretizacijo številskih samoocen valence in vzburjenosti, temveč iz poročane čustvene oznake `emotion-id`. S tem eksperimentalni nalogi sledita izvirni formulaciji in omogočata primerjavo z objavljenimi rezultati na isti podatkovni zbirki. Za dodatno primerjavo uporabimo tudi binarni različici, pri katerih obdržimo samo oba skrajna razreda.

TODO:

- Eksperimenti: pognati glavni nalogi diplome kot 3-razredno klasifikacijo valence in 3-razredno klasifikacijo vzburjenosti, ker sta tako neposredno primerljivi z formulacijo v MAHNOB-HCI.
- Eksperimenti: pognati še binarni low/high različici valence in vzburjenosti, kjer odstranimo srednji oziroma nevtralni razred in obdržimo izrazitejša skrajna razreda.

TODO:

- Pisanje: v besedilu jasno ločiti glavni eksperiment od dodatnega binarnega eksperimenta; binarno formulacijo opiši kot čistejšo in lažjo dopolnilno evalvacijo, ne kot zamenjavo glavne naloge.
- Pisanje: po rezultatih preveriti, ali imena razredov v tabelah, slikah in dodatkih sledijo enaki terminologiji kot v tabeli 7.1.

Tabela 7.1: Preslikava čustvenih oznak v razrede valence in vzburjenosti, povzeta po tabeli 6 izvirnega članka MAHNOB-HCI [14].

Ciljna naloga	Razred	Čustvene oznake
Valenca	neprijetna (<i>unpleasant</i>)	<i>fear, anger, disgust, sadness, anxiety</i>
Valenca	nevtralna (<i>neutral valence</i>)	<i>neutral, surprise</i>
Valenca	prijetna (<i>pleasant</i>)	<i>joy/happiness, amusement</i>
Vzbujenost	nizka (<i>calm</i>)	<i>sadness, disgust, neutral</i>
Vzbujenost	srednja (<i>medium aroused</i>)	<i>joy/happiness, amusement</i>
Vzbujenost	visoka (<i>excited/activated</i>)	<i>surprise, fear, anger, anxiety</i>

7.2 Validacijska protokola

7.2.1 Prečno preverjanje z izpuščanjem enega primerka

Uporabimo dva validacijska protokola prečnega preverjanja tipa "izpusti enega" (ang. *leave-one-out*, LOO). Pri takem protokolu množico podatkov najprej razdelimo na primerke po izbrani kategoriji, na primer po subjektih ali posnetkih. V vsaki iteraciji nato en primerek izvzamemo iz množice in njegove podatke uporabimo kot testno množico, podatke ostalih primerkov pa uporabimo za učenje oziroma jih pri nevronskih modelih dodatno razdelimo na učno in validacijsko množico. Pri klasičnih modelih strojnega učenja, kot sta SVM in LightGBM, validacijske množice v osnovnem učenju ne potrebujemo, pri nevronskih modelih, kot sta MLP in GNN, pa jo uporabimo za spremljanje učenja, spreminjanje hiperparametrov učenja ter zgodnje ustavljanje.

Velikost validacijske množice smo določili z `val_size=2`. Ta vrednost ustreza velikostnemu redu uporabljene podatkovne množice, ki po filtriranju vsebuje 22 subjektov in 20 posnetkov. Od testne množice se validacijska

razlikuje po tem, da lahko vpliva na potek učenja oziroma izbiro modela, testna množica pa ostane namenjena samo končni oceni delovanja v posamezni iteraciji.

Uporabili smo dva validacijska protokola prečnega preverjanja tipa LOO:

- **LOO po subjektih:** v vsaki iteraciji so podatki enega subjekta testna množica, podatki ostalih subjektov pa so na voljo za učenje oziroma validacijo.
- **LOO po posnetkih:** v vsaki iteraciji so podatki enega posnetka oziroma stimulusa testna množica, podatki ostalih posnetkov pa so na voljo za učenje oziroma validacijo.

Kombinirane delitve po subjektih in posnetkih v tej nalogi ne uporabljamo, ker bi bila računsko bistveno dražja in bi preseгла obseg diplomske naloge.

Pred izvedbo delitev smo iz podatkov izključili subjekte P9, P12 in P15. Ti subjekti so kot problematični navedeni že v izvirnem članku podatkovne zbirke MAHNOB-HCI, zato jih izključimo tudi tukaj in s tem ohranimo boljšo primerljivost z izvirnimi rezultati. Pri oznakah uporabimo samo primere, pri katerih je vrednost stolpca `emotion-derivation-status` enaka `ok`, saj s tem odstranimo ogleda posnetkov z nezanesljivo izpeljano čustveno oznako.

Pri vsaki iteraciji prečnega preverjanja standardizacijo izračunamo samo na učni množici. Tako za značilke vozlišč, značilke povezav in tabelarične značilke najprej izračunamo statistike učne množice, nato pa isto pretvorbo uporabimo še na validacijski in testni množici. S tem preprečimo uhajanje informacij iz validacijske ali testne množice v učni postopek.

TODO:

- Eksperimenti: za glavne rezultate pognati LOO po subjektih kot primarni validacijski protokol in LOO po posnetkih kot dodatni poročani protokol.
- Eksperimenti: k-kratnega prečnega preverjanja ne uporabljati in ne poročati kot glavni rezultat za primerjavo modelov; izjema je ablacijska študija, opisana v razdelku 7.6.

TODO:

- Pisanje: v poglavju z rezultati naj bodo glavne tabele najprej za LOO po subjektih, nato za LOO po posnetkih; k-kratno prečno preverjanje naj se pojavi samo pri ablacijski študiji.
- Pisanje: jasno zapisati, da LOO po subjektih ocenjuje posploševanje na nove udeležence, LOO po posnetkih pa posploševanje na nove posnetke oziroma stimulse.

7.2.2 LOO po subjektih

LOO po subjektih meri posploševanje na nove udeležence. Izvedli smo ga zato, ker pri uporabi modela na novem uporabniku običajno nimamo označenih podatkov zanj. S tem protokolom ocenimo, kako dobro se naučeni vzorci prenesejo na nove subjekte in koliko so modeli občutljivi na razlike med posameznimi udeleženci.

V vsaki iteraciji je en subjekt v testni množici. Pri nevronskega modelih sta dva izmed preostalih subjektov v validacijski množici, ostalih 19 subjektov pa je v učni množici. Pri tem protokolu delimo podatke po subjektih, zato so lahko podatki vseh posnetkov prisotni v učni, validacijski in testni množici.

7.2.3 LOO po posnetkih

LOO po posnetkih meri posploševanje na nove posnetke oziroma stimulse. Izvedli smo ga zato, ker preverja drugačen vidik posploševanja kot LOO po subjektih: nov posnetek lahko povzroči drugačne vzorce pogleda, saj je pogled usmerjen na druge dele zaslona in sledi drugačnemu dogajanju. S tem preverimo, kako dobre so napovedi modelov pri novem stimulusu.

V vsaki iteraciji je en posnetek v testni množici. Pri nevronskega modelih sta dva izmed preostalih posnetkov v validacijski množici, ostalih 17 posnetkov pa je v učni množici. Pri tem protokolu delimo podatke po posnetkih, zato so lahko podatki vseh subjektov prisotni v učni, validacijski in testni množici.

7.3 Metrike

Za vsako nalogo in vsak validacijski protokol izračunamo več metrik, ker različne metrike povedo različne informacije o delovanju modela. Kot glavni metriki uporabimo točnost in macro-F1, z namenom direktne primerjave z izvirnim člankom podatkovne zbirke MAHNOB-HCI. Članek sicer ne poroča izrecno, ali uporablja navadno ali uravnoteženo točnost oziroma macro-F1 ali weighted-F1, vendar to utemeljeno sklepamo iz poročanih rezultatov naključnega klasifikatorja.

Rezultate metrik poročamo kot povprečje in standardni odklon čez iteracije prečnega preverjanja, torej v obliki $\text{mean} \pm \text{std}$.

7.4 Spremljanje učenja in diagnostika

TODO:

- Napiši, da diagnostiko učenja obravnavamo ločeno od končnih metrik vrednotenja, kot so accuracy, F1 in AUC.
- Navedi, da za nevronske modele shranjujemo učno izgubo, validacijsko izgubo, najboljšo epoho, zgodnje ustavljanje, čas epohe, trenutno stopnjo učenja in norme gradientov.
- Pojasni, da krivulji učne in validacijske izgube uporabimo za preverjanje stabilnosti optimizacije in znakov prekomernega prilaganja; testno izgubo izračunamo šele po izbiri najboljšega modela.
- Za grafovske modele napiši, da dodatno spremljamo varianco predstavitev grafa, povprečno kosinusno podobnost predstavitev, razpon logitov in entropijo napovednih verjetnosti.
- Pojasni namen teh GNN diagnostik: zaznavanje prekomernega glajenja, kolapsa predstavitev in skoraj konstantnih napovedi klasiﬁkacijske glave.
- Za predlagani model omeni še povzetke naučenih uteži povezav po časovnih, prostorskih in fiksacijskih relacijah.
- V glavnem besedilu poročaj samo agregirane krivulje izgub, porazdelitev najboljše epohe in ključne GNN diagnostike; podrobne grafe po gubah in relacijske porazdelitve uteži prestavi v dodatek D.

7.5 Glavna primerjava modelov

TODO:

- Ta razdelek naj bo samo protokolarni povzetek primerjanih modelov, signalnih naborov in hiperparametrov.
- Ne razlagaj ponovno, kaj je homogeni ali heterogeni graf; za to uporabi sklic na poglavji 2 in 5.
- Ne razlagaj ponovno naučenih uteži povezav, relacijskega posredovanja sporočil ali READOUT; za to uporabi sklic na poglavje 6.
- Tabela modelov naj vsebuje kratek opis vloge modela v primerjavi, ne metodološke definicije.

TODO:

- Ta razdelek kasneje prepisati v opis glavne factorske primerjave: modeli po vrsticah, nabori signalov po stolpcih oziroma ločeni teki za *samo pogled*, *pogled in zenici* in *vsi signali*.
- Ločiti modele, ki so definirani za vse nabore signalov, od modelov, ki so smiselni samo za posamezen nabor: GazeMAE za *samo pogled*, morebitni MOMENT za *samo zenici* oziroma zenični del.

Glavna primerjava vključuje modele v tabeli 7.3. Tabela poleg imena modela povzema kratko vlogo modela v primerjavi in osnovne parametre, ki jih pri posamezni vrsti modela poročamo ali uporabljamo pri razlagi rezultatov.

[Na koncu preveri, da se vrstni red ujema z vrstnim redom v tabelah/plotih. Preveri tudi, da se ujemajo poimenovanja znotraj diplome (recimo, če si že definiral naš GNN kot X , potem uporablaj ta konsistentno v besedilu, tabelah in slikah).]

Vsi grafovski modeli v glavnih poskusih uporabljajo GCNConv. V dodatnem poskusu na naboru pogled+zenici smo preizkusili še GATConv, GraphConv in GINConv oziroma GINEConv. Razlike med različicami niso bile velike, GCNConv pa je dosegel primerljive in stabilne rezultate pri neuteženi in uteženi

arhitekturi. Zato smo v glavnih poskusih ohranili enoten operator `GCNConv`, podrobnosti primerjave pa podajamo v dodatku A.4.

TODO:

- Če je izbira grafovske konvolucije razložena v dodatku A.4, tukaj pusti samo protokolarno odločitev in sklic.

Za nastavitev predlaganega GNN smo izvedli kompaktno iskanje po mreži na 3-razredni valenci s k -kratnim prečnim preverjanjem po subjektih ($k = 5$, en subjekt na validacijsko množico), pri čemer smo preizkusili `num_layers` $\in \{2, 3, 4\}$, `hidden_channels` $\in \{64, 128, 256\}$, `kt` $\in \{1, 2, 3\}$, `ks` $\in \{1, 2, 3\}$ in `kf` oziroma `fixation_dilation_k` $\in \{1, 2, 3, 5\}$. Kot končno nastavitev smo izbrali `num_layers=2`, `hidden_channels=64`, `kt=1`, `ks=1` in `kf=3`, saj je bila ta konfiguracija med najboljšimi po accuracy in macro-F1, hkrati pa je ohranila razmeroma majhen model s 101.143 učljivimi parametri in uravnoteženo gostoto grafovskih povezav.

TODO:

- Eksperimenti: preveriti, da primerjava vključuje diplomski grafovski izhodiščni model **osnovni GCN**; stare interne različice grafovskega modela ne sodijo v diplomsko primerjavo.
- Eksperimenti: za osnovni GCN uporabiti isto grafovsko predstavitev, iste signale, ista okna, iste delitve in isto standardizacijo kot pri predlaganem GNN.
- Eksperimenti: pri osnovnem GCN združiti relacije `temporal_forward`, `temporal_backward`, `spatial` in `fixation` v homogeni graf, odstraniti podvojene povezave ter ne uporabiti značilk povezav ali naučenih uteži povezav.
- Eksperimenti: preveriti, da osnovni GCN uporablja `GCNConv`, isto napovedno glavo, iste YAML hiperparametre in ločen parameter za readout; trenutni readout je `attention`, pozneje lahko preverimo še `mean`.
- Eksperimenti: preveriti, da osnovni GCN deluje za 2- in 3-razredno klasifikacijo ter da sta `num_layers=3` in `hidden_channels=128` res uporabljena tudi pri njem.

TODO:

- Pisanje: v tabeli in besedilu uporabljaj izraz osnovni GCN.
- Pisanje: v razlagi osnovnega GCN poudari, da je to arhitekturno poenostavljen grafovski izhodiščni model, ne starejša različica predlaganega modela.

7.6 Ablacijska študija

TODO:

- Če ta razdelek ostane, naj opisuje samo protokol ablacijske študije.
- Ne razlagaj ponovno, kako so časovne, prostorske ali fiksacijske povezave zgrajene; sklicuj se na poglavje 5.
- Ne razlagaj ponovno, kako model uporablja relacije ali uteži; sklicuj se na poglavje 6.

TODO:

- Preveriti, ali ta razdelek po novi zasnovi sploh ostane ločena ablacijska študija ali se združi z glavno primerjavo signalnih naborov.
- Če ostane ločeno, naj ablacijska študija odgovarja predvsem na vprašanja znotraj predlaganega GNN; primerjava *samo pogled, pogled in zenici* in *vsi signali* naj bo glavna signalna primerjava, ne samo ablacijska opomba.

Namen ablacijske študije je bil preveriti, koliko kateri signali prispevajo k boljšim napovedim predlaganega modela. Izhodišče je bil predlagani model iz glavne primerjave. Pri vsaki ablacijski nastavitvi smo ohranili enak validacijski protokol, enake delitve podatkov in enake hiperparametre učenja, zakrili pa smo samo eno skupino informacij (en signal).

Preverili smo štiri ablacijske nastavitve. Pri prvi smo odstranili značilke velikosti zenic. Pri drugi smo odstranili časovno informacijo, torej časovne značilke vozlišč in povezav ter časovne povezave. Pri tretji smo odstranili prostorsko informacijo, ki vključuje koordinate pogleda (x, y) , razdaljo in iz njih izpeljane prostorske povezave ter značilke povezav. Pri četrti smo odstranili informacijo o fiksacijah, torej trajanje fiksacij in fiksacijske povezave.

TODO:

- Eksperimenti: ablacijske poskuse pognati za 3-razredno valenco in 3-razredno vzburjenost.
- Eksperimenti: zaradi časovne ekonomičnosti ablacijske poskuse pognati s k -kratnim prečnim preverjanjem po subjektih, trenutno z $k = 5$, ne s polnim LOO po subjektih.
- Eksperimenti: pripraviti ablacijske nastavitve za odstranitev časovne informacije, prostorske oziroma informacije pogleda, fiksacijske informacije, zenične informacije in razdaljne informacije.
- Eksperimenti: ko odstranimo signal, odstraniti vse informacije, izpeljane iz njega: značilke vozlišč, značilke povezav in povezave.

TODO:

- Pisanje: trenutni opis štirih ablacijsko nastavitvev uskladiti s petimi skupinami signalov; razdaljo obravnavaj ločeno od prostorske informacije oziroma informacije pogleda, če bo tako implementirana v poskusih.
- Pisanje: po pridobitvi rezultatov odločiti, ali v glavnem besedilu podrobno poročamo obe nalogi ali predvsem valenco; za vzburjenost naj bodo vsaj podporni rezultati v dodatku.
- Pisanje: v poglavju z rezultati zapisati, da so rezultati k -kratnega prečnega preverjanja in LOO dovolj primerljivi za ablacijsko analizo, ker nas zanima relativni vpliv odstranitve signalov, ne končna absolutna ocena modela.

[Morebitni dodatni poskusi naj bodo obravnavani kot ločena arhitekturna analiza, ne kot ablacijska študija vhodnih signalov: izklop uteži povezav, uporaba 5 s oken namesto 10 s oken, odstranitev MLP fuzije relacijskih predstavitev in primerjava različnih strategij združevanja grafa.]

Tabela 7.2: Metrike, uporabljene pri vrednotenju modelov.

Metrika	Definicija	Interpretacija
Accuracy	Delež pravilno razvrščenih primerov med vsemi primeri.	Ena izmed dveh glavnih metrik za primerjavo z izvirnimi rezultati na podatkovni zbirki MAHNOB-HCI.
Macro-F1	Povprečje vrednosti F1 po razredih, pri čemer ima vsak razred enako težo.	Druga glavna metrika za primerjavo z izvirnim člankom; posebej pomembna pri neuravnoteženih razredih.
Balanced accuracy	Povprečje priklica po razredih.	Enaka teža vseh razredov pri oceni uspešnosti.
Weighted-F1	Povprečje vrednosti F1 po razredih, uteženo s številom primerov v posameznem razredu.	Dodatna ocena uspešnosti glede na dejansko porazdelitev razredov.
AUC	Ločljivost razredov na podlagi napovedanih verjetnosti; pri večrazredni nalogi jo izračunamo po pristopu one-vs-rest.	Podporna informacija o ločevanju posameznih razredov.
Confusion matrix	Število in delež napovedi za vsako kombinacijo pravega in napovedanega razreda.	Razlaga tipičnih napak modela; pri prikazu je normalizirana po vrsticah.

Tabela 7.3: Modeli, vključeni v glavno primerjavo, njihova vloga in osnovni parametri.

Model	Opis	Parametri
Naključni klasifikator	Enakomerno naključno vzorčenje razreda.	<code>random_state=42</code>
Večinski klasifikator	Napoved najpogostejšega razreda učne množice.	/
SVM	Klasifikator z jedrom RBF nad agregiranimi značilkami okna.	<code>C=1.0, kernel=rbf,</code> <code>probability=true</code>
LightGBM	Gradientno spodbujena odločitvena drevesa nad agregiranimi značilkami okna.	<code>n_estimators=100,</code> <code>learning_rate=0.05,</code> <code>max_depth=5</code>
MLP	Polno povezana nevronska mreža nad agregiranimi značilkami okna.	<code>hidden_layers=(64,64),</code> <code>dropout=0.1,</code> <code>learning_rate=0.001,</code> <code>weight_decay=0.0001</code>
GazeMAE + MLP	Zamrznjen prednaučen kodirnik položajev pogleda.	predstavitev z 512 razsežnostmi, <code>hidden_layer_size=128,</code> <code>dropout=0.2,</code> <code>learning_rate=0.001</code>
Osnovni GCN	Homogeni grafovski primerjalni model z enotnim posredovanjem sporočil.	<code>GCNConv, num_layers=3,</code> <code>hidden_channels=128</code>
Predlagani GNN	Heterogena časovno-prostorska grafovska nevronska mreža z naučenimi utežmi povezav.	<code>GCNConv, num_layers=2,</code> <code>hidden_channels=64, kt=1,</code> <code>ks=1, kf=3,</code> <code>relation_pooling=mlp,</code> <code>graph_pooling=attention</code>

Poglavje 8

Rezultati


TODO:

- To poglavje je načrtano okoli glavnega eksperimenta: binarna klasifikacija valence z 7-kratnim prečnim preverjanjem po subjektih.
- Vir rezultatov je retinirani tek `RETAIN_2026-06-12_16-29-08`.
- V besedilu na začetku na kratko zapiši, da ime artefakta še vsebuje staro oznako `3class`, vendar metapodatki razredov potrjujejo binarno nalogo z razredoma nizka in visoka valenca.
- Povej, da so v glavnem besedilu prikazani samo ključni rezultati, razširjene metrike pa so v dodatku A.2.

8.1 Porazdelitev razredov in zanesljivost oznak

TODO:

- Opiši, da so po odstranitvi nevtralnega razreda razredi nizka/visoka valenca skoraj uravnoteženi pri vseh štirih množicah signalov.
- Uporabi številke iz tabele `label_distribution_aggregate.csv`: delež nizke valence je približno 52 %, delež visoke valence pa približno 48 %.
- Poveži večinski klasifikator s porazdelitvijo razredov: visoka točnost večinskega modela ne pomeni dobrega razločevanja, kar pokaže nizek makro F1.
- Kratko utemelji, zakaj je binarna valenca glavna ciljna naloga: analiza ujemanja oznak s samoocenami pokaže samo 3,3 % neujemanja za binarno valenco, medtem ko je neujemanje pri binarni vzburljenosti približno 29,7 %.



Slika 8.1: Porazdelitev razredov za glavni binarni eksperiment z valenco.

8.2 Glavna primerjava modelov

TODO:


- Najprej razloži zapis v celicah: prva številka je točnost, druga je makro F1; obe sta v odstotkih.
- Poudari, da tabela primerja isto ciljno nalogo za štiri enakovredne množice signalov: samo pogled, samo zenici, pogled in zenici ter vsi signali.
- Zapiši glavno ugotovitev: najboljše rezultate dosežejo negrafovski modeli nad agregiranimi značilkami, grafovski modeli pa so večinoma pod najboljšima SVM in LightGBM.
- Posebej omeni, da množica pogled in zenici doseže najvišji posamični rezultat, medtem ko dodajanje vseh signalov ne prinese izboljšanja.
- Pri GazeMAE/MOMENT pojasni, da je to enoten prikaz zamrznjenih predstavitvenih modelov: GazeMAE pri pogledu, MOMENT pri zenicah in fuzija obeh pri kombiniranih signalih.

Tabela 8.1: Glavna primerjava modelov pri binarni klasifikaciji valence. Celice vsebujejo točnost / makro F1 v odstotkih.

Model	samo pogled	samo zenici	pogled in zenici	vsi signali
Naključni	50,2 / 50,1	50,7 / 50,6	50,8 / 50,6	50,9 / 50,7
Večinski	52,5 / 34,4	52,2 / 34,2	52,1 / 34,2	52,2 / 34,2
SVM	67,5 / 67,2	62,1 / 60,7	70,5 / 69,7	68,6 / 67,6
LightGBM	69,7 / 69,4	63,1 / 61,9	69,6 / 68,8	69,0 / 68,3
MLP	67,0 / 66,7	62,0 / 60,3	68,7 / 67,6	67,2 / 66,2
GazeMAE/MOMENT	65,7 / 65,2	60,5 / 60,1	65,6 / 65,2	66,1 / 65,6
GCN	64,4 / 64,1	61,0 / 58,4	65,4 / 63,9	59,6 / 57,6
HeteroGCN-mean	61,7 / 59,2	58,6 / 55,7	63,8 / 61,1	61,8 / 59,7
HeteroGCN-MLP	65,9 / 65,8	59,1 / 56,0	64,2 / 62,8	60,5 / 56,6
Končni GNN	64,3 / 64,0	58,4 / 54,5	65,5 / 64,4	62,7 / 60,8

TODO:

- Spodnja slika prikazuje iste vrednosti kot tabela 8.1; barva celice sledi makro F1.
- Po pisanju se odloči, ali v glavnem besedilu obdržiš tabelo, heatmap ali oboje. Če obdržiš oboje, naj besedilo jasno pove, da gre za alternativna prikaza istih rezultatov.



Slika 8.2: Toplotni prikaz glavne primerjave modelov. V celicah sta zapisani točnost / makro F1 v odstotkih, barva pa prikazuje makro F1.

8.3 Vpliv množice signalov


TODO:

- Opiši razliko med štirimi signalnimi množicami in jih obravnavaj enakovredno.
- Izpostavi, da je samo zenici šibkejša, vendar informativna signalna množica; ni pomožni ali nedokončan eksperiment.
- Primerjaj samo pogled in pogled in zenici: dodajanje zeničnih signalov izboljša najboljši rezultat pri SVM, manj jasno pa pomaga grafovskim modelom.
- Pojasni, da vsi signali ne pomenijo nujno boljšega rezultata, saj dodatni signali lahko dodajo šum ali povečajo težavnost modeliranja.
- Pri interpretaciji ne sklepaj, da so zenice ali razdalja nepomembne na splošno; sklep velja za uporabljeno predstavitev, podatkovno zbirko in protokol.

8.4 Matrike zmede

TODO:

- Matrike zmede so prikazane samo za množico pogled in zenici, ker tam nastopi najboljši skupni rezultat.
- Primerjaj najboljši splošni model SVM in najboljši grafovski model, tj. končni GNN.
- Opiši, kateri razred je pogostejše zamenjan in ali model kaže izrazit zamik proti nizki ali visoki valenci.
- Povej, da so prikazane samo vrstično normalizirane vrednosti; absolutne matrike zmede sodijo v dodatek, če jih bomo sploh vključili.



Slika 8.3: Vrstično normalizirani matriki zmede za najboljši model in najboljši grafovski model pri množici signalov pogled in zenici.

8.5 Velikost in računska zahtevnost modelov

TODO:

- Tabela naj bo uporabljena za praktično interpretacijo rezultatov: ali bolj zapleteni modeli prinesejo dovolj boljše rezultate glede na svojo ceno.
- Pojasni, da za SVM, LightGBM, večinski in naključni model število nevronskega parametrov ni smiselna primerjava, zato je označeno z -.
- Pri GazeMAE/MOMENT loči učljive parametre glave in vse parametre zamrznjenih kodirnikov.
- Izpostavi, da so grafovski modeli računsko dražji na okno kot tabelarni modeli, čeprav v glavnih metrikah ne dosežejo najboljših rezultatov.

Tabela 8.2: Velikost in računska zahtevnost modelov pri množici signalov pogled in zenici.

Model	Učljivi parametri	Vsi parametri	Učenje [ms/okno]	Inferenca [ms/okno]
Naključni	–	–	–	–
Večinski	–	–	–	–
SVM	–	–	0,386	0,079
LightGBM	–	–	0,042	0,002
MLP	7.234	7.234	0,390	0,001
GazeMAE/MOMENT	180.738	127.217.238	0,263	0,001
GCN	26.051	26.051	20,727	0,190
HeteroGCN-mean	42.691	42.691	26,641	0,201
HeteroGCN-MLP	75.715	75.715	22,272	0,201
Končni GNN	76.006	76.006	21,742	0,193

8.6 Dodatna preverjanja

TODO:

- Kratko omeni dodatni poskus izbire grafovske konvolucije iz dodatka A.4.
- Povej samo bistvo: GCNConv ni bil absolutno najboljši operator v dodatnem poskusu, vendar je bil dovolj stabilen in poenostavi primerjavo arhitekturnih stopenj.
- Ne razširjaj tega dela v novo glavno primerjavo modelov; podrobne številke naj ostanejo v dodatku.

8.7 Povzetek rezultatov

TODO:

- V nekaj odstavkih povzemi odgovore na raziskovalno vprašanje.
- Prvi odstavek: najboljši rezultati pripadajo negrafovskim modelom, predvsem SVM in LightGBM.
- Drugi odstavek: grafovska predstavitev dosega rezultate nad naključnim in večinskim izhodiščem, vendar trenutna grafovska arhitektura ne izboljša klasifikacije glede na agregirane tabelarične značilke.
- Tretji odstavek: signalna množica pogled in zenici je najboljša v tej evalvaciji, samo zenici pa ostane smiselna samostojna primerjava.
- Zaključni previdno: rezultati ne zavračajo uporabnosti grafovskega modeliranja podatkov sledilnika pogleda, kažejo pa, da uporabljena grafovska arhitektura in konstrukcija povezav v tej nalogi nista presegli močnejših negrafovskih primerjav.

Poglavje 9

Diskusija

TODO:

- Diskusijo preusmeriti iz vprašanja, ali GNN absolutno zmaga, v vprašanje, kako se modeli obnašajo pri različnih naborih signalov.
- Posebej interpretirati razlike med *samo pogled*, *pogled in zenici* in *vsi signali*: ali zenični signal pomaga nad koordinatami pogleda, ali dodatni signali v *vsi signali* pomagajo ali dodajo šum, ter ali GNN bogatejšo strukturo izkoristi bolje kot negrafovski modeli.
- GazeMAE obravnavati kot močno referenco za množico *samo pogled*; če premaga modele z več signali, to interpretirati kot pomembno ugotovitev o naučenih predstavitvah pogleda.
- *Samo zenici* in MOMENT opisati samo kot prihodnje delo ali podporni poskus, če ne bosta dokončana.

9.1 Ali grafovska predstavitev pomaga?

TODO:

- ali finalni GNN premaga ne-grafovske primerjalne modele;
- če ne premaga: ali kaže smiselno vedenje;
- pri kateri nalogi je graf najbolj koristen;
- LOO po subjektih v primerjavi z LOO po posnetkih;
- primerjava proti GazeMAE + MLP;
- povezava z ablations;
- konservativen zaključek.

9.2 Vloga časovnih in prostorskih povezav

TODO:

- časovne povezave;
- prostorske povezave;
- fiksacijske povezave;
- ločevanje časovnih povezav naprej in nazaj;
- naučene predznačene uteži povezav;
- `distance-avg`;
- `fixation-duration`;
- značilka povezave `delta_distance`;
- kaj to pomeni za signale sledilnika pogleda;
- brez kavzalnih trditev.

9.3 Primerjava z GazeMAE

TODO:

- ali GazeMAE + MLP premaga primerjalne modele;
- ali GazeMAE + MLP premaga GNN;
- samonadzorovano učenje predstavitev kot uporabna smer;
- zamrznjena enkoderja position/velocity;
- 512-dim okenska predstavitev;
- omejitev: primerjalni model s prenosom;
- omejitev: ne polna reprodukcija predtreniranja.

9.4 Stabilnost učenja in notranje predstavitve

TODO:

- Povzemi, ali krivulje izgub kažejo stabilno učenje ali prekomerno prileganje.
- Interpretiraj varianco in kosinusno podobnost predstavitev v povezavi s prekomernim glajenjem.
- Interpretiraj razpon logitov v povezavi z zanesljivostjo oziroma zasičenostjo napovedne glave.
- V eni povedi poročaj, da diagnostika iz dodatka D.1 kaže informativno sliko učenja: GNN se uči razločevalnih grafovskih predstavitev in pri glavnih signalnih naborih ne kaže jasnega kolapsa oziroma prekomernega glajenja.
- Če diagnostika ne pokaže jasnega vzorca, to napiši previdno in brez pretiranih sklepov.
- Poveži ugotovitve z arhitekturnimi odločitvami iz poglavja 6.4.5.

9.5 Primerjava z izvirnim MAHNOB-HCI pristopom

TODO:

- izvirni članek: ročno oblikovane značilke pogleda;
- izvirni članek: drugačen cevovod izbire značilk;
- izvirni članek: SVM;
- ta naloga: grafi iz časovnih oken surovejših signalov;
- primerjava metodološko motivacijska;
- ne neposredna reprodukcija;
- posebej omeniti uporabo `distance-avg` in fiksacijskih informacij kot približanje širšemu naboru signalov iz literature.

9.6 Omejitve

Glavne omejitve naloge so:

- uporaba ene glavne podatkovne zbirke;
- subjektivnost čustvenih oznak;
- omejitev na signale sledilnika pogleda brez drugih fizioloških modalnosti;
- občutljivost grafovske konstrukcije na hiperparametre;
- računska zahtevnost validacije z LOO protokoli;
- možnost prekomernega glajenja v grafovskih modelih.

9.7 Možnosti nadaljnjega dela

Možne smeri nadaljnjega dela vključujejo:

- učenje povezav namesto ročne konstrukcije grafa;
- uporabo grafovskih transformerjev;
- samonadzorovano predtreniranje na neoznačenih signalih sledilnika pogleda;
- razvoj grafovskega temeljnega modela za podatke pogleda;
- razširitev na večmodalne fiziološke podatke;
- evalvacijo na več podatkovnih zbirkah.

TODO: Pri pisanju tega odseka dodaj tudi dve konkretni smeri nadaljnjega dela:

- razmislek in implementacijo uporabe mežikov, saj literatura mežike obravnava kot informativen signal pri prepoznavi čustvenih stanj iz podatkov pogleda [13, 16];
- razširitev grafovske predstavitve s fiksacijskimi meta-vozlišči, torej idejo 3D lift, kjer bi posamezne meritve ostale osnovna vozlišča, fiksacije pa bi bile dodatna vozlišča višje ravni, povezana z meritvami, ki jim pripadajo.

Poglavje 10

Zaključek

TODO:

- Zaključek na koncu uskladiti z novo zgodbo: glavna naloga je binarna klasifikacija, glavna primerjava pa modeli pri množicah *samo pogled*, *pogled in zenici* in *usi signali*.
- Sklep naj pošteno pove, pri katerih signalih in modelih GNN pomaga oziroma ne pomaga, namesto da predpostavlja, da mora biti GNN najboljši.
- Če GazeMAE ostane zelo močan, ga omeniti kot pomembno referenco za naučene predstavitve pogleda in motivacijo za nadaljnje delo z združevanjem predstavitev.
- Pri nadaljnjem delu omeni tudi preizkus drugih grafovskih plasti, npr. GATConv, GraphSAGE, GIN in grafovskih transformerjev; v glavnih eksperimentih je bil operator namenoma fiksiran na GCNConv.

TODO: Zaključek napiši čisto na koncu. Struktura:

- en odstavek: kaj je bil problem;
- en odstavek: kaj si naredil;
- en odstavek: glavni rezultati;
- en odstavek: kaj rezultati pomenijo;
- en odstavek: omejitve in prihodnje delo.

V diplomski nalogi smo obravnavali uporabo grafovskih nevronske mreže za prepoznavo afektivnih stanj iz podatkov sledilnika pogleda. Časovna okna meritev smo predstavili kot časovno-prostorske grafe, v katerih vozlišča predstavljajo posamezne meritve, povezave pa časovne, prostorske in fiksacijske odnose med njimi. Predlagani pristop smo ovrednotili na podatkovni zbirki MAHNOB-HCI pri 3-razredni klasifikaciji valence in vznemirjenosti.

TODO:

- Zaključek naj grafovsko predstavitev samo kratko povzame; ne ponavljaj definicij grafa, heterogenosti, uteženosti ali pravil konstrukcije povezav.
- Če omenjaš naučene predznačene uteži, jih predstavi kot ugotovitev oziroma komponento modela, ne ponovno kot metodološko definicijo.
- Uskladi z novo glavno nalogo in terminologijo: binarna klasifikacija valence, časovno-prostorski graf, klasifikacija čustvenih oznak.

TODO:

- najboljši model;
- ali graf pomaga glede na ne-grafovske primerjalne modele;
- ali predlagani GNN pomaga glede na osnovni GCN in ne-grafovske primerjalne modele;
- vloga časovnih povezav;
- vloga prostorskih povezav;
- vloga fiksacijskih povezav;
- vloga naučenih predznačenih uteži;
- glavna omejitev;
- najbolj smiselna smer nadaljnjega dela.

Dodatek A

Dodatni rezultati

TODO:

- Sem dodaj dodatne tabele po foldih, rezultate manj pomembnih modelov in rezultate, ki niso šli v glavno besedilo.
- Dodaj rezultate za *LOO po subjektih* in *LOO po posnetkih* pri vseh signalnih naborih: pogled, zenici, pogled+zenici in vsi signali.
- Dodaj vse izračunane metrike rezultatov, ne samo *accuracy* in makro-F1, ki ostaneta v glavnem besedilu.
- Razširjene metrike: balanced accuracy, weighted-F1, AUC, po potrebi precision/recall po razredih in rezultati po posameznih gubah.
- Dodatne matrike zmede: LOO po posnetkih, binarne naloge, najboljši negrafovski model in primerjave, ki niso nujne za glavno zgodbo.
- Dodaj rezultate primerjave različnih tipov grafovskih konvolucij oziroma GNN slojev, če ostanejo zunaj glavnega besedila.
- Dodaj rezultate 3-razredne klasifikacije in kratek komentar primerjave z izvirnim člankom podatkovne zbirke MAHNOB-HCI oziroma HCI-tagging.
- Dodatne porazdelitve podatkov: porazdelitev razredov po subjektih, po posnetkih, po izvorni čustveni oznaki in za binarni low/high nalogi.
- Dodatne slike ujemanja oznak: podrobnejše heatmape Table 6 razredov proti samoocenam in povzetki label-noise analize, če v glavnem besedilu ostane samo ena skupna slika

A.1 Preslikava čustvenih oznak v valenco

Preslikava čustvenih oznak v razrede valence sledi tabeli 6 izvirnega članka podatkovne zbirke MAHNOB-HCI [14]. Razredi niso tvorjeni z neposrednim rezanjem številskih samoocen valence, temveč iz poročane čustvene oznake posnetka. Pri binarni nalogi uporabimo samo skrajna razreda valence, nevtralni razred pa izločimo.

Tabela A.1: Preslikava čustvenih oznak v razrede valence po izvirnem članku podatkovne zbirke MAHNOB-HCI. Pri binarni nalogi uporabimo samo neprijetno in prijetno valenco.

Razred valence	Uporaba v binarni nalogi	Izvirne čustvene oznake
Neprijetna valenca	da	<i>fear, anger, disgust, sadness, anxiety</i>
Nevtralna valenca	ne	<i>surprise, neutral</i>
Prijetna valenca	da	<i>joy, happiness, amusement</i>

A.2 Razširjeni rezultati binarne klasifikacije valence

TODO:

- Tabele v tem razdelku so razširjena različica glavne primerjave iz poglavja 8.
- V besedilu dodatka po potrebi pojasni, da so preciznost, priklic in AUC makro povprečja; Micro-F1 je pri enooznačni klasifikaciji enak točnosti.
- Vrednosti so podane kot povprečje $\pm$ standardni odklon čez sedem gub prečnega preverjanja po subjektih.
- Vir podatkov za vse štiri tabele je `metric_summary_with_std.csv` iz reteniranega teka `RETAIN_2026-06-12_16-29-08`.

Tabela A.2: Razširjeni rezultati za množico signalov samo pogled. Vrednosti so povprečje $\pm$ standardni odklon čez sedem gub, v odstotkih.

Model	Točnost	Preciznost	Priklic	Makro F1	Micro-F1	AUC
Naključni	50,2 $\pm$ 1,8	50,2 $\pm$ 1,7	50,2 $\pm$ 1,7	50,1 $\pm$ 1,6	50,2 $\pm$ 1,8	50,2 $\pm$ 1,7
Večinski	52,5 $\pm$ 4,7	26,2 $\pm$ 2,4	50,0 $\pm$ 0,0	34,4 $\pm$ 1,9	52,5 $\pm$ 4,7	50,0 $\pm$ 0,0
SVM	67,5 $\pm$ 1,8	67,5 $\pm$ 1,7	67,4 $\pm$ 1,7	67,2 $\pm$ 1,7	67,5 $\pm$ 1,8	72,6 $\pm$ 2,5
LightGBM	69,7 $\pm$ 2,2	69,6 $\pm$ 2,5	69,6 $\pm$ 2,1	69,4 $\pm$ 2,3	69,7 $\pm$ 2,2	76,6 $\pm$ 2,0
MLP	67,0 $\pm$ 2,1	67,0 $\pm$ 2,0	66,9 $\pm$ 2,1	66,7 $\pm$ 2,3	67,0 $\pm$ 2,1	72,6 $\pm$ 2,7
GazeMAE/MOMENT	65,7 $\pm$ 3,2	66,5 $\pm$ 3,0	65,8 $\pm$ 2,8	65,2 $\pm$ 3,5	65,7 $\pm$ 3,2	71,9 $\pm$ 4,9
GCN	64,4 $\pm$ 4,8	64,6 $\pm$ 4,5	64,6 $\pm$ 4,7	64,1 $\pm$ 5,2	64,4 $\pm$ 4,8	70,7 $\pm$ 6,3
HeteroGCN-mean	61,7 $\pm$ 6,3	60,1 $\pm$ 9,9	61,3 $\pm$ 6,9	59,2 $\pm$ 11,2	61,7 $\pm$ 6,3	64,7 $\pm$ 11,2
HeteroGCN-MLP	65,9 $\pm$ 3,9	66,1 $\pm$ 3,8	66,2 $\pm$ 3,6	65,8 $\pm$ 4,0	65,9 $\pm$ 3,9	72,2 $\pm$ 4,7
Končni GNN	64,3 $\pm$ 5,0	64,8 $\pm$ 4,8	64,6 $\pm$ 4,8	64,0 $\pm$ 5,2	64,3 $\pm$ 5,0	70,3 $\pm$ 5,8

Tabela A.3: Razširjeni rezultati za množico signalov samo zenici. Vrednosti so povprečje $\pm$ standardni odklon čez sedem gub, v odstotkih.

Model	Točnost	Preciznost	Priklic	Makro F1	Micro-F1	AUC
Naključni	50,7 $\pm$ 2,0	50,7 $\pm$ 2,0	50,7 $\pm$ 2,0	50,6 $\pm$ 1,9	50,7 $\pm$ 2,0	50,7 $\pm$ 2,0
Večinski	52,2 $\pm$ 4,9	26,1 $\pm$ 2,4	50,0 $\pm$ 0,0	34,2 $\pm$ 2,0	52,2 $\pm$ 4,9	50,0 $\pm$ 0,0
SVM	62,1 $\pm$ 3,3	62,9 $\pm$ 3,0	61,7 $\pm$ 2,8	60,7 $\pm$ 3,6	62,1 $\pm$ 3,3	66,5 $\pm$ 3,4
LightGBM	63,1 $\pm$ 3,9	63,7 $\pm$ 2,7	62,7 $\pm$ 3,2	61,9 $\pm$ 4,3	63,1 $\pm$ 3,9	68,7 $\pm$ 3,4
MLP	62,0 $\pm$ 4,0	63,6 $\pm$ 3,9	61,5 $\pm$ 2,8	60,3 $\pm$ 4,6	62,0 $\pm$ 4,0	67,6 $\pm$ 3,6
GazeMAE/MOMENT	60,5 $\pm$ 2,5	60,8 $\pm$ 2,7	60,6 $\pm$ 2,7	60,1 $\pm$ 2,4	60,5 $\pm$ 2,5	64,9 $\pm$ 3,0
GCN	61,0 $\pm$ 3,4	65,1 $\pm$ 7,0	60,7 $\pm$ 3,0	58,4 $\pm$ 4,4	61,0 $\pm$ 3,4	67,5 $\pm$ 5,0
HeteroGCN-mean	58,6 $\pm$ 4,2	61,5 $\pm$ 6,8	58,3 $\pm$ 3,9	55,7 $\pm$ 6,1	58,6 $\pm$ 4,2	64,5 $\pm$ 3,6
HeteroGCN-MLP	59,1 $\pm$ 4,1	62,7 $\pm$ 6,7	58,8 $\pm$ 3,6	56,0 $\pm$ 6,1	59,1 $\pm$ 4,1	64,9 $\pm$ 5,0
Končni GNN	58,4 $\pm$ 4,1	62,4 $\pm$ 6,3	58,1 $\pm$ 3,5	54,5 $\pm$ 7,5	58,4 $\pm$ 4,1	66,4 $\pm$ 4,9

Tabela A.4: Razširjeni rezultati za množico signalov pogled in zenici. Vrednosti so povprečje $\pm$ standardni odklon čez sedem gub, v odstotkih.

Model	Točnost	Preciznost	Priklic	Makro F1	Micro-F1	AUC
Naključni	50,8 $\pm$ 2,2	50,7 $\pm$ 2,1	50,7 $\pm$ 2,1	50,6 $\pm$ 2,0	50,8 $\pm$ 2,2	50,7 $\pm$ 2,1
Večinski	52,1 $\pm$ 4,9	26,0 $\pm$ 2,4	50,0 $\pm$ 0,0	34,2 $\pm$ 2,0	52,1 $\pm$ 4,9	50,0 $\pm$ 0,0
SVM	70,5 $\pm$ 2,9	71,9 $\pm$ 2,1	70,3 $\pm$ 2,6	69,7 $\pm$ 3,4	70,5 $\pm$ 2,9	78,1 $\pm$ 1,9
LightGBM	69,6 $\pm$ 2,7	71,0 $\pm$ 2,0	69,5 $\pm$ 2,3	68,8 $\pm$ 3,1	69,6 $\pm$ 2,7	78,2 $\pm$ 2,2
MLP	68,7 $\pm$ 1,9	70,6 $\pm$ 1,8	68,5 $\pm$ 1,6	67,6 $\pm$ 2,5	68,7 $\pm$ 1,9	77,8 $\pm$ 2,4
GazeMAE/MOMENT	65,6 $\pm$ 4,7	66,5 $\pm$ 4,3	65,9 $\pm$ 4,0	65,2 $\pm$ 4,7	65,6 $\pm$ 4,7	73,0 $\pm$ 6,9
GCN	65,4 $\pm$ 2,8	67,2 $\pm$ 1,4	65,1 $\pm$ 1,8	63,9 $\pm$ 3,2	65,4 $\pm$ 2,8	73,1 $\pm$ 2,2
HeteroGCN-mean	63,8 $\pm$ 4,0	66,6 $\pm$ 2,0	63,3 $\pm$ 4,0	61,1 $\pm$ 6,9	63,8 $\pm$ 4,0	72,8 $\pm$ 2,7
HeteroGCN-MLP	64,2 $\pm$ 3,7	65,5 $\pm$ 3,1	63,8 $\pm$ 2,8	62,8 $\pm$ 3,6	64,2 $\pm$ 3,7	72,3 $\pm$ 3,7
Končni GNN	65,5 $\pm$ 2,3	66,6 $\pm$ 1,3	65,2 $\pm$ 1,5	64,4 $\pm$ 2,6	65,5 $\pm$ 2,3	73,2 $\pm$ 1,6

Tabela A.5: Razširjeni rezultati za množico signalov vsi signali. Vrednosti so povprečje $\pm$ standardni odklon čez sedem gub, v odstotkih.

Model	Točnost	Preciznost	Priklic	Makro F1	Micro-F1	AUC
Naključni	50,9 $\pm$ 2,0	50,8 $\pm$ 1,9	50,9 $\pm$ 1,9	50,7 $\pm$ 1,8	50,9 $\pm$ 2,0	50,9 $\pm$ 1,9
Večinski	52,2 $\pm$ 4,8	26,1 $\pm$ 2,4	50,0 $\pm$ 0,0	34,2 $\pm$ 2,0	52,2 $\pm$ 4,8	50,0 $\pm$ 0,0
SVM	68,6 $\pm$ 3,3	69,9 $\pm$ 2,1	68,3 $\pm$ 2,3	67,6 $\pm$ 3,3	68,6 $\pm$ 3,3	76,2 $\pm$ 2,6
LightGBM	69,0 $\pm$ 3,0	70,4 $\pm$ 2,2	69,0 $\pm$ 2,5	68,3 $\pm$ 3,2	69,0 $\pm$ 3,0	77,6 $\pm$ 2,7
MLP	67,2 $\pm$ 3,0	68,9 $\pm$ 2,6	67,1 $\pm$ 2,2	66,2 $\pm$ 2,7	67,2 $\pm$ 3,0	75,4 $\pm$ 3,6
GazeMAE/MOMENT	66,1 $\pm$ 3,1	66,8 $\pm$ 2,6	66,3 $\pm$ 3,0	65,6 $\pm$ 3,4	66,1 $\pm$ 3,1	72,2 $\pm$ 4,2
GCN	59,6 $\pm$ 8,4	61,5 $\pm$ 8,9	59,3 $\pm$ 8,0	57,6 $\pm$ 8,5	59,6 $\pm$ 8,4	65,7 $\pm$ 12,3
HeteroGCN-mean	61,8 $\pm$ 3,9	63,8 $\pm$ 3,7	61,3 $\pm$ 2,5	59,7 $\pm$ 4,0	61,8 $\pm$ 3,9	69,6 $\pm$ 3,1
HeteroGCN-MLP	60,5 $\pm$ 6,7	61,3 $\pm$ 9,3	59,9 $\pm$ 6,3	56,6 $\pm$ 10,7	60,5 $\pm$ 6,7	69,0 $\pm$ 6,2
Končni GNN	62,7 $\pm$ 4,5	64,6 $\pm$ 3,0	62,3 $\pm$ 3,1	60,8 $\pm$ 5,1	62,7 $\pm$ 4,5	70,2 $\pm$ 3,4

A.3 Ujemanje izpeljanih oznak s samoocenami

TODO: Dodaj podrobnejše heatmape oziroma povzetke analize ujemanja razredov iz tabele 6 s številskimi samoocenami. Ta dodatek naj utemelji, zakaj je vznurjenost v uporabljenem podnaboru šumnejša ciljna oznaka kot valenca.

A.4 Izbira tipa grafovske konvolucije

Za preverjanje izbire grafovskega operatorja smo izvedli dodatni poskus na binarni nalogi valence z naborom signalov pogled+zenici. Primerjali smo osnovni homogeni grafovski model in uteženo heterogeno arhitekturo z različnimi tipi grafovskih konvolucij. Pri osnovnem modelu so bile povezave neutružene, pri uteženi heterogeni arhitekturi pa so različice **GCNConv**, **GraphConv** in **GINEConv** uporabile naučene skalarne uteži povezav. Različica **GATConv** teh skalarne uteži ni uporabila, saj pomembnost povezav modelira z notranjim mehanizmom pozornosti.

Če bi izbirali izključno najboljši operator za ta dodatni poskus, bi pri neutruženem osnovnem modelu izbrali **GINConv**, pri uteženi heterogeni arhitekturi pa **GraphConv**. V glavnih poskusih tega nismo storili, ker bi s tem hkrati

spremenili več delov arhitekture in otežili primerjavo med osnovnim GCN in uteženo heterogeno različico. **GCNConv** se je v obeh skupinah uvrstil približno v sredino: ni bil najboljši operator, hkrati pa tudi ni izrazito odstopal navzdol. Zato smo ga obravnavali kot dober kompromis med enostavnostjo, konsistentnostjo eksperimentalne zasnove in rezultati. Glavni namen naloge ni bil poiskati absolutno najboljši grafovski operator, temveč primerjati grafovsko predstavitev in arhitekturne stopnje pri enakem, razmeroma standardnem operatorju posredovanja sporočil.

Tabela A.6: Primerjava tipov grafovskih konvolucij pri naboru signalov pogled+zenici.

Arhitektura	Operator	Accuracy	Makro-F1	Opomba
Osnovni GCN	GCNConv	0,6474	0,6337	neuteženi homogeni graf
Osnovni GCN	GATConv	0,6484	0,6336	neutežena pozor- nost
Osnovni GCN	GraphConv	0,6367	0,6192	neuteženi homogeni graf
Osnovni GCN	GINConv	0,6613	0,6501	najboljši neuteženi rezultat
HeteroGCN-MLP-w	GCNConv	0,6391	0,6103	naučene uteži povezav
HeteroGCN-MLP-w	GATConv	0,6370	0,6116	pozornost brez skalarnih uteži
HeteroGCN-MLP-w	GraphConv	0,6606	0,6503	najboljši uteženi rezultat
HeteroGCN-MLP-w	GINEConv	0,6325	0,6028	značilke in uteži povezav

Dodatek B

Hiperparametri


TODO:

- tabela hiperparametrov za primerjalne modele;
- tabela hiperparametrov za GazeMAE + MLP;
- tabela hiperparametrov za osnovni GCN;
- tabela hiperparametrov za predlagani GNN;
- predlagani GNN: `GCNConv, hidden_channels=128, num_layers=3;`
- predlagani GNN: `relation_pooling=mlp, graph_pooling=attention;`
- osnovni GCN: uporabljeni isti splošni parametri kot pri predlaganem GNN; posebej navesti readout funkcijo;
- trenutni graf: `kt=2, ks=2, fixation_dilation_k=3;`
- dodaj rezultate mrežnega iskanja velikostnih hiperparametrov GNN: `kt, ks, kf`, število slojev in dimenzija skritih predstavitev;
- trenutne edge značilke: `use_delta_distance_edge_feature=true;`
- trenutni trening: učna stopnja $5 \cdot 10^{-5}$, velikost mini-serije 256, največ 500 epoh, potrpežljivost 20;
- dodaj kratek opis uporabljene strojne in programske opreme za poganjanje poskusov: CPU, GPU, RAM, operacijski sistem, različica Pythona, ključne knjižnice in različice paketov;
- dodaj kratko poročilo o času učenja oziroma trajanju poskusov,


Dodatek C

Dodatne vizualizacije grafov


Ta dodatek dopolnjuje osrednji primer grafovske konstrukcije iz poglavja 5. Slike prikazujejo isti izsek časovnega okna, vendar ločeno za posamezne tipe povezav.



Slika C.1: Primer časovnih povezav v izseku grafa. Povezave sledijo časovni urejenosti meritev in ločijo smer naprej ter nazaj.



Slika C.2: Primer prostorskih povezav v izseku grafa. Povezave nastanejo med meritvami s podobnim položajem pogleda, zato niso nujno omejene na časovno zaporedne meritve.



Slika C.3: Primer fiksacijskih povezav v izseku grafa. Povezave združujejo meritve, ki pripadajo isti zaznani fiksaciji, pri čemer razširjena konstrukcija ohrani redkejšo povezovalno strukturo.

TODO:

- Po potrebi dodaj primer celotnega 10-sekundnega grafa.
- Po potrebi dodaj ločen prikaz razširjenih fiksacijskih povezav znotraj ene fiksacije za razlago parametra k_f .
- Po potrebi dodaj prikaz prekrivanja relacij med istimi pari vozlišč s krivljenimi povezavami.

Dodatek D

Diagnostika predstavitev modela

TODO:

- Dodaj variance po plasteh, kosinusne podobnosti, porazdelitve logitov in dodatne slike kolapsa predstavitev.
- Dodaj per-fold krivulje učne in validacijske izgube, če so v glavnem besedilu prikazane samo agregirane ali reprezentativne krivulje.
- Dodaj porazdelitve entropije napovednih verjetnosti in razpona logitov za osnovni GCN ter predlagani GNN.
- Dodaj porazdelitve naučenih uteži povezav po relacijah `temporal_forward`, `temporal_backward`, `spatial` in `fixation`, če so artefakti na voljo.
- UMAP naučenih predstavitev grafa dodaj sem, če je slika uporabna kot diagnostika, vendar ni dovolj močna za glavno besedilo. Pri vsakem UMAP prikazu zapiši, ali je barvan po razredu, subjektu ali posnetku.
- Če UMAP kaže predvsem subjektne ali stimulusne gručice, ga interpretiraj kot omejitev oziroma opozorilo, ne kot dokaz razredne ločljivosti.

D.1 Diagnostika prekomernega glajenja

TODO: V tem razdelku poročaj diagnostiko iz GFM-for-eyetracker/results/quick_v1_v2_comparison/RETAIN_2026-06-12_16-29-08. Interpretacija naj bo informativna: rezultati ne kažejo jasnega kolapsa predstavitev oziroma prekomernega glajenja pri glavnih grafovskih modelih. Posebej omeni, da je signalni nabor `pupil_only` šibkejši in ima bolj neodločne napovedi, vendar tega ne predstavimo kot dokaz sistemskega kolapsa GNN.

Tabela D.1: TODO: Diagnostika naučenih predstavitev in izhodov najboljšega grafovskega modela za posamezen signalni nabor pri binarni klasifikaciji valence. Vrednosti so agregirane po testnih gubah.

Signalni nabor	Najboljši GNN	Makro-F1	Urav. točnost	Razpon logitov	Entropija	Varianca predstavitev	Kos. podobnost
<code>all_signals</code>	HeteroGCN-MLP-w	0,608	0,623	3,31	0,545	0,352	0,409
<code>gaze_only</code>	HeteroGCN-MLP	0,658	0,662	3,93	0,583	0,291	0,307
<code>gaze_pupil</code>	HeteroGCN-MLP-w	0,644	0,652	3,38	0,582	0,336	0,360
<code>pupil_only</code>	GCN	0,584	0,607	1,40	0,653	0,258	0,569

Dodatek E

Zgodovinski poskusi na eSEEd_v2

TODO: Če želiš ohraniti eSEEd_v2 rezultate, jih daj sem: kratka motivacija, glavne težave, zakaj ni glavni dataset, brez pretiranega širjenja glavne zgodbe.

Literatura

- [1] Jimmy Lei Ba, Jamie Ryan Kiros in Geoffrey E. Hinton. „Layer Normalization“. V: *arXiv preprint arXiv:1607.06450* (2016). URL: <https://arxiv.org/abs/1607.06450>.
- [2] Dzmitry Bahdanau, Kyunghyun Cho in Yoshua Bengio. „Neural Machine Translation by Jointly Learning to Align and Translate“. V: *International Conference on Learning Representations*. 2015. URL: <https://arxiv.org/abs/1409.0473>.
- [3] Louise Gillian C. Bautista in Prospero C. Naval. „GazeMAE: General Representations of Eye Movements Using a Micro-Macro Autoencoder“. V: *2020 25th International Conference on Pattern Recognition (ICPR)*. IEEE, 2021, str. 7004–7011. DOI: 10.1109/ICPR48806.2021.9412761.
- [4] Tomi Božak, Mitja Luštrek in Gašper Slapničar. „Feature-Based Emotion Classification Using Eye-Tracking Data“. V: *Information Society 2024*. Ljubljana, Slovenia, 2024. DOI: 10.70314/is.2024.scai.9988.
- [5] Justin Gilmer in sod. „Neural Message Passing for Quantum Chemistry“. V: *Proceedings of the 34th International Conference on Machine Learning*. Zv. 70. Proceedings of Machine Learning Research. PMLR, 2017, str. 1263–1272.
- [6] Ian Goodfellow, Yoshua Bengio in Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.

- [7] Mononito Goswami in sod. „MOMENT: A Family of Open Time-Series Foundation Models“. V: *Proceedings of the 41st International Conference on Machine Learning*. Zv. 235. Proceedings of Machine Learning Research. PMLR, 2024, str. 16115–16152. URL: <https://proceedings.mlr.press/v235/goswami24a.html>.
- [8] Kaiming He in sod. „Deep Residual Learning for Image Recognition“. V: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016, str. 770–778. DOI: 10.1109/CVPR.2016.90.
- [9] Dan Hendrycks in Kevin Gimpel. „Gaussian Error Linear Units (GELUs)“. V: *arXiv preprint arXiv:1606.08415* (2016). URL: <https://arxiv.org/abs/1606.08415>.
- [10] Ming Jin in sod. „A Survey on Graph Neural Networks for Time Series: Forecasting, Classification, Imputation, and Anomaly Detection“. V: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 46.12 (2024), str. 10466–10485. DOI: 10.1109/TPAMI.2024.3443141.
- [11] Thomas N. Kipf in Max Welling. „Semi-Supervised Classification with Graph Convolutional Networks“. V: *International Conference on Learning Representations*. 2017. URL: <https://openreview.net/forum?id=SJU4ayYgl>.
- [12] Yujia Li in sod. „Gated Graph Sequence Neural Networks“. V: *International Conference on Learning Representations*. 2016. URL: <https://arxiv.org/abs/1511.05493>.
- [13] Jia Zheng Lim, James Mountstephens in Jason Teo. „Emotion Recognition Using Eye-Tracking: Taxonomy, Review and Current Challenges“. V: *Sensors* 20.8 (2020), str. 2384. DOI: 10.3390/s20082384.
- [14] Mohammad Soleymani in sod. „A Multimodal Database for Affect Recognition and Implicit Tagging“. V: *IEEE Transactions on Affective Computing* 3.1 (2012), str. 42–55. DOI: 10.1109/T-AFFC.2011.25.

- [15] Nitish Srivastava in sod. „Dropout: A Simple Way to Prevent Neural Networks from Overfitting“. V: *Journal of Machine Learning Research* 15.56 (2014), str. 1929–1958. URL: <http://jmlr.org/papers/v15/srivastava14a.html>.
- [16] Paweł Tarnowski in sod. „Eye-Tracking Analysis for Emotion Recognition“. V: *Computational Intelligence and Neuroscience* 2020 (2020), str. 2909267. DOI: 10.1155/2020/2909267.
- [17] Petar Veličković in sod. „Graph Attention Networks“. V: *International Conference on Learning Representations*. 2018. URL: <https://openreview.net/forum?id=rJXMpikCZ>.
- [18] Yang Wang, Zhao Lv in Yongjun Zheng. „Automatic Emotion Perception Using Eye Movement Information for E-Healthcare Systems“. V: *Sensors* 18.9 (2018), str. 2826. DOI: 10.3390/s18092826.
- [19] Qun Wu in sod. „Emotion Classification on Eye-Tracking and Electroencephalograph Fused Signals Employing Deep Gradient Neural Networks“. V: *Applied Soft Computing* 110 (2021), str. 107752. DOI: 10.1016/j.asoc.2021.107752.
- [20] Bing Yu, Haoteng Yin in Zhanxing Zhu. „Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting“. V: *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence*. International Joint Conferences on Artificial Intelligence Organization, 2018, str. 3634–3640. DOI: 10.24963/ijcai.2018/505.
- [21] Tianyi Zhang in sod. „RCEA: Real-Time, Continuous Emotion Annotation for Collecting Precise Mobile Video Ground Truth Labels“. V: *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, 2020, str. 1–15. DOI: 10.1145/3313831.3376808.