

UNIVERZA V LJUBLJANI
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO

Tomi Božak

**Grafovske nevronske mreže za
klasifikacijo čustvenih oznak iz podatkov
sledilnika pogleda**

DIPLOMSKO DELO

UNIVERZITETNI ŠTUDIJSKI PROGRAM
PRVE STOPNJE
RAČUNALNIŠTVO IN INFORMATIKA

MENTOR: izr. prof. dr. Lovro Šubelj
SOMENTOR: doc. dr. Gašper Slapničar

Ljubljana, 2026

To delo je ponujeno pod licenco *Creative Commons Priznanje avtorstva-Deljenje pod enakimi pogoji 2.5 Slovenija* (ali novejšo različico). To pomeni, da se tako besedilo, slike, grafi in druge sestavine dela kot tudi rezultati diplomskega dela lahko prosto distribuirajo, reproducirajo, uporabljajo, priobčujejo javnosti in predelujejo, pod pogojem, da se jasno in vidno navede avtorja in naslov tega dela in da se v primeru spremembe, preoblikovanja ali uporabe tega dela v svojem delu, lahko distribuira predelava le pod licenco, ki je enaka tej. Podrobnosti licence so dostopne na spletni strani creativecommons.si ali na Inštitutu za intelektualno lastnino, Streliška 1, 1000 Ljubljana.



Izvorna koda diplomskega dela, njeni rezultati in v ta namen razvita programska oprema je ponujena pod licenco GNU General Public License, različica 3 (ali novejša). To pomeni, da se lahko prosto distribuira in/ali predeluje pod njenimi pogoji. Podrobnosti licence so dostopne na spletni strani <http://www.gnu.org/licenses/>.

Besedilo je oblikovano z urejevalnikom besedil L^AT_EX.

Kandidat: Tomi Božak

Naslov: Grafovske nevronske mreže za klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda

Vrsta naloge: Diplomaska naloga na univerzitetnem programu prve stopnje

Mentor: izr. prof. dr. Lovro Šubelj

Somentor: doc. dr. Gašper Slapničar

Opis:

TODO: Besedilo teme diplomskega dela prepisi iz študijskega informacijskega sistema.

Title: Graph Neural Networks for Classification of Emotional Labels from Eye-Tracking Data

Description:

TODO: Prevedi uradni opis teme diplomskega dela iz STUDIS-a.

TODO: Zahvaliti se IJS, da so omogočili uporabo njihove infrastrukture. Zahvaliti se mentorju Lovru za nasvete pri razvoju GNN in somentorju za nasvete pri raziskovalnem delu. Zahvaliti se tudi Mitji Luštreku za nasvete pri raziskovalnem delu. (tudi FRIju in družini al je too much?)

TODO: Posvetilo lahko odstraniš, če ga ne
želiš.

Kazalo

Povzetek

Abstract

Razširjeni povzetek	1
1 Uvod	5
1.1 Raziskovalni problem	5
1.1.1 Raziskovalna vprašanja	6
1.2 Doprinosi naloge	6
1.3 Struktura naloge	7
2 Teoretično ozadje	9
2.1 Grafi	10
2.1.1 Osnovna definicija grafa	10
2.1.2 Usmerjeni, uteženi in heterogeni grafi	10
2.2 Grafske nevroonske mreže	10
2.2.1 Posredovanje sporočil	11
2.2.2 Klasifikacija na ravni grafa	11
2.2.3 Prekomerno glajenje in kolaps predstavitev	12
2.3 Podatki sledilnika pogleda	12
2.3.1 Merjeni signali	12
2.3.2 Časovna narava signala	12
2.4 Čustvena stanja: valenca in vzburjenost	13

2.4.1	Dimenzijski opis čustev	13
2.4.2	3-razredna klasifikacija	13
3	Sorodna dela	15
3.1	Prepoznavanje čustev iz podatkov sledilnika pogleda	15
3.1.1	Ročno oblikovane značilke	15
3.1.2	Naučene predstavitve	16
3.2	Podatkovna zbirka MAHNOB-HCI	16
3.2.1	Izvirni protokol za valenco in vzburjenost	16
3.2.2	Razlika do eksperimentalne postavitve v tej nalogi . . .	16
3.3	Grafovske nevronske mreže za časovno-prostorske podatke . .	17
3.3.1	Uporaba na oknih podatkov pogleda	18
3.4	Učenje predstavitev iz podatkov pogleda in GazeMAE	18
3.4.1	GazeMAE	18
3.5	Položaj te naloge glede na sorodna dela	19
4	Podatki in predobdelava	21
4.1	Podatkovna zbirka MAHNOB-HCI	21
4.1.1	Izvirna zbirka	21
4.1.2	Lokalni podnabor	22
4.2	Ciljne oznake	22
4.2.1	Izvor čustvenih oznak	22
4.2.2	Preslikava v razrede valence in vzburjenosti	22
4.3	Priprava vhodnih signalov	24
4.3.1	Uporabljeni stolpci	25
4.3.2	Čiščenje in filtriranje podatkov	25
4.4	Normalizacija	26
4.4.1	Normalizacija pri grafovskih modelih	26
4.4.2	Normalizacija pri tabelaričnih modelih	26
4.4.3	Preprečevanje uhajanja informacij	26
4.5	Segmentacija v časovna okna	27
4.5.1	Dolžina okna	27

4.5.2	Dodelitev oznake oknu	27
4.5.3	Minimalno število vzorcev	27
4.6	Predhodni poskus z zbirko eSEEd_v2	28
5	Grafovski predstavitev podatkov sledilnika pogleda	31
5.1	Učni vzorec kot graf	33
5.1.1	Definicija grafa	33
5.1.2	Oznaka grafa	33
5.2	Vozlišča	34
5.2.1	Definicija vozlišča	34
5.2.2	Značilke vozlišč	34
5.3	Heterogena grafovski predstavitev	35
5.3.1	Tipi relacij	35
5.3.2	Zakaj ločimo relacije	36
5.4	Povezave	36
5.4.1	Časovne povezave	36
5.4.2	Prostorske povezave	38
5.4.3	Fiksacijske povezave	39
5.5	Uteži povezav	43
5.5.1	Značilke povezav	43
5.5.2	Normalizacija uteži	44
5.6	Statistika grafov	45
5.6.1	Število vozlišč in povezav	46
5.6.2	Računska zahtevnost	46
6	Primerjani modeli in predlagana arhitektura	49
6.1	Negrafovski osnovni modeli	51
6.1.1	MLP	52
6.2	Negrafovski predstavnik SOTA: GazeMAE + MLP	52
6.3	Osnovni GCN	53
6.3.1	Izbira grafovske konvolucije	54
6.4	Predlagani prostorsko-časovni heterogeni GNN	55

6.4.1	Pregled arhitekture	55
6.4.2	Relacijsko posredovanje sporočil in uteži povezav . . .	56
6.4.3	Fuzija relacijskih predstavitev	57
6.4.4	Predstavitev grafa in napoved	58
6.4.5	Stabilizacija učenja	59
7	Eksperimentalni protokol	61
7.1	Eksperimentalne naloge	61
7.1.1	Valenca in vzburjenost	62
7.2	Validacijska protokola	63
7.2.1	Prečno preverjanje z izpuščanjem enega primerka . . .	63
7.2.2	Subject LOO	65
7.2.3	Recording LOO	65
7.3	Metrike	66
7.4	Spremljanje učenja in diagnostika	67
7.5	Glavna primerjava modelov	68
7.6	Ablacijska študija	71
8	Rezultati	75
8.1	Porazdelitev razredov	78
8.1.1	3-razredna valenca	78
8.1.2	3-razredna vzburjenost	79
8.1.3	Binarni nalogi	79
8.2	Rezultati za 3-razredno valenco	80
8.2.1	Subject LOO	80
8.2.2	Recording LOO	81
8.2.3	Interpretacija rezultatov	82
8.3	Rezultati za 3-razredno vzburjenost	83
8.3.1	Subject LOO	83
8.3.2	Recording LOO	84
8.4	Binarna klasifikacija valence in vzburjenosti	85
8.4.1	Binarna valenca	85

8.4.2	Binarna vzburjenost	86
8.5	Primerjava validacijskih protokolov	87
8.5.1	Posploševanje na nove subjekte	87
8.5.2	Posploševanje na nove posnetke	87
8.6	Analiza oznak in napak	88
8.6.1	Ujemanje oznak s samoocenami	88
8.6.2	Matrike zmede	89
8.7	Ablacijska študija	90
8.7.1	Vpliv vhodnih signalov in povezav	90
8.8	Analiza učenja in notranjih predstavitev	91
8.8.1	Krivulje izgub	91
8.8.2	Predstavitve in grafovske diagnostike	92
9	Diskusija	93
9.1	Ali grafovska predstavitev pomaga?	94
9.2	Vloga časovnih in prostorskih povezav	95
9.3	Primerjava z GazeMAE	96
9.4	Stabilnost učenja in notranje predstavitve	96
9.5	Primerjava z izvirnim MAHNOB-HCI pristopom	97
9.6	Omejitve	97
9.7	Možnosti nadaljnjega dela	98
10	Zaključek	99
A	Dodatni rezultati	103
A.1	Izbira tipa grafovske konvolucije	105
B	Hiperparametri	107
C	Dodatne vizualizacije grafov	109
D	Diagnostika predstavitev modela	111
E	Zgodovinski poskusi na eSEEd_v2	113

Seznam uporabljenih kratic

kratica	angleško	slovensko
AUC	area under the curve	ploščina pod krivuljo
F1	F1 score	mera F1
GAT	graph attention network	grafovska pozornostna mreža
GCN	graph convolutional network	grafovska konvolucijska mreža
GFM	graph foundation model	grafovski temeljni model
GNN	graph neural network	grafovska nevronska mreža
LOO	leave-one-out	izpusti enega
LORO	leave-one-recording-out	izpusti en posnetek
LOSO	leave-one-subject-out	izpusti en subjekt
MLP	multilayer perceptron	večslojni perceptron
SVM	support vector machine	metoda podpornih vektorjev

Povzetek

Naslov: Grafovske nevronske mreže za klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda

Avtor: Tomi Božak

V diplomski nalogi raziskujemo uporabo grafovskih nevronske mreže za prepoznavo afektivnih stanj iz podatkov sledilnika pogleda.

TODO: Povzetek prepisati po končnih rezultatih: glavna naloga naj bo binarna klasifikacija, glavna primerjava pa modeli pri naborih *gaze*, *gaze+pupil* in *all*; GazeMAE omeni kot *gaze-only* referenco, MOMENT/*pupil-only* samo, če bo dejansko izveden.

TODO:

- Povzetek sme povzeti grafovsko predstavitev v enem stavku, ne sme pa ponavljati definicij grafa, heterogenosti ali uteži povezav.
- Uporabi enako terminologijo kot v glavnem besedilu: *časovno-prostorski graf* in *časovno-prostorska grafovska predstavitev*, ne mešaj s *prostorsko-časovni graf*.

Osrednji metodološki problem je predstavitev časovnega okna meritev pogleda kot prostorsko-časovnega grafa, v katerem vozlišča predstavljajo posamezne meritve, povezave pa opisujejo časovno bližino, prostorsko bližino in pripadnost isti fiksaciji. Na takšni predstavitvi razvijemo in ovrednotimo grafovski model za večrazredno klasifikacijo valence in vzburjenosti (ang. arousal).

Eksperimentalno evalvacijo izvedemo na podatkovni zbirki MAHNOB-HCI z dvema validacijskima protokoloma: delitvijo po subjektih in delitvijo po posnetkih. Grafovske modele primerjamo z ne-grafovskimi modeli strojnega učenja ter s predstavitvijo GazeMAE kot predstavnikom sodobnih metod učenja predstavitev iz podatkov pogleda. Poleg končnih klasifikacijskih rezultatov analiziramo tudi vpliv posameznih komponent grafovske konstrukcije, vključno s časovnimi povezavami, prostorskimi povezavami, fiksacijskimi povezavami, značilkami zenice in utežmi povezav.

Glavno raziskovalno vprašanje naloge je, ali lahko prostorsko-časovna grafovska predstavitev eye-tracking oken izboljša klasifikacijo afektivnih stanj v primerjavi z ne-grafovskimi modeli na enakih vhodnih oknih.

Ključne besede: grafovske nevronske mreže, prostorsko-časovni grafi, sledilnik pogleda, prepoznavanje čustev, afektivno računalništvo, strojno učenje.

Abstract

Title: Graph Neural Networks for Classification of Emotional Labels from Eye-Tracking Data

Author: Tomi Božak

This thesis investigates the use of graph neural networks for affective state recognition from eye-tracking data.

TODO: Rewrite the abstract after the final experiments: the main task should be binary classification, and the main comparison should cover models under the *gaze*, *gaze+pupil*, and *all* input sets; describe GazeMAE as a *gaze-only* reference and mention MOMENT/*pupil-only* only if the experiment is actually completed.

The central methodological problem is the representation of a temporal window of gaze measurements as a spatio-temporal graph, where nodes correspond to individual samples and edges encode temporal proximity, spatial proximity, and shared fixation membership. Based on this representation, we develop and evaluate a graph-based model for three-class classification of valence and arousal.

The experimental evaluation is performed on the MAHNOB-HCI dataset using two validation protocols: leave-one-subject-out and leave-one-recording-out evaluation. Graph-based models are compared against non-graph machine learning baselines and against GazeMAE as a representative of modern gaze representation learning methods. In addition to final classification performance, we analyze the contribution of individual components of the

graph construction, including temporal edges, spatial edges, fixation edges, pupil features, and edge weights.

The main research question of the thesis is whether a spatio-temporal graph representation of eye-tracking windows can improve affective state classification compared to non-graph models trained on the same input windows.

Keywords: graph neural networks, spatio-temporal graphs, eye tracking, emotion recognition, affective computing, machine learning.

Razširjeni povzetek

TODO: To poglavje napiši na koncu, ko bodo znani rezultati. Struktura naj bo podobna raziskovalnemu članku:

- novo izhodišče: glavna evalvacija naj bo binarna klasifikacija in primerjava modelov pri naborih *gaze*, *gaze+pupil* in *all*;
- GazeMAE opiši kot *gaze-only* referenco; *pupil-only*/MOMENT omeni samo, če bo eksperiment dokončan;
- motivacija: zakaj grafovska predstavitev podatkov sledilnika pogleda;
- predlagana metoda: kako iz časovnih oken nastanejo grafi;
- eksperimentalni protokol: MAHNOB-HCI, 3-razredna valenca/vzbujenost, subject LOO in recording LOO;
- rezultati: primerjava z baseline modeli, GazeMAE in GNN arhitekturami;
- sklep: kaj grafovska predstavitev prispeva in kje so omejitve.

I Grafovske nevronske mreže in motivacija

TODO: Kratko povzemi, kaj so grafovske nevronske mreže, zakaj so primerne za podatke z relacijsko, prostorsko ali časovno strukturo in zakaj je eye-tracking okno smiselno obravnavati kot prostorsko-časovni graf.

II Grafovski predstavitev podatkov sledilnika pogleda

TODO:

- Razširjeni povzetek naj grafovski predstavitev samo povzame; natančne definicije ostanejo v poglavju 5.
- Ne ponavljaj formul za konstrukcijo povezav, značilk povezav ali normalizacijo uteži.
- Uteži povezav omeni samo kot arhitekturno komponento, definirano v poglavju 6; ne kot del osnovne definicije vhodnega grafa.
- vozlišče = ena meritev sledilnika pogleda;
- značilke vozlišča = koordinati pogleda (x, y) , leva/desna zenica, `time-window-normalized`, `distance-avg`, `fixation-duration`;
- časovne povezave = bližina vzorcev v času, $k_t = 2$;
- prostorske povezave = bližina vzorcev v prostoru pogleda, $k_s = 2$;
- fiksacijske povezave = razširjene povezave znotraj fiksacije, $k_f = 3$;
- uteži povezav = naučene predznačene uteži iz značilk relacije;
- `fixation-index` = grupiranje, ne numerična značilka vozlišča.

III Modeliranje in eksperimentalna evalvacija

TODO: Kratko povzemi uporabljeno podatkovno zbirko MAHNOB-HCI, analizi 3-razredne valence in 3-razredne vznemirjenosti, validacijo subject LOO in recording LOO ter primerjane modele: SVM, LightGBM, MLP, GazeMAE + MLP, osnovni GCN in predlagani GNN.

IV Rezultati in sklep

TODO: Dopolni po zaključku eksperimentov: kateri model je najboljši pri valenci, kateri pri vzburjenosti, ali GNN izboljša rezultate glede na ne-grafovske baseline modele, katere komponente grafa najbolj prispevajo k rezultatu ter glavne omejitve in prihodnje delo.

Poglavje 1

Uvod

Za učenje iz podatkov, kjer niso pomembne zgolj lastnosti posameznih elementov, ampak tudi odnosi med njimi, lahko uporabimo grafovske nevronske mreže (GNN) [6, 10]. Primer takšnih podatkov so podatki sledilnika pogleda. Meritvam sledilnika pogleda lahko smiselno določimo časovne in prostorske odnose in jim s tem priredimo časovno-prostorski graf. Na tem grafu se z grafovsko nevronske mreže učimo predstavitev vozlišč in grafov, ki jih uporabimo za klasifikacijo grafa. Podatki, uporabljeni v tej nalogi, so označeni s čustvenimi oznakami valence, zato GNN učimo binarno klasifikacijo valence, rezultate pa primerjamo z rezultati uveljavljenih negrafovskih pristopov. Eksperimentalno primerjavo izvedemo na štirih signalnih naborih: samo koordinatah pogleda (pogled), samo velikostih zenic (zenici), združenih koordinatah pogleda in velikostih zenic (pogled+zenici) ter celotnem naboru razpoložljivih signalov (vsi signali).

1.1 Raziskovalni problem

Raziskovalni problem naloge je zasnova, implementacija in ovrednotenje grafovskih predstavitev podatkov sledilnika pogleda za klasifikacijo valence.

1.1.1 Raziskovalna vprašanja

Glavno raziskovalno vprašanje je:

RV1: Kakšna je klasifikacijska uspešnost grafovske nevronske mreže za binarno klasifikacijo valence iz podatkov sledilnika pogleda v primerjavi s klasifikacijsko uspešnostjo uveljavljenih negrafovskih pristopov?

Dodatna podvprašanja so:

PV1: Kako podatke sledilnika pogleda smiselno predstaviti kot časovno-prostorski graf?

PV2: Kako se uspešnost klasifikatorjev razlikuje med posameznimi nabori signalov sledilnika pogleda?

PV3: Kako se klasifikacijska uspešnost spreminja z večjo kompleksnostjo grafovske nevronske mreže?

1.2 Doprinosi naloge

Glavni doprinosi diplomske naloge so:

1. zasnova časovno-prostorske grafovske predstavitve časovnih oken podatkov sledilnika pogleda;
2. ovrednotenje arhitekturne lestvice grafovskih modelov za klasifikacijo čustvenih oznak iz podatkov sledilnika pogleda;
3. primerjava klasifikacijske uspešnosti pri različnih signalnih naborih;
4. primerjava grafovskih modelov z uveljavljenimi negrafovskimi modeli in zamrznjenimi prednaučenimi predstavitvenimi modeli.

[Ali rabimo te doprinose ali raje odstranimo, glede na to da se samo ponovijo raziskovalna vprašanja?]

1.3 Struktura naloge

V poglavju 2 predstavimo teoretično ozadje grafov, grafovskih nevronske mreže, podatkov sledilnika pogleda in afektivnega računalništva. V poglavju 3 predstavimo sorodna dela, vključno z uporabo podatkovne zbirke MAHNOB-HCI in metodami učenja predstavitev iz podatkov pogleda. Poglavje 4 opisuje uporabljene podatke, ciljne oznake in predobdelavo. V poglavju 5 opišemo konstrukcijo časovno-prostorskega grafa. Poglavje 6 predstavi uporabljene modele. V poglavju 7 opišemo eksperimentalni protokol, v poglavju 8 pa rezultate glavne primerjave modelov in signalnih naborov. Poglavje 9 vsebuje interpretacijo rezultatov, omejitve in možnosti nadaljnjega dela. Nalogo sklenemo v poglavju 10.

Poglavje 2

Teoretično ozadje

V tem poglavju predstavimo metodološke pojme, ki so potrebni za razumevanje grafov, grafovskih nevronske mreže, podatkov sledilnika pogleda ter valence.

TODO:

- To poglavje naj bo edino mesto za splošne definicije: graf, usmerjenost, uteženost, homogenost/heterogenost, posredovanje sporočil, READOUT in prekomerno glajenje.
- Ne opisuj podrobne konstrukcije grafa iz podatkov sledilnika pogleda; ta mora ostati v poglavju 5.
- Ne opisuj arhitekturne uporabe relacij, naučenih uteži povezav ali attention READOUT; to sodi v poglavje 6.
- Uvod poglavja uskladi z novo zgodbo: glavna naloga je binarna klasifikacija valence, vzburjenost pa je ozadje oziroma sekundarni kontekst, če ostane v nalogi.

2.1 Grafi

2.1.1 Osnovna definicija grafa

Graf definiramo kot

$$G = (V, E), \quad (2.1)$$

kjer je V množica vozlišč, $E \subseteq V \times V$ pa množica povezav med vozlišči. Vozlišča praviloma vsebujejo značilke $\mathbf{x}_v$, ki jih zapišemo v matriko

$$X \in \mathbb{R}^{|V| \times d}, \quad (2.2)$$

kjer je d število značilk posameznega vozlišča. Povezavo med vozliščema i in j označimo z $e_{ij} \in E$.

2.1.2 Usmerjeni, uteženi in heterogeni grafi

V usmerjenih grafih ima povezava določeno izvorno in ponorno vozlišče, zato velja $e_{ij} \neq e_{ji}$. V neusmerjenih grafih povezave nimajo smeri, zato velja $e_{ij} = e_{ji}$.

Povezave lahko vsebujejo tudi uteži. Utež povezave med vozliščema i in j označimo z w_{ij} . Za neutružene povezave si lahko predstavljamo, da imajo utež $w_{ij} = 1$. Če imajo povezave več uteži, jih zapišemo kot vektor $\mathbf{e}_{ij}$ [6].

Homogeni in heterogeni grafi

Homogeni graf je graf, ki ne loči različnih vrst vozlišč ali povezav. Heterogeni graf vsebuje vsaj dve različni vrsti vozlišč ali povezav. V tej nalogi uporabljamo heterogeno grafovsko predstavitev, saj ločimo več tipov povezav.

2.2 Grafovske nevronske mreže

Grafovske nevronske mreže so razred nevronskih mrež, namenjen učenju nad podatki, ki jih naravno predstavimo z grafom [6, 10, 17]. Cilj GNN je naučiti

se predstavitev vozlišč, povezav ali celotnega grafa tako, da model pri izračunu predstavitve posameznega vozlišča upošteva tudi njegovo lokalno okolico.

2.2.1 Posredovanje sporočil

Osnovna ideja GNN je *posredovanje sporočil* [6]. Vsako vozlišče v posamezni plasti prejme informacije od svojih sosedov, jih agregira in na podlagi zbranih informacij posodobi svojo predstavitev.

Splošna oblika plasti

Splošno plast posredovanja sporočil lahko zapišemo kot

$$\mathbf{h}_v^{(k)} = \phi^{(k)} \left(\mathbf{h}_v^{(k-1)}, \bigoplus_{u \in \mathcal{N}(v)} \psi^{(k)}(\mathbf{h}_v^{(k-1)}, \mathbf{h}_u^{(k-1)}, \mathbf{e}_{uv}) \right), \quad (2.3)$$

kjer je $\mathcal{N}(v)$ množica sosedov vozlišča v , $\psi^{(k)}$ funkcija sporočila, $\oplus$ agregacijska funkcija, $\phi^{(k)}$ funkcija posodobitve, $\mathbf{h}_v^{(k)}$ pa predstavitev vozlišča v v plasti k .

Agregacijska funkcija

Agregacijska funkcija mora biti praviloma invariantna na vrstni red sosedov, saj graf v splošnem nima naravne ureditve vozlišč. Zato se pogosto uporabljajo operacije, kot so vsota, povprečje ali maksimum. Ta lastnost omogoča, da ista GNN plast deluje na grafih različnih velikosti.

2.2.2 Klasifikacija na ravni grafa

Ker želimo napovedati oznako celotnega časovnega okna, nalogo obravnavamo kot klasifikacijo grafa. Po več plasteh grafovske nevronske mreže dobimo predstavitve vozlišč $\mathbf{h}_v^{(K)}$, ki jih združimo v predstavitev celotnega grafa:

$$\mathbf{h}_G = \text{READOUT}(\{\mathbf{h}_v^{(K)} : v \in V\}). \quad (2.4)$$

Funkcija READOUT je agregacijska funkcija na ravni grafa. Pogoste izbire so povprečje, vsota, maksimum ali združevanje s pozornostjo. Predstavitev

grafa $\mathbf{h}_G$ nato uporabimo v klasifikacijski glavi, ki napove razred celotnega grafa.

2.2.3 Prekomerno glajenje in kolaps predstavitev

Pri grafovskih nevronskih mrežah lahko več zaporednih agregacij povzroči, da si predstavitve vozlišč postanejo preveč podobne. Ta pojav imenujemo prekomerno glajenje. V praksi se lahko pokaže kot zmanjšanje variance predstavitev, visoka medsebojna podobnost vozliščnih vektorjev in skoraj konstantni izhodi klasifikacijske glave.

Zato med treniranjem in evalvacijo modelov spremljamo statistike predstavitev na različnih delih modela. Varianca predstavitev kaže, ali model še ohranja razlike med vozlišči in grafi. Kosinusna podobnost pokaže, ali predstavitve postajajo usmerjene v podobno smer. Razpon logitov pa pokaže, ali klasifikacijska glava proizvaja dovolj raznolike napovedi ali se približuje skoraj konstantnemu izhodu.

2.3 Podatki sledilnika pogleda

2.3.1 Merjeni signali

Sledilnik pogleda je naprava, ki meri, kam v prostoru ali na zaslonu oseba usmerja pogled. Poleg lokacije pogleda lahko meri tudi velikost zenic. Meritve se izvajajo zaporedno z določeno vzorčno frekvenco, ki je odvisna od zmogljivosti naprave in namena uporabe. Pogoste vzorčne frekvence raziskovalnih sledilnikov pogleda so 60 Hz, 100 Hz, 500 Hz in 1000 Hz [12, 16].

2.3.2 Časovna narava signala

Lokacija pogleda se običajno zapiše v obliki koordinat (x, y) . Velikost zenice označuje njen premer in se običajno zapiše kot skalar. Podatke sledilnika pogleda obravnavamo kot časovno vrsto meritev pogleda in velikosti zenic. Takšni podatki so primerni za grafovsko obravnavo, saj lahko posamezne

meritve v časovnem oknu predstavimo kot vozlišča, povezave pa določimo glede na časovno bližino, prostorsko bližino lokacij pogleda ali pripadnost isti fiksaciji.

TODO:

- Ta razdelek naj ostane konceptualno ozadje o signalih sledilnika pogleda.
- Podrobno pravilo, da vozlišča predstavljajo meritve, povezave pa časovne, prostorske in fiksacijske odnose, naj bo natančno definirano samo v poglavju 5.
- Tu po potrebi dodaj samo kratek most do poglavja 5, brez ponavljanja formul ali parametrov k_t , k_s in k_f .

2.4 Čustvena stanja: valenca in vzburjenost

2.4.1 Dimenzijski opis čustev

Čustvena stanja pogosto opisujemo z dimenzijama valence in vzburjenosti. Valenca opisuje prijetnost oziroma neprijetnost čustvenega odziva, vzburjenost pa stopnjo aktivacije odziva [14].

2.4.2 3-razredna klasifikacija

TODO:

- Ta razdelek uskladi z uvodom in trenutno zgodbo naloge.
- Če je glavna naloga binarna klasifikacija valence, naj bo 3-razredna preslikava predstavljena samo kot izvorni MAHNOB-HCI kontekst oziroma kot podrobnost poglavja 4.
- Podrobne sezname čustvenih oznak po razredih ne podvajaj tukaj, če so že v poglavju 4 ali poglavju 7; tu raje dodaj sklic.

V tej nalogi valenco in vzburjenost obravnavamo kot dve ločeni 3-razredni klasifikacijski nalogi. Takšna formulacija omogoča primerjavo z izhodiščnim člankom podatkovne zbirke MAHNOB-HCI, kjer so avtorji prav tako poročali rezultate za 3-razredno klasifikacijo valence in vzburjenosti [14]. Razredi niso tvorjeni z neposrednim rezanjem številskih ocen valence in vzburjenosti, temveč iz poročane čustvene oznake posnetka.

Pri vzburjenosti uporabimo tri razrede: nizka, srednja in visoka vzburjenost. V razred nizke vzburjenosti spadajo oznake *sadness*, *disgust* in *neutral*. V razred srednje vzburjenosti spadajo oznake *joy*, *happiness* in *amusement*. V razred visoke vzburjenosti spadajo oznake *surprise*, *fear*, *anger* in *anxiety*. Pri valenci uporabimo razrede neprijetna, nevtralna in prijetna valenca. V razred neprijetne valence spadajo oznake *fear*, *anger*, *disgust*, *sadness* in *anxiety*. V razred nevtralne valence spadata oznaki *surprise* in *neutral*. V razred prijetne valence spadajo oznake *joy*, *happiness* in *amusement*.

Poglavje 3

Sorodna dela

To poglavje povzame sorodna dela, ki so neposredno povezana s to nalogo. Osredotočimo se na prepoznavanje čustev iz podatkov sledilnika pogleda, podatkovno zbirko MAHNOB-HCI, grafovske nevronske mreže za časovno-prostorske podatke ter učenje predstavitev iz podatkov pogleda.

3.1 Prepoznavanje čustev iz podatkov sledilnika pogleda

3.1.1 Ročno oblikovane značilke

Podatki sledilnika pogleda se v prepoznavanju čustev uporabljajo kot vedenjski in psihofiziološki signal. Najpogosteje uporabljeni signali vključujejo lokacijo pogleda, značilke fiksacij in sakad, mežike, velikost zenice ter spremembe razdalje med očesom in sledilnikom pogleda [12, 16]. Iz teh signalov lahko izpeljemo ročno oblikovane značilke, kot so povprečna velikost zenice, trajanje fiksacij, število fiksacij, dolžina poti pogleda ali statistike porazdelitve koordinat pogleda. Takšni pristopi so razložljivi, vendar zahtevajo izbiro značilk in pogosto tudi dodatno predobdelavo signala.

3.1.2 Naučene predstavitve

Novejši pristopi namesto ročno oblikovanih značilk uporabljajo naučene predstavitve [4]. Model v tem primeru prejme manj obdelan časovni signal in se sam nauči predstavitev, ki so uporabne za napovedno nalogo. Ciljne naloge v sorodnih delih so različne: klasifikacija diskretnega čustvenega razreda, napoved valence in vzburjenosti ter binarna klasifikacija čustvenega odziva [14].

3.2 Podatkovna zbirka MAHNOB-HCI

Podatkovna zbirka MAHNOB-HCI je večmodalna zbirka za prepoznavanje čustev in implicitno označevanje multimedijskih vsebin [14]. Vsebuje odzive udeležencev na čustvene video posnetke ter sinhrono zajete signale, med katerimi so obrazni video, zvok, fiziološki signali, EEG in podatki sledilnika pogleda. V tej nalogi uporabljamo samo podatke sledilnika pogleda, ker je osrednji cilj raziskati grafovsko predstavitev tega tipa časovnega signala.

3.2.1 Izvirni protokol za valenco in vzburjenost

Za to nalogo je pomemben del zbirke, v katerem so udeleženci gledali čustvene video posnetke in po vsakem posnetku podali samoocene. V izvirnem članku so avtorji za prepoznavanje čustev med drugim poročali rezultate za 3-razredno klasifikacijo valence in vzburjenosti, pri čemer so razrede izpeljali iz poročane čustvene oznake. Enako formulacijo uporabimo tudi v tej nalogi, saj omogoča primerjavo z izhodiščnim protokolom podatkovne zbirke.

3.2.2 Razlika do eksperimentalne postavitve v tej nalogi

Kljub temu neposredna primerjava med rezultati v izvirnem članku in rezultati te naloge ni mogoča, saj avtorji uporabljajo ročno oblikovane značilke, izračunane iz celotnega odziva na posnetek. Naš pristop uporablja časovna okna surovih signalov pogleda in velikosti zenic, ki jih pretvorimo v grafe.

Zato je primerjava smiselna kot referenčni okvir za podatkovno zbirko in ciljno nalogo, ne kot ponovitev izvirnega eksperimenta.

3.3 Grafovske nevronske mreže za časovno-prostorske podatke

TODO:

- Ta razdelek naj ostane pregled sorodnih del in motivacija za uporabo GNN na časovno-prostorskih podatkih.
- Ne ponavljaj splošnih definicij grafa, heterogenosti, uteženosti ali READOUT; te so v poglavju 2.
- Ne opisuj natančne konstrukcije grafa te naloge; ta je enkratno definirana v poglavju 5. Tu naj bo največ kratek opis položaja te naloge glede na sorodna dela.

Grafovske nevronske mreže so primerne za podatke, pri katerih so pomembni odnosi med elementi [6, 10, 17]. Pri časovno-prostorskih podatkih lahko vozlišča predstavljajo meritve, lokacije ali druge osnovne elemente, povezave pa opisujejo časovno zaporedje, prostorsko bližino ali druge odnose med njimi. Časovno-prostorske grafovske nevronske mreže so se uveljavile predvsem pri nalogah, kjer podatki naravno nastopajo kot časovne vrste na grafu, na primer pri napovedovanju prometa [18]. Ta primer je za to nalogo predvsem analogija za podatkovno strukturo: zaporedne meritve pogleda v časovnem oknu obravnavamo podobno kot časovne meritve senzorjev v prometnem omrežju.

3.3.1 Uporaba na oknih podatkov pogleda

TODO:

- Ta podrazdelek skrajšaj, da ne podvaja poglavja 5.
- Namesto opisovanja časovnih in prostorskih povezav dodaj sklic na poglavje 5; tukaj poudari samo, da je prispevek naloge uporaba take predstavitve na oknih podatkov sledilnika pogleda.
- Če ostane omemba relacij, uporabi isti vrstni red kot drugje: časovne, prostorske, fiksacijske.

V tej nalogi to idejo uporabimo na časovnih oknih podatkov sledilnika pogleda. Posamezne meritve znotraj okna predstavimo kot vozlišča. Časovne povezave opisujejo zaporedje meritev, prostorske povezave pa podobnost lokacij pogleda, izračunano iz evklidske razdalje med koordinatami pogleda. S tem dobimo časovno-prostorski graf, ki je prilagojen strukturi podatkov in hkrati omogoča uporabo GNN za klasifikacijo celotnega okna.

3.4 Učenje predstavitev iz podatkov pogleda in GazeMAE

Poleg ročno oblikovanih značilk se pri podatkih pogleda pojavljajo tudi metode za samonadzorovano učenje predstavitev. Takšne metode poskušajo iz neoznačenih ali šibko označenih zaporedij pogleda naučiti vektorske predstavitve, ki jih lahko nato uporabimo pri različnih napovednih nalogah.

3.4.1 GazeMAE

GazeMAE je primer takšnega pristopa. Podatke pogleda obravnava kot zaporedja položajev in hitrosti ter z avtokodirniško arhitekturo uči mikro- in makro-predstavitve očesnih gibov [4].

GazeMAE v tej nalogi obravnavamo kot relevanten ne-grafovski predstav-

nik učenja predstavitev iz podatkov pogleda. Eksperimentalno ga vključimo kot ločeno procesno verigo:

$$\text{podatki} \rightarrow \textit{GazeMAE} \rightarrow \text{predstavitev} \rightarrow \text{MLP klasifikator} \rightarrow \text{napoved.} \quad (3.1)$$

3.5 Položaj te naloge glede na sorodna dela

Ta naloga ne tekmuje neposredno z vsemi večmodalnimi metodami za prepoznavanje čustev. Večmodalni sistemi lahko uporabljajo EEG, fiziološke signale, obrazni video, zvok in podatke pogleda, zato rešujejo širši problem kot ta naloga. Naš fokus je ožji: zanima nas, ali lahko časovno-prostorska grafovska predstavitev izboljša klasifikacijo valence in vzburjenosti iz podatkov sledilnika pogleda.

Glavna primerjava je zato med grafovskimi in ne-grafovskimi modeli na enakih vhodnih oknih. Ne-grafovski modeli služijo kot kontrola, ki pokaže, koliko informacije je dostopne brez eksplicitne grafovske strukture. Grafovski modeli pa preverjajo, ali relacije med meritvami pogleda izboljšajo naučeno predstavitev okna.

Poglavje 4

Podatki in predobdelava

4.1 Podatkovna zbirka MAHNOB-HCI

4.1.1 Izvirna zbirka

V delu uporabljamo podatke iz podatkovne zbirke MAHNOB-HCI [14]. Gre za večmodalno zbirko, namenjeno raziskavam prepoznavanja čustev in implicitnega označevanja multimedijskih vsebin. Zbirka vsebuje dva glavna eksperimentalna sklopa: prepoznavanje čustvenih stanj iz odzivov na čustvene videoposnetke in implicitno označevanje na podlagi odzivov na pravilne oziroma napačne oznake pod sliko ali posnetkom. V tej nalogi uporabljamo samo prvi sklop, to je eksperiment vzbujanja čustev z videoposnetki.

Izvirni članek poroča o 30 rekrutiranih udeležencih, od katerih je bilo v analizi uporabljenih 27. Udeleženci P9, P12 in P15 so bili izključeni zaradi tehničnih težav oziroma nepopolnega zajema podatkov. V eksperimentu vzbujanja čustev so udeleženci gledali 20 čustveno vzbujujočih videoposnetkov. Pred vsakim čustvenim posnetkom je bil prikazan še kratek nevtralni posnetek, odziv nanj pa je bil shranjen ločeno. Po ogledu posameznega posnetka so udeleženci podali samoocene čustvene oznake, vznburjenosti, valence, dominantnosti in predvidljivosti.

Čeprav je MAHNOB-HCI večmodalna zbirka, v tej nalogi uporabljamo

izključno signale sledilnika pogleda. Podatki pogleda so bili v izvirnem eksperimentu zajeti s sledilnikom Tobii X120 pri frekvenci 60 Hz. Zajeti signali vključujejo smer pogleda, premer zenice, oznako fiksacije in razdaljo očesa do sledilnika. Ostalih modalnosti, kot so EEG, fiziološki signali in obrazni videoposnetki, pri modeliranju v tej nalogi ne uporabljamo.

4.1.2 Lokalni podnabor

Pri delu ne uporabljamo popolne izvirne večmodalne izdaje zbirke. Izvirna zbirka podatkov ni več javno dostopna, lokalno pa imamo na voljo podnabor, ki vsebuje podatke sledilnika pogleda in pripadajoče oznake. Zato lokalnega podnabora ne obravnavamo kot popolne rekonstrukcije izvirne zbirke, temveč kot preverljiv podnabor MAHNOB-HCI podatkov, ki vsebujejo podatke sledilnika pogleda za eksperiment vzbujanja čustev.

4.2 Ciljne oznake

4.2.1 Izvor čustvenih oznak

V eksperimentih ne napovedujemo posamezne čustvene oznake neposredno, temveč iz nje izpeljemo dve ločeni klasifikacijski nalogi: 3-razredno klasifikacijo valence in 3-razredno klasifikacijo vzburjenosti. Tako sledimo izvirnemu eksperimentalnemu protokolu zbirke MAHNOB-HCI in omogočimo primerjavo z objavljenimi rezultati. Numeričnih samoocen valence in vzburjenosti ne diskretiziramo z dodatnimi pragovi, temveč uporabimo preslikavo iz čustvenih oznak v razrede valence in vzburjenosti, prikazano v tabeli 4.1.

4.2.2 Preslikava v razrede valence in vzburjenosti

Oznake čustvenih stanj so pridobljene iz metapodatkov posameznega poskusa. Kadar so bila v datoteki `session.xml` prisotna vsa potrebna polja, uporabimo oznake iz XML metapodatkov. Pri stimulusnih poskusih z nepopolnimi XML metapodatki pretvorba uporabi nadomestni vir `Guide-Cut`. V

Tabela 4.1: Preslikava čustvenih oznak v 3-razredni nalogi valence in vzburjenosti.

Izvorna čustvena oznaka	Razred valence	Razred vzburjenosti
Nevtralno stanje	nevtralna	nizka
Žalost	negativna	nizka
Gnus	negativna	nizka
Veselje / sreča	pozitivna	srednja
Zabava	pozitivna	srednja
Presenečenje	nevtralna	visoka
Strah	negativna	visoka
Jeza	negativna	visoka
Tesnoba	negativna	visoka

eksperimentalnem cevovodu uporabljamo samo vrstice z veljavno izpeljano oznako.

TODO:

- Glavno besedilo: dodati eno kompaktno sliko porazdelitve razredov po končnih 10-sekundnih oknih. Slika naj v dveh panelih pokaže 3-razredno valenco in 3-razredno vzburjenost; v oznakah ali spremljevalni tabeli naj bodo absolutna števila in deleži.
- Glavno besedilo: pri sliki jasno navesti pogoje izračuna: `min_samples_per_window=60`, izključeni subjekti P9, P12 in P15, samo `emotion-elicitation`, samo `emotion-derivation-status=ok`.
- Dodatek A: predstaviti podrobnejše porazdelitve, če bodo potrebne, npr. porazdelitve po subjektih, po posnetkih, po izvornih čustvenih oznakah in ločene porazdelitve za binarni low/high nalogi.
- Ne dodajaj več ločenih slik porazdelitve v glavno besedilo, razen če ena od porazdelitev neposredno pojasnjuje rezultat modela.

4.3 Priprava vhodnih signalov

TODO:

- Dodati kratek podrazdelek ali tabelo z eksperimentalnimi nabori signalov: *gaze* = samo koordinati pogleda (x, y) ; *gaze+pupil* = koordinati pogleda in velikosti zenic; *all* = trenutni celoten nabor z razdaljo, fiksacijami, fiksacijskimi povezavami in značilkami povezav.
- *Pupil-only* zaenkrat označiti kot odprto možnost oziroma placeholder, ne kot del glavnega eksperimentalnega protokola, dokler ne bo jasna modelna definicija.
- Če bo implementiran MOMENT + MLP za zenični signal, dodati ločen opis priprave zenične časovne vrste in način združevanja z GazeMAE predstavitvami.

4.3.1 Uporabljeni stolpci

Za vsak časovni vzorec uporabimo štiri osnovne signale sledilnika pogleda:

- horizontalno koordinato pogleda x_i ,
- vertikalno koordinato pogleda y_i ,
- velikost leve zenice $p_i^{(l)}$,
- velikost desne zenice $p_i^{(r)}$.

V trenutni implementaciji so to stolpci `x-avg`, `y-avg`, `pupil-size-left-avg` in `pupil-size-right-avg`. Koordinati pogleda predstavljata povprečen položaj pogleda med levim in desnim očesom, velikosti zenic pa sta ohranjeni ločeno. Poleg osnovnih signalov trenutna konfiguracija doda še normalizirani čas znotraj okna, povprečno razdaljo med očmi in sledilnikom ter trajanje fiksacije. To ustreza stolpcem `time-window-normalized`, `distance-avg` in `fixation-duration`. Stolpec `fixation-index` uporabimo za konstrukcijo fiksacijskih povezav, ne pa kot numerično vhodno značilko. Čas v sekundah uporabljamo pri tvorbi časovnih oken in časovnih povezav, za vhodno značilko modela pa uporabimo okensko normalizirani čas.

4.3.2 Čiščenje in filtriranje podatkov

Modeli ne uporabljajo neposredno surovih Tobii TSV datotek. Vir za eksperimentalni cevovod je obdelani predpomnilnik `data/processed/cached_hci_tagging_emotion`. Ta nastane s pretvorbo izvornih Tobii izvozov in pripadajočih metapodatkov v skupno tabelarično obliko. Nato se kode veljavnosti sledilnika pogleda preslikajo v binarne indikatorje zaupanja. Za podatke MAHNOB-HCI zahtevamo veljaven signal levega in desnega očesa.

Kratke vrzeli v numeričnih signalih se interpolirajo, signala velikosti zenice pa se dodatno zgladita s kratkim drsečim povprečjem. Nato ohranimo samo eksperiment vzbujanja čustev in vrstice z veljavno oznako. Za učenje odstranimo vrstice brez osnovnih signalov pogleda ali zenic. V privzetem

eksperimentalnem cevovodu dodatno uporabimo robustni filter osamelcev q01–q99 na štirih osnovnih signalih.

4.4 Normalizacija

Po čiščenju so signali obdelani, vendar še niso standardizirani. Prva standardizacija se izvede šele po razdelitvi podatkov na učni, validacijski in testni fold.

4.4.1 Normalizacija pri grafovskih modelih

Pri grafovskem modelu se `StandardScaler` prilagodi samo na matrikah značilk vozlišč iz grafov učnega folda. Isti scaler se nato uporabi za grafe učnega, validacijskega in testnega folda. Pri naučenih značilkah povezav se scalerji prav tako prilagodijo samo na učnem foldu. Časovne povezave imajo skupen scaler za relaciji `temporal_forward` in `temporal_backward`, pri čemer značilka smeri ostane neskalirana. Prostorske in fiksacijske povezave imajo ločena scalerja.

4.4.2 Normalizacija pri tabelaričnih modelih

Pri tabelaričnih osnovnih modelih se najprej tvorijo časovna okna in agregirane tabelarične značilke, nato se `StandardScaler` prilagodi samo na matriki `X_train`.

4.4.3 Preprečevanje uhajanja informacij

S tem preprečimo uhajanje informacij iz validacijskih in testnih foldov v učno množico.

4.5 Segmentacija v časovna okna

4.5.1 Dolžina okna

Časovno vrsto razdelimo na neprekrivajoča se časovna okna dolžine $T = 10$ s. Vsako uporabno časovno okno predstavlja en učni primer. Pri ne-grafovskih osnovnih modelih ga pretvorimo v tabelarični vektor značilk, pri grafovskem modelu pa v časovno-prostorski graf. Za 10 s smo se odločili na podlagi sorodnega dela na podatkih sledilnika pogleda, kjer so se daljša okna med dolžinami 1, 3, 5 in 10 s praviloma izkazala za bolj informativna [5]. Še daljših oken ne uporabimo, ker bi dobili manj učnih primerov in hkrati izgubili del lokalnih časovnih sprememb, kar je znan kompromis pri segmentaciji fizioloških signalov za prepoznavanje čustev [3, 13].

4.5.2 Dodelitev oznake oknu

Oznaka okna je določena s parom udeleženec–posnetek, saj vsa okna istega označenega ogleda videoposnetka podedujejo isto čustveno oznako.

4.5.3 Minimalno število vzorcev

Pri vzorčni frekvenci 60 Hz bi 10-sekundno okno brez manjkajočih vrednosti vsebovalo 600 vzorcev. Zaradi čiščenja, odstranjevanja neveljavnih vzorcev in filtriranja je dejansko število vzorcev v oknih manjše. Po dodatnem filtru osamelcev q01–q99 dobimo 5158 uporabnih 10-sekundnih časovnih oken.

TODO:

- Kandidatna slika za glavno besedilo: UMAP projekcija procesiranih učnih primerov po tvorbi oken. Najprej poskusi projekcijo agregiranih tabelaričnih značilk oken, obarvano po valenci in vzburjenosti.
- Če UMAP pokaže jasno in razločljivo strukturo, ga vključi kot kvalitativni prikaz podatkov v poglavje o podatkih ali rezultate; v besedilu eksplicitno zapiši, da gre za vizualizacijsko projekcijo in ne za kvantitativni dokaz ločljivosti razredov.
- Če UMAP ne pokaže jasne strukture ali je slika vizualno neprepričljiva, ga ne vključi v glavno besedilo; po potrebi ga prestavi v dodatek A ali ga izpusti.
- Pri vseh UMAP slikah preveri barvanje po razredu, subjektu in posnetku, da ločiš morebitno razredno strukturo od subjektnih oziroma stimulusnih učinkov.

4.6 Predhodni poskus z zbirko eSEEd_v2

Pred prehodom na MAHNOB-HCI je bil del razvoja izveden na podatkovni zbirki eSEEd_v2. Ta del ni osrednji eksperimentalni prispevek naloge, temveč služi kot zgodovinska motivacija za spremembo podatkovne zbirke. Začetni poskusi so pokazali težave z zanesljivostjo oznak, kakovostjo signalov in stabilnostjo učenja. Zato smo glavno eksperimentalno evalvacijo izvedli na podatkovni zbirki MAHNOB-HCI, ki ima jasnejši protokol označevanja in uporabnejši lokalni podnabor signalov sledilnika pogleda.

Tabela 4.2: Zmanjševanje količine podatkov od izvirne zbirke MAHNOB-HCI do končnih časovnih oken, uporabljenih v eksperimentalnem cevovodu.

Korak	Vrstice	Udeleženci	Opis
Izvirna zbirka MAHNOB-HCI	–	30	Večmodalna zbirka; izvirni članek v analizi uporabi 27 udeležencev.
Lokalni podnabor podatkov sledilnika pogleda	3 797 165	24	Lokalna kopija eksperimenta vzbujanja čustev s podatki sledilnika pogleda in oznakami.
Po izključitvi P9, P12 in P15	3 535 842	22	P15 v lokalnem podnaboru ni prisoten, zato sta odstranjena le P9 in P12.
Veljavno označene vrstice	2 995 632	22	Ohranjeni so samo označeni podatki, uporabljeni za učenje modelov čustvenih stanj.
Pripravljeno za učenje	2 814 005	22	Odstranjene so vrstice brez ključnih signalov pogleda ali zenic.
Po filtru osamelcev q01–q99	2 639 048	22	Robustno filtriranje štirih osnovnih signalov pogleda in zenic.
Uporabna 10-sekundna časovna okna	5 158	22	Vsako okno postane en učni primer oziroma graf.

Poglavje 5

Grafovski predstavitev podatkov sledilnika pogleda

To poglavje je eno osrednjih metodoloških poglavij naloge. Njegov namen je natančno opisati, kako iz časovnega okna meritev sledilnika pogleda nastane graf, ki ga uporabimo kot vhod v grafovsko nevronske mrežo.

TODO:

- To poglavje naj bo edino mesto za natančno definicijo konkretnega vhodnega grafa te naloge.
- Ne ponavljaj splošnih definicij grafa, heterogenosti ali uteženosti iz poglavja 2; uporabi sklic.
- Ne opisuj arhitekturnih odločitev modela, kot so relacijske transformacije, MLP za uteži, normalizacija naučenih uteži, GCNConv ali READOUT; te prestavi v poglavje 6.

TODO:

- Dodati opombo, da se grafovska konstrukcija v eksperimentih prilagodi izbranemu naboru signalov.
- Za *gaze* opisati graf iz koordinat pogleda (x, y) in relacij, ki jih je smiselno zgraditi iz pogleda; za *gaze+pupil* dodati zenične značilke vozlišč; za *all* ohraniti trenutno polno konstrukcijo z razdaljo, fiksacijami, fiksacijskimi povezavami in značilkami povezav.
- *Pupil-only* ne vključevati v glavno grafovsko konstrukcijo, dokler ni jasen smiseln GNN protokol; zaenkrat ga označiti kot odprto možnost ali ga izpustiti.

TODO:

- Glavno besedilo: dodati eno osrednjo metodološko sliko grafovske predstavitve. Slika naj na majhnem, berljivem izseku okna pokaže vozlišča po koordinatah pogleda in relacije časovnih, prostorskih ter fiksacijskih povezav z različnimi barvami ali paneli.
- Glavno besedilo: slika naj razloži idejo konstrukcije grafa, ne vseh implementacijskih podrobnosti. Ne dodajaj ločene slike za vsako relacijo v glavnem besedilu, ker bi to prekinilo tok poglavja.
- Dodatek C: predstaviti podrobne vizualizacije posameznih relacij, primer 10-sekundnega grafa, berljiv 2- ali 5-sekundni izsek, prekrivanja relacij in različice z velikostjo vozlišč po zenici.

5.1 Učni vzorec kot graf

5.1.1 Definicija grafa

Vsak učni vzorec je časovno okno meritev sledilnika pogleda. Okno pretvorimo v graf

$$G = (V, E_t^+, E_t^-, E_s, E_f), \quad (5.1)$$

kjer je V množica vozlišč, E_t^+ množica časovnih povezav naprej, E_t^- množica časovnih povezav nazaj, E_s množica prostorskih povezav in E_f množica fiksacijskih povezav.

Vozlišča predstavljajo zaporedne meritve sledilnika pogleda znotraj časovnega okna. Povezave med vozlišči opisujejo različne relacije med meritvami: časovno zaporednost, prostorsko bližino pogleda in pripadnost isti fiksaciji. En graf predstavlja en učni vzorec.

5.1.2 Oznaka grafa

TODO:

- Uskladi z novo formulacijo naloge: glavni cilj je binarna klasifikacija valence.
- Tu zapiši samo, da je oznaka na ravni grafa oziroma časovnega okna; podrobna preslikava oznak naj ostane v poglavju 4 oziroma 7.

Vsak graf označimo z oznako pripadajočega časovnega okna. V nalogi to oznako uporabimo pri ločenih klasifikacijskih nalogah valence in vzburjenosti.

[Na koncu popravi, če klasifikacijski nalogi nista ločeni, ampak združeni v eno nalogo. Predvidevam, da bosta ločeni, ker mislim, da so tako tudi naredili v MAHNOB članku.]

5.2 Vozlišča

5.2.1 Definicija vozlišča

Vsako vozlišče predstavlja eno meritev sledilnika pogleda znotraj časovnega okna:

$$v_i \leftrightarrow \mathbf{x}_i. \quad (5.2)$$

Če okno vsebuje n veljavnih meritev, potem graf vsebuje n vozlišč. V osnovni nastavitvi uporabljamo 10-sekundna okna. Ker so meritve vzorčene s frekvenco 60 Hz, je pričakovano število meritev v polnem oknu

$$n_{\text{exp}} = 10 \text{ s} \cdot 60 \text{ Hz} = 600. \quad (5.3)$$

Grafovski predstavitev naravno podpira spremenljivo število vozlišč. Grafovska nevronska mreža namreč deluje na množici vozlišč in povezav, končno predstavitev celotnega grafa pa pridobi z agregacijo vozliščnih predstavitev.

5.2.2 Značilke vozlišč

TODO:

- Tu naj ostane samo opis vhodnih značilk vozlišč kot dela grafovske predstavitve.
- Preslikavo značilk vozlišč v latentni prostor opiši v poglavju 6.4.
- Ne opisuj LayerNorm, dropout, MLP blokov ali drugih arhitekturnih komponent v tem poglavju.

Vektor značilk vozlišča je

$$\mathbf{x}_i = [x_i, y_i, p_{l,i}, p_{r,i}, t_i, d_i, f_{dur,i}], \quad (5.4)$$

kjer sta x_i in y_i koordinati pogleda, $p_{l,i}$ in $p_{r,i}$ velikosti leve in desne zenice, t_i je normalizirani čas znotraj okna, d_i razdalja med sledilnikom in udeleženci očmi, $f_{dur,i}$ pa trajanje fiksacije, ki ji pripada i -ta meritev.

Časovna značilka

Časovna značilka t_i modelu poda položaj meritve znotraj okna.

Koordinate pogleda

Koordinati x_i in y_i opisujeta položaj pogleda in sta uporabljeni tudi pri konstrukciji prostorskih povezav.

Značilke zenice

Značilki $p_{l,i}$ in $p_{r,i}$ opisujeta velikost leve in desne zenice.

Razdalja do sledilnika in fiksacije

Značilki d_i in $f_{dur,i}$ opisujeta razdaljo do sledilnika ter trajanje fiksacije pripadajoče meritve. Manjkajoče vrednosti trajanja fiksacije in meritve, ki ne pripadajo fiksaciji, so kodirane z vrednostjo $f_{dur,i} = 0$.

5.3 Heterogena grafovski predstavitev

TODO:

- Splošna definicija heterogenega grafa naj ostane v poglavju 2.
- Tukaj definiraj samo konkretno množico relacij $\mathcal{R}$ in razloži, kaj posamezna relacija pomeni v podatkih sledilnika pogleda.
- Razlago, da model za vsako relacijo uporablja ločeno transformacijo oziroma ločeno posredovanje sporočil, prestavi v poglavje 6.4.2.

5.3.1 Tipi relacij

Ker različne povezave opisujejo različne odnose med meritvami, graf obravnavamo kot heterogen graf z več tipi povezav. V trenutni predstavitvi upora-

bljamo množico relacij

$$\mathcal{R} = \{\text{temporal_forward}, \text{temporal_backward}, \text{spatial}, \text{fixation}\}. \quad (5.5)$$

Časovne povezave naprej, časovne povezave nazaj, prostorske povezave in fiksacijske povezave so obravnavane kot ločene relacije.

5.3.2 Zakaj ločimo relacije

Ločevanje relacij omogoča, da model za vsak tip relacije uporablja ločeno transformacijo oziroma ločeno funkcijo posredovanja sporočil. S tem lahko časovno zaporednost, prostorsko bližino in pripadnost isti fiksaciji modeliramo z različnimi parametri, namesto da bi vse povezave obravnavali kot enakovredne. S tem tudi dovolimo modelu, da se za različne relacije nauči dajati različno težo istim vozliščem. Morda je neko vozlišče zelo pomembno s pogleda časovne zaporednosti, ampak povsem nepomembno z vidika umeščenosti v prostor.

TODO:

- Ta pododsek naj ostane konceptualna motivacija za heterogen graf.
- Podrobnosti, kako model dejansko uporabi ločene relacijske transformacije, prestavi v poglavje 6.4.
- Popravi slog in tipkarske napake; izogni se preveč modelno specifični razlagi v poglavju 5.

5.4 Povezave

5.4.1 Časovne povezave

Časovne povezave povezujejo meritve zaporedne v času. Naj bodo vozlišča v posameznem oknu urejena po času, tako da je v_i i -ta meritev v časovnem zaporedju. Parameter $k_t \in \mathbb{N}$ določa število časovnih sosedov na vsako stran. V privzeti nastavitvi uporabljamo $k_t = 2$. *[preveri končni k_t]*


Povezave naprej in nazaj

Ločimo usmerjene časovne povezave naprej in nazaj:

$$E_t^+ = \{(v_i, v_j) : 1 \leq j - i \leq k_t\}, \quad (5.6)$$

$$E_t^- = \{(v_i, v_j) : 1 \leq i - j \leq k_t\}. \quad (5.7)$$

Povezave v E_t^+ potekajo od prejšnjih proti kasnejšim meritvam, povezave v E_t^- pa od kasnejših proti prejšnjim meritvam. Ločitev smeri je smiselna, ker ima vrstni red očesnega gibanja pomen. Primer časovnih povezav na majhnem izseku okna je prikazan na sliki 5.1.



Slika 5.1: Primer časovnih povezav v izseku grafa. Povezave sledijo časovni urejenosti meritev in ločijo smer naprej ter nazaj.

Parameter k_t

Parameter k_t določa velikost lokalnega časovnega konteksta in s tem število povezav, ki jih dodamo okrog posamezne meritve. Smiselno lahko zahtevamo $k_t < n$, kjer je n število vozlišč v oknu. Pričakovano število usmerjenih povezav v grafu naprej je $|E_t^+| = k_t \cdot n - \sum_{i=1}^{k_t} (i) = k_t \cdot n - \frac{k_t(k_t+1)}{2} = k_t \cdot (n - \frac{k_t+1}{2})$. Za obravnavani primer $k_t = 2$ in $n = 600$ je to $|E_t^+| = 2 \cdot (600 - \frac{2+1}{2}) = 1197$ usmerjenih povezav naprej, enako število pa je tudi usmerjenih povezav nazaj. Torej skupno imamo približno $2k_t \cdot n$ časovnih povezav.

- V glavno metodološko sliko vključi časovne povezave, v dodatek C pa prestavi ločeni vizualizaciji *temporal_forward* in *temporal_backward*.
- Razmisli o smiselnosti k_t glede na število layerjev GNN.

5.4.2 Prostorske povezave

Prostorske povezave so neusmerjene povezave, ki povezujejo meritve s podobnim položajem pogleda znotraj istega časovnega okna. Za vsako vozlišče poiščemo k_s najbližjih sosedov v prostoru koordinat pogleda (x, y) .

Najbližji sosedi v prostoru pogleda


Prostorsko razdaljo med meritvama i in j definiramo evklidsko:

$$d_{ij}^{(s)} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}. \quad (5.8)$$

Za vsako vozlišče v_i poiščemo k_s najbližjih sosedov v prostoru koordinat pogleda (x, y) z uporabo k-d drevesa. Če je v_j med temi sosedi, dodamo povezavo med vozliščema v_i in v_j ; ker prostorske povezave obravnavamo kot neusmerjene, povezavo predstavimo z obema usmerjenima povezavama (v_i, v_j) in (v_j, v_i) . Na koncu odstranimo podvojene povezave znotraj relacije E_s .

Simetrizacija povezav

Ker povezave obravnavamo kot neusmerjene, vsaki povezavi (v_i, v_j) dodamo tudi povezavo (v_j, v_i) . Primer prostorskih povezav je prikazan na sliki 5.2.



Slika 5.2: Primer prostorskih povezav v izseku grafa. Povezave nastanejo med meritvami s podobnim položajem pogleda, zato niso nujno omejene na časovno zaporedne meritve.

- V glavno metodološko sliko vključi prostorske povezave, v dodatek C pa prestavi ločeno vizualizacijo *spatial* povezav.
- $k_s = 2$ v trenutnih poskusih. Preveri končni k_s .

5.4.3 Fiksacijske povezave

Fiksacijske povezave povezujejo meritve, ki pripadajo isti zaznani fiksaciji. Pripadnost fiksaciji določimo z identifikatorjem fiksacije, podanim v MAHNOB-HCI podatkih.

Redčenje povezav znotraj fiksacije

Znotraj posamezne fiksacije ne povežemo vseh vozlišč med seboj, saj bi to povzročilo preveliko število fiksacijskih povezav. Namesto tega uporabimo redkejšo konstrukcijo, ki ohrani informacijo o pripadnosti isti fiksaciji, vendar zmanjša prostorsko in časovno zahtevnost konstrukcije grafa ter učenja na grafu. To konstrukcijo imenujemo razširjene povezave znotraj fiksacije (angl. *dilated intra-fixation edges*). Fiksacijo obravnavamo kot zvezno zaporedje vozlišč z istim veljavnim identifikatorjem *fixation-index*. Če ima taka fiksacija F vozlišč, jim znotraj fiksacije priredimo lokalne indekse $0, \dots, F-1$.

Gostoto povezav uravnava parameter k_f , ki določa število fiksacijskih povezav, ki jih generira vsako vozlišče. V trenutni privzeti konfiguraciji uporabljamo $k_f = 3$. Za posamezno fiksacijo najprej izračunamo korak razširitve

$$s = \max(1, \lfloor F/k_f + 0,5 \rfloor). \quad (5.9)$$

Množico kandidatnih odmikov nato definiramo kot


$$D = \{(1 + qs) \bmod F \mid q = 0, \dots, k_f - 1\}. \quad (5.10)$$

Morebitni odmik 0 in podvojene odmiške odstranimo. Za vsak odmik $d \in D$ dodamo neusmerjene povezave

$$\{v_i, v_{(i+d) \bmod F}\}, \quad i = 0, \dots, F-1. \quad (5.11)$$

Pri zapisu grafa za posredovanje sporočil vsako neusmerjeno povezavo predstavimo z dvema usmerjenima povezavama. Podvojene povezave znotraj relacije E_f odstranimo.

Na primer, pri fiksaciji dolžine $F = 30$ in parametru $k_f = 3$ dobimo $s = 10$. Vozlišče z lokalnim indeksom 0 torej povežemo z vozlišči 1, 11 in 21. Odmik 1 ohrani časovno lokalno komunikacijo znotraj fiksacije, večji odmiški pa omogočijo širjenje informacij tudi med časovno bolj oddaljenimi meritvami iste fiksacije. Primer fiksacijskih povezav je prikazan na sliki 5.3.



Slika 5.3: Primer fiksacijskih povezav v izseku grafa. Povezave združujejo meritve, ki pripadajo isti zaznani fiksaciji, pri čemer razširjena konstrukcija ohrani redkejšo povezovalno strukturo.


Razširjene povezave imajo večji doseg kot zgolj zaporedne fiksacijske povezave, hkrati pa se izognejo kombinatorični eksploziji, ki bi nastala pri polnem kliku. Pri polnem kliku bi namreč število povezav naraščalo kvadratno z dolžino fiksacije. Pri analiziranih 10-sekundnih oknih dobimo približno 1.956 fiksacijskih povezav na graf pri $k_f = 2$, 2.908 pri $k_f = 3$, 4.163 pri $k_f = 5$ in 7.273 pri $k_f = 10$. Pri privzeti izbiri $k_f = 3$ so fiksacijske povezave predstavljale približno 45,7 % vseh povezav v grafu (relacije `temporal`, `spatial` in `fixation`).

Izbira $k_f = 3$ je zato kompromis med dosegom in gostoto grafa. Ker vsaka plast GNN omogoča izmenjavo informacij med neposredno povezanimi vozlišči, se doseg znotraj fiksacije povečuje tudi z večanjem števila plasti. Pri

$k_f = 3$ vozlišče že v eni plasti prejme informacije iz več delov iste fiksacije, večplastni model pa lahko te informacije dodatno propagira po fiksacijski relaciji. Večje vrednosti k_f povečajo gostoto grafa, računsko zahtevnost in možnosti za prekomerno glajenje, manjše vrednosti pa graf dodatno razredčijo.

- V glavno metodološko sliko vključi fiksacijske povezave, v dodatek C pa prestavi ločeno vizualizacijo *fixation* povezav in primer razširjenih povezav znotraj ene fiksacije.
- $k_f = 3$ v trenutnih poskusih. Preveri končni k_f glede na eksperimente (consider $k_f=2$).

Isti izsek z vsemi opisanimi tipi povezav je prikazan na sliki 5.4. Prikaz povzema konstrukcijo heterogenega grafa in zato služi kot povezava med formalno definicijo grafa ter posameznimi konstrukcijskimi pravili.



Slika 5.4: Majhen primer konstrukcije grafa iz podatkov sledilnika pogleda. Vozlišča predstavljajo meritve v izseku časovnega okna, povezave pa skupaj prikazujejo časovne, prostorske in fiksacijske relacije, opisane v tem poglavju.

5.5 Uteži povezav

TODO:

- Ta odsek preimenuj v *Značilke povezav*, če bodo naučene uteži in njihova normalizacija predstavljene v poglavju 6.
- Razdeli vsebino tega odseka med poglavji 5 in 6.4.
- V poglavju 5 naj ostanejo značilke povezav: katere količine opišejo relacijo med dvema meritvama.
- V poglavju 6.4 prestavi ali tam povzemalno opiši arhitekturni del: MLP za izračun uteži, predznačene uteži, normalizacijo in uporabo uteži pri posredovanju sporočil.
- V poglavju 5 ne poudarjaj več, da model iz značilk izračuna uteži; to naj bo predvsem del opisa predlaganega modela.

Uteži povezav omogočajo, da model razlikuje med povezavami, ki povezujejo v času in prostoru različno oddaljene meritve.

5.5.1 Značilke povezav

Za vsako povezavo sestavimo vektor značilk, iz katerega model izračuna surovo skalarno oceno povezave:

$$a_{ij} = f_{\theta}(\mathbf{r}_{ij}), \quad (5.12)$$

kjer je $\mathbf{r}_{ij}$ vektor značilk povezave e_{ij} , f_{θ} pa večslojni perceptron. Za časovne, prostorske in fiksacijske povezave so uporabljene značilke $[t_i, t_j, \Delta t, \Delta x, \Delta y, d_{ij}^{screen}, \Delta d_{ij}^{eye}]$, pri časovnih povezavah pa dodatno še značilka smeri ρ_{ij} . Pri časovni povezavi naprej je $\rho_{ij} = 1$, pri časovni povezavi nazaj pa $\rho_{ij} = -1$. Časovne povezave imajo torej 8 značilk, prostorske in fiksacijske povezave pa 7 značilk, iz katerih se izračunajo uteži povezav.

Tabela 5.1: Značilke povezav za izračun naučenih uteži povezav.

Značilka	Opis
t_i	Normaliziran čas izvirnega vozlišča znotraj časovnega okna.
t_j	Normaliziran čas ciljnega vozlišča znotraj časovnega okna.
Δt	Časovna razlika med ciljnim in izvirnim vozliščem, $\Delta t = t_j - t_i$.
Δx	Razlika v vodoravni koordinati pogleda, $\Delta x = x_j - x_i$.
Δy	Razlika v navpični koordinati pogleda, $\Delta y = y_j - y_i$.
d_{ij}^{screen}	Evklidska razdalja med položajema pogleda na zaslonu.
Δd_{ij}^{eye}	Sprememba razdalje med sledilnikom in udeležencevimi očmi.
$\rho_{ij} = \pm 1$	Smer časovne povezave; uporablja se samo pri časovnih povezavah.

5.5.2 Normalizacija uteži

TODO:

- Razmisli o prestavitvi tega pododseka v poglavje 6.4, ker je normalizacija uteži del arhitekture modela in ne del same definicije vhodnega grafa.
- Če formule ostanejo tukaj, jih v 6.4 ne ponavljaj; tam dodaj samo konceptualni povzetek in sklic na ta odsek.
- Če formule prestaviš v 6.4, naj poglavje 5 vsebuje samo tabelo značilk povezav.

Surovo skalarno oceno a_{ij} najprej preslikamo v omejeno območje na interval $(-1, 1)$:

$$\tilde{w}_{ij} = \tanh(a_{ij}). \quad (5.13)$$

Nato uteži normaliziramo po vhodnih povezavah ciljnega vozlišča. To pomeni, da za vozlišče v_j upoštevamo povezave, ki imajo v_j za ciljno vozlišče. Pri neusmerjenih povezavah, tretiramo vse povezave za vhodne in izhodne. Normalizacijo izvedemo ločeno za vsako relacijo r :

$$w_{ij}^{(r)} = \frac{\tilde{w}_{ij}^{(r)}}{\sum_{i' \in \mathcal{N}_r^-(j)} |\tilde{w}_{i'j}^{(r)}| + \epsilon}, \quad (5.14)$$

kjer je $\mathcal{N}_r^-(j)$ množica izvornih vozlišč, ki so z vozliščem v_j povezana z vhodno povezavo tipa r . Majhna konstanta ϵ prepreči deljenje z nič. Takšna normalizacija stabilizira velikost agregiranih sporočil tudi pri vozliščih z večjim številom vhodnih povezav.

Za izračun surovih ocen uporabljamo tri ločene večslojne perceptrone: enega za časovne povezave, enega za prostorske povezave in enega za fiksacijske povezave. Časovni relaciji naprej in nazaj si delita isti perceptron, ločeni pa sta z dodatno značilko smeri ρ_{ij} . Skalarne uteži povezav se uporabljajo pri konvoluciji `GCNConv`, ki je privzeta izbira modela. Pri poskusih z `GATConv` se te skalarne uteži ne uporabijo, saj `GATConv` pomembnost povezav modelira z notranjim mehanizmom pozornosti.

5.6 Statistika grafov

TODO:

- Ta razdelek lahko ostane v poglavju 5, ker opisuje lastnosti konstruiranih grafov.
- V njem ne razlagaj več splošne računske zahtevnosti GNN modela; za to uporabi poglavje 6, poglavje 7 ali dodatek s hiperparametri.
- Preveri, da so parametri v napisu tabele skladni s končno izbrano konfiguracijo in da niso v konfliktu z opisom v poglavju 7.

5.6.1 Število vozlišč in povezav

Tabela 5.2: Povzetek statistike grafov za privzeto 10-sekundno okno pri $k_t = 2$, $k_s = 2$ in $k_f = 3$.

Količina	Vrednost
Mediana števila vozlišč	560
Povprečno število vozlišč	505,9
Mediana števila časovnih povezav naprej	1117
Mediana števila časovnih povezav nazaj	1117
Mediana števila prostorskih povezav	1546
Mediana števila fiksacijskih povezav	3204
Povprečna gostota grafa	TODO

[Verjetno prestavi to poglavje nižje med modele.]

5.6.2 Računska zahtevnost

TODO:

- Ta odsek verjetno ne sodi v poglavje 5, ker govori o zahtevnosti modela, ne o konstrukciji vhodnega grafa.
- Statistiko števila vozlišč in povezav lahko pustiš v poglavju 5.
- Oceno števila parametrov, časa učenja, pomnilniške zahtevnosti in primerjavo z drugimi modeli prestavi v poglavje 6, poglavje 7 ali dodatek s hiperparametri.
- Če v poglavju 5 ostane kaj o zahtevnosti, naj bo omejeno na zahtevnost konstrukcije grafa in gostoto povezav.

TODO: Stvari spodaj

- Oceni velikost GNN modela po neki metriki – število učinkovitih parametrov.

- Primerjaj velikost med modeli:
 - GNN približno 560K parametrov, MLP baseline približno 5K, GazeMAE + MLP približno 2.100K parametrov, od tega samo 80K učljivih (MLP), ker je GazeMAE hrbtenica zamrznjena. (Te podatke je potrebno preveriti.)
 - LightGBM lahko merimo v `n_estimators` in `max_depth`, ampak ni zelo primerljivo.
 - SVM je odvisen od števila podpornih vektorjev. SVM in LGBM bomo zato primerjali samo časovno.
- Pri eni plasti GNN je strošek posredovanja sporočil približno linearen v številu povezav in v širini skritih predstavitev. Za L plasti je zato groba odvisnost $O(L \cdot |E| \cdot H)$, ob tem pa model vsebuje še linearne transformacije in MLP-je za združevanje relacij. Pri predlaganem modelu je $L = 3$, $H = 128$, tipičen graf pa ima nekaj sto vozlišč in nekaj tisoč povezav.
- Primerjaj prostorsko zahtevnost med modeli.
- Primerjaj časovno zahtevnost med modeli – konkreten povprečen čas učenja za vsak model v tej nalogi.
- Verjetno prestavi to poglavje nižje med modele.

Poglavje 6

Primerjani modeli in predlagana arhitektura

V tem poglavju predstavimo klasifikacijske modele strojnega učenja, ki jih primerjamo v eksperimentalni evalvaciji. Modele razdelimo na negrafovske osnovne modele, model GazeMAE + MLP kot predstavnika SOTA ter grafovske modele. *[...grafovske modele - množina?]*

Vsi modeli uporabljajo iste izvirne podatke, ista 10-sekundna okna in iste delitve na učne, validacijske (v primerih nevronske mreže) in testne množice. Razlika je v predstavitvi vhodnih podatkov. Grafovski modeli prejmejo okno kot graf meritev, negrafovski osnovni modeli prejmejo agregirano tabelarično predstavitev istega okna, GazeMAE pa po svoji konstrukciji le koordinati pogleda (x , y) za celotno 10 s okno.

TODO:

- To poglavje naj bo edino mesto za opis arhitektur modelov.
- Ne ponavljaj splošnih definicij grafov in GNN iz poglavja 2.
- Ne ponavljaj pravil konstrukcije časovnih, prostorskih in fiksacijskih povezav iz poglavja 5; uporabi sklic na konkretno grafovsko predstavitev.
- Tu pa obdrži opis, kako posamezen model uporablja že definirano predstavitev: homogenizacija pri osnovnem GCN, relacijska obravnavna pri heterogenem GNN, naučene uteži povezav, fuzija relacij in konkretni READOUT.

TODO:

- Poglavje preurediti tako, da modeli niso opisani samo za en polni vhodni nabor, ampak za primerjavo po naborih *gaze*, *gaze+pupil* in *all*.
- Jasno zapisati, da GazeMAE učimo oziroma uporabimo samo na *gaze-only* vhodu, ker uporablja koordinate pogleda; če dosega močne rezultate, ga lahko v rezultatih primerjamo kot referenco tudi proti modelom, ki uporabljajo bogatejše nabore signalov.
- Dodati placeholder za morebitni MOMENT + MLP nad zeničnim signalom ter za kombinacijo MOMENT in GazeMAE predstavitev v skupni MLP pri *gaze+pupil* oziroma *all*.
- Pri GNN zaenkrat ne dodajati *pupil-only* različice, dokler ni jasen smiseln grafovski protokol.

Za pravično primerjavo osnovnim modelom podamo agregirane značilke istih signalov kot jih prejme GNN. To so: koordinati pogleda (x , y), velikosti leve in desne zenice, oddaljenost od zaslona ter informacija o fiksacijah. Za vsak signal izračunamo opisne statistike na ravni okna: povprečje, standardni

odklon, minimum, maksimum, razpon, mediano, prvi kvartil, tretji kvartil in medkvartilni razmik. Pri fiksacijah dodamo še število fiksacij, delež meritev v oknu, ki pripadajo fiksacijam, vsoto trajanj, povprečno trajanje in največje trajanje fiksacije. Takšna pretvorba časovnega signala v opisne statistike na ravni okna oziroma odziva je običajen pristop pri klasičnih modelih strojnega učenja za podatke pogleda [5, 12, 16].

6.1 Negrafovski osnovni modeli

Prvo skupino primerjalnih modelov sestavljajo negrafovski osnovni modeli. Z izrazom osnovni model označujemo preprostejši primerjalni model, s katerim preverimo, ali zahtevnejša arhitektura prinaša dodatno korist. V to skupino vključimo večinski klasifikator, naključni klasifikator, klasifikator podpornih vektorjev (SVM), Light Gradient Boosting Machine (LightGBM) in večplastni perceptron (MLP).

Večinski in naključni klasifikator predstavljata spodnjo primerjalno mejo. Večinski klasifikator vedno napove večinski razred testne množice, naključni klasifikator pa vse razrede napove z enako verjetnostjo (33,3 % oz 50 %). Če model ne preseže rezultatov teh dveh klasifikatorjev, težko trdimo, da se iz vhodnih podatkov uči uporabne vzorce.

SVM vključimo kot predstavnika jedrnih metod oziroma metod podpornih vektorjev, LightGBM kot učinkovitega predstavnika ansambelskih drevesnih metod z gradientnim spodbujevanjem, MLP pa kot osnovni nevronske model brez grafovske strukture. Hiperparametrov osnovnih modelov nismo optimizirali.

Pri modelih SVM in MLP vhodne značilke standardiziramo s pretvorbo, naučeno samo na učni podmnožici. Ista pretvorba se nato uporabi na testni in, v primeru MLP, tudi validacijski množici. LightGBM standardizacije ne potrebuje, zato prejme neposredno tabelarično predstavitev okna.

6.1.1 MLP

Osnovni MLP uporabimo kot nevronske model nad agregirano tabelarično predstavitev okna. Vhod modela je vektor agregiranih značilk enega 10-sekundnega okna, izhod pa logiti za tri razrede valence oziroma vznemirjenosti. Arhitektura je namerno preprosta: dve skriti polno povezani plasti velikosti 64 z aktivacijo ReLU in izpuščanjem, za njima pa izhodna linearna plast. Model učimo z navzkrižno entropijo. Za optimizacijo uporabimo AdamW, validacijsko podmnožico pa uporabimo za zgodnje ustavljanje na podlagi validacijske izgube.

6.2 Negrafovski predstavnik SOTA: GazeMAE + MLP

Za primerjavo s sodobnim temeljnim modelom smo uporabili odprtokodni prednaučeni kodirnik GazeMAE [4]. Uporabili smo ga po principu zamrzne hrbtenice. To pomeni, da parametrov kodirnika med učenjem nismo spreminjali, ampak smo z njim iz podatkov pogleda izračunali vektorske predstavitve, na katerih smo nato učili MLP. V tem delu MLP zato ne nastopa kot samostojen klasifikator nad ročno agregiranimi značilkami, temveč kot klasifikacijska glava nad značilkami, ki jih izračuna GazeMAE. Ker je bil GazeMAE učen na 2 s oknih, vzorčenih s frekvenco 500 Hz, smo tudi uporabljena 10 s okna najprej pretvorili v obliko, ki jo model pričakuje. Signala koordinat pogleda (x, y) smo razdelili na pet neprekrivajočih se 2 s kosov in ju prevzorčili na ciljno frekvenco 500 Hz. Iz teh kosov smo s kodirnikom pridobili predstavitev celotnega okna s 512 razsežnostmi, ta predstavitev pa je bila vhod v klasifikacijsko glavo MLP. Procesna veriga torej izgleda sledeče:

koordinate $(x, y) \rightarrow$ predprocesiranje $\rightarrow$ GazeMAE $\rightarrow$ predstavitev $\rightarrow$ MLP $\rightarrow$ napoved.

(6.1)

TODO: naredi lep diagram/grafiko/nekaj boljšega kot je trenutni zapis procesne verige.

6.3 Osnovni GCN

TODO:

- Ta razdelek naj ne redefinira grafa; sklicuj se na poglavje 5.
- Natančno povej samo arhitekturno razliko: osnovni GCN združi vse relacije v homogen graf, ne uporablja značilke povezav in ne uporablja naučenih uteži povezav.
- READOUT opiši samo kot konkretno izbiro modela, ne kot ponovno splošno definicijo klasifikacije grafov; splošna definicija je v poglavju 2.2.2.

Grafovski modeli se od negrafovskih modelov razlikujejo že v predstavitvi podatkov, saj okno meritev obravnavajo kot graf in ne kot tabelarični vektor značilke. Predlagani model, predstavljen v naslednjem odseku, tej predstavitvi doda še ločeno obravnavo tipov povezav, fuzijo relacijskih predstavitev in naučene uteži povezav. Zato za primerjavo s predlaganim modelom poleg negrafovskih modelov uporabimo še osnovni GCN, s katerim ločimo vpliv same grafovske predstavitve od vpliva bolj dodelane heterogene grafovske arhitekture.

Osnovni GCN je homogeni GCN. Osnovni GCN uporablja isto grafovsko predstavitev okna, kot je bila opisana v poglavju 5: vozlišča vsebujejo iste značilke, uporabljeni so isti izvorni signali in ista časovna okna. Od predlaganega GNN, ki ga opišemo v naslednjem odseku, se razlikuje po tem, da ne ločuje časovnih, prostorskih in fiksacijskih relacij. Vse povezave združi v en homogen graf, posredovanje sporočil pa izvede z običajnimi plastmi `GCNConv`. Model prav tako ne uporablja uteži povezav.

Tehnično lahko osnovni GCN zapišemo kot:

$$X \rightarrow f_{GCN} \rightarrow \text{READOUT} \rightarrow f_{\text{head}}, \quad (6.2)$$

kjer je X matrika značilke vozlišč, f_{GCN} zaporedje grafovskih konvolucijskih plasti, korak READOUT združi predstavitve vozlišč v predstavitev celotnega grafa, f_{head} pa iz te predstavitve izračuna napoved razreda. Ta model zato

predstavlja vmesno primerjavo med učenjem nad agregiranimi tabelaričnimi značilkami in predlaganim heterogenim grafovskim modelom.

[Ko bo osnovni GCN dokončno definiran, koda napisana, rezultati pridobljeni, tehnično še bolj specifikiraj točno arhitekturo. Npr: uporabljen je bil identičen MLP head, ista READOUT funkcija, isti preprocessing $X \rightarrow fGCN$, itd.] [Zamenjaj vse te diagrame z lepo grafiko, ki nazorno pokaže cevovode/poteke.]

TODO:

- Pisanje: opis uskladiti s končno implementacijo: ista grafovska predstavitev, isti signali, ista okna, iste delitve in ista standardizacija kot pri predlaganem GNN.
- Pisanje: preveriti in zapisati, da uporablja `GCNConv`, isto napovedno glavo, iste YAML hiperparametre in ločen readout parameter, trenutno `attention`; možnost `mean` omeni samo, če bo dejansko preverjena.

6.3.1 Izbira grafovske konvolucije

TODO:

- Odloči, ali ta razdelek ostane v poglavju 6 ali gre v eksperimentalni protokol kot utemeljitev fiksiiranega operatorja.
- Če ostane tukaj, naj poglavje 7 ne ponavlja razlage primerjave `GCNConv`, `GATConv`, `GraphConv` in `GINConv`, ampak naj se sklicuje sem oziroma v dodatek.

V vseh grafovskih modelih uporabimo plast `GCNConv` [10]. Ta izbira ohrani konvolucijski operator fiksni, zato lahko primerjava med grafovskimi modeli bolj jasno pokaže vpliv tistih delov, ki so za nalogo pomembnejši: ločevanja časovnih, prostorskih in fiksacijskih relacij, združevanja relacijskih predstavitev ter naučenih uteži povezav. Poleg tega `GCNConv` neposredno podpira skalarne uteži povezav, ki jih predlagani model izračuna iz značilk povezav.


Drugih grafovskih plasti zato ne obravnavamo kot del glavnega eksperimentalnega protokola. GATConv [17] bi pomenil drugačen način določanja pomembnosti sosedov in v trenutni implementaciji ne uporablja istih skalar-nih uteži povezav. GraphSAGE je zanimiv predvsem pri zelo velikih grafih in vzorčenju sosesk, kar pri grafih posameznih časovnih oken ni osrednja omejit-ev. GIN je močan model za klasifikacijo grafov, vendar bi zahteval dodatno uglaševanje na razmeroma majhni in šumni podatkovni zbirki. Grafovski transformerji so smiselna smer nadaljnjega dela, vendar bi v to nalogo vnesli še ločeno vprašanje pozicijskih in strukturnih kodiranj.

6.4 Predlagani prostorsko-časovni heterogeni GNN

Končni model nadgradi osnovni GCN iz prejšnjega odseka in temelji na prostorsko-časovni heterogeni grafovski nevronske mreži. Model ločeno obrav-nava časovne povezave naprej, časovne povezave nazaj, prostorske povezave in fiksacijske povezave. S tem lahko za različne tipe odnosov uporablja različne transformacije.

6.4.1 Pregled arhitekture

Osnovni potek modela je prikazan na sliki 6.1.



Slika 6.1: Delovna shema predlaganega GNN. Diagram prikazuje glavni tok podatkov od vhodnega okna do napovedi ter ločeno pot za izračun uteži povezav in pozornostnih uteži vozlišč.

TODO: Trenutni diagram je samo delovna predloga za pisanje. Pred oddajo je treba izdelati končne diagrame arhitekture in z njimi zamenjati to predlogo: pregledni diagram celotnega predlaganega GNN ter ločen diagram notranjosti heterogene GNN plasti. Besedilo pod diagrammom pa je treba prilagoditi poimenovanjem na diagramu. dodati je treba tudi računanje uteži na povezavah

Na diagramu je X vhodna matrika značilk vozlišč opisana v poglavju 5.2.2, f_{pre} je naučena preslikava X v skupni latentni prostor, $f_{\text{HeteroGNN}}$ so plasti predlagane heterogene grafovске nevronske mreže, f_{fuzija} označuje združevanje vseh štirih predstavitev vozlišča v eno skupno predstavitev, READOUT predstavlja združevanje predstavitev vozlišč v predstavitev celotnega grafa, ki se prenese kot vhod v napovedno klasifikacijsko glavo f_{head} .

Za primerjavo podajamo tudi potek osnovnega GCN:

$$X \rightarrow f_{\text{GCN}} \rightarrow \text{READOUT} \rightarrow f_{\text{head}}, \quad (6.3)$$

6.4.2 Relacijsko posredovanje sporočil in uteži povezav

TODO:

- Ta podrazdelek naj bo glavno mesto za arhitekturno razlago naučenih uteži povezav.
- Sem prestavi formuli za surovo oceno, preslikavo s tanh in normalizacijo uteži iz poglavja 5.5, če ostaneta del končnega modela.
- V poglavju 5 naj po predstavitvi ostane samo tabela značilk povezav in sklic, da jih končni model uporabi za izračun uteži.

Kot definirano v poglavju 5.3, $f_{\text{HeteroGNN}}$ ločeno obravnava različne relacije oziroma tipe povezav med vozlišči. Za primerjavo, osnovni GCN vse povezave obravnava kot enake, zato težje prilagodi posredovanje sporočil različnim odnosom med meritvami.

Posredovanje sporočil med vozlišči v heterogenem grafovskem modelu izvajamo ločeno po relacijah. Model se za vsako relacijo nauči svojo grafovsko

konvolucijo in tako ločeno izračuna predstavitev vozlišč na podlagi vseh štirih tipov povezav.

Za izračun uteži povezav se model uči treh večslojnih perceptronov f_w^{time} , f_w^{space} ter f_w^{fixation} . Te funkcije iz značilk povezave izračunajo skalarno predznačeno utež, ki določa, kako močno posamezna povezava vpliva na posredovanje sporočil. Ker so uteži predznačene, lahko povezava prispevek sosednjega vozlišča tudi zmanjša. Časovne povezave naprej in nazaj si delijo isto funkcijo f_w^{time} , smer povezave pa je podana kot dodatna značilka povezave ρ_{ij} . Značilke povezav, iz katerih model izračuna uteži, so opisane v poglavju 5.5.

[Ko bomo imeli sliko/diagram poteka (nekaj podobnega kot je GFM-for-eyetracker/docs/figures/gnn_pipeline bomo tukaj referencirali funkcijo/MLP, ki računa uteži. Trenutno za placeholder pustimo f_w^{rel}].

[Če normalizacijo uteži prestaviš iz poglavja 5 v 6.4, dodaj tukaj kratko formulo; sicer formule ne ponavljaj.]

6.4.3 Fuzija relacijskih predstavitev

Po posredovanju sporočil po različnih tipih povezav dobimo za vsako vozlišče eno predstavitev na relacijo. Te predstavitve združimo na ravni vozlišč s konkatencijo in MLP fuzijo v enotno predstavitev vozlišča:

$$\mathbf{h}_i = f_{\text{fuzija}} \left(\left[\mathbf{h}_i^{(t+)} \parallel \mathbf{h}_i^{(t-)} \parallel \mathbf{h}_i^{(s)} \parallel \mathbf{h}_i^{(f)} \right] \right), \quad (6.4)$$

kjer $\parallel$ označuje konkatencijo, $\mathbf{h}_i^{(t+)}$ časovno predstavitev naprej, $\mathbf{h}_i^{(t-)}$ časovno predstavitev nazaj, $\mathbf{h}_i^{(s)}$ prostorsko predstavitev in $\mathbf{h}_i^{(f)}$ fiksacijsko predstavitev.

6.4.4 Predstavitev grafa in napoved

TODO:

- Ne ponavljaš splošne razlage READOUT iz poglavja 2.2.2.
- Tukaj opiši samo konkretno izbiro arhitekture: združevanje s pozornostjo, izračun α_v , klasifikacijska glava in izguba za dejansko število razredov.
- Uskladi besedilo in izgubo z novo glavno nalogo: binarna klasifikacija valence, ne trirazredna valenca in vzburjenost, razen če bo ta del ostal kot sekundarni eksperiment.

Ker napovedujemo oznako celotnega okna, moramo predstavitev vozlišč združiti v predstavitev grafa. Uporabimo združevanje s pozornostjo:

$$\mathbf{h}_G = \sum_{v \in V} \alpha_v \mathbf{h}_v, \quad (6.5)$$

kjer je $\mathbf{h}_G$ predstavitev grafa, α_v utež pozornosti za vozlišče v , $\mathbf{h}_v$ pa predstavitev vozlišča v . S tem modelu omogočimo, da se dinamično opre na informativne dele časovnega okna, torej na informativna vozlišča. Uteži pozornosti izračunamo s softmax normalizacijo, kot je običajno pri mehki pozornosti in pozornostnem združevanju grafov [2, 11]:

$$\alpha_v = \frac{\exp(g(\mathbf{h}_v))}{\sum_{u \in V} \exp(g(\mathbf{h}_u))}, \quad (6.6)$$

kjer je g naučena funkcija, ki vozliščni predstavitvi priredi skalarno oceno pomembnosti.

Predstavitev grafa $\mathbf{h}_G$ posredujemo v napovedno glavo f_{head} , ki vrne logite za tri razrede. Pri vrednotenju logite s funkcijo softmax pretvorimo v napovedne verjetnosti, končno napoved pa določimo kot razred z največjo napovedno verjetnostjo. Valenco in vzburjenost obravnavamo kot ločeni klasifikacijski nalogi, zato za vsako nalogo učimo ločen model z enako arhitekturo. Model

učimo z znano navzkrižno entropijo za trirazredno klasifikacijo:

$$\mathcal{L} = - \sum_{c=1}^3 y_c \log \hat{y}_c, \quad (6.7)$$

kjer je $\mathcal{L}$ izguba, y_c prava oznaka razreda c , $\hat{y}_c$ pa napovedana verjetnost za razred c [7].

Podrobnosti optimizacije, kot so učna stopnja, velikost mini-serij in število epoh, podamo v eksperimentalnem protokolu.

6.4.5 Stabilizacija učenja

Pri učenju uporabimo več uveljavljenih mehanizmov, ki pomagajo pri stabilnosti optimizacije in zmanjševanju prekomernega prileganja. Rezidualne povezave olajšajo pretok informacij skozi več grafovskih plasti, normalizacija plasti stabilizira porazdelitve latentnih predstavitev, aktivacija GELU uvede gladko nelinearnost, izpuščanje pa deluje kot regularizacija [8, 1, 9, 15]. Te komponente ne spreminjajo grafovske predstavitve podatkov, temveč izboljšajo učni postopek predlagane arhitekture.

[Dodamo angleške izraze v oklepajih? Npr. izpuščanje (ang. dropout)]

Poglavje 7

Eksperimentalni protokol

7.1 Eksperimentalne naloge

TODO:

- Novo delovno izhodišče: glavna naloga naj bo binarna klasifikacija, ne več 3-razredna klasifikacija; obstoječi opis 3-razredne naloge kasneje prestaviti v dodatni ali primerjalni del, če jo bomo še poročali.
- Glavno primerjavo zastaviti kot $\text{model} \times \text{nabor signalov}$, z nabori *gaze*, *gaze+pupil* in *all*; *pupil-only* naj ostane placeholder za morebitni MOMENT eksperiment, ne obvezni del GNN primerjave.
- Za začetek uporabiti subject k-fold kot glavni protokol; recording k-fold, subject LOO in recording LOO označiti kot možne dodatne robustnostne preveritve, če bodo izvedene.
- GazeMAE trenirati oziroma uporabiti samo na *gaze-only*; v tabelah ga je dovoljeno primerjati tudi z drugimi nabori kot referenčni model, vendar ne kot model, treniran na teh signalih.

7.1.1 Valenca in vzburjenost

V nalogi obravnavamo dve glavni klasifikacijski nalogi: 3-razredno klasifikacijo valence ter 3-razredno klasifikacijo vzburjenosti. Obe nalogi definiramo po preslikavi iz tabele 6 izvirnega članka podatkovne zbirke MAHNOB-HCI [14]. Razredi niso dobljeni z neposredno diskretizacijo številskih samoocen valence in vzburjenosti, temveč iz poročane čustvene oznake `emotion-id`. S tem eksperimentalni nalogi sledita izvirni formulaciji in omogočata primerjavo z objavljenimi rezultati na isti podatkovni zbirki. Za dodatno primerjavo uporabimo tudi binarni različici, pri katerih obdržimo samo oba skrajna razreda.

TODO:

- Eksperimenti: pognati glavni nalogi diplome kot 3-razredno klasifikacijo valence in 3-razredno klasifikacijo vzburjenosti, ker sta tako neposredno primerljivi z formulacijo v MAHNOB-HCI.
- Eksperimenti: pognati še binarni low/high različici valence in vzburjenosti, kjer odstranimo srednji oziroma nevtralni razred in obdržimo izrazitejša skrajna razreda.

TODO:

- Pisanje: v besedilu jasno ločiti glavni eksperiment od dodatnega binarnega eksperimenta; binarno formulacijo opiši kot čistejšo in lažjo dopolnilno evalvacijo, ne kot zamenjavo glavne naloge.
- Pisanje: po rezultatih preveriti, ali imena razredov v tabelah, slikah in dodatkih sledijo enaki terminologiji kot v tabeli 7.1.

Tabela 7.1: Preslikava čustvenih oznak v razrede valence in vzburjenosti, povzeta po tabeli 6 izvirnega članka MAHNOB-HCI [14].

Ciljna naloga	Razred	Čustvene oznake
Valenca	neprijetna (<i>unpleasant</i>)	<i>fear, anger, disgust, sadness, anxiety</i>
Valenca	nevtralna (<i>neutral valence</i>)	<i>neutral, surprise</i>
Valenca	prijetna (<i>pleasant</i>)	<i>joy/happiness, amusement</i>
Vzbujenost	nizka (<i>calm</i>)	<i>sadness, disgust, neutral</i>
Vzbujenost	srednja (<i>medium aroused</i>)	<i>joy/happiness, amusement</i>
Vzbujenost	visoka (<i>excited/activated</i>)	<i>surprise, fear, anger, anxiety</i>

7.2 Validacijska protokola

7.2.1 Prečno preverjanje z izpuščanjem enega primerka

Uporabimo dva validacijska protokola prečnega preverjanja tipa "izpusti enega" (ang. *leave-one-out*, LOO). Pri takem protokolu množico podatkov najprej razdelimo na primerke po izbrani kategoriji, na primer po subjektih ali posnetkih. V vsaki iteraciji nato en primerek izvzamemo iz množice in njegove podatke uporabimo kot testno množico, podatke ostalih primerkov pa uporabimo za učenje oziroma jih pri nevronskih modelih dodatno razdelimo na učno in validacijsko množico. Pri klasičnih modelih strojnega učenja, kot sta SVM in LightGBM, validacijske množice v osnovnem učenju ne potrebujemo, pri nevronskih modelih, kot sta MLP in GNN, pa jo uporabimo za spremljanje učenja, spreminjanje hiperparametrov učenja ter zgodnje ustavljanje.

Velikost validacijske množice smo določili z `val_size=2`. Ta vrednost ustreza velikostnemu redu uporabljene podatkovne množice, ki po filtriranju vsebuje 22 subjektov in 20 posnetkov. Od testne množice se validacijska

razlikuje po tem, da lahko vpliva na potek učenja oziroma izbiro modela, testna množica pa ostane namenjena samo končni oceni delovanja v posamezni iteraciji.

Uporabili smo dva validacijska protokola prečnega preverjanja tipa LOO:

- **Subject LOO:** v vsaki iteraciji so podatki enega subjekta testna množica, podatki ostalih subjektov pa so na voljo za učenje oziroma validacijo.
- **Recording LOO:** v vsaki iteraciji so podatki enega posnetka oziroma stimulusa testna množica, podatki ostalih posnetkov pa so na voljo za učenje oziroma validacijo.

Kombinirane delitve po subjektih in posnetkih v tej nalogi ne uporabljamo, ker bi bila računsko bistveno dražja in bi presegla obseg diplomske naloge.

Pred izvedbo delitev smo iz podatkov izključili subjekte P9, P12 in P15. Ti subjekti so kot problematični navedeni že v izvirnem članku podatkovne zbirke MAHNOB-HCI, zato jih izključimo tudi tukaj in s tem ohranimo boljšo primerljivost z izvirnimi rezultati. Pri oznakah uporabimo samo primere, pri katerih je vrednost stolpca `emotion-derivation-status` enaka `ok`, saj s tem odstranimo ogleda posnetkov z nezanesljivo izpeljano čustveno oznako.

Pri vsaki iteraciji prečnega preverjanja standardizacijo izračunamo samo na učni množici. Tako za značilke vozlišč, značilke povezav in tabelarične značilke najprej izračunamo statistike učne množice, nato pa isto pretvorbo uporabimo še na validacijski in testni množici. S tem preprečimo uhajanje informacij iz validacijske ali testne množice v učni postopek.

TODO:

- Eksperimenti: za glavne rezultate pognati subject LOO kot primarni validacijski protokol in recording LOO kot dodatni poročani protokol.
- Eksperimenti: kfold ne uporabljati in ne poročati kot glavni rezultat za primerjavo modelov; izjema je ablacijska študija, opisana v razdelku 7.6.

TODO:

- Pisanje: v poglavju z rezultati naj bodo glavne tabele najprej za subject LOO, nato za recording LOO; kfold naj se pojavi samo pri ablacijski študiji.
- Pisanje: jasno zapisati, da subject LOO ocenjuje posploševanje na nove udeležence, recording LOO pa posploševanje na nove posnetke oziroma stimulse.

7.2.2 Subject LOO

Subject LOO meri posploševanje na nove udeležence. Izvedli smo ga zato, ker pri uporabi modela na novem uporabniku običajno nimamo označenih podatkov zanj. S tem protokolom ocenimo, kako dobro se naučeni vzorci prenesejo na nove subjekte in koliko so modeli občutljivi na razlike med posameznimi udeleženci.

V vsaki iteraciji je en subjekt v testni množici. Pri nevronske modelih sta dva izmed preostalih subjektov v validacijski množici, ostalih 19 subjektov pa je v učni množici. Pri tem protokolu delimo podatke po subjektih, zato so lahko podatki vseh posnetkov prisotni v učni, validacijski in testni množici.

7.2.3 Recording LOO

Recording LOO meri posploševanje na nove posnetke oziroma stimulse. Izvedli smo ga zato, ker preverja drugačen vidik posploševanja kot Subject LOO: nov posnetek lahko povzroči drugačne vzorce pogleda, saj je pogled usmerjen na druge dele zaslona in sledi drugačnemu dogajanju. S tem preverimo, kako dobre so napovedi modelov pri novem stimulusu.

V vsaki iteraciji je en posnetek v testni množici. Pri nevronske modelih sta dva izmed preostalih posnetkov v validacijski množici, ostalih 17 posnetkov pa je v učni množici. Pri tem protokolu delimo podatke po posnetkih, zato so lahko podatki vseh subjektov prisotni v učni, validacijski in testni množici.

7.3 Metrike

Za vsako nalogo in vsak validacijski protokol izračunamo več metrik, ker različne metrike povedo različne informacije o delovanju modela. Kot glavni metriki uporabimo točnost in macro-F1, z namenom direktne primerjave z izvirnim člankom podatkovne zbirke MAHNOB-HCI. Članek sicer ne poroča izrecno, ali uporablja navadno ali uravnoteženo točnost oziroma macro-F1 ali weighted-F1, vendar to utemeljeno sklepamo iz poročanih rezultatov naključnega klasifikatorja.

Rezultate metrik poročamo kot povprečje in standardni odklon čez iteracije prečnega preverjanja, torej v obliki $\text{mean} \pm \text{std}$.

7.4 Spremljanje učenja in diagnostika

TODO:

- Napiši, da diagnostiko učenja obravnavamo ločeno od končnih metrik vrednotenja, kot so accuracy, F1 in AUC.
- Navedi, da za nevronske modele shranjujemo učno izgubo, validacijsko izgubo, najboljšo epoho, zgodnje ustavljanje, čas epohe, trenutno stopnjo učenja in norme gradientov.
- Pojasni, da krivulji učne in validacijske izgube uporabimo za preverjanje stabilnosti optimizacije in znakov prekomernega prilaganja; testno izgubo izračunamo šele po izbiri najboljšega modela.
- Za grafovske modele napiši, da dodatno spremljamo varianco predstavitev grafa, povprečno kosinusno podobnost predstavitev, razpon logitov in entropijo napovednih verjetnosti.
- Pojasni namen teh GNN diagnostik: zaznavanje prekomernega glajenja, kolapsa predstavitev in skoraj konstantnih napovedi klasiﬁkacijske glave.
- Za predlagani model omeni še povzetke naučenih uteži povezav po časovnih, prostorskih in fiksacijskih relacijah.
- V glavnem besedilu poročaj samo agregirane krivulje izgub, porazdelitev najboljše epohe in ključne GNN diagnostike; podrobne grafe po gubah in relacijske porazdelitve uteži prestavi v dodatek D.

7.5 Glavna primerjava modelov

TODO:

- Ta razdelek naj bo samo protokolarni povzetek primerjanih modelov, signalnih naborov in hiperparametrov.
- Ne razlagaj ponovno, kaj je homogeni ali heterogeni graf; za to uporabi sklic na poglavji 2 in 5.
- Ne razlagaj ponovno naučenih uteži povezav, relacijskega posredovanja sporočil ali READOUT; za to uporabi sklic na poglavje 6.
- Tabela modelov naj vsebuje kratek opis vloge modela v primerjavi, ne metodološke definicije.

TODO:

- Ta razdelek kasneje prepisati v opis glavne factorske primerjave: modeli po vrsticah, nabori signalov po stolpcih oziroma ločeni teki za *gaze*, *gaze+pupil* in *all*.
- Ločiti modele, ki so definirani za vse nabore signalov, od modelov, ki so smiselni samo za posamezen nabor: GazeMAE za *gaze-only*, morebitni MOMENT za *pupil-only* oziroma zenični del.

Glavna primerjava vključuje modele v tabeli 7.3. Tabela poleg imena modela povzema kratko vlogo modela v primerjavi in osnovne parametre, ki jih pri posamezni vrsti modela poročamo ali uporabljamo pri razlagi rezultatov.

[Na koncu preveri, da se vrstni red ujema z vrstnim redom v tabelah/plotih. Preveri tudi, da se ujemajo poimenovanja znotraj diplome (recimo, če si že definiral naš GNN kot X , potem uporablaj ta konsistentno v besedilu, tabelah in slikah).]

Vsi grafovski modeli v glavnih poskusih uporabljajo GCNConv. V dodatnem poskusu na naboru pogled+zenici smo preizkusili še GATConv, GraphConv in GINConv oziroma GINEConv. Razlike med različicami niso bile velike, GCNConv pa je dosegel primerljive in stabilne rezultate pri neuteženi in uteženi

arhitekturi. Zato smo v glavnih poskusih ohranili enoten operator `GCNConv`, podrobnosti primerjave pa podajamo v dodatku A.1.

TODO:

- Če je izbira grafovske konvolucije razložena v poglavju A.1, tukaj pusti samo protokolarno odločitev in sklic.
- Preveri sklic: trenutno A.1 kaže na razdelek v poglavju 6, ne v dodatek.

Za nastavitev predlaganega GNN smo izvedli kompakten grid search na 3-razredni valenci s subject k-fold protokolom ($k = 5$, en subjekt na validacijsko množico), pri čemer smo preizkusili `num_layers` $\in \{2, 3, 4\}$, `hidden_channels` $\in \{64, 128, 256\}$, `kt` $\in \{1, 2, 3\}$, `ks` $\in \{1, 2, 3\}$ in `kf` oziroma `fixation_dilation_k` $\in \{1, 2, 3, 5\}$. Kot končno nastavitev smo izbrali `num_layers=2`, `hidden_channels=64`, `kt=1`, `ks=1` in `kf=3`, saj je bila ta konfiguracija med najboljšimi po accuracy in macro-F1, hkrati pa je ohranila razmeroma majhen model s 101.143 učljivimi parametri in uravnoteženo gostoto grafovskih povezav.

TODO:

- Eksperimenti: preveriti, da primerjava vključuje diplomski grafovski baseline **osnovni GCN**; stare interne različice grafovskega modela ne sodijo v diplomsko primerjavo.
- Eksperimenti: za osnovni GCN uporabiti isto grafovsko predstavitev, iste signale, ista okna, iste delitve in isto standardizacijo kot pri predlaganem GNN.
- Eksperimenti: pri osnovnem GCN združiti relacije `temporal_forward`, `temporal_backward`, `spatial` in `fixation` v homogeni graf, odstraniti podvojene povezave ter ne uporabiti značilk povezav ali naučenih uteži povezav.
- Eksperimenti: preveriti, da osnovni GCN uporablja `GCNConv`, isto napovedno glavo, iste YAML hiperparametre in ločen parameter za readout; trenutni readout je `attention`, pozneje lahko preverimo še `mean`.
- Eksperimenti: preveriti, da osnovni GCN deluje za 2- in 3-razredno klasifikacijo ter da sta `num_layers=3` in `hidden_channels=128` res uporabljena tudi pri njem.

TODO:

- Pisanje: v tabeli in besedilu uporabljaj izraz osnovni GCN.
- Pisanje: v razlagi osnovnega GCN poudari, da je to arhitekturno poenostavljen grafovski baseline, ne starejša različica predlaganega modela.

7.6 Ablacijska študija

TODO:

- Če ta razdelek ostane, naj opisuje samo protokol ablacijske študije.
- Ne razlagaj ponovno, kako so časovne, prostorske ali fiksacijske povezave zgrajene; sklicuj se na poglavje 5.
- Ne razlagaj ponovno, kako model uporablja relacije ali uteži; sklicuj se na poglavje 6.

TODO:

- Preveriti, ali ta razdelek po novi zasnovi sploh ostane ločena ablacijska študija ali se združi z glavno primerjavo signalnih naborov.
- Če ostane ločeno, naj ablacijska študija odgovarja predvsem na vprašanja znotraj predlaganega GNN; primerjava *gaze*, *gaze+pupil* in *all* naj bo glavna signalna primerjava, ne samo ablacijska opomba.

Namen ablacijske študije je bil preveriti, koliko kateri signali prispevajo k boljšim napovedim predlaganega modela. Izhodišče je bil predlagani model iz glavne primerjave. Pri vsaki ablacijski nastavitvi smo ohranili enak validacijski protokol, enake delitve podatkov in enake hiperparametre učenja, zakrili pa smo samo eno skupino informacij (en signal).

Preverili smo štiri ablacijske nastavitve. Pri prvi smo odstranili značilke velikosti zenic. Pri drugi smo odstranili časovno informacijo, torej časovne značilke vozlišč in povezav ter časovne povezave. Pri tretji smo odstranili prostorsko informacijo, ki vključuje koordinate pogleda (x, y) , razdaljo in iz njih izpeljane prostorske povezave ter značilke povezav. Pri četrti smo odstranili informacijo o fiksacijah, torej trajanje fiksacij in fiksacijske povezave.

TODO:

- Eksperimenti: ablacijske poskuse pognati za 3-razredno valenco in 3-razredno vzburjenost.
- Eksperimenti: zaradi časovne ekonomičnosti ablacijske poskuse pognati na subject kfold, trenutno z $k = 5$, ne na polnem subject LOO.
- Eksperimenti: pripraviti ablacijske nastavitve za odstranitev časovne informacije, prostorske oziroma gaze informacije, fiksacijske informacije, zenične informacije in razdaljne informacije.
- Eksperimenti: ko odstranimo signal, odstraniti vse informacije, izpeljane iz njega: značilke vozlišč, značilke povezav in povezave.

TODO:

- Pisanje: trenutni opis štirih ablacijsko nastavitvev uskladiti s petimi skupinami signalov; razdaljo obravnavaj ločeno od prostorske/gaze informacije, če bo tako implementirana v poskusih.
- Pisanje: po pridobitvi rezultatov odločiti, ali v glavnem besedilu podrobno poročamo obe nalogi ali predvsem valenco; za vzburjenost naj bodo vsaj podporni rezultati v dodatku.
- Pisanje: v poglavju z rezultati zapisati, da so kfold in LOO rezultati dovolj primerljivi za ablacijsko analizo, ker nas zanima relativni vpliv odstranitve signalov, ne končna absolutna ocena modela.

[Morebitni dodatni poskusi naj bodo obravnavani kot ločena arhitekturna analiza, ne kot ablacijska študija vhodnih signalov: izklop uteži povezav, uporaba 5 s oken namesto 10 s oken, odstranitev MLP fuzije relacijskih predstavitev in primerjava različnih strategij združevanja grafa.]

Tabela 7.2: Metrike, uporabljene pri vrednotenju modelov.

Metrika	Definicija	Interpretacija
Accuracy	Delež pravilno razvrščenih primerov med vsemi primeri.	Ena izmed dveh glavnih metrik za primerjavo z izvirnimi rezultati na podatkovni zbirki MAHNOB-HCI.
Macro-F1	Povprečje vrednosti F1 po razredih, pri čemer ima vsak razred enako težo.	Druga glavna metrika za primerjavo z izvirnim člankom; posebej pomembna pri neuravnoteženih razredih.
Balanced accuracy	Povprečje priklica po razredih.	Enaka teža vseh razredov pri oceni uspešnosti.
Weighted-F1	Povprečje vrednosti F1 po razredih, uteženo s številom primerov v posameznem razredu.	Dodatna ocena uspešnosti glede na dejansko porazdelitev razredov.
AUC	Ločljivost razredov na podlagi napovedanih verjetnosti; pri večrazredni nalogi jo izračunamo po pristopu one-vs-rest.	Podporna informacija o ločevanju posameznih razredov.
Confusion matrix	Število in delež napovedi za vsako kombinacijo pravega in napovedanega razreda.	Razlaga tipičnih napak modela; pri prikazu je normalizirana po vrsticah.

Tabela 7.3: Modeli, vključeni v glavno primerjavo, njihova vloga in osnovni parametri.

Model	Opis	Parametri
Naključni klasifikator	Enakomerno naključno vzorčenje razreda.	<code>random_state=42</code>
Večinski klasifikator	Napoved najpogostejšega razreda učne množice.	/
SVM	Klasifikator z jedrom RBF nad agregiranimi značilkami okna.	<code>C=1.0, kernel=rbf,</code> <code>probability=true</code>
LightGBM	Gradientno spodbujena odločitvena drevesa nad agregiranimi značilkami okna.	<code>n_estimators=100,</code> <code>learning_rate=0.05,</code> <code>max_depth=5</code>
MLP	Polno povezana nevronska mreža nad agregiranimi značilkami okna.	<code>hidden_layers=(64,64),</code> <code>dropout=0.1,</code> <code>learning_rate=0.001,</code> <code>weight_decay=0.0001</code>
GazeMAE + MLP	Zamrznjen prednaučen kodirnik položajev pogleda.	predstavitev z 512 razsežnostmi, <code>hidden_layer_size=128,</code> <code>dropout=0.2,</code> <code>learning_rate=0.001</code>
Osnovni GCN	Homogeni grafovski primerjalni model z enotnim posredovanjem sporočil.	<code>GCNConv, num_layers=3,</code> <code>hidden_channels=128</code>
Predlagani GNN	Heterogena časovno-prostorska grafovska nevronska mreža z naučenimi utežmi povezav.	<code>GCNConv, num_layers=2,</code> <code>hidden_channels=64, kt=1,</code> <code>ks=1, kf=3,</code> <code>relation_pooling=mlp,</code> <code>graph_pooling=attention</code>

Poglavje 8

Rezultati

TODO:

- Poglavje rezultatov preurediti okoli glavne binarne naloge in subject k-fold protokola.
- Glavni prikaz naj primerja modele pri naborih *gaze*, *gaze+pupil* in *all*; najprimernejša oblika je tabela ali heatmapa model $\times$ nabor signalov za macro-F1 in accuracy.
- 3-razredne rezultate in LOO protokole prestaviti v dodatni ali sekundarni del, če bodo sploh izvedeni oziroma poročani.
- GazeMAE prikazati kot model, naučen/uporabljen na *gaze-only*, in ga po potrebi primerjati z modeli na bogatejših naborih kot močno referenčno točko, ne kot model z enakim vhodom.
- *Pupil-only* rezultatov ne obljubljeni, dokler ni jasna implementacija MOMENT + MLP oziroma GNN protokol.

TODO:

- Eksperimenti: najprej zbrati rezultate glavnih poskusov na MAHNOB-HCI za 3-razredno valenco in 3-razredno vzburjenost.
- Eksperimenti: za vsako glavno nalogo zbrati subject LOO kot glavni rezultat in recording LOO kot dodatni rezultat; kfold rezultatov ne vključuj v glavne tabele.
- Eksperimenti: zbrati še rezultate binarne low/high valence in binarne low/high vzburjenosti kot dodatna poskusa v glavnem besedilu.

TODO:

- Pisanje: rezultate poročati kot $\text{mean} \pm \text{std}$ čez gube oziroma iteracije validacijskega protokola.
- Pisanje: glavne tabele v tem poglavju naj vsebujejo samo accuracy in macro-F1; balanced accuracy, weighted-F1, AUC in podrobnejše tabele prestavi v dodatek.
- Pisanje: grid search hiperparametrov predlaganega GNN omeni samo kratko kot podporni poskus za izbiro konfiguracije. Glavni opis iskalnega prostora in utemeljitev izbire naj ostaneta v eksperimentalnem protokolu; v rezultatih po potrebi dodaj največ eno kratko poved ali majhno tabelo v dodatku.
- Pisanje: eSEEd_v2 rezultatov ne mešati z glavnimi tabelami; če jih ohranimo, sodijo v dodatek ali kratko motivacijsko opombo.
- Pisanje: pred oddajo uskladiti vrstni red modelov v tabelah, slikah in besedilu z vrstnim redom v poglavju 7.5.

TODO:

- Pisanje: v dodatku pripraviti razširjene tabele z balanced accuracy, weighted-F1, AUC, po potrebi še rezultati po posameznih gubah in dodatnimi matrikami zmede.
- Pisanje: preveriti strukturo dodatkov in po potrebi prenoviti dodatek z dodatnimi rezultati, da ne podvaja glavnih tabel iz tega poglavja.

TODO:

- Uredniški plan slik v glavnem besedilu: obdrži samo slike, ki neposredno podprejo glavno zgodbo rezultatov. Cilj je približno ena slika za porazdelitev podatkov, ena do dve slike za glavne rezultate, ena slika za napake modela, ena slika za ablacijsko študijo in po potrebi ena diagnostična slika.
- Glavno besedilo: ne dodajaj vseh avtomatsko ustvarjenih plotov iz eksperimentalnega cevovoda. Heatmape vseh metrik, dodatne matrike zmede, per-fold grafe, recording LOO podrobnosti in alternativne metrike prestavi v dodatek A.
- Kandidatna slika: UMAP procesiranih podatkov ali naučenih predstavitev. Vključi jo samo, če je vizualno berljiva, stabilna glede na naključni seed in pomaga razložiti razliko med vhodnimi podatki, GazeMAE predstavitev ali GNN predstavitevami.
- Če UMAP ne pokaže jasne razredne ali modelne strukture, ga uporabi največ kot opombo v dodatku A; v glavnem besedilu ga izpusti.

8.1 Porazdelitev razredov

8.1.1 3-razredna valenca

TODO:

- Eksperimenti: iz končnega snapshot-a po tvorbi oken izračunati število in delež oken za razrede neprijetna, nevtralna in prijetna valenca.
- Eksperimenti: izračun ponoviti za podatke po izključitvi subjektov P9, P12 in P15 ter po filtriranju `emotion-derivation-status=ok`.
- Eksperimenti: preveriti in navesti uporabljeno vrednost `min_samples_per_window=60`.
- Slika: valenco združi z vzburjenostjo v eno skupno sliko porazdelitve razredov; ne ustvarjaj dveh ločenih glavnih slik.

TODO:

- Pisanje: poročati, ali je bil uporabljen downsampling oziroma kakšna druga obravnava neuravnoteženosti razredov.
- Pisanje: kratko povezati porazdelitev razredov z interpretacijo večinskega klasifikatorja.

8.1.2 3-razredna vzburjenost

TODO:

- Eksperimenti: iz končnega snapshot-a po tvorbi oken izračunati število in delež oken za razrede nizka, srednja in visoka vzburjenost.
- Eksperimenti: preveriti, ali je porazdelitev vzburjenosti bolj neuravnotežena ali manj usklajena s samoocenami kot porazdelitev valence.
- Slika: vzburjenost naj bo drugi panel skupne slike porazdelitve razredov.

TODO:

- Pisanje: poročati neuravnoteženost razredov in večinski klasifikator kot referenčno točko.
- Pisanje: v interpretaciji biti previden, ker je ujemanje oznak vzburjenosti s samoocenami šibkejše kot pri valenci.

8.1.3 Binarni nalogi

TODO:

- Eksperimenti: za binarno low/high valenco izračunati število in delež oken po odstranitvi srednjega oziroma nevtralnega razreda.
- Eksperimenti: za binarno low/high vzburjenost izračunati število in delež oken po odstranitvi srednjega razreda.
- Dodatek A: binarne porazdelitve naj bodo v dodatku, razen če postanejo ključne za razlago glavnega rezultata.

TODO:

- Pisanje: binarni nalogi predstaviti kot dodatno evalvacijo z izrazitejšimi razredi, ne kot glavno formulacijo naloge.

8.2 Rezultati za 3-razredno valenco

8.2.1 Subject LOO

TODO:

- Eksperimenti: pognati vse modele za 3-razredno valenco pri subject LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1 kot mean $\pm$ std.

TODO:

- Pisanje: to tabelo obravnavaj kot glavno tabelo rezultatov za valenco.
- Pisanje: po rezultatih dodati kratek komentar najboljšega modela, najboljšega negrafovskega primerjalnega modela in razlike med osnovnim GCN ter predlaganim GNN.

Tabela 8.1: TODO: Rezultati za 3-razredno klasifikacijo valence pri subject LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

TODO:

- Slika: dodati bar plot accuracy in macro-F1 za 3-razredno valenco pri subject LOO, če tabela sama ni dovolj pregledna. Slika naj bo združljiva po slogu z ustrezno sliko za vznurjenost ali naj obe nalogi združi v eno sliko.
- Slika: dodati vrstično normalizirano matriko zmede za najboljši model pri 3-razredni valenci; po potrebi dodati še primerjavo z najboljšim negrafovskim modelom.

8.2.2 Recording LOO

TODO:

- Eksperimenti: pognati vse modele za 3-razredno valenco pri recording LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1 kot mean $\pm$ std.

TODO:

- Pisanje: recording LOO poročaj kot dodatni rezultat, ki preverja posploševanje na nove posnetke oziroma stimuluse.

Tabela 8.2: TODO: Rezultati za 3-razredno klasifikacijo valence pri recording LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

8.2.3 Interpretacija rezultatov

TODO:

- Pisanje: interpretirati predvsem subject LOO, ker je to glavni protokol za končne rezultate.
- Pisanje: primerjati predlagani GNN z najboljšim negrafovskim primerjalnim modelom, GazeMAE + MLP in osnovnim GCN.
- Pisanje: primerjati subject LOO in recording LOO ter opozoriti, da recording LOO še vedno deli iste subjekte med učno in testno množico.
- Pisanje: opisati najpogostejše zamenjave razredov iz matrike zmede.
- Pisanje: sklepe oblikovati previdno in jih vezati na accuracy, macro-F1 ter strukturo napak, ne samo na eno metriko.

8.3 Rezultati za 3-razredno vzburjenost

8.3.1 Subject LOO

TODO:

- Eksperimenti: pognati vse modele za 3-razredno vzburjenost pri subject LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1 kot mean $\pm$ std.

TODO:

- Pisanje: to tabelo obravnavaj kot glavno tabelo rezultatov za vzburjenost, vendar v interpretaciji upoštevaj slabše ujemanje oznak s samoocenami.

Tabela 8.3: TODO: Rezultati za 3-razredno klasifikacijo vzburjenosti pri subject LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

TODO:

- Slika: dodati bar plot accuracy in macro-F1 za 3-razredno vzburjenost pri subject LOO, po možnosti v isti sliki kot valenco.
- Slika: dodati vrstično normalizirano matriko zmede za najboljši model pri 3-razredni vzburjenosti.

8.3.2 Recording LOO**TODO:**

- Eksperimenti: pognati vse modele za 3-razredno vzburjenost pri recording LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1 kot mean $\pm$ std.

TODO:

- Pisanje: recording LOO poročaj kot dodatni rezultat in ga interpretiraj ločeno od subject LOO.

Tabela 8.4: TODO: Rezultati za 3-razredno klasifikacijo vzburjenosti pri recording LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

8.4 Binarna klasifikacija valence in vzburjenosti

8.4.1 Binarna valenca

TODO:

- Eksperimenti: pognati low/high valenco za subject LOO in recording LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1; podrobnejše metrike prestavi v dodatek.

TODO:

- Pisanje: pojasniti, da ta poskus odstrani nevtralni oziroma srednji razred in zato preverja čistejšo formulacijo z izrazitejšimi razredi.
- Pisanje: poročati, ali se relativni vrstni red modelov ujema s 3-razredno valenco.

Tabela 8.5: TODO: Rezultati za binarno low/high klasifikacijo valence pri subject LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

8.4.2 Binarna vzburjenost

TODO:

- Eksperimenti: pognati low/high vzburjenost za subject LOO in recording LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1; podrobnejše metrike prestavi v dodatek.

TODO:

- Pisanje: pojasniti, da ta poskus odstrani srednji razred vzburjenosti in preverja izrazitejši kontrast med nizko in visoko vzburjenostjo.
- Pisanje: poročati, ali binarna formulacija ublaži težave, opažene pri 3-razredni vzburjenosti.

Tabela 8.6: TODO: Rezultati za binarno low/high klasifikacijo vzburjenosti pri subject LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

TODO:

- Pisanje: odločiti, ali recording LOO tabele za binarno valenco in vzburjenost ostanejo v glavnem besedilu ali gredo v dodatek; v glavnem besedilu naj bo vsaj kratek povzetek.

8.5 Primerjava validacijskih protokolov

8.5.1 Posploševanje na nove subjekte

TODO:

- Pisanje: povzeti subject LOO rezultate za 3-razredno valenco in vzburjenost.
- Pisanje: komentirati variance med gubami in morebitne težavne subjekte, če jih pokažejo rezultati.
- Pisanje: posebej poudariti, da je subject LOO glavni protokol za končne rezultate naloge.

8.5.2 Posploševanje na nove posnetke

TODO:

- Pisanje: povzeti recording LOO rezultate za 3-razredno valenco in vzburjenost.
- Pisanje: primerjati, ali je posploševanje na nove posnetke lažje ali težje od posploševanja na nove subjekte.
- Pisanje: opozoriti, da recording LOO lahko deli iste subjekte med učno in testno množico, zato ne meri istega vidika posploševanja kot subject LOO.

8.6 Analiza oznak in napak

8.6.1 Ujemanje oznak s samoocenami

TODO:

- Eksperimenti: uporabiti artefakte iz `label_noise_analysis` za analizo ujemanja razredov valence in vzburjenosti s samoocenami.

TODO:

- Slika: dodati label-alignment plot ali matriko zmede iz `label_noise_analysis`.
- Glavno besedilo: uporabi največ eno sliko za ujemanje Table 6 oznak s samoocenami, prednostno heatmapo za valenco in vzburjenost skupaj. Podrobnejše label-noise slike prestavi v dodatek A.
- Pisanje: razložiti, zakaj pri interpretaciji vzburjenosti pričakujemo več negotovosti kot pri valenci.

8.6.2 Matrike zmede

TODO:

- Slika: dodati matriko zmede za najboljši GNN pri 3-razredni valenci.
- Slika: dodati matriko zmede za najboljši GNN pri 3-razredni vzburjenosti.
- Slika: po potrebi dodati matriko zmede za najboljši negrafovski primerjalni model samo v dodatek A, razen če neposredno spremeni interpretacijo glavne primerjave.
- Pisanje: matrike zmede naj bodo vrstično normalizirane z barvno lestvico $[0, 1]$.
- Pisanje: opisati najpogostejše zamenjave razredov in jih povezati s porazdelitvijo razredov ter analizo oznak.

8.7 Ablacijska študija

8.7.1 Vpliv vhodnih signalov in povezav

TODO:

- Eksperimenti: pognati ablacijsko študijo za 3-razredno valenco in 3-razredno vzburjenost.
- Eksperimenti: uporabiti subject kfold, trenutno $k = 5$, zaradi časovne ekonomičnosti.
- Eksperimenti: preveriti primerljivost kfold in LOO rezultatov na osnovnih konfiguracijah ter zapisati, da je primerljivost zadostna za relativno ablacijsko analizo.
- Eksperimenti: za vsako ablacijsko nastavitev odstraniti ustrezne značilke vozlišč, značilke povezav in povezave, izpeljane iz odstranjenega signala.

TODO:

- Pisanje: v glavnem besedilu glede na rezultate verjetno podrobneje poročati valenco, vzburjenost pa povzeti ali predstaviti v dodatek.
- Slika: dodati en ablation bar plot za accuracy in macro-F1. Če sta valenca in vzburjenost obe informativni, ju združi v eno sliko z dvema paneloma; sicer naj bo v glavnem besedilu samo valenca, vzburjenost pa v dodatku A.

Tabela 8.7: TODO: Ablacijska študija predlaganega modela pri 3-razredni valenci na subject kfold.

Nastavitev	Accuracy	Macro-F1
Predlagani GNN	TODO	TODO
Brez časovne informacije	TODO	TODO
Brez prostorske/gaze informacije	TODO	TODO
Brez fiksacijske informacije	TODO	TODO
Brez zenične informacije	TODO	TODO
Brez razdaljne informacije	TODO	TODO

8.8 Analiza učenja in notranjih predstavitev

8.8.1 Krivulje izgub

TODO:

- Eksperimenti: zbrati najboljšo epoho, zgodnje ustavljanje in morebitne znake nestabilnega učenja.

TODO:

- Slika: dodati train/val loss krivulje za glavne nevronske modele, posebej za osnovni GCN in predlagani GNN. V glavnem besedilu naj bo samo agregiran ali reprezentativen prikaz; per-fold krivulje prestavi v dodatek D.
- Pisanje: krivulje uporabiti za podporo interpretaciji rezultatov, ne kot novo glavno evalvacijo.

8.8.2 Predstavitev in grafske diagnostike

TODO:

- Eksperimenti: zbrati varianco predstavitev, povprečno kosinusno podobnost, razpon logitov in entropijo napovednih verjetnosti za grafske modele, če so artefakti na voljo.
- Eksperimenti: za predlagani GNN zbrati tudi povzetke naučenih uteži povezav po časovnih, prostorskih in fiksacijskih relacijah.

TODO:

- Kandidatna slika: UMAP naučenih predstavitev grafa za najboljši GNN in, če je smiselno, primerjava z vhodnimi agregiranimi značilkami ali GazeMAE predstavitvami.
- UMAP vključi v glavno besedilo samo, če jasno pokaže informativno strukturo in ne zgolj subjektnih ali stimulusnih skupkov; drugače ga prestavi v dodatek D ali izpusti.
- Pisanje: primerjati osnovni GCN in predlagani GNN samo toliko, kolikor diagnostika pomaga razložiti glavne rezultate.
- Pisanje: podrobne grafe po gubah in relacijske porazdelitve uteži predstaviti v dodatek D.

Poglavje 9

Diskusija

TODO:

- Diskusijo preusmeriti iz vprašanja, ali GNN absolutno zmaga, v vprašanje, kako se modeli obnašajo pri različnih naborih signalov.
- Posebej interpretirati razlike med *gaze*, *gaze+pupil* in *all*: ali zenični signal pomaga nad koordinatami pogleda, ali dodatni signali v *all* pomagajo ali dodajo šum, ter ali GNN bogatejšo strukturo izkoristi bolje kot negrafovski modeli.
- GazeMAE obravnavati kot močno *gaze-only* referenco; če premaga modele z več signali, to interpretirati kot pomembno ugotovitev o naučenih predstavitev pogleda.
- *Pupil-only* in MOMENT opisati samo kot prihodnje delo ali podporni poskus, če ne bosta dokončana.

9.1 Ali grafovska predstavitev pomaga?

TODO:

- ali finalni GNN premaga ne-grafovske baseline modele;
- če ne premaga: ali kaže smiselno vedenje;
- pri kateri nalogi je graf najbolj koristen;
- subject LOO vs recording LOO;
- primerjava proti GazeMAE + MLP;
- povezava z ablations;
- konservativen zaključek.

9.2 Vloga časovnih in prostorskih povezav

TODO:

- časovne povezave;
- prostorske povezave;
- fiksacijske povezave;
- forward/backward temporal separation;
- learned signed edge weights;
- distance-avg;
- fixation-duration;
- delta_distance edge feature;
- kaj to pomeni za eye-tracking signale;
- brez kavzalnih trditev.

9.3 Primerjava z GazeMAE

TODO:

- ali GazeMAE + MLP premaga baseline modele;
- ali GazeMAE + MLP premaga GNN;
- self-supervised representation learning kot uporabna smer;
- zamrznjena enkoderja position/velocity;
- 512-dim okenska predstavitev;
- omejitev: transfer baseline;
- omejitev: ne polna reprodukcija predtreniranja.

9.4 Stabilnost učenja in notranje predstavitve

TODO:

- Povzemi, ali krivulje izgub kažejo stabilno učenje ali prekomerno prileganje.
- Interpretiraj varianco in kosinusno podobnost predstavitev v povezavi s prekomernim glajenjem.
- Interpretiraj razpon logitov v povezavi z zanesljivostjo oziroma zasičenostjo napovedne glave.
- Če diagnostika ne pokaže jasnega vzorca, to napiši previdno in brez pretiranih sklepov.
- Poveži ugotovitve z arhitekturnimi odločitvami iz poglavja 6.4.5.

9.5 Primerjava z izvirnim MAHNOB-HCI pristopom

TODO:

- izvirni paper: ročno oblikovane eye-gaze značilke;
- izvirni paper: drugačen pipeline izbire značilk;
- izvirni paper: SVM;
- ta naloga: grafi iz časovnih oken surovejših signalov;
- primerjava metodološko motivacijska;
- ne neposredna reprodukcija;
- posebej omeniti uporabo `distance-avg` in fiksacijskih informacij kot približanje širšemu naboru signalov iz literature.

9.6 Omejitve

Glavne omejitve naloge so:

- uporaba ene glavne podatkovne zbirke;
- subjektivnost čustvenih oznak;
- omejitev na eye-tracking signale brez drugih fizioloških modalnosti;
- občutljivost grafovske konstrukcije na hiperparametre;
- računska zahtevnost validacije z LOO protokoli;
- možnost prekomernega glajenja v grafovskih modelih.

9.7 Možnosti nadaljnjega dela

Možne smeri nadaljnjega dela vključujejo:

- učenje povezav namesto ročne konstrukcije grafa;
- uporabo grafovskih transformerjev;
- samonadzorovano predtreniranje na neoznačenih eye-tracking signalih;
- razvoj grafovskega foundation modela za podatke pogleda;
- razširitev na večmodalne fiziološke podatke;
- evalvacijo na več podatkovnih zbirkah.

TODO: Pri pisanju tega odseka dodaj tudi dve konkretni smeri nadaljnjega dela:

- razmislek in implementacijo uporabe mežikov, saj literatura mežike obravnava kot informativen signal pri prepoznavi čustvenih stanj iz podatkov pogleda [12, 16];
- razširitev grafovske predstavitve s fiksacijskimi meta-vozlišči, torej idejo 3D lift, kjer bi posamezne meritve ostale osnovna vozlišča, fiksacije pa bi bile dodatna vozlišča višje ravni, povezana z meritvami, ki jim pripadajo.

Poglavje 10

Zaključek

TODO:

- Zaključek na koncu uskladiti z novo zgodbo: glavna naloga je binarna klasifikacija, glavna primerjava pa modeli pri naborih *gaze*, *gaze+pupil* in *all*.
- Sklep naj pošteno pove, pri katerih signalih in modelih GNN pomaga oziroma ne pomaga, namesto da predpostavlja, da mora biti GNN najboljši.
- Če GazeMAE ostane zelo močan, ga omeniti kot pomembno referenco za naučene predstavitve pogleda in motivacijo za nadaljnje delo z združevanjem predstavitev.
- Pri nadaljnjem delu omeni tudi preizkus drugih grafovskih plasti, npr. GATConv, GraphSAGE, GIN in grafovskih transformerjev; v glavnih eksperimentih je bil operator namenoma fiksiran na GCNConv.

TODO: Zaključek napiši čisto na koncu. Struktura:

- en odstavek: kaj je bil problem;
- en odstavek: kaj si naredil;
- en odstavek: glavni rezultati;
- en odstavek: kaj rezultati pomenijo;
- en odstavek: omejitve in prihodnje delo.

V diplomski nalogi smo obravnavali uporabo grafovskih nevronske mreže za prepoznavo afektivnih stanj iz podatkov sledilnika pogleda. Časovna okna meritev smo predstavili kot časovno-prostorske grafe, v katerih vozlišča predstavljajo posamezne meritve, povezave pa časovne, prostorske in fiksacijske odnose med njimi. Predlagani pristop smo ovrednotili na podatkovni zbirki MAHNOB-HCI pri 3-razredni klasifikaciji valence in vznemirjenosti.

TODO:

- Zaključek naj grafovsko predstavitev samo kratko povzame; ne ponavljaj definicij grafa, heterogenosti, uteženosti ali pravil konstrukcije povezav.
- Če omenjaš naučene predznačene uteži, jih predstavi kot ugotovitev oziroma komponento modela, ne ponovno kot metodološko definicijo.
- Uskladi z novo glavno nalogo in terminologijo: binarna klasifikacija valence, časovno-prostorski graf, klasifikacija čustvenih oznak.

TODO:

- najboljši model;
- ali graf pomaga glede na ne-grafovske baseline;
- ali predlagani GNN pomaga glede na osnovni GCN in ne-grafovske primerjalne modele;
- vloga časovnih povezav;
- vloga prostorskih povezav;
- vloga fiksacijskih povezav;
- vloga naučenih predznačenih uteži;
- glavna omejitev;
- najbolj smiselna smer nadaljnjega dela.

Dodatek A

Dodatni rezultati

TODO:

- Sem dodaj dodatne tabele po foldih, rezultate manj pomembnih modelov in rezultate, ki niso šli v glavno besedilo.
- Dodaj rezultate za *subject LOO* in *recording LOO* pri vseh signalnih naborih: pogled, zenici, pogled+zenici in vsi signali.
- Dodaj vse izračunane metrike rezultatov, ne samo *accuracy* in makro-F1, ki ostaneta v glavnem besedilu.
- Razširjene metrike: balanced accuracy, weighted-F1, AUC, po potrebi precision/recall po razredih in rezultati po posameznih gubah.
- Dodatne matrike zmede: recording LOO, binarne naloge, najboljši negrafovski model in primerjave, ki niso nujne za glavno zgodbo.
- Dodaj rezultate primerjave različnih tipov grafovskih konvolucij oziroma GNN slojev, če ostanejo zunaj glavnega besedila.
- Dodaj rezultate 3-razredne klasifikacije in kratek komentar primerjave z izvirnim člankom podatkovne zbirke MAHNOB-HCI oziroma HCI-tagging.
- Dodatne porazdelitve podatkov: porazdelitev razredov po subjektih, po posnetkih, po izvorni čustveni oznaki in za binarni low/high nalogi.
- Dodatne slike ujemanja oznak: podrobnejše heatmape Table 6 razredov proti samoocenam in povzetki label-noise analize, če v glavnem besedilu ostane samo ena skupna slika.

A.1 Izbira tipa grafovske konvolucije

Za preverjanje izbire grafovskega operatorja smo izvedli dodatni poskus na binarni nalogi valence z naborom signalov pogled+zenici. Primerjali smo osnovni homogeni grafovski model in uteženo heterogeno arhitekturo z različnimi tipi grafovskih konvolucij. Pri osnovnem modelu so bile povezave neutružene, pri uteženi heterogeni arhitekturi pa so različice **GCNConv**, **GraphConv** in **GINEConv** uporabile naučene skalarne uteži povezav. Različica **GATConv** teh skalarnih uteži ni uporabila, saj pomembnost povezav modelira z notranjim mehanizmom pozornosti.

Če bi izbirali izključno najboljši operator za ta dodatni poskus, bi pri neutruženem osnovnem modelu izbrali **GINEConv**, pri uteženi heterogeni arhitekturi pa **GraphConv**. V glavnih poskusih tega nismo storili, ker bi s tem hkrati spremenili več delov arhitekture in otežili primerjavo med osnovnim GCN in uteženo heterogeno različico. **GCNConv** se je v obeh skupinah uvrstil približno v sredino: ni bil najboljši operator, hkrati pa tudi ni izrazito odstopal navzdol. Zato smo ga obravnavali kot dober kompromis med enostavnostjo, konsistentnostjo eksperimentalne zasnove in rezultati. Glavni namen naloge ni bil poiskati absolutno najboljši grafovski operator, temveč primerjati grafovsko predstavitev in arhitekturne stopnje pri enakem, razmeroma standardnem operatorju posredovanja sporočil.

Tabela A.1: Primerjava tipov grafovskih konvolucij pri naboru signalov pogled+zenici.

Arhitektura	Operator	Accuracy	Makro-F1	Opomba
Osnovni GCN	GCNConv	0,6474	0,6337	neuteženi homogeni graf
Osnovni GCN	GATConv	0,6484	0,6336	neutežena pozor- nost
Osnovni GCN	GraphConv	0,6367	0,6192	neuteženi homogeni graf
Osnovni GCN	GINConv	0,6613	0,6501	najboljši neuteženi rezultat
HeteroGCN-MLP-w	GCNConv	0,6391	0,6103	naučene uteži povezav
HeteroGCN-MLP-w	GATConv	0,6370	0,6116	pozornost brez skalarnih uteži
HeteroGCN-MLP-w	GraphConv	0,6606	0,6503	najboljši uteženi rezultat
HeteroGCN-MLP-w	GINEConv	0,6325	0,6028	značilke in uteži povezav

Dodatek B

Hiperparametri

TODO:

- tabela hiperparametrov za baseline modele;
- tabela hiperparametrov za GazeMAE + MLP;
- tabela hiperparametrov za osnovni GCN;
- tabela hiperparametrov za predlagani GNN;
- predlagani GNN: `GCNConv`, `hidden_channels=128`, `num_layers=3`;
- predlagani GNN: `relation_pooling=mlp`, `graph_pooling=attention`;
- osnovni GCN: uporabljeni isti splošni parametri kot pri predlaganem GNN; posebej navesti readout funkcijo;
- trenutni graf: `kt=2`, `ks=2`, `fixation_dilation_k=3`;
- dodaj rezultate mrežnega iskanja velikostnih hiperparametrov GNN: `kt`, `ks`, `kf`, število slojev in dimenzija skritih predstavitev;
- trenutne edge značilke: `use_delta_distance_edge_feature=true`;
- trenutni trening: učna stopnja $5 \cdot 10^{-5}$, velikost mini-serije 256, največ 500 epoh, potrpežljivost 20;
- dodaj kratek opis uporabljene strojne in programske opreme za poganjanje poskusov: CPU, GPU, RAM, operacijski sistem, različica Pythona, ključne knjižnice in različice paketov;
- dodaj kratko poročilo o času učenja oziroma trajanju poskusov,

Dodatek C

Dodatne vizualizacije grafov

TODO:

- Dodatek naj dopolni eno osrednjo sliko grafovske predstavitve iz glavnega besedila, ne pa je podvaja.
- primer 10 s grafa;
- berljiv primer 2 s ali 5 s grafa;
- vizualizacija `temporal_forward` povezav;
- vizualizacija `temporal_backward` povezav;
- vizualizacija `spatial` povezav;
- vizualizacija `fixation` povezav;
- ločen prikaz razširjenih fiksacijskih povezav znotraj ene fiksacije za razlago parametra k_f ;
- prikaz prekrivanja relacij med istimi pari vozlišč s krivljenimi povezavami;
- vozlišča po koordinatah pogleda (x , y);
- velikost vozlišč po povprečni velikosti zenice;
- lokalne oznake vozlišč od 0 naprej;
- robovi različnih barv po relacijah.
- Pri vseh grafovskih slikah uporabi enako barvno shemo relacij kot v glavnem besedilu.

Dodatek D

Diagnostika predstavitev modela

TODO:

- Dodaj variance po plasteh, kosinusne podobnosti, porazdelitve logitov in dodatne slike kolapsa predstavitev.
- Dodaj per-fold krivulje učne in validacijske izgube, če so v glavnem besedilu prikazane samo agregirane ali reprezentativne krivulje.
- Dodaj porazdelitve entropije napovednih verjetnosti in razpona logitov za osnovni GCN ter predlagani GNN.
- Dodaj porazdelitve naučenih uteži povezav po relacijah `temporal_forward`, `temporal_backward`, `spatial` in `fixation`, če so artefakti na voljo.
- UMAP naučenih predstavitev grafa dodaj sem, če je slika uporabna kot diagnostika, vendar ni dovolj močna za glavno besedilo. Pri vsakem UMAP prikazu zapiši, ali je barvan po razredu, subjektu ali posnetku.
- Če UMAP kaže predvsem subjektne ali stimulusne gruče, ga interpretiraj kot omejitev oziroma opozorilo, ne kot dokaz razredne ločljivosti.

Dodatek E

Zgodovinski poskusi na eSEEd_v2

TODO: Če želiš ohraniti eSEEd_v2 rezultate, jih daj sem: kratka motivacija, glavne težave, zakaj ni glavni dataset, brez pretiranega širjenja glavne zgodbe.

Literatura

- [1] Jimmy Lei Ba, Jamie Ryan Kiros in Geoffrey E. Hinton. „Layer Normalization“. V: *arXiv preprint arXiv:1607.06450* (2016). URL: <https://arxiv.org/abs/1607.06450>.
- [2] Dzmitry Bahdanau, Kyunghyun Cho in Yoshua Bengio. „Neural Machine Translation by Jointly Learning to Align and Translate“. V: *International Conference on Learning Representations*. 2015. URL: <https://arxiv.org/abs/1409.0473>.
- [3] Marcos F. Bamonte, Marcelo Risk in Victor Herrero. „Determining the Optimal Window Duration to Enhance Emotion Recognition Based on Galvanic Skin Response and Photoplethysmography Signals“. V: *Electronics* 13.16 (2024), str. 3333. DOI: 10.3390/electronics13163333.
- [4] Louise Gillian C. Bautista in Prospero C. Naval. „GazeMAE: General Representations of Eye Movements Using a Micro-Macro Autoencoder“. V: *2020 25th International Conference on Pattern Recognition (ICPR)*. IEEE, 2021, str. 7004–7011. DOI: 10.1109/ICPR48806.2021.9412761.
- [5] Tomi Božak, Mitja Luštrek in Gašper Slapničar. „Feature-Based Emotion Classification Using Eye-Tracking Data“. V: *Information Society 2024*. Ljubljana, Slovenia, 2024. DOI: 10.70314/is.2024.scai.9988.
- [6] Justin Gilmer in sod. „Neural Message Passing for Quantum Chemistry“. V: *Proceedings of the 34th International Conference on Machine Learning*. Zv. 70. Proceedings of Machine Learning Research. PMLR, 2017, str. 1263–1272.

- [7] Ian Goodfellow, Yoshua Bengio in Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [8] Kaiming He in sod. „Deep Residual Learning for Image Recognition“. V: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016, str. 770–778. DOI: 10.1109/CVPR.2016.90.
- [9] Dan Hendrycks in Kevin Gimpel. „Gaussian Error Linear Units (GELUs)“. V: *arXiv preprint arXiv:1606.08415* (2016). URL: <https://arxiv.org/abs/1606.08415>.
- [10] Thomas N. Kipf in Max Welling. „Semi-Supervised Classification with Graph Convolutional Networks“. V: *International Conference on Learning Representations*. 2017. URL: <https://openreview.net/forum?id=SJU4ayYgl>.
- [11] Yujia Li in sod. „Gated Graph Sequence Neural Networks“. V: *International Conference on Learning Representations*. 2016. URL: <https://arxiv.org/abs/1511.05493>.
- [12] Jia Zheng Lim, James Mountstephens in Jason Teo. „Emotion Recognition Using Eye-Tracking: Taxonomy, Review and Current Challenges“. V: *Sensors* 20.8 (2020), str. 2384. DOI: 10.3390/s20082384.
- [13] Delin Ouyang in sod. „The Effect of Time Window Length on EEG-Based Emotion Recognition“. V: *Sensors* 22.13 (2022), str. 4939. DOI: 10.3390/s22134939.
- [14] Mohammad Soleymani in sod. „A Multimodal Database for Affect Recognition and Implicit Tagging“. V: *IEEE Transactions on Affective Computing* 3.1 (2012), str. 42–55. DOI: 10.1109/T-AFFC.2011.25.
- [15] Nitish Srivastava in sod. „Dropout: A Simple Way to Prevent Neural Networks from Overfitting“. V: *Journal of Machine Learning Research* 15.56 (2014), str. 1929–1958. URL: <http://jmlr.org/papers/v15/srivastava14a.html>.

-
- [16] Paweł Tarnowski in sod. „Eye-Tracking Analysis for Emotion Recognition“. V: *Computational Intelligence and Neuroscience 2020* (2020), str. 2909267. DOI: 10.1155/2020/2909267.
 - [17] Petar Veličković in sod. „Graph Attention Networks“. V: *International Conference on Learning Representations*. 2018. URL: <https://openreview.net/forum?id=rJXMpikCZ>.
 - [18] Bing Yu, Haoteng Yin in Zhanxing Zhu. „Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting“. V: *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence*. International Joint Conferences on Artificial Intelligence Organization, 2018, str. 3634–3640. DOI: 10.24963/ijcai.2018/505.