

UNIVERZA V LJUBLJANI
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO
FAKULTETA ZA MATEMATIKO IN FIZIKO

Tomi Božak

**Grafovske nevronske mreže za
klasifikacijo valence iz podatkov
sledilnika pogleda**

DIPLOMSKO DELO

UNIVERZITETNI ŠTUDIJSKI PROGRAM
PRVE STOPNJE
RAČUNALNIŠTVO IN MATEMATIKA

MENTOR: izr. prof. dr. Lovro Šubelj
SOMENTOR: doc. dr. Gašper Slapničar

Ljubljana, 2026

To delo je ponujeno pod licenco *Creative Commons Priznanje avtorstva-Deljenje pod enakimi pogoji 2.5 Slovenija* (ali novejšo različico). To pomeni, da se tako besedilo, slike, grafi in druge sestavine dela kot tudi rezultati diplomskega dela lahko prosto distribuirajo, reproducirajo, uporabljajo, priobčujejo javnosti in predelujejo, pod pogojem, da se jasno in vidno navede avtorja in naslov tega dela in da se v primeru spremembe, preoblikovanja ali uporabe tega dela v svojem delu, lahko distribuira predelava le pod licenco, ki je enaka tej. Podrobnosti licence so dostopne na spletni strani creativecommons.si ali na Inštitutu za intelektualno lastnino, Streliška 1, 1000 Ljubljana.



Izvorna koda diplomskega dela, njeni rezultati in v ta namen razvita programska oprema je ponujena pod licenco GNU General Public License, različica 3 (ali novejša). To pomeni, da se lahko prosto distribuira in/ali predeluje pod njenimi pogoji. Podrobnosti licence so dostopne na spletni strani <http://www.gnu.org/licenses/>.

Besedilo je oblikovano z urejevalnikom besedil L^AT_EX.

Kandidat: Tomi Božak

Naslov: Grafovske nevronske mreže za klasifikacijo valence iz podatkov sledilnika pogleda

Vrsta naloge: Diplomaska naloga na univerzitetnem programu prve stopnje

Mentor: izr. prof. dr. Lovro Šubelj

Somentor: doc. dr. Gašper Slapničar

Opis:

Podatki, pridobljeni s sledilniki pogleda, se pogosto uporabljajo za klasifikacijo čustvenih stanj posameznikov med izvajanjem različnih nalog. V diplomskem delu se osredotočite na problem napovedovanja pozitivne oziroma negativne valence. V ta namen predlagajte ustrezno arhitekturo grafovskih nevronskih mrež ter uspešnost naučenega modela primerjajte z drugimi pristopi, kot so klasični modeli strojnega učenja za tabelarične podatke ter prednaučeni kodirniki signalov. Na koncu kritično ovrednotite uspešnost pristopa, ki temelji na grafovskem modeliranju, in predlagajte smernice za prihodnje delo.

Title: Graph Neural Networks for Valence Classification from Eye-Tracking Data

Iskreno se želim zahvaliti obema mentorjema, izr. prof. dr. Lovru Šublju za usmerjanje na področju grafovskih nevronskih mrež in doc. dr. Gašperju Slapničarju za nesebično svetovanje – nemalokrat tudi izven delovnega časa –, dvoletno mentoriranje na raziskovalnem področju in usmerjanje pri tako večjih kot tudi manjših odločitvah. Odseku E9 na IJS se zahvaljujem za neprecenljive izkušnje na področju raziskovanja in podatkovnih znanosti, za prostor, računske vire in možnost, da sem diplomsko delo opravljal v sklopu raziskovalnega dela. Hvala sodelavcem skupine AMI za strokovne razprave ter koristne nasvete in ideje ob raziskovalnih izzivih. Hvala FRI in FMF za kvalitetne temelje na področju računalništva in matematike. Nenazadnje pa gre zahvala od srca tudi družini in partnerki Lari za večno podporo v vseh okoliščinah. Brez vaše pomoči bi bil vsak korak te poti težji.

Kazalo

Povzetek

Abstract

1	Uvod	1
2	Sorodna dela	5
3	Podatki in predobdelava	9
3.1	Podatkovne zbirke sledilnika pogleda	9
3.1.1	Podatkovna zbirka MAHNOB-HCI	10
3.2	Samooocene čustvenega stanja in ciljni razredi	11
3.3	Priprava podatkov za učenje	12
3.3.1	Množice signalov in čiščenje podatkov	12
3.3.2	Standardizacija in tvorba časovnih oken	13
4	Grafovski predstavitev podatkov sledilnika pogleda	17
4.1	Vozlišča	18
4.1.1	Definicija	18
4.1.2	Vektor značilk vozlišča	18
4.2	Relacije	19
4.2.1	Časovne povezave	19
4.2.2	Prostorske povezave	20
4.2.3	Fiksacijske povezave	21
4.2.4	Značilke povezav	21

4.3	Grafi po množicah signalov	23
4.4	Statistika konstruiranih grafov	23
5	Primerjani modeli	27
5.1	Pregled primerjanih pristopov	27
5.2	Negrafovski osnovni modeli	29
5.2.1	Izhodiščna klasifikatorja	29
5.2.2	Klasični modeli strojnega učenja	29
5.3	Zamrznjeni prednaučeni predstavitveni modeli	30
5.3.1	GazeMAE	31
5.3.2	MOMENT	31
5.3.3	Združene predstavitve GazeMAE in MOMENT	31
5.4	Grafovski modeli	32
5.4.1	Posredovanje sporočil in skupni cevovod	33
5.4.2	GCN	36
5.4.3	HeteroGCN-mean	36
5.4.4	HeteroGCN-MLP	39
5.4.5	HeteroGCN-MLP-w	39
5.4.6	Izbira grafovске konvolucije	41
6	Eksperimentalni protokol	45
6.1	Zasnova glavne primerjave	45
6.2	Validacijski protokol	46
6.2.1	7-kratno prečno preverjanje po subjektih	46
6.2.2	Predhodna preverjanja z LOSO	47
6.3	Nastavitve učenja in hiperparametri	47
6.4	Metrike vrednotenja	47
6.5	Spremljanje učenja	48
7	Rezultati	51
7.1	Glavni rezultati klasifikacije	51
7.2	Velikost in računska zahtevnost modelov	54

8	Diskusija	57
9	Zaključek	59
A	Dodatni rezultati	61
A.1	Preslikava diskretnih samoocen čustvenega stanja v valenco . .	61
A.2	Dodatne metrike in diagnostične meritve	62
A.3	Razširjeni rezultati binarne klasifikacije valence	63
A.4	Primerjava z LOSO	67
A.5	Matrike zamenjav	67
A.6	Ujemanje izpeljanih razredov s samoocenami	73
A.7	Izbira tipa grafovske konvolucije	74
A.8	Diagnostika predstavitev	74
B	Hiperparametri	77
B.1	Hiperparametri modelov	77
B.2	Predhodno mrežno iskanje	77
B.3	Strojna in programska oprema	79
B.4	Učljive uteži povezav	80
C	Dodatne podrobnosti grafovske konstrukcije	81
C.1	Razširjene povezave znotraj fiksacije	81
C.2	Značilke povezav	82
C.3	Ločeni prikazi tipov povezav	82
	Literatura	87

Seznam uporabljenih kratic

kratica	angleško	slovensko
AUC	area under the curve	ploščina pod krivuljo
CUDA	compute unified device architecture	arhitektura CUDA za računanje na grafičnih procesorjih
EEG	electroencephalography	elektroencefalografija
F1	F1 score	mera F1
GAT	graph attention network	grafovska pozornostna mreža
GCN	graph convolutional network	grafovska konvolucijska mreža
GELU	Gaussian error linear unit	aktivacijska funkcija GELU
GIN	graph isomorphism network	grafovska izomorfna mreža
GNN	graph neural network	grafovska nevronska mreža
LightGBM	light gradient boosting machine	metoda LightGBM z gradientno spodbujenimi odločitvenimi drevesi
LOSO	leave-one-subject-out	izpusti enega subjekta
MAHNOB-HCI	MAHNOB-HCI database	podatkovna zbirka MAHNOB-HCI
MLP	multilayer perceptron	večslojni perceptron
PyG	PyTorch Geometric	knjižnica PyTorch Geometric
RBF	radial basis function	radialna bazna funkcija
ST-GCN	spatio-temporal graph convolutional network	časovno-prostorska grafovska konvolucijska mreža
SVM	support vector machine	metoda podpornih vektorjev

Povzetek

Naslov: Grafovske nevronske mreže za klasifikacijo valence iz podatkov sledilnika pogleda

Avtor: Tomi Božak

Podatki sledilnika pogleda vsebujejo časovne in prostorske odnose med meritvami. Časovno-prostorska grafovska predstavitev te odnose eksplicitno kodira s povezavami med vozlišči, medtem ko jih klasična tabelarična predstavitev običajno ne. V diplomski nalogi preverimo, ali lahko grafovske nevronske mreže te odnose uporabijo pri binarni klasifikaciji valence. Časovna okna meritev sledilnika pogleda predstavimo kot časovno-prostorske grafe, v katerih vozlišča ustrezajo meritvam, povezave pa opisujejo časovno bližino, prostorsko bližino in pripadnost isti fiksaciji. Grafovske modele primerjamo z izhodiščnima klasifikatorjema, klasičnimi modeli strojnega učenja ter prednaučenima kodirnikoma signalov. Modele ovrednotimo s 7-kratnim prečnim preverjanjem po subjektih na štirih množicah signalov: *samo pogled*, *samo zenici*, *pogled in zenici* ter *usi signali*. Rezultati kažejo, da so grafovske predstavitve informativne, saj grafovski modeli pri vseh množicah signalov presežejo naključni in večinski klasifikator in so po rezultatih primerljivi z uveljavljenimi modeli. Najboljši grafovski model doseže 65,5 % točnost in 64,4 % makro F1 pri množici *pogled in zenici*, vendar ostane pod najboljšim rezultatom modela SVM, ki doseže 70,5 % točnost in 69,7 % makro F1. V izbranih eksperimentih so najuspešnejši klasični modeli z ročno oblikovanimi značilkami, grafovsko modeliranje pa ostaja smiselna raziskovalna smer za podatke sledilnika pogleda.

Ključne besede: grafovske nevronske mreže, časovno-prostorski grafi, podatki sledilnika pogleda, klasifikacija valence.

Abstract

Title: Graph Neural Networks for Valence Classification from Eye-Tracking Data

Author: Tomi Božak

Eye-tracking data contain temporal and spatial relations between measurements that are not modelled directly by a classical tabular representation. This thesis investigates whether graph neural networks can use these relations for binary valence classification. Temporal windows of eye-tracking data are represented as spatio-temporal graphs, where nodes correspond to individual measurements and edges encode temporal proximity, spatial proximity, and shared fixation membership. Graph-based models are compared with baseline classifiers, classical machine learning models, and frozen pretrained signal encoders. The experiments use 7-fold cross-validation by subject and evaluate four signal sets: *gaze*, *pupil only*, *gaze and pupil*, and *all signals*. The results show that graph representations are informative, since graph-based models outperform random and majority classifiers for all signal sets. The best graph-based model achieves 65.5 % accuracy and 64.4 % macro F1 on the *gaze and pupil* signal set, but remains below the best **SVM** result, which reaches 70.5 % accuracy and 69.7 % macro F1. In the evaluated experimental setting, classical models with hand-crafted features are therefore the strongest approach, while graph-based modelling remains a meaningful research direction for eye-tracking data.

Keywords: graph neural networks, spatio-temporal graphs, eye-tracking


data, valence classification.

Poglavje 1

Uvod

Za učenje iz podatkov, kjer niso pomembne zgolj lastnosti posameznih elementov, ampak tudi odnosi med njimi, lahko med drugim uporabimo grafovske nevronske mreže (GNN) [8, 17]. Primer takšnih podatkov so podatki sledilnika pogleda. Meritvam sledilnika pogleda lahko smiselno določimo časovne in prostorske odnose in jim s tem priredimo časovno-prostorski graf. Na tem grafu se z grafovsko nevronske mreže učimo predstavitev vozlišč in grafov, ki jih uporabimo za klasifikacijo grafa. Podatki, uporabljeni v tej nalogi, vsebujejo samoocene čustvenega stanja udeležencev, iz katerih izpeljemo razrede valence. GNN zato učimo binarno klasificirati valenco, rezultate pa primerjamo z rezultati uveljavljenih negrafovskih pristopov. Z izrazom *množica signalov* v tej nalogi označujemo izbor vrst podatkov sledilnika pogleda, ki jih uporabimo kot vhod modela. Eksperimentalno primerjavo izvedemo na štirih množicah signalov: samo koordinatah pogleda (*samo pogled*), samo velikostih zenic (*samo zenici*), združenih koordinatah pogleda in velikostih zenic (*pogled in zenici*) ter vseh razpoložljivih signalih (*vsi signali*). Pregled celotnega eksperimentalnega toka je prikazan na sliki 1.1: iz iste podatkovne zbirke izpeljemo več vhodnih predstavitev, jih ovrednotimo z različnimi družinami modelov in rezultate primerjamo na problemu binarne klasifikacije valence.

Raziskovalni problem naloge je zasnova, implementacija in ovrednotenje grafovske predstavitve podatkov sledilnika pogleda za binarno klasifikacijo



Slika 1.1: Pregled naloge: priprava podatkov MAHNOB-HCI, tri glavne poti modeliranja, štiri množice signalov in povzetek eksperimentalne primerjave binarne klasifikacije valence iz podatkov sledilnika pogleda.

valence.

Glavno raziskovalno vprašanje je: Kakšna je klasifikacijska uspešnost grafovske nevronske mreže za binarno klasifikacijo valence iz podatkov sledilnika pogleda v primerjavi s klasifikacijsko uspešnostjo uveljavljenih negrafovskih pristopov?

Dodatna podvprašanja so:

1. Kako podatke sledilnika pogleda smiselno predstaviti kot časovno-prostorski graf?
2. Kako se klasifikacijska uspešnost modelov razlikuje med posameznimi množicami signalov sledilnika pogleda?

3. Kako se klasifikacijska uspešnost grafovskih modelov spreminja z večjo arhitekturno kompleksnostjo?
4. Kakšno je razmerje med klasifikacijsko uspešnostjo ter velikostjo in računsko zahtevnostjo primerjanih modelov?

V nadaljevanju v poglavju 2 najprej predstavimo sorodna dela in metode učenja predstavitev iz podatkov pogleda. Poglavje 3 opisuje uporabljene podatke, samoocene čustvenega stanja, ciljne razrede in predobdelavo, v poglavju 4 pa opišemo konstrukcijo časovno-prostorskega grafa. V poglavju 5 predstavimo primerjane modele. Poglavje 6 združuje eksperimentalni protokol in rezultate glavne primerjave modelov na različnih množicah signalov. Nalogo sklenemo z interpretacijo rezultatov, omejitvami, doprinosi in možnostmi nadaljnjega dela v poglavju 8.

Pri pripravi diplomskega dela sem kot podporno orodje uporabljal ChatGPT (GPT-5.5 Thinking) [24]. Orodje sem uporabljal za pisanje in razlago programske kode, pomoč pri strukturiranju poglavij, jezikovno in slogovno izboljševanje lastnega besedila, preverjanje razumljivosti razlage, iskanje terminoloških možnosti in prevodov, pripravo slik in tabel ter oblikovanje zapisov v okolju L^AT_EX.

Orodje ni bilo uporabljeno kot samostojen vir znanstvenih trditev. Vse vsebinske trditve, uporabljeni viri, eksperimentalni rezultati, programska koda in končne odločitve so bili preverjeni, dopolnjeni, popravljeni in potrjeni s strani avtorja. V orodje niso bili vneseni osebni podatki udeležencev ali drugi zaupni podatki. Avtor prevzema polno odgovornost za vsebino diplomskega dela.

Poglavje 2

Sorodna dela

To poglavje umešča nalogo med obstoječe pristope za delo s podatki sledilnika pogleda. Sorodna dela v tem poglavju obravnavamo z vidika vprašanja, kako podatke sledilnika pogleda predstaviti za klasifikacijo čustvenih oznak in kakšno klasifikacijsko uspešnost pri tem dosega. Čustvena stanja se pogosto opisujejo z dimenzijama valence in vzburjenosti, pri čemer valenca opisuje razpon čustvenega odziva od negativnega do pozitivnega [19]. Najprej predstavimo grafovske nevronske mreže za časovne vrste in časovno-prostorske podatke, saj je osrednji del naloge pretvorba časovnega okna meritev sledilnika pogleda v graf. Na koncu povzamemo še učenje predstavitev iz signala sledilnika pogleda ter položaj te naloge glede na sorodna dela.

Grafovske nevronske mreže za časovno-prostorske podatke Za modeliranje časovnih vrst se pogosto uporabljajo rekurentne nevronske mreže, kot so mreže LSTM, in transformerji, ki modelirajo časovne odvisnosti med meritvami [15]. Grafovska predstavitev je smiselna, kadar želimo poleg časovne urejenosti eksplicitno modelirati tudi odnose med več časovnimi vrstami ali prostorske odnose med meritvami [15]. Pregled GNN za časovne vrste to področje obravnava skozi naloge napovedovanja, klasifikacije, imputacije in zaznavanja anomalij. Za to nalogo je pomembna predvsem formulacija, pri kateri posamezno časovno okno pretvorimo v grafovsko predstavitev in njegov

razred napovemo na ravni celotnega grafa.

Pri podatkih sledilnika pogleda imajo meritve poleg časovnega vrstnega reda tudi prostorsko komponento, saj je vsaka veljavna meritev vezana na položaj pogleda na zaslonu. Podobno ločevanje časovnih in prostorskih odvisnosti uporabljajo časovno-prostorske grafovske mreže, na primer ST-GCN pri napovedovanju prometa, kjer grafovska konvolucija modelira prostorske povezave med senzorji, časovna konvolucija pa dinamiko signala skozi čas [35]. V tej nalogi je ta pristop uporaben kot metodološka analogija, saj ne napovedujemo prihodnjih meritev, temveč klasificiramo razred časovnega okna meritev.

Učenje predstavitev iz signalov Poleg ročno oblikovanih značilk obstajajo pristopi, ki se predstavitev naučijo neposredno iz zaporedij meritev. S tem zmanjšajo odvisnost od ročne izbire značilk, hkrati pa so njihove predstavitve vezane na podatke in naloge, uporabljene pri predtreniranju. V nalogi takšni modeli služijo kot most med klasičnimi modeli na ročno agregiranih značilkah in grafovskimi modeli, ki se predstavitev učijo na sami strukturi podatkov.

GazeMAE je primer odprtokodnega modela, zasnovanega posebej za očesne gibe, ki z dvema časovno-konvolucijskima avtokodirnikoma ločeno kodira zaporedji koordinat pogleda in iz njih izračunanih hitrosti. Pri samonadzorovanem učenju avtokodirnika rekonstruirata delno izpuščene vrednosti signalov [2]. **MOMENT** je splošnejši prednaučen temeljni model za časovne vrste, ki signal razdeli na dele fiksne dolžine in jih kodira z arhitekturo transformerjev. Pri predtreniranju naključno zakrije nekatere dele signala in se uči njihove rekonstrukcije iz preostalega konteksta, zato je uporaben kot primerjava pri ostalih signalih [10].

Položaj te naloge glede na sorodna dela Pregled sorodnih del kaže, da se podatki sledilnika pogleda pri prepoznavanju čustvenih stanj najpogosteje uporabljajo v obliki ročno oblikovanih značilk ali zaporedij meritev [19, 30, 21]. Tudi izvirni članek podatkovne zbirke MAHNOB-HCI uporablja ročno

oblikovane značilke pogleda: pri trirazredni klasifikaciji valence po protokolu LOSO (angl. *leave-one-subject-out*), pri katerem je vsak udeleženec enkrat uporabljen kot testna množica, so avtorji dosegli točnost 68,8 % in povprečni F1 0,68 [27]. Ti rezultati niso neposredno primerljivi z rezultati te naloge, saj uporabljamo binarno klasifikacijo, drugačna časovna okna in drug eksperimentalni protokol. Grafovski modeli so pogosteje uporabljeni pri drugih vrstah časovno-prostorskih podatkov oziroma pri fizioloških signalih, predvsem pri EEG, kjer vozlišča običajno predstavljajo elektrode ali možganska področja [28, 37, 20]. Obstajajo tudi pristopi, ki grafovske modele uporabljajo pri večmodalni prepoznavi čustev iz EEG in podatkov očesnih gibov [33, 21]. Ker v pregledu sorodnih del nismo našli pristopa, ki bi izključno podatke sledilnika pogleda obravnaval kot časovno-prostorski graf posameznih meritev, se ta naloga osredotoča na primerjavo različnih predstavitev (izključno) podatkov sledilnika pogleda. Samoocene čustvenega stanja uporabimo kot evalvacijsko nalogo, s katero primerjamo različne predstavitve istega časovnega okna: agregirane značilke za klasične modele, predstavitve iz prednaučenih kodirnikov [2] in časovno-prostorsko grafovsko predstavitev za GNN.

Grafovski del naloge preverja, ali eksplicitne časovne, prostorske in fiksacijske relacije med meritvami pogleda prispevajo višji klasifikacijski točnosti. V predlagani predstavitvi vozlišča predstavljajo posamezne meritve, povezave pa časovno bližino, prostorsko bližino in pripadnost isti fiksaciji. Naloga torej povezuje (1) binarno klasifikacijo valence iz podatkov sledilnika pogleda, (2) GNN za časovno-prostorske podatke ter (3) primerjavo ročno oblikovanih, samonaučenih in grafovskih predstavitev časovnih oken.

Poglavje 3

Podatki in predobdelava

3.1 Podatkovne zbirke sledilnika pogleda

Sledilnik pogleda je naprava, ki meri, kam v prostoru ali na zaslonu oseba usmerja pogled. Poleg lokacije pogleda lahko meri tudi velikost zenic, ki jo običajno opišemo s premerom zenice. Signal pogleda navadno opišemo s koordinatama x in y na zaslonu. Iz dinamike teh dveh signalov nekateri sledilniki zaznavajo in poročajo tudi informacije o fiksacijah, sakadah in mežikih, ki nas v tej domeni pogosto zanimajo. Fiksacija je obdobje razmeroma stabilnega pogleda na omejenem območju, sakada hiter premik pogleda med fiksacijama, mežik pa kratkotrajno zaprtje oči [19]. Meritve se izvajajo zaporedno z določeno frekvenco vzorčenja (pogosto med 60 Hz in 1000 Hz), ki je odvisna od zmogljivosti naprave in namena uporabe.

Na voljo je več prosto dostopnih podatkovnih zbirk sledilnika pogleda, ki se razlikujejo po vrsti zajetih signalov. Tukaj naštejemo le nekatere. Najpogostejše vsebujejo koordinate pogleda in velikosti zenic, vendar so nekateri podatki omejeni zgolj na velikosti zenic [25] ali koordinate pogleda [3]. Zbirki COLET in GazeBase vsebujejo podatke o pogledu in velikosti zenic [18, 11], zbirki MAHNOB-HCI in eSEEd_v2 pa poleg njih vključujeta še informacije o fiksacijah, sakadah in mežikih [27, 26].


Za to nalogo smo izbrali podatke z oznakami čustev in s čim več vrstami

signalov sledilnika pogleda. Prve poskuse smo izvedli na podatkovni zbirki eSEEd_v2, vendar so se pokazale težave z zanesljivostjo samoocen čustvenega stanja, kakovostjo signalov in stabilnostjo učenja. Zato smo glavno eksperimentalno evalvacijo izvedli na podatkovni zbirki MAHNOB-HCI.

3.1.1 Podatkovna zbirka MAHNOB-HCI

Podatkovna zbirka MAHNOB-HCI je večmodalna zbirka za prepoznavanje čustev in implicitno označevanje multimedijskih vsebin [27]. Zbirka vsebuje dva glavna eksperimentalna sklopa: prepoznavanje čustvenih stanj iz odzivov na videoposnetke in implicitno označevanje na podlagi odzivov na pravilne oziroma napačne oznake pod sliko ali posnetkom. Vsebuje odzive udeležencev na video posnetke, katerih cilj je bil vzbuditi določena čustva v udeležencu. Odzive sinhrono zajame z videoposnetkom obraza, zvokom, elektroencefalogramom (EEG), fiziološkimi signali – elektrokardiogramom (EKG), galvanskim odzivom kože (GSR), amplitudo dihanja in temperaturo kože – ter signali sledilnika pogleda. Meritve sledilnika pogleda so bile zajete s sledilnikom Tobii X120 pri frekvenci 60 Hz. V tej nalogi uporabljamo samo prvi sklop, to je eksperiment vzbujanja čustev z videoposnetki, in izključno signale sledilnika pogleda.

Izvirni članek poroča o 30 rekrutiranih udeležencih. Udeležence P9, P12 in P15 so avtorji izključili zaradi tehničnih težav oziroma nepopolnega zajema podatkov. V tej nalogi po vzoru izvirnega članka izključimo iste tri udeležence, poleg tega pa izključimo tudi udeležence, za katere ni na voljo podatkov iz eksperimentov vzbujanja čustev. V eksperimentu vzbujanja čustev so udeleženci gledali 20 videoposnetkov, katerih namen je bil vzbuditi različna čustva v gledalcu. Pred vsakim posnetkom, ki naj bi vzbujal določeno čustvo, je bil prikazan še kratek nevtralni posnetek, odziv nanj pa je bil shranjen ločeno. Po ogledu posameznega posnetka so udeleženci podali samoocene čustvenega stanja – številski oceni valence in vzburjenosti, diskretno samooceno čustvenega stanja ter še nekaj dodatnih ocen, ki jih ne uporabimo.



Slika 3.1: Porazdelitev 10-sekundnih oken po razredih binarne valence.

3.2 Samoocene čustvenega stanja in ciljni razredi

Ciljni razredi v tej nalogi izhajajo iz diskretnih samoocen čustvenega stanja, ki so jih udeleženci podali po ogledu videoposnetka. Diskretne samoocene čustvenega stanja preslikamo v razrede valence skladno s preslikavo iz izvirnega članka [27], ki je prikazana v dodatku A.1. S tem najprej dobimo tri razrede: negativno, nevtralno in pozitivno valenco. Nevtralni razred odstranimo, da ciljna naloga vsebuje izrazitejši kontrast med razredoma in s tem modelom omogočimo boljše pogoje za učenje vzorcev v podatkih.

Razred valence je določen na ravni kombinacije udeleženca in videoposnetka. Vsa časovna okna in s tem vsi grafi istega ogleda videoposnetka zato pripadajo istemu razredu. Porazdelitev oken po odstranitvi nevtralnega razreda prikazana na sliki 3.1 kaže, da sta končna razreda pri vseh množicah signalov skoraj uravnotežena.

Vzbujenosti v tej nalogi ne klasificiramo. Razlog je predvsem večja šumnost razredov v uporabljeni podatkovni zbirki. Kot kaže prikaz ujemanja izpeljanih razredov s samoocenami v dodatku A.6, se samoocene stopnje

vzburjenosti slabše ujemajo z definiranimi razredi kot samoocene valence.

3.3 Priprava podatkov za učenje

V tem razdelku opišemo skupne korake priprave podatkov: izbiro in čiščenje signalov, standardizacijo ter tvorbo časovnih oken. Predobdelava pri tem označuje celoten postopek priprave podatkov pred učenjem modelov, čiščenje pa njegov ožji del, ki vključuje izbor uporabnih zapisov ter obravnavo neveljavnih, manjkajočih in osamelih meritev.

3.3.1 Množice signalov in čiščenje podatkov

Tukaj navedemo konkretne skupine signalov, ki jih uporabimo v eksperimentih. Indeks i označuje posamezno meritev sledilnika pogleda. V uporabljeni podatkovni zbirki imamo na voljo pet osnovnih vrst signalov. To so:

- časovni žig meritve t_i ,
- koordinati pogleda na zaslonu (x_i, y_i) – povprečje med meritvama levega in desnega očesa,
- velikost leve in desne zenice $(p_i^{(l)}, p_i^{(r)})$,
- oddaljenost od sledilnika pogleda d_i ter
- informacija o fiksacijah, tj. pripadnost fiksaciji ter trajanje fiksacije.

Da preverimo robustnost modelov glede na razpoložljivost vhodnih signalov ter primerjamo njihovo klasifikacijsko uspešnost za posamezne tipe vhodnih signalov, podatke MAHNOB-HCI razdelimo v štiri delno prekrivajoče se eksperimentalne množice signalov. V vseh štirih množicah uporabimo tudi informacijo o času. Množica *samo pogled* poleg časa vsebuje koordinati pogleda, množica *samo zenici* vsebuje velikosti leve in desne zenice, množica *pogled in zenici* združi koordinati pogleda in velikosti zenic, množica *vsí signali* pa doda še oddaljenost od sledilnika pogleda in informacijo o fiksacijah.


Podrobna povezava med temi množicami, značilkami vozlišč in razpoložljivimi tipi povezav je podana pri opisu grafovske konstrukcije v razdelku 4.3.

Izbrane podatke pred uporabo očistimo. Najprej iz lokalne kopije zbirke MAHNOB-HCI odstranimo podatke, ki jih v tej nalogi ne uporabljamo, in ohranimo le podatke eksperimenta vzbujanja čustev. Nato odstranimo vrstice brez signalov pogleda ali velikosti zenic. Na voljo imamo tudi signale veljavnosti, na podlagi katerih odstranimo meritve, za katere je sledilnik poročal, da je meritev za vsaj eno oko neveljavna. Dodatno uporabimo filter osamelcev q01-q99, ki odstrani meritve, pri katerih je vsaj eden od štirih osnovnih signalov pod prvim ali nad devetindevetdesetim percentilom, saj te vrednosti močno izkrivljajo porazdelitve signalov. Na koncu kratke vrzeli v numeričnih signalih linearno interpoliramo, signala velikosti leve in desne zenice pa dodatno zgladimo s kratkim centriranim drsečim povprečjem treh meritev. Porazdelitvi položajev pogleda in velikosti zenic po čiščenju sta za množico signalov *pogled in zenici* prikazani na slikah 3.2 in 3.3. Na sliki 3.3 je opazen tudi rahel sistematični zamik med porazdelitvama velikosti leve in desne zenice, ki ga izvirni članek o zbirki MAHNOB-HCI ne obravnava [27]. Ker zamik ni vezan na posameznega udeleženca, je naša hipoteza, da to ni fiziološka asimetrija, temveč merilni artefakt sledilnika pogleda.


3.3.2 Standardizacija in tvorba časovnih oken

Posamezne skupine signalov so izražene v različnih velikostnih redih. Modeli strojnega učenja, kot so SVM, MLP ter GNN, so občutljivi na velikostni red vhodnih značilk oz. signalov. Zato signale standardiziramo z znano formulo $\frac{x-\mu}{\sigma}$. Povprečje μ in standardni odklon σ izračunamo na učni podmnožici, nato pa na validacijski in testni podmnožici standardizacijo uporabimo z istimi parametri kot na učni. Pri grafovskih modelih na enak način standardiziramo tudi značilke povezav, kadar jih uporabljena množica signalov vsebuje.

Nato časovno vrsto razdelimo na neprekrivajoča se časovna okna dolžine $T = 10$ s. Vsako uporabno časovno okno predstavlja en učni primer. Za 10 s smo se odločili na podlagi sorodnega dela na podatkih sledilnika pogleda,



Slika 3.2: Toplotni prikaz položajev pogleda v očiščenih podatkih za množico signalov *pogled in zenici*.



Slika 3.3: Porazdelitev velikosti leve in desne zenice v očiščenih podatkih za množico signalov *pogled in zenici*.

kjer so se daljša okna med dolžinami 1, 3, 5 in 10 s praviloma izkazala za bolj informativna [5]. Daljših oken ne uporabimo, ker bi težje predpostavili, da celotno okno opisuje enoten čustveni odziv, saj se lahko ta med ogledom posnetka že opazno spremeni [36]. Tudi sorodna dela na prepoznavanju čustev iz očesnih signalov pogosto uporabljajo razmeroma kratka okna [32, 33].

Ciljni razred okna je določen s parom udeleženec-posnetek, saj so udeleženci vprašalnike izpolnjevali le po vsakem ogledu videoposnetka in ne vmes. Okno uporabimo, če po predhodnem čiščenju in filtru osamelcev vsebuje vsaj 60 veljavnih meritev.

Pri frekvenci vzorčenja 60 Hz bi 10-sekundno okno brez manjkajočih vrednosti vsebovalo 600 vzorcev. Zaradi čiščenja, odstranjevanja neveljavnih vzorcev in filtriranja je dejansko število vzorcev v oknih manjše. Po filtru osamelcev imamo 2 639 048 vrstic in 5 158 uporabnih 10-sekundnih časovnih oken, kar pomeni povprečno približno 512 meritev na uporabno okno. Pri kasnejši gradnji grafov se število vozlišč nekoliko razlikuje med množicami signalov; te vrednosti povzemamo v tabeli 4.2.

Po tvorbi časovnih oken se cevovod razdeli glede na uporabljeno predstavitev. Negrafovski osnovni modeli iz okna dobijo agregirane tabelarične značilke, zamrznjeni prednaučeni predstavitveni modeli neposredno prejmejo časovne vrste izbranih signalov sledilnika pogleda, grafovski modeli pa grafovsko predstavitev okna. Podrobnosti teh predstavitev so opisane v poglavjih 4 in 5.

Tabela 3.1 povzema, kako se skozi opisane korake predobdelave zmanjša količina podatkov, uporabljena v končni eksperimentalni primerjavi.

Tabela 3.1: Zmanjševanje količine podatkov od izvirne zbirke MAHNOB-HCI do končnih časovnih oken, uporabljenih v eksperimentalnem cevovodu.

Korak	Vrstice	Udeleženci	Opis
Izbira izvirne zbirke MAHNOB-HCI	–	30	Večmodalna zbirka; izvirni članek v analizi uporabi 27 udeležencev.
Izbira podmnožice s samooocenami čustvenega stanja	3 797 165	24	Ohranimo le posnetke iz eksperimenta vzbujanja čustev, ki imajo podatke sledilnika pogleda in samoocene čustvenega stanja.
Izključitev manj kakovostnih udeležencev	3 535 842	22	Izključena P9 ter P12. P15 izključen že prej, ker nima samooznak čustev.
Izbira vrstic z veljavnimi samooocenami	2 995 632	22	Ohranimo le vrstice s podatki, uporabljenimi za učenje modelov samoocen čustvenega stanja.
Priprava podatkov za učenje	2 814 005	22	Odstranjene so vrstice brez signalov pogleda ali zenic.
Filter osamelcev q01-q99	2 639 048	22	Robustno filtriranje štirih osnovnih signalov pogleda in zenic.
Tvorba uporabnih* 10-sekundnih časovnih oken	5 158	22	Vsako okno postane en učni primer oziroma graf.

Opomba: * Za uporabno štejemo časovno okno, ki po čiščenju in filtriranju osamelcev vsebuje najmanj 60 veljavnih meritev sledilnika pogleda.

Poglavje 4

Grafovska predstavitev podatkov sledilnika pogleda

V prejšnjem poglavju smo podatke sledilnika pogleda pripravili za učenje modelov strojnega učenja. V tem poglavju opišemo, kako posamezno časovno okno meritev pretvorimo v graf, ki ga uporabimo kot vhod za grafovske modele. Vozlišča predstavljajo veljavne meritve znotraj okna, povezave pa izbrane odnose med meritvami.

Graf definiramo kot

$$G = (V, E), \quad (4.1)$$

kjer je V množica vozlišč, $E \subseteq V \times V$ pa množica povezav med vozlišči. Vozlišča praviloma vsebujejo značilke $\mathbf{x}_v$, ki jih zapišemo v matriko

$$X \in \mathbb{R}^{|V| \times d}, \quad (4.2)$$

kjer je d število značilk posameznega vozlišča. Povezavo med vozliščema i in j označimo z $e_{ij} \in E$.

V usmerjenih grafih ima povezava določeno izvirno in ponorno vozlišče, zato velja $e_{ij} \neq e_{ji}$. V neusmerjenih grafih povezave nimajo smeri, zato velja $e_{ij} = e_{ji}$.

Povezave lahko vsebujejo tudi uteži. Utež povezave med vozliščema i in j označimo z w_{ij} . Za neutežene povezave si lahko predstavljamo, da imajo utež $w_{ij} = 1$. Če imajo povezave več uteži, jih zapišemo kot vektor $\mathbf{e}_{ij}$ [8].

Homogeni graf je graf, ki ne loči različnih vrst vozlišč in povezav. Heterogeni graf vsebuje vsaj dve različni vrsti vozlišč ali povezav. V tej nalogi uporabljamo heterogeno grafovsko predstavitev, saj ločimo več tipov povezav.

Najprej podamo najbogatejšo grafovsko predstavitev učnega vzorca, ki uporablja vse razpoložljive signale. Nato pokažemo, kako se ista osnovna konstrukcija prilagodi štirim množicam signalov iz poglavja 3.3. Kadar določena množica signalov ne vsebuje informacije, potrebne za posamezno značilko ali relacijo, ta del predstavitve izpustimo. Graf zato v štirih primerih predstavlja isti učni vzorec, razlikuje pa se po količini vhodne informacije in po razpoložljivih relacijah med meritvami.

4.1 Vozlišča

4.1.1 Definicija

Vsako vozlišče v_i predstavlja eno meritev sledilnika pogleda x_i v trenutku i znotraj časovnega okna:

$$v_i \leftrightarrow \mathbf{x}_i. \quad (4.3)$$

Če okno vsebuje n veljavnih meritev, potem graf vsebuje n vozlišč. Vrednost n se lahko med okni razlikuje, saj po čiščenju in filtriranju niso vsa okna popolna. Grafovska predstavitev naravno podpira spremenljivo število vozlišč.

4.1.2 Vektor značilk vozlišča

Vektor značilk vozlišča za končni graf za množico *vsí signali* je

$$\mathbf{x}_i = \left[t_i, x_i, y_i, p_i^{(l)}, p_i^{(r)}, d_i, f_{dur,i} \right], \quad (4.4)$$

kjer je t_i normaliziran časovni žig za vozlišče i , x_i in y_i sta koordinati pogleda, $p_i^{(l)}$ in $p_i^{(r)}$ velikosti leve in desne zenice, d_i je oddaljenost od sledilnika pogleda, $f_{dur,i}$ pa trajanje fiksacije.

Naj bo $\tilde{t}_i$ izvirni relativni časovni žig meritve, $\tilde{t}_0$ časovni žig prve veljavne meritve v oknu, $T = 10$ s pa dolžina okna. Normaliziran časovni žig

izračunamo kot

$$t_i = \frac{\tilde{t}_i - \tilde{t}_0}{T}. \quad (4.5)$$

Tako ima prva veljavna meritev v oknu časovno značilko $t_0 = 0$, preostale meritve pa so izražene relativno na dolžino okna.

Za ostale podgrafe se vektor značilk ustrezno filtrira. V vseh primerih ohranimo časovno značilko t_i , ostale podatke pa ohranimo glede na obravnavano množico signalov.

4.2 Relacije

Definiramo tri relacije med meritvami: časovno, prostorsko in fiksacijsko. Posledično v grafu oblikujemo štiri tipe povezav, saj je časovni tip povezave usmerjen – bodisi naprej ali nazaj. Prostorske in fiksacijske povezave pa obravnavamo kot neusmerjene.

Vsaka povezava ima določen tip relacije, saj časovna povezava, prostorska povezava in fiksacijska povezava opisujejo različne odnose med meritvami. Ta zapis heterogenim grafovskim modelom, opisanim v poglavju 5, omogoča ločeno obravnavo relacij. Osnovni GCN uporabi isti nabor povezav, vendar relacij modelno ne loči; v tem primeru dobimo enostaven homogen graf. Podrobnosti o uporabi relacij v posameznih modelih so opisane v poglavju 5.

4.2.1 Časovne povezave

Časovne povezave povezujejo meritve zaporedne v času. Naj bodo vozlišča v posameznem oknu urejena po času, tako da je v_i i -ta meritev v časovnem zaporedju.

Ločimo usmerjene časovne povezave naprej in nazaj:

$$E_t^+ = \{(v_i, v_j) : 1 \leq j - i \leq k_t\}, \quad (4.6)$$

$$E_t^- = \{(v_i, v_j) : 1 \leq i - j \leq k_t\}. \quad (4.7)$$

Parameter $k_t \in \mathbb{N}$ določa število časovnih sosedov na vsako stran. Končna konfiguracija uporablja $k_t = 1$, zato je vozlišče v_i povezano samo z neposredno predhodno in neposredno naslednjo meritvijo, kadar ti vozlišči obstajata.

Povezave v E_t^+ potekajo od prejšnjih proti kasnejšim meritvam, povezave v E_t^- pa od kasnejših proti prejšnjim meritvam. Pri grafu z n vozlišči to pri $k_t = 1$ pomeni $n - 1$ časovnih povezav naprej in $n - 1$ časovnih povezav nazaj. Za polno 10-sekundno okno s pričakovanimi 600 meritvami je to 599 povezav v vsako smer.

4.2.2 Prostorske povezave

Prostorske povezave so neusmerjene povezave, ki povezujejo meritve s podobnim položajem pogleda znotraj istega časovnega okna. Zato so na voljo le pri množicah signalov *samo pogled*, *pogled in zenici* in *vsil signali*, ki vsebujejo koordinati pogleda (x, y) .

Prostorsko razdaljo med meritvama i in j definiramo evklidsko:

$$d_{ij}^{(s)} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}. \quad (4.8)$$

Za vsako vozlišče v_i poiščemo k_s najbližjih sosedov v prostoru koordinat pogleda (x, y) z uporabo k-d drevesa. Če je v_j med temi sosedi, dodamo povezavo med vozliščema v_i in v_j . Ker prostorske povezave obravnavamo kot neusmerjene, povezavo predstavimo z dvema usmerjenima povezavama (v_i, v_j) in (v_j, v_i) . Na koncu odstranimo podvojene povezave znotraj relacije E_s .

Število prostorskih povezav zato ni določeno samo z n in k_s , ampak tudi z geometrijo položajev pogleda. Pred simetrizacijo vsako vozlišče prispeva k_s sosedskih izbir, po simetrizaciji in odstranitvi podvojenih parov pa za usmerjeni zapis neusmerjene relacije velja

$$nk_s \leq |E_s| \leq 2nk_s. \quad (4.9)$$

Dejansko gostoto prostorskih povezav zato poročamo z opazovanimi statistiki grafov.

4.2.3 Fiksacijske povezave

Fiksacijske povezave povezujejo meritve, ki pripadajo isti zaznani fiksaciji. Pripadnost fiksaciji določimo z identifikatorjem fiksacije, podanim v MAHNOB-HCI podatkih. Ta podatek imamo zgolj v množici *vsi signali*, zato so te povezave vključene le v končni graf.

Redčenje povezav znotraj fiksacije


Znotraj posamezne fiksacije ne povežemo vseh vozlišč med seboj, saj bi to povzročilo preveliko število fiksacijskih povezav. Za to nalogo smo zato definirali redkejšo konstrukcijo *razširjenih povezav znotraj fiksacije* (angl. *dilated intra-fixation edges*), ki ohrani pripadnost isti fiksaciji, ne da bi graf postal pregost. Parameter $k_f = 3$ iz vsakega vozlišča generira tri povezave – eno do neposrednega naslednika in dve do meritev na približno enakomerno razporejenih položajih znotraj iste fiksacije. Tako konstrukcija združi lokalne in bolj oddaljene povezave znotraj fiksacije, hkrati pa se izogne kvadratni rasti števila povezav pri polni kliku. Shematski prikaz je na sliki 4.1, formalna definicija konstrukcije pa v dodatku C.1.

4.2.4 Značilke povezav

Povezavam poleg tipa relacije priredimo tudi značilke povezav, ki opisujejo odnos med izvirno meritvijo v_i in ciljno meritvijo v_j . Osnovne časovne značilke so normalizirani čas izvirne in ciljne meritve, t_i in t_j , ter časovna razlika $\Delta t = t_j - t_i$. Čeprav bi model te časovne značilke načeloma lahko izpeljal iz značilk obeh vozlišč, jih vključimo neposredno, da mu olajšamo učenje časovnih odnosov med meritvama. Pri časovnih povezavah dodamo še smer ρ_{ij} , kjer ima povezava naprej vrednost $\rho_{ij} = 1$, povezava nazaj pa $\rho_{ij} = -1$. Značilke povezav so del grafske predstavitve, vendar jih uporabi le model HeteroGCN-MLP-w, opisan v poglavju 5.

Pri grafih, ki vsebujejo koordinate pogleda, povezavam dodamo tudi prostorske značilke. To sta razliki v koordinatah pogleda, $\Delta x = x_j - x_i$ in

$$F = 21, k_f = 3, L = 2, \\ s = 7, D = \{1, 8, 15\}$$



Slika 4.1: Shematski prikaz razširjenih povezav znotraj ene fiksacije za povprečno velikost fiksacije. Iz $F = 21$ in $k_f = 3$ izračunamo $s = 7$ in $D = \{1, 8, 15\}$. Število plasti GNN je $L = 2$, kar vpliva na doseg sporočila posameznega vozlišča in gostoto grafa. Vozlišča so prikazana v krogu z lokalnimi indeksi znotraj fiksacije. Odtenka modrih povezav ločita neposredne sosede izbranega vozlišča $v = 0$ in dodatna vozlišča, dosegljiva v drugem skoku po fiksacijski relaciji.

$\Delta y = y_j - y_i$, ter evklidska razdalja med položajema pogleda na zaslonu d_{ij}^{zaslon} . Te značilke so zato na voljo pri vseh množicah signalov, razen pri množici *samo zenici*.

Pri grafih, ki vsebujejo velikosti zenic, povezavam dodamo spremembi velikosti leve in desne zenice. Značilki $\Delta p_{ij}^{(l)} = p_j^{(l)} - p_i^{(l)}$ in $\Delta p_{ij}^{(r)} = p_j^{(r)} - p_i^{(r)}$ sta na voljo pri množicah *samo zenici*, *pogled in zenici* ter *vsii signali*.

Pri množici *vsii signali* povezavam dodamo še značilko, povezano z oddaljenostjo od sledilnika pogleda. Značilka $\Delta d_{ij} = d_j - d_i$ opisuje razliko v oddaljenosti od sledilnika pogleda med ciljno in izvirno meritvijo.

Podroben pregled značilk povezav je podan v tabeli C.1 v dodatku C.

4.3 Grafi po množicah signalov


Za vsako množico signalov iz razdelka 3.3 zgradimo graf po isti osnovni konstrukciji. Razlika med grafi je v značilkah vozlišč, relacijah in značilkah povezav, ki jih izbrana množica signalov omogoča. Množica *vsii signali* je najbogatejša predstavitev. Ostale množice uporabijo ustrezne podmnožice značilk in relacij. Tabela 4.1 prikazuje uporabljene komponente grafske predstavitve za vse štiri množice signalov.

Slika 4.2 prikazuje primer najbogatejše konstrukcije na majhnem izseku časovnega okna za množico *vsii signali*. Prikaz združi vozlišča, časovne, prostorske in fiksacijske povezave v isti graf.

4.4 Statistika konstruiranih grafov

Tabela 4.2 prikazuje osnovne statistike grafov, ki nastanejo pri končni konfiguraciji konstrukcije. Vrednosti so izračunane za osrednjo eksperimentalno nalogo, t.j. binarno klasifikacijo negativne in pozitivne valence. Ker se posamezne množice signalov filtrirajo glede na razpoložljivost uporabljenih signalov, število konstruiranih grafov med stolpci ni povsem enako.

Ničelne vrednosti pri prostorskih in fiksacijskih povezavah pomenijo, da ta



Slika 4.2: Primer grafovske konstrukcije za množico *vsi signali*. Vozlišča predstavljajo meritve v izseku časovnega okna, povezave pa prikazujejo časovne, prostorske in fiksacijske relacije. Ločeni prikazi posameznih relacij so zbrani v dodatku C.

Tabela 4.1: Množice signalov in pripadajoča grafovska konstrukcija. Značilke povezav uporabi le model HeteroGCN-MLP-w pri izračunu ucljivih predznačenih uteži povezav. Smer ρ_{ij} velja samo za časovne povezave.

Množica signalov	Značilke vozlišč	Relacije	Značilke povezav
<i>samo pogled</i>	t_i, x_i, y_i	E_t^+, E_t^-, E_s	$t_i, t_j, \Delta t, \rho_{ij}, \Delta x, \Delta y, d_{ij}^{\text{zaslon}}$
<i>samo zenici</i>	$t_i, p_i^{(l)}, p_i^{(r)}$	E_t^+, E_t^-	$t_i, t_j, \Delta t, \rho_{ij}, \Delta p_{ij}^{(l)}, \Delta p_{ij}^{(r)}$
<i>pogled in zenici</i>	$t_i, x_i, y_i, p_i^{(l)}, p_i^{(r)}$	E_t^+, E_t^-, E_s	$t_i, t_j, \Delta t, \rho_{ij}, \Delta x, \Delta y, d_{ij}^{\text{zaslon}}, \Delta p_{ij}^{(l)}, \Delta p_{ij}^{(r)}$
<i>vsi signali</i>	$t_i, x_i, y_i, p_i^{(l)}, p_i^{(r)}, d_i, f_{dur,i}$	E_t^+, E_t^-, E_s, E_f	$t_i, t_j, \Delta t, \rho_{ij}, \Delta x, \Delta y, d_{ij}^{\text{zaslon}}, \Delta p_{ij}^{(l)}, \Delta p_{ij}^{(r)}, \Delta d_{ij}$

Opomba: Barve označujejo čas, pogled in prostorske značilke, zenici ter fiksacije in dodatne signale.

relacija pri posamezni množici signalov ni del konstrukcije. Največjo razliko v gostoti grafa povzroči fiksacijska relacija pri množici *vsi signali*, kjer fiksacijske povezave doprinesejo 62,4 % vseh povezav.

Tabela 4.2: Osnovne statistike konstruiranih grafov pri $k_t = 1$, $k_s = 1$ in $k_f = 3$.

Statistika	<i>samo pogled</i>	<i>samo zenici</i>	<i>pogled in zenici</i>	<i>vsi signali</i>
Število grafov	5.097	5.065	5.055	5.034
Mediana števila vozlišč	591	601	585	561
Mediana časovnih povezav naprej	590	600	584	560
Mediana časovnih povezav nazaj	590	600	584	560
Mediana prostorskih povezav	860	0	855	825
Mediana fiksacijskih povezav	0	0	0	3.210
Mediana skupnega števila povezav	2.047	1.200	2.029	5.153

Poglavje 5

Primerjani modeli

V nalogi se osredotočamo na primerjavo štirih družin modelov strojnega učenja za klasifikacijo valence iz podatkov sledilnika pogleda. V tem poglavju razložimo, katere so te družine in na kratko opišemo vsak uporabljen model znotraj družine. Grafovske modele opišemo podrobneje, saj predstavljajo metodološko jedro naloge, poleg tega pa so za podatke sledilnika pogleda manj standardiziran pristop kot uveljavljeni klasični modeli.

Modeli se razlikujejo po predstavitvi vhodnih podatkov. Negrafovski osnovni modeli prejmejo agregirano tabelarično predstavitev posameznega časovnega okna (značilke), zamrznjeni prednaučeni predstavitveni modeli dobijo časovne vrste izbranih signalov, grafovski modeli pa delujejo na grafu, ki predstavlja časovno okno meritev.

5.1 Pregled primerjanih pristopov

V tabeli 5.1 je prikazano, katere modele uporabljamo, kateri družini vsak model pripada, kakšne podatke sprejme na vhod in kakšno vlogo ima v naši primerjalni študiji.

Tabela 5.1: Pregled primerjanih modelov in njihovih vhodnih predstavitev.

Družina modelov	Model	Vhod v model	Vloga v primerjavi
izhodiščna klasifikatorja	Naključni	brez učenja iz značilke	spodnja meja naključnega ugibanja
	Večinski		spodnja meja napovedovanja najpogostejšega razreda
klasični modeli strojnega učenja	SVM	agregirane značilke okna	klasični model strojnega učenja
	LightGBM		
	MLP		
zamrznjeni prednaučeni predstavitveni modeli	GazeMAE	koordinati pogleda (x, y)	prednaučena predstavitev za množico <i>samo pogled</i>
	MOMENT	časovne vrste izbranih signalov	prednaučena predstavitev za množice s signali zenic oziroma več signali
grafovski modeli	GCN	homogeni graf okna	osnovni grafovski model
	HeteroGCN-mean	heterogeni graf okna	ločena obravnava relacij s preprosto fuzijo
	HeteroGCN-MLP		ločena obravnava relacij z učljivo fuzijo
	HeteroGCN-MLP-w	heterogeni graf okna in značilke povezav	najkompleksnejša stopnja arhitekturne lestvice

5.2 Negrafovski osnovni modeli

5.2.1 Izhodiščna klasifikatorja

Večinski in naključni klasifikator predstavljata spodnjo primerjalno mejo. Večinski klasifikator vedno napove večinski razred učne množice, naključni klasifikator pa razrede napoveduje z enako verjetnostjo ne glede na porazdelitev podatkov. Pri binarni klasifikaciji to pomeni verjetnost 50 % za vsak razred. Cilj je, da naučeni modeli presežejo rezultate izhodiščnih klasifikatorjev, saj s tem pokažemo uspešno prepoznavanje vzorcev.

5.2.2 Klasični modeli strojnega učenja

Za pravično primerjavo negrafovskim osnovnim modelom podamo agregirane značilke istih signalov, kot jih prejme GNN. V primeru množice *vsí signali* so to koordinati pogleda (x , y), velikosti leve in desne zenice, oddaljenost od sledilnika pogleda ter informacija o fiksacijah. Dodamo tudi normaliziran čas meritve znotraj okna. Za vsak signal izračunamo opisne statistike na ravni okna: povprečje, standardni odklon, minimum, maksimum, razpon, mediano, prvi kvartil, tretji kvartil in medkvartilni razmik. Pri fiksacijah dodamo še število fiksacij, delež meritev v oknu, ki pripadajo fiksacijam, vsoto trajanj, povprečno trajanje in največje trajanje fiksacije. V primeru množice *vsí signali* je eno okno v tabelarični predstavitvi opisano z 68 agregiranimi značilkami. Takšna pretvorba časovnega signala v opisne statistike na ravni okna oziroma odziva je običajen pristop pri klasičnih modelih strojnega učenja za podatke pogleda [5, 19, 30].

SVM

SVM uporabimo kot klasični model z RBF jedrom nad agregiranimi značilkami okna [6]. RBF jedro modelu omogoča nelinearno ločevanje razredov, zato je SVM uporaben kot močan negrafovski osnovni model. Ker je SVM občutljiv na velikostni red vhodnih značilk, agregirane značilke pred učenjem standardizir-

ramo, da značilke z večjimi številskimi vrednostmi ne vplivajo nesorazmerno na odločanje modela.

MLP

Osnovni MLP uporabimo kot primer osnovnega nevronskega modela [9]. Vhod modela je vektor agregiranih značilk enega časovnega okna, izhod pa logiti za razrede ciljne naloge. Arhitektura je namerno preprosta: dve skriti polno povezani plasti z aktivacijo ReLU in izpuščanjem, za njima pa izhodna linearna plast. Model učimo s prečno entropijo.

LightGBM

LightGBM uporabimo kot predstavnika gradientno spodbujenih odločitvenih dreves [16]. Model je primeren za tabelarične podatke, zato je naravna primerjava za agregirane značilke časovnih oken. Za razliko od SVM in MLP standardizacije vhodnih značilk ne potrebuje, saj odločitvena drevesa delujejo na pragovih posameznih značilk.

5.3 Zamrznjeni prednaučeni predstavitveni modeli

Poleg modelov nad ročno agregiranimi značilkami uporabimo tudi dva prednaučena kodirnika signalov: **GazeMAE** za podatke pogleda in **MOMENT** za ostale časovne vrste [2, 10]. Takšni modeli vhodnega okna ne pretvorijo v vnaprej določene statistike, temveč neposredno iz signala izračunajo vektorsko predstavitev. V tej nalogi ju uporabimo kot zamrznjena kodirnika, zato njunih parametrov med učenjem ne spreminjamo. Na izračunanih predstavitev nato učimo ločeno klasifikacijsko glavo MLP. Ta MLP je arhitekturno drugačen, vendar ločen in nepovezan s samostojnim klasifikatorjem MLP iz družine klasičnih modelov strojnega učenja.

5.3.1 GazeMAE

Za podatke pogleda uporabimo odprtokodni prednaučeni kodirnik GazeMAE [2]. Model prejme samo koordinati pogleda (x, y) , zato ga samostojno uporabimo le za množico *samo pogled*. Ker je bil GazeMAE učen na 2 s oknih, vzorčenih s frekvenco 500 Hz, uporabljena 10 s okna najprej pretvorimo v obliko, ki jo model pričakuje. Koordinati pogleda razdelimo na pet neprekrivajočih se 2 s kosov in ju prevzorčimo na ciljno frekvenco 500 Hz. Kodirnik temelji na časovno-konvolucijskih mrežah, ki ločeno kodirajo položaj in hitrost pogleda. Iz predstavitev posameznih kosov nato z združevanjem pridobimo predstavitev celotnega okna s 512 razsežnostmi.

5.3.2 MOMENT

MOMENT uporabimo kot splošni prednaučeni model za časovne vrste [10]. V nasprotju z GazeMAE ni vezan samo na koordinate pogleda, zato ga uporabimo za večkanalne časovne vrste signalov, ki pripadajo izbrani množici signalov v posameznem eksperimentu. To so lahko velikosti zenic, oddaljenost od sledilnika pogleda in trajanje fiksacije. Samostojno ga uporabimo le za množico *samo zenici*. V primerih *pogled in zenici* ter *vsii signali* pa ga uporabimo skupaj z GazeMAE. Vhodno okno pred uporabo prevzorčimo na 512 časovnih korakov. MOMENT temelji na arhitekturi transformerjev za časovne vrste in v uporabljeni nastavitvi izračuna predstavitev okna s 768 razsežnostmi.

5.3.3 Združene predstavitve GazeMAE in MOMENT

Pri množicah *pogled in zenici* ter *vsii signali* uporabimo združeno predstavitev obeh kodirnikov. Predstavitev GazeMAE in predstavitev MOMENT konkateneramo v en skupni vektor, ki je nato vhod v klasifikacijsko glavo MLP.

V rezultatih zamrznjene prednaučene predstavitvene modele obravnavamo kot eno družino modelov GazeMAE/MOMENT. Pri množici *samo pogled* ta vrstica pomeni uporabo GazeMAE, pri množici *samo zenici* uporabo MOMENT, pri množicah *pogled in zenici* ter *vsii signali* pa združeno predstavitev obeh kodirnikov.

Tabela 5.2: Arhitekturna lestvica grafovskih modelov.

Model	Ločene relacije	Fuzija relacij	Uteži pove- zav	Namen stopnje
GCN	ne	–	ne	preveri osnovno grafovsko predstavitev v homogenem grafu
HeteroGCN-mean	da	povprečje	ne	preveri vpliv ločene obravnave relacij
HeteroGCN-MLP	da	MLP	ne	preveri vpliv učljive fuzije relacijskih predstavitev
HeteroGCN-MLP-w	da	MLP	da	preveri vpliv učljivih predznačenih uteži povezav

Za to smo se odločili zato, da ohranimo tabelo rezultatov pregledno.

5.4 Grafovski modeli

Grafovski modeli uporabljajo grafovsko predstavitev okna iz poglavja 4. Štiri grafovske modele uredimo v arhitekturno lestvico, tj. zaporedje postopnih nadgradenj, v katerem vsaka naslednja stopnja doda eno obravnavano zmožnost modela. Pri isti množici signalov vse stopnje uporabljajo iste vozliščne značilke, iste relacije in ista časovna okna. Razlikujejo se po tem, kako obravnavajo tipe povezav, kako združujejo relacijske predstavitve in ali uporabljajo značilke povezav za izračun učljivih uteži povezav. Najprej definiramo osnovno GNN, nato pa s tremi nadgradnjami postopno gradimo končni model. V tabeli 5.2 so na kratko predstavljene razlike med vsemi štirimi stopnjami grafovskih modelov.

5.4.1 Posredovanje sporočil in skupni cevovod

Grafovske nevronske mreže (GNN) so razred nevronskih mrež, namenjen učenju nad podatki, ki jih lahko predstavimo z grafom [8, 17, 31]. Cilj GNN je naučiti se predstavitev vozlišč, povezav ali celotnega grafa tako, da model pri izračunu predstavitve posameznega vozlišča upošteva tudi njegovo lokalno okolico.

Osnovna ideja GNN je *posredovanje sporočil* [8]. Vsako vozlišče v posamezni plasti prejme informacije od svojih sosedov, jih agregira in na podlagi zbranih informacij posodobi svojo predstavitev.

Splošno plast posredovanja sporočil lahko zapišemo kot

$$\mathbf{h}_v^{(k)} = \phi^{(k)} \left(\mathbf{h}_v^{(k-1)}, \bigoplus_{u \in \mathcal{N}(v)} \psi^{(k)}(\mathbf{h}_v^{(k-1)}, \mathbf{h}_u^{(k-1)}, \mathbf{e}_{uv}) \right), \quad (5.1)$$

kjer je $\mathcal{N}(v)$ množica sosedov vozlišča v , $\psi^{(k)}$ funkcija sporočila, $\oplus$ agregacijska funkcija, $\phi^{(k)}$ funkcija posodobitve, $\mathbf{h}_v^{(k)}$ pa predstavitev vozlišča v v plasti k . Funkcija $\psi^{(k)}$ je lahko linearna preslikava ali večslojni perceptron nad predstavitvama vozlišč in značilkami povezave, $\phi^{(k)}$ pa preprosta vsota prejšnje predstavitve vozlišča in agregiranega sporočila, večslojni perceptron ali rekurentna enota. Isti funkciji $\psi^{(k)}$ in $\phi^{(k)}$ uporabimo pri vseh vozliščih, zato je plast ob invariantni agregaciji ekvivariantna na permutacijo vozlišč, kar pomeni, da preureditev vozlišč le enako preuredi njihove izhodne predstavitve. Agregacijska funkcija $\oplus$ mora biti invariantna na vrstni red sosedov. To lastnost imajo na primer vsota, povprečje in maksimum, zato lahko ista GNN plast deluje na grafih različnih velikosti. Pri časovnih vrstah je ureditev meritev sicer naravno določena s časom, vendar jo mora model zajeti eksplicitno, na primer s časovnimi povezavami ali časovnimi značilkami, saj se z grafovsko predstavitvijo sicer izgubi.

Pri heterogenem grafu, kjer povezave razdelimo po tipih oziroma relacijah $r \in \mathcal{R}$, namesto ene same množice sosedov obravnavamo množice $\mathcal{N}_r(v)$, ki vsebujejo sosede vozlišča v po relaciji r . Sporočila se najprej agregirajo ločeno

znotraj posamezne relacije:

$$\mathbf{m}_{v,r}^{(k)} = \bigoplus_{u \in \mathcal{N}_r(v)} \psi_r^{(k)}(\mathbf{h}_u^{(k-1)}, \mathbf{e}_{uv}). \quad (5.2)$$

Pri tem je $\psi_r^{(k)}$ funkcija sporočila za relacijo r , $\mathbf{m}_{v,r}^{(k)}$ pa agregirano sporočilo, ki ga vozlišče v prejme po tej relaciji v plasti k . Za vsako relacijo lahko uporabimo ločeno linearno preslikavo ali večslojni perceptron $\psi_r^{(k)}$, agregacija znotraj posamezne relacije pa mora biti, tako kot prej, invariantna na vrstni red sosedov. Relacijska sporočila $\mathbf{m}_{v,r}^{(k)}$ se nato združijo v skupno sporočilo za vozlišče. Združevanje relacij je lahko vsota ali povprečje, lahko pa vključuje konkatenacijo oziroma učljivo fuzijo relacijskih predstavitev, pri katerih mora biti vrstni red relacij vnaprej določen.

Če želimo napovedati razred celotnega grafa, lahko nalogo obravnavamo kot klasifikacijo na ravni grafa. Naj bo L število plasti grafovske nevronske mreže. Na zadnji, L -ti plasti dobimo končne predstavitve vozlišč $\mathbf{h}_v^{(L)}$, ki jih združimo v predstavitev celotnega grafa:

$$\mathbf{h}_G = \text{READOUT}(\{\mathbf{h}_v^{(L)} : v \in V\}). \quad (5.3)$$

Funkcija READOUT je agregacijska funkcija na ravni grafa. Pogoste izbire so povprečje, vsota, maksimum ali združevanje s pozornostjo. Predstavitve grafa $\mathbf{h}_G$ nato uporabimo v klasifikacijski glavi, ki napove razred celotnega grafa.

Grafovske modeli na vhod prejmejo graf glede na izbrano množico signalov, kot definirano v poglavju 4. Razsežnost vhodnih preslikav prilagodimo izbrani množici signalov – ločeno za značilke vozlišč, pri modelu **HeteroGCN-MLP-w** pa tudi za značilke povezav.

Vhodne vektorje najprej preslikamo v skupni latentni prostor z dvoslojnim MLP. Tako dobimo začetno predstavitev vsakega vozlišča, ki jo nato posodablja grafovske plasti. Te plasti posredujejo sporočila po povezavah grafa in pri vsakem vozlišču združijo informacije iz njegove okolice. V grafovskih blokih uporabimo aktivacijo GELU, rezidualne povezave, normalizacijo plasti in izpuščanje. Aktivacijska funkcija GELU je določena kot $\text{GELU}(x) = x\Phi(x)$,

kjer $\Phi(x)$ označuje porazdelitveno funkcijo standardne normalne porazdelitve. Rezidualna povezava vhod bloka prišteje njegovi izhodni preslikavi, normalizacija plasti pa za vsako vozlišče normalizira komponente predstavitev z njihovim povprečjem in varianco. Izpuščanje med učenjem z določeno verjetnostjo nastavi posamezne aktivacije na nič, s čimer omejuje prekomerno prileganje. Ti gradniki niso predmet primerjave med grafovskimi modeli. Gre za uveljavljene gradnike nevronske mreže, ki podpirajo stabilnejše učenje in omejujejo prekomerno prileganje [13, 12, 1, 29]. Primerjava se osredotoča na obravnavo relacij, fuzijo relacijskih predstavitev in uporabo značilk povezav. Ker napovedujemo razred celotnega okna, iz končnih predstavitev vozlišč s pozornostnim združevanjem izračunamo predstavitev celotnega grafa. Uporabimo $\mathbf{h}_G = \sum_{v \in V} \alpha_v \mathbf{h}_v$, kjer je $\mathbf{h}_G$ predstavitev grafa, α_v utež pozornosti za vozlišče v , $\mathbf{h}_v$ pa predstavitev vozlišča v . Uteži pozornosti normaliziramo s softmax normalizacijo:

$$\alpha_v = \frac{\exp(g(\mathbf{h}_v))}{\sum_{u \in V} \exp(g(\mathbf{h}_u))}. \quad (5.4)$$

Pri tem je g učljiva funkcija, ki predstavitvi vozlišča priredi skalarno oceno pomembnosti. Predstavitev grafa nato pošljemo skozi klasifikacijsko glavo MLP. Glava izračuna dva logita, enega za negativno in enega za pozitivno valenco. Napoved je razred z večjim logitom. Pri poročanju verjetnosti logite normaliziramo s softmaxom. Podrobnosti o številu plasti, velikosti skritih predstavitev, verjetnosti izpuščanja in ostalih hiperparametrih so opisane v dodatku B.

Vse GNN učimo od začetka do konca (ang. *end-to-end*), kar pomeni, da se vsi učljivi deli modela optimizirajo hkrati glede na klasifikacijsko izgubo. To vključuje začetno preslikavo značilk vozlišč, grafovske plasti, morebitno fuzijo relacij, pozornostno združevanje in klasifikacijsko glavo. V nadaljevanju opišemo specifične vsake arhitekture v štiri-stopenjski arhitekturni lestvici, začnši z najenostavnejšim – s homogenim GCN. V enačbah posameznih modelov je $\mathbf{H}^{(k-1)}$ matrika vhodnih predstavitev vozlišč v k -ti grafovski plasti, $\mathbf{Z}^{(k)}$ pa njen izhod pred skupno rezidualno povezavo, normalizacijo plasti in izpuščanjem.

5.4.2 GCN

GCN je v osnovi homogeni grafovski model. Uporablja isto grafovsko predstavitev okna, kot je bila opisana v poglavju 4, vendar ne ločuje časovnih, prostorskih in fiksacijskih relacij. Vse povezave združi v en homogen graf, posredovanje sporočil pa izvede s plastmi **GCNConv** iz knjižnice PyTorch Geometric (PyG) [7]. Model ne uporablja značilnk povezav in posledično učljivih uteži povezav. Glavni korak ene plasti modela zapišemo kot [17]

$$\mathbf{Z}^{(k)} = \text{GELU}\left(\mathbf{D}^{-\frac{1}{2}}\mathbf{A}\mathbf{D}^{-\frac{1}{2}}\mathbf{H}^{(k-1)}\boldsymbol{\Theta}^{(k)} + \mathbf{b}^{(k)}\right), \quad (5.5)$$


kjer je $\mathbf{A}$ matrika sosednosti homogenega grafa, $\mathbf{D}$ pripadajoča diagonalna matrika stopenj, $\boldsymbol{\Theta}^{(k)}$ matrika učljivih parametrov in $\mathbf{b}^{(k)}$ pristranskost. V grafovski konvoluciji ne dodajamo zank iz vozlišča vase, saj se lastna predstavitev vozlišča ohranja prek rezidualne povezave. Slika 5.1 prikazuje osnovni cevovod tega modela.

5.4.3 HeteroGCN-mean


HeteroGCN-mean dobimo tako, da GCN nadgradimo s heterogeno grafovsko predstavitvijo. Kot opisano v 4 tukaj ločimo različne tipe relacij. Relacijske predstavitve vozlišč združimo v skupno predstavitev vozlišča s preprostim povprečenjem. Ker časovne, prostorske in fiksacijske povezave opisujejo različne odnose med meritvami, pričakujemo, da bo njihova ločena obdelava ohranila informacije, ki se pri homogenem združevanju povezav lahko izgubijo. Za vsako relacijo $r \in \mathcal{R}$ uporabimo ločeno grafovsko konvolucijo, nato pa njihove izhode povprečimo:

$$\begin{aligned} \mathbf{Z}_r^{(k)} &= \text{GELU}\left(\mathbf{D}_r^{-\frac{1}{2}}\mathbf{A}_r\mathbf{D}_r^{-\frac{1}{2}}\mathbf{H}^{(k-1)}\boldsymbol{\Theta}_r^{(k)} + \mathbf{b}_r^{(k)}\right), \\ \mathbf{Z}^{(k)} &= \frac{1}{|\mathcal{R}|} \sum_{r \in \mathcal{R}} \mathbf{Z}_r^{(k)}, \end{aligned} \quad (5.6)$$

kjer $\mathbf{A}_r$ in $\mathbf{D}_r$ opisujeta povezave in stopnje vozlišč znotraj relacije r , vsaka relacija pa ima svoje parametre $\boldsymbol{\Theta}_r^{(k)}$ in $\mathbf{b}_r^{(k)}$. Kot prikazano v diagramu 5.2, je sprememba glede na homogeni GCN samo v tem, da se sporočila najprej izračunajo ločeno po relacijah, nato pa združijo s povprečenjem.



Slika 5.1: Diagram arhitekture GCN. Model vse povezave obravnava kot en homogen graf, zato se sporočila posredujejo prek ene skupne grafovske konvolucije.



Slika 5.2: Diagram arhitekture HeteroGCN-mean. Model ločeno izračuna sporočila po časovnih, prostorskih in fiksacijskih relacijah, relacijske predstavitve pa združi s povprečenjem.

5.4.4 HeteroGCN-MLP


HeteroGCN-MLP dobimo tako, da HeteroGCN-mean nadgradimo z učljivo fuzijo relacijskih predstavitev. Različne predstavitve vozlišč – tiste, ki so v danem modelu na voljo izmed časovne naprej, časovne nazaj, prostorske ter fiksacijske – najprej konkateneramo, nato pa jih z dvoslojnim perceptronom združimo v skupno predstavitev vozlišča. Preprosto povprečenje vsem relacijam pripiše enako vlogo, učljiva fuzija pa modelu omogoči, da glede na klasifikacijsko nalogo različne relacijske predstavitve uporabi različno. Relacijski izhodi $\mathbf{Z}_r^{(k)}$ se izračunajo kot v enačbi (5.6), njihovo učljivo fuzijo pa zapišemo kot

$$\mathbf{Z}^{(k)} = f_{\text{fuz}}^{(k)} \left(\parallel_{r \in \mathcal{R}} \mathbf{Z}_r^{(k)} \right), \quad (5.7)$$

kjer $\parallel$ označuje konkatencijo v vnaprej določenem vrstnem redu relacij, $f_{\text{fuz}}^{(k)}$ pa dvoslojni perceptron k -te grafske plasti. Kot prikazano v diagramu 5.3, je sprememba glede na HeteroGCN-mean v zamenjavi ročno določene fuzije z učljivo fuzijo relacijskih predstavitev.

5.4.5 HeteroGCN-MLP-w

HeteroGCN-MLP-w dobimo tako, da HeteroGCN-MLP nadgradimo z učljivimi utežmi povezav. Za izračun uteži povezav ima model tri večslojne perceptrone: $f_w^{\text{čas}}$, f_w^{prostor} in $f_w^{\text{fiksacija}}$. Ti na podlagi vektorja značilk posamezne povezave, katerega komponente so povzete v tabeli C.1, izračunajo skalarno predznačeno utež, ki določa, kako močno posamezna povezava vpliva na posredovanje sporočil. Pri posamezni množici signalov se uporabijo le funkcije za relacije, ki so v grafu prisotne. Časovne povezave naprej in nazaj si delijo isto funkcijo $f_w^{\text{čas}}$, smer povezave pa je podana kot dodatna značilka povezave ρ_{ij} . Formule za izračun in normalizacijo uteži so podane v dodatku B.4. Za vozlišče v in



Slika 5.3: Diagram arhitekture HeteroGCN-MLP. Model relacijske predstavitve najprej konkatencira, nato pa jih združi z učljivo fuzijo prek dvoslojnega perceptrona.

relacijo r je glavni korak uteženega posredovanja sporočil


$$\begin{aligned} \mathbf{z}_{v,r}^{(k)} &= \text{GELU} \left(\sum_{u \in \mathcal{N}_r(v)} w_{uv}^{(r)} \Theta_r^{(k)} \mathbf{h}_u^{(k-1)} + \mathbf{b}_r^{(k)} \right), \\ \mathbf{z}_v^{(k)} &= f_{\text{fuz}}^{(k)} \left(\parallel_{r \in \mathcal{R}} \mathbf{z}_{v,r}^{(k)} \right). \end{aligned} \quad (5.8)$$

Uteži $w_{uv}^{(r)}$ so že normalizirane po vhodnih povezavah vozlišča v znotraj relacije, zato pri tej različici ne uporabimo dodatne normalizacije s stopnjami vozlišč. Ker tudi povezave istega tipa niso nujno enako informativne, lahko model v tej *končni* stopnji z utežmi na podlagi njihovih značilk poudari koristnejše povezave ter oslabi ali predznačeno spremeni prispevek manj koristnih. Slika 5.4 prikazuje dodano vejo za izračun učljivih uteži povezav.

5.4.6 Izbira grafske konvolucije

V glavnih poskusih v vseh grafovskih modelih uporabimo plast **GCNConv** [17]. **GCNConv** je enostaven in uveljavljen operator posredovanja sporočil, ki ga lahko ohranimo nespremenjenega skozi celotno arhitekturno lestvico. V dodatnem poskusu smo ga primerjali s plastmi **GATConv** [31], **GraphConv** [23] ter **GINConv** oziroma **GINEConv** [34, 14]. **GATConv** z mehanizmom pozornosti nauči uteži prispevkov sosednjih vozlišč, **GraphConv** pa ločeno preslika predstavitev ciljnega vozlišča in agregirane predstavitev njegovih sosedov. **GINConv** agregirano predstavitev obdela z večslojnim perceptronom, **GINEConv** pa isti pristop razširi z značilkami povezav. Pri osnovnem GCN smo preizkusili **GINConv**, pri modelu **HeteroGCN-MLP-w** pa **GINEConv**. Pri heterogenem modelu plasti **GCNConv** in **GraphConv** uporabljata učljive skalarne uteži povezav, **GATConv** pa značilke povezav vključi neposredno v izračun pozornosti in ločenih skalarne uteži ne uporablja. Plast **GINEConv** je v implementaciji razširjena kot **WeightedGINEConv**, ki poleg značilk povezav uporabi tudi učljive skalarne uteži.

Poskus smo izvedli na binarni nalogi valence z množico signalov *pogled in zenici*. Razlike med operatorji so bile razmeroma majhne, **GCNConv** pa je



Slika 5.4: Diagram arhitekture HeteroGCN-MLP-w. Model poleg učljive fuzije relacij uporablja še značilke povezav, iz katerih z relacijsko odvisnimi perceptroni izračuna učljive predznačene uteži povezav.

dosegel primerljive in konsistentne rezultate tako pri osnovnem homogenem modelu kot pri uteženi heterogeni arhitekturi. Podrobnosti primerjave so podane v dodatku A.7.

Poglavje 6

Eksperimentalni protokol

V prejšnjih poglavjih smo definirali podatke, ciljne razrede, časovna okna, grafovsko predstavitev in primerjane modele. V tem poglavju določimo, kako te komponente ovrednotimo v skupni eksperimentalni primerjavi. Glavna evalvacijska naloga je binarna klasifikacija negativne proti pozitivni valenci. Primerjava je zasnovana kot kombinacija modelov iz poglavja 5 in množic signalov iz razdelka 3.3. Vsi modeli uporabljajo iste učne vzorce in iste delitve na učno, validacijsko in testno množico. Koda za predobdelavo, konstrukcijo grafov, učenje modelov, evalvacijo in generiranje rezultatov je javno dostopna v repozitoriju projekta [4]. Podatkovna zbirka MAHNOB-HCI v repozitorij ni vključena. Pridobili smo jo preko uradnega spletnega mesta podatkovne zbirke [22].

6.1 Zasnova glavne primerjave

Cilj glavne primerjave je odgovoriti na raziskovalno vprašanje 1: Kakšna je klasifikacijska uspešnost grafovske nevronske mreže za binarno klasifikacijo valence iz podatkov sledilnika pogleda v primerjavi s klasifikacijsko uspešnostjo uveljavljenih negrafovskih pristopov? Zato v primerjavi spreminjamo le način predstavitev okna in model, ki to predstavitev uporabi.

Ciljni razred je binarni razred valence, pri katerem model ločuje med

negativno in pozitivno valenco. Vse štiri množice iz tabele 4.1 obravnavamo kot enakovreden del primerjave, saj nas zanima tudi, kako se klasifikacijska uspešnost spreminja z razpoložljivostjo različnih signalov sledilnika pogleda.

V primerjavi smo uporabili vse modeli iz tabele 5.1: izhodiščna klasifikatorja, klasični modeli nad agregiranimi značilkami, zamrznjeni prednaučeni predstavitevni modeli in grafovski modeli. S tem primerjamo tri različne načine opisa istega časovnega okna: tabelarni povzetek signalov, vektorsko predstavitev časovne vrste in grafovsko predstavitev meritev.

6.2 Validacijski protokol

6.2.1 7-kratno prečno preverjanje po subjektih

Glavno primerjavo izvedemo s 7-kratnim prečnim preverjanjem po subjektih. Pri vsaki ponovitvi so testni subjekti popolnoma ločeni od subjektov, ki so uporabljeni za učenje in validacijo. Iz učnega dela izberemo eno skupino subjektov za validacijsko množico, preostali subjekti pa sestavljajo učno množico. Delitve so pri vseh modelih in vseh množicah signalov enake, določene s fiksnim naključnim semenom.

Takšna delitev ocenjuje posploševanje na nove udeležence. To je za našo nalogo pomembno, saj so signali sledilnika pogleda močno odvisni od specifik posameznika [19]. Ker 22 subjektov ni deljivo s sedem, imajo posamezne testne razdelitve različno velikost – nekatere vsebujejo tri, druge pa štiri testne subjekte.

Validacijska množica se uporablja med učenjem, testna množica pa samo za končno oceno v posamezni ponovitvi. Pri nevronskih modelih zato najboljšo različico modela izberemo glede na validacijsko izgubo, nato pa njeno delovanje izmerimo na pripadajoči testni množici.

6.2.2 Predhodna preverjanja z LOSO

V zgodnejših fazah smo za množico *pogled in zenici* izvedli tudi LOSO. Ker končna primerjava vključuje več modelov in štiri množice signalov, bi polni LOSO protokol bistveno povečal število potrebnih eksperimentov. Zato ga uporabimo kot podporno preverjanje na podmnožici podatkovne zbirke, glavno primerjavo pa izvedemo s 7-kratnim protokolom. Primerjava obeh validacijskih protokolov za valenco in množico *pogled in zenici* je podana v dodatku A.4.

6.3 Nastavitve učenja in hiperparametri

V tem razdelku navedemo nastavitve učenja, ki vplivajo na izvedbo eksperimentov. Nevronske modele učimo z zgodnjim ustavljanjem na validacijski izgubi. Grafovski modeli uporabljajo operator `GCNConv`, dve grafovski plasti, skrite predstavitve velikosti 64 ter povezave s parametri $k_t = 1$, $k_s = 1$ in $k_f = 3$, kot so definirani v poglavju 4. Podrobni hiperparametri vseh modelov so podani v dodatku B.

Nastavitve grafovskih modelov izberemo na podlagi predhodnega kompaktnega mrežnega iskanja. To iskanje smo izvedli v zgodnejši fazi raziskave, ko je klasifikacijska naloga bila še trirazredna, saj je poleg negativne in pozitivne vključevala tudi nevtralno valenco. V dodatku B.2 rezultate iskanja poročamo le kot podporni poskus pri izbiri stabilnih nastavitvev.

6.4 Metrike vrednotenja

Za vrednotenje uporabimo več standardnih metrik, pri čemer sta glavni točnost in makro F1. Za vsak model in vsako množico signalov poročamo povprečje po sedmih testnih razdelitvah. Točnost uporabimo kot osnovno metriko, ker ima glavna naloga dva enakovredna in globalno skoraj uravnotežena razreda,

kot kaže slika 3.1. Za C razredov in N primerov jo izračunamo kot

$$\text{tonost} = \frac{1}{N} \sum_{c=1}^C \text{TP}_c, \quad (6.1)$$

kjer je TP_c število pravilno razvrščenih primerov razreda c .

Makro F1 uporabimo kot dopolnilno glavno metriko. Čeprav sta razreda globalno skoraj uravnotežena, so lahko posamezne testne razdelitve precej neuravnotežene (tudi do razmerja 1 : 2). Makro F1 izračuna F1 ločeno za vsak razred in nato rezultate povpreči z enako utežjo:

$$\text{makro F1} = \frac{1}{C} \sum_{c=1}^C \frac{2\text{TP}_c}{2\text{TP}_c + \text{FP}_c + \text{FN}_c}, \quad (6.2)$$

kjer FP_c in FN_c označujeta število lažno pozitivnih oziroma lažno negativnih napovedi za razred c . S tem dopolni točnost predvsem pri modelih, ki lahko dosežejo sprejemljivo točnost, vendar večino primerov napovedujejo v en sam razred.

Poleg glavnih metrik spremljamo tudi uravnoteženo točnost, preciznost, priklic oziroma občutljivost, uteženi F1, AUC, izgubo in matrike zamenjav. Te metrike uporabimo predvsem za preverjanje stabilnosti in za podrobnejšo analizo napak. Njihove definicije so podane v dodatku A.2. V glavnem besedilu se osredotočimo na točnost in makro F1, razširjene metrike pa poročamo v dodatku A.3.

6.5 Spremljanje učenja

Poleg končnih metrik shranjujemo tudi podatke o poteku učenja. Pri nevronske modelih spremljamo učno in validacijsko izgubo, najboljšo epoho, informacijo o zgodnjem ustavljanju, čas epohe in norme gradientov. Krivulje izgub služijo predvsem preverjanju stabilnosti optimizacije in zaznavanju potencialnega prekomernega prileganja.

Pri grafoskih nevronske mrežah lahko več zaporednih agregacij povzroči, da si predstavitve vozlišč postanejo preveč podobne. Ta pojav imenujemo

prekomerno glajenje. V praksi se lahko pokaže kot zmanjšanje variance predstavitev, visoka medsebojna podobnost vozliščnih vektorjev in skoraj konstantni izhodi klasifikacijske glave. Pri grafovskih modelih spremljamo še nekaj diagnostičnih meritev naučenih predstavitev in napovedi. Med njimi so varianca predstavitev grafa, povprečna kosinusna podobnost predstavitev, razpon logitov in entropija napovednih verjetnosti. Te meritve uporabimo za preverjanje, ali se med učenjem pojavijo skoraj konstantne napovedi, zaznavanje kolapsa predstavitev ali znakov prekomernega glajenja. Definicije spremljanih učnih in diagnostičnih meritev so podane v dodatku A.2. Krivulje učne in validacijske izgube poročamo med rezultati v poglavju 7, diagnostiko naučenih predstavitev in napovedi pa v dodatku A.8.

Poglavje 7

Rezultati

V tem poglavju predstavimo rezultate primerjave različnih modelov za binarno klasifikacijo valence pri 7-kratnem prečnem preverjanju po subjektih. Dodatne rezultate in razširjene metrike poročamo v dodatku A.

7.1 Glavni rezultati klasifikacije

Tabela 7.1 prikazuje povprečno točnost in makro F1 pri 7-kratnem prečnem preverjanju po subjektih. Vse vrednosti so zapisane v odstotkih, štiri signalne množice pa so obravnavane kot enakovredne različice iste klasifikacijske naloge. Večinski klasifikator doseže točnost okoli 52 %, kar ustreza porazdelitvi razredov na sliki 3.1, vendar ima zaradi napovedovanja samo enega razreda makro F1 okoli 34 %.

Najvišjo točnost (70,5 %) in makro F1 (69,7 %) doseže SVM pri signalni množici *pogled in zenici*. LightGBM doseže najboljši rezultat pri množicah *samo pogled*, *samo zenici* in *vsi signali*. Med posameznimi signalnimi množicami je *samo zenici* najšibkejša, vendar vsi naučeni modeli tudi pri tej množici presežejo naključni in večinski klasifikator. Dodajanje zeničnih signalov k pogledu prinese najvišji posamični rezultat, medtem ko množica *vsi signali* v tej primerjavi ne preseže množice *pogled in zenici*.

Grafovski modeli so pri vseh signalnih množicah zanesljivo nad obema

Tabela 7.1: Glavna primerjava modelov pri binarni klasifikaciji valence. Celice vsebujejo točnost/makro F1 v odstotkih. Odebeljena pisava označuje najboljši rezultat za vsak stolpec, odebeljena poševna pisava pa najboljši rezultat med grafovskimi modeli.


Model	samo pogled	samo zenici	pogled in zenici	vsi signali
Naključni	50,2/50,1	50,7/50,6	50,8/50,6	50,9/50,7
Večinski	52,5/34,4	52,2/34,2	52,1/34,2	52,2/34,2
SVM	67,5/67,2	62,1/60,7	70,5/69,7	68,6/67,6
LightGBM	69,7/69,4	63,1/61,9	69,6/68,8	69,0/68,3
MLP	67,0/66,7	62,0/60,3	68,7/67,6	67,2/66,2
GazeMAE/MOMENT*	65,7/65,2	60,5/60,1	65,6/65,2	66,1/65,6
GCN	64,4/64,1	61,0/58,4	65,4/63,9	59,6/57,6
HeteroGCN-mean	61,7/59,2	58,6/55,7	63,8/61,1	61,8/59,7
HeteroGCN-MLP	65,9/65,8	59,1/56,0	64,2/62,8	60,5/56,6
HeteroGCN-MLP-w	64,3/64,0	58,4/54,5	65,5/64,4	62,7/60,8

Opomba: * GazeMAE/MOMENT označuje enoten prikaz zamrznjenih predstavitvenih modelov: GazeMAE pri pogledu, MOMENT pri zenicah in fuzijo obeh pri kombiniranih signalih, kot je pojasnjeno v poglavju 5.3.

izhodiščnima klasifikatorjema, vendar ostanejo pod najboljšima modeloma SVM in LightGBM. Najboljši grafovski rezultat je odvisen od signalne množice – pri *samo pogled* je najuspešnejši HeteroGCN-MLP, pri *samo zenici* osnovni GCN, pri *pogled in zenici* in *vsi signali* pa HeteroGCN-MLP-w. Rezultati torej ne kažejo monotonega izboljševanja z večanjem arhitekturne kompleksnosti grafovskih modelov. V nadaljevanju podrobnejše rezultate matrike zamenjav ter računsko zahtevnost modelov prikažemo na primeru, kjer modeli dosegajo najboljše rezultate, to je na množici *pogled in zenici*. Dodatne matrike zamenjav za vse modele in vse množice signalov so prikazane v dodatku A.5.


Poleg končnih klasifikacijskih meritev smo preverili tudi potek učenja

modelov. Slika 7.1 prikazuje učno in validacijsko izgubo vseh štirih grafovskih arhitektur pri množici signalov *pogled in zenici*. Za berljivost so prikazane povprečne vrednosti čez sedem delitev po subjektih, zasenčeno območje pa predstavlja standardni odklon med delitvami. Ker se delitve zaradi zgodnjega ustavljanja končajo po različnem številu epoh, se dolžina krivulj med modeli razlikuje in se posledično zasenčeno območje pri večjem številu epoh skrči vse do 0, saj se je le v enem primeru model učil največ epoh.



Slika 7.1: Povprečni potek učne in validacijske izgube grafovskih modelov pri množici signalov *pogled in zenici*. Zasenčena območja predstavljajo standardni odklon čez sedem delitev po subjektih.

Pri vseh arhitekturah učna izguba na začetku hitro upade, nato pa se spremembe umirijo. Validacijska izguba se po začetnem izboljšanju večinoma stabilizira, pri čemer med delitvami ostaja opazna variabilnost. Validacijska izguba je pri večini modelov nižja od učne, kar je lahko posledica merjenja v različnih načinih delovanja modela. Modele učimo z izpuščanjem, ki poveča šum in s tem učno izgubo, med validacijo pa izpuščanja ni. Poleg tega je



Slika 7.2: Vrstično normalizirani matriki zamenjav za najboljši model SVM in najboljši grafovski model HeteroGCN-MLP-w pri množici signalov *pogled in zenici*.

učna izguba povprečje med posodabljanjem uteži skozi epoho, validacijska izguba pa se izračuna po koncu epohe, ko so uteži že prilagojene.

Slika 7.2 prikazuje napake za signalno množico *pogled in zenici*, pri kateri je dosežen najboljši skupni rezultat. Najuspešnejši model SVM pravilno razvrsti 73,0 % vzorcev negativne valence in 67,7 % vzorcev pozitivne valence, najuspešnejši grafovski model, HeteroGCN-MLP-w, pa 64,8 % oziroma 65,8 %.

7.2 Velikost in računska zahtevnost modelov

Za odgovor na podvprašanje 4 smo poleg klasifikacijske uspešnosti primerjali tudi velikost modelov ter izmerjeni čas učenja in sklepanja. Tabela 7.2 prikazuje te vrednosti za množico signalov *pogled in zenici*, kjer je bil dosežen najboljši skupni rezultat. Stolpec *Vhod* označuje različne predstavitve istih podatkov, ki uporabljajo agregirane značilke okna, zamrznjene predstavitve prednaučenih kodirnikov oziroma grafovsko predstavitev okna.

Izhodiščna klasifikatorja ter modela SVM in LightGBM nimajo števila nevronskega parametrov, zato je pri njih ta vrednost označena z -. Pri GazeMAE, MOMENT in njuni združeni različici stolpec učljivih parametrov zajema samo

Tabela 7.2: Velikost in računska zahtevnost modelov pri množici signalov *pogled in zenici*.

Model	Vhod	Učljivi parametri (v tisočih)	Vsi parametri (v tisočih)	Učenje [ms/okno]	Sklepanje [ms/okno]	Točnost [%]
Naključni	–	–	–	0,00	0,00	50,8
Večinski	–	–	–	0,00	0,00	52,1
SVM	agregati	–	–	0,39	0,08	70,5
LightGBM	agregati	–	–	0,04	0,00	69,6
MLP	agregati	7	7	0,39	0,00	68,7
GazeMAE*	s. pogleda	82	2.119	0,25	2,64	65,7
MOMENT*	s. zenic	115	125.115	0,24	1,69	60,5
GazeMAE+MOMENT	s. pogleda in zenic	181	127.217	0,26	6,12	65,6
GCN	grafi	26	26	20,73	0,19	65,4
HeteroGCN-mean	grafi	43	43	26,64	0,20	63,8
HeteroGCN-MLP	grafi	76	76	22,27	0,20	64,2
HeteroGCN-MLP-w	grafi	76	76	21,74	0,19	65,5

Opomba: * Vrstici za GazeMAE in MOMENT prikazujeta rezultate na množicah signalov *samo pogled* oziroma *samo zenici*. Čas sklepanja zajema celoten napovedni prehod od že pripravljenega vhoda modela (signalov) do razrednih verjetnosti – to vključuje kodiranje signala, združevanje predstavitev in klasifikacijsko glavo.

klasifikacijsko glavo, stolpec vseh parametrov pa tudi uporabljena zamrznjena kodirnika. Grafovski modeli imajo bistveno manj parametrov kot zamrznjeni prednaučeni kodirniki, vendar je njihov izmerjeni čas učenja na okno za približno dva velikostna razreda večji kot pri negrafovskih modelih. Glede na razmerje med točnostjo in izmerjenim časom sta v tej primerjavi najugodnejša klasična modela SVM in LightGBM.

Poglavje 8

Diskusija

Kot kažejo slike 3.1, 3.2 in 3.3, ima glavna naloga skoraj uravnotežene razrede, očiščene meritve pa pričakovane porazdelitve. To poveča možnost, da se modeli naučijo uporabnih signalov namesto šuma. Matrike zamenjav pokažejo, da modeli niso izrazito pristranski do enega razreda. Posledično imata točnost in makro F1 v rezultatih podobne vrednosti.

Grafovski modeli iz podatkov izluščijo uporaben signal, saj izhodiščne klasifikatorje presegajo za približno deset odstotnih točk točnosti. Njihova uspešnost je primerljiva z uspešnostjo zamrznjenih prednaučenih kodirnikov. Primerjava sicer ni povsem neposredna: GNN se v vsaki delitvi učijo na učnem delu podatkovne zbirke MAHNOB-HCI, medtem ko sta bila **GazeMAE** in **MOMENT** prednaučena na drugih večjih podatkovnih zbirkah, njuna kodirnika pa med učenjem ostaneta zamrznjena. Grafovske predstavitve in predstavitve prednaučenih kodirnikov so torej informativne, vendar pri obravnavanju problema ne presegajo uveljavljenih pristopov s klasičnimi modeli strojnega učenja in ekspertno oblikovanimi značilkami. Ta ugotovitev je metodološko pomembna, saj kaže, da večja izrazna moč grafovskih in drugih globokih modelov sama po sebi ne zagotavlja boljše klasifikacijske uspešnosti. Enostavnejši modeli jih konsistentno prekašajo, hkrati pa so hitrejši in zasedejo manj pomnilnika.

Izkaže se, da je najinformativnejši signal v tej podatkovni množici signal

pogleda, torej koordinati (x, y) v množici *samo pogled*. Velikosti zenic v množici *pogled in zenici* dodajo nekaj koristne informacije, ostali signali iz množice *vsi signali* pa ne pokažejo izrazite dodane vrednosti. Čeprav slednja vsebuje več informacij, so rezultati večinoma slabši, kar kaže, da dodatni signali v našem primeru modelom prej dodajo šum kot koristno strukturo. Rezultati torej kažejo, da je uporabljena grafovska predstavitev smiselna in informativna, vendar v tej raziskavi najmočnejši ostajajo klasični modeli z ročno oblikovanimi značilkami iz signalov koordinat pogleda in velikosti zenice.

Ugotovitve so omejene na uporabljeno podatkovno zbirko, izbrane množice signalov, binarno klasifikacijo valence in protokol evalvacije, ki ne preverja generalizacije na druge posnetke ali podatkovne zbirke. Ciljni razredi so izpeljani iz samoocen čustvenega stanja, zato vsebujejo določeno mero subjektivnosti in šuma. Omejitev je tudi uporabljena grafovska konstrukcija, saj predstavlja le enega izmed možnih načinov modeliranja odnosov med meritvami sledilnika pogleda.

Poglavje 9

Zaključek

Podatki sledilnika pogleda vsebujejo časovne, prostorske in fiksacijske odnose med meritvami, ki jih klasična tabelarična struktura podatkov ne modelira neposredno. Grafovske nevronske mreže omogočajo eksplicitno modeliranje relacij med meritvami, zato so naraven kandidat za obravnavo takšnih podatkov. V nalogi smo preverili uporabnost grafovske predstavitve podatkov sledilnika pogleda pri binarni klasifikaciji valence. Časovna okna meritev smo predstavili kot časovno-prostorske grafe in jih ovrednotili s štirimi grafovskimi modeli, ki se postopno nadgrajujejo od preproste proti kompleksnejšim različicam. Grafovske modele smo primerjali s še tremi družinami modelov: izhodiščnima modeloma (naključni in večinski klasifikator), klasičnimi modeli strojnega učenja (SVM, LightGBM, MLP) ter prednaučenima kodirnikoma signalov (GazeMAE, MOMENT). Izvedli smo primerjalno evalvacijo vseh modelov na štirih delno prekrivajočih se množicah signalov: *samo pogled*, *samo zenici*, *pogled in zenici* ter *vsi signali*.

Glavni doprinosi naloge izhajajo direktno iz raziskovalnih vprašanj in so:

1. časovno-prostorska grafovska predstavitev časovnih oken podatkov sledilnika pogleda;
2. ovrednotenje arhitekturne lestvice grafovskih modelov za binarno klasifikacijo valence iz podatkov sledilnika pogleda;

3. primerjava klasifikacijske uspešnosti med štirimi množicami signalov sledilnika pogleda;
4. primerjava grafovskih modelov z negrafovskimi osnovnimi modeli in zamrznjenimi prednaučenimi predstavitvenimi modeli.

Rezultati kažejo, da grafovski modeli iz meritev sledilnika pogleda izluščijo uporaben signal in presegajo izhodiščna klasifikatorja, njihova uspešnost pa je primerljiva z uspešnostjo zamrznjenih prednaučenih kodirnikov. Kljub temu so se pri obravnavanju problema najboljše izkazali klasični modeli strojnega učenja z ročno oblikovanimi značilkami. Med preizkušenimi množicami signalov so bile najinformativnejše koordinate pogleda, velikosti zenic so prispevale nekaj dodatnih informacij, drugi razpoložljivi signali pa niso pokazali izrazite dodane vrednosti.

Grafovsko modeliranje podatkov sledilnika pogleda je še v veliki meri neraziskana, vendar smiselna nadaljnja raziskovalna smer. V nadaljnjem delu bomo preverili drugačna pravila povezovanja, na primer povezovanje vozlišč s podobno dinamiko pogleda ali povezovanje meritev iste fiksacije z metavozliščem, s čimer bi graf razširili v tretjo dimenzijo. Grafovsko predstavitev bi bilo mogoče dopolniti tudi z mežiki in sakadami ter preizkusiti dodatne grafovske arhitekture, predvsem grafovske transformerje. Posebej zanimivo je samonadzorovano predtreniranje na signalih sledilnika pogleda, ki bi lahko zmanjšalo odvisnost od majhnih označenih podatkovnih zbirk in omogočilo uporabo neoznačenih podatkov. Rezultate bi bilo treba preveriti še na več podatkovnih zbirkah, pri prenosu med nalogami in v pogojih uporabe v realnem času.

V nalogi smo tako pokazali, da je grafovska predstavitev smiselna za podatke sledilnika pogleda, saj je najboljši GNN pri klasifikaciji binarne valence dosegel točnost 65,9 %.

Dodatek A

Dodatni rezultati

A.1 Preslikava diskretnih samoocen čustvenega stanja v valenco

Preslikava diskretnih samoocen čustvenega stanja v razrede valence sledi tabeli 6 izvirnega članka podatkovne zbirke MAHNOB-HCI [27]. Pri binarni nalogi uporabimo samo skrajna razreda valence, nevtralni razred pa izločimo. Tako model ločuje med negativno in pozitivno valenco, primeri z vmesnim oziroma nevtralnim razredom pa niso del glavne evalvacijske naloge.

Tabela A.1: Preslikava diskretnih samoocen čustvenega stanja v razrede valence po izvirnem članku podatkovne zbirke MAHNOB-HCI.

Razred valence	Uporaba v binarni nalogi	Izvorne diskretne samoocene čustvenega stanja
Negativna valenca	da	<i>fear, anger, disgust, sadness, anxiety</i>
Nevtralna valenca	ne	<i>surprise, neutral</i>
Pozitivna valenca	da	<i>joy, happiness, amusement</i>

A.2 Dodatne metrike in diagnostične meritve

V nadaljevanju so kratko opredeljene mere, uporabljene poleg točnosti in makro F1, ki sta definirani v poglavju 6.4. Za razred c naj bodo TP_c , FP_c in FN_c števila pravih pozitivnih, lažno pozitivnih oziroma lažno negativnih napovedi.

Uravnotežena točnost je povprečje priklicev po razredih, zato vsakemu razredu pripiše enako težo:

$$\text{uravnotežena točnost} = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c}.$$

Preciznost pove, kolikšen delež napovedi razreda c je pravilen, priklic oziroma občutljivost pa, kolikšen delež dejanskih primerov tega razreda model prepozna:

$$\text{preciznost}_c = \frac{TP_c}{TP_c + FP_c}, \quad \text{priklic}_c = \frac{TP_c}{TP_c + FN_c}.$$

V poročanih binarnih rezultatih sta preciznost in priklic makro povprečji po razredih. Uteženi F1 je povprečje F1 po razredih, uteženo s številom dejanskih primerov posameznega razreda.

AUC (angl. *area under the ROC curve*) je ploščina pod krivuljo ROC in meri, kako dobro napovedne verjetnosti razvrstijo pozitivne primere pred negativne neodvisno od izbranega klasifikacijskega praga. Izguba je povprečna negativna logaritemska verjetnost pravih razredov, tj. križna entropija; manjša vrednost pomeni boljše ujemanje napovednih verjetnosti s ciljnim razredi. Matrika zamenjav vsebuje števila primerov za vse pare dejanskih vrstic in napovedanih stolpcev; diagonalne celice so pravilne napovedi, preostale pa napake.

Med učenjem shranjujemo učno in validacijsko izgubo po epohah, najboljšo epoko z najmanjšo validacijsko izgubo, podatek o zgodnjem ustavljanju, čas epohe ter povprečno in največjo L_2 -normo gradientov parametrov. Pri grafovskih modelih dodatno spremljamo povprečno varianco komponent predstavitev grafa, povprečno kosinusno podobnost vseh parov predstavitev,

Tabela A.2: Razširjeni rezultati za množico signalov *samo pogled*. Vrednosti so povprečje $\pm$ standardni odklon čez sedem testnih množic (v odstotkih). Krepko je označen najboljši rezultat v posameznem stolpcu, krepko poševno pa najboljši rezultat med grafovskimi modeli.

Model	Točnost	Preciz- nost	Priklic	Makro F1	AUC
Naključni	$50,2 \pm 1,8$	$50,2 \pm 1,7$	$50,2 \pm 1,7$	$50,1 \pm 1,6$	$50,2 \pm 1,7$
Večinski	$52,5 \pm 4,7$	$26,2 \pm 2,4$	$50,0 \pm 0,0$	$34,4 \pm 1,9$	$50,0 \pm 0,0$
SVM	$67,5 \pm 1,8$	$67,5 \pm 1,7$	$67,4 \pm 1,7$	$67,2 \pm 1,7$	$72,6 \pm 2,5$
LightGBM	$69,7 \pm 2,2$	$69,6 \pm 2,5$	$69,6 \pm 2,1$	$69,4 \pm 2,3$	$76,6 \pm 2,0$
MLP	$67,0 \pm 2,1$	$67,0 \pm 2,0$	$66,9 \pm 2,1$	$66,7 \pm 2,3$	$72,6 \pm 2,7$
GazeMAE/MOMENT	$65,7 \pm 3,2$	$66,5 \pm 3,0$	$65,8 \pm 2,8$	$65,2 \pm 3,5$	$71,9 \pm 4,9$
GCN	$64,4 \pm 4,8$	$64,6 \pm 4,5$	$64,6 \pm 4,7$	$64,1 \pm 5,2$	$70,7 \pm 6,3$
HeteroGCN-mean	$61,7 \pm 6,3$	$60,1 \pm 9,9$	$61,3 \pm 6,9$	$59,2 \pm 11,2$	$64,7 \pm 11,2$
HeteroGCN-MLP	$65,9 \pm 3,9$	$66,1 \pm 3,8$	$66,2 \pm 3,6$	$65,8 \pm 4,0$	$72,2 \pm 4,7$
HeteroGCN-MLP-w	$64,3 \pm 5,0$	$64,8 \pm 4,8$	$64,6 \pm 4,8$	$64,0 \pm 5,2$	$70,3 \pm 5,8$

razpon logitov kot razliko med največjim in najmanjšim logitom ter povprečno entropijo napovednih verjetnosti. Nizka varianca oziroma majhen razpon logitov skupaj z visoko podobnostjo lahko kažeta na skoraj konstantne predstavitve ali napovedi; entropija pove njihovo povprečno gotovost.

A.3 Razširjeni rezultati binarne klasifikacije valence

Tabele v tem razdelku razširjajo glavno primerjavo iz poglavja 7. Vrednosti so povprečje $\pm$ standardni odklon čez sedem testnih množic prečnega preverjanja po subjektih. Micro-F1 je pri tej enooznačni klasifikaciji enak točnosti. Razširjene metrike dodatno potrjujejo sklep iz glavne primerjave, saj ostane podoben tudi pri drugih pogledih na napake modelov.

Tabela A.3: Razširjeni rezultati za množico signalov *samo zenici*. Vrednosti so povprečje $\pm$ standardni odklon čez sedem testnih množic (v odstotkih). Krepko je označen najboljši rezultat v posameznem stolpcu, krepko poševno pa najboljši rezultat med grafovskimi modeli.

Model	Točnost	Preciz- nost	Priklic	Makro F1	AUC
Naključni	$50,7 \pm 2,0$	$50,7 \pm 2,0$	$50,7 \pm 2,0$	$50,6 \pm 1,9$	$50,7 \pm 2,0$
Večinski	$52,2 \pm 4,9$	$26,1 \pm 2,4$	$50,0 \pm 0,0$	$34,2 \pm 2,0$	$50,0 \pm 0,0$
SVM	$62,1 \pm 3,3$	$62,9 \pm 3,0$	$61,7 \pm 2,8$	$60,7 \pm 3,6$	$66,5 \pm 3,4$
LightGBM	$63,1 \pm 3,9$	$63,7 \pm 2,7$	$62,7 \pm 3,2$	$61,9 \pm 4,3$	$68,7 \pm 3,4$
MLP	$62,0 \pm 4,0$	$63,6 \pm 3,9$	$61,5 \pm 2,8$	$60,3 \pm 4,6$	$67,6 \pm 3,6$
GazeMAE/MOMENT	$60,5 \pm 2,5$	$60,8 \pm 2,7$	$60,6 \pm 2,7$	$60,1 \pm 2,4$	$64,9 \pm 3,0$
GCN	<i>$61,0 \pm 3,4$</i>	<i>$65,1 \pm 7,0$</i>	<i>$60,7 \pm 3,0$</i>	<i>$58,4 \pm 4,4$</i>	<i>$67,5 \pm 5,0$</i>
HeteroGCN-mean	$58,6 \pm 4,2$	$61,5 \pm 6,8$	$58,3 \pm 3,9$	$55,7 \pm 6,1$	$64,5 \pm 3,6$
HeteroGCN-MLP	$59,1 \pm 4,1$	$62,7 \pm 6,7$	$58,8 \pm 3,6$	$56,0 \pm 6,1$	$64,9 \pm 5,0$
HeteroGCN-MLP-w	$58,4 \pm 4,1$	$62,4 \pm 6,3$	$58,1 \pm 3,5$	$54,5 \pm 7,5$	$66,4 \pm 4,9$

Tabela A.4: Razširjeni rezultati za množico signalov *pogled in zenici*. Vrednosti so povprečje $\pm$ standardni odklon čez sedem testnih množic (v odstotkih). Krepko je označen najboljši rezultat v posameznem stolpcu, krepko poševno pa najboljši rezultat med grafovskimi modeli.

Model	Točnost	Preciz- nost	Priklic	Makro F1	AUC
Naključni	$50,8 \pm 2,2$	$50,7 \pm 2,1$	$50,7 \pm 2,1$	$50,6 \pm 2,0$	$50,7 \pm 2,1$
Večinski	$52,1 \pm 4,9$	$26,0 \pm 2,4$	$50,0 \pm 0,0$	$34,2 \pm 2,0$	$50,0 \pm 0,0$
SVM	$70,5 \pm 2,9$	$71,9 \pm 2,1$	$70,3 \pm 2,6$	$69,7 \pm 3,4$	$78,1 \pm 1,9$
LightGBM	$69,6 \pm 2,7$	$71,0 \pm 2,0$	$69,5 \pm 2,3$	$68,8 \pm 3,1$	$78,2 \pm 2,2$
MLP	$68,7 \pm 1,9$	$70,6 \pm 1,8$	$68,5 \pm 1,6$	$67,6 \pm 2,5$	$77,8 \pm 2,4$
GazeMAE/MOMENT	$65,6 \pm 4,7$	$66,5 \pm 4,3$	$65,9 \pm 4,0$	$65,2 \pm 4,7$	$73,0 \pm 6,9$
GCN	$65,4 \pm 2,8$	$67,2 \pm 1,4$	$65,1 \pm 1,8$	$63,9 \pm 3,2$	$73,1 \pm 2,2$
HeteroGCN-mean	$63,8 \pm 4,0$	$66,6 \pm 2,0$	$63,3 \pm 4,0$	$61,1 \pm 6,9$	$72,8 \pm 2,7$
HeteroGCN-MLP	$64,2 \pm 3,7$	$65,5 \pm 3,1$	$63,8 \pm 2,8$	$62,8 \pm 3,6$	$72,3 \pm 3,7$
HeteroGCN-MLP-w	$65,5 \pm 2,3$	$66,6 \pm 1,3$	$65,2 \pm 1,5$	$64,4 \pm 2,6$	$73,2 \pm 1,6$

Tabela A.5: Razširjeni rezultati za množico signalov *vs* *signali*. Vrednosti so povprečje $\pm$ standardni odklon čez sedem testnih množic (v odstotkih). Krepko je označen najboljši rezultat v posameznem stolpcu, krepko poševno pa najboljši rezultat med grafovskimi modeli.

Model	Točnost	Preciznost	Priklic	Makro F1	AUC
Naključni	$50,9 \pm 2,0$	$50,8 \pm 1,9$	$50,9 \pm 1,9$	$50,7 \pm 1,8$	$50,9 \pm 1,9$
Večinski	$52,2 \pm 4,8$	$26,1 \pm 2,4$	$50,0 \pm 0,0$	$34,2 \pm 2,0$	$50,0 \pm 0,0$
SVM	$68,6 \pm 3,3$	$69,9 \pm 2,1$	$68,3 \pm 2,3$	$67,6 \pm 3,3$	$76,2 \pm 2,6$
LightGBM	$69,0 \pm 3,0$	$70,4 \pm 2,2$	$69,0 \pm 2,5$	$68,3 \pm 3,2$	$77,6 \pm 2,7$
MLP	$67,2 \pm 3,0$	$68,9 \pm 2,6$	$67,1 \pm 2,2$	$66,2 \pm 2,7$	$75,4 \pm 3,6$
GazeMAE/MOMENT	$66,1 \pm 3,1$	$66,8 \pm 2,6$	$66,3 \pm 3,0$	$65,6 \pm 3,4$	$72,2 \pm 4,2$
GCN	$59,6 \pm 8,4$	$61,5 \pm 8,9$	$59,3 \pm 8,0$	$57,6 \pm 8,5$	$65,7 \pm 12,3$
HeteroGCN-mean	$61,8 \pm 3,9$	$63,8 \pm 3,7$	$61,3 \pm 2,5$	$59,7 \pm 4,0$	$69,6 \pm 3,1$
HeteroGCN-MLP	$60,5 \pm 6,7$	$61,3 \pm 9,3$	$59,9 \pm 6,3$	$56,6 \pm 10,7$	$69,0 \pm 6,2$
HeteroGCN-MLP-w	$62,7 \pm 4,5$	$64,6 \pm 3,0$	$62,3 \pm 3,1$	$60,8 \pm 5,1$	$70,2 \pm 3,4$

Tabela A.6: Primerjava 7-kratnega prečnega preverjanja po subjektih in LOSO za množico signalov *pogled in zenici* za izbrane modele. LOSO nismo poganjali v začetnih fazah za hitro primerjavo, zato nekateri modeli manjkajo. Vrednosti so povprečja v odstotkih. Krepko je označen najboljši rezultat v posameznem stolpcu, krepko poševno pa najboljši rezultat med grafovskimi modeli.

Model	Točnost		Makro F1	
	7-kratno	LOSO	7-kratno	LOSO
Naključni	50,8	48,7	50,6	48,2
Večinski	52,1	51,8	34,2	33,9
LightGBM	69,6	70,1	68,8	68,3
GazeMAE/MOMENT	65,6	68,6	65,2	67,8
GCN	65,4	64,0	63,9	61,0
HeteroGCN-MLP-w	65,5	63,2	64,4	60,1


A.4 Primerjava z LOSO

LOSO v vsaki ponovitvi uporabi enega subjekta kot testno množico, vse ostale subjekte pa za učenje oziroma validacijo. V primerjavi s 7-kratnim protokolom zato uporabi več ponovitev in manjšo testno množico v posamezni ponovitvi. Spodnja tabela primerja oba protokola za množico signalov *pogled in zenici*; LOSO je bil izveden za podmnožico modelov, zato pomišljaj označuje, da vrednost ni bila izračunana.


A.5 Matrike zamenjav

V nadaljevanju so prikazane vrstično normalizirane matrike zamenjav za vse modele in vse množice signalov. Za vsako množico signalov je pripravljen en prikaz z desetimi matrikami zamenjav v vrstnem redu modelov iz glavne tabele rezultatov. Vrstice predstavljajo dejanski razred, stolpci pa napovedani razred. Vrednosti so deleži znotraj dejanskega razreda. Matrike dopolnjujejo agregirane metrike iz prejšnjih tabel, ker pokažejo, ali model napake dela


približno simetrično ali pa sistematično preferira en razred. Večinski model pričakovano napoveduje samo najpogostejši razred, pri naučenih modelih pa je razlika med diagonalnima celicama manj izrazita. Pri množici *samo zenici* so napake bolj uravnotežene z naključnim ugibanjem kot pri množicah s koordinatami pogleda, kar podpira sklep, da same zenice v tej podatkovni zbirki nosijo šibkejši signal za binarno valenco.




Slika A.1: Matrike zamenjav za množico signalov *samo pogled*. Prikaz vključuje naključni in večinski model, klasične modele SVM, LightGBM in MLP, zamrznjene predstavitve GazeMAE/MOMENT ter štiri grafovske modele od osnovnega GCN do HeteroGCN-MLP-w.




Slika A.2: Matrike zamenjav za množico signalov *samo zenici*. Razporeditev modelov je enaka kot pri drugih množicah signalov: izhodiščna modela, trije klasični oziroma nevronske primerjalni modeli, zamrznjene predstavitve in štiri grafske arhitekture.



Slika A.3: Matrike zamenjav za množico signalov *pogled in zenici*. Ta množica doseže najboljši skupni rezultat v glavni primerjavi, zato prikaz omogoča neposredno primerjavo napak med najuspešnejšim SVM in grafovskimi modeli.



Slika A.4: Matrike zamenjav za množico signalov *vs* signali. Prikaz povzema napake modelov pri najbogatejši vhodni predstavitvi, ki poleg pogleda in zenice vključuje še oddaljenost od sledilnika pogleda ter fiksacijske informacije.



Slika A.5: Ujemanje razredov valence in vzburjenosti, izpeljanih iz preslikave v tabeli A.1, z razredi iz številskih samoocen. Vrednosti so deleži znotraj izpeljanega razreda.

A.6 Ujemanje izpeljanih razredov s samoocenami

Slika A.5 primerja razrede, izpeljane iz preslikave v tabeli A.1, z razredi, dobljenimi iz številskih samoocen. Primerjava je uporabna kot groba ocena skladnosti med diskretnimi in številskimi samoocenami čustvenega stanja, ki so bile zbrane v istem eksperimentu. Pri binarni valenci je ujemanje na uporabljenem podnaboru 96,7 %, pri binarni vzburjenosti pa 70,3 %. Zato vzburjenosti ne uporabimo kot glavno ciljno nalogo. Slike kažejo, da izpeljani razredi valence bolje sledijo samoocenam udeležencev kot izpeljani razredi vzburjenosti. To ne pomeni, da so razredi valence brez šuma, vendar je za glavno primerjavo modelov bolj smiselna in stabilna ciljna naloga.

A.7 Izbira tipa grafovske konvolucije

Izbiro operatorja `GCNConv` smo preverili z dodatnim poskusom na binarni nalogi valence pri množici signalov *pogled in zenici*. `GCNConv` je najpreprostejša izbira in ustreza osnovnemu posredovanju sporočil po normalizirani sosednosti. `GATConv` doda pozornost nad sosedi in je uporaben, kadar želimo, da model sam uteži prispevke sosednjih vozlišč. `GraphConv` uporabi ločen prispevek lastnega vozlišča in sosedov; pri osnovnem modelu deluje brez uteži povezav. `GINConv` agregirano predstavitev obdela z večslojnim perceptronom, `GINEConv` pa v agregacijo vključi tudi značilke povezav. Pri modelu `HeteroGCN-MLP-w` plasti `GCNConv` in `GraphConv` uporabljata učljive skalarne uteži povezav. `GATConv` namesto njih značilke povezav vključi v izračun pozornosti, `GINEConv` pa je razširjen kot `WeightedGINEConv`, ki uporabi značilke povezav in učljive skalarne uteži. V naših poskusih so bile razlike majhne. Pri osnovnem GCN je najvišjo vrednost dosegel `GINConv`, pri `HeteroGCN-MLP-w` pa `GraphConv`, vendar razlika ni bila dovolj velika, da bi spreminjala glavno eksperimentalno zgodbo. Zato smo v glavnih poskusih ohranili enoten in enostaven operator `GCNConv`. Ta primerjava ni ločeno iskanje najboljše grafovske arhitekture, temveč preverjanje, da izbira osnovnega operatorja ne določa glavnega sklepa naloge.

A.8 Diagnostika predstavitev

Diagnostika ne kaže jasnega kolapsa predstavitev pri glavnih grafovskih modelih. Množica *samo zenici* ima bolj neodločne napovedi, vendar tega ne obravnavamo kot sistemski kolaps grafovskih modelov. Entropija in razpon logitov opisujeta gotovost napovedi, varianca predstavitev in kosinusna podobnost pa razpršenost naučenih predstavitev grafov. Pri množici *samo zenici* sta razpon logitov in varianca predstavitev manjša, entropija pa večja, kar je skladno z manj odločnimi napovedmi. Pri množicah s koordinatami pogleda so logiti izrazitejši in predstavitve bolj razpršene. Slabši rezultati grafovskih modelov v glavni primerjavi torej niso posledica očitnega kolapsa

Tabela A.7: Primerjava tipov grafovskih konvolucij pri množici signalov *pogled in zenici*. Stolpec arhitektura označuje grafovski model, v katerem je bil zamenjan operator posredovanja sporočil, stolpec operator pa uporabljeno grafovsko konvolucijo. Točnost in makro F1 sta povprečni vrednosti čez sedem testnih množic. Krepko je označen najboljši rezultat za posamezno metriko znotraj vsake arhitekturne skupine, krepko poševno pa drugi najboljši rezultat.

Arhitektura	Operator	Točnost	Makro F1
Osnovni GCN	GCNConv	0,6474	<i>0,6337</i>
Osnovni GCN	GATConv	<i>0,6484</i>	0,6336
Osnovni GCN	GraphConv	0,6367	0,6192
Osnovni GCN	GINConv	0,6613	0,6501
HeteroGCN-MLP-w	GCNConv	<i>0,6391</i>	0,6103
HeteroGCN-MLP-w	GATConv	0,6370	<i>0,6116</i>
HeteroGCN-MLP-w	GraphConv	0,6606	0,6503
HeteroGCN-MLP-w	GINEConv	0,6325	0,6028

Tabela A.8: Diagnostika naučenih predstavitev in izhodov najboljšega grafovskega modela po množicah signalov. Makro F1 in uravnotežena točnost opisujeta uspešnost klasifikacije, razpon logitov in entropija gotovost napovedi, varianca predstavitev razpršenost naučenih vektorjev, kos. pod. pa povprečno kosinusno podobnost med predstavitvami. Krepko sta označena najboljši makro F1 in najboljša uravnotežena točnost.

Množica signalov	Najboljša GNN	Makro F1	Urav. točnost	Razpon logitov	Entro- pija	Varianca predst.	Kos. pod.
<i>vsi signali</i>	HeteroGCN-MLP-w	0,608	0,623	3,31	0,545	0,352	0,409
<i>samo pogled</i>	HeteroGCN-MLP	0,658	0,662	3,93	0,583	0,291	0,307
<i>pogled in zenici</i>	HeteroGCN-MLP-w	0,644	0,652	3,38	0,582	0,336	0,360
<i>samo zenici</i>	GCN	0,584	0,607	1,40	0,653	0,258	0,569

predstavitev v skoraj enake vektorje. Diagnostiko razumemo predvsem kot podporno preverjanje stabilnosti učenja, ne kot dokaz, da je izbrana grafovska arhitektura optimalna.

Dodatek B

Hiperparametri

B.1 Hiperparametri modelov

Tabela B.1 povzema glavne hiperparametre modelov v končnih eksperimentih. Klasični primerjalni modeli uporabljajo agregirane tabelarične značilke, nevronske primerjalne glave uporabljajo bodisi agregirane značilke bodisi zamrznjene predstavitve, grafovski modeli pa uporabljajo grafovsko predstavitev časovnih oken.

B.2 Predhodno mrežno iskanje

Nastavitve grafovske konstrukcije smo izbrali po majhnem predhodnem mrežnem iskanju na 3-razredni valenci, glede na izvirne razrede definirane v tabeli A.1. Iskanje je spreminjalo število grafovskih plasti, velikost skritih predstavitev ter parametre konstrukcije k_t , k_s in k_f . Primerjali smo več nastavitve števila plasti in skrite razsežnosti, vendar med njimi ni bilo velikih razlik. Ker je bil najmanjši model med najboljšimi in najstabilnejšimi, hkrati pa je računsko najvarčnejši, smo za končne poskuse izbrali $L = 2$ (število skritih plasti GNN) in $d = 64$ (razsežnost skritih plasti). Pri tej arhitekturni nastavitvi smo v mrežnem iskanju spreminjali $k_t \in \{1, 2, 3\}$, $k_s \in \{1, 2, 3\}$ in $k_f \in \{1, 2, 3, 5\}$. Najvišji rezultat v tem pomožnem iskanju je dosegla

Tabela B.1: Glavni hiperparametri modelov v končnih eksperimentih.

Model oziroma družina	Podatkovna predstavitev	Glavni hiperparametri
Naključni model	agregirane značilke	enakomerna naključna napoved; seme 42
Večinski model	agregirane značilke	napoved večinskega razreda na učni množici
SVM	agregirane značilke	RBF; $C = 1,0$; <code>probability=true</code> ; standardizacija značilk
LightGBM	agregirane značilke	<code>n_estimators=100</code> ; <code>learning_rate=0.05</code> ; <code>max_depth=5</code> ; seme 42
MLP	agregirane značilke	skrita velikost 64; največ 200 epoh; učna stopnja 10^{-3} ; <code>dropout=0.1</code> ; mini-serija 128; potrpežljivost 15
GazeMAE/MOMENT glave	zamrznjene predstavitve	skrita velikost 128; največ 100 epoh; učna stopnja 10^{-3} ; <code>dropout=0.2</code> ; mini-serija 128; potrpežljivost 15
Grafovski modeli	grafi časovnih oken	GCNConv; 2 plasti; <code>hidden_channels=64</code> ; pozornostno združevanje; <code>dropout=0.1</code> ; učna stopnja $5 \cdot 10^{-5}$; mini-serija 256; največ 350 epoh; potrpežljivost 20
GCN	grafi časovnih oken	homogen graf; brez ločenih relacij in značilk povezav
HeteroGCN-mean	grafi časovnih oken	ločene relacije; združevanje s povprečenjem
HeteroGCN-MLP	grafi časovnih oken	ločene relacije; združevanje z MLP
HeteroGCN-MLP-w	grafi časovnih oken	kot HeteroGCN-MLP, z učljivimi utežmi povezav
Grafovska konstrukcija	grafi časovnih oken	$k_t = 1$; $k_s = 1$; $k_f = 3$; standardizirane značilke povezav

Tabela B.2: Povzetek predhodnega mrežnega iskanja hiperparametrov grafovske konstrukcije. Stolpci k_t , k_s in k_f pomenijo velikost časovne, prostorske oziroma fiksacijske okolice pri konstrukciji grafa. Vrstica preiskani prostor podaja množice preizkušenih vrednosti, vrstica najvišji makro F1 najboljšo najdeno kombinacijo, vrstica končna nastavitvev pa vrednosti, uporabljene v glavnih poskusih.

Nastavitvev	k_t	k_s	k_f	Opomba
Preiskani prostor	$\{1, 2, 3\}$	$\{1, 2, 3\}$	$\{1, 2, 3, 5\}$	36 uspešno izvedenih kombinacij
Najvišji makro F1	3	1	5	makro F1 = 0,510, točnost = 0,522
Končna nastavitvev	1	1	3	redkejši graf in manjša računska zahtevnost

nastavitvev $k_t = 3$, $k_s = 1$ in $k_f = 5$, vendar so bile razlike majhne. V končnih poskusih smo uporabili redkejšo nastavitvev $k_t = 1$, $k_s = 1$ in $k_f = 3$, ker zmanjša gostoto grafa in računsko zahtevnost ter ohrani stabilno delovanje.

B.3 Strojna in programska oprema

Glavni eksperimenti so bili izvedeni na računalniku z operacijskim sistemom Linux Ubuntu, grafično kartico NVIDIA GeForce RTX 4070 z 12 GB grafičnega pomnilnika, procesorjem AMD Ryzen 7 5700X, 32 GB sistemskega pomnilnika in pogonom Samsung SSD 990 PRO NVMe. Poskusi so bili poganjani v okolju Conda `gfm`. Uporabljene so bile različice: Python 3.10.19, PyTorch 2.9.1+cu126, CUDA 12.6, PyG 2.7.0, scikit-learn 1.7.2, LightGBM 4.6.0, NumPy 1.25.2, pandas 2.3.3, Matplotlib 3.10.6 in seaborn 0.13.2.

B.4 Učljive uteži povezav

V modelu **HeteroGCN-MLP-w** značilke povezave uporabimo za izračun skalarne uteži povezave. Naj bo $\mathbf{e}_{ij}^{(r)}$ vektor značilk povezave (v_i, v_j) v relaciji r . Najprej izračunamo surovo oceno:

$$s_{ij}^{(r)} = f_w^{(r)} \left(\mathbf{e}_{ij}^{(r)} \right), \quad (\text{B.1})$$

kjer je $f_w^{(r)}$ večslojni perceptron za ustrezno družino relacij. Za časovne povezave naprej in nazaj uporabimo isti perceptron $f_w^{\text{čas}}$, za prostorske povezave f_w^{prostor} , za fiksacijske povezave pa $f_w^{\text{fiksacija}}$. Vsak od teh perceptronov ima obliko

$$d_e \rightarrow 6 \rightarrow 4 \rightarrow 2 \rightarrow 1, \quad (\text{B.2})$$

kjer je d_e razsežnost vektorja značilk povezave za izbrano relacijo in množico signalov.

Surovo oceno nato omejimo s funkcijo $\tanh$:

$$\tilde{w}_{ij}^{(r)} = \tanh \left(s_{ij}^{(r)} \right). \quad (\text{B.3})$$

Končno utež normaliziramo po vhodnih povezavah ciljne meritve v_j znotraj iste relacije:

$$w_{ij}^{(r)} = \frac{\tilde{w}_{ij}^{(r)}}{\sum_{k:(v_k, v_j) \in E_r} \left| \tilde{w}_{kj}^{(r)} \right| + \epsilon}, \quad (\text{B.4})$$

kjer je $\epsilon = 10^{-8}$ majhna konstanta za numerično stabilnost. Ker normalizacija ohrani predznak uteži, lahko povezava prispevek sosednjega vozlišča tudi zmanjša, ne le poveča.

Dodatek C

Dodatne podrobnosti grafovske konstrukcije

Ta dodatek dopolnjuje opis grafovske konstrukcije iz poglavja 4.

C.1 Razširjene povezave znotraj fiksacije

Fiksacijo obravnavamo kot neprekinjeno zaporedje vozlišč z istim veljavnim identifikatorjem fiksacije. Če ima taka fiksacija F vozlišč, jim priredimo lokalne indekse $0, \dots, F-1$. Parameter k_f določa število fiksacijskih povezav, ki jih generira vsako vozlišče. Za posamezno fiksacijo najprej izračunamo korak razširitve

$$s = \max(1, \lfloor F/k_f + 0,5 \rfloor). \quad (\text{C.1})$$

Množico kandidatnih odmkov določimo kot

$$D = \{(1 + qs) \bmod F \mid q = 0, \dots, k_f - 1\}. \quad (\text{C.2})$$

Morebitni odmik 0 in podvojene odmičke odstranimo. Za vsak odmik $d \in D$ dodamo neusmerjene povezave

$$\{v_i, v_{(i+d) \bmod F}\}, \quad i = 0, \dots, F-1. \quad (\text{C.3})$$

Pri zapisu grafa za posredovanje sporočil vsako neusmerjeno povezavo predstavimo z dvema usmerjenima povezavama in odstranimo podvojene povezave znotraj relacije E_f .

Pri fiksaciji dolžine $F = 21$ in parametru $k_f = 3$ dobimo $s = 7$. Vozlišče z lokalnim indeksom 0 se zato poveže z vozlišči 1, 8 in 15. Odmik 1 ohrani časovno lokalno komunikacijo, večji odmiki pa omogočijo širjenje informacij tudi med časovno bolj oddaljenimi meritvami iste fiksacije. Ker vsaka plast GNN omogoča izmenjavo informacij med neposredno povezanimi vozlišči, se doseg znotraj fiksacije dodatno povečuje s številom plasti.

C.2 Značilke povezav

Tabela C.1 podrobno opisuje simbole značilk povezav, uporabljene v tabeli 4.1.

C.3 Ločeni prikazi tipov povezav

Slike prikazujejo isti izsek časovnega okna, vendar ločeno za posamezne tipe povezav. Namenjene so predvsem lažjemu branju slike 4.2: časovne povezave pokažejo lokalni red meritev, prostorske povezave sosednost položajev pogleda na zaslonu, fiksacijske povezave pa povezovanje meritev znotraj iste zaznane fiksacije.


Tabela C.1: Značilke povezav v grafovski predstavitvi. Izraz *vse relacije* pomeni vse relacije, ki so prisotne pri navedeni množici signalov.

Značilka	Opis	Relacije	Množice signalov
t_i	Normaliziran čas izvirne meritve znotraj časovnega okna.	Vse relacije.	Vse štiri množice.
t_j	Normaliziran čas ciljne meritve znotraj časovnega okna.	Vse relacije.	Vse štiri množice.
Δt	Časovna razlika med ciljno in izvirno meritvijo, $\Delta t = t_j - t_i$.	Vse relacije.	Vse štiri množice.
ρ_{ij}	Smer časovne povezave; pri povezavi naprej je $\rho_{ij} = 1$, pri povezavi nazaj pa $\rho_{ij} = -1$.	Samo časovne.	Vse štiri množice.
Δx	Razlika v vodoravni koordinati pogleda, $\Delta x = x_j - x_i$.	Vse relacije.	<i>samo pogled, pogled in zenici, vsi signali.</i>
Δy	Razlika v navpični koordinati pogleda, $\Delta y = y_j - y_i$.	Vse relacije.	<i>samo pogled, pogled in zenici, vsi signali.</i>
d_{ij}^{zaslon}	Evklidska razdalja med položajema pogleda na zaslonu.	Vse relacije.	<i>samo pogled, pogled in zenici, vsi signali.</i>
$\Delta p_{ij}^{(l)}$	Razlika v velikosti leve zenice, $\Delta p_{ij}^{(l)} = p_j^{(l)} - p_i^{(l)}$.	Vse relacije.	<i>samo zenici, pogled in zenici, vsi signali.</i>
$\Delta p_{ij}^{(r)}$	Razlika v velikosti desne zenice, $\Delta p_{ij}^{(r)} = p_j^{(r)} - p_i^{(r)}$.	Vse relacije.	<i>samo zenici, pogled in zenici, vsi signali.</i>
Δd_{ij}	Razlika v oddaljenosti od sledilnika pogleda, $\Delta d_{ij} = d_j - d_i$.	Vse relacije.	<i>vsii signali.</i>


Opomba: Barve označujejo čas, pogled in prostorske značilke, zenici ter fiksacije in dodatne signale.



Slika C.1: Časovne povezave v izseku grafa. Oranžne povezave vodijo naprej po zaporedju meritev, rožnate pa nazaj, zato prikaz poudari lokalno časovno okolico vsakega vozlišča.



Slika C.2: Prostorske povezave v izseku grafa. Povezujejo meritve s podobnim položajem pogleda na zaslonu, zato lahko povežejo tudi časovno bolj oddaljena vozlišča.



Slika C.3: Fiksacijske povezave v izseku grafa. Povezujejo meritve iz iste zaznane fiksacije, vendar z omejenim številom odmikov, da graf ne postane preveč gost.

Literatura

- [1] Jimmy Lei Ba, Jamie Ryan Kiros in Geoffrey E. Hinton. „Layer Normalization“. V: *arXiv preprint arXiv:1607.06450* (2016). URL: <https://arxiv.org/abs/1607.06450>.
- [2] Louise Gillian C. Bautista in Prospero C. Naval. „GazeMAE: General Representations of Eye Movements Using a Micro-Macro Autoencoder“. V: *2020 25th International Conference on Pattern Recognition (ICPR)*. IEEE, 2021, str. 7004–7011. DOI: 10.1109/ICPR48806.2021.9412761.
- [3] Marie E. Bellet in sod. „Human-Level Saccade Detection Performance Using Deep Neural Networks“. V: *Journal of Neurophysiology* 121.2 (2019), str. 646–661. DOI: 10.1152/jn.00601.2018.
- [4] Tomi Božak. *GFM-for-eyetracker: Graph Foundation Model Research Codebase for Eye-Tracking Signals*. GitHub repository, commit 2a5cacc. 2026. URL: <https://github.com/Space0code/GFM-for-eyetracker> (pridobljeno 8. 7. 2026).
- [5] Tomi Božak, Mitja Luštrek in Gašper Slapničar. „Feature-Based Emotion Classification Using Eye-Tracking Data“. V: *Information Society 2024*. Ljubljana, Slovenia, 2024. DOI: 10.70314/is.2024.scai.9988.
- [6] Corinna Cortes in Vladimir Vapnik. „Support-Vector Networks“. V: *Machine Learning* 20.3 (1995), str. 273–297. DOI: 10.1007/BF00994018.
- [7] Matthias Fey in Jan Eric Lenssen. „Fast Graph Representation Learning with PyTorch Geometric“. V: *ICLR Workshop on Representation*

- Learning on Graphs and Manifolds*. 2019. arXiv: 1903.02428 [cs.LG]. URL: <https://arxiv.org/abs/1903.02428>.
- [8] Justin Gilmer in sod. „Neural Message Passing for Quantum Chemistry“. V: *Proceedings of the 34th International Conference on Machine Learning*. Zv. 70. Proceedings of Machine Learning Research. PMLR, 2017, str. 1263–1272.
- [9] Ian Goodfellow, Yoshua Bengio in Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [10] Mononito Goswami in sod. „MOMENT: A Family of Open Time-Series Foundation Models“. V: *Proceedings of the 41st International Conference on Machine Learning*. Zv. 235. Proceedings of Machine Learning Research. PMLR, 2024, str. 16115–16152. URL: <https://proceedings.mlr.press/v235/goswami24a.html>.
- [11] Henry Griffith in sod. „GazeBase, a Large-Scale, Multi-Stimulus, Longitudinal Eye Movement Dataset“. V: *Scientific Data* 8.1 (2021), str. 184. DOI: 10.1038/s41597-021-00959-y.
- [12] Kaiming He in sod. „Deep Residual Learning for Image Recognition“. V: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016, str. 770–778. DOI: 10.1109/CVPR.2016.90.
- [13] Dan Hendrycks in Kevin Gimpel. „Gaussian Error Linear Units (GELUs)“. V: *arXiv preprint arXiv:1606.08415* (2016). URL: <https://arxiv.org/abs/1606.08415>.
- [14] Weihua Hu in sod. „Strategies for Pre-Training Graph Neural Networks“. V: *International Conference on Learning Representations*. 2020. URL: <https://openreview.net/forum?id=HJlWWJSFDH>.
- [15] Ming Jin in sod. „A Survey on Graph Neural Networks for Time Series: Forecasting, Classification, Imputation, and Anomaly Detection“. V: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 46.12 (2024), str. 10466–10485. DOI: 10.1109/TPAMI.2024.3443141.

- [16] Guolin Ke in sod. „LightGBM: A Highly Efficient Gradient Boosting Decision Tree“. V: *Advances in Neural Information Processing Systems*. Zv. 30. Curran Associates, Inc., 2017, str. 3149–3157. URL: <https://papers.nips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree>.
- [17] Thomas N. Kipf in Max Welling. „Semi-Supervised Classification with Graph Convolutional Networks“. V: *International Conference on Learning Representations*. 2017. URL: <https://openreview.net/forum?id=SJU4ayYgl>.
- [18] Emmanouil Ktistakis in sod. „COLET: A Dataset for COgnitive workLoad Estimation Based on Eye-Tracking“. V: *Computer Methods and Programs in Biomedicine* 224 (2022), str. 106989. DOI: 10.1016/j.cmpb.2022.106989.
- [19] Jia Zheng Lim, James Mountstephens in Jason Teo. „Emotion Recognition Using Eye-Tracking: Taxonomy, Review and Current Challenges“. V: *Sensors* 20.8 (2020), str. 2384. DOI: 10.3390/s20082384.
- [20] Chenyu Liu in sod. „Graph Neural Networks in EEG-Based Emotion Recognition: A Survey“. V: *arXiv preprint arXiv:2402.01138* (2024). arXiv: 2402.01138 [cs.LG].
- [21] Yifei Lu in sod. „Combining Eye Movements and EEG to Enhance Emotion Recognition“. V: *Proceedings of the Twenty-Fourth International Joint Conference on Artificial Intelligence*. IJCAI. 2015, str. 1170–1176.
- [22] *MAHNOB Databases*. MAHNOB. URL: <https://mahnob-db.eu/> (pridobljeno 22. 8. 2024).
- [23] Christopher Morris in sod. „Weisfeiler and Leman Go Neural: Higher-Order Graph Neural Networks“. V: *Proceedings of the AAAI Conference on Artificial Intelligence*. Zv. 33. 1. 2019, str. 4602–4609. DOI: 10.1609/aaai.v33i01.33014602.
- [24] OpenAI. *ChatGPT*. Uporabljeno podporno orodje; model GPT-5.5 Thinking. 2026. URL: <https://chatgpt.com/> (pridobljeno 8. 7. 2026).

- [25] Marco Pedrotti in sod. „Automatic Stress Classification With Pupil Diameter Analysis“. V: *International Journal of Human-Computer Interaction* 30.3 (2014), str. 220–236. DOI: 10.1080/10447318.2013.848320.
- [26] Vasileios Skaramagkas in sod. „eSEE-d: Emotional State Estimation Based on Eye-Tracking Dataset“. V: *Brain Sciences* 13.4 (2023), str. 589. DOI: 10.3390/brainsci13040589.
- [27] Mohammad Soleymani in sod. „A Multimodal Database for Affect Recognition and Implicit Tagging“. V: *IEEE Transactions on Affective Computing* 3.1 (2012), str. 42–55. DOI: 10.1109/T-AFFC.2011.25.
- [28] Tengfei Song in sod. „EEG Emotion Recognition Using Dynamical Graph Convolutional Neural Networks“. V: *IEEE Transactions on Affective Computing* 11.3 (2020), str. 532–541. DOI: 10.1109/TAFFC.2018.2817622.
- [29] Nitish Srivastava in sod. „Dropout: A Simple Way to Prevent Neural Networks from Overfitting“. V: *Journal of Machine Learning Research* 15.56 (2014), str. 1929–1958. URL: <http://jmlr.org/papers/v15/srivastava14a.html>.
- [30] Paweł Tarnowski in sod. „Eye-Tracking Analysis for Emotion Recognition“. V: *Computational Intelligence and Neuroscience* 2020 (2020), str. 2909267. DOI: 10.1155/2020/2909267.
- [31] Petar Veličković in sod. „Graph Attention Networks“. V: *International Conference on Learning Representations*. 2018. URL: <https://openreview.net/forum?id=rJXMpikCZ>.
- [32] Yang Wang, Zhao Lv in Yongjun Zheng. „Automatic Emotion Perception Using Eye Movement Information for E-Healthcare Systems“. V: *Sensors* 18.9 (2018), str. 2826. DOI: 10.3390/s18092826.
- [33] Qun Wu in sod. „Emotion Classification on Eye-Tracking and Electroencephalograph Fused Signals Employing Deep Gradient Neural Networks“. V: *Applied Soft Computing* 110 (2021), str. 107752. DOI: 10.1016/j.asoc.2021.107752.

-
- [34] Keyulu Xu in sod. „How Powerful Are Graph Neural Networks?“ V: *International Conference on Learning Representations*. 2019. URL: <https://openreview.net/forum?id=ryGs6iA5Km>.
- [35] Bing Yu, Haoteng Yin in Zhanxing Zhu. „Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting“. V: *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence*. International Joint Conferences on Artificial Intelligence Organization, 2018, str. 3634–3640. DOI: 10.24963/ijcai.2018/505.
- [36] Tianyi Zhang in sod. „RCEA: Real-Time, Continuous Emotion Annotation for Collecting Precise Mobile Video Ground Truth Labels“. V: *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, 2020, str. 1–15. DOI: 10.1145/3313831.3376808.
- [37] Peixiang Zhong, Di Wang in Chunyan Miao. „EEG-Based Emotion Recognition Using Regularized Graph Neural Networks“. V: *IEEE Transactions on Affective Computing* 13.3 (2022), str. 1290–1301. DOI: 10.1109/TAFFC.2020.2994159.