

UNIVERZA V LJUBLJANI
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO

Tomi Božak

**Grafovska nevronska mreža za
prepoznavo čustev iz podatkov sledilnika
pogleda**

DIPLOMSKO DELO

UNIVERZITETNI ŠTUDIJSKI PROGRAM
PRVE STOPNJE
RAČUNALNIŠTVO IN INFORMATIKA

MENTOR: izr. prof. dr. Lovro Šubelj
SOMENTOR: doc. dr. Gašper Slapničar

Ljubljana, 2026

To delo je ponujeno pod licenco *Creative Commons Priznanje avtorstva-Deljenje pod enakimi pogoji 2.5 Slovenija* (ali novejšo različico). To pomeni, da se tako besedilo, slike, grafi in druge sestavine dela kot tudi rezultati diplomskega dela lahko prosto distribuirajo, reproducirajo, uporabljajo, priobčujejo javnosti in predelujejo, pod pogojem, da se jasno in vidno navede avtorja in naslov tega dela in da se v primeru spremembe, preoblikovanja ali uporabe tega dela v svojem delu, lahko distribuira predelava le pod licenco, ki je enaka tej. Podrobnosti licence so dostopne na spletni strani creativecommons.si ali na Inštitutu za intelektualno lastnino, Streliška 1, 1000 Ljubljana.



Izvorna koda diplomskega dela, njeni rezultati in v ta namen razvita programska oprema je ponujena pod licenco GNU General Public License, različica 3 (ali novejša). To pomeni, da se lahko prosto distribuira in/ali predeluje pod njenimi pogoji. Podrobnosti licence so dostopne na spletni strani <http://www.gnu.org/licenses/>.

Besedilo je oblikovano z urejevalnikom besedil L^AT_EX.

Kandidat: Tomi Božak

Naslov: Grafovska nevronska mreža za prepoznavo čustev iz podatkov sledilnika pogleda

Vrsta naloge: Diplomaska naloga na univerzitetnem programu prve stopnje

Mentor: izr. prof. dr. Lovro Šubelj

Somentor: doc. dr. Gašper Slapničar

Opis:

TODO: Besedilo teme diplomskega dela prepisi iz študijskega informacijskega sistema.

Title: Graph Neural Network for Emotion Recognition from Eye-Tracking Data

Description:

TODO: Prevedi uradni opis teme diplomskega dela iz STUDIS-a.

TODO: Zahvaliti se IJS, da so omogočili uporabo njihove infrastrukture. Zahvaliti se mentorju Lovru za nasvete pri razvoju GNN in somentorju za nasvete pri raziskovalnem delu. Zahvaliti se tudi Mitji Luštreku za nasvete pri raziskovalnem delu. (tudi FRIju in družini al je too much?)

TODO: Posvetilo lahko odstraniš, če ga ne
želiš.

Kazalo

Povzetek

Abstract

Razširjeni povzetek	1
1 Uvod	3
1.1 Motivacija	4
1.1.1 Verzija 1: poudarek na GNN	4
1.1.2 Verzija 2: aplikacijsko usmerjeno	5
1.2 Raziskovalni problem	5
1.3 Raziskovalna vprašanja	5
1.4 Doprinosi naloge	6
1.5 Struktura naloge	7
2 Teoretično ozadje	9
2.1 Grafi	9
2.1.1 Osnovna definicija grafa	9
2.1.2 Usmerjeni, uteženi in heterogeni grafi	10
2.2 Grafske nevronske mreže	10
2.2.1 Posredovanje sporočil	10
2.2.2 Klasifikacija na ravni grafa	11
2.2.3 Prekomerno glajenje in kolaps predstavitev	11
2.3 Podatki sledilnika pogleda	12

2.3.1	Merjeni signali	12
2.3.2	Časovna narava signala	12
2.4	Čustvena stanja: valenca in vzburjenost	13
2.4.1	Dimenzijski opis čustev	13
2.4.2	3-razredna klasifikacija	13
3	Sorodna dela	15
3.1	Prepoznavanje čustev iz podatkov sledilnika pogleda	15
3.1.1	Ročno oblikovane značilke	15
3.1.2	Naučene predstavitve	16
3.2	Podatkovna zbirka MAHNOB-HCI	16
3.2.1	Izvirni protokol za valenco in vzburjenost	16
3.2.2	Razlika do eksperimentalne postavitve v tej nalogi . . .	16
3.3	Grafovske nevronske mreže za časovno-prostorske podatke . .	17
3.3.1	Uporaba na oknih podatkov pogleda	17
3.4	Učenje predstavitev iz podatkov pogleda in GazeMAE	17
3.4.1	GazeMAE	18
3.5	Položaj te naloge glede na sorodna dela	18
4	Podatki in predobdelava	19
4.1	Podatkovna zbirka MAHNOB-HCI	19
4.1.1	Izvirna zbirka	19
4.1.2	Lokalni podnabor	20
4.2	Ciljne oznake	20
4.2.1	Izvor čustvenih oznak	20
4.2.2	Preslikava v razrede valence in vzburjenosti	20
4.3	Priprava vhodnih signalov	22
4.3.1	Uporabljeni stolpci	22
4.3.2	Čiščenje in filtriranje podatkov	22
4.4	Normalizacija	23
4.4.1	Normalizacija pri grafovskih modelih	23
4.4.2	Normalizacija pri tabelarnih modelih	23

4.4.3	Preprečevanje uhajanja informacij	23
4.5	Segmentacija v časovna okna	24
4.5.1	Dolžina okna	24
4.5.2	Dodelitev oznake oknu	24
4.5.3	Minimalno število vzorcev	24
4.6	Predhodni poskus z zbirko eSEEd_v2	24
5	Grafovski predstavitev podatkov sledilnika pogleda	27
5.1	Učni vzorec kot graf	27
5.1.1	Definicija grafa	27
5.1.2	Oznaka grafa	28
5.2	Vozlišča	28
5.2.1	Definicija vozlišča	28
5.2.2	Značilke vozlišč	28
5.3	Heterogena grafovski predstavitev	29
5.3.1	Tipi relacij	29
5.3.2	Zakaj ločimo relacije	30
5.4	Povezave	30
5.4.1	Časovne povezave	30
5.4.2	Prostorske povezave	31
5.4.3	Fiksacijske povezave	32
5.5	Uteži povezav	34
5.5.1	Značilke povezav	34
5.5.2	Normalizacija uteži	35
5.6	Statistika grafov	37
5.6.1	Število vozlišč in povezav	37
5.6.2	Računska zahtevnost	37
6	Primerjani modeli in predlagana arhitektura	39
6.1	Negrafovski osnovni modeli	40
6.1.1	MLP	40
6.2	Negrafovski predstavnik SOTA: GazeMAE + MLP	41

6.3	Grafovski osnovni model	41
6.4	Predlagani prostorsko-časovni heterogeni GNN	43
6.4.1	Pregled arhitekture	44
6.4.2	Relacijsko posredovanje sporočil in uteži povezav	44
6.4.3	Fuzija relacijskih predstavitev	45
6.4.4	Predstavitev grafa in napoved	45
6.4.5	Stabilizacija učenja	46
7	Eksperimentalni protokol	47
7.1	Eksperimentalne naloge	47
7.1.1	Valenca in vzburjenost	47
7.2	Validacijska protokola	48
7.2.1	Prečno preverjanje z izpuščanjem enega primerka	48
7.2.2	Subject LOO	50
7.2.3	Recording LOO	51
7.3	Metrike	51
7.4	Spremljanje učenja in diagnostika	52
7.5	Glavna primerjava modelov	52
7.6	Ablacijska študija	54
8	Rezultati	59
8.1	Porazdelitev razredov	61
8.1.1	3-razredna valenca	61
8.1.2	3-razredna vzburjenost	61
8.1.3	Binarni nalogi	62
8.2	Rezultati za 3-razredno valenco	62
8.2.1	Subject LOO	62
8.2.2	Recording LOO	64
8.2.3	Interpretacija rezultatov	65
8.3	Rezultati za 3-razredno vzburjenost	65
8.3.1	Subject LOO	65
8.3.2	Recording LOO	66

8.4	Binarna klasifikacija valence in vzburjenosti	67
8.4.1	Binarna valenca	67
8.4.2	Binarna vzburjenost	68
8.5	Primerjava validacijskih protokolov	69
8.5.1	Posploševanje na nove subjekte	69
8.5.2	Posploševanje na nove posnetke	70
8.6	Analiza oznak in napak	70
8.6.1	Ujemanje oznak s samoocenami	70
8.6.2	Matrike zmede	71
8.7	Ablacijska študija	71
8.7.1	Vpliv vhodnih signalov in povezav	71
8.8	Analiza učenja in notranjih predstavitev	72
8.8.1	Krivulje izgub	72
8.8.2	Predstavitve in grafovske diagnostike	73
9	Diskusija	75
9.1	Ali grafovska predstavitve pomaga?	75
9.2	Vloga časovnih in prostorskih povezav	76
9.3	Primerjava z GazeMAE	77
9.4	Stabilnost učenja in notranje predstavitve	77
9.5	Primerjava z izvirnim MAHNOB-HCI pristopom	78
9.6	Omejitve	78
9.7	Možnosti nadaljnjega dela	79
10	Zaključek	81
A	Dodatni rezultati	83
B	Hiperparametri	85
C	Dodatne vizualizacije grafov	87
D	Diagnostika predstavitev modela	89

E	Zgodovinski poskusi na eSEEd_v2	91
	Literatura	93

Seznam uporabljenih kratic

kratica	angleško	slovensko
AUC	area under the curve	ploščina pod krivuljo
F1	F1 score	mera F1
GAT	graph attention network	grafovska pozornostna mreža
GCN	graph convolutional network	grafovska konvolucijska mreža
GFM	graph foundation model	grafovski temeljni model
GNN	graph neural network	grafovska nevronska mreža
LOO	leave-one-out	izpusti enega
LORO	leave-one-recording-out	izpusti en posnetek
LOSO	leave-one-subject-out	izpusti en subjekt
MLP	multilayer perceptron	večslojni perceptron
SVM	support vector machine	metoda podpornih vektorjev

Povzetek

Naslov: Grafovska nevronska mreža za prepoznavo čustev iz podatkov sledilnika pogleda

Avtor: Tomi Božak

V diplomski nalogi raziskujemo uporabo grafovskih nevronskih mrež za prepoznavo afektivnih stanj iz podatkov sledilnika pogleda. Osrednji metodološki problem je predstavitev časovnega okna meritev pogleda kot prostorsko-časovnega grafa, v katerem vozlišča predstavljajo posamezne meritve, povezave pa opisujejo časovno bližino, prostorsko bližino in pripadnost isti fiksaciji. Na takšni predstavitvi razvijemo in ovrednotimo grafovski model za večrazredno klasifikacijo valence in vzburjenosti (ang. arousal).

Eksperimentalno evalvacijo izvedemo na podatkovni zbirki MAHNOB-HCI z dvema validacijskima protokoloma: delitvijo po subjektih in delitvijo po posnetkih. Grafovske modele primerjamo z ne-grafovskimi modeli strojnega učenja ter s predstavitvijo GazeMAE kot predstavnikom sodobnih metod učenja predstavitev iz podatkov pogleda. Poleg končnih klasifikacijskih rezultatov analiziramo tudi vpliv posameznih komponent grafovske konstrukcije, vključno s časovnimi povezavami, prostorskimi povezavami, fiksacijskimi povezavami, značilkami zenice in utežmi povezav.

Glavno raziskovalno vprašanje naloge je, ali lahko prostorsko-časovna grafovska predstavitev eye-tracking oken izboljša klasifikacijo afektivnih stanj v primerjavi z ne-grafovskimi modeli na enakih vhodnih oknih.

Ključne besede: grafovske nevronske mreže, prostorsko-časovni grafi, sledil-

nik pogleda, prepoznavanje čustev, afektivno računalništvo, strojno učenje.

Abstract

Title: Graph Neural Network for Emotion Recognition from Eye-Tracking Data

Author: Tomi Božak

This thesis investigates the use of graph neural networks for affective state recognition from eye-tracking data. The central methodological problem is the representation of a temporal window of gaze measurements as a spatio-temporal graph, where nodes correspond to individual samples and edges encode temporal proximity, spatial proximity, and shared fixation membership. Based on this representation, we develop and evaluate a graph-based model for three-class classification of valence and arousal.

The experimental evaluation is performed on the MAHNOB-HCI dataset using two validation protocols: leave-one-subject-out and leave-one-recording-out evaluation. Graph-based models are compared against non-graph machine learning baselines and against GazeMAE as a representative of modern gaze representation learning methods. In addition to final classification performance, we analyze the contribution of individual components of the graph construction, including temporal edges, spatial edges, fixation edges, pupil features, and edge weights.

The main research question of the thesis is whether a spatio-temporal graph representation of eye-tracking windows can improve affective state classification compared to non-graph models trained on the same input windows.

Keywords: graph neural networks, spatio-temporal graphs, eye tracking, emotion recognition, affective computing, machine learning.

Razširjeni povzetek

TODO: To poglavje napiši na koncu, ko bodo znani rezultati. Struktura naj bo podobna raziskovalnemu članku:

- motivacija: zakaj grafovska predstavitev podatkov sledilnika pogleda;
- predlagana metoda: kako iz časovnih oken nastanejo grafi;
- eksperimentalni protokol: MAHNOB-HCI, 3-razredna valenca/vzburjenost, subject LOO in recording LOO;
- rezultati: primerjava z baseline modeli, GazeMAE in GNN arhitekturami;
- sklep: kaj grafovska predstavitev prispeva in kje so omejitve.

I Grafovske nevronske mreže in motivacija

TODO: Kratko povzemi, kaj so grafovske nevronske mreže, zakaj so primerne za podatke z relacijsko, prostorsko ali časovno strukturo in zakaj je eye-tracking okno smiselno obravnavati kot prostorsko-časovni graf.

II Grafovska predstavitev podatkov sledilnika pogleda

TODO:

- vozlišče = ena meritev sledilnika pogleda;
- značilke vozlišča = `x-avg`, `y-avg`, `leva/desna zenica`, `time-window-normalized`, `distance-avg`, `fixation-duration`;
- časovne povezave = bližina vzorcev v času, $k_t = 2$;
- prostorske povezave = bližina vzorcev v prostoru pogleda, $k_s = 2$;
- fiksacijske povezave = razširjene povezave znotraj fiksacije, $k_f = 3$;
- uteži povezav = naučene predznačene uteži iz značilk relacije;
- `fixation-index` = grupiranje, ne numerična značilka vozlišča.

III Modeliranje in eksperimentalna evalvacija

TODO: Kratko povzemi uporabljeno podatkovno zbirko MAHNOB-HCI, nalogi 3-razredne valence in 3-razredne vzburjenosti, validacijo subject LOO in recording LOO ter primerjane modele: SVM, LightGBM, MLP, GazeMAE + MLP, GCN, GAT in finalni heterogeni GNN.

IV Rezultati in sklep

TODO: Dopolni po zaključku eksperimentov: kateri model je najboljši pri valenci, kateri pri vzburjenosti, ali GNN izboljša rezultate glede na ne-grafovske baseline modele, katere komponente grafa najbolj prispevajo k rezultatu ter glavne omejitve in prihodnje delo.

Poglavje 1

Uvod

Prepoznavanje čustev oziroma afektivnih stanj iz fizioloških in vedenjskih signalov je pomemben problem na področju afektivnega računalništva. Med možnimi viri podatkov je tudi sledilnik pogleda, ki omogoča merjenje položaja pogleda, dinamike premikanja oči in velikosti zenic. Ti signali so časovno odvisni in lahko vsebujejo informacije o pozornosti, kognitivni obremenitvi in čustvenem stanju udeleženca.

V tej diplomski nalogi se osredotočamo na grafovsko modeliranje podatkov sledilnika pogleda. Namesto da časovno okno meritev obravnavamo zgolj kot tabelaričen niz ali vektor agregiranih značilk, ga predstavimo kot prostorsko-časovni graf. V takem grafu posamezne meritve predstavljajo vozlišča, povezave pa opisujejo odnose med meritvami. Časovne povezave povezujejo meritve, ki so si blizu v času, prostorske povezave meritve, ki so si blizu v prostoru pogleda, fiksacijske povezave pa meritve znotraj iste zaznane fiksacije.

Osrednje raziskovalno vprašanje naloge je:

Ali lahko prostorsko-časovna grafovska predstavitev podatkov sledilnika pogleda izboljša klasifikacijo čustvenih stanj v primerjavi z ne-grafovskimi modeli na enakih vhodnih podatkih?

Nalogo obravnavamo kot problem nadzorovane klasifikacije grafov. Vsako časovno okno podatkov sledilnika pogleda pretvorimo v graf, model pa napove

čustveno oznako pripadajočega okna. Glavni ciljni nalogi sta 3-razredna klasifikacija valence in 3-razredna klasifikacija vzburjenosti na podatkovni zbirki MAHNOB-HCI.

1.1 Motivacija

TODO:

- izberi eno končno verzijo motivacije;
- spodaj ohranjeni dve delovni verziji iz Overleafa;
- končna motivacija naj poudari grafovsko predstavitev kot metodološki prispevek;
- omeniti časovne, prostorske in fiksacijske odnose;
- ne obljubljeni splošnega foundation modela kot glavni rezultat diplome.

1.1.1 Verzija 1: poudarek na GNN

Podatki sledilnika pogleda so časovna vrsta prostorskih meritev: vsak vzorec vsebuje položaj pogleda, velikost zenice in časovni žig. Pri prepoznavi čustvenih stanj se takšni podatki pogosto pretvorijo v tabelarične značilke na ravni časovnega okna, na primer v povprečja, standardne odklone, statistike fiksacij, dolžine poti pogleda in agregirane značilke zenice [10, 13]. Takšen pristop poenostavi modeliranje, vendar hkrati zabriše zaporedje meritev, lokalne prehode pogleda in prostorske odnose med točkami pogleda.

Osrednja motivacija te naloge je zato metodološka: preveriti želimo, ali je mogoče časovno okno podatkov sledilnika pogleda predstaviti kot časovno-prostorski graf in ga obdelati z grafovsko nevronske mrežo. V predlagani predstavitvi posamezne meritve ostanejo eksplicitno prisotne kot vozlišča, povezave pa kodirajo časovno zaporedje in prostorsko bližino med meritvami.

Takšna predstavitev omogoča, da model sklepa neposredno iz strukture gibanja pogleda in sprememb velikosti zenice, namesto da bi uporabljal le vnaprej agregirane statistike.

1.1.2 Verzija 2: aplikacijsko usmerjeno

Prepoznavanje čustvenih stanj iz človekovih fizioloških in vedenjskih odzivov je pomemben problem afektivnega računalništva, saj omogoča razvoj sistemov, ki se lahko prilagajajo uporabnikovemu stanju [11, 10]. Pri tem se pogosto uporabljajo kontaktni fiziološki podatki, kot so elektroencefalografija, elektrokardiografija, variabilnost srčnega utripa in elektrodermalna aktivnost, vendar njihova uporaba zahteva namensko namestitev senzorjev in je zato manj primerna za nevsiljive interakcijske sisteme [11]. Sledilnik pogleda predstavlja manj obremenjujoč vir podatkov, saj meri gibanje pogleda in velikost zenice, ki sta povezana s pozornostjo, kognitivno obremenitvijo in čustvenimi odzivi [10, 13]. V tej nalogi zato obravnavamo podatke sledilnika pogleda kot časovno-prostorske grafe, kjer posamezne meritve predstavljajo vozlišča, povezave pa opisujejo časovne prehode in prostorsko bližino pogleda.

1.2 Raziskovalni problem

Raziskovalni problem naloge je zasnova, implementacija in ovrednotenje grafovskih predstavitev podatkov sledilnika pogleda za klasifikacijo čustvenih stanj. Pri tem nas zanimata dva vidika. Prvi je predstavitevni: kako iz zaporedja meritev zgraditi graf, ki smiselno odraža časovne in prostorske odnose v signalu. Drugi je modelni: ali lahko grafovska nevronska mreža takšno predstavitev izkoristi bolje kot ne-grafovski modeli, ki uporabljajo enaka vhodna okna.

1.3 Raziskovalna vprašanja

Glavno raziskovalno vprašanje je:

RV1: Ali lahko prostorsko-časovna grafovska predstavitev podatkov sledilnika pogleda izboljša klasifikacijo čustvenih stanj v primerjavi z ne-grafovskimi modeli na enakih vhodnih oknih?

Dodatna podvprašanja so:

PV1: Kako podatke sledilnika pogleda predstaviti kot prostorsko-časovni graf?

PV2: Kakšen je vpliv časovnih povezav, prostorskih povezav, fiksacijskih povezav, uteži povezav, informacije o velikosti zenice, razdalje do sledilnika in trajanja fiksacij na uspešnost modela?

PV3: Katere komponente končnega modela statistično značilno izboljšajo rezultate inference?

PV4: Kako se grafovski modeli primerjajo s klasičnimi modeli strojnega učenja in predstavnikom najsodobnejših modelov (angl. *state of the art*, SOTA) za podatke sledilnika pogleda?

PV5: Kako se rezultati razlikujejo med delitvijo po subjektih in delitvijo po posnetkih?

PV6: Kako se napovedna uspešnost modelov razlikuje med 3-razredno klasifikacijo valence in 3-razredno klasifikacijo vzburjenosti?

1.4 Doprinosi naloge

Glavni doprinosi diplomske naloge so:

1. zasnova prostorsko-časovne grafovske predstavitve podatkov sledilnika pogleda;
2. implementacija heterogene časovno-prostorske grafovske nevronske mreže za 3-razredno klasifikacijo valence in vzburjenosti;

3. primerjava grafovskih modelov z ne-grafovskimi modeli na enakih vhodnih oknih;
4. vključitev GazeMAE + MLP kot primerjave s sodobnim pristopom učenja predstavitev iz podatkov pogleda;
5. evalvacija z dvema validacijskima protokoloma: subject LOO in recording LOO;
6. ablacijska analiza vpliva ključnih komponent grafovske konstrukcije in arhitekture.

TODO:

- po rezultatih preformulirati prispevke;
- iz “implementirali smo” v vsebinske trditve;
- dodati kratko omembo binarne evalvacije low/high valence in vznburjenosti kot dodatne preveritve z izrazitejšimi razredi;
- dodati, ali grafovski modeli izboljšajo ne-grafovske baseline;
- dodati, katere grafovske komponente največ prispevajo.

1.5 Struktura naloge

V poglavju 2 predstavimo teoretično ozadje grafov, grafovskih nevronske mreže, podatkov sledilnika pogleda in afektivnega računalništva. V poglavju 3 predstavimo sorodna dela, vključno z uporabo podatkovne zbirke MAHNOB-HCI in metodami učenja predstavitev iz podatkov pogleda. Poglavlje 4 opisuje uporabljene podatke, ciljne oznake in predobdelavo. V poglavju 5 opišemo konstrukcijo prostorsko-časovnega grafa. Poglavlje 6 predstavi uporabljene modele. V poglavju 7 opišemo eksperimentalni protokol, v poglavju 8 pa rezultate in ablacijsko študijo. Poglavlje 9 vsebuje interpretacijo rezultatov, omejitve in možnosti nadaljnjega dela. Nalogo sklenemo v poglavju 10.

Poglavje 2

Teoretično ozadje

To poglavje predstavi metodološke pojme, ki so potrebni za razumevanje predlaganega pristopa. Najprej uvedemo grafe in grafske nevronske mreže, nato opišemo klasifikacijo na ravni grafa in pojav prekomernega glajenja. Na koncu povzamemo osnovne lastnosti podatkov sledilnika pogleda ter ciljni oznaki valence in vznburjenosti. Psihološko ozadje čustev obravnavamo le v obsegu, ki je potreben za razumevanje klasifikacijske naloge.

2.1 Grafi

2.1.1 Osnovna definicija grafa

Graf definiramo kot

$$G = (V, E), \quad (2.1)$$

kjer je V množica vozlišč, $E \subseteq V \times V$ pa množica povezav med vozlišči. Vozlišča imajo lahko značilke, ki jih zapišemo v matriko

$$X \in \mathbb{R}^{|V| \times d}, \quad (2.2)$$

kjer je d število značilk posameznega vozlišča. Povezavo med vozliščema i in j označimo z $e_{ij} \in E$.

2.1.2 Usmerjeni, uteženi in heterogeni grafi

V usmerjenih grafih ima povezava določeno izvirno in ponorno vozlišče, zato velja $e_{ij} \neq e_{ji}$. V neusmerjenih grafih povezave nimajo smeri, zato velja $e_{ij} = e_{ji}$.

Povezave lahko vsebujejo tudi uteži ali dodatne značilke. Utež povezave med vozliščema i in j označimo z w_{ij} . Za neutežene povezave si lahko predstavljamo, da imajo utež $w_{ij} = 1$. Če imajo povezave več značilk, jih zapišemo kot vektor $\mathbf{e}_{ij}$ [4].

Homogeni in heterogeni grafi

Homogeni graf je graf, ki ne loči različnih vrst vozlišč ali povezav. Heterogeni graf vsebuje vsaj dve različni vrsti vozlišč ali povezav. V tej nalogi uporabljamo heterogeno grafovsko predstavitev, saj ločimo več tipov povezav: časovne povezave naprej, časovne povezave nazaj, prostorske povezave in fiksacijske povezave.

2.2 Grafovske nevronske mreže

Grafovske nevronske mreže so razred nevronskih mrež, namenjen učenju nad podatki, ki jih naravno predstavimo z grafom [4, 8, 14]. Graf zapišemo kot $G = (V, E)$, kjer je V množica vozlišč, E pa množica povezav med njimi. Vozlišča lahko vsebujejo značilke $\mathbf{x}_v$, povezave pa dodatne značilke $\mathbf{e}_{uv}$, ki opisujejo odnos med vozliščema u in v . Cilj GNN je naučiti se predstavitev vozlišč, povezav ali celotnega grafa tako, da model pri izračunu predstavitve posameznega vozlišča upošteva tudi njegovo lokalno okolico.

2.2.1 Posredovanje sporočil

Osnovna ideja GNN je *posredovanje sporočil* [4]. Vsako vozlišče v posamezni plasti prejme informacije od svojih sosedov, jih agregira in na podlagi zbranih informacij posodobi svojo predstavitev.

Splošna oblika plasti

Splošno plast posredovanja sporočil lahko zapišemo kot

$$\mathbf{h}_v^{(k)} = \phi^{(k)} \left(\mathbf{h}_v^{(k-1)}, \bigoplus_{u \in \mathcal{N}(v)} \psi^{(k)}(\mathbf{h}_v^{(k-1)}, \mathbf{h}_u^{(k-1)}, \mathbf{e}_{uv}) \right), \quad (2.3)$$

kjer je $\mathcal{N}(v)$ množica sosedov vozlišča v , $\psi^{(k)}$ funkcija sporočila, $\oplus$ agregacijska funkcija, $\phi^{(k)}$ funkcija posodobitve, $\mathbf{h}_v^{(k)}$ pa predstavitev vozlišča v v plasti k .

Agregacijska funkcija

Agregacijska funkcija mora biti praviloma invariantna na vrstni red sosedov, saj graf nima naravne ureditve vozlišč. Zato se pogosto uporabljajo operacije, kot so vsota, povprečje ali maksimum. Ta lastnost omogoča, da ista GNN plast deluje na grafih različnih velikosti.

2.2.2 Klasifikacija na ravni grafa

Ker želimo napovedati oznako celotnega časovnega okna, nalogo obravnavamo kot klasifikacijo grafa. Po več plasteh grafovske nevronske mreže dobimo predstavitve vozlišč $\mathbf{h}_v^{(K)}$, ki jih združimo v predstavitev celotnega grafa:

$$\mathbf{h}_G = \text{READOUT}(\{\mathbf{h}_v^{(K)} : v \in V\}). \quad (2.4)$$

Funkcija READOUT je agregacijska funkcija na ravni grafa. Pogoste izbire so povprečje, vsota, maksimum ali združevanje s pozornostjo. Predstavitev grafa $\mathbf{h}_G$ nato uporabimo v klasifikacijski glavi, ki napove razred celotnega grafa.

2.2.3 Prekomerno glajenje in kolaps predstavitev

Pri grafovskih nevronskih mrežah lahko več zaporednih agregacij povzroči, da si predstavitve vozlišč postanejo preveč podobne. Ta pojav imenujemo prekomerno glajenje. V praksi se lahko pokaže kot zmanjšanje variance

predstavitev, visoka medsebojna podobnost vozliščnih vektorjev in skoraj konstantni izhodi klasifikacijske glave.

Zato med treniranjem in evalvacijo modelov spremljamo statistike predstavitev na različnih delih modela. Varianca predstavitev kaže, ali model še ohranja razlike med vozlišči in grafi. Kosinusna podobnost pokaže, ali predstavitev postajajo usmerjene v podobno smer. Razpon logitov pa pokaže, ali klasifikacijska glava proizvaja dovolj raznolike napovedi ali se približuje skoraj konstantnemu izhodu.

2.3 Podatki sledilnika pogleda

2.3.1 Merjeni signali

Sledilnik pogleda je naprava, ki meri, kam v prostoru ali na zaslonu oseba usmerja pogled. Poleg lokacije pogleda lahko meri tudi velikost zenic. Meritve se izvajajo zaporedno z določeno vzorčno frekvenco, ki je odvisna od zmogljivosti naprave in namena uporabe. Pogoste vzorčne frekvence raziskovalnih sledilnikov pogleda so 60 Hz, 100 Hz, 500 Hz in 1000 Hz [10, 13].

2.3.2 Časovna narava signala

Lokacija pogleda se običajno zapiše v obliki koordinat (x, y) . Velikost zenice označuje njen premer in se običajno zapiše kot skalar. Podatke sledilnika pogleda obravnavamo kot časovno vrsto meritev pogleda in velikosti zenic. Takšni podatki so primerni za grafovsko obravnavo, saj lahko posamezne meritve v časovnem oknu predstavimo kot vozlišča, povezave pa določimo glede na časovno bližino, prostorsko bližino lokacij pogleda ali pripadnost isti fiksaciji.

2.4 Čustvena stanja: valenca in vzburjenost

2.4.1 Dimenzijski opis čustev

Čustvena stanja pogosto opisujemo z dimenzijama valence in vzburjenosti. Valenca opisuje prijetnost oziroma neprijetnost čustvenega odziva, vzburjenost pa stopnjo aktivacije odziva [11].

2.4.2 3-razredna klasifikacija

V tej nalogi valenco in vzburjenost obravnavamo kot dve ločeni 3-razredni klasifikacijski nalogi. Takšna formulacija omogoča primerjavo z izhodiščnim člankom podatkovne zbirke MAHNOB-HCI, kjer so avtorji prav tako poročali rezultate za 3-razredno klasifikacijo valence in vzburjenosti [11]. Razredi niso tvorjeni z neposrednim rezanjem številskih ocen valence in vzburjenosti, temveč iz poročane čustvene oznake posnetka.

Pri vzburjenosti uporabimo tri razrede: nizka, srednja in visoka vzburjenost. V razred nizke vzburjenosti spadajo oznake *sadness*, *disgust* in *neutral*. V razred srednje vzburjenosti spadajo oznake *joy*, *happiness* in *amusement*. V razred visoke vzburjenosti spadajo oznake *surprise*, *fear*, *anger* in *anxiety*. Pri valenci uporabimo razrede neprijetna, nevtralna in prijetna valenca. V razred neprijetne valence spadajo oznake *fear*, *anger*, *disgust*, *sadness* in *anxiety*. V razred nevtralne valence spadajo oznaki *surprise* in *neutral*. V razred prijetne valence spadajo oznake *joy*, *happiness* in *amusement*.

Poglavje 3

Sorodna dela

To poglavje povzame sorodna dela, ki so neposredno povezana s to nalogo. Osredotočimo se na prepoznavanje čustev iz podatkov sledilnika pogleda, podatkovno zbirko MAHNOB-HCI, grafovske nevronske mreže za časovno-prostorske podatke ter učenje predstavitev iz podatkov pogleda.

3.1 Prepoznavanje čustev iz podatkov sledilnika pogleda

3.1.1 Ročno oblikovane značilke

Podatki sledilnika pogleda se v prepoznavanju čustev uporabljajo kot vedenjski in psihofiziološki signal. Najpogosteje uporabljeni signali vključujejo lokacijo pogleda, značilke fiksacij in sakad, mežike, velikost zenice ter spremembe razdalje med očesom in sledilnikom pogleda [10, 13]. Iz teh signalov lahko izpeljemo ročno oblikovane značilke, kot so povprečna velikost zenice, trajanje fiksacij, število fiksacij, dolžina poti pogleda ali statistike porazdelitve koordinat pogleda. Takšni pristopi so razložljivi, vendar zahtevajo izbiro značilk in pogosto tudi dodatno predobdelavo signala.

3.1.2 Naučene predstavitve

Novejši pristopi namesto ročno oblikovanih značilnk uporabljajo naučene predstavitve [3]. Model v tem primeru prejme manj obdelan časovni signal in se sam nauči predstavitev, ki so uporabne za napovedno nalogo. Ciljne naloge v sorodnih delih so različne: klasifikacija diskretnega čustvenega razreda, napoved valence in vzburjenosti ter binarna klasifikacija čustvenega odziva [11].

3.2 Podatkovna zbirka MAHNOB-HCI

Podatkovna zbirka MAHNOB-HCI je večmodalna zbirka za prepoznavanje čustev in implicitno označevanje multimedijskih vsebin [11]. Vsebuje odzive udeležencev na čustvene video posnetke ter sinhrono zajete signale, med katerimi so obrazni video, zvok, fiziološki signali, EEG in podatki sledilnika pogleda. V tej nalogi uporabljamo samo podatke sledilnika pogleda, ker je osrednji cilj raziskati grafovsko predstavitev tega tipa časovnega signala.

3.2.1 Izvirni protokol za valenco in vzburjenost

Za to nalogo je pomemben del zbirke, v katerem so udeleženci gledali čustvene video posnetke in po vsakem posnetku podali samoocene. V izvirnem članku so avtorji za prepoznavanje čustev med drugim poročali rezultate za 3-razredno klasifikacijo valence in vzburjenosti, pri čemer so razrede izpeljali iz poročane čustvene oznake. Enako formulacijo uporabimo tudi v tej nalogi, saj omogoča primerjavo z izhodiščnim protokolom podatkovne zbirke.

3.2.2 Razlika do eksperimentalne postavitve v tej nalogi

Kljub temu neposredna primerjava med rezultati v izvirnem članku in rezultati te naloge ni mogoča, saj avtorji uporabljajo ročno oblikovane značilke, izračunane iz celotnega odziva na posnetek. Naš pristop uporablja časovna okna surovih signalov pogleda in velikosti zenic, ki jih pretvorimo v grafe.

Zato je primerjava smiselna kot referenčni okvir za podatkovno zbirko in ciljno nalogo, ne kot ponovitev izvirnega eksperimenta.

3.3 Grafovske nevronske mreže za časovno-prostorske podatke

Grafovske nevronske mreže so primerne za podatke, pri katerih so pomembni odnosi med elementi [4, 8, 14]. Pri časovno-prostorskih podatkih lahko vozlišča predstavljajo meritve, lokacije ali druge osnovne elemente, povezave pa opisujejo časovno zaporedje, prostorsko bližino ali druge odnose med njimi. Časovno-prostorske grafovske nevronske mreže so se uveljavile predvsem pri nalogah, kjer podatki naravno nastopajo kot časovne vrste na grafu, na primer pri napovedovanju prometa [15].

3.3.1 Uporaba na oknih podatkov pogleda

V tej nalogi to idejo uporabimo na časovnih oknih podatkov sledilnika pogleda. Posamezne meritve znotraj okna predstavimo kot vozlišča. Časovne povezave opisujejo zaporedje meritev, prostorske povezave pa podobnost lokacij pogleda. S tem dobimo časovno-prostorski graf, ki je prilagojen strukturi podatkov in hkrati omogoča uporabo GNN za klasifikacijo celotnega okna.

3.4 Učenje predstavitev iz podatkov pogleda in GazeMAE

Poleg ročno oblikovanih značilk se pri podatkih pogleda pojavljajo tudi metode za samonadzorovano učenje predstavitev. Takšne metode poskušajo iz neoznačenih ali šibko označenih zaporedij pogleda naučiti vektorske predstavitve, ki jih lahko nato uporabimo pri različnih napovednih nalogah.

3.4.1 GazeMAE

GazeMAE je primer takšnega pristopa. Podatke pogleda obravnava kot zaporedja položajev in hitrosti ter z avtokodirniško arhitekturo uči mikro- in makro-predstavitve očesnih gibov [3].

GazeMAE v tej nalogi obravnavamo kot relevanten ne-grafovski predstavnik učenja predstavitev iz podatkov pogleda. Eksperimentalno ga vključimo kot ločeno procesno verigo:

$$\text{podatki} \rightarrow \text{GazeMAE} \rightarrow \text{predstavitev} \rightarrow \text{MLP klasifikator} \rightarrow \text{napoved.} \quad (3.1)$$

3.5 Položaj te naloge glede na sorodna dela

Ta naloga ne tekmuje neposredno z vsemi večmodalnimi metodami za prepoznavanje čustev. Večmodalni sistemi lahko uporabljajo EEG, fiziološke signale, obrazni video, zvok in podatke pogleda, zato rešujejo širši problem kot ta naloga. Naš fokus je ožji: zanima nas, ali lahko časovno-prostorska grafovska predstavitev izboljša klasifikacijo valence in vzburjenosti iz podatkov sledilnika pogleda.

Glavna primerjava je zato med grafovskimi in ne-grafovskimi modeli na enakih vhodnih oknih. Ne-grafovski modeli služijo kot kontrola, ki pokaže, koliko informacije je dostopne brez eksplicitne grafovske strukture. Grafovski modeli pa preverjajo, ali relacije med meritvami pogleda izboljšajo naučeno predstavitev okna.

Poglavje 4

Podatki in predobdelava

4.1 Podatkovna zbirka MAHNOB-HCI

4.1.1 Izvirna zbirka

V delu uporabljamo podatke iz podatkovne zbirke MAHNOB-HCI [11]. Gre za večmodalno zbirko, namenjeno raziskavam prepoznavanja čustev in implicitnega označevanja multimedijskih vsebin. Zbirka vsebuje dva glavna eksperimentalna sklopa: prepoznavanje čustvenih stanj iz odzivov na čustvene videoposnetke in implicitno označevanje na podlagi odzivov na pravilne oziroma napačne oznake pod sliko ali posnetkom. V tej nalogi uporabljamo samo prvi sklop, to je eksperiment vzbujanja čustev z videoposnetki.

Izvirni članek poroča o 30 rekrutiranih udeležencih, od katerih je bilo v analizi uporabljenih 27. Udeleženci P9, P12 in P15 so bili izključeni zaradi tehničnih težav oziroma nepopolnega zajema podatkov. V eksperimentu vzbujanja čustev so udeleženci gledali 20 čustveno vzbujujočih videoposnetkov. Pred vsakim čustvenim posnetkom je bil prikazan še kratek nevtralni posnetek, odziv nanj pa je bil shranjen ločeno. Po ogledu posameznega posnetka so udeleženci podali samoocene čustvene oznake, vznburjenosti, valence, dominantnosti in predvidljivosti.

Čeprav je MAHNOB-HCI večmodalna zbirka, v tej nalogi uporabljamo

izključno signale sledilnika pogleda. Podatki pogleda so bili v izvirnem eksperimentu zajeti s sledilnikom Tobii X120 pri frekvenci 60 Hz. Zajeti signali vključujejo smer pogleda, premer zenice, oznako fiksacije in razdaljo očesa do sledilnika. Ostalih modalnosti, kot so EEG, fiziološki signali in obrazni videoposnetki, pri modeliranju v tej nalogi ne uporabljamo.

4.1.2 Lokalni podnabor

Pri delu ne uporabljamo popolne izvirne večmodalne izdaje zbirke. Izvirna zbirka podatkov ni več javno dostopna, lokalno pa imamo na voljo podnabor, ki vsebuje podatke sledilnika pogleda in pripadajoče oznake. Zato lokalnega podnabora ne obravnavamo kot popolne rekonstrukcije izvirne zbirke, temveč kot preverljiv podnabor MAHNOB-HCI podatkov, ki vsebujejo podatke sledilnika pogleda za eksperiment vzbujanja čustev.

4.2 Ciljne oznake

4.2.1 Izvor čustvenih oznak

V eksperimentih ne napovedujemo posamezne čustvene oznake neposredno, temveč iz nje izpeljemo dve ločeni klasifikacijski nalogi: 3-razredno klasifikacijo valence in 3-razredno klasifikacijo vzburjenosti. Tako sledimo izvirnemu eksperimentalnemu protokolu zbirke MAHNOB-HCI in omogočimo primerjavo z objavljenimi rezultati. Numeričnih samoocen valence in vzburjenosti ne diskretiziramo z dodatnimi pragovi, temveč uporabimo preslikavo iz čustvenih oznak v razrede valence in vzburjenosti, prikazano v tabeli 4.1.

4.2.2 Preslikava v razrede valence in vzburjenosti

Oznake čustvenih stanj so pridobljene iz metapodatkov posameznega poskusa. Kadar so bila v datoteki `session.xml` prisotna vsa potrebna polja, uporabimo oznake iz XML metapodatkov. Pri stimulusnih poskusih z nepopolnimi XML metapodatki pretvorba uporabi nadomestni vir `Guide-Cut`. V

Tabela 4.1: Preslikava čustvenih oznak v 3-razredni nalogi valence in vzburjenosti.

Izvorna čustvena oznaka	Razred valence	Razred vzburjenosti
Nevtralno stanje	nevtralna	nizka
Žalost	negativna	nizka
Gnus	negativna	nizka
Veselje / sreča	pozitivna	srednja
Zabava	pozitivna	srednja
Presenečenje	nevtralna	visoka
Strah	negativna	visoka
Jeza	negativna	visoka
Tesnoba	negativna	visoka

eksperimentalnem cevovodu uporabljamo samo vrstice z veljavno izpeljano oznako.

TODO:

- tabela/slika porazdelitve razredov za valenco;
- tabela/slika porazdelitve razredov za vzburjenost;
- po končni tvorbi 10-sekundnih oken;
- `min_samples_per_window=60`;
- izključeni subjekti: P9, P12, P15;
- samo `emotion-elicitation`;
- samo `emotion-derivation-status=ok`;
- ločeno navesti absolutna števila in deleže.

4.3 Priprava vhodnih signalov

4.3.1 Uporabljeni stolpci

Za vsak časovni vzorec uporabimo štiri osnovne signale sledilnika pogleda:

- horizontalno koordinato pogleda x_i ,
- vertikalno koordinato pogleda y_i ,
- velikost leve zenice $p_i^{(l)}$,
- velikost desne zenice $p_i^{(r)}$.

V trenutni implementaciji so to stolpci `x-avg`, `y-avg`, `pupil-size-left-avg` in `pupil-size-right-avg`. Koordinati pogleda predstavljata povprečen položaj pogleda med levim in desnim očesom, velikosti zenic pa sta ohranjeni ločeno. Poleg osnovnih signalov trenutna konfiguracija doda še normalizirani čas znotraj okna, povprečno razdaljo med očmi in sledilnikom ter trajanje fiksacije. To ustreza stolpcem `time-window-normalized`, `distance-avg` in `fixation-duration`. Stolpec `fixation-index` uporabimo za konstrukcijo fiksacijskih povezav, ne pa kot numerično vhodno značilko. Čas v sekundah uporabljamo pri tvorbi časovnih oken in časovnih povezav, za vhodno značilko modela pa uporabimo okensko normalizirani čas.

4.3.2 Čiščenje in filtriranje podatkov

Modeli ne uporabljajo neposredno surovih Tobii TSV datotek. Vir za eksperimentalni cevovod je obdelani predpomnilnik `data/processed/cached_hci_tagging_emotion.csv`. Ta nastane s pretvorbo izvornih Tobii izvozov in pripadajočih metapodatkov v skupno tabelarično obliko. Nato se kode veljavnosti sledilnika pogleda preslikajo v binarne indikatorje zaupanja. Za podatke MAHNOB-HCI zahtevamo veljaven signal levega in desnega očesa.

Kratke vrzeli v numeričnih signalih se interpolirajo, signala velikosti zenice pa se dodatno zgladita s kratkim drsečim povprečjem. Nato ohranimo

samo eksperiment vzbujanja čustev in vrstice z veljavno oznako. Za učenje odstranimo vrstice brez osnovnih signalov pogleda ali zenic. V privzetem eksperimentalnem cevovodu dodatno uporabimo robustni filter osamelcev q01–q99 na štirih osnovnih signalih.

4.4 Normalizacija

Po čiščenju so signali obdelani, vendar še niso standardizirani. Prva standardizacija se izvede šele po razdelitvi podatkov na učni, validacijski in testni fold.

4.4.1 Normalizacija pri grafovskih modelih

Pri grafovskem modelu se `StandardScaler` prilagodi samo na matrikah značilk vozlišč iz grafov učnega folda. Isti scaler se nato uporabi za grafe učnega, validacijskega in testnega folda. Pri naučenih značilkah povezav se scalerji prav tako prilagodijo samo na učnem foldu. Časovne povezave imajo skupen scaler za relaciji `temporal_forward` in `temporal_backward`, pri čemer značilka smeri ostane neskalirana. Prostorske in fiksacijske povezave imajo ločena scalerja.

4.4.2 Normalizacija pri tabelaričnih modelih

Pri tabelaričnih osnovnih modelih se najprej tvorijo časovna okna in agregirane tabelarične značilke, nato se `StandardScaler` prilagodi samo na matriki `X_train`.

4.4.3 Preprečevanje uhajanja informacij

S tem preprečimo uhajanje informacij iz validacijskih in testnih foldov v učno množico.

4.5 Segmentacija v časovna okna

4.5.1 Dolžina okna

Časovno vrsto razdelimo na neprekrivajoča se časovna okna dolžine $T = 10$ s. Vsako uporabno časovno okno predstavlja en učni primer. Pri ne-grafovskih osnovnih modelih ga pretvorimo v tabelarični vektor značilk, pri grafovskem modelu pa v časovno-prostorski graf.

4.5.2 Dodelitev oznake oknu

Oznaka okna je določena s parom udeleženec–posnetek, saj vsa okna istega označenega ogleda videoposnetka podedujejo isto čustveno oznako.

4.5.3 Minimalno število vzorcev

Pri vzorčni frekvenci 60 Hz bi 10-sekundno okno brez manjkajočih vrednosti vsebovalo 600 vzorcev. Zaradi čiščenja, odstranjevanja neveljavnih vzorcev in filtriranja je dejansko število vzorcev v oknih manjše. Po dodatnem filtru osamelcev q01–q99 dobimo 5 158 uporabnih 10-sekundnih časovnih oken.

4.6 Predhodni poskus z zbirko eSEEd_v2

Pred prehodom na MAHNOB-HCI je bil del razvoja izveden na podatkovni zbirki eSEEd_v2. Ta del ni osrednji eksperimentalni prispevek naloge, temveč služi kot zgodovinska motivacija za spremembo podatkovne zbirke. Začetni poskusi so pokazali težave z zanesljivostjo oznak, kakovostjo signalov in stabilnostjo učenja. Zato smo glavno eksperimentalno evalvacijo izvedli na podatkovni zbirki MAHNOB-HCI, ki ima jasnejši protokol označevanja in uporabnejši lokalni podnabor signalov sledilnika pogleda.

Tabela 4.2: Zmanjševanje količine podatkov od izvirne zbirke MAHNOB-HCI do končnih časovnih oken, uporabljenih v eksperimentalnem cevovodu.

Korak	Vrstice	Udeleženci	Opis
Izvirna zbirka MAHNOB-HCI	–	30	Večmodalna zbirka; izvirni članek v analizi uporabi 27 udeležencev.
Lokalni podnabor podatkov sledilnika pogleda	3 797 165	24	Lokalna kopija eksperimenta vzbujanja čustev s podatki sledilnika pogleda in oznakami.
Po izključitvi P9, P12 in P15	3 535 842	22	P15 v lokalnem podnaboru ni prisoten, zato sta odstranjena le P9 in P12.
Veljavno označene vrstice	2 995 632	22	Ohranjeni so samo označeni podatki, uporabljeni za učenje modelov čustvenih stanj.
Pripravljeno za učenje	2 814 005	22	Odstranjene so vrstice brez ključnih signalov pogleda ali zenic.
Po filtru osamelcev q01–q99	2 639 048	22	Robustno filtriranje štirih osnovnih signalov pogleda in zenic.
Uporabna 10-sekundna časovna okna	5 158	22	Vsako okno postane en učni primer oziroma graf.

Poglavje 5

Grafovski predstavitev podatkov sledilnika pogleda

To poglavje je eno osrednjih metodoloških poglavij naloge. Njegov namen je natančno opisati, kako iz časovnega okna meritev sledilnika pogleda nastane graf, ki ga uporabimo kot vhod v grafovsko nevronske mrežo.

5.1 Učni vzorec kot graf

5.1.1 Definicija grafa

Vsak učni vzorec je časovno okno meritev sledilnika pogleda. Okno pretvorimo v graf

$$G = (V, E_t^+, E_t^-, E_s, E_f), \quad (5.1)$$

kjer je V množica vozlišč, E_t^+ množica časovnih povezav naprej, E_t^- množica časovnih povezav nazaj, E_s množica prostorskih povezav in E_f množica fiksacijskih povezav.

Vozlišča predstavljajo zaporedne meritve sledilnika pogleda znotraj časovnega okna. Povezave med vozlišči opisujejo različne relacije med meritvami: časovno zaporednost, prostorsko bližino pogleda in pripadnost isti fiksaciji. En graf predstavlja en učni vzorec.

5.1.2 Oznaka grafa

Vsak graf označimo z oznako pripadajočega časovnega okna. V nalogi to oznako uporabimo pri ločenih klasifikacijskih nalogah valence in vzburjenosti.

[Na koncu popravi, če klasifikacijski nalogi nista ločeni, ampak združeni v eno nalogo. Predvidevam, da bosta ločeni, ker mislim, da so tako tudi naredili v MAHNOB članku.]

5.2 Vozlišča

5.2.1 Definicija vozlišča

Vsako vozlišče predstavlja eno meritev sledilnika pogleda znotraj časovnega okna:

$$v_i \leftrightarrow \mathbf{x}_i. \quad (5.2)$$

Če okno vsebuje n veljavnih meritev, potem graf vsebuje n vozlišč. V osnovni nastavitvi uporabljamo 10-sekundna okna. Ker so meritve vzorčene s frekvenco 60 Hz, je pričakovano število meritev v polnem oknu

$$n_{\text{exp}} = 10 \text{ s} \cdot 60 \text{ Hz} = 600. \quad (5.3)$$

Grafovski predstavitev naravno podpira spremenljivo število vozlišč. Grafovski nevrnska mreža namreč deluje na množici vozlišč in povezav, končno predstavitev celotnega grafa pa pridobi z agregacijo vozliščnih predstavitev.

5.2.2 Značilke vozlišč

TODO:

- Tu naj ostane samo opis vhodnih značilk vozlišč kot dela grafovske predstavitve.
- Preslikavo značilk vozlišč v latentni prostor opiši v poglavju 6.4.
- Ne opisuj LayerNorm, dropout, MLP blokov ali drugih arhitekturnih komponent v tem poglavju.

Vektor značilk vozlišča je

$$\mathbf{x}_i = [x_i, y_i, p_{l,i}, p_{r,i}, t_i, d_i, f_{dur,i}], \quad (5.4)$$

kjer sta x_i in y_i koordinati pogleda, $p_{l,i}$ in $p_{r,i}$ velikosti leve in desne zenice, t_i je normalizirani čas znotraj okna, d_i razdalja med sledilnikom in udeležencem v očmi, $f_{dur,i}$ pa trajanje fiksacije, ki ji pripada i -ta meritev.

Časovna značilka

Časovna značilka t_i modelu poda položaj meritve znotraj okna.

Koordinate pogleda

Koordinati x_i in y_i opisujeta položaj pogleda in sta uporabljeni tudi pri konstrukciji prostorskih povezav.

Značilke zenice

Značilki $p_{l,i}$ in $p_{r,i}$ opisujeta velikost leve in desne zenice.

Razdalja do sledilnika in fiksacije

Značilki d_i in $f_{dur,i}$ opisujeta razdaljo do sledilnika ter trajanje fiksacije pripadajoče meritve. Manjkajoče vrednosti trajanja fiksacije in meritve, ki ne pripadajo fiksaciji, so kodirane z vrednostjo $f_{dur,i} = 0$.

5.3 Heterogena grafovski predstavitev

5.3.1 Tipi relacij

Ker različne povezave opisujejo različne odnose med meritvami, graf obravnavamo kot heterogen graf z več tipi povezav. V trenutni predstavitvi uporabljamo množico relacij

$$\mathcal{R} = \{\text{temporal_forward}, \text{temporal_backward}, \text{spatial}, \text{fixation}\}. \quad (5.5)$$

Časovne povezave naprej, časovne povezave nazaj, prostorske povezave in fiksacijske povezave so obravnavane kot ločene relacije.

5.3.2 Zakaj ločimo relacije

Ločevanje relacij omogoča, da model za vsak tip relacije uporablja ločeno transformacijo oziroma ločeno funkcijo posredovanja sporočil. S tem lahko časovno zaporednost, prostorsko bližino in pripadnost isti fiksaciji modeliramo z različnimi parametri, namesto da bi vse povezave obravnavali kot enakovredne. S tem tudi dovolimo modelu, da se za različne relacije nauči dajati različno težo istim vozliščem. Morda je neko vozlišče zelo pomembno s pogleda časovne zaporednosti, ampak povsem nepomembno z vidika umeščenosti v prostor.

TODO:

- Ta pododsek naj ostane konceptualna motivacija za heterogen graf.
- Podrobnosti, kako model dejansko uporabi ločene relacijske transformacije, prestavi v poglavje 6.4.
- Popravi slog in tipkarske napake; izogni se preveč modelno specifični razlagi v poglavju 5.

5.4 Povezave

5.4.1 Časovne povezave

Časovne povezave povezujejo meritve zaporedne v času. Naj bodo vozlišča v posameznem oknu urejena po času, tako da je v_i i -ta meritev v časovnem zaporedju. Parameter $k_t \in \mathbb{N}$ določa število časovnih sosedov na vsako stran. V privzeti nastavitvi uporabljamo $k_t = 2$. *[preveri končni k_t]*

Povezave naprej in nazaj

Ločimo usmerjene časovne povezave naprej in nazaj:

$$E_t^+ = \{(v_i, v_j) : 1 \leq j - i \leq k_t\}, \quad (5.6)$$

$$E_t^- = \{(v_i, v_j) : 1 \leq i - j \leq k_t\}. \quad (5.7)$$

Povezave v E_t^+ potekajo od prejšnjih proti kasnejšim meritvam, povezave v E_t^- pa od kasnejših proti prejšnjim meritvam. Ločitev smeri je smiselna, ker ima vrstni red očesnega gibanja pomen.

Parameter k_t

Parameter k_t določa velikost lokalnega časovnega konteksta in s tem število povezav, ki jih dodamo okrog posamezne meritve. Smiselno lahko zahtevamo $k_t < n$, kjer je n število vozlišč v oknu. Pričakovano število usmerjenih povezav v grafu naprej je $|E_t^+| = k_t \cdot n - \sum_{i=1}^{k_t} (i) = k_t \cdot n - \frac{k_t(k_t+1)}{2} = k_t \cdot (n - \frac{k_t+1}{2})$. Za obravnavani primer $[k_t = 2 \text{ in } n = 600 \text{ je to } |E_t^+| = 2 \cdot (600 - \frac{2+1}{2}) = 1197]$ usmerjenih povezav naprej, enako število pa je tudi usmerjenih povezav nazaj. Torej skupno imamo približno $2k_t \cdot n$ časovnih povezav.

- Vstavi sliko časovnih povezav.
- Razmisli o smiselnosti k_t glede na število layerjev GNN.

5.4.2 Prostorske povezave

Prostorske povezave so neusmerjene povezave, ki povezujejo meritve s podobnim položajem pogleda znotraj istega časovnega okna. Za vsako vozlišče poiščemo k_s najbližjih sosedov v prostoru koordinat pogleda (x, y) .

Najbližji sosedi v prostoru pogleda

Prostorsko razdaljo med meritvama i in j definiramo evklidsko:

$$d_{ij}^{(s)} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}. \quad (5.8)$$

Za vsako vozlišče v_i poiščemo k_s najbližjih sosedov v prostoru koordinat pogleda (x, y) z uporabo k-d drevesa. Če je v_j med temi sosedi, dodamo povezavo med vozliščema v_i in v_j ; ker prostorske povezave obravnavamo kot neusmerjene, povezavo predstavimo z obema usmerjenima povezavama (v_i, v_j) in (v_j, v_i) . Na koncu odstranimo podvojene povezave znotraj relacije E_s .

Simetrizacija povezav

Ker povezave obravnavamo kot neusmerjene, vsaki povezavi (v_i, v_j) dodamo tudi povezavo (v_j, v_i) .

- Vstavi sliko prostorskih povezav.
- $k_s = 2$ v trenutnih poskusih. Preveri končni k_s .

5.4.3 Fiksacijske povezave

Fiksacijske povezave povezujejo meritve, ki pripadajo isti zaznani fiksaciji. Pripadnost fiksaciji določimo z identifikatorjem fiksacije, podanim v MAHNOB-HCI podatkih.

Redčenje povezav znotraj fiksacije

Znotraj posamezne fiksacije ne povežemo vseh vozlišč med seboj, saj bi to povzročilo preveliko število fiksacijskih povezav. Namesto tega uporabimo redkejšo konstrukcijo, ki ohrani informacijo o pripadnosti isti fiksaciji, vendar zmanjša prostorsko in časovno zahtevnost konstrukcije grafa ter učenja na grafu. To konstrukcijo imenujemo razširjene povezave znotraj fiksacije (angl. *dilated intra-fixation edges*). Fiksacijo obravnavamo kot zvezno zaporedje vozlišč z istim veljavnim identifikatorjem `fixation-index`. Če ima taka fiksacija F vozlišč, jim znotraj fiksacije priredimo lokalne indekse $0, \dots, F-1$.

Gostoto povezav uravnava parameter k_f , ki določa število fiksacijskih povezav, ki jih generira vsako vozlišče. V trenutni privzeti konfiguraciji uporabljamo $k_f = 3$. Za posamezno fiksacijo najprej izračunamo korak

razširitve

$$s = \max(1, \lfloor F/k_f + 0,5 \rfloor). \quad (5.9)$$

Množico kandidatnih odmkov nato definiramo kot

$$D = \{(1 + qs) \bmod F \mid q = 0, \dots, k_f - 1\}. \quad (5.10)$$

Morebitni odmik 0 in podvojene odmiške odstranimo. Za vsak odmik $d \in D$ dodamo neusmerjene povezave

$$\{v_i, v_{(i+d) \bmod F}\}, \quad i = 0, \dots, F - 1. \quad (5.11)$$

Pri zapisu grafa za posredovanje sporočil vsako neusmerjeno povezavo predstavimo z dvema usmerjenima povezavama. Podvojene povezave znotraj relacije E_f odstranimo.

Na primer, pri fiksaciji dolžine $F = 30$ in parametru $k_f = 3$ dobimo $s = 10$. Vozlišče z lokalnim indeksom 0 torej povežemo z vozlišči 1, 11 in 21. Odmik 1 ohrani časovno lokalno komunikacijo znotraj fiksacije, večji odmiški pa omogočijo širjenje informacij tudi med časovno bolj oddaljenimi meritvami iste fiksacije.

Razširjene povezave imajo večji doseg kot zgolj zaporedne fiksacijske povezave, hkrati pa se izognejo kombinatorični eksploziji, ki bi nastala pri polnem kliku. Pri polnem kliku bi namreč število povezav naraščalo kvadratno z dolžino fiksacije. Pri analiziranih 10-sekundnih oknih dobimo približno 1.956 fiksacijskih povezav na graf pri $k_f = 2$, 2.908 pri $k_f = 3$, 4.163 pri $k_f = 5$ in 7.273 pri $k_f = 10$. Pri privzeti izbiri $k_f = 3$ so fiksacijske povezave predstavljale približno 45,7 % vseh povezav v grafu (relacije `temporal`, `spatial` in `fixation`).

Izbira $k_f = 3$ je zato kompromis med dosegom in gostoto grafa. Ker vsaka plast GNN omogoča izmenjavo informacij med neposredno povezanimi vozlišči, se doseg znotraj fiksacije povečuje tudi z večanjem števila plasti. Pri $k_f = 3$ vozlišče že v eni plasti prejme informacije iz več delov iste fiksacije, večplastni model pa lahko te informacije dodatno propagira po fiksacijski relaciji. Večje vrednosti k_f povečajo gostoto grafa, računsko zahtevnost in možnosti za prekomerno glajenje, manjše vrednosti pa graf dodatno razredčijo.

- Vstavi sliko fiksacijskih povezav.
- $k_f = 3$ v trenutnih poskusih. Preveri končni k_f glede na eksperimente (consider $k_f=2$).

5.5 Uteži povezav

TODO:

- Razdeli vsebino tega odseka med poglavji 5 in 6.4.
- V poglavju 5 naj ostanejo značilke povezav: katere količine opišejo relacijo med dvema meritvama.
- V poglavje 6.4 prestavi ali tam povzemalno opiši arhitekturni del: MLP za izračun uteži, predznačene uteži, normalizacijo in uporabo uteži pri posredovanju sporočil.
- V poglavju 5 ne poudarjaj več, da model iz značilk izračuna uteži; to naj bo predvsem del opisa predlaganega modela.

Uteži povezav omogočajo, da model razlikuje med povezavami, ki povezujejo v času in prostoru različno oddaljene meritve.

5.5.1 Značilke povezav

Za vsako povezavo sestavimo vektor značilk, iz katerega model izračuna surovo skalarno oceno povezave:

$$a_{ij} = f_{\theta}(\mathbf{r}_{ij}), \quad (5.12)$$

kjer je $\mathbf{r}_{ij}$ vektor značilk povezave e_{ij} , f_{θ} pa večslojni perceptron. Za časovne, prostorske in fiksacijske povezave so uporabljene značilke $[t_i, t_j, \Delta t, \Delta x, \Delta y, d_{ij}^{screen}, \Delta d_{ij}^{eye}]$, pri časovnih povezavah pa dodatno še značilka smeri ρ_{ij} . Pri časovni povezavi naprej je $\rho_{ij} = 1$, pri časovni povezavi nazaj pa $\rho_{ij} = -1$. Časovne povezave imajo torej 8 značilk, prostorske in fiksacijske povezave pa 7 značilk, iz katerih se izračunajo uteži povezav.

Tabela 5.1: Značilke povezav za izračun naučenih uteži povezav.

Značilka	Opis
t_i	Normaliziran čas izvirnega vozlišča znotraj časovnega okna.
t_j	Normaliziran čas ciljnega vozlišča znotraj časovnega okna.
Δt	Časovna razlika med ciljnim in izvirnim vozliščem, $\Delta t = t_j - t_i$.
Δx	Razlika v vodoravni koordinati pogleda, $\Delta x = x_j - x_i$.
Δy	Razlika v navpični koordinati pogleda, $\Delta y = y_j - y_i$.
d_{ij}^{screen}	Evklidska razdalja med položajema pogleda na zaslonu.
Δd_{ij}^{eye}	Sprememba razdalje med sledilnikom in udeležencem oči.
$\rho_{ij} = \pm 1$	Smer časovne povezave; uporablja se samo pri časovnih povezavah.

5.5.2 Normalizacija uteži

TODO:

- Razmisli o prestavitvi tega pododseka v poglavje 6.4, ker je normalizacija uteži del arhitekture modela in ne del same definicije vhodnega grafa.
- Če formule ostanejo tukaj, jih v 6.4 ne ponavljaj; tam dodaj samo konceptualni povzetek in sklic na ta odsek.
- Če formule prestaviš v 6.4, naj poglavje 5 vsebuje samo tabelo značilk povezav.

Surovo skalarno oceno a_{ij} najprej preslikamo v omejeno območje na interval $(-1, 1)$:

$$\tilde{w}_{ij} = \tanh(a_{ij}). \quad (5.13)$$

Nato uteži normaliziramo po vhodnih povezavah ciljnega vozlišča. To pomeni, da za vozlišče v_j upoštevamo povezave, ki imajo v_j za ciljno vozlišče. Pri neusmerjenih povezavah, tretiramo vse povezave za vhodne in izhodne. Normalizacijo izvedemo ločeno za vsako relacijo r :

$$w_{ij}^{(r)} = \frac{\tilde{w}_{ij}^{(r)}}{\sum_{i' \in \mathcal{N}_r^-(j)} |\tilde{w}_{i'j}^{(r)}| + \epsilon}, \quad (5.14)$$

kjer je $\mathcal{N}_r^-(j)$ množica izvornih vozlišč, ki so z vozliščem v_j povezana z vhodno povezavo tipa r . Majhna konstanta ϵ prepreči deljenje z nič. Takšna normalizacija stabilizira velikost agregiranih sporočil tudi pri vozliščih z večjim številom vhodnih povezav.

Za izračun surovih ocen uporabljamo tri ločene večslojne perceptrone: enega za časovne povezave, enega za prostorske povezave in enega za fiksacijske povezave. Časovni relaciji naprej in nazaj si delita isti perceptron, ločeni pa sta z dodatno značilko smeri ρ_{ij} . Skalarne uteži povezav se uporabljajo pri konvoluciji **GCNConv**, ki je privzeta izbira modela. Pri poskusih z **GATConv** se te skalarne uteži ne uporabijo, saj **GATConv** pomembnost povezav modelira z notranjim mehanizmom pozornosti.

5.6 Statistika grafov

5.6.1 Število vozlišč in povezav

Tabela 5.2: Povzetek statistike grafov za privzeto 10-sekundno okno pri $k_t = 2$, $k_s = 2$ in $k_f = 3$.

Količina	Vrednost
Mediana števila vozlišč	560
Povprečno število vozlišč	505,9
Mediana števila časovnih povezav naprej	1117
Mediana števila časovnih povezav nazaj	1117
Mediana števila prostorskih povezav	1546
Mediana števila fiksacijskih povezav	3204
Povprečna gostota grafa	TODO

[Verjetno prestavi to poglavje nižje med modele.]

5.6.2 Računska zahtevnost

TODO:

- Ta odsek verjetno ne sodi v poglavje 5, ker govori o zahtevnosti modela, ne o konstrukciji vhodnega grafa.
- Statistiko števila vozlišč in povezav lahko pustiš v poglavju 5.
- Oceno števila parametrov, časa učenja, pomnilniške zahtevnosti in primerjavo z drugimi modeli prestavi v poglavje 6, poglavje 7 ali dodatek s hiperparametri.
- Če v poglavju 5 ostane kaj o zahtevnosti, naj bo omejeno na zahtevnost konstrukcije grafa in gostoto povezav.

TODO: Stvari spodaj

- Oceni velikost GNN modela po neki metriki – število učljivih parametrov.
- Primerjaj velikost med modeli:
 - GNN približno 560K parametrov, MLP baseline približno 5K, GazeMAE + MLP približno 2.100K parametrov, od tega samo 80K učljivih (MLP), ker je GazeMAE hrbtenica zamrznjena. (Te podatke je potrebno preveriti.)
 - LightGBM lahko merimo v `n_estimators` in `max_depth`, ampak ni zelo primerljivo.
 - SVM je odvisen od števila podpornih vektorjev. SVM in LGBM bomo zato primerjali samo časovno.
- Pri eni plasti GNN je strošek posredovanja sporočil približno linearen v številu povezav in v širini skritih predstavitev. Za L plasti je zato groba odvisnost $O(L \cdot |E| \cdot H)$, ob tem pa model vsebuje še linearne transformacije in MLP-je za združevanje relacij. Pri predlaganem modelu je $L = 3$, $H = 128$, tipičen graf pa ima nekaj sto vozlišč in nekaj tisoč povezav.
- Primerjaj prostorsko zahtevnost med modeli.
- Primerjaj časovno zahtevnost med modeli – konkreten povprečen čas učenja za vsak model v tej nalogi.
- Verjetno prestavi to poglavje nižje med modele.

Poglavje 6

Primerjani modeli in predlagana arhitektura

V tem poglavju predstavimo klasifikacijske modele strojnega učenja, ki jih primerjamo v eksperimentalni evalvaciji. Modele razdelimo na negrafovske osnovne modele, model GazeMAE + MLP kot predstavnika SOTA ter grafovske modele. *[...grafovske modele - množina?]*

Vsi modeli – osnovni, predstavnik SOTA ter grafovski modeli – uporabljajo iste izvirne podatke, ista 10-sekundna okna in iste delitve na učne, validacijske in testne množice. Razlika je v predstavitvi vhodnega vzorca. Grafovski modeli prejmejo okno kot graf meritev, negrafovski osnovni modeli prejmejo agregirano tabelarično predstavitev istega okna, GazeMAE pa po svoji konstrukciji le signala **x-avg** in **y-avg** koordinat za celotno 10 s okno. Za poštenjšo primerjavo so v tabelarični vhod osnovnih modelov vključene agregirane značilke istih osnovnih signalov, ki jih uporabimo tudi pri GNN: koordinati pogleda **x-avg** in **y-avg**, velikosti leve in desne zenice, oddaljenost od zaslona ter informacije o fiksacijah oziroma trajanju fiksacij.

TODO: Natančen seznam agregiranih statistik bomo zapisali po dokončni uskladitvi implementacije; predvidene so opisne statistike posameznega signala znotraj okna, na primer povprečje, standardni odklon, minimum, maksimum in razpon.

6.1 Negrafovski osnovni modeli

Prvo skupino primerjalnih modelov sestavljajo negrafovski osnovni modeli. Z izrazom osnovni model označujemo preprostejši primerjalni model, s katerim preverimo, ali zahtevnejša arhitektura prinaša dodatno korist. V to skupino vključimo večinski klasifikator, naključni klasifikator, klasifikator podpornih vektorjev (SVM), Light Gradient Boosting Machine (LightGBM) in večplastni perceptron (MLP).

Večinski in naključni klasifikator predstavljata spodnjo primerjalno mejo. Če model ne preseže teh dveh klasifikatorjev, težko trdimo, da se iz vhodnih podatkov uči uporabne vzorce. SVM vključimo kot predstavnika jedrnih metod oziroma metod podpornih vektorjev, LightGBM kot učinkovitega predstavnika ansambelskih drevesnih metod z gradientnim spodbujevanjem, MLP pa kot osnovni nevronske model brez eksplicitne grafovske strukture. Hiperparametrov osnovnih modelov nismo optimizirali.

Pri modelih SVM in MLP vhodne značilke standardiziramo s pretvorbo, naučeno samo na učni podmnožici. Ista pretvorba se nato uporabi na validacijski in testni množici. LightGBM standardizacije ne potrebuje, zato prejme neposredno tabelarično predstavitev okna.

6.1.1 MLP

Osnovni MLP uporabimo kot nevronske model nad agregirano tabelarično predstavitevijo okna. Vhod modela je vektor agregiranih značilk enega 10-sekundnega okna, izhod pa logiti za tri razrede valence oziroma vzburjenosti. Arhitektura je namerno preprosta: dve skriti polno povezani plasti velikosti 64 z aktivacijo ReLU in izpuščanjem, za njima pa izhodna linearna plast. Model učimo z navzkrižno entropijo. Za optimizacijo uporabimo AdamW, validacijsko podmnožico pa uporabimo za zgodnje ustavljanje na podlagi validacijske izgube.

6.2 Negrafovski predstavnik SOTA: GazeMAE + MLP

Za primerjavo s sodobnim temeljnim modelom smo uporabili odprtokodni prednaučeni kodirnik GazeMAE [3]. Uporabili smo ga po principu zamrznjene hrbtnice: parametrov kodirnika med učenjem nismo spreminjali, ampak smo z njim iz podatkov pogleda izračunali vektorske predstavitve, na katerih smo nato učili MLP. V tem delu MLP zato ne nastopa kot samostojen klasifikator nad ročno agregiranimi značilkami, temveč kot klasifikacijska glava nad značilkami, ki jih izračuna GazeMAE. Ker je bil GazeMAE učen na 2 s oknih, vzorčenih s frekvenco 500 Hz, smo tudi uporabljena 10 s okna najprej pretvorili v obliko, ki jo model pričakuje: signala koordinat pogleda (x, y) smo razdelili na pet neprekrivajočih se 2 s kosov in ju prevzorčili na ciljno frekvenco 500 Hz. Iz teh kosov smo s kodirnikom pridobili predstavitev celotnega okna z 512 razsežnostmi, ta predstavitev pa je bila vhod v klasifikacijsko glavo MLP. Procesna veriga je zato:

$$\text{koordinate } (x, y) \rightarrow \text{predprocesiranje} \rightarrow \text{GazeMAE} \rightarrow \text{predstavitev} \rightarrow \text{MLP} \rightarrow \text{napoved.} \quad (6.1)$$

6.3 Grafovski osnovni model

Grafovski modeli se od negrafovskih osnovnih modelov razlikujejo že v predstavitvi podatkov, saj okno meritev obravnavajo kot graf in ne kot tabelarični vektor značilk. Predlagani model, predstavljen v naslednjem odseku, tej predstavitvi doda še ločeno obravnavo tipov povezav, fuzijo relacijskih predstavitev in naučene uteži povezav. Zato za primerjavo s predlaganim modelom poleg negrafovskih modelov uporabimo še osnovni grafovski model, s katerim ločimo vpliv same grafovske predstavitve od vpliva bolj dodelane heterogene grafovske arhitekture.

Osnovni grafovski model je homogeni GCN. Vhodni podatki so enaki kot pri predlaganem GNN: vozlišča vsebujejo iste značilke, uporabljeni so isti

izvorni signali in ista časovna okna. Razlika je v tem, da osnovni model še ne ločuje časovnih, prostorskih in fiksacijskih relacij. Vse povezave obravnava kot povezave istega tipa, posredovanje sporočil pa izvede z običajnimi plastmi GCNConv. Model prav tako ne uporablja uteži na povezavah.

Tehnično lahko osnovni model zapišemo kot:

$$X \rightarrow f_{GCN} \rightarrow \text{READOUT} \rightarrow f_{\text{head}}, \quad (6.2)$$

kjer je X matrika značilk vozlišč, f_{GCN} zaporedje grafovskih konvolucijskih plasti, korak READOUT združi predstavitev vozlišč v predstavitev celotnega grafa, f_{head} pa iz te predstavitev izračuna napoved razreda. Ta model zato predstavlja vmesno primerjavo med učenjem nad agregiranimi tabelarnimi značilkami in predlaganim heterogenim grafovskim modelom.

[Ko bo osnovni GCN dokončno definiran, koda napisana, rezultati pridobljeni, tehnično še bolj specificiraj točno arhitekturo. Npr: uporabljen je bil identičen MLP head, ista READOUT funkcija, isti preprocessing $X \rightarrow f_{GCN}$, itd.]

TODO:

- Pisanje: osnovni grafovski model v diplomi dosledno poimenuj Osnovni GCN.
- Pisanje: opis uskladiti s končno implementacijo: ista grafovska predstavitev, isti signali, ista okna, iste delitve in ista standardizacija kot pri predlaganem GNN.
- Pisanje: zapisati, da Osnovni GCN relacije `temporal_forward`, `temporal_backward`, `spatial` in `fixation` združi v homogeni graf, odstrani podvojene povezave ter ne uporablja značilk povezav ali naučenih uteži povezav.
- Pisanje: preveriti in zapisati, da uporablja `GCNConv`, isto napovedno glavo, iste YAML hiperparametre in ločen readout parameter, trenutno `attention`; možnost `mean` omeni samo, če bo dejansko preverjena.
- Pisanje: ne predstavlja ga kot starejšo različico predlaganega GNN, temveč kot ločen grafovski baseline za preverjanje učinka homogene grafovske predstavitve.

6.4 Predlagani prostorsko-časovni heterogeni GNN

Končni model nadgradi osnovni GCN iz prejšnjega odseka in temelji na prostorsko-časovni heterogeni grafovski nevronske mreži. Model ločeno obravnava časovne povezave naprej, časovne povezave nazaj, prostorske povezave in fiksacijske povezave. S tem lahko za različne tipe odnosov uporablja različne transformacije.

6.4.1 Pregled arhitekture

Osnovni potek modela je:

$$X \rightarrow f_{\text{pre}} \rightarrow f_{\text{HeteroGNN}} \rightarrow f_{\text{fuzija}} \rightarrow \text{READOUT} \rightarrow f_{\text{head}}, \quad (6.3)$$

kjer je X vhodna matrika značilk vozlišč opisana v poglavju 5.2.2, f_{pre} je naučena preslikava X v skupni latentni prostor, $f_{\text{HeteroGNN}}$ so plasti predlagane heterogene grafovske nevronske mreže, f_{fuzija} označuje združevanje vseh štirih predstavitev vozlišča v eno skupno predstavitev, READOUT predstavlja združevanje predstavitev vozlišč v predstavitev celotnega grafa, ki se prenese kot vhod v napovedno klasifikacijsko glavo f_{head} .

Za primerjavo podajamo tudi potek osnovnega modela GCN:

$$X \rightarrow f_{\text{GCN}} \rightarrow \text{READOUT} \rightarrow f_{\text{head}}, \quad (6.4)$$

6.4.2 Relacijsko posredovanje sporočil in uteži povezav

Kot definirano v poglavju 5.3, $f_{\text{HeteroGNN}}$ ločeno obravnava različne relacije oziroma tipe povezav med vozlišči. Za primerjavo, osnovni GCN vse povezave obravnava kot enake, zato težje prilagodi posredovanje sporočil različnim odnosom med meritvami.

Posredovanje sporočil med vozlišči izvajamo ločeno po relacijah. Model se za vsako relacijo nauči svojo grafovsko konvolucijo in tako ločeno izračuna predstavitev vozlišč na podlagi vseh štirih tipov povezav.

Za izračun uteži povezav se model uči treh večslojnih perceptronov f_w^{rel} – enega za časovne, enega za prostorske in enega za fiksacijske povezave. Te funkcije iz značilk povezave izračunajo skalarno predznačeno utež, ki določa, kako močno posamezna povezava vpliva na posredovanje sporočil. Ker so uteži predznačene, lahko povezava prispevek sosednjega vozlišča tudi zmanjša. Časovne povezave naprej in nazaj si delijo isto funkcijo f_w^{time} , smer povezave pa je podana kot dodatna značilka povezave ρ_{ij} . Značilke povezav, iz katerih model izračuna uteži, so opisane v poglavju 5.5.

*[Ko bomo imeli sliko/diagram poteka (nekaj podobnega kot je GFM-for-eyetracker/docs/figures/gnn_pipeline bomo tukaj referencirali funkcijo/MLP, ki računa uteži. Trenutno za placeholder pustimo f_w^{rel} .]
 [Če normalizacijo uteži prestaviš iz poglavja 5 v 6.4, dodaj tukaj kratko formulo; sicer formule ne ponavljaj.]*

6.4.3 Fuzija relacijskih predstavitev

Po posredovanju sporočil po različnih tipih povezav dobimo za vsako vozlišče eno predstavitev na relacijo. Te predstavitve združimo na ravni vozlišč s konkatencijo in MLP fuzijo v enotno predstavitev vozlišča:

$$\mathbf{h}_i = f_{\text{fuzija}} \left(\left[\mathbf{h}_i^{(t+)} \parallel \mathbf{h}_i^{(t-)} \parallel \mathbf{h}_i^{(s)} \parallel \mathbf{h}_i^{(f)} \right] \right), \quad (6.5)$$

kjer $\parallel$ označuje konkatencijo, $\mathbf{h}_i^{(t+)}$ časovno predstavitev naprej, $\mathbf{h}_i^{(t-)}$ časovno predstavitev nazaj, $\mathbf{h}_i^{(s)}$ prostorsko predstavitev in $\mathbf{h}_i^{(f)}$ fiksacijsko predstavitev.

6.4.4 Predstavitev grafa in napoved

Ker napovedujemo oznako celotnega okna, moramo predstavitve vozlišč združiti v predstavitev grafa. Uporabimo združevanje s pozornostjo:

$$\mathbf{h}_G = \sum_{v \in V} \alpha_v \mathbf{h}_v, \quad (6.6)$$

kjer je $\mathbf{h}_G$ predstavitev grafa, α_v utež pozornosti za vozlišče v , $\mathbf{h}_v$ pa predstavitev vozlišča v . S tem modelu omogočimo, da se dinamično opre na informativne dele časovnega okna, torej na informativna vozlišča. Uteži pozornosti izračunamo s softmax normalizacijo, kot je običajno pri mehki pozornosti in pozornostnem združevanju grafov [2, 9]:

$$\alpha_v = \frac{\exp(g(\mathbf{h}_v))}{\sum_{u \in V} \exp(g(\mathbf{h}_u))}, \quad (6.7)$$

kjer je g naučena funkcija, ki vozliščni predstavitvi priredi skalarno oceno pomembnosti.

Predstavitev grafa $\mathbf{h}_G$ posredujemo v napovedno glavo f_{head} , ki vrne logite za tri razrede. Pri vrednotenju logite s funkcijo softmax pretvorimo v napovedne verjetnosti, končno napoved pa določimo kot razred z največjo napovedno verjetnostjo. Valenco in vzburjenost obravnavamo kot ločeni klasifikacijski nalogi, zato za vsako nalogo učimo ločen model z enako arhitekturo. Model učimo z znano navzkrižno entropijo za trirazredno klasifikacijo:

$$\mathcal{L} = - \sum_{c=1}^3 y_c \log \hat{y}_c, \quad (6.8)$$

kjer je $\mathcal{L}$ izguba, y_c prava oznaka razreda c , $\hat{y}_c$ pa napovedana verjetnost za razred c [5].

Podrobnosti optimizacije, kot so učna stopnja, velikost mini-serij in število epoh, podamo v eksperimentalnem protokolu.

6.4.5 Stabilizacija učenja

Pri učenju uporabimo več uveljavljenih mehanizmov, ki pomagajo pri stabilnosti optimizacije in zmanjševanju prekomernega prileganja. Rezidualne povezave olajšajo pretok informacij skozi več grafovskih plasti, normalizacija plasti stabilizira porazdelitve latentnih predstavitev, aktivacija GELU uvede gladko nelinearnost, izpuščanje pa deluje kot regularizacija [6, 1, 7, 12]. Te komponente ne spreminjajo grafovskih predstavitev podatkov, temveč izboljšajo učni postopek predlagane arhitekture.

[Dodamo angleške izraze v oklepajih? Npr. izpuščanje (ang. dropout)]

Poglavje 7

Eksperimentalni protokol

7.1 Eksperimentalne naloge

7.1.1 Valenca in vzburjenost

V nalogi obravnavamo dve glavni klasifikacijski nalogi: 3-razredno klasifikacijo valence ter 3-razredno klasifikacijo vzburjenosti. Obe nalogi definiramo po preslikavi iz tabele 6 izvirnega članka podatkovne zbirke MAHNOB-HCI [11]. Razredi niso dobljeni z neposredno diskretizacijo številskih samoocen valence in vzburjenosti, temveč iz poročane čustvene oznake `emotion-id`. S tem eksperimentalni nalogi sledita izvirni formulaciji in omogočata primerjavo z objavljenimi rezultati na isti podatkovni zbirki. Za dodatno primerjavo uporabimo tudi binarni različici, pri katerih obdržimo samo oba skrajna razreda.

TODO:

- Eksperimenti: pognati glavni nalogi diplome kot 3-razredno klasifikacijo valence in 3-razredno klasifikacijo vzburjenosti, ker sta tako neposredno primerljivi z formulacijo v MAHNOB-HCI.
- Eksperimenti: pognati še binarni low/high različici valence in vzburjenosti, kjer odstranimo srednji oziroma nevtralni razred in obdržimo izrazitejša skrajna razreda.

Tabela 7.1: Preslikava čustvenih oznak v razrede valence in vzburjenosti, povzeta po tabeli 6 izvirnega članka MAHNOB-HCI [11].

Ciljna naloga	Razred	Čustvene oznake
Valenca	neprijetna (<i>unpleasant</i>)	<i>fear, anger, disgust, sadness, anxiety</i>
Valenca	nevtralna (<i>neutral</i> <i>valence</i>)	<i>neutral, surprise</i>
Valenca	prijetna (<i>pleasant</i>)	<i>joy/happiness, amusement</i>
Vzburjenost	nizka (<i>calm</i>)	<i>sadness, disgust, neutral</i>
Vzburjenost	srednja (<i>medium</i> <i>aroused</i>)	<i>joy/happiness, amusement</i>
Vzburjenost	visoka (<i>excited/activated</i>)	<i>surprise, fear, anger, anxiety</i>

TODO:

- Pisanje: v besedilu jasno ločiti glavni eksperiment od dodatnega binarnega eksperimenta; binarno formulacijo opiši kot čistejšo in lažjo dopolnilno evalvacijo, ne kot zamenjavo glavne naloge.
- Pisanje: po rezultatih preveriti, ali imena razredov v tabelah, slikah in dodatkih sledijo enaki terminologiji kot v tabeli 7.1.

7.2 Validacijska protokola

7.2.1 Prečno preverjanje z izpuščanjem enega primerka

Uporabimo dva validacijska protokola prečnega preverjanja tipa "izpusti enega" (ang. *leave-one-out*, LOO). Pri takem protokolu množico podatkov najprej razdelimo na primerke po izbrani kategoriji, na primer po subjektih ali posnetkih. V vsaki iteraciji nato en primerek izvzamemo iz množice in njegove podatke uporabimo kot testno množico, podatke ostalih primerkov pa

uporabimo za učenje oziroma jih pri nevronske modelih dodatno razdelimo na učno in validacijsko množico. Pri klasičnih modelih strojnega učenja, kot sta SVM in LightGBM, validacijske množice v osnovnem učenju ne potrebujemo, pri nevronske modelih, kot sta MLP in GNN, pa jo uporabimo za spremljanje učenja, spreminjanje hiperparametrov učenja ter zgodnje ustavljanje.

Velikost validacijske množice smo določili z `val_size=2`. Ta vrednost ustreza velikostnemu redu uporabljene podatkovne množice, ki po filtriranju vsebuje 22 subjektov in 20 posnetkov. Od testne množice se validacijska razlikuje po tem, da lahko vpliva na potek učenja oziroma izbiro modela, testna množica pa ostane namenjena samo končni oceni delovanja v posamezni iteraciji.

Uporabili smo dva validacijska protokola prečnega preverjanja tipa LOO:

- **Subject LOO:** v vsaki iteraciji so podatki enega subjekta testna množica, podatki ostalih subjektov pa so na voljo za učenje oziroma validacijo.
- **Recording LOO:** v vsaki iteraciji so podatki enega posnetka oziroma stimulusa testna množica, podatki ostalih posnetkov pa so na voljo za učenje oziroma validacijo.

Kombinirane delitve po subjektih in posnetkih v tej nalogi ne uporabljamo, ker bi bila računsko bistveno dražja in bi presegla obseg diplomske naloge.

Pred izvedbo delitev smo iz podatkov izključili subjekte P9, P12 in P15. Ti subjekti so kot problematični navedeni že v izvirnem članku podatkovne zbirke MAHNOB-HCI, zato jih izključimo tudi tukaj in s tem ohranimo boljšo primerljivost z izvirnimi rezultati. Pri oznakah uporabimo samo primere, pri katerih je vrednost stolpca `emotion-derivation-status` enaka `ok`, saj s tem odstranimo oglede posnetkov z nezanesljivo izpeljano čustveno oznako.

Pri vsaki iteraciji prečnega preverjanja standardizacijo izračunamo samo na učni množici. Tako za značilke vozlišč, značilke povezav in tabelarične značilke najprej izračunamo statistike učne množice, nato pa isto pretvorbo uporabimo še na validacijski in testni množici. S tem preprečimo uhajanje

informacij iz validacijske ali testne množice v učni postopek.

TODO:

- Eksperimenti: za glavne rezultate pognati subject LOO kot primarni validacijski protokol in recording LOO kot dodatni poročani protokol.
- Eksperimenti: kfold ne uporabljati in ne poročati kot glavni rezultat za primerjavo modelov; izjema je ablacijska študija, opisana v razdelku 7.6.

TODO:

- Pisanje: v poglavju z rezultati naj bodo glavne tabele najprej za subject LOO, nato za recording LOO; kfold naj se pojavi samo pri ablacijski študiji.
- Pisanje: jasno zapisati, da subject LOO ocenjuje posploševanje na nove udeležence, recording LOO pa posploševanje na nove posnetke oziroma stimuluse.

7.2.2 Subject LOO

Subject LOO meri posploševanje na nove udeležence. Izvedli smo ga zato, ker pri uporabi modela na novem uporabniku običajno nimamo označenih podatkov zanj. S tem protokolom ocenimo, kako dobro se naučeni vzorci prenesejo na nove subjekte in koliko so modeli občutljivi na razlike med posameznimi udeleženci.

V vsaki iteraciji je en subjekt v testni množici. Pri nevronskih modelih sta dva izmed preostalih subjektov v validacijski množici, ostalih 19 subjektov pa je v učni množici. Pri tem protokolu delimo podatke po subjektih, zato so lahko podatki vseh posnetkov prisotni v učni, validacijski in testni množici.

7.2.3 Recording LOO

Recording LOO meri posploševanje na nove posnetke oziroma stimulse. Izvedli smo ga zato, ker preverja drugačen vidik posploševanja kot Subject LOO: nov posnetek lahko povzroči drugačne vzorce pogleda, saj je pogled usmerjen na druge dele zaslona in sledi drugačnemu dogajanju. S tem preverimo, kako dobre so napovedi modelov pri novem stimulusu.

V vsaki iteraciji je en posnetek v testni množici. Pri nevronskih modelih sta dva izmed preostalih posnetkov v validacijski množici, ostalih 17 posnetkov pa je v učni množici. Pri tem protokolu delimo podatke po posnetkih, zato so lahko podatki vseh subjektov prisotni v učni, validacijski in testni množici.

7.3 Metrike

Za vsako nalogo in vsak validacijski protokol izračunamo več metrik, ker različne metrike povedo različne informacije o delovanju modela. Kot glavni metriki uporabimo točnost in macro-F1, z namenom direktne primerjave z izvirnim člankom podatkovne zbirke MAHNOB-HCI. Članek sicer ne poroča izrecno, ali uporablja navadno ali uravnoteženo točnost oziroma macro-F1 ali weighted-F1, vendar to utemeljeno sklepamo iz poročanih rezultatov naključnega klasifikatorja.

Rezultate metrik poročamo kot povprečje in standardni odklon čez iteracije prečnega preverjanja, torej v obliki $\text{mean} \pm \text{std}$.

7.4 Spremljanje učenja in diagnostika

TODO:

- Napiši, da diagnostiko učenja obravnavamo ločeno od končnih metrik vrednotenja, kot so accuracy, F1 in AUC.
- Navedi, da za nevronske modele shranjujemo učno izgubo, validacijsko izgubo, najboljšo epoho, zgodnje ustavljanje, čas epohe, trenutno stopnjo učenja in norme gradientov.
- Pojasni, da krivulji učne in validacijske izgube uporabimo za preverjanje stabilnosti optimizacije in znakov prekomernega prileganja; testno izgubo izračunamo šele po izbiri najboljšega modela.
- Za grafske modele napiši, da dodatno spremljamo varianco predstavitev grafa, povprečno kosinusno podobnost predstavitev, razpon logitov in entropijo napovednih verjetnosti.
- Pojasni namen teh GNN diagnostik: zaznavanje prekomernega glajenja, kolapsa predstavitev in skoraj konstantnih napovedi klasiﬁkacijske glave.
- Za predlagani model omeni še povzetke naučenih uteži povezav po časovnih, prostorskih in fiksacijskih relacijah.
- V glavnem besedilu poročaj samo agregirane krivulje izgub, porazdelitev najboljše epohe in ključne GNN diagnostike; podrobne grafe po gubah in relacijske porazdelitve uteži prestavi v dodatek D.

7.5 Glavna primerjava modelov

Glavna primerjava vključuje modele v tabeli 7.3. Tabela poleg imena modela povzema kratko vlogo modela v primerjavi in osnovne parametre, ki jih pri posamezni vrsti modela poročamo ali uporabljamo pri razlagi rezultatov.

[Na koncu preveri, da se vrstni red ujema z vrstnim redom v tabelah/plotih. Preveri tudi, da se ujemajo poimenovanja znotraj diplome (recimo, če si že definiral naš GNN kot X , potem uporabljal ta konsistentno v besedilu, tabelah in slikah).]

TODO:

- Eksperimenti: preveriti, da primerjava vključuje diplomski grafovski baseline **Osnovni GCN**; stare interne različice grafovskega modela ne sodijo v diplomsko primerjavo.
- Eksperimenti: za Osnovni GCN uporabiti isto grafovsko predstavitev, iste signale, ista okna, iste delitve in isto standardizacijo kot pri predlaganem GNN.
- Eksperimenti: pri Osnovnem GCN združiti relacije `temporal_forward`, `temporal_backward`, `spatial` in `fixation` v homogeni graf, odstraniti podvojene povezave ter ne uporabiti značilnk povezav ali naučenih uteži povezav.
- Eksperimenti: preveriti, da Osnovni GCN uporablja `GCNConv`, isto napovedno glavo, iste YAML hiperparametre in ločen parameter za readout; trenutni readout je `attention`, pozneje lahko preverimo še `mean`.
- Eksperimenti: preveriti, da Osnovni GCN deluje za 2- in 3-razredno klasifikacijo ter da sta `num_layers=3` in `hidden_channels=128` res uporabljena tudi pri njem.

TODO:

- Pisanje: v tabeli in besedilu uporabljaj ime Osnovni GCN.
- Pisanje: v razlagi osnovnega GCN poudari, da je to arhitekturno poenostavljen grafovski baseline, ne starejša različica predlaganega modela.

7.6 Ablacijska študija

Namen ablacijske študije je bil preveriti, koliko kateri signali prispevajo k boljšim napovedim predlaganega modela. Izhodišče je bil predlagani model iz glavne primerjave. Pri vsaki ablacijski nastavitvi smo ohranili enak validacijski protokol, enake delitve podatkov in enake hiperparametre učenja, zakrili pa smo samo eno skupino informacij (en signal).

Preverili smo štiri ablacijske nastavitve. Pri prvi smo odstranili značilke velikosti zenic. Pri drugi smo odstranili časovno informacijo, torej časovne značilke vozlišč in povezav ter časovne povezave. Pri tretji smo odstranili prostorsko informacijo, ki vključuje koordinate pogleda (x, y) , razdaljo in iz njih izpeljane prostorske povezave ter značilke povezav. Pri četrti smo odstranili informacijo o fiksacijah, torej trajanje fiksacij in fiksacijske povezave.

TODO:

- Eksperimenti: ablacijske poskuse pognati za 3-razredno valenco in 3-razredno vzburjenost.
- Eksperimenti: zaradi časovne ekonomičnosti ablacijske poskuse pognati na subject kfold, trenutno z $k = 5$, ne na polnem subject LOO.
- Eksperimenti: pripraviti ablacijske nastavitve za odstranitev časovne informacije, prostorske oziroma gaze informacije, fiksacijske informacije, zenične informacije in razdaljne informacije.
- Eksperimenti: ko odstranimo signal, odstraniti vse informacije, izpeljane iz njega: značilke vozlišč, značilke povezav in povezave.

TODO:

- Pisanje: trenutni opis štirih ablacijsko nastavitvev uskladiti s petimi skupinami signalov; razdaljo obravnavaj ločeno od prostorske/gaze informacije, če bo tako implementirana v poskusih.
- Pisanje: po pridobitvi rezultatov odločiti, ali v glavnem besedilu podrobno poročamo obe nalogi ali predvsem valenco; za vzburjenost naj bodo vsaj podporni rezultati v dodatku.
- Pisanje: v poglavju z rezultati zapisati, da so kfold in LOO rezultati dovolj primerljivi za ablacijsko analizo, ker nas zanima relativni vpliv odstranitve signalov, ne končna absolutna ocena modela.

[Morebitni dodatni poskusi naj bodo obravnavani kot ločena arhitekturna analiza, ne kot ablacijska študija vhodnih signalov: izklop uteži povezav, uporaba 5 s oken namesto 10 s oken, odstranitev MLP fuzije relacijskih predstavitev in primerjava različnih strategij združevanja grafa.]

Tabela 7.2: Metrike, uporabljene pri vrednotenju modelov.

Metrika	Definicija	Interpretacija
Accuracy	Delež pravilno razvrščenih primerov med vsemi primeri.	Ena izmed dveh glavnih metrik za primerjavo z izvirnimi rezultati na podatkovni zbirki MAHNOB-HCI.
Macro-F1	Povprečje vrednosti F1 po razredih, pri čemer ima vsak razred enako težo.	Druga glavna metrika za primerjavo z izvirnim člankom; posebej pomembna pri neuravnoteženih razredih.
Balanced accuracy	Povprečje priklica po razredih.	Enaka teža vseh razredov pri oceni uspešnosti.
Weighted-F1	Povprečje vrednosti F1 po razredih, uteženo s številom primerov v posameznem razredu.	Dodatna ocena uspešnosti glede na dejansko porazdelitev razredov.
AUC	Ločljivost razredov na podlagi napovedanih verjetnosti; pri večrazredni nalogi jo izračunamo po pristopu one-vs-rest.	Podporna informacija o ločevanju posameznih razredov.
Confusion matrix	Število in delež napovedi za vsako kombinacijo pravega in napovedanega razreda.	Razlaga tipičnih napak modela; pri prikazu je normalizirana po vrsticah.

Tabela 7.3: Modeli, vključeni v glavno primerjavo, njihova vloga in osnovni parametri.

Model	Opis	Parametri
Naključni klasifikator	Enakomerno naključno vzorčenje razreda.	<code>random_state=42</code>
Večinski klasifikator	Napoved najpogostejšega razreda učne množice.	/
SVM	Klasifikator z jedrom RBF nad agregiranimi značilkami okna.	<code>C=1.0, kernel=rbf, probability=true</code>
LightGBM	Gradientno spodbujena odločitvena drevesa nad agregiranimi značilkami okna.	<code>n_estimators=100, learning_rate=0.05, max_depth=5</code>
MLP	Polno povezana nevronska mreža nad agregiranimi značilkami okna.	<code>hidden_layers=(64,64), dropout=0.1, learning_rate=0.001, weight_decay=0.0001</code>
GazeMAE + MLP	Zamrznjen prednaučen kodirnik položajev pogleda.	<code>predstavitev z 512 razsežnostmi, hidden_layer_size=128, dropout=0.2, learning_rate=0.001</code>
Osnovni GCN	Homogeni grafovski primerjalni model z enotnim posredovanjem sporočil.	<code>GCNConv, num_layers=3, hidden_channels=128</code>
Predlagani GNN	Heterogena časovno-prostorska grafovska nevronska mreža z naučenimi utežmi povezav.	<code>GCNConv, num_layers=3, hidden_channels=128, relation_pooling=mlp, graph_pooling=attention</code>

Poglavje 8

Rezultati

TODO:

- Eksperimenti: najprej zbrati rezultate glavnih poskusov na MAHNOB-HCI za 3-razredno valenco in 3-razredno vzburjenost.
- Eksperimenti: za vsako glavno nalogo zbrati subject LOO kot glavni rezultat in recording LOO kot dodatni rezultat; kfold rezultatov ne vključuj v glavne tabele.
- Eksperimenti: zbrati še rezultate binarne low/high valence in binarne low/high vzburjenosti kot dodatna poskusa v glavnem besedilu.

TODO:

- Pisanje: rezultate poročati kot $\text{mean} \pm \text{std}$ čez gube oziroma iteracije validacijskega protokola.
- Pisanje: glavne tabele v tem poglavju naj vsebujejo samo accuracy in macro-F1; balanced accuracy, weighted-F1, AUC in podrobnejše tabele prestavi v dodatek.
- Pisanje: eSEEd_v2 rezultatov ne mešati z glavnimi tabelami; če jih ohranimo, sodijo v dodatek ali kratko motivacijsko opombo.
- Pisanje: pred oddajo uskladiti vrstni red modelov v tabelah, slikah in besedilu z vrstnim redom v poglavju 7.5.

TODO:

- Pisanje: v dodatku pripraviti razširjene tabele z balanced accuracy, weighted-F1, AUC, po potrebi še rezultati po posameznih gubah in dodatnimi matrikami zmede.
- Pisanje: preveriti strukturo dodatkov in po potrebi prenoviti dodatek z dodatnimi rezultati, da ne podvaja glavnih tabel iz tega poglavja.

8.1 Porazdelitev razredov

8.1.1 3-razredna valenca

TODO:

- Eksperimenti: iz končnega snapshot-a po tvorbi oken izračunati število in delež oken za razrede neprijetna, nevtralna in prijetna valenca.
- Eksperimenti: izračun ponoviti za podatke po izključitvi subjektov P9, P12 in P15 ter po filtriranju `emotion-derivation-status=ok`.
- Eksperimenti: preveriti in navesti uporabljeno vrednost `min_samples_per_window=60`.

TODO:

- Pisanje: poročati, ali je bil uporabljen downsampling oziroma kakšna druga obravnava neuravnoteženosti razredov.
- Pisanje: kratko povezati porazdelitev razredov z interpretacijo večinskega klasifikatorja.

8.1.2 3-razredna vzburjenost

TODO:

- Eksperimenti: iz končnega snapshot-a po tvorbi oken izračunati število in delež oken za razrede nizka, srednja in visoka vzburjenost.
- Eksperimenti: preveriti, ali je porazdelitev vzburjenosti bolj neuravnotežena ali manj usklajena s samoocenami kot porazdelitev valence.

TODO:

- Pisanje: poročati neuravnoteženost razredov in večinski klasifikator kot referenčno točko.
- Pisanje: v interpretaciji biti previden, ker je ujemanje oznak vzburjenosti s samoocenami šibkejše kot pri valenci.

8.1.3 Binarni nalogi

TODO:

- Eksperimenti: za binarno low/high valenco izračunati število in delež oken po odstranitvi srednjega oziroma nevtralnega razreda.
- Eksperimenti: za binarno low/high vzburjenost izračunati število in delež oken po odstranitvi srednjega razreda.

TODO:

- Pisanje: binarni nalogi predstaviti kot dodatno evalvacijo z izrazitejšimi razredi, ne kot glavno formulacijo naloge.

8.2 Rezultati za 3-razredno valenco

8.2.1 Subject LOO

TODO:

- Eksperimenti: pognati vse modele za 3-razredno valenco pri subject LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1 kot mean $\pm$ std.

TODO:

- Pisanje: to tabelo obravnavaj kot glavno tabelo rezultatov za valenco.
- Pisanje: po rezultatih dodati kratek komentar najboljšega modela, najboljšega negrafovskega primerjalnega modela in razlike med Osnovnim GCN ter predlaganim GNN.

Tabela 8.1: TODO: Rezultati za 3-razredno klasifikacijo valence pri subject LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

TODO:

- Slika: dodati bar plot accuracy in macro-F1 za 3-razredno valenco pri subject LOO.
- Slika: dodati vrstično normalizirano matriko zmede za najboljši model pri 3-razredni valenci; po potrebi dodati še primerjavo z najboljšim negrafovskim modelom.

8.2.2 Recording LOO

TODO:

- Eksperimenti: pognati vse modele za 3-razredno valenco pri recording LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1 kot mean $\pm$ std.

TODO:

- Pisanje: recording LOO poročaj kot dodatni rezultat, ki preverja posploševanje na nove posnetke oziroma stimuluse.

Tabela 8.2: TODO: Rezultati za 3-razredno klasifikacijo valence pri recording LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

8.2.3 Interpretacija rezultatov

TODO:

- Pisanje: interpretirati predvsem subject LOO, ker je to glavni protokol za končne rezultate.
- Pisanje: primerjati predlagani GNN z najboljšim negrafovskim primerjalnim modelom, GazeMAE + MLP in Osnovnim GCN.
- Pisanje: primerjati subject LOO in recording LOO ter opozoriti, da recording LOO še vedno deli iste subjekte med učno in testno množico.
- Pisanje: opisati najpogostejše zamenjave razredov iz matrike zmede.
- Pisanje: sklepe oblikovati previdno in jih vezati na accuracy, macro-F1 ter strukturo napak, ne samo na eno metriko.

8.3 Rezultati za 3-razredno vzburjenost

8.3.1 Subject LOO

TODO:

- Eksperimenti: pognati vse modele za 3-razredno vzburjenost pri subject LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1 kot mean $\pm$ std.

TODO:

- Pisanje: to tabelo obravnavaj kot glavno tabelo rezultatov za vzburjenost, vendar v interpretaciji upoštevaj slabše ujemanje oznak s samoocenami.

Tabela 8.3: TODO: Rezultati za 3-razredno klasifikacijo vzburjenosti pri subject LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

TODO:

- Slika: dodati bar plot accuracy in macro-F1 za 3-razredno vzburjenost pri subject LOO.
- Slika: dodati vrstično normalizirano matriko zmede za najboljši model pri 3-razredni vzburjenosti.

8.3.2 Recording LOO

TODO:

- Eksperimenti: pognati vse modele za 3-razredno vzburjenost pri recording LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1 kot mean $\pm$ std.

TODO:

- Pisanje: recording LOO poročaj kot dodatni rezultat in ga interpretiraj ločeno od subject LOO.

Tabela 8.4: TODO: Rezultati za 3-razredno klasifikacijo vzburjenosti pri recording LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

8.4 Binarna klasifikacija valence in vzburjenosti

8.4.1 Binarna valenca

TODO:

- Eksperimenti: pognati low/high valenco za subject LOO in recording LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1; podrobnejše metrike prestavi v dodatek.

TODO:

- Pisanje: pojasniti, da ta poskus odstrani nevtralni oziroma srednji razred in zato preverja čistejšo formulacijo z izrazitejšimi razredi.
- Pisanje: poročati, ali se relativni vrstni red modelov ujema s 3-razredno valenco.

Tabela 8.5: TODO: Rezultati za binarno low/high klasifikacijo valence pri subject LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

8.4.2 Binarna vzburjenost

TODO:

- Eksperimenti: pognati low/high vzburjenost za subject LOO in recording LOO.
- Eksperimenti: za vsak model zbrati accuracy in macro-F1; podrobnejše metrike prestavi v dodatek.

TODO:

- Pisanje: pojasniti, da ta poskus odstrani srednji razred vzburjenosti in preverja izrazitejši kontrast med nizko in visoko vzburjenostjo.
- Pisanje: poročati, ali binarna formulacija ublaži težave, opažene pri 3-razredni vzburjenosti.

Tabela 8.6: TODO: Rezultati za binarno low/high klasifikacijo vzburjenosti pri subject LOO.

Model	Accuracy	Macro-F1
Naključni klasifikator	TODO	TODO
Večinski klasifikator	TODO	TODO
SVM	TODO	TODO
LightGBM	TODO	TODO
MLP	TODO	TODO
GazeMAE + MLP	TODO	TODO
Osnovni GCN	TODO	TODO
Predlagani GNN	TODO	TODO

TODO:

- Pisanje: odločiti, ali recording LOO tabele za binarno valenco in vzburjenost ostanejo v glavnem besedilu ali gredo v dodatek; v glavnem besedilu naj bo vsaj kratek povzetek.

8.5 Primerjava validacijskih protokolov

8.5.1 Posploševanje na nove subjekte

TODO:

- Pisanje: povzeti subject LOO rezultate za 3-razredno valenco in vzburjenost.
- Pisanje: komentirati variance med gubami in morebitne težavne subjekte, če jih pokažejo rezultati.
- Pisanje: posebej poudariti, da je subject LOO glavni protokol za končne rezultate naloge.

8.5.2 Posploševanje na nove posnetke

TODO:

- Pisanje: povzeti recording LOO rezultate za 3-razredno valenco in vzburjenost.
- Pisanje: primerjati, ali je posploševanje na nove posnetke lažje ali težje od posploševanja na nove subjekte.
- Pisanje: opozoriti, da recording LOO lahko deli iste subjekte med učno in testno množico, zato ne meri istega vidika posploševanja kot subject LOO.

8.6 Analiza oznak in napak

8.6.1 Ujemanje oznak s samoocenami

TODO:

- Eksperimenti: uporabiti artefakte iz `label_noise_analysis` za analizo ujemanja razredov valence in vzburjenosti s samoocenami.

TODO:

- Slika: dodati label-alignment plot ali matriko zmede iz `label_noise_analysis`.
- Pisanje: razložiti, zakaj pri interpretaciji vzburjenosti pričakujemo več negotovosti kot pri valenci.

8.6.2 Matrike zmede

TODO:

- Slika: dodati matriko zmede za najboljši GNN pri 3-razredni valenci.
- Slika: dodati matriko zmede za najboljši GNN pri 3-razredni vzburjenosti.
- Slika: po potrebi dodati matriko zmede za najboljši negrafovski primerjalni model.
- Pisanje: matrike zmede naj bodo vrstično normalizirane z barvno lestvico $[0, 1]$.
- Pisanje: opisati najpogostejše zamenjave razredov in jih povezati s porazdelitvijo razredov ter analizo oznak.

8.7 Ablacijska študija

8.7.1 Vpliv vhodnih signalov in povezav

TODO:

- Eksperimenti: pognati ablacijsko študijo za 3-razredno valenco in 3-razredno vzburjenost.
- Eksperimenti: uporabiti subject kfold, trenutno $k = 5$, zaradi časovne ekonomičnosti.
- Eksperimenti: preveriti primerljivost kfold in LOO rezultatov na osnovnih konfiguracijah ter zapisati, da je primerljivost zadostna za relativno ablacijsko analizo.
- Eksperimenti: za vsako ablacijsko nastavitvev odstraniti ustrezne značilke vozlišč, značilke povezav in povezave, izpeljane iz odstranjenega signala.

TODO:

- Pisanje: v glavnem besedilu glede na rezultate verjetno podrobneje poročati valenco, vzburjenost pa povzeti ali prestaviti v dodatek.
- Slika: dodati ablation bar plot za accuracy in macro-F1.

Tabela 8.7: TODO: Ablacijska študija predlaganega modela pri 3-razredni valenci na subject kfold.

Nastavitev	Accuracy	Macro-F1
Predlagani GNN	TODO	TODO
Brez časovne informacije	TODO	TODO
Brez prostorske/gaze informacije	TODO	TODO
Brez fiksacijske informacije	TODO	TODO
Brez zenične informacije	TODO	TODO
Brez razdaljne informacije	TODO	TODO

8.8 Analiza učenja in notranjih predstavitev

8.8.1 Krivulje izgub

TODO:

- Eksperimenti: zbrati najboljšo epoho, zgodnje ustavljanje in morebitne znake nestabilnega učenja.

TODO:

- Slika: dodati train/val loss krivulje za glavne nevronske modele, posebej za Osnovni GCN in predlagani GNN.
- Pisanje: krivulje uporabiti za podporo interpretaciji rezultatov, ne kot novo glavno evalvacijo.

8.8.2 Predstavitev in grafske diagnostike

TODO:

- Eksperimenti: zbrati varianco predstavitev, povprečno kosinusno podobnost, razpon logitov in entropijo napovednih verjetnosti za grafske modele, če so artefakti na voljo.
- Eksperimenti: za predlagani GNN zbrati tudi povzetke naučenih uteži povezav po časovnih, prostorskih in fiksacijskih relacijah.

TODO:

- Pisanje: primerjati Osnovni GCN in predlagani GNN samo toliko, kolikor diagnostika pomaga razložiti glavne rezultate.
- Pisanje: podrobne grafe po gubah in relacijske porazdelitve uteži predstaviti v dodatek D.

Poglavje 9

Diskusija

9.1 Ali grafovska predstavitev pomaga?

TODO:

- ali finalni GNN premaga ne-grafovske baseline modele;
- če ne premaga: ali kaže smiselno vedenje;
- pri kateri nalogi je graf najbolj koristen;
- subject LOO vs recording LOO;
- primerjava proti GazeMAE + MLP;
- povezava z ablations;
- konservativen zaključek.

9.2 Vloga časovnih in prostorskih povezav

TODO:

- časovne povezave;
- prostorske povezave;
- fiksacijske povezave;
- forward/backward temporal separation;
- learned signed edge weights;
- distance-avg;
- fixation-duration;
- delta_distance edge feature;
- kaj to pomeni za eye-tracking signale;
- brez kavzalnih trditev.

9.3 Primerjava z GazeMAE

TODO:

- ali GazeMAE + MLP premaga baseline modele;
- ali GazeMAE + MLP premaga GNN;
- self-supervised representation learning kot uporabna smer;
- zamrznjena enkoderja position/velocity;
- 512-dim okenska predstavitev;
- omejitev: transfer baseline;
- omejitev: ne polna reprodukcija predtreniranja.

9.4 Stabilnost učenja in notranje predstavitve

TODO:

- Povzemi, ali krivulje izgub kažejo stabilno učenje ali prekomerno prileganje.
- Interpretiraj varianco in kosinusno podobnost predstavitev v povezavi s prekomernim glajenjem.
- Interpretiraj razpon logitov v povezavi z zanesljivostjo oziroma zasičenostjo napovedne glave.
- Če diagnostika ne pokaže jasnega vzorca, to napiši previdno in brez pretiranih sklepov.
- Poveži ugotovitve z arhitekturnimi odločitvami iz poglavja 6.4.5.

9.5 Primerjava z izvirnim MAHNOB-HCI pristopom

TODO:

- izvirni paper: ročno oblikovane eye-gaze značilke;
- izvirni paper: drugačen pipeline izbire značilk;
- izvirni paper: SVM;
- ta naloga: grafi iz časovnih oken surovejših signalov;
- primerjava metodološko motivacijska;
- ne neposredna reprodukcija;
- posebej omeniti uporabo `distance-avg` in fiksacijskih informacij kot približanje širšemu naboru signalov iz literature.

9.6 Omejitve

Glavne omejitve naloge so:

- uporaba ene glavne podatkovne zbirke;
- subjektivnost čustvenih oznak;
- omejitev na eye-tracking signale brez drugih fizioloških modalnosti;
- občutljivost grafovske konstrukcije na hiperparametre;
- računska zahtevnost validacije z LOO protokoli;
- možnost prekomernega glajenja v grafovskih modelih.

9.7 Možnosti nadaljnjega dela

Možne smeri nadaljnjega dela vključujejo:

- učenje povezav namesto ročne konstrukcije grafa;
- uporabo grafovskih transformerjev;
- samonadzorovano predtreniranje na neoznačenih eye-tracking signalih;
- razvoj grafovskega foundation modela za podatke pogleda;
- razširitev na večmodalne fiziološke podatke;
- evalvacijo na več podatkovnih zbirkah.

Poglavje 10

Zaključek

TODO: Zaključek napiši čisto na koncu. Struktura:

- en odstavek: kaj je bil problem;
- en odstavek: kaj si naredil;
- en odstavek: glavni rezultati;
- en odstavek: kaj rezultati pomenijo;
- en odstavek: omejitve in prihodnje delo.

V diplomski nalogi smo obravnavali uporabo grafovskih nevronske mreže za prepoznavo afektivnih stanj iz podatkov sledilnika pogleda. Časovna okna meritev smo predstavili kot časovno-prostorske grafe, v katerih vozlišča predstavljajo posamezne meritve, povezave pa časovne, prostorske in fiksacijske odnose med njimi. Predlagani pristop smo ovrednotili na podatkovni zbirki MAHNOB-HCI pri 3-razredni klasifikaciji valence in vzburjenosti.

TODO:

- najboljši model;
- ali graf pomaga glede na ne-grafovske baseline;
- ali predlagani GNN pomaga glede na Osnovni GCN in ne-grafovske primerjalne modele;
- vloga časovnih povezav;
- vloga prostorskih povezav;
- vloga fiksacijskih povezav;
- vloga naučenih predznačenih uteži;
- glavna omejitev;
- najbolj smiselna smer nadaljnjega dela.

Dodatek A

Dodatni rezultati

TODO: Sem dodaj dodatne tabele po foldih, rezultate manj pomembnih modelov in rezultate, ki niso šli v glavno besedilo.

Dodatek B

Hiperparametri

TODO:

- tabela hiperparametrov za baseline modele;
- tabela hiperparametrov za GazeMAE + MLP;
- tabela hiperparametrov za Osnovni GCN;
- tabela hiperparametrov za predlagani GNN;
- predlagani GNN: `GCNConv`, `hidden_channels=128`, `num_layers=3`;
- predlagani GNN: `relation_pooling=mlp`, `graph_pooling=attention`;
- Osnovni GCN: uporabljeni isti splošni parametri kot pri predlaganem GNN; posebej navesti readout funkcijo;
- trenutni graf: `kt=2`, `ks=2`, `fixation_dilation_k=3`;
- trenutne edge značilke: `use_delta_distance_edge_feature=true`;
- trenutni trening: učna stopnja $5 \cdot 10^{-5}$, velikost mini-serije 256, največ 500 epoh, potrpežljivost 20;
- finalni config path;
- search space, če bo uporabljen;
- opomba, če kaj ni bilo sistematično tunano.

Dodatek C

Dodatne vizualizacije grafov

TODO:

- primer 10 s grafa;
- berljiv primer 2 s ali 5 s grafa;
- vizualizacija `temporal_forward` povezav;
- vizualizacija `temporal_backward` povezav;
- vizualizacija `spatial` povezav;
- vizualizacija `fixation` povezav;
- prikaz prekrivanja relacij med istimi pari vozlišč s krivljenimi povezavami;
- vozlišča po koordinatah `x-avg/y-avg`;
- velikost vozlišč po povprečni velikosti zenice;
- lokalne oznake vozlišč od 0 naprej;
- robovi različnih barv po relacijah.

Dodatek D

Diagnostika predstavitev modela

TODO: Dodaj variance po plasteh, kosinusne podobnosti, logit distributions in dodatne slike kolapsa predstavitev.

Dodatek E

Zgodovinski poskusi na eSEEd_v2

TODO: Če želiš ohraniti eSEEd_v2 rezultate, jih daj sem: kratka motivacija, glavne težave, zakaj ni glavni dataset, brez pretiranega širjenja glavne zgodbe.

Literatura

- [1] Jimmy Lei Ba, Jamie Ryan Kiros in Geoffrey E. Hinton. „Layer Normalization“. V: *arXiv preprint arXiv:1607.06450* (2016). URL: <https://arxiv.org/abs/1607.06450>.
- [2] Dzmitry Bahdanau, Kyunghyun Cho in Yoshua Bengio. „Neural Machine Translation by Jointly Learning to Align and Translate“. V: *International Conference on Learning Representations*. 2015. URL: <https://arxiv.org/abs/1409.0473>.
- [3] Louise Gillian C. Bautista in Prospero C. Naval. „GazeMAE: General Representations of Eye Movements Using a Micro-Macro Autoencoder“. V: *2020 25th International Conference on Pattern Recognition (ICPR)*. IEEE, 2021, str. 7004–7011. DOI: 10.1109/ICPR48806.2021.9412761.
- [4] Justin Gilmer in sod. „Neural Message Passing for Quantum Chemistry“. V: *Proceedings of the 34th International Conference on Machine Learning*. Zv. 70. Proceedings of Machine Learning Research. PMLR, 2017, str. 1263–1272.
- [5] Ian Goodfellow, Yoshua Bengio in Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [6] Kaiming He in sod. „Deep Residual Learning for Image Recognition“. V: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016, str. 770–778. DOI: 10.1109/CVPR.2016.90.

- [7] Dan Hendrycks in Kevin Gimpel. „Gaussian Error Linear Units (GELUs)“. V: *arXiv preprint arXiv:1606.08415* (2016). URL: <https://arxiv.org/abs/1606.08415>.
- [8] Thomas N. Kipf in Max Welling. „Semi-Supervised Classification with Graph Convolutional Networks“. V: *International Conference on Learning Representations*. 2017. URL: <https://openreview.net/forum?id=SJU4ayYgl>.
- [9] Yujia Li in sod. „Gated Graph Sequence Neural Networks“. V: *International Conference on Learning Representations*. 2016. URL: <https://arxiv.org/abs/1511.05493>.
- [10] Jia Zheng Lim, James Mountstephens in Jason Teo. „Emotion Recognition Using Eye-Tracking: Taxonomy, Review and Current Challenges“. V: *Sensors* 20.8 (2020), str. 2384. DOI: 10.3390/s20082384.
- [11] Mohammad Soleymani in sod. „A Multimodal Database for Affect Recognition and Implicit Tagging“. V: *IEEE Transactions on Affective Computing* 3.1 (2012), str. 42–55. DOI: 10.1109/T-AFFC.2011.25.
- [12] Nitish Srivastava in sod. „Dropout: A Simple Way to Prevent Neural Networks from Overfitting“. V: *Journal of Machine Learning Research* 15.56 (2014), str. 1929–1958. URL: <http://jmlr.org/papers/v15/srivastava14a.html>.
- [13] Paweł Tarnowski in sod. „Eye-Tracking Analysis for Emotion Recognition“. V: *Computational Intelligence and Neuroscience 2020* (2020), str. 2909267. DOI: 10.1155/2020/2909267.
- [14] Petar Veličković in sod. „Graph Attention Networks“. V: *International Conference on Learning Representations*. 2018. URL: <https://openreview.net/forum?id=rJXMpikCZ>.
- [15] Bing Yu, Haoteng Yin in Zhanxing Zhu. „Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting“. V: *Proceedings of the Twenty-Seventh International Joint Conference*

on Artificial Intelligence. International Joint Conferences on Artificial Intelligence Organization, 2018, str. 3634–3640. DOI: 10.24963/ijcai.2018/505.