

UNIVERZA V LJUBLJANI
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO

Tomi Božak

**Grafovska nevronska mreža za
prepoznavo čustev iz sledilnika pogleda**

DIPLOMSKO DELO

UNIVERZITETNI ŠTUDIJSKI PROGRAM
PRVE STOPNJE
RAČUNALNIŠTVO IN INFORMATIKA

MENTOR: TODO
SOMENTOR: TODO

Ljubljana, 2026

To delo je ponujeno pod licenco *Creative Commons Priznanje avtorstva-Deljenje pod enakimi pogoji 2.5 Slovenija* (ali novejšo različico). To pomeni, da se tako besedilo, slike, grafi in druge sestavine dela kot tudi rezultati diplomskega dela lahko prosto distribuirajo, reproducirajo, uporabljajo, priobčujejo javnosti in predelujejo, pod pogojem, da se jasno in vidno navede avtorja in naslov tega dela in da se v primeru spremembe, preoblikovanja ali uporabe tega dela v svojem delu, lahko distribuira predelava le pod licenco, ki je enaka tej. Podrobnosti licence so dostopne na spletni strani creativecommons.si ali na Inštitutu za intelektualno lastnino, Streliška 1, 1000 Ljubljana.



Izvorna koda diplomskega dela, njeni rezultati in v ta namen razvita programska oprema je ponujena pod licenco GNU General Public License, različica 3 (ali novejša). To pomeni, da se lahko prosto distribuira in/ali predeluje pod njenimi pogoji. Podrobnosti licence so dostopne na spletni strani <http://www.gnu.org/licenses/>.

Besedilo je oblikovano z urejevalnikom besedil L^AT_EX.

Kandidat: Tomi Božak

Naslov: Grafovska nevronska mreža za prepoznavo čustev iz sledilnika pogleda

Vrsta naloge: Diplomaska naloga na univerzitetnem programu prve stopnje

Mentor: TODO

Somentor: TODO

Opis:

TODO: Besedilo teme diplomskega dela prepisi iz študijskega informacijskega sistema.

Title: Graph Neural Network for Emotion Recognition from Eye-Tracking Data

Description:

TODO: Prevedi uradni opis teme diplomskega dela iz STUDIS-a.

TODO: Zahvalo napiši ali odstrani pred oddajo.

TODO: Posvetilo lahko odstraniš, če ga ne
želiš.

Kazalo

Povzetek

Abstract

Razširjeni povzetek	1
1 Uvod	3
1.1 Motivacija	4
1.1.1 Verzija 1: poudarek na GNN	4
1.1.2 Verzija 2: aplikacijsko usmerjeno	4
1.2 Raziskovalni problem	5
1.3 Raziskovalna vprašanja	5
1.4 Doprinosi naloge	6
1.5 Struktura naloge	7
2 Teoretično ozadje	9
2.1 Grafi	9
2.1.1 Osnovna definicija grafa	9
2.1.2 Usmerjeni, uteženi in heterogeni grafi	10
2.2 Grafske nevronske mreže	10
2.2.1 Posredovanje sporočil	10
2.2.2 Klasifikacija na ravni grafa	11
2.2.3 Prekomerno glajenje in kolaps predstavitev	11
2.3 Podatki sledilnika pogleda	12

2.3.1	Merjeni signali	12
2.3.2	Časovna narava signala	12
2.4	Čustvena stanja: valenca in vzburjenost	13
2.4.1	Dimenzijski opis čustev	13
2.4.2	3-razredna klasifikacija	13
3	Sorodna dela	15
3.1	Prepoznavanje čustev iz podatkov sledilnika pogleda	15
3.1.1	Ročno oblikovane značilke	15
3.1.2	Naučene predstavitve	16
3.2	Podatkovna zbirka MAHNOB-HCI	16
3.2.1	Izvirni protokol za valenco in vzburjenost	16
3.2.2	Razlika do naše eksperimentalne postavitve	16
3.3	Grafovske nevronske mreže za časovno-prostorske podatke . .	17
3.3.1	Uporaba na oknih podatkov pogleda	17
3.4	Učenje predstavitev iz podatkov pogleda in GazeMAE	17
3.4.1	GazeMAE	18
3.5	Položaj te naloge glede na sorodna dela	18
4	Podatki in predobdelava	19
4.1	Podatkovna zbirka MAHNOB-HCI	19
4.1.1	Izvirna zbirka	19
4.1.2	Lokalni podnabor	20
4.2	Ciljne oznake	20
4.2.1	Izvor čustvenih oznak	20
4.2.2	Preslikava v razrede valence in vzburjenosti	20
4.3	Priprava vhodnih signalov	21
4.3.1	Uporabljeni stolpci	21
4.3.2	Čiščenje in filtriranje podatkov	22
4.4	Normalizacija	22
4.4.1	Normalizacija pri grafovskih modelih	22
4.4.2	Normalizacija pri tabelaričnih modelih	23

4.4.3	Preprečevanje uhajanja informacij	23
4.5	Segmentacija v časovna okna	23
4.5.1	Dolžina okna	23
4.5.2	Dodelitev oznake oknu	23
4.5.3	Minimalno število vzorcev	23
4.6	Predhodni poskus z zbirko eSEEd_v2	24
5	Grafovski predstavitev podatkov sledilnika pogleda	27
5.1	Učni vzorec kot graf	27
5.1.1	Definicija grafa	27
5.1.2	Oznaka grafa	28
5.2	Vozlišča	28
5.2.1	Definicija vozlišča	28
5.2.2	Značilke vozlišč	28
5.3	Povezave	29
5.3.1	Časovne povezave	29
5.3.2	Prostorske povezave	30
5.3.3	Fiksacijske povezave	30
5.4	Uteži povezav	31
5.4.1	Značilke povezav	31
5.4.2	Normalizacija uteži	31
5.5	Heterogena grafovski predstavitev	31
5.5.1	Tipi relacij	31
5.5.2	Zakaj ločimo relacije	32
5.6	Statistika grafov	32
5.6.1	Število vozlišč in povezav	32
5.6.2	Računska zahtevnost	32
6	Modeli	33
6.1	Ne-grafovski osnovni modeli	33
6.1.1	Primerjani modeli	33
6.2	GazeMAE + MLP	34

6.2.1	Procesna veriga	34
6.3	Grafovski osnovni modeli	34
6.3.1	GCN	34
6.3.2	GAT	34
6.4	Predlagani prostorsko-časovni heterogeni GNN	35
6.4.1	Pregled arhitekture	35
6.4.2	Fuzija prostorskih in časovnih predstavitev	35
6.4.3	Združevanje v predstavitev grafa	35
6.4.4	Napovedna glava in učenje	36
6.4.5	Diagnostika predstavitev	36
7	Eksperimentalni protokol	37
7.1	Eksperimentalne naloge	37
7.1.1	Valenca in vzburjenost	37
7.2	Validacijska protokola	37
7.2.1	Definicija protokolov	37
7.2.2	Razlika med protokoloma	38
7.3	Metrike	38
7.3.1	Zbrane metrike	38
7.4	Glavna primerjava modelov	39
7.4.1	Primerjani modeli	39
7.5	Ablacijska študija	39
7.5.1	Predvidene ablacijske nastavitve	39
8	Rezultati	41
8.1	Porazdelitev razredov	41
8.1.1	Valenca	41
8.1.2	Vzburjenost	41
8.2	Rezultati za 3-razredno valenco	42
8.2.1	Subject LOO	42
8.2.2	Recording LOO	42
8.2.3	Interpretacija rezultatov	43

8.3	Rezultati za 3-razredno vzburjenje	43
8.3.1	Subject LOO	43
8.3.2	Recording LOO	44
8.4	Primerjava validacijskih protokolov	44
8.4.1	Posploševanje na nove subjekte	44
8.4.2	Posploševanje na nove posnetke	44
8.5	Ablacijska študija	45
8.5.1	Vpliv vhodnih signalov in povezav	45
8.6	Analiza notranjih predstavitev modela	45
8.6.1	Varianca in podobnost predstavitev	45
8.7	Analiza napak	45
8.7.1	Matrike zmede	45
9	Diskusija	47
9.1	Ali grafovska predstavitev pomaga?	47
9.2	Vloga časovnih in prostorskih povezav	47
9.3	Primerjava z GazeMAE	47
9.4	Primerjava z izvirnim MAHNOB-HCI pristopom	48
9.5	Omejitve	48
9.6	Možnosti nadaljnjega dela	48
10	Zaključek	49
A	Dodatni rezultati	51
B	Hiperparametri	53
C	Dodatne vizualizacije grafov	55
D	Diagnostika predstavitev modela	57
E	Zgodovinski poskusi na eSEEd_v2	59
	Literatura	61

Seznam uporabljenih kratic

kratica	angleško	slovensko
AUC	area under the curve	ploščina pod krivuljo
F1	F1 score	mera F1
GAT	graph attention network	grafovska pozornostna mreža
GCN	graph convolutional network	grafovska konvolucijska mreža
GFM	graph foundation model	grafovski temeljni model
GNN	graph neural network	grafovska nevronska mreža
LOO	leave-one-out	izpusti enega
LORO	leave-one-recording-out	izpusti en posnetek
LOSO	leave-one-subject-out	izpusti en subjekt
MLP	multilayer perceptron	večslojni perceptron
SVM	support vector machine	metoda podpornih vektorjev

Povzetek

Naslov: Grafovska nevronska mreža za prepoznavo čustev iz sledilnika pogleda

Avtor: Tomi Božak

V diplomski nalogi raziskujemo uporabo grafovskih nevronskih mrež za prepoznavo afektivnih stanj iz podatkov sledilnika pogleda. Osrednji metodološki problem je predstavitev časovnega okna meritev pogleda kot prostorsko-časovnega grafa, v katerem vozlišča predstavljajo posamezne meritve, povezave pa opisujejo časovno in prostorsko bližino med njimi. Na takšni predstavitvi razvijemo in ovrednotimo grafovski model za večrazredno klasifikacijo valence in vznburjenja.

Eksperimentalno evalvacijo izvedemo na podatkovni zbirki MAHNOB-HCI z dvema validacijskima protokoloma: delitvijo po subjektih in delitvijo po posnetkih. Grafovske modele primerjamo z ne-grafovskimi modeli strojnega učenja ter s predstavitvijo GazeMAE kot predstavnikom sodobnih metod učenja predstavitev iz podatkov pogleda. Poleg končnih klasifikacijskih rezultatov analiziramo tudi vpliv posameznih komponent grafovske konstrukcije, vključno s časovnimi povezavami, prostorskimi povezavami, značilkami zenice in utežmi povezav.

Glavno raziskovalno vprašanje naloge je, ali lahko prostorsko-časovna grafovska predstavitev eye-tracking oken izboljša klasifikacijo afektivnih stanj v primerjavi z ne-grafovskimi modeli na enakih vhodnih oknih.

Ključne besede: grafovske nevronske mreže, prostorsko-časovni grafi, sledil-

nik pogleda, prepoznavanje čustev, afektivno računalništvo, strojno učenje.

Abstract

Title: Graph Neural Network for Emotion Recognition from Eye-Tracking Data

Author: Tomi Božak

This thesis investigates the use of graph neural networks for affective state recognition from eye-tracking data. The central methodological problem is the representation of a temporal window of gaze measurements as a spatio-temporal graph, where nodes correspond to individual samples and edges encode temporal and spatial proximity between them. Based on this representation, we develop and evaluate a graph-based model for three-class classification of valence and arousal.

The experimental evaluation is performed on the MAHNOB-HCI dataset using two validation protocols: leave-one-subject-out and leave-one-recording-out evaluation. Graph-based models are compared against non-graph machine learning baselines and against GazeMAE as a representative of modern gaze representation learning methods. In addition to final classification performance, we analyze the contribution of individual components of the graph construction, including temporal edges, spatial edges, pupil features, and edge weights.

The main research question of the thesis is whether a spatio-temporal graph representation of eye-tracking windows can improve affective state classification compared to non-graph models trained on the same input windows.

Keywords: graph neural networks, spatio-temporal graphs, eye tracking, emotion recognition, affective computing, machine learning.

Razširjeni povzetek

TODO: To poglavje napiši na koncu, ko bodo znani rezultati. Struktura naj bo podobna raziskovalnemu članku:

- motivacija: zakaj grafovska predstavitev podatkov sledilnika pogleda;
- predlagana metoda: kako iz časovnih oken nastanejo grafi;
- eksperimentalni protokol: MAHNOB-HCI, 3-razredna valenca/vzburljenje, subject LOO in recording LOO;
- rezultati: primerjava z baseline modeli, GazeMAE in GNN arhitekturami;
- sklep: kaj grafovska predstavitev prispeva in kje so omejitve.

I Grafovske nevronske mreže in motivacija

TODO: Kratko povzemi, kaj so grafovske nevronske mreže, zakaj so primerne za podatke z relacijsko, prostorsko ali časovno strukturo in zakaj je eye-tracking okno smiselno obravnavati kot prostorsko-časovni graf.

II Grafovska predstavitev podatkov sledilnika pogleda

TODO: Kratko povzemi: vozlišče = ena meritev sledilnika pogleda; značilke vozlišča = koordinate pogleda in velikosti zenic; časovne povezave = bližina vzorcev v času; prostorske povezave = bližina vzorcev v prostoru pogleda; uteži povezav kot del modela.

III Modeliranje in eksperimentalna evalvacija

TODO: Kratko povzemi uporabljeno podatkovno zbirko MAHNOB-HCI, nalogi 3-class valence in 3-class arousal, validacijo subject LOO in recording LOO ter primerjane modele: SVM, LightGBM, MLP, GazeMAE + MLP, GCN, GAT in finalni heterogeni GNN.

IV Rezultati in sklep

TODO: Dopolni po zaključku eksperimentov: kateri model je najboljši pri valenci, kateri pri vzburjenju, ali GNN izboljša rezultate glede na ne-grafovske baseline modele, katere komponente grafa najbolj prispevajo k rezultatu ter glavne omejitve in prihodnje delo.

Poglavje 1

Uvod

Prepoznavanje čustev oziroma afektivnih stanj iz fizioloških in vedenjskih signalov je pomemben problem na področju afektivnega računalništva. Med možnimi viri podatkov je tudi sledilnik pogleda, ki omogoča merjenje položaja pogleda, dinamike premikanja oči in velikosti zenic. Ti signali so časovno odvisni in lahko vsebujejo informacije o pozornosti, kognitivni obremenitvi in čustvenem stanju udeleženca.

V tej diplomski nalogi se osredotočamo na grafovsko modeliranje podatkov sledilnika pogleda. Namesto da časovno okno meritev obravnavamo zgolj kot tabelaričen niz ali vektor agregiranih značilk, ga predstavimo kot prostorsko-časovni graf. V takem grafu posamezne meritve predstavljajo vozlišča, povezave pa opisujejo odnose med meritvami. Časovne povezave povezujejo meritve, ki so si blizu v času, prostorske povezave pa meritve, ki so si blizu v prostoru pogleda.

Osrednje raziskovalno vprašanje naloge je:

Ali lahko prostorsko-časovna grafovsko predstavitev podatkov sledilnika pogleda izboljša klasifikacijo čustvenih stanj v primerjavi z ne-grafovskimi modeli na enakih vhodnih podatkih?

Nalogo obravnavamo kot problem nadzorovane klasifikacije grafov. Vsako časovno okno podatkov sledilnika pogleda pretvorimo v graf, model pa napove

čustveno oznako pripadajočega okna. Glavni ciljni nalogi sta 3-razredna klasifikacija valence in 3-razredna klasifikacija vznburjenja na podatkovni zbirki MAHNOB-HCI.

1.1 Motivacija

TODO: Izberi in uredi eno končno verzijo motivacije. Spodaj sta ohranjeni dve delovni verziji iz Overleafa.

1.1.1 Verzija 1: poudarek na GNN

Podatki sledilnika pogleda so časovna vrsta prostorskih meritev: vsak vzorec vsebuje položaj pogleda, velikost zenice in časovni žig. Pri prepoznavi čustvenih stanj se takšni podatki pogosto pretvorijo v tabelarične značilke na ravni časovnega okna, na primer v povprečja, standardne odklone, statistike fiksacij, dolžine poti pogleda in agregirane značilke zenice [4, 6]. Takšen pristop poenostavi modeliranje, vendar hkrati zabriše zaporedje meritev, lokalne prehode pogleda in prostorske odnose med točkami pogleda.

Osrednja motivacija te naloge je zato metodološka: preveriti želimo, ali je mogoče časovno okno podatkov sledilnika pogleda predstaviti kot časovno-prostorski graf in ga obdelati z grafovsko nevronske mrežo. V predlagani predstavitvi posamezne meritve ostanejo eksplicitno prisotne kot vozlišča, povezave pa kodirajo časovno zaporedje in prostorsko bližino med meritvami. Takšna predstavitev omogoča, da model sklepa neposredno iz strukture gibanja pogleda in sprememb velikosti zenice, namesto da bi uporabljal le vnaprej agregirane statistike.

1.1.2 Verzija 2: aplikacijsko usmerjeno

Prepoznavna čustvenih stanj iz človekovih fizioloških in vedenjskih odzivov je pomemben problem afektivnega računalništva, saj omogoča razvoj sistemov, ki se lahko prilagajajo uporabnikovemu stanju [5, 4]. Pri tem se pogosto

uporabljajo kontaktni fiziološki podatki, kot so elektroencefalografija, elektrokardiografija, variabilnost srčnega utripa in elektrodermalna aktivnost, vendar njihova uporaba zahteva namensko namestitev senzorjev in je zato manj primerna za nevsiljive interakcijske sisteme [5]. Sledilnik pogleda predstavlja manj obremenjujoč vir podatkov, saj meri gibanje pogleda in velikost zenice, ki sta povezana s pozornostjo, kognitivno obremenitvijo in čustvenimi odzivi [4, 6]. V tej nalogi zato obravnavamo podatke sledilnika pogleda kot časovno-prostorske grafe, kjer posamezne meritve predstavljajo vozlišča, povezave pa opisujejo časovne prehode in prostorsko bližino pogleda.

1.2 Raziskovalni problem

Raziskovalni problem naloge je zasnova, implementacija in ovrednotenje grafovskih predstavitev podatkov sledilnika pogleda za klasifikacijo čustvenih stanj. Pri tem nas zanimata dva vidika. Prvi je predstavitevni: kako iz zaporedja meritev zgraditi graf, ki smiselno odraža časovne in prostorske odnose v signalu. Drugi je modelni: ali lahko grafovska nevronska mreža takšno predstavitev izkoristi bolje kot ne-grafovski modeli, ki uporabljajo enaka vhodna okna.

1.3 Raziskovalna vprašanja

Glavno raziskovalno vprašanje je:

RV1: Ali lahko prostorsko-časovna grafovska predstavitev podatkov sledilnika pogleda izboljša klasifikacijo čustvenih stanj v primerjavi z ne-grafovskimi modeli na enakih vhodnih oknih?

Dodatna podvprašanja so:

PV1: Kako podatke sledilnika pogleda predstaviti kot prostorsko-časovni graf?

- PV2:** Kakšen je vpliv časovnih povezav, prostorskih povezav, uteži povezav, informacije o velikosti zenice in informacije smeri pogleda na uspešnost modela?
- PV3:** Katere komponente končnega modela statistično značilno izboljšajo rezultate inference?
- PV4:** Kako se grafovski modeli primerjajo s klasičnimi modeli strojnega učenja in predstavnikom SOTA?
- PV5:** Kako se rezultati razlikujejo med delitvijo po subjektih in delitvijo po posnetkih?
- PV6:** Kako se napovedna uspešnost modelov razlikuje med 3-razredno klasifikacijo valence in 3-razredno klasifikacijo vzburjenosti?

1.4 Doprinosi naloge

Glavni doprinosi diplomske naloge so:

1. zasnova prostorsko-časovne grafovske predstavitve podatkov sledilnika pogleda;
2. implementacija heterogene časovno-prostorske grafovske nevronske mreže za 3-razredno klasifikacijo valence in vzburjenja;
3. primerjava grafovskih modelov z ne-grafovskimi modeli na enakih vhodnih oknih;
4. vključitev GazeMAE + MLP kot primerjave s sodobnim pristopom učenja predstavitev iz podatkov pogleda;
5. evalvacija z dvema validacijskima protokoloma: subject LOO in recording LOO;
6. ablacijska analiza vpliva ključnih komponent grafovske konstrukcije.

TODO: Ko bodo rezultati znani, prispevke po potrebi preformuliraj iz “implementirali smo” v bolj vsebinske trditve.

1.5 Struktura naloge

V poglavju 2 predstavimo teoretično ozadje grafov, grafovskih nevronske mreže, podatkov sledilnika pogleda in afektivnega računalništva. V poglavju 3 predstavimo sorodna dela, vključno z uporabo podatkovne zbirke MAHNOB-HCI in metodami učenja predstavitev iz podatkov pogleda. Poglavje 4 opisuje uporabljene podatke, ciljne oznake in predobdelavo. V poglavju 5 opišemo konstrukcijo prostorsko-časovnega grafa. Poglavje 6 predstavi uporabljene modele. V poglavju 7 opišemo eksperimentalni protokol, v poglavju 8 pa rezultate in ablacijsko študijo. Poglavje 9 vsebuje interpretacijo rezultatov, omejitve in možnosti nadaljnjega dela. Nalogo sklenemo v poglavju 10.

Poglavje 2

Teoretično ozadje

To poglavje predstavi metodološke pojme, ki so potrebni za razumevanje predlaganega pristopa. Najprej uvedemo grafe in grafske nevronske mreže, nato opišemo klasifikacijo na ravni grafa in pojav prekomernega glajenja. Na koncu povzamemo osnovne lastnosti podatkov sledilnika pogleda ter ciljni oznaki valence in vznburjenosti. Psihološko ozadje čustev obravnavamo le v obsegu, ki je potreben za razumevanje klasifikacijske naloge.

2.1 Grafi

2.1.1 Osnovna definicija grafa

Graf definiramo kot

$$G = (V, E), \quad (2.1)$$

kjer je V množica vozlišč, $E \subseteq V \times V$ pa množica povezav med vozlišči. Vozlišča imajo lahko značilke, ki jih zapišemo v matriko

$$X \in \mathbb{R}^{|V| \times d}, \quad (2.2)$$

kjer je d število značilk posameznega vozlišča. Povezavo med vozliščema i in j označimo z $e_{ij} \in E$.

2.1.2 Usmerjeni, uteženi in heterogeni grafi

V usmerjenih grafih ima povezava določeno izvorno in ponorno vozlišče, zato velja $e_{ij} \neq e_{ji}$. V neusmerjenih grafih povezave nimajo smeri, zato velja $e_{ij} = e_{ji}$.

Povezave lahko vsebujejo tudi uteži ali dodatne značilke. Utež povezave med vozliščema i in j označimo z w_{ij} . Za neutežene povezave si lahko predstavljamo, da imajo utež $w_{ij} = 1$. Če imajo povezave več značilk, jih zapišemo kot vektor $\mathbf{e}_{ij}$ [2].

Homogeni in heterogeni grafi

Homogeni graf je graf, ki ne loči različnih vrst vozlišč ali povezav. Heterogeni graf vsebuje vsaj dve različni vrsti vozlišč ali povezav. V tej nalogi uporabljamo heterogeno grafovsko predstavitev, saj ločimo vsaj dva tipa povezav: časovne povezave in prostorske povezave.

2.2 Grafovske nevronske mreže

Grafovske nevronske mreže so razred nevronskih mrež, namenjen učenju nad podatki, ki jih naravno predstavimo z grafom [2, 3, 7]. Graf zapišemo kot $G = (V, E)$, kjer je V množica vozlišč, E pa množica povezav med njimi. Vozlišča lahko vsebujejo značilke $\mathbf{x}_v$, povezave pa dodatne značilke $\mathbf{e}_{uv}$, ki opisujejo odnos med vozliščema u in v . Cilj GNN je naučiti se predstavitev vozlišč, povezav ali celotnega grafa tako, da model pri izračunu predstavitve posameznega vozlišča upošteva tudi njegovo lokalno okolico.

2.2.1 Posredovanje sporočil

Osnovna ideja GNN je *posredovanje sporočil* [2]. Vsako vozlišče v posamezni plasti prejme informacije od svojih sosedov, jih agregira in na podlagi zbranih informacij posodobi svojo predstavitev.

Splošna oblika plasti

Splošno plast posredovanja sporočil lahko zapišemo kot

$$\mathbf{h}_v^{(k)} = \phi^{(k)} \left(\mathbf{h}_v^{(k-1)}, \bigoplus_{u \in \mathcal{N}(v)} \psi^{(k)}(\mathbf{h}_v^{(k-1)}, \mathbf{h}_u^{(k-1)}, \mathbf{e}_{uv}) \right), \quad (2.3)$$

kjer je $\mathcal{N}(v)$ množica sosedov vozlišča v , $\psi^{(k)}$ funkcija sporočila, $\oplus$ agregacijska funkcija, $\phi^{(k)}$ funkcija posodobitve, $\mathbf{h}_v^{(k)}$ pa predstavitev vozlišča v v plasti k .

Agregacijska funkcija

Agregacijska funkcija mora biti praviloma invariantna na vrstni red sosedov, saj graf nima naravne ureditve vozlišč. Zato se pogosto uporabljajo operacije, kot so vsota, povprečje ali maksimum. Ta lastnost omogoča, da ista GNN plast deluje na grafih različnih velikosti.

2.2.2 Klasifikacija na ravni grafa

Ker želimo napovedati oznako celotnega časovnega okna, nalogo obravnavamo kot klasifikacijo grafa. Po več plasteh grafovske nevronske mreže dobimo predstavitve vozlišč $\mathbf{h}_v^{(K)}$, ki jih združimo v predstavitev celotnega grafa:

$$\mathbf{h}_G = \text{READOUT}(\{\mathbf{h}_v^{(K)} : v \in V\}). \quad (2.4)$$

Funkcija READOUT je agregacijska funkcija na ravni grafa. Pogoste izbire so povprečje, vsota, maksimum ali združevanje s pozornostjo. Predstavitev grafa $\mathbf{h}_G$ nato uporabimo v klasifikacijski glavi, ki napove razred celotnega grafa.

2.2.3 Prekomerno glajenje in kolaps predstavitev

Pri grafovskih nevronskih mrežah lahko več zaporednih agregacij povzroči, da si predstavitve vozlišč postanejo preveč podobne. Ta pojav imenujemo prekomerno glajenje. V praksi se lahko pokaže kot zmanjšanje variance

predstavitev, visoka medsebojna podobnost vozliščnih vektorjev in skoraj konstantni izhodi klasifikacijske glave.

Zato med treniranjem in evalvacijo modelov spremljamo statistike predstavitev na različnih delih modela. Varianca predstavitev kaže, ali model še ohranja razlike med vozlišči in grafi. Kosinusna podobnost pokaže, ali predstavitev postajajo usmerjene v podobno smer. Razpon logitov pa pokaže, ali klasifikacijska glava proizvaja dovolj raznolike napovedi ali se približuje skoraj konstantnemu izhodu.

2.3 Podatki sledilnika pogleda

2.3.1 Merjeni signali

Sledilnik pogleda je naprava, ki meri, kam v prostoru ali na zaslonu oseba usmerja pogled. Poleg lokacije pogleda lahko meri tudi velikost zenic. Meritve se izvajajo zaporedno z določeno vzorčno frekvenco, ki je odvisna od zmogljivosti naprave in namena uporabe. Pogoste vzorčne frekvence raziskovalnih sledilnikov pogleda so 60 Hz, 100 Hz, 500 Hz in 1000 Hz [4, 6].

2.3.2 Časovna narava signala

Lokacija pogleda se običajno zapiše v obliki koordinat (x, y) . Velikost zenice označuje njen premer in se običajno zapiše kot skalar. Podatke sledilnika pogleda obravnavamo kot časovno vrsto meritev pogleda in velikosti zenic. Takšni podatki so primerni za grafovsko obravnavo, saj lahko posamezne meritve v časovnem oknu predstavimo kot vozlišča, povezave pa določimo glede na časovno ali prostorsko bližino lokacij pogleda.

2.4 Čustvena stanja: valenca in vzburjenost

2.4.1 Dimenzijski opis čustev

Čustvena stanja pogosto opisujemo z dimenzijama valence in vzburjenosti. Valenca opisuje prijetnost oziroma neprijetnost čustvenega odziva, vzburjenost pa stopnjo aktivacije odziva [5].

2.4.2 3-razredna klasifikacija

V tej nalogi valenco in vzburjenost obravnavamo kot dve ločeni 3-razredni klasifikacijski nalogi. Takšna formulacija omogoča primerjavo z izhodiščnim člankom podatkovne zbirke MAHNOB-HCI, kjer so avtorji prav tako poročali rezultate za 3-razredno klasifikacijo valence in vzburjenosti [5]. Razredi niso tvorjeni z neposrednim rezanjem številskih ocen valence in vzburjenosti, temveč iz poročane čustvene oznake posnetka.

Pri vzburjenosti uporabimo tri razrede: nizka, srednja in visoka vzburjenost. V razred nizke vzburjenosti spadajo oznake *sadness*, *disgust* in *neutral*. V razred srednje vzburjenosti spadajo oznake *joy*, *happiness* in *amusement*. V razred visoke vzburjenosti spadajo oznake *surprise*, *fear*, *anger* in *anxiety*. Pri valenci uporabimo razrede neprijetna, nevtralna in prijetna valenca. V razred neprijetne valence spadajo oznake *fear*, *anger*, *disgust*, *sadness* in *anxiety*. V razred nevtralne valence spadajo oznaki *surprise* in *neutral*. V razred prijetne valence spadajo oznake *joy*, *happiness* in *amusement*.

Poglavje 3

Sorodna dela

To poglavje povzame sorodna dela, ki so neposredno povezana z našo nalogo. Osredotočimo se na prepoznavanje čustev iz podatkov sledilnika pogleda, podatkovno zbirko MAHNOB-HCI, grafovske nevronske mreže za časovno-prostorske podatke ter učenje predstavitev iz podatkov pogleda.

3.1 Prepoznavanje čustev iz podatkov sledilnika pogleda

3.1.1 Ročno oblikovane značilke

Podatki sledilnika pogleda se v prepoznavanju čustev uporabljajo kot vedenjski in psihofiziološki signal. Najpogosteje uporabljeni signali vključujejo lokacijo pogleda, značilke fiksacij in sakad, mežike, velikost zenice ter spremembe razdalje med očesom in sledilnikom pogleda [4, 6]. Iz teh signalov lahko izpeljemo ročno oblikovane značilke, kot so povprečna velikost zenice, trajanje fiksacij, število fiksacij, dolžina poti pogleda ali statistike porazdelitve koordinat pogleda. Takšni pristopi so razložljivi, vendar zahtevajo izbiro značilk in pogosto tudi dodatno predobdelavo signala.

3.1.2 Naučene predstavitve

Novejši pristopi namesto ročno oblikovanih značilk uporabljajo naučene predstavitve. Model v tem primeru prejme manj obdelan časovni signal in se sam nauči predstavitev, ki so uporabne za napovedno nalogo. Ciljne naloge v sorodnih delih so različne: klasifikacija diskretnega čustvenega razreda, napoved valence in vzburjenosti ter binarna klasifikacija čustvenega odziva.

3.2 Podatkovna zbirka MAHNOB-HCI

Podatkovna zbirka MAHNOB-HCI je večmodalna zbirka za prepoznavanje čustev in implicitno označevanje multimedijskih vsebin [5]. Vsebuje odzive udeležencev na čustvene video posnetke ter sinhrono zajete signale, med katerimi so obrazni video, zvok, fiziološki signali, EEG in podatki sledilnika pogleda. V tej nalogi uporabljamo samo podatke sledilnika pogleda, ker je osrednji cilj raziskati grafovsko predstavitev tega tipa časovnega signala.

3.2.1 Izvirni protokol za valenco in vzburjenost

Za našo nalogo je pomemben del zbirke, v katerem so udeleženci gledali čustvene video posnetke in po vsakem posnetku podali samoocene. V izvirnem članku so avtorji za prepoznavanje čustev med drugim poročali rezultate za 3-razredno klasifikacijo valence in vzburjenosti, pri čemer so razrede izpeljali iz poročane čustvene oznake. Enako formulacijo uporabimo tudi v tej nalogi, saj omogoča primerjavo z izhodiščnim protokolom podatkovne zbirke.

3.2.2 Razlika do naše eksperimentalne postavitve

Kljub temu neposredna primerjava med rezultati v izvirnem članku in našimi rezultati ni mogoča, saj avtorji uporabljajo ročno oblikovane značilke, izračunane iz celotnega odziva na posnetek. Naš pristop uporablja časovna okna surovih signalov pogleda in velikosti zenic, ki jih pretvorimo v grafe. Zato

je primerjava smiselna kot referenčni okvir za podatkovno zbirko in ciljno nalogo, ne kot ponovitev izvirnega eksperimenta.

3.3 Grafovske nevronske mreže za časovno-prostorske podatke

Grafovske nevronske mreže so primerne za podatke, pri katerih so pomembni odnosi med elementi [2, 3, 7]. Pri časovno-prostorskih podatkih lahko vozlišča predstavljajo meritve, lokacije ali druge osnovne elemente, povezave pa opisujejo prostorsko bližino, časovno zaporedje ali druge odnose med njimi. Časovno-prostorske grafovske nevronske mreže so se uveljavile predvsem pri nalogah, kjer podatki naravno nastopajo kot časovne vrste na grafu, na primer pri napovedovanju prometa [8].

3.3.1 Uporaba na oknih podatkov pogleda

V tej nalogi to idejo uporabimo na časovnih oknih podatkov sledilnika pogleda. Posamezne meritve znotraj okna predstavimo kot vozlišča. Časovne povezave opisujejo zaporedje meritev, prostorske povezave pa podobnost lokacij pogleda. S tem dobimo časovno-prostorski graf, ki je prilagojen strukturi podatkov in hkrati omogoča uporabo GNN za klasifikacijo celotnega okna.

3.4 Učenje predstavitev iz podatkov pogleda in GazeMAE

Poleg ročno oblikovanih značilk se pri podatkih pogleda pojavljajo tudi metode za samonadzorovano učenje predstavitev. Takšne metode poskušajo iz neoznačenih ali šibko označenih zaporedij pogleda naučiti vektorske predstavitve, ki jih lahko nato uporabimo pri različnih napovednih nalogah.

3.4.1 GazeMAE

GazeMAE je primer takšnega pristopa. Podatke pogleda obravnava kot zaporedja položajev in hitrosti ter z avtokodirniško arhitekturo uči mikro- in makro-predstavitve očesnih gibov [1].

GazeMAE v tej nalogi obravnavamo kot relevanten ne-grafovski predstavnik učenja predstavitev iz podatkov pogleda. Eksperimentalno ga vključimo kot ločeno procesno verigo:

$$\text{podatki} \rightarrow \text{GazeMAE} \rightarrow \text{predstavitev} \rightarrow \text{MLP klasifikator} \rightarrow \text{napoved.} \quad (3.1)$$

3.5 Položaj te naloge glede na sorodna dela

Ta naloga ne tekmuje neposredno z vsemi večmodalnimi metodami za prepoznavanje čustev. Večmodalni sistemi lahko uporabljajo EEG, fiziološke signale, obrazni video, zvok in podatke pogleda, zato rešujejo širši problem kot ta naloga. Naš fokus je ožji: zanima nas, ali lahko časovno-prostorska grafovska predstavitve izboljša klasifikacijo valence in vzburjenosti iz podatkov sledilnika pogleda.

Glavna primerjava je zato med grafovskimi in ne-grafovskimi modeli na enakih vhodnih oknih. Ne-grafovski modeli služijo kot kontrola, ki pokaže, koliko informacije je dostopne brez eksplicitne grafovske strukture. Grafovski modeli pa preverjajo, ali relacije med meritvami pogleda izboljšajo naučeno predstavitve okna.

Poglavje 4

Podatki in predobdelava

4.1 Podatkovna zbirka MAHNOB-HCI

4.1.1 Izvirna zbirka

V delu uporabljamo podatke iz podatkovne zbirke MAHNOB-HCI [5]. Gre za večmodalno zbirko, namenjeno raziskavam prepoznavanja čustev in implicitnega označevanja multimedijskih vsebin. Zbirka vsebuje dva glavna eksperimentalna sklopa: prepoznavanje čustvenih stanj iz odzivov na čustvene videoposnetke in implicitno označevanje na podlagi odzivov na pravilne oziroma napačne oznake pod sliko ali posnetkom. V tej nalogi uporabljamo samo prvi sklop, to je eksperiment vzbujanja čustev z videoposnetki.

Izvirni članek poroča o 30 rekrutiranih udeležencih, od katerih je bilo v analizi uporabljenih 27. Udeleženci P9, P12 in P15 so bili izključeni zaradi tehničnih težav oziroma nepopolnega zajema podatkov. V eksperimentu vzbujanja čustev so udeleženci gledali 20 čustveno vzbujujočih videoposnetkov. Pred vsakim čustvenim posnetkom je bil prikazan še kratek nevtralni posnetek, odziv nanj pa je bil shranjen ločeno. Po ogledu posameznega posnetka so udeleženci podali samoocene čustvene oznake, vznburjenosti, valence, dominantnosti in predvidljivosti.

Čeprav je MAHNOB-HCI večmodalna zbirka, v tej nalogi uporabljamo

izključno signale sledilnika pogleda. Podatki pogleda so bili v izvirnem eksperimentu zajeti s sledilnikom Tobii X120 pri frekvenci 60 Hz. Zajeti signali vključujejo smer pogleda, premer zenice, oznako fiksacije in razdaljo očesa do sledilnika. Ostalih modalnosti, kot so EEG, fiziološki signali in obrazni videoposnetki, v našem modeliranju ne uporabljamo.

4.1.2 Lokalni podnabor

Pri delu ne uporabljamo popolne izvirne večmodalne izdaje zbirke. Izvirna zbirka podatkov ni več javno dostopna, lokalno pa imamo na voljo podnabor, ki vsebuje podatke sledilnika pogleda in pripadajoče oznake. Zato lokalnega podnabora ne obravnavamo kot popolne rekonstrukcije izvirne zbirke, temveč kot preverljiv podnabor MAHNOB-HCI podatkov, ki vsebujejo podatke sledilnika pogleda za eksperiment vzbujanja čustev.

4.2 Ciljne oznake

4.2.1 Izvor čustvenih oznak

V eksperimentih ne napovedujemo posamezne čustvene oznake neposredno, temveč iz nje izpeljemo dve ločeni klasifikacijski nalogi: 3-razredno klasifikacijo valence in 3-razredno klasifikacijo vzburjenosti. Tako sledimo izvirnemu eksperimentalnemu protokolu zbirke MAHNOB-HCI in omogočimo primerjavo z objavljenimi rezultati. Numeričnih samoocen valence in vzburjenosti ne diskretiziramo z dodatnimi pragovi, temveč uporabimo preslikavo iz čustvenih oznak v razrede valence in vzburjenosti, prikazano v tabeli 4.1.

4.2.2 Preslikava v razrede valence in vzburjenosti

Oznake čustvenih stanj so pridobljene iz metapodatkov posameznega poskusa. Kadar so bila v datoteki `session.xml` prisotna vsa potrebna polja, uporabimo oznake iz XML metapodatkov. Pri stimulusnih poskusih z nepopolnimi XML metapodatki pretvorba uporabi nadomestni vir `Guide-Cut`. V

Tabela 4.1: Preslikava čustvenih oznak v 3-razredni nalogi valence in vzburjenosti.

Izvorna čustvena oznaka	Razred valence	Razred vzburjenosti
Nevtralno stanje	nevtralna	nizka
Žalost	negativna	nizka
Gnus	negativna	nizka
Veselje / sreča	pozitivna	srednja
Zabava	pozitivna	srednja
Presenečenje	nevtralna	visoka
Strah	negativna	visoka
Jeza	negativna	visoka
Tesnoba	negativna	visoka

eksperimentalnem cevovodu uporabljamo samo vrstice z veljavno izpeljano oznako.

TODO: Dodaj tabeli/sliki porazdelitve razredov za valenco in vzburjenost po končni tvorbi 10-sekundnih oken.

4.3 Priprava vhodnih signalov

4.3.1 Uporabljeni stolpci

Za vsak časovni vzorec uporabimo štiri osnovne signale sledilnika pogleda:

- horizontalno koordinato pogleda x_i ,
- vertikalno koordinato pogleda y_i ,
- velikost leve zenice $p_i^{(l)}$,
- velikost desne zenice $p_i^{(r)}$.

V trenutni implementaciji so to stolpci `x-avg`, `y-avg`, `pupil-size-left-avg` in `pupil-size-right-avg`. Koordinati pogleda predstavljata povprečen položaj pogleda med levim in desnim očesom, velikosti zenic pa sta ohranjeni ločeno. Čas t_i v sekundah uporabljamo pri konstrukciji časovnih povezav.

4.3.2 Čiščenje in filtriranje podatkov

Modeli ne uporabljajo neposredno surovih Tobii TSV datotek. Vir za eksperimentalni cevovod je obdelani predpomnilnik `data/processed/cached_hci_tagging_emotion.csv`. Ta nastane s pretvorbo izvornih Tobii izvozov in pripadajočih metapodatkov v skupno tabelarično obliko. Nato se kode veljavnosti sledilnika pogleda preslikajo v binarne indikatorje zaupanja. Za podatke MAHNOB-HCI zahtevamo veljaven signal levega in desnega očesa.

Kratke vrzeli v numeričnih signalih se interpolirajo, signala velikosti zenice pa se dodatno zgladita s kratkim drsečim povprečjem. Nato ohranimo samo eksperiment vzbujanja čustev in vrstice z veljavno oznako. Za učenje odstranimo vrstice brez osnovnih signalov pogleda ali zenic. V privzetem eksperimentalnem cevovodu dodatno uporabimo robustni filter osamelcev `q01-q99` na štirih osnovnih signalih.

4.4 Normalizacija

Po čiščenju so signali obdelani, vendar še niso standardizirani. Prva standardizacija se izvede šele po razdelitvi podatkov na učni, validacijski in testni fold.

4.4.1 Normalizacija pri grafovskih modelih

Pri grafovskem modelu se `StandardScaler` prilagodi samo na matrikah značilk vozlišč iz grafov učnega folda. Isti scaler se nato uporabi za grafe učnega, validacijskega in testnega folda.

4.4.2 Normalizacija pri tabelarnih modelih

Pri tabelarnih osnovnih modelih se najprej tvorijo časovna okna in agregirane tabelarne značilke, nato se `StandardScaler` prilagodi samo na matriki `X_train`.

4.4.3 Preprečevanje uhajanja informacij

S tem preprečimo uhajanje informacij iz validacijskih in testnih foldov v učno množico.

4.5 Segmentacija v časovna okna

4.5.1 Dolžina okna

Časovno vrsto razdelimo na neprekrivajoča se časovna okna dolžine $T = 10$ s. Vsako uporabno časovno okno predstavlja en učni primer. Pri ne-grafovskih osnovnih modelih ga pretvorimo v tabelarni vektor značilk, pri grafovskem modelu pa v časovno-prostorski graf.

4.5.2 Dodelitev oznake oknu

Oznaka okna je določena s parom udeleženec–posnetek, saj vsa okna istega označenega oglada videoposnetka podedujejo isto čustveno oznako.

4.5.3 Minimalno število vzorcev

Pri vzorčni frekvenci 60 Hz bi 10-sekundno okno brez manjkajočih vrednosti vsebovalo 600 vzorcev. Zaradi čiščenja, odstranjevanja neveljavnih vzorcev in filtriranja je dejansko število vzorcev v oknih manjše. Po dodatnem filtru osamelcev q01–q99 dobimo 5158 uporabnih 10-sekundnih časovnih oken.

4.6 Predhodni poskus z zbirko eSEEd_v2

Pred prehodom na MAHNOB-HCI je bil del razvoja izveden na podatkovni zbirki eSEEd_v2. Ta del ni osrednji eksperimentalni prispevek naloge, temveč služi kot zgodovinska motivacija za spremembo podatkovne zbirke. Začetni poskusi so pokazali težave z zanesljivostjo oznak, kakovostjo signalov in stabilnostjo učenja. Zato smo glavno eksperimentalno evalvacijo izvedli na podatkovni zbirki MAHNOB-HCI, ki ima jasnejši protokol označevanja in uporabnejši lokalni podnabor signalov sledilnika pogleda.

Tabela 4.2: Zmanjševanje količine podatkov od izvirne zbirke MAHNOB-HCI do končnih časovnih oken, uporabljenih v eksperimentalnem cevovodu.

Korak	Vrstice	Udeleženci	Opis
Izvirna zbirka MAHNOB-HCI	–	30	Večmodalna zbirka; izvirni članek v analizi uporabi 27 udeležencev.
Lokalni podnabor podatkov sledilnika pogleda	3 797 165	24	Lokalna kopija eksperimenta vzbujanja čustev s podatki sledilnika pogleda in oznakami.
Po izključitvi P9, P12 in P15	3 535 842	22	P15 v lokalnem podnaboru ni prisoten, zato sta odstranjena le P9 in P12.
Veljavno označene vrstice	2 995 632	22	Ohranjeni so samo označeni podatki, uporabljeni za učenje modelov čustvenih stanj.
Pripravljeno za učenje	2 814 005	22	Odstranjene so vrstice brez ključnih signalov pogleda ali zenic.
Po filtru osamelcev q01–q99	2 639 048	22	Robustno filtriranje štirih osnovnih signalov pogleda in zenic.
Uporabna 10-sekundna časovna okna	5 158	22	Vsako okno postane en učni primer oziroma graf.

Poglavje 5

Grafovski predstavitev podatkov sledilnika pogleda

To poglavje je eno osrednjih metodoloških poglavij naloge. Njegov namen je natančno opisati, kako iz časovnega okna meritev sledilnika pogleda nastane graf, ki ga uporabimo kot vhod v grafovsko nevronske mrežo.

5.1 Učni vzorec kot graf

5.1.1 Definicija grafa

Vsak učni vzorec je časovno okno meritev sledilnika pogleda. Okno pretvorimo v graf

$$G = (V, E_t^+, E_t^-, E_s, E_f), \quad (5.1)$$

kjer je V množica vozlišč, E_t^+ množica časovnih povezav naprej, E_t^- množica časovnih povezav nazaj, E_s množica prostorskih povezav in E_f množica fiksacijskih povezav.

Vozlišča predstavljajo zaporedne meritve sledilnika pogleda znotraj časovnega okna. Povezave med vozlišči opisujejo različne relacije med meritvami: časovno zaporednost, prostorsko bližino pogleda in pripadnost isti fiksaciji. En graf predstavlja en učni vzorec.

5.1.2 Oznaka grafa

Vsak graf označimo z oznako pripadajočega časovnega okna. V nalogi to oznako uporabimo pri ločenih klasifikacijskih nalogah valence in vzburjenosti.

5.2 Vozlišča

5.2.1 Definicija vozlišča

Vsako vozlišče predstavlja eno meritev sledilnika pogleda znotraj časovnega okna:

$$v_i \leftrightarrow \mathbf{x}_i. \quad (5.2)$$

Če okno vsebuje n veljavnih meritev, potem graf vsebuje n vozlišč. V osnovni nastavitvi uporabljamo 10-sekundna okna. Ker so meritve vzorčene s frekvenco 60 Hz, je pričakovano število meritev v polnem oknu

$$n_{\text{exp}} = 10 \text{ s} \cdot 60 \text{ Hz} = 600. \quad (5.3)$$

Grafovski predstavitev naravno podpira spremenljivo število vozlišč. Grafovski nevronski mreži namreč deluje na množici vozlišč in povezav, končno predstavitev celotnega grafa pa pridobi z agregacijo vozliščnih predstavitev.

5.2.2 Značilke vozlišč

Vektor značilk vozlišča je

$$\mathbf{x}_i = [t_i, x_i, y_i, p_{l,i}, p_{r,i}, d_i, f_{dur,i}], \quad (5.4)$$

kjer je t_i čas, ki je pretekel od začetka okna, x_i in y_i sta koordinati pogleda, $p_{l,i}$ in $p_{r,i}$ sta velikosti leve in desne zenice, d_i je razdalja med sledilnikom in udeleženci očmi, $f_{dur,i}$ pa trajanje fiksacije, ki ji pripada i -ta meritev.

Časovna značilka

Časovna značilka t_i modelu poda položaj meritve znotraj okna.

Koordinate pogleda

Koordinati x_i in y_i opisujeta položaj pogleda in sta uporabljeni tudi pri konstrukciji prostorskih povezav.

Značilke zenice

Značilki $p_{l,i}$ in $p_{r,i}$ opisujeta velikost leve in desne zenice.

Razdalja do sledilnika in fiksacije

Značilki d_i in $f_{dur,i}$ opisujeta razdaljo do sledilnika ter trajanje fiksacije pripadajoče meritve.

TODO: Preveri, kako so kodirane meritve, ki ne pripadajo nobeni fiksaciji. Če je vrednost $f_{dur,i} = 0$, to eksplicitno dodaj.

5.3 Povezave

5.3.1 Časovne povezave

Časovne povezave povezujejo zaporedne meritve znotraj lokalnega časovnega konteksta. Naj bodo vozlišča v posameznem oknu urejena po času, tako da je v_i i -ta meritev v časovnem zaporedju. Parameter $k_t \in \mathbb{N}$ določa število časovnih sosedov na vsako stran in ne časovnega radija v sekundah. V trenutnih poskusih uporabljamo $k_t = 2$.

Povezave naprej in nazaj

Ločimo usmerjene časovne povezave naprej in nazaj:

$$E_t^+ = \{(v_i, v_j) : 1 \leq j - i \leq k_t\}, \quad (5.5)$$

$$E_t^- = \{(v_i, v_j) : 1 \leq i - j \leq k_t\}. \quad (5.6)$$

Povezave v E_t^+ potekajo od prejšnjih proti kasnejšim meritvam, povezave v E_t^- pa od kasnejših proti prejšnjim meritvam. Ločitev smeri je smiselna, ker ima vrstni red očesnega gibanja pomen.

Parameter k_t

Parameter k_t določa velikost lokalnega časovnega konteksta in s tem število povezav, ki jih dodamo okrog posamezne meritve.

TODO: Dodaj sliko grafa s časovnimi povezavami.

5.3.2 Prostorske povezave

Prostorske povezave so neusmerjene povezave, ki povezujejo meritve s podobnim položajem pogleda znotraj istega časovnega okna. Za vsako vozlišče poiščemo k_s najbližjih sosedov v prostoru koordinat pogleda (x, y) .

Najbližji sosedi v prostoru pogleda

Prostorsko razdaljo med meritvama i in j definiramo kot

$$d_{ij}^{(s)} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}. \quad (5.7)$$

Povezava (v_i, v_j) je dodana, če je v_j med k_s najbližjimi prostorskimi sosedi vozlišča v_i .

Simetrizacija povezav

Ker povezave obravnavamo kot neusmerjene, vsaki povezavi (v_i, v_j) dodamo tudi povezavo (v_j, v_i) .

TODO: Dodaj vrednost k_s , ko bo končna konfiguracija določena, in sliko grafa s prostorskimi povezavami.

5.3.3 Fiksacijske povezave

Fiksacijske povezave povezujejo meritve, ki pripadajo isti zaznani fiksaciji. Pripadnost fiksaciji določimo z identifikatorjem fiksacije.

Redčenje povezav znotraj fiksacije

Znotraj posamezne fiksacije ne povežemo vseh vozlišč med seboj, saj bi to povzročilo veliko število povezav pri daljših fiksacijah. Namesto tega uporabimo redkejšo konstrukcijo, ki ohrani informacijo o pripadnosti isti fiksaciji, vendar zmanjša prostorsko in časovno zahtevnost konstrukcije grafa.

TODO: Uskladi opis fiksacijskih povezav s finalno implementacijo in ablacijsko zasnovno.

5.4 Uteži povezav

Uteži povezav omogočajo, da model razlikuje med bližnjimi in oddaljenimi povezavami.

5.4.1 Značilke povezav

V trenutni smeri razvoja uporabimo naučene uteži povezav, izračunane iz značilk relacije:

$$w_{ij} = f_{\theta}(\mathbf{r}_{ij}), \quad (5.8)$$

kjer je $\mathbf{r}_{ij}$ vektor značilk povezave, f_{θ} pa večslojni perceptron. Za prostorske povezave so priporočene značilke $[t_i, t_j, \Delta t, \Delta x, \Delta y, d_{ij}]$, za časovne povezave pa dodatno še značilka smeri.

5.4.2 Normalizacija uteži

TODO: Na koncu uskladi enačbo z dejansko implementacijo normalizacije podpisanih vhodnih uteži po ciljnem vozlišču.

5.5 Heterogena grafovski predstavitev

5.5.1 Tipi relacij

Ker različne povezave opisujejo različne odnose, graf obravnavamo kot heterogen graf z več tipi povezav. Prostorske povezave, časovne povezave naprej in

časovne povezave nazaj imajo ločene relacije.

5.5.2 Zakaj ločimo relacije

To omogoča, da model za vsak tip odnosa uporablja ločeno transformacijo oziroma ločeno funkcijo posredovanja sporočil.

5.6 Statistika grafov

5.6.1 Število vozlišč in povezav

Tabela 5.1: TODO: Povzetek statistike grafov za privzeto 10-sekundno okno.

Količina	Vrednost
Mediana števila vozlišč	TODO
Povprečno število vozlišč	TODO
Mediana števila prostorskih povezav	TODO
Mediana števila časovnih povezav naprej	TODO
Mediana števila časovnih povezav nazaj	TODO
Povprečna gostota grafa	TODO

5.6.2 Računska zahtevnost

TODO: Dodaj statistiko za 10 s okna, statistiko za 5 s okna, eno sliko primera grafa in komentar računske zahtevnosti.

Poglavje 6

Modeli

V tem poglavju predstavimo modele, ki jih primerjamo v eksperimentalni evalvaciji. Modele razdelimo na ne-grafovske osnovne modele, model GazeMAE + MLP in grafovske modele.

6.1 Ne-grafovski osnovni modeli

Grafovske modele primerjamo z ne-grafovskimi modeli, ki ne uporabljajo eksplicitne strukture grafa. Ti modeli služijo kot kontrola, ali grafavska predstavitev dejansko prispeva informacijo.

6.1.1 Primerjani modeli

Uporabljeni osnovni modeli so:

- večinski klasifikator,
- SVM,
- LightGBM,
- MLP.

TODO: Dodaj, kako iz časovnega okna pripraviš vhod za baseline modele, katere agregirane/window značilke uporabiš, ali baseline modeli uporabljajo iste signale kot GNN, hiperparametre in jasno razlago enakih splitov.

6.2 GazeMAE + MLP

Model GazeMAE + MLP uporabimo kot primerjavo s sodobnim pristopom učenja predstavitev iz podatkov pogleda.

6.2.1 Procesna veriga

Pipeline je:

$$\text{podatki} \rightarrow \text{GazeMAE} \rightarrow \text{predstavitev} \rightarrow \text{MLP} \rightarrow \text{napoved}. \quad (6.1)$$

TODO: Dopolni opis zamrznjenih prednaučenih GazeMAE enkoderjev, vhodnega formata, dimenzije embeddinga, arhitekture MLP klasifikatorja in omejitev reprodukcije.

6.3 Grafovski osnovni modeli

Za oceno vpliva grafovske arhitekture primerjamo več grafovskih modelov. Osnovni grafovski primerjavi sta GCN in GAT.

6.3.1 GCN

GCN predstavlja preprost model agregacije sosedov.

6.3.2 GAT

GAT uporablja mehanizem pozornosti za uteževanje prispevkov sosednjih vozlišč.

TODO: Dodaj kratek opis GCN, kratek opis GAT in ali uporabljata isto grafovsko konstrukcijo kot finalni model.

6.4 Predlagani prostorsko-časovni heterogeni GNN

Finalni model temelji na prostorsko-časovni heterogeni grafovski nevronske mreži. Model ločeno obravnava prostorske povezave, časovne povezave naprej in časovne povezave nazaj. S tem lahko za različne tipe odnosov uporablja različne parametre.

6.4.1 Pregled arhitekture

Osnovni potek modela je:

$$X \rightarrow f_{\text{pre}} \rightarrow f_{\text{GNN}} \rightarrow f_{\text{fuzija}} \rightarrow \text{READOUT} \rightarrow f_{\text{head}}. \quad (6.2)$$

TODO: Dodaj arhitekturne detajle: preprocess MLP, LayerNorm, residual connections, GELU, dropout, edge weights, število plasti, hidden dimension in ločeno obravnavo relacij.

6.4.2 Fuzija prostorskih in časovnih predstavitev

Po posredovanju sporočil po različnih tipih povezav dobimo predstavitve, ki izvirajo iz prostorskih in časovnih relacij. Te predstavitve združimo na ravni vozlišč s konkatenacijo in MLP fuzijo:

$$\mathbf{h}_i = f_{\text{fuzija}} \left(\left[\mathbf{h}_i^{(s)} \parallel \mathbf{h}_i^{(t+)} \parallel \mathbf{h}_i^{(t-)} \right] \right), \quad (6.3)$$

kjer $\parallel$ označuje konkatenacijo, $\mathbf{h}_i^{(s)}$ prostorsko predstavitev, $\mathbf{h}_i^{(t+)}$ časovno predstavitev naprej in $\mathbf{h}_i^{(t-)}$ časovno predstavitev nazaj.

6.4.3 Združevanje v predstavitev grafa

Ker napovedujemo oznako celotnega okna, moramo predstavitve vozlišč združiti v predstavitev grafa. Osnovna možnost je povprečno združevanje:

$$\mathbf{h}_G^{\text{mean}} = \frac{1}{|V|} \sum_{v \in V} \mathbf{h}_v. \quad (6.4)$$

TODO: Določi finalno pooling strategijo: mean pooling, mean+max pooling ali attention pooling.

6.4.4 Napovedna glava in učenje

Predstavitev grafa $\mathbf{h}_G$ vstopi v klasifikacijsko glavo, ki napove enega izmed treh razredov valence oziroma vzburjenja. Za 3-razredno klasifikacijo uporabimo navzkrižno entropijo:

$$\mathcal{L} = - \sum_{c=1}^3 y_c \log \hat{y}_c. \quad (6.5)$$

TODO: Dodaj, ali treniraš ločena modela za valenco in vzburjenje, class weights, optimizator, learning rate, batch size, število epoh, early stopping, seed-e in strojno opremo.

6.4.5 Diagnostika predstavitev

Poleg končnih klasifikacijskih metrik spremljamo tudi notranje predstavitve modela. Namen diagnostike je preveriti, ali model ohranja raznolikost predstavitev ali pa pride do kolapsa.

TODO: Dodaj statistike variance, kosinusne podobnosti, razpona logitov in razlago, kako diagnostika pomaga interpretirati oversmoothing.

Poglavje 7

Eksperimentalni protokol

7.1 Eksperimentalne naloge

7.1.1 Valenca in vzburjenost

V nalogi obravnavamo dve glavni klasifikacijski nalogi:

1. 3-razredna klasifikacija valence;
2. 3-razredna klasifikacija vzburjenja.

Obe nalogi obravnavamo enakovredno.

TODO: Dodaj definicijo treh razredov pri valenci in vzburjenju ter pojasni, zakaj ne poročáš regresije ali emotion-id multiclass kot glavnega rezultata.

7.2 Validacijska protokola

7.2.1 Definicija protokolov

Uporabimo dva validacijska protokola:

- **Subject LOO:** v vsakem foldu je en subjekt testna množica, ostali subjekti pa učna množica.

- **Recording LOO:** v vsakem foldu je en posnetek oziroma stimulus testna množica, ostali posnetki pa učna množica.

7.2.2 Razlika med protokoloma

Prvi protokol meri posploševanje na nove udeležence, drugi pa posploševanje na nove posnetke. Kombinirane delitve po subjektih in posnetkih v tej nalogi ne uporabljamo, ker bi bila računsko bistveno dražja in bi presegla obseg diplomske naloge.

TODO: Dodaj natančno definicijo foldov, število foldov in opis validacijske množice ter preprečevanja uhajanja informacij.

7.3 Metrike

7.3.1 Zbrane metrike

Za vsako nalogo in vsak validacijski protokol zbiramo naslednje metrike:

- balanced accuracy,
- accuracy,
- macro-F1,
- weighted-F1,
- AUC,
- confusion matrix.

TODO: Dopolni glavne metrike, poudari balanced accuracy in macro-F1, opiši one-vs-rest macro AUC in način poročanja $\text{mean} \pm \text{std}$ čez folde.

7.4 Glavna primerjava modelov

7.4.1 Primerjani modeli

Glavna primerjava vključuje naslednje modele:

- večinski klasifikator,
- SVM,
- LightGBM,
- MLP,
- GazeMAE + MLP,
- GCN,
- GAT,
- predlagani prostorsko-časovni heterogeni GNN.

TODO: Dodaj tabelo konfiguracij modelov, enake vhodne podatke za primerljive modele, iste splitte in isti način poročanja metrik.

7.5 Ablacijska študija

Ablacijska študija bo izvedena po zaklepu finalne arhitekture. Namen ablacijske študije je preveriti, katere komponente grafovske predstavitve in modela dejansko prispevajo k rezultatu.

7.5.1 Predvidene ablacijske nastavitve

Predvidene ablacijske nastavitve so:

- odstranitev značilke zenice,
- odstranitev prostorskih povezav,

- odstranitev časovnih povezav,
- izklop uteži povezav,
- uporaba 5-sekundnih oken namesto 10-sekundnih,
- odstranitev MLP fuzije prostorskih in časovnih predstavitev,
- primerjava različnih pooling strategij.

TODO: Ko bo model končan, izberi največ 5–7 ablations in rezultate predstavi v eni glavni tabeli.

Poglavje 8

Rezultati

TODO: To poglavje napiši šele po glavnih eksperimentih. Ne mešaj rezultatov iz eSEEd_v2 z glavno MAHNOB-HCI evalvacijo, razen če jih daš v dodatek ali kratko motivacijo.

8.1 Porazdelitev razredov

8.1.1 Valenca

TODO: Dodaj tabelo razredov za valenco po končni tvorbi oken.

8.1.2 Vzburjenost

TODO: Dodaj tabelo razredov za vzburjenost, komentar neuravnoteženosti in večinski baseline kot referenčno točko.

8.2 Rezultati za 3-razredno valenco

8.2.1 Subject LOO

Tabela 8.1: TODO: Rezultati za 3-razredno klasifikacijo valence pri subject LOO.

Model	Bal. acc.	Acc.	Macro-F1	Weighted-F1	AUC
Majority	TODO	TODO	TODO	TODO	TODO
SVM	TODO	TODO	TODO	TODO	TODO
LightGBM	TODO	TODO	TODO	TODO	TODO
MLP	TODO	TODO	TODO	TODO	TODO
GazeMAE + MLP	TODO	TODO	TODO	TODO	TODO
GCN	TODO	TODO	TODO	TODO	TODO
GAT	TODO	TODO	TODO	TODO	TODO
ST-HeteroGNN	TODO	TODO	TODO	TODO	TODO

8.2.2 Recording LOO

Tabela 8.2: TODO: Rezultati za 3-razredno klasifikacijo valence pri recording LOO.

Model	Bal. acc.	Acc.	Macro-F1	Weighted-F1	AUC
Majority	TODO	TODO	TODO	TODO	TODO
SVM	TODO	TODO	TODO	TODO	TODO
LightGBM	TODO	TODO	TODO	TODO	TODO
MLP	TODO	TODO	TODO	TODO	TODO
GazeMAE + MLP	TODO	TODO	TODO	TODO	TODO
GCN	TODO	TODO	TODO	TODO	TODO
GAT	TODO	TODO	TODO	TODO	TODO
ST-HeteroGNN	TODO	TODO	TODO	TODO	TODO

8.2.3 Interpretacija rezultatov

TODO: Po tabelah napiši, kateri model je najboljši, ali GNN premaga najboljši ne-grafovski baseline, ali je razlika med subject LOO in recording LOO velika ter interpretacijo confusion matrix.

8.3 Rezultati za 3-razredno vzburjenje

8.3.1 Subject LOO

Tabela 8.3: TODO: Rezultati za 3-razredno klasifikacijo vzburjenja pri subject LOO.

Model	Bal. acc.	Acc.	Macro-F1	Weighted-F1	AUC
Majority	TODO	TODO	TODO	TODO	TODO
SVM	TODO	TODO	TODO	TODO	TODO
LightGBM	TODO	TODO	TODO	TODO	TODO
MLP	TODO	TODO	TODO	TODO	TODO
GazeMAE + MLP	TODO	TODO	TODO	TODO	TODO
GCN	TODO	TODO	TODO	TODO	TODO
GAT	TODO	TODO	TODO	TODO	TODO
ST-HeteroGNN	TODO	TODO	TODO	TODO	TODO

8.3.2 Recording LOO

Tabela 8.4: TODO: Rezultati za 3-razredno klasifikacijo vzburjenja pri recording LOO.

Model	Bal. acc.	Acc.	Macro-F1	Weighted-F1	AUC
Majority	TODO	TODO	TODO	TODO	TODO
SVM	TODO	TODO	TODO	TODO	TODO
LightGBM	TODO	TODO	TODO	TODO	TODO
MLP	TODO	TODO	TODO	TODO	TODO
GazeMAE + MLP	TODO	TODO	TODO	TODO	TODO
GCN	TODO	TODO	TODO	TODO	TODO
GAT	TODO	TODO	TODO	TODO	TODO
ST-HeteroGNN	TODO	TODO	TODO	TODO	TODO

8.4 Primerjava validacijskih protokolov

8.4.1 Posploševanje na nove subjekte

TODO: Dodaj primerjavo rezultatov pri subject LOO.

8.4.2 Posploševanje na nove posnetke

TODO: Dodaj primerjavo rezultatov pri recording LOO in razlago razlike med protokoloma.

8.5 Ablacijska študija

8.5.1 Vpliv vhodnih signalov in povezav

Tabela 8.5: TODO: Ablacijska študija finalnega modela.

Nastavitev	Bal. acc.	Acc.	Macro-F1	Weighted-F1	AUC
Finalni model	TODO	TODO	TODO	TODO	TODO
Brez pupil značilk	TODO	TODO	TODO	TODO	TODO
Brez prostorskih povezav	TODO	TODO	TODO	TODO	TODO
Brez časovnih povezav	TODO	TODO	TODO	TODO	TODO
Brez uteži povezav	TODO	TODO	TODO	TODO	TODO
5 s okna	TODO	TODO	TODO	TODO	TODO
Brez MLP fuzije	TODO	TODO	TODO	TODO	TODO

8.6 Analiza notranjih predstavitev modela

8.6.1 Varianca in podobnost predstavitev

TODO: Dodaj graf/tabelo variance predstavitev po plasteh, kosinusno podobnost, razpon logitov in komentar kolapsa predstavitev.

8.7 Analiza napak

8.7.1 Matrike zmede

TODO: Dodaj confusion matrix za najboljši model in najboljši baseline ter analizo najpogostejših zamenjav razredov.

Poglavje 9

Diskusija

9.1 Ali grafovska predstavitev pomaga?

TODO: Odgovori neposredno: ali finalni GNN premaga ne-grafovske baseline modele; če jih ne premaga, ali vseeno pokaže smiselno vedenje; pri kateri nalogi je graf najbolj koristen; ali graf prispeva več pri subject LOO ali recording LOO.

9.2 Vloga časovnih in prostorskih povezav

TODO: Interpretiraj ablations: časovne povezave, prostorske povezave, forward/backward temporal separation, edge weights in kaj to pomeni za razumevanje eye-tracking signalov.

9.3 Primerjava z GazeMAE

TODO: Povej, ali GazeMAE + MLP premaga baseline modele, ali premaga GNN, ali primerjava kaže, da je self-supervised representation learning uporabna smer, in katere so omejitve reprodukcije oziroma implementacije.

9.4 Primerjava z izvirnim MAHNOB-HCI pristopom

TODO: Povej previdno: izvirni paper uporablja drugačne ročno oblikovane eye-gaze značilke, drugačen pipeline izbire značilk in SVM; primerjava je metodološko motivacijska, ne neposredna reprodukcija.

9.5 Omejitve

Glavne omejitve naloge so:

- uporaba ene glavne podatkovne zbirke;
- subjektivnost čustvenih oznak;
- omejitev na eye-tracking signale brez drugih fizioloških modalnosti;
- občutljivost grafovske konstrukcije na hiperparametre;
- računska zahtevnost validacije z LOO protokoli;
- možnost prekomernega glajenja v grafovskih modelih.

9.6 Možnosti nadaljnjega dela

Možne smeri nadaljnjega dela vključujejo:

- učenje povezav namesto ročne konstrukcije grafa;
- uporabo grafovskih transformerjev;
- samonadzorovano predtreniranje na neoznačenih eye-tracking signalih;
- razvoj grafovskega foundation modela za podatke pogleda;
- razširitev na večmodalne fiziološke podatke;
- evalvacijo na več podatkovnih zbirkah.

Poglavje 10

Zaključek

TODO: Zaključek napiši čisto na koncu. Struktura:

- en odstavek: kaj je bil problem;
- en odstavek: kaj si naredil;
- en odstavek: glavni rezultati;
- en odstavek: kaj rezultati pomenijo;
- en odstavek: omejitve in prihodnje delo.

V diplomski nalogi smo obravnavali uporabo grafovskih nevronske mreže za prepoznavo afektivnih stanj iz podatkov sledilnika pogleda. Časovna okna meritev smo predstavili kot prostorsko-časovne grafe, v katerih vozlišča predstavljajo posamezne meritve, povezave pa časovne in prostorske odnose med njimi. Predlagani pristop smo ovrednotili na podatkovni zbirki MAHNOB-HCI pri 3-razredni klasifikaciji valence in vzburjenja.

TODO: Ta odstavek po rezultatih zamenjaj z dejanskimi ugotovitvami: kateri model je najboljši, ali graf pomaga, kateri del grafa je najbolj pomemben in kaj je glavna omejitev.

Dodatek A

Dodatni rezultati

TODO: Sem dodaj dodatne tabele po foldih, rezultate manj pomembnih modelov in rezultate, ki niso šli v glavno besedilo.

Dodatek B

Hiperparametri

TODO: Dodaj tabelo hiperparametrov za baseline modele, tabelo hiperparametrov za GNN modele, finalni config in search space, če delaš hyperparameter search.

Dodatek C

Dodatne vizualizacije grafov

TODO: Dodaj primer 10 s grafa, primer 5 s grafa, vizualizacijo spatial edges in vizualizacijo temporal edges.

Dodatek D

Diagnostika predstavitev modela

TODO: Dodaj variance po plasteh, kosinusne podobnosti, logit distributions in dodatne slike kolapsa predstavitev.

Dodatek E

Zgodovinski poskusi na eSEEd_v2

TODO: Če želiš ohraniti eSEEd_v2 rezultate, jih daj sem: kratka motivacija, glavne težave, zakaj ni glavni dataset, brez pretiranega širjenja glavne zgodbe.

Literatura

- [1] Louise Gillian C. Bautista in Prospero C. Naval. „GazeMAE: General Representations of Eye Movements Using a Micro-Macro Autoencoder“. V: *2020 25th International Conference on Pattern Recognition (ICPR)*. IEEE, 2021, str. 7004–7011. DOI: 10.1109/ICPR48806.2021.9412761.
- [2] Justin Gilmer in sod. „Neural Message Passing for Quantum Chemistry“. V: *Proceedings of the 34th International Conference on Machine Learning*. Zv. 70. Proceedings of Machine Learning Research. PMLR, 2017, str. 1263–1272.
- [3] Thomas N. Kipf in Max Welling. „Semi-Supervised Classification with Graph Convolutional Networks“. V: *International Conference on Learning Representations*. 2017. URL: <https://openreview.net/forum?id=SJU4ayYgl>.
- [4] Jia Zheng Lim, James Mountstephens in Jason Teo. „Emotion Recognition Using Eye-Tracking: Taxonomy, Review and Current Challenges“. V: *Sensors* 20.8 (2020), str. 2384. DOI: 10.3390/s20082384.
- [5] Mohammad Soleymani in sod. „A Multimodal Database for Affect Recognition and Implicit Tagging“. V: *IEEE Transactions on Affective Computing* 3.1 (2012), str. 42–55. DOI: 10.1109/T-AFFC.2011.25.
- [6] Paweł Tarnowski in sod. „Eye-Tracking Analysis for Emotion Recognition“. V: *Computational Intelligence and Neuroscience* 2020 (2020), str. 2909267. DOI: 10.1155/2020/2909267.

-
- [7] Petar Veličković in sod. „Graph Attention Networks“. V: *International Conference on Learning Representations*. 2018. URL: <https://openreview.net/forum?id=rJXMpikCZ>.
 - [8] Bing Yu, Haoteng Yin in Zhanxing Zhu. „Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting“. V: *Proceedings of the Twenty-Seventh International Joint Conference on Artificial Intelligence*. International Joint Conferences on Artificial Intelligence Organization, 2018, str. 3634–3640. DOI: 10.24963/ijcai.2018/505.